

MODELO LINEAL MULTIPLE

REPASO:

$$y_i = \theta_0 + \theta_1 X_{i,1} + \dots + \theta_{p-1} X_{i,p-1} + \varepsilon_i$$

$$\underbrace{Y}_{n \times 1} = \underbrace{X}_{n \times p} \underbrace{\theta}_{p \times 1} + \underbrace{\varepsilon}_{n \times 1}$$

- $\mathbb{E}(\varepsilon_i) = 0$
- $\text{Var}(\varepsilon_i) = \sigma^2$ (homocedástica)
- ε_i son indep e indep de las covariables $X_{i,1}, \dots, X_{i,1-p}$
- $\varepsilon_i \sim N(0, \sigma^2)$
- $\hat{\beta} = (X^t X)^{-1} X^t Y$ siempre que $X^t X$ tenga inversa
- $\mathbb{E}(\varepsilon) = 0$
- $\text{Var}(\varepsilon) = \Sigma_{\varepsilon} = \sigma^2 I$
- $\mathbb{E}(Y) = X\beta$
- $\text{Var}(Y) = \sigma^2 I$

Introducción a la Estadística y Ciencia de Datos

1. Para los bebés de bajo peso al nacer, se encontró una relación lineal significativa entre la presión sistólica y la edad gestacional. Los datos están en el archivo “bajoPeso.txt” y fueron generados artificialmente. Las mediciones de presión sistólica están guardadas bajo el nombre `presSist`, y las correspondientes edades gestacionales bajo `edadG`. También en ese archivo figuran los datos de `apgar5`, el índice Apgar a los 5 minutos para cada bebe recién nacido. El índice Apgar es un indicador del estado general de salud del bebe a los 5 minutos de haber nacido; aunque en realidad es una medida ordinal que se la suele tomar como si fuera continua.
 - a) Realizar un diagrama de dispersión del índice Apgar contra la presión sistólica. ¿Parece haber una relación lineal entre estas dos variables?
 - b) Usando la presión sistólica como variable respuesta y la edad gestacional y el índice Apgar como variables explicativas, ajustar el modelo lineal $Y = \beta_0 + \beta_1 \cdot \text{edadG} + \beta_2 \cdot \text{apgar5} + \epsilon$. Brindar todos los coeficientes estimados e interpretarlos.
 - c) ¿Cuál es la presión media estimada para la población de bebés de bajo peso cuya edad gestacional es 31 semanas y cuyo índice Apgar es 7?
 - d) Construir un intervalo de confianza de nivel 0,95 para β_1 . Calcular la estimación por intervalo con el conjunto de datos brindados. Identificar si los valores calculados aparecen en la salida de R.
 - e) Decidir si la estimación de β_1 es estadísticamente significativa. Indicar las hipótesis que se contrastan, el estadístico del test y la región de rechazo. Hallar el p -valor. Identificar si los valores calculados aparecen en la salida de R.
 - f) Repetir los dos incisos anteriores para β_2 .
 - g) Decidir si la relación lineal es estadísticamente significativa, justificando. Indicar las hipótesis que se contrastan, el estadístico del test y la región de rechazo. ¿Cómo se calcula el p -valor en este caso? Identificar si los valores calculados aparecen en la salida de R. Interpretar.
 - h) ¿Qué supuesto adicional a los hechos en el ítem b) necesita para calcular este intervalo?
 - i) Considere nuevamente un bebé de bajo peso cuya edad gestacional es 31 semanas y cuyo índice Apgar es 7.
 - 1) Construya un intervalo de confianza del 0,95 para la presión sistólica media poblacional dadas estas características.
 - 2) Construya un intervalo de predicción del 0,95 para la presión sistólica de un nuevo bebé en particular con estas características.
 - j) Comentar la magnitud de R^2 .

2. a) Realizar una simulación para verificar que es correcto el nivel de los tests de hipótesis para los parámetros individuales (sin contar el intercept). Considerar el siguiente modelo lineal:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \epsilon$$

donde $\beta_0 = 12$, $\beta_1 = 0$, $\beta_2 = 0$, $\sigma = 7$ y x_1 y x_2 son los datos del ejercicio anterior. Calcular el nivel empírico de los tests. ¿Qué proporción de veces se rechaza alguna de las dos hipótesis nulas?

- b) ¿Qué ocurre si agrego más covariables con coeficiente igual a 0?

$$1) r_i = y_i - \hat{y}_i$$

$$b) \hat{y} = 12.65 + 1.06 \cdot \text{edad6} + 3.05 \cdot \text{apgar5}$$

PresSist

$$c) \hat{y}_{\text{obs}} = 12.65 + 1.06 \cdot 31 + 3.05 \cdot 7 \cong 67.1$$

$$d) Y \sim N_n(X\theta, \sigma^2 I)$$

$$i) \hat{\theta} \sim N_p(\theta, \sigma^2 (X^T X)^{-1})$$

$$T_j = \frac{\hat{\theta}_j - \theta_j}{\underbrace{\hat{s}_d(\hat{\theta}_j)}_{= s \sqrt{d_{jj}}}} \sim t_{n-p}$$

#parametros
#obs

• $\hat{\theta}_j$ es la estimación

$$s = \sqrt{\frac{1}{n-p} \sum (y_i - \hat{y}_i)^2}$$

• d_{jj} es el j -ésimo elem diagonal de $(X^T X)^{-1}$

$$IC(\theta_j) = \left[\hat{\theta}_j \pm t_{n-p, \frac{\alpha}{2}} \cdot s \sqrt{d_{jj}} \right]$$

$$IC(\theta_j) = [1.06 \pm 1.98 \cdot 0.3056]^2$$

$$e) H_0: \theta_1 = 0 \quad \text{vs} \quad H_1: \theta_1 \neq 0$$

$$\text{Bajo } H_0: T_1 = \frac{\hat{\theta}_1}{\hat{s}_d(\hat{\theta}_1)} \sim t_{97} \quad T_{1, \text{obs}} = \frac{1.06}{0.3056} \cong 3.492$$

$$p\text{-valor} = P(|T_1| > T_{1,0.05}) \equiv 0.000723$$

A nivel 0.05, hay evidencia para rechazar H_0

5) TERMINAR...

$$g) H_0: \underbrace{\theta_1 = \theta_2 = 0}_{A\theta = 0} \quad \text{vs} \quad H_1: \underbrace{\theta_1 \neq 0 \text{ o } \theta_2 \neq 0}_{A\theta \neq 0}$$

Sirve para
modelos con
varios parámetros
en los cuales es útil
descartar params.

$$\begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$F = (A\hat{\theta} - c)^t [A(X^t X)A^t]^{-1} (A\hat{\theta} - c)^t \sim F_{q, n-p}$$

TERMINAR...

cont de restricciones
o # filas de A

$$i) \text{ Dada una nueva } x_0 \quad \hat{y}_0 = x_0^t \hat{\beta}$$

$$1) x_0^t \hat{\theta} \sim N(x_0^t \theta, \sigma^2 x_0^t (x_0^t x_0)^{-1} x_0) \rightarrow \frac{\hat{E}(y_0) - E(y_0)}{S \sqrt{x_0^t (x_0^t x_0)^{-1} x_0}}$$

$$IC(E(y_0)) = \left[x_0^t \hat{\theta} \pm t_{n-p, \frac{\alpha}{2}} \cdot S \sqrt{x_0^t (x_0^t x_0)^{-1} x_0} \right]$$

2) Predicción:

$$IP(E(y_0)) = \left[x_0^t \hat{\theta} \pm t_{n-p, \frac{\alpha}{2}} \cdot S \sqrt{1 + x_0^t (x_0^t x_0)^{-1} x_0} \right]$$

$$\hat{y}_0 - E(y_0)$$

$$\hat{y}_0 - y_0$$

$$\begin{aligned} \hat{y}_0 &\sim N(x_0^T \theta, \sigma^2 x_0^T (X^T X)^{-1} x_0) & \hat{y}_0 &= x_0^T \hat{\theta} \\ y_0 &\sim N(x_0^T \theta, \sigma^2) & E(\hat{y}_0) &= x_0^T \theta \\ & & V(\hat{y}_0) &= x_0^T V(\hat{\theta}) x_0 \\ & & &= x_0^T (X^T X)^{-1} \sigma^2 x_0 \end{aligned}$$

$$\hat{y}_0 - y_0 \sim N(0, \sigma^2 (1 + x_0^T (X^T X)^{-1} x_0))$$