

Introducción a la Estadística y Ciencia de Datos

Práctica — Regresión lineal y Paradoja de Simpson

Tratamiento de cálculos renales (basado en Charig et al., 1986)

Contexto. Un hospital evalúa dos tratamientos quirúrgicos para cálculos renales: el **Tratamiento A** (cirugía abierta, técnica tradicional) y el **Tratamiento B** (nefrolitotomía percutánea, técnica mínimamente invasiva). Se registraron 700 pacientes. Para cada uno se midió el **tamaño residual del cálculo** (en mm) a las cuatro semanas del procedimiento: valores más bajos indican mejor resultado. Las variables disponibles en el archivo `kidney_stones.csv` son:

- `treatment`: tratamiento recibido (A o B)
- `stone_size`: categoría del cálculo antes de la cirugía (small: diámetro < 20mm, large: diámetro ≥ 20mm)
- `stone_size_mm`: diámetro del cálculo antes de la cirugía (mm, variable continua)
- `residual_mm`: tamaño residual del cálculo a las 4 semanas (mm, variable respuesta)
- `treatment_A`: indicador binario (1 si Tratamiento A, 0 si B)
- `stone_large`: indicador binario (1 si cálculo grande, 0 si pequeño)

Sección 1 — Exploración y la Paradoja

Ejercicio 1 — Comparación global entre tratamientos

a. Calcule el tamaño residual medio para cada tratamiento. Complete la tabla:

Tratamiento	Pacientes	Residual medio (mm)	Desvío estándar (mm)
A	350	?	?
B	350	?	?

b. ¿Qué tratamiento parece mejor a partir de estos datos globales? Realice un test de hipótesis $H_0 : \mu_A = \mu_B$ vs. $H_1 : \mu_A \neq \mu_B$ usando la estadística:

$$\bar{X}_A \approx 6.48$$
$$\bar{X}_B \approx 5.52$$

$$T = \frac{\bar{X}_A - \bar{X}_B}{\sqrt{\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}}} \sim t_v$$

ver teórica 10
es una fórmula rara

Calcule el estadístico, indique su distribución aproximada bajo H_0 , calcule el p-valor e interprete.

c. ¿Es confiable esta conclusión? ¿Qué variable podría estar actuando como confusora?

No

Ejercicio 2 — Desagregación por tamaño del cálculo

a. Calcule el tamaño residual medio por tratamiento y tamaño del cálculo. Complete la tabla:

Tamaño	Tratamiento	Pacientes	Residual medio (mm)
Pequeño (<20mm)	A	87	?
Pequeño (<20mm)	B	270	?
Grande (≥20mm)	A	263	?
Grande (≥20mm)	B	80	?

b. ¿Qué tratamiento es mejor para cálculos pequeños? ¿Y para cálculos grandes? ¿Coincide con la conclusión del Ejercicio 1? Describa la paradoja.

c. Calcule el porcentaje de pacientes con cálculo grande en cada grupo de tratamiento. ¿Observa algún desbalance? ¿Por qué cree que ocurre? Calcule la correlación muestral entre `treatment_A` y `stone_large`. ≈ 0.52

Sección 2 — Regresión lineal simple

Ejercicio 3 — Modelo sin controlar por tamaño

Consideramos el modelo lineal simple:

$$\text{residual_mm}_i = \beta_0 + \beta_1 \cdot \text{treatment_A}_i + \varepsilon_i$$

$\Delta = \bar{X}_A - \bar{X}_B \rightarrow$ "penalización" por usar T_A

a. Ajuste este modelo por mínimos cuadrados. Reporte $\hat{\beta}_0$, $\hat{\beta}_1$, sus errores estándar y p-valores.

¿Cuál es la interpretación de $\hat{\beta}_1$?

b. ¿Cuánto vale $\hat{\beta}_0$? ¿Y $\hat{\beta}_0 + \hat{\beta}_1$? Relacione estos valores con las medias muestrales del Ejercicio 1.

c. ¿Cuál es el R^2 del modelo? ¿Qué indica sobre el poder explicativo del tratamiento solo?

d. ¿Hay evidencia suficiente a nivel 0.05 para afirmar que $\beta_1 = 0$? Interprete en el contexto del problema.

e. Halle la suma de los residuos. ¿Cuánto vale? Justifique.

Ejercicio 4 — Modelo con tamaño del cálculo (variable binaria)

Ahora incorporamos el tamaño del cálculo como covariable:

$$\text{residual_mm}_i = \beta_0 + \beta_1 \cdot \text{treatment_A}_i + \beta_2 \cdot \text{stone_large}_i + \varepsilon_i$$

- Ajuste este modelo. Reporte la tabla de coeficientes completa.
- ¿Cuál es el signo de $\hat{\beta}_1$ ahora? Compare con el Ejercicio 3. ¿Cómo explica el cambio? *¿pa mejora el p-valor?*
- Interprete $\hat{\beta}_2$: ¿cuántos mm más de cálculo residual se esperan en promedio para un paciente con cálculo grande respecto a uno con cálculo pequeño, recibiendo el mismo tratamiento?
- Calcule R^2 . Compare con el modelo del Ejercicio 3. ¿Por qué mejora tanto?
- Halle un intervalo de confianza de nivel 0.95 para β_1 . ¿Incluye al 0? ¿Qué concluye sobre el efecto del tratamiento controlando por tamaño?
- Halle un intervalo de confianza de nivel 0.95 para β_2 .
- Calcule la correlación entre los residuos de este modelo y la variable `stone_large`. ¿Qué valor espera y por qué? *$y_i - \hat{y}_i$*

Sección 3 — Regresión con variable continua y términos polinómicos

Ejercicio 5 — Tamaño continuo del cálculo

Reemplazamos la variable binaria `stone_large` por el diámetro continuo `stone_size_mm`:

$$\text{residual_mm}_i = \beta_0 + \beta_1 \cdot \text{treatment_A}_i + \beta_2 \cdot \text{stone_size_mm}_i + \varepsilon_i$$

- Ajuste este modelo. Reporte los coeficientes, errores estándar y p-valores.
- Interprete $\hat{\beta}_2$: ¿cuánto cambia el residual esperado por cada milímetro adicional de tamaño inicial del cálculo?
- Compare el R^2 de este modelo con el del Ejercicio 4. ¿Usar el tamaño continuo en lugar del binario mejora el ajuste?
- Grafique los residuos de este modelo en función de `stone_size_mm`. ¿Observa algún patrón? ¿Sugiere que podría ser útil agregar un término cuadrático?

Ejercicio 6 — Modelo polinómico

Ajuste el modelo:

$$\text{residual_mm}_i = \beta_0 + \beta_1 \cdot \text{treatment_A}_i + \beta_2 \cdot \text{stone_size_mm}_i + \beta_3 \cdot \text{stone_size_mm}_i^2 + \varepsilon_i$$

- Reporte los coeficientes estimados y sus errores estándar.
- Testee $H_0 : \beta_3 = 0$ vs. $H_1 : \beta_3 \neq 0$. ¿Hay evidencia de curvatura en la relación entre tamaño del cálculo y residual?

- c. Compare el R^2 ajustado de los modelos de los Ejercicios 4, 5 y 6. ¿Cuál elegiría y por qué?
- d. Superponga en un mismo gráfico, para cada tratamiento, la curva ajustada de residual esperado en función de `stone_size_mm` según el modelo del Ejercicio 6.

Sección 4 — Predicción

Ejercicio 7 — Intervalos de confianza y predicción

Use el modelo del Ejercicio 4 (con `treatment_A` y `stone_large`) para los siguientes ítems.

- a. Un nuevo paciente recibirá el Tratamiento B y tiene un cálculo pequeño. Estime el tamaño residual medio esperado para pacientes con esas características y calcule un intervalo de confianza de nivel 0.95.
- b. Para ese mismo perfil de paciente, calcule un intervalo de predicción de nivel 0.95 para su resultado individual. Compare con el ítem anterior y explique la diferencia.
- c. Repita los ítems (a) y (b) para un paciente que recibirá el Tratamiento A con un cálculo grande. ¿Cuál de los cuatro intervalos es más ancho? ¿Por qué?
- d. Estime la diferencia en tamaño residual esperado entre un paciente con Tratamiento A y cálculo grande, y un paciente con Tratamiento B y cálculo pequeño. ¿Qué parte de esa diferencia se atribuye al tratamiento y qué parte al tamaño del cálculo?