

Resolución — Paradoja de Simpson: Cálculos Renales

Introducción a la Estadística y Ciencia de Datos

Sección 1 — Exploración y la Paradoja

Ejercicio 1(a) — Comparación global

Tratamiento	Pacientes	Residual medio (mm)	Desvío estándar (mm)
A	350	6.485	3.716
B	350	5.525	3.530

El Tratamiento B tiene un residual medio 0.96 mm menor que el A. A primera vista, el Tratamiento B parece superior.

Ejercicio 1(b) — Test de medias

El estadístico de Welch bajo $H_0 : \mu_A = \mu_B$ es:

$$T = \frac{6.485 - 5.525}{\sqrt{\frac{3.716^2}{350} + \frac{3.530^2}{350}}} = \frac{0.960}{\sqrt{0.03948 + 0.03561}} = \frac{0.960}{0.2740} \approx 3.506$$

La distribución bajo H_0 es aproximadamente t_{696} . El p-valor es $2P(t_{696} > 3.506) \approx 0.00048$.

Conclusión: Se rechaza H_0 a cualquier nivel razonable. La diferencia global es estadísticamente significativa.

Ejercicio 1(c) — ¿Es confiable?

No. El análisis global ignora que los médicos no asignaron los tratamientos al azar: el Tratamiento A (cirugía abierta, más invasiva) fue reservado para los casos más graves, es decir, cálculos más grandes. El **tamaño del cálculo** es la variable de confusión: afecta tanto cuál tratamiento recibe el paciente como cuál es el resultado esperado.

Ejercicio 2(a) — Desagregado por tamaño

Tamaño	Tratamiento	Pacientes	Residual medio (mm)
Pequeño	A	87	1.994
Pequeño	B	270	4.030
Grande	A	263	7.971
Grande	B	80	10.572

Ejercicio 2(b) — La paradoja

El Tratamiento A es **mejor en ambos subgrupos**: produce 2.0 mm menos de residual en cálculos pequeños (1.994 vs. 4.030) y 2.6 mm menos en cálculos grandes (7.971 vs. 10.572). Sin embargo, globalmente parece peor (6.485 vs. 5.525). Esta es la Paradoja de Simpson: la dirección del efecto se invierte al agregar los datos.

Ejercicio 2(c) — Desbalance y confusión

El porcentaje de pacientes con cálculo grande es del 75.1% en el Tratamiento A y solo del 22.9% en el Tratamiento B. La correlación entre `treatment_A` y `stone_large` es $r \approx 0.523$, fuertemente positiva.

Los médicos asignaban los casos difíciles (cálculos grandes, inherentemente más difíciles de tratar) a la cirugía abierta por ser la técnica más establecida para casos

complejos. Esto genera el desbalance que produce la paradoja: el Tratamiento A carga con más casos graves, elevando su media global aunque sea mejor en cada subgrupo.

Sección 2 — Regresión lineal simple

Ejercicio 3 — Modelo sin controlar por tamaño

El modelo es $\text{residual}_i = \beta_0 + \beta_1 \cdot \text{treatment_A}_i + \varepsilon_i$. Los estimadores de mínimos cuadrados son:

Coficiente	Estimación	Error estándar	Estadístico t	p-valor
$\hat{\beta}_0$	5.525	0.194	28.52	< 0.001
$\hat{\beta}_1$	0.961	0.274	3.506	0.00048

$R^2 = 0.017$. Suma de residuos = 0 (exactamente, por las ecuaciones normales con intercept).

$\hat{\beta}_0 = 5.525$ es la media muestral del Tratamiento B; $\hat{\beta}_0 + \hat{\beta}_1 = 5.525 + 0.961 = 6.486 \approx 6.485$ es la media muestral del Tratamiento A. En regresión simple con una única variable binaria, los valores ajustados son exactamente las medias de cada grupo.

$\hat{\beta}_1 = +0.961 > 0$: sin controlar, el modelo indica que el Tratamiento A produce en promedio 0.96 mm más de residual que el B, es decir, parece peor. Hay evidencia suficiente para rechazar $H_0 : \beta_1 = 0$ a nivel 0.05 (p-valor ≈ 0.00048). Pero esta conclusión es espuria: es la manifestación algebraica de la Paradoja de Simpson.

El $R^2 = 0.017$ es muy bajo: el tratamiento solo, sin considerar el tamaño del cálculo, explica apenas el 1.7% de la variabilidad del residual.

Ver script R: seccion 3 – `lm(residual_mm ~ treatment_A)`

Ejercicio 4 — Modelo con tamaño del cálculo (binario)

El modelo es $\text{residual}_i = \beta_0 + \beta_1 \cdot \text{treatment_A}_i + \beta_2 \cdot \text{stone_large}_i + \varepsilon_i$. Los estimadores son:

Coficiente	Estimación	Error estándar	p-valor
$\hat{\beta}_0$	4.096	0.140	< 0.001
$\hat{\beta}_1$	-2.308	0.218	< 0.001
$\hat{\beta}_2$	6.252	0.218	< 0.001

$\hat{\beta}_1$ **cambió de signo**: pasó de +0.961 a -2.308. Controlando por tamaño del cálculo, el Tratamiento A produce en promedio 2.31 mm *menos* de residual que el B — es decir, es mejor. Este cambio de signo es la paradoja resuelta por el modelo de regresión múltiple.

$\hat{\beta}_2 = 6.252$: un paciente con cálculo grande tiene en promedio 6.25 mm más de residual que uno con cálculo pequeño, recibiendo el mismo tratamiento. Este coeficiente cuantifica la dificultad adicional que impone el tamaño del cálculo.

$R^2 = 0.550$: el modelo explica el 55% de la variabilidad del residual. La mejora respecto al modelo anterior (1.7%) refleja que el tamaño del cálculo es el principal predictor.

IC 95% para β_1 : [-2.736, -1.881]. No incluye al 0: hay evidencia muy fuerte de que el Tratamiento A es superior, controlando por tamaño.

IC 95% para β_2 : [5.824, 6.679].

La correlación entre los residuos de este modelo y `stone_large` es exactamente 0, por las ecuaciones normales ($X^T r = 0$).

```
Ver script R: seccion 4 - lm(residual_mm ~ treatment_A +
stone_large)
```

Sección 3 — Variable continua y términos polinómicos

Ejercicio 5 — Tamaño continuo

El modelo residual $y_i = \beta_0 + \beta_1 \cdot \text{treatment_A}_i + \beta_2 \cdot \text{stone_size_mm}_i + \varepsilon_i$ da:

Coefficiente	Estimación	Error estándar	p-valor
$\hat{\beta}_0$	1.616	0.248	< 0.001
$\hat{\beta}_1$	-1.325	0.246	< 0.001
$\hat{\beta}_2$	0.242	0.012	< 0.001

$\hat{\beta}_2 = 0.242$: por cada milímetro adicional de tamaño inicial del cálculo, el residual esperado aumenta en 0.24 mm, controlando por tratamiento.

$R^2 = 0.379$, menor que el del modelo con la variable binaria (0.550). Esto puede sorprender pero se explica porque la variable **stone_large** captura el salto discontinuo de medias entre los dos grupos, mientras que la variable continua impone una relación estrictamente lineal que es menos flexible.

Ver script R: seccion 5 – `lm(residual_mm ~ treatment_A + stone_size_mm)`

Ejercicio 6 — Modelo polinómico

El modelo cuadrático residual $y_i = \beta_0 + \beta_1 \cdot \text{treatment_A}_i + \beta_2 \cdot \text{stone_size_mm}_i + \beta_3 \cdot \text{stone_size_mm}_i^2 + \varepsilon_i$ da:

Coefficiente	Estimación	Error estándar	p-valor
$\hat{\beta}_0$	0.182	0.519	0.726
$\hat{\beta}_1$	-1.365	0.245	< 0.001
$\hat{\beta}_2$	0.408	0.055	< 0.001
$\hat{\beta}_3$	-0.00375	0.0012	0.0018

El test $H_0 : \beta_3 = 0$ tiene p-valor $\approx 0.0018 < 0.05$: hay evidencia de curvatura. La relación entre tamaño del cálculo y residual no es exactamente lineal.

Comparación de R^2 ajustado:

Modelo	R^2	R^2 ajustado
Ej. 4: treatment_A + stone_large	0.550	0.549
Ej. 5: treatment_A + stone_size_mm	0.379	0.377
Ej. 6: treatment_A + stone_size_mm + stone_size_mm ²	0.388	0.385

El modelo del Ejercicio 4 (con la variable binaria) sigue siendo el mejor en términos de R^2 ajustado. El término cuadrático mejora levemente el ajuste continuo pero no alcanza la flexibilidad del indicador binario, que captura el efecto de umbral de los 20 mm.

```
Ver script R: seccion 6 – lm(residual_mm ~ treatment_A +
stone_size_mm + I(stone_size_mm^2))
```

Sección 4 — Predicción

Ejercicio 7 — Intervalos

Usando el modelo del Ejercicio 4 con $\hat{\beta} = (4.096, -2.308, 6.252)$ y $s^2 = \text{RSS}/(n - 3)$.

(a)(b) Tratamiento B, cálculo pequeño: $x_0 = (1, 0, 0)^T$

$$\hat{y}_0 = 4.096 + (-2.308)(0) + 6.252(0) = 4.096 \text{ mm}$$

IC 95% para la media: [3.820, 4.371] mm.

IP 95% individual: [-0.732, 8.924] mm. El IP es mucho más ancho porque incorpora la variabilidad individual σ^2 . Nótese que el límite inferior es negativo: en la práctica se truncaría a 0 (el residual no puede ser negativo), lo que refleja que el modelo lineal no es perfecto para variables acotadas inferiormente.

(c) Tratamiento A, cálculo grande: $x_0 = (1, 1, 1)^T$

$$\hat{y}_0 = 4.096 + (-2.308)(1) + 6.252(1) = 8.040 \text{ mm}$$

IC 95% para la media: [7.761, 8.318] mm.

IP 95% individual: [3.212, 12.867] mm.

El IC más ancho es el IP de A, cálculo grande, porque la predicción puntual es más alta y los errores estándar de predicción son similares: el ancho del IP en escala absoluta crece con el nivel de la predicción.

(d) Diferencia entre A+grande y B+pequeño:

$$8.040 - 4.096 = 3.944 \text{ mm}$$

Esta diferencia se descompone en dos partes según el modelo:

- Efecto del tratamiento: $\hat{\beta}_1 = -2.308$ mm (a favor del Tratamiento A)
- Efecto del tamaño del cálculo: $\hat{\beta}_2 = +6.252$ mm (en contra por ser cálculo grande)

El resultado neto es $-2.308 + 6.252 = +3.944$ mm. El paciente A+grande tiene peor resultado esperado que el B+pequeño, pero por el tamaño del cálculo, no por el tratamiento: el tratamiento en realidad lo favorece en 2.3 mm.

```
Ver script R: seccion 7 – predict(modelo4, newdata,  
interval="confidence") y "prediction"
```

Conclusión general. La Paradoja de Simpson surge porque el Tratamiento A fue asignado desproporcionadamente a pacientes con cálculos grandes (casos más difíciles). La regresión múltiple permite controlar simultáneamente por el tamaño del cálculo y recuperar el efecto verdadero del tratamiento, que es positivo (A es mejor que B en 2.3 mm). La variable de confusión, al estar correlacionada tanto con el tratamiento como con el resultado, sesgaba completamente la comparación ingenua.