

1. Sean  $X_1, \dots, X_n \sim F$  variables aleatorias independientes. Sea  $X \sim X_i$  y supongamos que queremos estimar a  $\mu = \mathbb{E}_F(X)$  asumiendo sólo que  $\mu$  existe. La media  $\mu$  puede pensarse como una función de  $F$ : en efecto, podemos escribir  $\mu = T(F) = E_F(X)$ .

En general, cualquier función de la distribución  $F$  recibe el nombre de *funcional estadístico*. Otros ejemplos son la varianza  $\sigma^2 = T(F) = E_F(X^2) - (E_F(X))^2$  y la mediana  $m = T(F) = F^{-1}(1/2)$ .

El **estimador plug-in** de  $\theta = T(F)$  se define como

$$\hat{\theta}_n = T(F_n),$$

donde  $F_n$  es la distribución empírica, es decir  $F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i \leq x)$ .

- Hallar el estimador plug-in de  $\mu$
- Hallar el estimador plug-in de  $\sigma^2$
- Si  $T(F) = \mathbb{E}_F(r(X))$  para alguna función  $r$ , hallar el estimador plug-in de  $T(F)$ .
- Si  $A \subset \mathbb{R}$ , podríamos estimar  $\mathbb{P}_F(X \in A)$ , ¿cuánto resulta  $\hat{\mathbb{P}}_F(X \in A) = \mathbb{P}_{F_n}(X \in A)$ ? (Sug.: aplicar c) con la función indicadora apropiada).

a)  $\hat{\mu}_n = \mathbb{E}_{F_n}(X) = \sum x_i \cdot \mathbb{P}_{F_n}(X_i = x)$

Si  $X \sim F_n$ ,  $\mathbb{P}_{F_n}(X = x_i) = \frac{1}{n}$ ,  $i = 1, \dots, n$

$$\Rightarrow \hat{\mu}_n = \frac{1}{n} \sum x_i = \bar{X}$$

b)  $\hat{\sigma}_n^2 = \mathbb{E}_{F_n}(X^2) - \mathbb{E}_{F_n}(X)^2 = \sum x_i^2 \cdot \frac{1}{n} - \bar{X}^2$   
 $= \frac{1}{n} \sum (x_i - \bar{X})^2$

c)  $T(F_n) = \mathbb{E}_{F_n}(r(X)) = \frac{1}{n} \sum r(x_i)$

d)  $\hat{\mathbb{P}}_F(X \in A) = \mathbb{E}_{F_n}(\mathbb{I}_A(X)) = \frac{1}{n} \sum \mathbb{I}_A(x_i)$

2. La cantidad de partículas que emite una fuente radiactiva en un minuto es una variable aleatoria con distribución de Poisson de parámetro  $\lambda$ . Se midió la cantidad de emisiones en intervalos de 1 minuto, obteniendo las siguientes 15 muestras

500 - 488 - 426 - 510 - 450 - 368 - 508 - 514 - 426  
476 - 512 - 526 - 444 - 524 - 236

- a) A partir del Ejercicio 1 de la Práctica 2 estimar el valor del parámetro  $\lambda$  basado en la muestra utilizando un estimador de momentos
- 1) basado en el momento de orden 1, que llamaremos  $T_1$ .
  - 2) basado en el momento de orden 2, que llamaremos  $T_2$ .
- b) Notar que el cálculo de la varianza del estimador basado en el momento de orden 2 es difícil y que en este caso el *método bootstrap* puede auxiliarnos. Dado que hemos asumido que los datos provienen de una muestra Poisson, podemos apelar al *método bootstrap paramétrico*.
- 1) Explorar el comando `rpois` para obtener una muestra de tamaño 15 generada a partir del estimador  $T_{1,obs}$ , computar el estimador bootstrapeado y guardar el valor obtenido.
  - 2) Repetir  $B = 1000$  veces el ítem anterior guardando los valores bootstrapeados de  $T_1$  en un vector.
  - 3) Realizar un histograma basado en los valores bootstrapeados de  $T_1$  del ítem anterior. ¿Qué observa?
  - 4) A partir de los valores bootstrapeados de  $T_1$  estimar la varianza de  $T_1$ . ¿Tiene alguna intuición de cuanto valdría esta varianza?
- c) Repetir b) para  $T_2$  y comparar los resultados obtenidos para los dos estimadores.

$$a) 1) \hat{\lambda}_1 = \bar{X} \implies T_1 \approx 460.5$$

$$2) \hat{\lambda}_2 = \frac{-1 + \sqrt{1 + 4\bar{X}^2}}{2} \implies T_2 \approx 466$$

b) en R.

$$X_1, \dots, X_{15} \implies \hat{\lambda} = T_1(X_1, \dots, X_{15})$$

$$rP(n, \hat{\lambda}) \rightarrow X_1^b, \dots, X_{15}^b, b = 1, \dots, 1000$$

$$\rightarrow T_1(X_1^b, \dots, X_{15}^b) \quad \forall b \implies T_1^1, \dots, T_1^{1000}$$

$$\rightarrow \text{Var}(T_1^1, \dots, T_1^{1000})$$

5. (Para hacer con el R) Instalar el paquete `Lock5Data` correspondiente al libro de Lock<sup>[2]</sup>. En dicho paquete hay un conjunto de  $n = 25$  datos que se denomina `MustangPrice`. Cargarlo al R con la instrucción `data("MustangPrice")`.

Los datos corresponden a 25 automóviles Mustang usados que se ofrecen a la venta en un sitio de Internet en determinado momento. Se registraron las variables: *Age*, edad (en años), *Miles*, kilometraje (en millas) y *Price*, precio de venta (en miles de dólares) para cada automóvil de la muestra.

Nos enfocaremos en la correlación entre las variables *Price* y *Miles*. Recordemos que si  $(X, Y)$  es un vector aleatorio con distribución conjunta  $F$ , la correlación entre  $X$  e  $Y$  es

$$\rho = \frac{\text{Cov}(X, Y)}{\sqrt{\text{V}(X)\text{V}(Y)}}.$$


Además, dada una muestra de vectores aleatorios  $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$  podemos estimar a  $\rho$  mediante la correlación muestral definida por

$$\hat{\rho} = \frac{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{S_X^2 S_Y^2}},$$

La **correlación** mide fuerza y dirección de la asociación lineal entre dos variables. Dos palabras clave:

Dirección

- Positiva  $\rightarrow$  tienden a crecer juntas (1)
- Negativa  $\rightarrow$  una crece mientras la otra baja (2)



Fuerza

- Qué tan concentrados están los puntos alrededor de una recta
- cerca de 1  $\rightarrow$  fuerte, cerca de 0  $\rightarrow$  débil o inexistente

Lo importante es lo que **no mide**:

- No es causalidad — que *Price* y *Miles* correlacionen no significa que manejar más cause que el precio baje (aunque en este caso tiene sentido, en general correlación no implica causalidad)
- Solo captura relaciones lineales — dos variables pueden tener una relación perfecta (por ejemplo cuadrática) y aun así tener
- No dice nada sobre la escala — es adimensional, no importa si *Miles* está en km o millas

Por eso siempre conviene mirar el scatterplot además del número: puede verse muy distinto dependiendo de si hay outliers, si la nube es homogénea, etc

