

ESTADÍSTICA (M) [CURSADA AÑO 2019]

1. Estimación Puntual	3
1.1. Criterios para medir la bondad de un estimador	4
1.2. Estimadores insesgados	5
1.3. Estadísticos suficientes	6
1.4. Estadísticos minimales suficientes	7
1.5. Estimadores basados en estadísticos suficientes	7
1.6. Familias exponenciales	8
1.7. Estadísticos completos	10
1.8. Estimadores insesgados de mínima varianza uniformemente	12
1.9. Desigualdad de Rao-Cramer	13
1.10. Consistencia de estimadores	15
1.11. Ejercicios	17
1.11.1. Estimadores Basados en Momentos	17
1.11.2. Estimadores de máxima verosimilitud	19
1.11.3. Estimadores Bayesianos con Pérdida Cuadrática	24
1.11.4. Riesgo, Error Cuadrático Medio, Estimadores Insesgados	29
1.11.5. Consistencia y distribución asintótica	32
1.11.6. Estadísticos Suficientes	36
1.11.7. Teorema de Rao-Blackwell	40
1.11.8. Familias Exponenciales	43
1.11.9. Completitud y Estimadores IMVU	44
1.11.10. Desigualdad de Rao-Cramer	47
2. Intervalos y Regiones de Confianza	49
2.1. Procedimientos generales para obtener regiones de confianza	49
2.2. Procedimiento en dos pasos para encontrar un intervalo de longitud prefijada para la media de una $N(\mu, \sigma^2)$, μ y σ^2 desconocidos	51
2.3. Optimalidad de los intervalos de confianza	52
2.4. Regiones de confianza con nivel asintótico $(1 - \alpha)$	53
2.5. Ejercicios	53
2.5.1. Intervalos de Confianza de Nivel Exacto	53
2.5.2. Intervalos de Confianza de Nivel Asintótico	56
2.5.3. Intervalos Bootstrap	59
3. Tests de hipótesis	60
3.1. Formulación general del problema del test de hipótesis	60
3.2. Nivel de significación de un test	61
3.3. Tests óptimos para el caso de hipótesis simple contra hipótesis simple	62
3.4. Tests uniformemente más potentes para hipótesis unilaterales	66
3.5. Tests Insesgados	69
3.6. Test del cociente de máxima verosimilitud	70
3.7. Test con nivel de significación asintótico	70
3.8. Distribución asintótica del test del cociente de máxima verosimilitud	71
3.9. Relación entre regiones de confianza y test	73
3.10. Cotas de confianza óptimas	73
3.11. Relación entre intervalos de confianza con nivel asintótico $1 - \alpha$ y test con nivel de significación asintótico α	75
3.12. Ejercicios	75
3.12.1. Conceptos Básicos y Tests Bajo Normalidad	75
3.12.2. Teorema de Neyman-Pearson para Hipótesis Simples	78
3.12.3. Tests para Familias con Cociente de Verosimilitud Monótono	81

3.12.4. Tests de Cociente de Máxima Verosimilitud	84
3.12.5. Tests con Nivel de Significación Asintótica	85

Capítulo 1

Estimación Puntual

Definición 1.1. Se define como estadístico a cualquier función medible cuyo argumento es un vector muestra $\mathbf{X} = (X_1, \dots, X_k)$ y toma valores en un espacio euclideo de dimensión finita.

Observar que el vector $\mathbf{X}$ tiene distribución $\mathcal{F}(x_1, \dots, x_k; \boldsymbol{\theta})$ con $\boldsymbol{\theta} = (\theta_1, \dots, \theta_k) \in \Theta \subset \mathbb{R}^k$.

Definición 1.2. Un estimador puntual de $q(\boldsymbol{\theta})$ será cualquier estadístico $\delta(\mathbf{X})$ de $\mathbb{R}^k$ en $\mathbb{R}$.

Observación 1.3.

- (i) La única información que se tiene sobre $\boldsymbol{\theta}$ es el vector $\mathbf{X}$, por lo tanto, cualquier estimación que se haga de $\boldsymbol{\theta}$ deberá estar basada en $\mathbf{X}$.
- (ii) Un buen estimador $\delta(\mathbf{X})$ debería tener la propiedad de que cualquiera sea el valor de $\boldsymbol{\theta}$, que es desconocido, la diferencia $\delta(\mathbf{X}) - q(\boldsymbol{\theta})$ sea pequeña.

Definición 1.4. Método de Momentos (E.M.):

El método de momentos estima θ por el valor $\hat{\theta} = \delta(\mathbf{X})$ que satisface la ecuación

$$\frac{1}{n} \sum_{i=1}^n g(X_i) = \mathbb{E}_{\hat{\theta}}(g(X_1)).$$

Observación 1.5.

- (i) La justificación heurística de este método se basa en el hecho que de acuerdo a la ley de los grandes números

$$\frac{1}{n} \sum_{i=1}^n g(X_i) \xrightarrow[n \rightarrow \infty]{ctp} \mathbb{E}_{\theta}(g(X_1)).$$

- (ii) En general, se toman como funciones g las funciones generadoras de momentos.

Definición 1.6. Método de Máxima Verosimilitud (E.M.V.):

Diremos $\hat{\boldsymbol{\theta}}(\mathbf{X})$ es un estimador de máxima verosimilitud de $\boldsymbol{\theta}$, si se cumple

$$p(\mathbf{X}, \hat{\boldsymbol{\theta}}(\mathbf{X})) = \max_{\boldsymbol{\theta} \in \Theta} p(\mathbf{X}, \boldsymbol{\theta}).$$

Observación 1.7.

- (i) Cómputo del E.M.V.:

Supongamos ahora que θ es un subconjunto abierto de $\mathbb{R}^k$, que el soporte de $p(\mathbf{x}, \boldsymbol{\theta})$ no depende de $\boldsymbol{\theta}$ y que $p(\mathbf{x}, \boldsymbol{\theta})$ tiene derivadas parciales respecto a todas las componentes θ_i .

Como la función $\ln(y)$ (logaritmo natural) es monótona creciente, maximizar $p(\mathbf{x}, \boldsymbol{\theta})$ será equivalente a maximizar $\ln(p(\mathbf{x}, \boldsymbol{\theta}))$. Luego el E.M.V. $\hat{\boldsymbol{\theta}}(\mathbf{X})$ debe verificar:

$$\frac{\partial \ln(p(\mathbf{x}, \boldsymbol{\theta}))}{\partial \theta_i} = 0, \quad \forall i \in \{1, \dots, k\}$$

Hasta ahora hemos supuesto que X es un vector con una distribución arbitraria. Supongamos ahora que $\mathbf{X}$ es una muestra aleatoria de una distribución discreta o continua con densidad $p(\mathbf{X}, \boldsymbol{\theta})$. Luego se tiene

$$p(\mathbf{X}, \boldsymbol{\theta}) = \prod_{i=1}^k p(x_i, \theta_i)$$

y bajo las condiciones dadas anteriormente, el sistema de ecuaciones se transforma en

$$\sum_{i=1}^k \frac{\partial \ln(p(x_i, \hat{\boldsymbol{\theta}}))}{\partial \theta_j} = 0, \quad \forall j \in \{1, \dots, k\}$$

(ii) Lo visto en el ítem anterior son condiciones necesarias pero no suficientes para que $\hat{\theta}$ sea un máximo. Para asegurarse que $\hat{\theta}$ es un máximo deberían verificarse las condiciones de segundo orden respectivas. Además debe verificarse que no se trata de un máximo relativo sino absoluto.

Proposición 1.8. Invarianza de los E.M.V.:

Si $\hat{\theta}$ es E.M.V. de θ , entonces $\hat{\lambda} = q(\hat{\theta})$ es E.M.V. de $\lambda = q(\theta)$, donde q es una función biunívoca de Θ sobre Λ .

Demostración. Como $\hat{\theta}$ es E.M.V. de θ y $\hat{\lambda} = q(\hat{\theta})$ entonces

$$p(\mathbf{x}, \hat{\theta}) = \max_{\theta \in \Theta} p(\mathbf{x}, \theta) \Rightarrow p(\mathbf{x}, q^{-1}(\hat{\lambda})) = \max_{\lambda \in \Lambda} p(\mathbf{x}, q^{-1}(\lambda)) = p^*(\mathbf{x}, \hat{\lambda})$$

con p^* resulta ser la densidad de $\mathbf{X}$ como función de λ . □

Supongamos que $X_1, X_2, \dots, X_k$ son variables aleatorias de la forma

$$X_i = S_i(\theta_1, \dots, \theta_k) + \varepsilon_i, \quad 1 \leq i \leq k$$

donde $\theta = (\theta_1, \dots, \theta_k)$ es un vector de parámetros desconocido, del cual lo único que se conoce es que está en un conjunto $\Theta \subset \mathbb{R}^k$ y ε_i son variables aleatorias con

- (i) $\mathbb{E}(\varepsilon_i) = 0$.
- (ii) $\mathbb{V}(\varepsilon_i) = \sigma^2$.
- (iii) $\varepsilon_1, \dots, \varepsilon_k$ son variables aleatorias independientes.

Definición 1.9. Estimador de Cuadrados Mínimos (E.C.M.):

Llamaremos estimador de cuadrados mínimos al valor $\hat{\theta}(X_1, \dots, X_k)$ que satisface

$$\sum_{i=1}^k (X_i - S_i(\hat{\theta}))^2 = \min_{\theta \in \Theta} \sum_{i=1}^k (X_i - S_i(\theta))^2.$$

Observación 1.10. Cómputo del E.C.M.:

Si Θ es abierto y si las funciones $S_i(\theta_1, \dots, \theta_k)$ son derivables respecto a cada θ_i , $\hat{\theta}$ deberá satisfacer el sistema de ecuaciones siguiente

$$\frac{\partial}{\partial \theta_j} \sum_{i=1}^k (X_i - S_i(\hat{\theta}))^2 = 0, \quad \forall j \in \{1, \dots, k\}$$

que es equivalente a:

$$\sum_{i=1}^k (X_i - S_i(\hat{\theta})) \frac{\partial S_i(\hat{\theta})}{\partial \theta_j} = 0, \quad \forall j \in \{1, \dots, k\}$$

Estas condiciones son necesarias para el E.M.C. pero no son suficientes. También se deberán cumplir las condiciones de segundo orden, y se deberá verificar que se trata de un mínimo absoluto y no local.

1.1. Criterios para medir la bondad de un estimador

Definición 1.11. Llamaremos función de pérdida a una función $\ell(\theta, d)$ no negativa que nos indica cuánto se pierde cuando el valor del estimador es " d " y el valor verdadero del vector de parámetros es θ .

Esta pérdida será una variable aleatoria ya que depende de $\mathbf{X}$. Para evaluar globalmente el estimador $\delta(\mathbf{X})$ se puede utilizar el valor medio de esta pérdida.

Definición 1.12. Definimos a la función pérdida media del estimador δ o función de riesgo $R(\delta, \theta)$ a

$$R(\delta, \theta) = \mathbb{E}_{\theta}(\ell(\theta, \delta(\mathbf{X}))).$$

Definición 1.13. Definimos el Error Cuadrático Medio como

$$ECM_{\theta}(\delta) = R(\delta, \theta) = \mathbb{E}[(\delta(\mathbf{X}) - q(\theta))^2],$$

es decir, considerando $\ell(\theta, d) = (d - q(\theta))^2$.

Definición 1.14. Se dice que un estimador $\delta(\mathbf{X})$ de $q(\theta)$ es inadmisble respecto de la pérdida $\ell(\theta, d)$, si existe otro estimador $\delta'(\mathbf{X})$ mejor que él, es decir, si existe $\delta'(\mathbf{X})$ tal que

$$R(\delta', \theta) \leq R(\delta, \theta), \quad \forall \theta \in \Theta.$$

El estimador $\delta(\mathbf{X})$ se dirá admisible si no es inadmisble, es decir, si no existe ningún otro estimador que sea uniformemente mejor que él.

Observación 1.15. Un estimador óptimo δ^* podría definirse mediante la siguiente condición: Para cualquier otro estimador δ se tiene

$$ECM_{\theta}(\delta^*) \leq ECM_{\theta}(\delta), \quad \forall \theta \in \Theta.$$

Por otra parte, un estimador δ^* con E.C.M. mínimo uniformemente en θ no existe, salvo en casos excepcionales, debido a que la clase de todos los posibles estimadores es muy amplia.

Por lo tanto, una manera de obtener estimadores óptimos consistirán restringir primero la clase de los estimadores δ considerados, y luego buscar aquél con E.C.M. uniformemente menor dentro de esta clase. Otra forma de obtener estimadores óptimos consistirán minimizar algún criterio general basado en la función de riesgo, como el máximo riesgo.

Teorema 1.16. Supongamos que $\ell(\theta, d)$ es una pérdida estrictamente convexa en d y que $\delta(\mathbf{X})$ es admisible para $q(\theta)$. Si $\delta'(\mathbf{X})$ es otro estimador de $q(\theta)$ con el mismo riesgo que $\delta(\mathbf{X})$ entonces $\mathbb{P}_{\theta}(\delta(\mathbf{X}) = \delta'(\mathbf{X})) = 1$.

Demostración. Supongamos que $\mathbb{P}_{\theta}(\delta(\mathbf{X}) = \delta'(\mathbf{X})) < 1$ y sea $\delta^*(\mathbf{X}) = \frac{\delta(\mathbf{X}) + \delta'(\mathbf{X})}{2}$.

Luego, por ser $\ell(\theta, d)$ convexa se cumple

$$\ell(\theta, \delta^*(\mathbf{X})) < \frac{\ell(\theta, \delta(\mathbf{X})) + \ell(\theta, \delta'(\mathbf{X}))}{2}, \quad \text{salvo si } \delta(\mathbf{X}) = \delta'(\mathbf{X}).$$

Luego, tomando esperanza en ambos miembros, se tiene que

$$R(\delta^*, \theta) < \frac{R(\delta, \theta) + R(\delta', \theta)}{2} = R(\delta, \theta)$$

lo que contradice el hecho de que $\delta(\mathbf{X})$ es admisible. □

1.2. Estimadores insesgados

Definición 1.17. Se dice que $\delta(\mathbf{X})$ es un estimador insesgado para $q(\theta)$ si $\mathbb{E}_{\theta}(\delta(\mathbf{X})) = q(\theta)$ para todo $\theta \in \Theta$.

Si un estimador no es insesgado, se dice sesgado.

Definición 1.18. Se define el sesgo del estimador como

$$b_{\theta} = \mathbb{E}_{\theta}(\delta(\mathbf{X})) - q(\theta).$$

Cuando $\delta(\mathbf{X})$ es un estimador insesgado, su ECM coincide con su varianza

$$ECM_{\theta}(\delta) = \mathbb{E}_{\theta}[(\delta(\mathbf{X}) - q(\theta))^2] = \mathbb{E}_{\theta}[(\delta(\mathbf{X}) - \mathbb{E}_{\theta}(\delta(\mathbf{X})))^2] = \mathbb{V}_{\theta}(\delta(\mathbf{X})).$$

Proposición 1.19. Sea $\delta(\mathbf{X})$ estimador de $q(\theta)$, entonces

$$ECM_{\theta}(\delta(\mathbf{X})) = \mathbb{V}_{\theta}(\delta(\mathbf{X})) + b_{\theta}^2$$

Demostración. $ECM_{\theta}(\delta(\mathbf{X})) = \mathbb{E}_{\theta}[(\delta(\mathbf{X}) - q(\theta))^2] = \mathbb{E}_{\theta}[(\delta(\mathbf{X}) \pm \mathbb{E}_{\theta}(\delta(\mathbf{X})) - q(\theta))^2]$, entonces

$$\begin{aligned} ECM_{\theta}(\delta(\mathbf{X})) &= \underbrace{\mathbb{E}_{\theta}[(\delta(\mathbf{X}) - \mathbb{E}_{\theta}(\delta(\mathbf{X})))^2]}_{=\mathbb{V}_{\theta}(\delta(\mathbf{X}))} + \underbrace{\mathbb{E}_{\theta}[2(\delta(\mathbf{X}) - \mathbb{E}_{\theta}(\delta(\mathbf{X}))) (\mathbb{E}_{\theta}(\delta(\mathbf{X})) - q(\theta))]}_{=0} + \underbrace{\mathbb{E}_{\theta}[(\mathbb{E}_{\theta}(\delta(\mathbf{X})) - q(\theta))^2]}_{=b_{\theta}^2} \\ &\Rightarrow ECM_{\theta}(\delta(\mathbf{X})) = \mathbb{V}_{\theta}(\delta(\mathbf{X})) + b_{\theta}^2 \end{aligned}$$

□

Observación 1.20.

- (i) Comparar el ECM de dos estimadores insesgados se reduce a comprar sus varianzas.
- (ii) Si comparamos un estimador insesgado contra otro que no lo es, se elige aquel con menor ECM.
- (iii) Si comparamos dos estimadores sesgados, se elige aquel con menor ECM.

Definición 1.21. Decimos que δ_n es un estimador asintóticamente insesgado como estimador de $q(\theta)$ cuando

$$\forall \theta \in \Theta, \quad \mathbb{E}_{\theta}(\delta_n) \xrightarrow{n \rightarrow \infty} q(\theta).$$

Definición 1.22. Se dirá que $\delta(\mathbf{X})$ es un estimador insesgado de mínima varianza para $q(\theta)$, uniformemente en $\theta \in \Theta(IMVU)$ si:

- (i) $\delta(\mathbf{X})$ es insesgado en $q(\theta)$.
- (ii) dado otro estimador insesgado para $q(\theta)$, $\delta^*(\mathbf{X})$ se cumple

$$\mathbb{V}_{\theta}(\delta(\mathbf{X})) \leq \mathbb{V}_{\theta}(\delta^*(\mathbf{X})), \quad \forall \theta \in \Theta.$$

1.3. Estadísticos suficientes

Consideremos un vector aleatorio $\mathbf{X}$ de dimensión n cuya distribución pertenece a una familia $\mathcal{F} = \{F(\mathbf{x}, \boldsymbol{\theta}) \text{ con } \boldsymbol{\theta} \in \Theta \subset \mathbb{R}^k\}$. El vector $\mathbf{X}$ interesa en cuanto nos provee información sobre el valor verdadero de $\boldsymbol{\theta}$. Puede ocurrir que una parte de la información contenida en $\mathbf{X}$ carezca de interés para el conocimiento de $\boldsymbol{\theta}$ y convenga eliminarla.

Eliminando de $\mathbf{X}$ toda la información irrelevante, se obtendrá otro vector $\mathbf{T}$ que puede ser de dimensión menor que n .

Definición 1.23. Llamaremos estadístico a cualquier función medible $\mathbf{T} = r(\mathbf{X})$ con valores en un espacio euclídeo de dimensión finita.

Definición 1.24. Se dice que un estadístico $\mathbf{T} = r(\mathbf{X})$ es suficiente para $\boldsymbol{\theta}$ si la distribución de $\mathbf{X}$ condicional a que $\mathbf{T} = \mathbf{t}$ es independiente de $\boldsymbol{\theta}$ para todo $\mathbf{t}$.

Observación 1.25. La definición anterior puede interpretarse como afirmando que una vez conocido el valor $\mathbf{t}$ de $\mathbf{T}$, la distribución de $\mathbf{X}$ es independiente de $\boldsymbol{\theta}$ y, por lo tanto, no contiene información suplementaria sobre $\boldsymbol{\theta}$.

Teorema 1.26. (Factorización):

Sea $\mathbf{X}$ un vector aleatorio con función de densidad o función de probabilidad puntual $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta})$, $\boldsymbol{\theta} \in \Theta$. Entonces, el estadístico $\mathbf{T} = r(\mathbf{X})$ es suficiente para $\boldsymbol{\theta}$ si y sólo si existen dos funciones g y h tales que

$$\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}) = g(r(\mathbf{X}), \boldsymbol{\theta})h(\mathbf{x}).$$

Demostración.

($\Leftarrow$): La haremos sólo para el caso discreto. Supongamos primero que existen dos funciones g y h tales que $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta})$ se factoriza. Entonces la función de densidad conjunta vale

$$\mathbb{P}_{\mathbf{XT}}(\mathbf{x}, \mathbf{t}, \boldsymbol{\theta}) = \begin{cases} g(\mathbf{t}, \boldsymbol{\theta})h(\mathbf{x}) & r(\mathbf{x}) = \mathbf{t} \\ 0 & r(\mathbf{x}) \neq \mathbf{t} \end{cases}$$

y la densidad marginal $\mathbb{P}_{\mathbf{T}}(\mathbf{t}, \boldsymbol{\theta})$ está dada por

$$\mathbb{P}_{\mathbf{T}}(\mathbf{t}, \boldsymbol{\theta}) = \sum_{r(\mathbf{x})=\mathbf{t}} \mathbb{P}_{\mathbf{XT}}(\mathbf{x}, \mathbf{t}, \boldsymbol{\theta}) = \sum_{r(\mathbf{x})=\mathbf{t}} g(r(\mathbf{x}), \boldsymbol{\theta})h(\mathbf{x}) = g(\mathbf{t}, \boldsymbol{\theta}) \sum_{r(\mathbf{x})=\mathbf{t}} h(\mathbf{x}) = g(\mathbf{t}, \boldsymbol{\theta})h^*(\mathbf{t})$$

donde las sumatorias se realizan sobre todos los $\mathbf{x} = (x_1, x_2, \dots, x_n)$ tales que $r(\mathbf{x}) = \mathbf{t}$. Así resulta la función de densidad condicional

$$\mathbb{P}_{\mathbf{X}|\mathbf{T}}(\mathbf{x}, \boldsymbol{\theta}|\mathbf{t}) = \begin{cases} \frac{h(\mathbf{x})}{h^*(\mathbf{t})} & r(\mathbf{x}) = \mathbf{t} \\ 0 & r(\mathbf{x}) \neq \mathbf{t} \end{cases}$$

y por lo tanto la distribución de $\mathbf{X}$ dado $\mathbf{T} = \mathbf{t}$ es independiente de $\boldsymbol{\theta}$ para todo $\mathbf{t}$.

($\Rightarrow$): Si suponemos que $\mathbf{T} = r(\mathbf{X})$ es suficiente para $\boldsymbol{\theta}$, se tiene

$$\mathbb{P}_{\boldsymbol{\theta}}(\mathbf{X} = \mathbf{x}) = \mathbb{P}_{\boldsymbol{\theta}}(\mathbf{X} = \mathbf{x}, \mathbf{T} = r(\mathbf{x})) = \mathbb{P}_{\mathbf{XT}}(\mathbf{x}, r(\mathbf{x}), \boldsymbol{\theta}) \Rightarrow$$

$$\mathbb{P}_{\boldsymbol{\theta}}(\mathbf{X} = \mathbf{x}) = \underbrace{\mathbb{P}_{\mathbf{X}|\mathbf{T}}(\mathbf{x}, \boldsymbol{\theta}|r(\mathbf{x}))}_{=h(\mathbf{x})} \underbrace{\mathbb{P}_{\mathbf{T}}(r(\mathbf{x}), \boldsymbol{\theta})}_{=g(r(\mathbf{X}), \boldsymbol{\theta})}$$

El primero de los factores del último miembro es por hipótesis independiente de $\boldsymbol{\theta}$ y por eso podemos llamarlo $h(\mathbf{x})$ y el segundo, que depende de $\mathbf{x}$ a través de $\mathbf{t}$, puede denominarse $g(r(\mathbf{X}), \boldsymbol{\theta})$. $\square$

Observación 1.27. El teorema anterior permite dar una caracterización de estadísticos suficientes.

Corolario 1.28. Sea $\mathbf{X}$ un vector aleatorio con función de densidad o función de probabilidad puntual $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta})$, $\boldsymbol{\theta} \in \Theta$. Supongamos que la familia $\{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta})\}$ tiene soporte común independiente de $\boldsymbol{\theta}$. Entonces, una condición necesaria y suficiente para que $\mathbf{T}$ sea suficiente para $\boldsymbol{\theta}$ es que fijados $\boldsymbol{\theta}_1$ y $\boldsymbol{\theta}_2$ el cociente $\frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2)}$ sea función de $\mathbf{T}$.

Demostración. (Idea):

Sea $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}) = h(\mathbf{x})g(r(\mathbf{X}), \boldsymbol{\theta})$, luego

$$\frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2)} = \frac{h(\mathbf{x})g(r(\mathbf{X}), \boldsymbol{\theta}_1)}{h(\mathbf{x})g(r(\mathbf{X}), \boldsymbol{\theta}_2)} = \frac{g(r(\mathbf{X}), \boldsymbol{\theta}_1)}{g(r(\mathbf{X}), \boldsymbol{\theta}_2)}.$$

$\square$

Teorema 1.29. Si $\mathbf{X}$ es un vector aleatorio con una distribución $F(\mathbf{x}, \boldsymbol{\theta})$, con $\boldsymbol{\theta} \in \Theta$ si $\mathbf{T} = r(\mathbf{X})$ es un estadístico suficiente para $\boldsymbol{\theta}$ y si m es una función biunívoca de $\mathbf{T}$ entonces el estadístico $\mathbf{T}^* = m(\mathbf{T})$ también es suficiente para $\boldsymbol{\theta}$.

Demostración. Apliquemos el teorema de factorización a la función de densidad del vector $\mathbf{X}$:

$$\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}) = g(r(\mathbf{X}), \boldsymbol{\theta})h(\mathbf{x}) = g[m^{-1}(m(r(\mathbf{x}))), \boldsymbol{\theta}]h(\mathbf{x}).$$

El primer factor del último miembro es una función $g^*(r^*(\mathbf{x}), \boldsymbol{\theta})$, donde $r^*(\mathbf{x}) = m(r(\mathbf{x}))$, y esto prueba que $\mathbf{T}^* = r^*(\mathbf{x})$ es suficiente para $\boldsymbol{\theta}$. $\square$

Observación 1.30. El teorema anterior muestra que una función biunívoca de un estadístico suficiente es también un estadístico suficiente; es decir, las funciones biunívocas preservan suficiencia de estadísticos.

1.4. Estadísticos minimales suficientes

Definición 1.31. Sea $\mathbf{X}$ un vector aleatorio de dimensión n cuya distribución es $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$. Se dice que un estadístico $\mathbf{T} = r(\mathbf{X})$ es minimal suficiente para $\boldsymbol{\theta}$ si dado cualquier otro estadístico $\mathbf{U} = g(\mathbf{X})$ suficiente para $\boldsymbol{\theta}$ existe una función H tal que $\mathbf{T} = H(\mathbf{U})$.

Definición 1.32. Llamaremos soporte de la densidad o de la probabilidad puntual $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta})$ al conjunto

$$S_{\boldsymbol{\theta}} = \{\mathbf{x} : \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}) > 0\}.$$

Teorema 1.33. Supongamos que $\mathbf{X}$ tiene una distribución perteneciente a una familia finita de distribuciones $\mathcal{F} = \{F(\mathbf{x}, \boldsymbol{\theta}_i), 1 \leq i \leq k\}$ con densidades o probabilidades puntuales $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_i)$ para $1 \leq i \leq k$ y todas con el mismo soporte. Entonces el estadístico

$$\mathbf{T} = r(\mathbf{x}) = \left(\frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2)}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)}, \dots, \frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_k)}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)} \right).$$

es minimal suficiente.

Demostración. Obviamente, para todo $1 \leq i < j \leq k$ el cociente $\frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_i)}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_j)}$ es función de $\mathbf{T}$. Por lo tanto, por el Corolario del teorema de Factorización, $\mathbf{T}$ es suficiente.

Sea ahora $\mathbf{U}$ un estadístico suficiente para $\boldsymbol{\theta}$. Entonces, utilizando el Corolario anterior se cumple que para todo $2 \leq i \leq k$ el cociente $\frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_i)}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)}$ es una función de $\mathbf{U}$.

Luego, $\mathbf{T}$ es función de $\mathbf{U}$ y $\mathbf{T}$ es minimal suficiente. $\square$

Teorema 1.34. Supongamos que $\mathbf{X}$ tiene una distribución perteneciente a una familia de distribuciones

$$\mathcal{F} = \{F(\mathbf{x}, \boldsymbol{\theta}) \text{ con } \boldsymbol{\theta} \in \Theta \subset \mathbb{R}^k\}$$

con densidades o probabilidades puntuales $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta})$, todas con el mismo soporte. Sea

$$\mathcal{F}_0 = \{F(\mathbf{x}, \boldsymbol{\theta}) \text{ con } \boldsymbol{\theta} \in \Theta_0 \subset \Theta\}$$

Supongamos además que $\mathbf{T} = r(\mathbf{X})$ es un estadístico minimal suficiente para $\boldsymbol{\theta} \in \Theta_0$ y suficiente para $\boldsymbol{\theta} \in \Theta$, entonces $\mathbf{T}$ es minimal suficiente para $\boldsymbol{\theta} \in \Theta$.

Demostración. Sea $\mathbf{U}$ un estadístico suficiente para $\boldsymbol{\theta}$, entonces $\mathbf{U}$ es suficiente para $\boldsymbol{\theta} \in \Theta_0$. Por lo tanto, $\mathbf{T}$ es función de $\mathbf{U}$, con lo cual $\mathbf{T}$ es minimal suficiente. $\square$

1.5. Estimadores basados en estadísticos suficientes

Teorema 1.35. (Teorema de Rao-Blackwell):

Sea $\mathbf{X}$ un vector de una distribución perteneciente a la familia $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$. Sea $\mathbf{T}$ un estadístico suficiente para $\boldsymbol{\theta} \in \Theta$ y $\delta(\mathbf{X})$ un estimador de $q(\boldsymbol{\theta})$. Definamos un nuevo estimador

$$\delta^*(\mathbf{T}) = \mathbb{E}(\delta(\mathbf{X})|\mathbf{T})$$

Luego se tiene

(i) $ECM_{\boldsymbol{\theta}}(\delta^*) \leq ECM_{\boldsymbol{\theta}}(\delta)$ para todo $\boldsymbol{\theta} \in \Theta$.

(ii) La igualdad en (i) se satisface si y sólo si $\mathbb{P}(\delta^*(\mathbf{T}) = \delta(\mathbf{X})) = 1$ para todo $\boldsymbol{\theta} \in \Theta$.

(iii) Si $\delta(\mathbf{X})$ es insesgado, entonces $\delta^*(\mathbf{T})$ también lo es.

Demostración.

(i) $ECM_{\boldsymbol{\theta}}(\delta) = \mathbb{E}_{\boldsymbol{\theta}}[(\delta(\mathbf{X}) - q(\boldsymbol{\theta}))^2] = \mathbb{E}_{\boldsymbol{\theta}}[(\delta(\mathbf{X}) \pm \delta^*(\mathbf{T}) - q(\boldsymbol{\theta}))^2]$, entonces

$$ECM_{\boldsymbol{\theta}}(\delta) = \mathbb{E}_{\boldsymbol{\theta}}[(\delta^*(\mathbf{T}) - q(\boldsymbol{\theta}))^2] + \mathbb{E}_{\boldsymbol{\theta}}[(\delta(\mathbf{X}) - \delta^*(\mathbf{T}))^2] + 2\mathbb{E}_{\boldsymbol{\theta}}[(\delta^*(\mathbf{T}) - q(\boldsymbol{\theta}))(\delta(\mathbf{X}) - \delta^*(\mathbf{T}))]$$

además usando $\mathbb{E}(\mathbb{E}(X|T)) = \mathbb{E}(X)$, se tiene que

$$\begin{aligned} \mathbb{E}_{\boldsymbol{\theta}}[(\delta^*(\mathbf{T}) - q(\boldsymbol{\theta}))(\delta(\mathbf{X}) - \delta^*(\mathbf{T}))] &= \mathbb{E}_{\boldsymbol{\theta}}\{\mathbb{E}[(\delta^*(\mathbf{T}) - q(\boldsymbol{\theta}))(\delta(\mathbf{X}) - \delta^*(\mathbf{T}))|\mathbf{T}]\} = \mathbb{E}_{\boldsymbol{\theta}}\{(\delta^*(\mathbf{T}) - q(\boldsymbol{\theta}))\mathbb{E}(\delta(\mathbf{X}) - \delta^*(\mathbf{T})|\mathbf{T})\} \\ &\Rightarrow \mathbb{E}_{\boldsymbol{\theta}}[(\delta^*(\mathbf{T}) - q(\boldsymbol{\theta}))(\delta(\mathbf{X}) - \delta^*(\mathbf{T}))] = (\delta^*(\mathbf{T}) - q(\boldsymbol{\theta}))\mathbb{E}_{\boldsymbol{\theta}}\{\mathbb{E}(\delta(\mathbf{X}) - \delta^*(\mathbf{T})|\mathbf{T})\} \Rightarrow \\ \mathbb{E}_{\boldsymbol{\theta}}[(\delta^*(\mathbf{T}) - q(\boldsymbol{\theta}))(\delta(\mathbf{X}) - \delta^*(\mathbf{T}))] &= (\delta^*(\mathbf{T}) - q(\boldsymbol{\theta}))(\mathbb{E}(\delta(\mathbf{X})|\mathbf{T}) - \delta^*(\mathbf{T})) \underbrace{=}_{\mathbb{E}(\delta(\mathbf{X})|\mathbf{T})=\delta^*(\mathbf{T})} (\delta^*(\mathbf{T}) - q(\boldsymbol{\theta}))(\delta^*(\mathbf{T}) - \delta^*(\mathbf{T})) = 0. \end{aligned}$$

Luego,

$$ECM_{\boldsymbol{\theta}}(\delta) = \mathbb{E}_{\boldsymbol{\theta}}[(\delta(\mathbf{X}) - q(\boldsymbol{\theta}))^2] = ECM_{\boldsymbol{\theta}}(\delta^*) + ECM_{\boldsymbol{\theta}}[(\delta(\mathbf{X}) - \delta^*(\mathbf{T}))^2]$$

y resulta $ECM_{\boldsymbol{\theta}}(\delta) \leq ECM_{\boldsymbol{\theta}}(\delta^*)$.

(ii) Naturalmente, la igualdad se cumple sólo si $\mathbb{P}_{\boldsymbol{\theta}}(\delta(\mathbf{X}) = \delta^*(\mathbf{T})) = 1$ para todo $\boldsymbol{\theta} \in \Theta$.

(iii) Supongamos que δ es insesgado, luego se tiene

$$\mathbb{E}_{\boldsymbol{\theta}}(\delta^*(\mathbf{T})) = \mathbb{E}_{\boldsymbol{\theta}}(\mathbb{E}(\delta(\mathbf{X})|\mathbf{T})) = \mathbb{E}_{\boldsymbol{\theta}}(\delta(\mathbf{X})) = q(\boldsymbol{\theta}).$$

□

1.6. Familias exponenciales

Definición 1.36. Se dice que una familia de distribuciones continuas o discretas en $\mathbb{R}^m$, $F(\mathbf{x}, \boldsymbol{\theta})$, donde $\mathbf{x} = (x_1, \dots, x_m)$ y $\boldsymbol{\theta} \in \Theta \subset \mathbb{R}^m$ es una familia exponencial a k parámetros si la correspondiente función de densidad discreta o continua se puede escribir como

$$\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}) = A(\boldsymbol{\theta}) \exp \left\{ \sum_{i=1}^k c_i(\boldsymbol{\theta}) r_i(\mathbf{x}) \right\} h(\mathbf{x})$$

donde

(i) $c_i : \Theta \rightarrow \mathbb{R}$ para todo $i \in \{1, \dots, k\}$.

(iii) $r_i : \mathbb{R}^m \rightarrow \mathbb{R}$ para todo $i \in \{1, \dots, k\}$.

(ii) $A(\boldsymbol{\theta})$ es una función de Θ a $\mathbb{R}^+$.

(iv) $h(\mathbf{x})$ es una función de $\mathbb{R}^m$ a $\mathbb{R}^+$.

Teorema 1.37. Una familia exponencial a k parámetros cuya función de densidad viene dada por

$$\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}) = A(\boldsymbol{\theta}) \exp \left\{ \sum_{i=1}^k c_i(\boldsymbol{\theta}) r_i(\mathbf{x}) \right\} h(\mathbf{x})$$

tiene como estadístico suficiente para $\boldsymbol{\theta}$ el vector

$$\mathbf{T} = r(\mathbf{X}) = (r_1(\mathbf{X}), \dots, r_k(\mathbf{X})).$$

Demostración. Se deduce del Teorema de Factorización. □

Observación 1.38. El siguiente teorema afirma que para familias exponenciales de k parámetros, cualquiera sea el tamaño de la muestra, siempre existe un estadístico suficiente de sólo k componentes. Es decir, que toda la información se puede resumir en k variables aleatorias.

Teorema 1.39. Sea $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ una muestra aleatoria de una distribución que pertenece a una familia exponencial a k parámetros, cuya función de densidad viene dada por

$$\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}) = A(\boldsymbol{\theta}) \exp \left\{ \sum_{i=1}^k c_i(\boldsymbol{\theta}) r_i(\mathbf{x}) \right\} h(\mathbf{x})$$

Luego la distribución conjunta de $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ también pertenece a una familia exponencial a k parámetros y el estadístico suficiente para $\boldsymbol{\theta}$ es el vector

$$\mathbf{T}^* = (T_1^*, \dots, T_k^*), \text{ donde } T_i^* = \sum_{j=1}^n r_i(\mathbf{X}_j) \text{ con } 1 \leq i \leq k.$$

Demostración.

$$\mathbb{P}(x_1, x_2, \dots, x_n, \boldsymbol{\theta}) = \prod_{j=1}^n \mathbb{P}(x_j, \boldsymbol{\theta}) = A^n(\boldsymbol{\theta}) \exp \left\{ c_1(\boldsymbol{\theta}) \sum_{j=1}^n r_1(x_j) + \dots + c_k(\boldsymbol{\theta}) \sum_{j=1}^n r_k(x_j) \right\} \prod_{j=1}^n h(x_j) \Rightarrow$$

$$\mathbb{P}(x_1, x_2, \dots, x_n, \boldsymbol{\theta}) = A^*(\boldsymbol{\theta}) \exp \left\{ \sum_{j=1}^k c_j(\boldsymbol{\theta}) r_j^*(x_1, \dots, x_n) \right\} h^*(x_1, \dots, x_n)$$

donde $A^*(\boldsymbol{\theta}) = A^n(\boldsymbol{\theta})$, $r_i^*(x_1, \dots, x_n) = \sum_{j=1}^n r_i(x_j)$ y $h^*(x_1, \dots, x_n) = \prod_{j=1}^n h(x_j)$. □

Teorema 1.40. Sea $\mathbf{X}$ un vector cuya distribución pertenece a una familia exponencial a k parámetros cuya función de densidad satisfice

$$\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}) = A(\boldsymbol{\theta}) \exp \left\{ \sum_{i=1}^k c_i(\boldsymbol{\theta}) r_i(\mathbf{x}) \right\} h(\mathbf{x}).$$

Luego la función de densidad de los estadísticos suficientes $\mathbf{T} = (r_1(\mathbf{X}), \dots, r_k(\mathbf{X}))$ es de la forma

$$\mathbb{P}_{\mathbf{T}}(t_1, t_2, \dots, t_k, \boldsymbol{\theta}) = A(\boldsymbol{\theta}) e^{c_1(\boldsymbol{\theta})t_1 + \dots + c_k(\boldsymbol{\theta})t_k} h^*(t_1, \dots, t_k).$$

Por lo tanto la familia de distribuciones de $\mathbf{T}$ también forma una familia exponencial a k parámetros.

Demostración. Sólo se hará para el caso discreto.

$$\mathbb{P}(x_1, x_2, \dots, x_n, \boldsymbol{\theta}) = A(\boldsymbol{\theta}) \exp \left\{ \sum_{j=1}^k c_j(\boldsymbol{\theta}) r_j(\mathbf{x}) \right\} h(\mathbf{x}).$$

Luego, si $\mathbf{T} = r(\mathbf{x}) = (r_1(\mathbf{x}), \dots, r_k(\mathbf{x}))$ y si $\mathbf{t} = (t_1, \dots, t_k)$ se tendrá

$$\mathbb{P}_{\mathbf{T}}(\mathbf{t}, \boldsymbol{\theta}) = \sum_{\{\mathbf{x}: r(\mathbf{x})=\mathbf{t}\}} \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}) = \sum_{\{\mathbf{x}: r(\mathbf{x})=\mathbf{t}\}} A(\boldsymbol{\theta}) \exp \left\{ \sum_{j=1}^k c_j(\boldsymbol{\theta}) r_j(\mathbf{x}) \right\} h(\mathbf{x}) = A(\boldsymbol{\theta}) \exp \left\{ \sum_{j=1}^k c_j(\boldsymbol{\theta}) t_j \right\} \sum_{\{\mathbf{x}: r(\mathbf{x})=\mathbf{t}\}} h(\mathbf{x}).$$

□

Observación 1.41. El teorema anterior establece que las familias de distribuciones de los estadísticos suficientes de una familia exponencial a k parámetros también forma una familia exponencial a k parámetros.

Teorema 1.42. Sea $\mathbf{X} = (X_1, \dots, X_m)$ un vector aleatorio cuya distribución pertenece a una familia exponencial a un parámetro con densidad dada por $\mathbb{P}(\mathbf{x}, \theta) = A(\theta) e^{c(\theta)r(\mathbf{x})} h(\mathbf{x})$ con $\theta \in \Theta$, donde Θ es un abierto en $\mathbb{R}$ y $c(\theta)$ es infinitamente derivable. Luego se tiene:

$$(i) \ A(\theta) \text{ es infinitamente derivable.} \quad (ii) \ \mathbb{E}_{\theta}(r(\mathbf{x})) = -\frac{A'(\theta)}{A(\theta)c'(\theta)}. \quad (iii) \ \nabla_{\theta}(r(\mathbf{x})) = \frac{1}{c'(\theta)} \frac{\partial \mathbb{E}_{\theta} r(\mathbf{x})}{\partial \theta}.$$

Demostración.

(i) Supongamos que $\mathbf{X}$ sea continuo. El caso discreto es totalmente similar. Como

$$\int \dots \int A(\theta) e^{c(\theta)r(\mathbf{x})} h(\mathbf{x}) dx_1 \dots dx_m = 1 \Rightarrow \frac{1}{A(\theta)} = \int \dots \int e^{c(\theta)r(\mathbf{x})} h(\mathbf{x}) dx_1 \dots dx_m$$

Como el segundo miembro es infinitamente derivable, $A(\theta)$ también.

(ii) Para todo $\theta \in \Theta$, $\int \dots \int A(\theta) e^{c(\theta)r(\mathbf{x})} h(\mathbf{x}) dx_1 \dots dx_m = 1 \Rightarrow$

$$A'(\theta) \int \dots \int e^{c(\theta)r(\mathbf{x})} h(\mathbf{x}) dx_1 \dots dx_m + A(\theta) c'(\theta) \int \dots \int r(\mathbf{x}) e^{c(\theta)r(\mathbf{x})} h(\mathbf{x}) dx_1 \dots dx_m = 0$$

multiplicando y dividiendo por $A(\theta)$, esta última ecuación se puede escribir

$$\frac{A'(\theta)}{A(\theta)} + c'(\theta) \mathbb{E}_{\theta}(r(\mathbf{x})) = 0 \Rightarrow \mathbb{E}_{\theta}(r(\mathbf{x})) = -\frac{A'(\theta)}{A(\theta)c'(\theta)}.$$

(iii) $\mathbb{E}_\theta(r(\mathbf{x})) = \int \dots \int r(\mathbf{x})A(\theta)e^{c(\theta)r(\mathbf{x})}h(\mathbf{x})dx_1 \dots dx_m$, entonces

$$\begin{aligned}\frac{\partial \mathbb{E}_\theta r(\mathbf{x})}{\partial \theta} &= \int \dots \int r(\mathbf{x})A'(\theta)e^{c(\theta)r(\mathbf{x})}h(\mathbf{x})dx_1 \dots dx_m + \int \dots \int r^2(\mathbf{x})c'(\theta)A(\theta)e^{c(\theta)r(\mathbf{x})}h(\mathbf{x})dx_1 \dots dx_m \Rightarrow \\ \frac{\partial \mathbb{E}_\theta r(\mathbf{x})}{\partial \theta} &= \frac{A'(\theta)}{A(\theta)}\mathbb{E}_\theta(r(\mathbf{x})) + c'(\theta)\mathbb{E}_\theta(r^2(\mathbf{x})) = \frac{A'(\theta)}{A(\theta)}\frac{c'(\theta)}{c'(\theta)}\mathbb{E}_\theta(r(\mathbf{x})) + c'(\theta)\mathbb{E}_\theta(r^2(\mathbf{x})) \Rightarrow \\ \frac{\partial \mathbb{E}_\theta r(\mathbf{x})}{\partial \theta} &= \mathbb{E}_\theta(r(\mathbf{x}))c'(\theta)\mathbb{E}_\theta(r(\mathbf{x})) + c'(\theta)\mathbb{E}_\theta(r^2(\mathbf{x})) = -c'(\theta)\mathbb{E}_\theta^2(r(\mathbf{x})) + c'(\theta)\mathbb{E}_\theta(r^2(\mathbf{x})) = c'(\theta)\mathbb{V}_\theta(r(\mathbf{x})) \\ &\Rightarrow \mathbb{V}_\theta(r(\mathbf{x})) = \frac{1}{c'(\theta)}\frac{\partial \mathbb{E}_\theta r(\mathbf{x})}{\partial \theta}.\end{aligned}$$

□

1.7. Estadísticos completos

Definición 1.43. Sea $\mathbf{X}$ un vector aleatorio cuya distribución pertenece a una familia $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$. Un estadístico $\mathbf{T} = r(\mathbf{X})$ se dice completo si $\mathbb{E}_\theta(g(\mathbf{T})) = 0$ para todo $\boldsymbol{\theta}$ implica que $p_\theta(g(\mathbf{T}) = 0) = 1$ para todo $\boldsymbol{\theta} \in \Theta$.

Teorema 1.44. Sea una familia exponencial a k paámetros, discreta o continua con función de densidad dada por

$$\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}) = A(\boldsymbol{\theta})e^{c_1(\boldsymbol{\theta})r_1(\mathbf{x}) + \dots + c_k(\boldsymbol{\theta})r_k(\mathbf{x})}h(\mathbf{x})$$

y sea $\Lambda = \{\boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_k) : \lambda_i = c_i(\boldsymbol{\theta}) \mid \boldsymbol{\theta} \in \Theta\}$.

(i) Si Λ contiene $k+1$ puntos $\boldsymbol{\lambda}^{(1)}, \dots, \boldsymbol{\lambda}^{(k+1)}$ tales que

$$\{\boldsymbol{\lambda}^{(j)} - \boldsymbol{\lambda}^{(1)}, 2 \leq j \leq k+1\}$$

son linealmente independientes, entonces el estadístico suficiente $\mathbf{T} = (r_1(\mathbf{X}), \dots, r_k(\mathbf{X}))$ es minimal suficiente.

(ii) Si Λ un conjunto que contiene una esfera en $\mathbb{R}^k$, entonces estadístico suficiente $\mathbf{T} = (r_1(\mathbf{X}), \dots, r_k(\mathbf{X}))$ es completo.

Demostración.

(i) Como $\mathbf{T}$ es suficiente para $\mathcal{F} = \{\mathbb{P}(x_1, x_2, \dots, x_n, \boldsymbol{\theta}) = A(\boldsymbol{\theta})e^{c_1(\boldsymbol{\theta})r_1(\mathbf{x}) + \dots + c_k(\boldsymbol{\theta})r_k(\mathbf{x})}\} : \boldsymbol{\theta} \in \Theta$, sólo basta con probar que $\mathbf{T}$ es minimal suficiente para una subfamilia finita de $\mathcal{F}$ (**Teorema 1.34**).

Sean $\boldsymbol{\theta}^{(j)}$, $1 \leq j \leq k+1$ tales que

$$\boldsymbol{\lambda}^{(j)} = (\lambda_1^{(j)}, \dots, \lambda_k^{(j)}) = (c_1(\boldsymbol{\theta}^{(j)}), \dots, c_k(\boldsymbol{\theta}^{(j)}))$$

Consideremos la subfamilia

$$\mathcal{F}_0 = \left\{ p(\mathbf{x}, \boldsymbol{\theta}^{(j)}) = A(\boldsymbol{\theta}^{(j)}) \exp \left\{ \sum_{i=1}^k c_i(\boldsymbol{\theta}^{(j)})r_i(\mathbf{x}) \right\} h(\mathbf{x}) = A(\boldsymbol{\theta}^{(j)}) \exp \left\{ \sum_{i=1}^k \lambda_i^{(j)}r_i(\mathbf{x}) \right\} h(\mathbf{x}), \text{ con } 1 \leq j \leq k+1 \right\}$$

Luego, por **Teorema 1.33**, un estadístico minimal suficiente para $\mathcal{F}_0$ está dado por

$$\mathbf{T}^* = \left(\frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}^{(2)})}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}^{(1)})}, \dots, \frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}^{(k+1)})}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}^{(1)})} \right) = \left(\frac{A(\boldsymbol{\theta}^{(2)})e^{\lambda_1^{(2)}r_1(\mathbf{x}) + \dots + \lambda_k^{(2)}r_k(\mathbf{x})}}{A(\boldsymbol{\theta}^{(1)})e^{\lambda_1^{(1)}r_1(\mathbf{x}) + \dots + \lambda_k^{(1)}r_k(\mathbf{x})}}, \dots, \frac{A(\boldsymbol{\theta}^{(k+1)})e^{\lambda_1^{(k+1)}r_1(\mathbf{x}) + \dots + \lambda_k^{(k+1)}r_k(\mathbf{x})}}{A(\boldsymbol{\theta}^{(1)})e^{\lambda_1^{(1)}r_1(\mathbf{x}) + \dots + \lambda_k^{(1)}r_k(\mathbf{x})}} \right)$$

que es equivalente a

$$\mathbf{T}^{**} = \left(\sum_{i=1}^k [\lambda_i^{(2)} - \lambda_i^{(1)}]r_i(\mathbf{x}), \dots, \sum_{i=1}^k [\lambda_i^{(k+1)} - \lambda_i^{(1)}]r_i(\mathbf{x}) \right)$$

Como $\mathbf{T}^{**} = M\mathbf{T}$ donde la matriz $M \in \mathbb{R}^{k \times k}$ es no singular, ya que su j -ésima columna es el vector $\lambda_i^{(k+1)} - \lambda_i^{(1)}$, $\mathbf{T}$ es equivalente a $\mathbf{T}^{**}$ y, por lo tanto, es minimal suficiente para $\mathcal{F}_0$.

(ii) Sólo se demostrará para el caso que $k = 1$, y que $\mathbf{T} = r(\mathbf{X})$ toma un número finito de valores racionales. En este caso la función de densidad de $\mathbf{T}$ será de la forma:

$$\mathbb{P}(t, \boldsymbol{\theta}) = A(\boldsymbol{\theta})e^{c(\boldsymbol{\theta})t}h(t)$$

Supongamos que los posibles valores de $\mathbf{T}$ que tienen probabilidad positiva forman el conjunto

$$\mathcal{A} = \{t_1, t_2, \dots, t_r\} \cup \{-t'_1, \dots, -t'_s\}$$

donde los t_i y los t'_j son racionales no negativos.

Sea v un múltiplo común de los denominadores de todos los racionales t_i y los t'_j y sean $w_i = vt_i$ con $1 \leq i \leq r$ y $w'_j = vt'_j$ con $1 \leq j \leq s$. Luego, los w_i y los w'_j son naturales. Finalmente, sea $w = \max_{1 \leq j \leq s} w'_j$ tal que $z_i = w_i + w$ para todo $1 \leq i \leq r$ y $z'_j = -w'_j + w$ para todo $1 \leq j \leq s$ son números naturales diferentes.

Si $\mathbb{E}_{\boldsymbol{\theta}}(g(\mathbf{T})) = 0$ para todo $\boldsymbol{\theta} \in \Theta$, entonces para todo $\boldsymbol{\theta} \in \Theta$,

$$\begin{aligned} \sum_{i=1}^r g(t_i) \mathbb{P}(t_i, \boldsymbol{\theta}) + \sum_{j=1}^s g(-t'_j) \mathbb{P}(-t'_j, \boldsymbol{\theta}) &= 0 \Rightarrow \sum_{i=1}^r g(t_i) A(\boldsymbol{\theta}) e^{c(\boldsymbol{\theta}) t_i} h(t_i) + \sum_{j=1}^s g(-t'_j) A(\boldsymbol{\theta}) e^{c(\boldsymbol{\theta}) (-t'_j)} h(-t'_j) = 0 \\ \Rightarrow \forall \boldsymbol{\theta} \in \Theta, \sum_{i=1}^r g(t_i) h(t_i) \left(e^{c(\boldsymbol{\theta})/v} \right)^{vt_i} + \sum_{j=1}^s g(-t'_j) h(-t'_j) \left(e^{c(\boldsymbol{\theta})/v} \right)^{-vt'_j} &= 0. \end{aligned}$$

Llamando $\lambda = e^{c(\boldsymbol{\theta})/v}$ resulta que como hay infinitos posibles valores de $c(\boldsymbol{\theta})$, el conjunto Λ de posibles valores de λ , también es infinito. Luego para todo $\lambda \in \Lambda$ tenemos

$$\sum_{i=1}^r g(t_i) h(t_i) \lambda^{w_i} + \sum_{j=1}^s g(-t'_j) h(-t'_j) \lambda^{-w'_j} = 0$$

multiplicando por λ^w , tenemos el polinomio

$$P(\lambda) := \sum_{i=1}^r g(t_i) h(t_i) \lambda^{z_i} + \sum_{j=1}^s g(-t'_j) h(-t'_j) \lambda^{z'_j} = 0, \quad \forall \lambda \in \Lambda$$

y, por lo tanto, $P(\lambda)$ tiene infinitas raíces.

Luego todos los coeficientes deben ser 0; es decir, $g(t_i) h(t_i) = 0$ para todo $i \in \{1, \dots, r\}$ y $g(-t'_j) h(-t'_j) = 0$ para todo $j \in \{1, \dots, s\}$. Como $h(t_i), h(-t'_j) > 0$ para todo $i \in \{1, \dots, r\}$ y para todo $j \in \{1, \dots, s\}$ resulta que $g(t_i), g(-t'_j) = 0$ para todo $i \in \{1, \dots, r\}$ y para todo $j \in \{1, \dots, s\}$.

Luego, $\mathbb{P}_{\boldsymbol{\theta}}(g(\mathbf{T}) = 0) = 1$ para todo $\boldsymbol{\theta} \in \Theta$. □

Observación 1.45.

- (i) El teorema anterior muestra que bajo condiciones muy generales el estadístico suficiente que correspondiente a una familia exponencial es completo.
- (ii) Un estadístico minimal suficiente no necesariamente es completo.

Teorema 1.46. Sea $\mathbf{T}$ un estadístico suficiente y completo para $\boldsymbol{\theta}$. Si existe un estadístico minimal suficiente para $\boldsymbol{\theta}$ entonces $\mathbf{T}$ es minimal suficiente.

Demostración. La haremos sólo en el caso en que el estadístico minimal suficiente y el estadístico suficiente y completo $\mathbf{T}$ tienen dimensión 1.

Sea $\mathbf{U}$ el estadístico minimal suficiente para $\boldsymbol{\theta}$, luego por ser $\mathbf{T}$ suficiente se cumple que $\mathbf{U} = m(\mathbf{T})$ (usando la definición de minimal suficiente). Queremos ver que m es biunívoca.

Sea $\psi(t)$ la función arcotangente. Luego $\psi : \mathbb{R} \rightarrow [0, 2\pi]$ es una función estrictamente creciente y acotada. Por lo tanto, $\mathbb{E}_{\boldsymbol{\theta}}(\psi(\mathbf{T})) < \infty$ y bastará mostrar que $\psi(\mathbf{T})$ es función de $\mathbf{U}$.

Sea $\nu(\mathbf{U}) = \mathbb{E}(\psi(\mathbf{T})|\mathbf{U})$. Como $\mathbf{U}$ es suficiente $\nu(\mathbf{U})$ es un estadístico. Luego,

$$g(\mathbf{T}) = \psi(\mathbf{T}) - \nu[m(\mathbf{T})] = \psi(\mathbf{T}) - \nu(\mathbf{U})$$

y, entonces, $\mathbb{E}_{\boldsymbol{\theta}}(g(\mathbf{T})) = 0$ para todo $\boldsymbol{\theta} \in \Theta$.

Por lo tanto, como $\mathbf{T}$ es completo, $\mathbb{P}_{\boldsymbol{\theta}}(\psi(\mathbf{T}) = \nu(\mathbf{U})) = 1$ para todo $\boldsymbol{\theta} \in \Theta$, y, entonces, $\mathbf{T}$ es equivalente a $\mathbf{U}$. □

Teorema 1.47. (Teorema de Basu):

Sea $\mathbf{T}$ un estadístico suficiente y completo para $\boldsymbol{\theta}$. Sea $\mathbf{U} = g(\mathbf{X})$ un estadístico cuya distribución no depende de $\boldsymbol{\theta}$ entonces $\mathbf{U}$ es independiente de $\mathbf{T}$.

Demostración. Sea A un suceso, como $\mathbf{U}$ tiene distribución independiente de $\boldsymbol{\theta}$, $\mathbb{P}_A = \mathbb{P}(\mathbf{U} \in A)$ no depende de $\boldsymbol{\theta}$. Sea $\nu_A(t) = \mathbb{P}(\mathbf{U} \in A | \mathbf{T} = t)$. Como $\mathbf{T}$ es suficiente $\nu_A(\mathbf{T})$ es un estadístico que no depende de $\boldsymbol{\theta}$.

Por otra parte, $\mathbb{E}_{\boldsymbol{\theta}}(\nu_A(\mathbf{T}) - \mathbb{P}_A) = 0$ para todo $\boldsymbol{\theta} \in \Theta$, con lo cual la completitud de $\mathbf{T}$ implica que $\mathbb{P}_{\boldsymbol{\theta}}(\nu_A(\mathbf{T}) = \mathbb{P}_A) = 1$ para todo $\boldsymbol{\theta} \in \Theta$ y por lo tanto, $\mathbf{U}$ es independiente de $\mathbf{T}$. □

Observación 1.48. El teorema anterior es útil en situaciones donde probar independencia entre estadísticos puede resultar laborioso.

1.8. Estimadores insesgados de mínima varianza uniformemente

Teorema 1.49. (*Lehmann-Scheffé*):

Sea $\mathbf{X}$ un vector aleatorio de cuya distribución pertenece a la familia $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$. Sea $\mathbf{T}$ un estadístico suficiente y completo.

Luego dada una función $q(\boldsymbol{\theta})$ de Θ en $\mathbb{R}$, se tiene que:

- (i) Existe a lo sumo un estimador insesgado de $q(\boldsymbol{\theta})$, basado en $\mathbf{T}$.
- (ii) Si $\delta(\mathbf{T})$ es un estimador insesgado de $q(\boldsymbol{\theta})$, entonces $\delta(\mathbf{T})$ es IMVU.
- (iii) Si $\delta(\mathbf{X})$ es un estimador insesgado para $q(\boldsymbol{\theta})$, luego $\delta^*(\mathbf{T}) = \mathbb{E}(\delta(\mathbf{X})|\mathbf{T})$ es un estimador IMVU para $q(\boldsymbol{\theta})$.

Demostración.

- (i) Sean $\delta_1(\mathbf{T})$ y $\delta_2(\mathbf{T})$ dos estimadores insesgados de $q(\boldsymbol{\theta})$. Luego,

$$\mathbb{E}_{\boldsymbol{\theta}}(\delta_1(\mathbf{T}) - \delta_2(\mathbf{T})) = 0, \quad \forall \boldsymbol{\theta} \in \Theta$$

como $\mathbf{T}$ es completo,

$$\mathbb{P}_{\boldsymbol{\theta}}(\delta_1(\mathbf{T}) - \delta_2(\mathbf{T}) = 0) = 1, \quad \forall \boldsymbol{\theta} \in \Theta.$$

- (ii) Sea $\delta(\mathbf{T})$ un estimador insesgado de $q(\boldsymbol{\theta})$, y sea $\delta_1(\mathbf{X})$ otro estimador insesgado. Si llamamos $\delta_1^*(\mathbf{T}) = \mathbb{E}(\delta_1(\mathbf{X})|\mathbf{T})$ sabemos, por el Teorema de Rao-Blackwell, que $\delta_1^*(\mathbf{T})$ es insesgado y para todo $\boldsymbol{\theta} \in \Theta$

$$ECM_{\boldsymbol{\theta}}(\delta_1^*) = \mathbb{V}_{\boldsymbol{\theta}}(\delta_1^*) \leq \mathbb{V}_{\boldsymbol{\theta}}(\delta_1) = ECM_{\boldsymbol{\theta}}(\delta_1)$$

Por otra parte, por el inciso anterior se tiene que $\delta_1^*(\mathbf{T}) = \delta(\mathbf{T})$ con probabilidad 1. Luego, $\mathbb{V}_{\boldsymbol{\theta}}(\delta_1^*) = \mathbb{V}_{\boldsymbol{\theta}}(\delta)$ y, entonces, $\mathbb{V}_{\boldsymbol{\theta}}(\delta) \leq \mathbb{V}_{\boldsymbol{\theta}}(\delta_1)$.

- (iii) Por el Teorema de Rao-Blackwell, $\delta^*(\mathbf{T})$ es insesgado. Y por otra parte, por el inciso anterior, se deduce que es un estimador IMVU para $q(\boldsymbol{\theta})$. $\square$

Observación 1.50.

- (i) El teorema anterior da un método para construir estimadores IMVU cuando se conoce un estadístico que es a la vez suficiente y completo.
- (ii) De acuerdo al inciso (ii) del teorema anterior, en el caso de tener un estadístico suficiente y completo $\mathbf{T}$, cualquier estimador insesgado basado en $\mathbf{T}$ es un estimador IMVU.
- (iii) El inciso (iii) del teorema anterior, indica cómo construir un estimador IMVU de $q(\boldsymbol{\theta})$ a partir de cualquier estimador insesgado.

Teorema 1.51. Sea $\mathbf{X}$ un vector aleatorio cuya distribución pertenece a una familia exponencial a k parámetros con función de densidad dada por

$$\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}) = A(\boldsymbol{\theta}) \exp \left\{ \sum_{i=1}^k c_i(\boldsymbol{\theta}) r_i(\mathbf{x}) \right\} h(\mathbf{x})$$

donde $\boldsymbol{\theta}$ toma valores en el conjunto Θ . Supongamos además que

$$\Lambda = \{\boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_k) : \lambda_i = c_i(\boldsymbol{\theta}) \mid \boldsymbol{\theta} \in \Theta\}$$

contiene una esfera en $\mathbb{R}^k$.

Sea $\mathbf{T} = (r_1(\mathbf{X}), \dots, r_k(\mathbf{X}))$ tal que $\delta(\mathbf{T})$ es un estimador insesgado de $q(\boldsymbol{\theta})$, entonces $\delta(\mathbf{T})$ es un estimador IMVU para $q(\boldsymbol{\theta})$.

Demostración. Puesto que la familia de distribuciones de $\mathbf{T}$ también forma una familia exponencial a k parámetros, el resultado se deduce del Teorema de Lehmann-Scheffé. $\square$

Teorema 1.52. Supongamos que $\mathbf{X}$ es un vector aleatorio de cuya distribución pertenece a la familia $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$. Sea $\Delta = \{\delta(\mathbf{X}) : \mathbb{E}_{\boldsymbol{\theta}}(\delta^2(\mathbf{X})) < \infty\}$.

Sea $\mathcal{U} = \{\delta(\mathbf{X}) \in \Delta : \mathbb{E}_{\boldsymbol{\theta}}(\delta(\mathbf{X})) = 0, \forall \boldsymbol{\theta} \in \Theta\}$. Una condición necesaria y suficiente para que $\delta \in \Delta$, insesgado, sea IMVU para $q(\boldsymbol{\theta})$ es que $\mathbb{E}_{\boldsymbol{\theta}}(\delta(\mathbf{X})U) = 0$, para todo $\boldsymbol{\theta} \in \Theta$ y para todo $U \in \mathcal{U}$.

1.9. Desigualdad de Rao-Cramer

Definición 1.53. Definimos las Condiciones de Rao-Cramer a las siguientes

- (A) El conjunto $S = \{\mathbf{x} : \mathbb{P}(\mathbf{x}, \theta) > 0\}$ es independiente de θ .
 (B) Para todo $\mathbf{x}$, $\mathbb{P}(\mathbf{x}, \theta)$ es derivable respecto de θ .
 (C) Si $h(\mathbf{X})$ es un estadístico tal que $\mathbb{E}_\theta(|h(\mathbf{X})|) < \infty$ para todo $\theta \in \Theta$, entonces se tiene

$$\frac{\partial}{\partial \theta} \left[\int_{\mathbb{R}} \dots \int_{\mathbb{R}} h(\mathbf{x}) \mathbb{P}(\mathbf{x}, \theta) d\mathbf{x} \right] = \int_{\mathbb{R}} \dots \int_{\mathbb{R}} h(\mathbf{x}) \frac{\partial \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta} d\mathbf{x}$$

donde $d\mathbf{x} = (dx_1, \dots, dx_n)$ (es decir, se puede derivar dentro del signo integral).

- (D) $0 < I(\theta) = \mathbb{E}_\theta \left[\left(\frac{\partial \ln(\mathbb{P}(\mathbf{X}, \theta))}{\partial \theta} \right)^2 \right] < \infty$. $I(\theta)$ se denomina número de información de Fisher.

Lema 1.54. Supongamos que se cumplen las Condiciones de Rao-Cramer. Sea $\psi(\mathbf{X}, \theta) = \frac{\partial \ln(\mathbb{P}(\mathbf{X}, \theta))}{\partial \theta}$. Entonces

- (i) $\mathbb{E}_\theta(\psi(\mathbf{X}, \theta)) = 0$ y $\mathbb{V}_\theta(\psi(\mathbf{X}, \theta)) = I(\theta)$.
 (ii) Si además existe la derivada segunda de $\mathbb{P}(\mathbf{x}, \theta)$ respecto de θ y si para todo estadístico $h(\mathbf{X})$ tal que $\mathbb{E}_\theta(|h(\mathbf{X})|) < \infty$ para todo $\theta \in \Theta$, se cumple que

$$\frac{\partial^2}{\partial \theta^2} \left[\int_{\mathbb{R}} \dots \int_{\mathbb{R}} h(\mathbf{x}) \mathbb{P}(\mathbf{x}, \theta) d\mathbf{x} \right] = \int_{\mathbb{R}} \dots \int_{\mathbb{R}} h(\mathbf{x}) \frac{\partial^2 \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta^2} d\mathbf{x}$$

$$\text{entonces } I(\theta) = -\mathbb{E}_\theta \left(\frac{\partial^2 \ln(\mathbb{P}(\mathbf{X}, \theta))}{\partial \theta^2} \right) = -\mathbb{E}_\theta \left(\frac{\partial \psi(\mathbf{X}, \theta)}{\partial \theta} \right).$$

Demostración.

- (i) Por ser $\mathbb{P}(\mathbf{x}, \theta)$ una densidad, si S es el conjunto definido en la condición (A) se tiene

$$\int_{\mathbb{R}} \dots \int_{\mathbb{R}} \mathbb{P}(\mathbf{x}, \theta) d\mathbf{x} = \int_{\mathbb{R}} \dots \int_{\mathbb{R}} \mathbb{P}(\mathbf{x}, \theta) \mathbb{1}_S d\mathbf{x} = 1$$

donde $\mathbb{1}_S$ es la función indicadora del conjunto S . Luego aplicando la condición (C) a $h(\mathbf{x}) = \mathbb{1}_S(\mathbf{x})$ se obtiene derivando ambos miembros que

$$0 = \int_{\mathbb{R}} \dots \int_{\mathbb{R}} \frac{\partial \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta} \mathbb{1}_S(\mathbf{x}) d\mathbf{x} = \int_{\mathbb{R}} \dots \int_{\mathbb{R}} \left[\frac{1}{\mathbb{P}(\mathbf{x}, \theta)} \frac{\partial \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta} \right] \mathbb{1}_S(\mathbf{x}) \mathbb{P}(\mathbf{x}, \theta) d\mathbf{x} = \int_{\mathbb{R}} \dots \int_{\mathbb{R}} \frac{\partial \ln(\mathbb{P}(\mathbf{x}, \theta))}{\partial \theta} \mathbb{1}_S(\mathbf{x}) \mathbb{P}(\mathbf{x}, \theta) d\mathbf{x} \Rightarrow$$

$$\mathbb{E}_\theta(\psi(\mathbf{X}, \theta)) = \mathbb{E}_\theta \left(\frac{\partial \ln(\mathbb{P}(\mathbf{X}, \theta))}{\partial \theta} \right) = 0.$$

y como $I(\theta) = \mathbb{E}_\theta(\psi^2(\mathbf{X}, \theta))$, se sigue que $\mathbb{V}_\theta(\psi(\mathbf{X}, \theta)) = I(\theta)$.

- (ii) $\frac{\partial^2 \ln(\mathbb{P}(\mathbf{x}, \theta))}{\partial \theta^2} = \frac{\partial}{\partial \theta} \left(\frac{1}{\mathbb{P}(\mathbf{x}, \theta)} \frac{\partial \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta} \right) = \left[\frac{\partial^2 \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta^2} \mathbb{P}(\mathbf{x}, \theta) - \frac{\partial \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta} \frac{\partial \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta} \right] \frac{1}{\mathbb{P}^2(\mathbf{x}, \theta)}$, entonces

$$\frac{\partial^2 \ln(\mathbb{P}(\mathbf{x}, \theta))}{\partial \theta^2} = \frac{1}{\mathbb{P}(\mathbf{x}, \theta)} \frac{\partial^2 \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta^2} - \frac{1}{\mathbb{P}^2(\mathbf{x}, \theta)} \left(\frac{\partial \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta} \right)^2 = \frac{1}{\mathbb{P}(\mathbf{x}, \theta)} \frac{\partial^2 \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta^2} - \left(\frac{1}{\mathbb{P}(\mathbf{x}, \theta)} \frac{\partial \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta} \right)^2 \Rightarrow$$

$$\frac{\partial(\psi(\mathbf{x}, \theta))}{\partial \theta} = \frac{\partial^2 \ln(\mathbb{P}(\mathbf{x}, \theta))}{\partial \theta^2} = \frac{1}{\mathbb{P}(\mathbf{x}, \theta)} \frac{\partial^2 \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta^2} - \psi^2(\mathbf{x}, \theta).$$

Luego,

$$\mathbb{E}_\theta \left(\frac{\partial^2 \ln(\mathbb{P}(\mathbf{x}, \theta))}{\partial \theta^2} \right) = \int_{\mathbb{R}} \dots \int_{\mathbb{R}} \frac{\partial^2 \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta^2} d\mathbf{x} - \mathbb{E}_\theta(\psi^2(\mathbf{X}, \theta))$$

Por otra parte, puesto que

$$\frac{\partial^2}{\partial \theta^2} \left[\int_{\mathbb{R}} \dots \int_{\mathbb{R}} h(\mathbf{x}) \mathbb{P}(\mathbf{x}, \theta) d\mathbf{x} \right] = \int_{\mathbb{R}} \dots \int_{\mathbb{R}} h(\mathbf{x}) \frac{\partial^2 \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta^2} d\mathbf{x}$$

si $h(\mathbf{x}) = \mathbb{1}_S(\mathbf{x})$ se tiene que

$$\int_{\mathbb{R}} \dots \int_{\mathbb{R}} \frac{\partial^2 \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta^2} d\mathbf{x} = 0 \Rightarrow \mathbb{E}_\theta \left(\frac{\partial^2 \ln(\mathbb{P}(\mathbf{x}, \theta))}{\partial \theta^2} \right) = -\mathbb{E}_\theta(\psi^2(\mathbf{X}, \theta)) = -I(\theta).$$

□

Teorema 1.55. (Teorema Rao-Cramer):

Bajo las las Condiciones de Rao-Cramer, si $\delta(\mathbf{X})$ es un estimador insesgado $q(\theta)$ tal que $\mathbb{E}_\theta(\delta^2(\mathbf{X})) < \infty$ se tiene

$$(i) \quad \mathbb{V}_\theta(\delta(\mathbf{X})) \geq \frac{|q'(\theta)|^2}{I(\theta)}.$$

(ii) En el inciso anterior, la igualdad vale si y sólo si $\delta(\mathbf{X})$ es estadístico suficiente de una familia exponencial, es decir si y sólo si

$$\mathbb{P}(\mathbf{x}, \theta) = A(\theta)e^{c(\theta)\delta(\mathbf{x})}h(\mathbf{x})$$

Demostración.

(i) Sea $\psi(\mathbf{x}, \theta) = \frac{\partial \ln(\mathbb{P}(\mathbf{x}, \theta))}{\partial \theta}$. Por el lema anterior, se tiene que

$$\mathbb{E}_\theta(\psi(\mathbf{x}, \theta)) = 0 \text{ y } \mathbb{V}_\theta(\psi(\mathbf{x}, \theta)) = I(\theta)$$

Por otro lado, como $\delta(\mathbf{X})$ es insesgado se tiene

$$\mathbb{E}_\theta(\delta(\mathbf{X})) = \int_{\mathbb{R}} \dots \int_{\mathbb{R}} \mathbb{P}(\mathbf{x}, \theta) \underbrace{\delta(\mathbf{X}) \mathbb{1}_S(\mathbf{x})}_{h(\mathbf{x})} d\mathbf{x} = q(\theta)$$

y luego aplicando la hipótesis C,

$$\begin{aligned} \int_{\mathbb{R}} \dots \int_{\mathbb{R}} \delta(\mathbf{X}) \frac{\partial \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta} d\mathbf{x} &= q'(\theta) \Rightarrow \mathbb{E}_\theta(\delta(\mathbf{X})\psi(\mathbf{X}, \theta)) = \int_{\mathbb{R}} \dots \int_{\mathbb{R}} \delta(\mathbf{x})\psi(\mathbf{x}, \theta)\mathbb{P}(\mathbf{x}, \theta) d\mathbf{x} \Rightarrow \\ \mathbb{E}_\theta(\delta(\mathbf{X})\psi(\mathbf{X}, \theta)) &= \int_{\mathbb{R}} \dots \int_{\mathbb{R}} \delta(\mathbf{x}) \underbrace{\frac{\partial \ln(\mathbb{P}(\mathbf{x}, \theta))}{\partial \theta}}_{=\frac{1}{\mathbb{P}(\mathbf{x}, \theta)} \frac{\partial \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta}} \mathbb{1}_S(\mathbf{x}) \mathbb{P}(\mathbf{x}, \theta) d\mathbf{x} = q'(\theta). \end{aligned}$$

luego,

$$Cov(\delta(\mathbf{X}), \psi(\mathbf{X}, \theta)) = \mathbb{E}(\delta(\mathbf{X})\psi(\mathbf{X}, \theta)) - \mathbb{E}(\delta(\mathbf{X})) \underbrace{\mathbb{E}(\psi(\mathbf{X}, \theta))}_{=0} = \mathbb{E}(\delta(\mathbf{X})\psi(\mathbf{X}, \theta)) = q'(\theta)$$

De acuerdo a la desigualdad de Cauchy-Schwartz, $Cov^2(X, Y) \leq \mathbb{V}(X)\mathbb{V}(Y)$, donde la igualdad vale si y sólo si $\mathbb{P}(Y = aX + b) = 1$ para algunas constantes a y b . Por lo tanto

$$Cov^2(\delta(\mathbf{X}), \psi(\mathbf{X}, \theta)) = (q'(\theta))^2 \leq \mathbb{V}_\theta(\delta(\mathbf{X})) \underbrace{\mathbb{V}_\theta(\psi(\mathbf{X}, \theta))}_{=I(\theta)}$$

donde la igualdad vale si y sólo si

$$\frac{\partial \ln(\mathbb{P}(\mathbf{X}, \theta))}{\partial \theta} = \psi(\mathbf{X}, \theta) = a(\theta)\delta(\mathbf{X}) + b(\theta) \text{ con probabilidad 1.}$$

Por lo tanto, $\mathbb{V}_\theta(\delta(\mathbf{X})) \geq \frac{(q'(\theta))^2}{I(\theta)}$.

(ii) $\mathbb{V}_\theta(\delta(\mathbf{X})) = \frac{(q'(\theta))^2}{I(\theta)} \Leftrightarrow \mathbb{P}(\psi(\mathbf{X}, \theta) = a(\theta)\delta(\mathbf{X}) + b(\theta)) = 1$, por lo tanto, probaremos que

$$\mathbb{P}(\psi(\mathbf{X}, \theta) = a(\theta)\delta(\mathbf{X}) + b(\theta)) = 1 \Leftrightarrow \mathbb{P}(\mathbf{x}, \theta) = A(\theta)e^{c(\theta)\delta(\mathbf{x})}h(\mathbf{x}).$$

($\Rightarrow$):

$$\begin{aligned} \int_{\Theta} \psi(\mathbf{x}, \theta) d\theta &= \ln(p(\mathbf{x}, \theta)) = \delta(\mathbf{x}) \int_{\Theta} a(\theta) d\theta + \int_{\Theta} b(\theta) d\theta + g(\mathbf{x}) = \delta(\mathbf{x})c(\theta) + g(\mathbf{x}) + B(\theta) \Rightarrow \\ p(\mathbf{x}, \theta) &= \underbrace{e^{B(\theta)}}_{=A(\theta)} e^{\delta(\mathbf{x})c(\theta)} \underbrace{e^{g(\mathbf{x})}}_{=h(\mathbf{x})} = A(\theta)e^{c(\theta)\delta(\mathbf{x})}h(\mathbf{x}). \end{aligned}$$

($\Leftarrow$):

$$\mathbb{P}(\mathbf{x}, \theta) = A(\theta)e^{c(\theta)\delta(\mathbf{x})}h(\mathbf{x}) \Leftrightarrow \ln(\mathbb{P}(\mathbf{x}, \theta)) = \ln(A(\theta)) + c(\theta)\delta(\mathbf{x}) + \ln(h(\mathbf{x})) \Rightarrow \frac{\partial \ln(\mathbb{P}(\mathbf{x}, \theta))}{\partial \theta} = \underbrace{\frac{A'(\theta)}{A(\theta)}}_{b(\theta)} + \underbrace{c'(\theta)}_{a(\theta)} \delta(\mathbf{x}).$$

□

Observación 1.56.

- (i) Si $\delta(\mathbf{X})$ es un estimador insesgado de $q(\theta)$ y $\mathbb{V}_\theta(\delta(\mathbf{X})) \leq \frac{(q'(\theta))^2}{I(\theta)}$ para todo $\theta \in \Theta$. Entonces el inciso (i) del Teorema Rao-Cramer resulta que $\delta(\mathbf{X})$ es IMVU. Por lo tanto esto da otro criterio para verificar si un estimador insesgado dado es IMVU.
- (ii) Por los incisos (i) y (ii) si $\mathbb{P}(\mathbf{x}, \theta) = A(\theta)e^{c(\theta)\delta(\mathbf{x})}h(\mathbf{x})$, y si $\delta(\mathbf{X})$ es un estimador insesgado de $q(\theta)$, entonces $\delta(\mathbf{X})$ es un estimador IMVU de $q(\theta)$.
- (iii) Si $\delta(\mathbf{X})$ es un estimador de θ , su varianza debe ser mayor o igual que $1/I(\theta)$. Luego se puede esperar que cuanto mayor sea $I(\theta)$ (como $1/I(\theta)$ será menor) existe la posibilidad de encontrar estimadores con menor varianza y por lo tanto más precisos. De ahí el nombre de **número de información** que se le da a $I(\theta)$. Es decir cuanto mayor es $I(\theta)$, mejores estimadores de θ se pueden encontrar, y por lo tanto se puede decir que más información da el vector $\mathbf{X}$ sobre θ . El hecho de que se pueden encontrar estimadores con varianza aproximadamente igual a $1/I(\theta)$ será cierto para n grande.

Teorema 1.57. Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución con densidad $\mathbb{P}(\mathbf{x}, \theta)$ con $\theta \in \Theta \subset \mathbb{R}$. Luego, si se denomina $I_n(\theta)$ al número de información de $X_1, X_2, \dots, X_n$ e $I_1(\theta)$ al número de información de X_1 , entonces se tiene $I_n(\theta) = nI_1(\theta)$.

Demostración. $\mathbb{P}(\mathbf{x}, \theta) = \prod_{i=1}^n \mathbb{P}(x_i, \theta) \Rightarrow \ln(\mathbb{P}(\mathbf{x}, \theta)) = \sum_{i=1}^n \ln(\mathbb{P}(x_i, \theta)) \Rightarrow \frac{\partial \ln(\mathbb{P}(\mathbf{x}, \theta))}{\partial \theta} = \sum_{i=1}^n \frac{\partial \ln(\mathbb{P}(x_i, \theta))}{\partial \theta}.$

Luego, como $X_1, X_2, \dots, X_n$ son independientes,

$$I(\theta) = \mathbb{V}_\theta \left(\frac{\partial \ln(\mathbb{P}(\mathbf{X}, \theta))}{\partial \theta} \right) = \sum_{i=1}^n \mathbb{V}_\theta \left(\frac{\partial \ln(\mathbb{P}(X_i, \theta))}{\partial \theta} \right) = nI_1(\theta).$$

□

Observación 1.58. El teorema anterior nos indica que una muestra aleatoria de tamaño n $X_1, X_2, \dots, X_n$ nos da n veces más información que una sola observación.

1.10. Consistencia de estimadores

Definición 1.59. Sea $\mathcal{F} = \{F(\mathbf{x}, \theta) : \theta \in \Theta\}$ una familia de distribuciones y supongamos que para cada n se tiene un estimador $\delta_n(X_1, X_2, \dots, X_n)$ de $q(\theta)$ basado en una muestra aleatoria de tamaño n . Diremos que $\delta_n(X_1, X_2, \dots, X_n)$ es una sucesión fuertemente consistente de estimadores de $q(\theta)$ si

$$\delta_n(X_1, X_2, \dots, X_n) \xrightarrow[n \rightarrow \infty]{ctp} q(\theta).$$

es decir, $\mathbb{P}_\theta \left(\lim_{n \rightarrow \infty} \delta_n(X_1, X_2, \dots, X_n) = q(\theta) \right) = 1$ para todo $\theta \in \Theta$.

Definición 1.60. Sea $\mathcal{F} = \{F(\mathbf{x}, \theta) : \theta \in \Theta\}$ una familia de distribuciones y supongamos que para cada n se tiene un estimador $\delta_n(X_1, X_2, \dots, X_n)$ de $q(\theta)$ basado en una muestra aleatoria de tamaño n . Diremos que $\delta_n(X_1, X_2, \dots, X_n)$ es una sucesión débilmente consistente de estimadores de $q(\theta)$ si

$$\delta_n(X_1, X_2, \dots, X_n) \xrightarrow[n \rightarrow \infty]{p} q(\theta).$$

es decir, para todo $\varepsilon > 0$ y $\theta \in \Theta$, $\lim_{n \rightarrow \infty} \mathbb{P}_\theta (|\delta_n(X_1, X_2, \dots, X_n) - q(\theta)| > \varepsilon) = 0$.

Teorema 1.61. Sea, para todo n , $\delta_n := \delta_n(X_1, X_2, \dots, X_n)$ un estimador de $q(\theta)$ basado en una muestra aleatoria de tamaño n . Si $\mathbb{V}_\theta(\delta_n) \xrightarrow[n \rightarrow \infty]{} 0$ y $\mathbb{E}_\theta(\delta_n) \xrightarrow[n \rightarrow \infty]{} q(\theta)$, entonces δ_n es débilmente consistente.

Demostración. Por la desigualdad de Chebychev se tiene

$$\mathbb{P}_\theta (|\delta_n - q(\theta)| > \varepsilon) \leq \frac{\mathbb{E}_\theta [(\delta_n - q(\theta))^2]}{\varepsilon^2} \leq \frac{\mathbb{V}_\theta(\delta_n) + [\mathbb{E}_\theta(\delta_n) - q(\theta)]^2}{\varepsilon^2} \xrightarrow[n \rightarrow \infty]{} 0.$$

□

Observación 1.62. El teorema anterior da una condición suficiente para que una sucesión de estimadores sea débilmente consistente.

Teorema 1.63. Sea $\delta_n := \delta_n(X_1, X_2, \dots, X_n)$ una sucesión de estimadores IMVU para $q(\theta)$, donde $X_1, X_2, \dots, X_n$ es una muestra aleatoria de una distribución perteneciente a la familia $F(x, \theta)$, con $\theta \in \Theta$.

Luego $\mathbb{V}_\theta(\delta_n)$ tiende a cero si n tiende a infinito.

Demostración. Sea $\delta_n^*(X_1, X_2, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n \delta_1(X_i)$, luego $\mathbb{E}_\theta(\delta_n^*(X_1, X_2, \dots, X_n)) = \mathbb{E}_\theta(\delta_1(X_1)) = q(\theta)$ y, entonces, δ_n^* es un estimador insesgado de $q(\theta)$.

Por otro lado, $\mathbb{V}_\theta(\delta_n^*(X_1, X_2, \dots, X_n)) = \frac{\mathbb{V}_\theta(\delta_1(X_1))}{n}$ y puesto que δ_n es un estimador *IMVU* de $q(\theta)$, se cumple

$$\mathbb{V}_\theta(\delta_n) \leq \mathbb{V}_\theta(\delta_n^*) = \frac{1}{n} \mathbb{V}_\theta(\delta_1(X_1)) \Rightarrow \lim_{n \rightarrow \infty} \mathbb{V}_\theta(\delta_n(X_1, X_2, \dots, X_n)) = 0.$$

□

Observación 1.64. El teorema anterior muestra que si δ_n es una sucesión de estimadores *IMVU* para $q(\theta)$ entonces cumple la hipótesis del **Teorema 1.61**.

Corolario 1.65. Si $\delta_n := \delta_n(X_1, X_2, \dots, X_n)$ es una sucesión de estimadores *IMVU* para $q(\theta)$ donde $X_1, X_2, \dots, X_n$ es una muestra aleatoria de una distribución perteneciente a la familia $F(x, \theta)$, con $\theta \in \Theta$ entonces δ_n es una sucesión de estimadores débilmente consistentes.

Teorema 1.66. (Consistencia de los E.M.):

Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución perteneciente a la familia $F(x, \theta)$, con $\theta \in \Theta \subset \mathbb{R}$, $h(x)$ una función continua con valores en $\mathbb{R}$ y supongamos que $\mathbb{E}_\theta(h(X_1)) = g(\theta)$ es, como función de θ , continua y estrictamente monótona. Sea el estimador de momentos $\hat{\theta}_n$ definido como la solución de

$$\frac{1}{n} \sum_{i=1}^n h(X_i) = \mathbb{E}_\theta(h(X_1)) = g(\theta)$$

Luego con probabilidad 1 existe n_0 tal que para todo $n \geq n_0$ la ecuación que define $\hat{\theta}_n$ tiene solución y es fuertemente consistente para θ .

Demostración. Sea $\varepsilon > 0$ y supongamos que $g(\theta)$ es, como función de θ , continua y estrictamente creciente (el caso contrario de demuestra de manera análoga). Luego,

$$g(\theta - \varepsilon) < g(\theta) < g(\theta + \varepsilon)$$

Sea $\delta = \min\{g(\theta + \varepsilon) - g(\theta); g(\theta) - g(\theta - \varepsilon)\}$, entonces

$$g(\theta - \varepsilon) \leq g(\theta) - \delta < g(\theta) < g(\theta) + \delta \leq g(\theta + \varepsilon)$$

Por otro lado, por la Ley Fuerte de los Grandes Números, $\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n h(X_i) = g(\theta)$ c.t.p. Entonces con probabilidad 1, dado $\delta > 0$ existe n_0 tal que para todo $n \geq n_0$ se tiene

$$g(\theta) - \delta \leq \frac{1}{n} \sum_{i=1}^n h(X_i) \leq g(\theta) + \delta \Rightarrow g(\theta - \varepsilon) \leq \frac{1}{n} \sum_{i=1}^n h(X_i) \leq g(\theta + \varepsilon), \quad \forall n \geq n_0$$

Como $g(\theta)$ es continua y estrictamente creciente, para $n \geq n_0$ existe un único valor $\hat{\theta}_n$ que satisface

$$\frac{1}{n} \sum_{i=1}^n h(X_i) = \mathbb{E}_\theta(h(X_1)) = g(\theta).$$

Además dicho valor debe estar entre $\theta - \varepsilon$ y $\theta + \varepsilon$, es decir que $\hat{\theta}_n \in (\theta - \varepsilon, \theta + \varepsilon)$ para $n \geq n_0$ que es lo que queríamos demostrar. □

Teorema 1.67. (Consistencia de los E.M.V.):

Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución discreta o continua con densidad en la familia $\mathbb{P}(x, \theta)$ con $\theta \in \Theta$, donde Θ es un intervalo abierto de $\mathbb{R}$.

Supongamos que $\mathbb{P}(x, \theta)$ es derivable respecto de θ y que el conjunto $S = \{x : \mathbb{P}(x, \theta) \neq 0\}$ es independiente de θ para todo $\theta \in \Theta$.

Sea $\hat{\theta}_n$ el estimador de máxima verosimilitud de θ , que satisface

$$\sum_{i=1}^n \frac{\partial \ln(\mathbb{P}(x_i, \hat{\theta}_n))}{\partial \theta} = 0$$

donde tal ecuación tiene a lo sumo una solución y que $\theta \neq \theta'$ implica que $\mathbb{P}(x, \theta) \neq \mathbb{P}(x, \theta')$.

Entonces $\lim_{n \rightarrow \infty} \hat{\theta}_n = \theta$ c.t.p., es decir, $\hat{\theta}_n$ es una sucesión de estimadores fuertemente consistente.

Definición 1.68. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución perteneciente a la familia $F(x, \theta)$, con $\theta \in \Theta \subset \mathbb{R}$. Decimos que $\delta_n := \delta_n(X_1, X_2, \dots, X_n)$ es una sucesión de estimadores asintóticamente normal para $q(\theta)$ si

$$\sqrt{n}(\delta_n - q(\theta)) \xrightarrow[n \rightarrow \infty]{D} N(0, \sigma^2(b\theta)).$$

1.11. Ejercicios

1.11.1. Estimadores Basados en Momentos

1. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución

- $Bi(1, \theta)$, $0 < \theta < 1$.
- $\mathcal{P}(\theta)$, $\theta > 0$.
- $\mathcal{E}(\theta)$, $\theta > 0$.
- $\mathcal{G}(\theta)$, $0 < \theta < 1$.

En cada uno de estos casos, encontrar:

- a) Un estimador de θ basado únicamente en el primer momento.
- b) Un estimador de θ basado únicamente en el segundo momento.

Verificar si los respectivos estimadores cumplan las restricciones impuestas sobre el parámetro. Por ejemplo, para el caso de la Binomial, verificar si la imagen del estimador obtenido esté contenido en el intervalo $(0, 1)$.

Solución:

- como $X_i \sim Bi(1, \theta)$ se tiene que $\mathbb{E}_\theta(X_i) = \theta \quad \forall i \in \{1, \dots, n\}$, luego $\forall i \in \{1, \dots, n\}$

$$\frac{1}{n} \sum_{i=1}^n X_i = n \frac{1}{n} \mathbb{E}_\theta(X_1) = \theta$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = n \frac{1}{n} \mathbb{E}_\theta(X_1^2) = \mathbb{V}_\theta(X_1) + \mathbb{E}_\theta^2(X_1) = \theta(1 - \theta) + \theta^2 = \theta$$

Por lo tanto,

$$\hat{\theta} = \overline{X_n}, \quad \text{resulta ser su estimador de primer momento.}$$

$$\hat{\theta} = \overline{X_n^2}, \quad \text{resulta ser su estimador de segundo momento.}$$

- como $X_i \sim \mathcal{P}(\theta)$ se tiene que $\mathbb{E}_\theta(X_i) = \theta \quad \forall i \in \{1, \dots, n\}$, luego $\forall i \in \{1, \dots, n\}$

$$\frac{1}{n} \sum_{i=1}^n X_i = n \frac{1}{n} \mathbb{E}_\theta(X_1) = \theta$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = n \frac{1}{n} \mathbb{E}_\theta(X_1^2) = \mathbb{V}_\theta(X_1) + \mathbb{E}_\theta^2(X_1) = \theta + \theta^2$$

Por lo tanto,

$$\hat{\theta} = \overline{X_n}, \quad \text{resulta ser su estimador de primer momento.}$$

Para buscar su estimador de segundo momento notemos que

$$0 = \theta + \theta^2 + \overline{X_n^2} \Leftrightarrow \theta_{1,2} = \frac{-1 \pm \sqrt{1 + 4\overline{X_n^2}}}{2}$$

pero buscamos que $\hat{\theta} > 0$, entonces

$$\hat{\theta} = \frac{-1 + \sqrt{1 + 4\overline{X_n^2}}}{2}, \quad \text{resulta ser su estimador de segundo momento.}$$

- como $X_i \sim \mathcal{E}(\theta)$ se tiene que $\mathbb{E}_\theta(X_i) = \frac{1}{\theta}$ y $\mathbb{V}_\theta(X_i) = \frac{1}{\theta^2} \quad \forall i \in \{1, \dots, n\}$, luego $\forall i \in \{1, \dots, n\}$

$$\frac{1}{n} \sum_{i=1}^n X_i = n \frac{1}{n} \mathbb{E}_\theta(X_1) = \frac{1}{\theta}$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = n \frac{1}{n} \mathbb{E}_\theta(X_1^2) = \mathbb{V}_\theta(X_1) + \mathbb{E}_\theta^2(X_1) = \frac{1}{\theta^2} + \frac{1}{\theta^2} = \frac{2}{\theta^2}$$

Por lo tanto,

$$\hat{\theta} = \frac{1}{\overline{X_n}}, \quad \text{resulta ser su estimador de primer momento.}$$

$$\hat{\theta} = \sqrt{\frac{2}{\overline{X_n^2}}}, \quad \text{resulta ser su estimador de segundo momento.}$$

- como $X_i \sim \mathcal{G}(\theta)$ se tiene que $\mathbb{E}_\theta(X_i) = \frac{1}{\theta}$ y $\mathbb{V}_\theta(X_i) = \frac{1-\theta}{\theta^2} \quad \forall i \in \{1, \dots, n\}$, luego $\forall i \in \{1, \dots, n\}$

$$\frac{1}{n} \sum_{i=1}^n X_i = n \frac{1}{n} \mathbb{E}_\theta(X_1) = \frac{1}{\theta}$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = n \frac{1}{n} \mathbb{E}_\theta(X_1^2) = \mathbb{V}_\theta(X_1) + \mathbb{E}_\theta^2(X_1) = \frac{1-\theta}{\theta^2} + \frac{1}{\theta^2} = \frac{2-\theta}{\theta^2}$$

Por lo tanto,

$$\hat{\theta} = \frac{1}{\overline{X_n}}, \quad \text{resulta ser su estimador de primer momento.}$$

Para buscar su estimador de segundo momento notemos que

$$0 = \theta^2 \overline{X_n^2} + \theta - 2 \Leftrightarrow \theta_{1,2} = \frac{-1 \pm \sqrt{1 + 8\overline{X_n^2}}}{2\overline{X_n^2}}$$

pero buscamos que $\hat{\theta} \in (0, 1)$, entonces

$$\hat{\theta} = \frac{-1 + \sqrt{1 + 8\overline{X_n^2}}}{2\overline{X_n^2}}, \quad \text{resulta ser su estimador de segundo momento.}$$

2. Estimadores de momentos para $q(\theta)$. Supongamos que tenemos una muestra aleatoria $X_1, \dots, X_n$ y queremos un estimador basado en momentos para $q(\theta)$, donde θ es un parámetro desconocido de la distribución de la muestra y q es una función conocida. Consideremos las siguientes dos estrategias:

- Si tenemos $\hat{\theta}$ un estimador de momentos para θ , estimar $q(\theta)$ con $q(\hat{\theta})$.
- Buscar una función g tal que $\mathbb{E}[g(X_1)] = q(\theta)$ y luego aproximar $\mathbb{E}[g(X_1)]$ con $\frac{1}{n} \sum_{i=1}^n g(X_i)$.

Aplicar las estrategias (a) y (b) en los siguientes casos:

- Sea $X_1, \dots, X_n$ una m.a. de una distribución $\mathcal{E}(\theta)$ y se quiere estimar $q(\theta) = P_\theta(X_1 \geq 1)$.
- Sea $X_1, \dots, X_n$ una m.a. de una distribución $N(0, \sigma^2)$, con $\sigma > 0$ y se quiere estimar σ .

Solución:

- Para la primer estrategia debemos notar que

$$P_\theta(X_1 \geq 1) = 1 - P_\theta(X_1 < 1) = 1 - (1 - e^{-\theta}) = e^{-\theta} = q(\theta)$$

y usando el estimador de momentos para θ , tenemos que

$$q(\hat{\theta}) = e^{-\hat{\theta}} = e^{-1/\overline{X_n}}$$

En cuanto a la segunda, si $g(x) = \mathbb{1}_{[1, +\infty)}(X_1)$ entonces $\mathbb{E}_{q(\theta)}(g(X_1)) = P_\theta(X_1 \geq 1) = q(\theta)$. Por lo tanto, aproximamos $\mathbb{E}(g(X_1))$ usando

$$\widehat{q(\theta)} = \frac{1}{n} \sum_{i=1}^n g(X_i)$$

- Buscamos el estimador de segundo momento,

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = \mathbb{E}_{\hat{\sigma}}(X_1^2) = \mathbb{V}_{\hat{\sigma}}(X_1) + \mathbb{E}_{\hat{\sigma}}^2(X_1) = \hat{\sigma}^2 \Rightarrow \hat{\sigma} = \sqrt{\overline{X_n^2}}$$

Para encontrar una función g tal que $\mathbb{E}[g(X_1)] = q(\theta)$ notemos que

$$\begin{aligned} \mathbb{E}(|X_1|) &= \int_{\mathbb{R}} |x| \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{x^2}{2\sigma^2}} dx = \int_{-\infty}^0 (-x) \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{x^2}{2\sigma^2}} dx + \int_0^{\infty} x \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{x^2}{2\sigma^2}} dx \\ &\Rightarrow \mathbb{E}(|X_1|) = e^{-\frac{x^2}{2\sigma^2}} \frac{\sigma}{\sqrt{2\pi}} \Big|_{-\infty}^0 - e^{-\frac{x^2}{2\sigma^2}} \frac{\sigma}{\sqrt{2\pi}} \Big|_0^{\infty} = 2 \frac{\sigma}{\sqrt{2\pi}} = \sqrt{\frac{2\sigma^2}{\pi}} \end{aligned}$$

Luego,

$$\frac{1}{n} \sum_{i=1}^n |X_i| = \sqrt{\frac{2\widehat{\sigma}^2}{\pi}} \Rightarrow \hat{\sigma} = \sqrt{\frac{\pi}{2n^2}} \sum_{i=1}^n |X_i|$$

3. Sean $X_1, X_2, \dots, X_n$ variables aleatorias independientes e idénticamente distribuidas. Hallar el estimador de los momentos de μ si

a) la densidad de X_1 está dada por:

$$f(x) = \frac{1}{\mu^4} x \mathbb{1}_{[0, \mu^2]}(x) + \frac{1}{\mu^4} (2\mu^2 - x) \mathbb{1}_{[\mu^2, 2\mu^2]}(x) \quad \mu > 0$$

b) la función de probabilidad de X_1 está dada por:

$$\frac{k}{p(k)} \mid \begin{array}{ccc} 1 & 2 & 4 \\ \mu^2 & 2\mu(1-\mu) & (1-\mu)^2 \end{array} \quad 0 < \mu < 1$$

Solución:

a) Calculemos la esperanza,

$$\mathbb{E}_\mu(X_1) = \int_0^{\mu^2} \frac{x^2}{\mu^4} dx + \int_{\mu^2}^{2\mu^2} \frac{x}{\mu^4} (2\mu^2 - x) dx = \frac{x^3}{3\mu^4} \Big|_0^{\mu^2} + \frac{2}{\mu^2} \frac{x^2}{2} \Big|_{\mu^2}^{2\mu^2} - \frac{x^3}{3\mu^4} \Big|_{\mu^2}^{2\mu^2} = \mu^2$$

luego,

$$\overline{X_n} = \mathbb{E}_{\hat{\mu}}(X_1) = \hat{\mu}^2 \Rightarrow \hat{\mu} = \sqrt{\overline{X_n}}$$

b) Calculemos la esperanza,

$$\mathbb{E}_\mu(X_1) = \mu^2 + 2[2\mu(1-\mu)] + 4(1-\mu)^2 = \mu^2 + 4\mu(1-\mu) + 4(1-\mu)^2 = [\mu + 2(1-\mu)]^2 = (2-\mu)^2$$

luego,

$$\overline{X_n} = \mathbb{E}_{\hat{\mu}}(X_1) = (2-\hat{\mu})^2 \Rightarrow \hat{\mu} = 2 + \sqrt{\overline{X_n}}$$

1.11.2. Estimadores de máxima verosimilitud

1. Dada una muestra aleatoria $X_1, \dots, X_n$ para cada una de las distribuciones consideradas en el ejercicio A.1, encontrar los respectivos estimadores de máxima verosimilitud (EMV) de θ .

Solución:

- $Bi(1, \theta)$, $0 < \theta < 1$.

$$L(\theta) = \prod_{i=1}^n [(1-\theta)\mathbb{1}_{\{0\}}(x_i) + \theta\mathbb{1}_{\{1\}}(x_i)] = (1-\theta)^{\sum \mathbb{1}_{\{0\}}(x_i)} \theta^{\sum \mathbb{1}_{\{1\}}(x_i)}$$

$$\Rightarrow L(\theta) = (1-\theta)^{\#\{i: x_i=0\}} \theta^{\#\{i: x_i=1\}}$$

para aliviar un poco la notación, $N_0 = \#\{i : x_i = 0\}$ y, por lo tanto, $n - N_0 = N_1 = \#\{i : x_i = 1\}$.

Buscamos $\theta \in (0, 1)$ tal que $\frac{\partial \ln(L(\theta))}{\partial \theta} = 0$ donde

$$\ln(L(\theta)) = N_0 \ln(1-\theta) + (n - N_0) \ln(\theta)$$

luego,

$$\frac{\partial \ln(L(\theta))}{\partial \theta} = 0 \Leftrightarrow -\frac{N_0}{1-\theta} + \frac{n - N_0}{\theta} = 0 \Leftrightarrow \frac{N_0}{1-\theta} = \frac{n - N_0}{\theta} \Leftrightarrow N_0 \theta = (n - N_0)(1-\theta) \Leftrightarrow \theta = 1 - \frac{N_0}{n}$$

y para chequear que es un punto máximo, notemos que

$$\frac{\partial^2 \ln(L(\theta))}{\partial^2 \theta} = -\frac{N_0}{(1-\theta)^2} + \frac{n - N_0}{\theta^2} < 0 \quad \forall \theta$$

Por lo tanto,

$$\hat{\theta}_{EMV} = 1 - \frac{N_0}{n}$$

- $\mathcal{P}(\theta)$, $\theta > 0$.

$$L(\theta) = \prod_{i=1}^n \frac{e^{-\theta} \theta^{x_i}}{x_i!} = e^{-n\theta} \theta^{\sum x_i} \prod_{i=1}^n \frac{1}{x_i!}$$

sabemos que $\prod_{i=1}^n \frac{1}{x_i!}$ resulta ser una constante por lo que para el encontrar el estimador de máxima verosimilitud basta con maximizar $L'(\theta) = e^{-n\theta} \theta^{\sum x_i}$.

Luego,

$$0 = \frac{\partial \ln(L'(\theta))}{\partial \theta} = \frac{\partial}{\partial \theta} \left(-n\theta + \sum_{i=1}^n x_i \ln(\theta) \right) = -n + \frac{1}{\theta} \sum_{i=1}^n x_i \Leftrightarrow \theta = \overline{X_n}$$

y para chequear que es un punto máximo, notemos que

$$\frac{\partial^2 \ln(L(\theta))}{\partial^2 \theta} = -\frac{1}{\theta^2} \sum_{i=1}^n x_i < 0 \quad \forall \theta$$

Por lo tanto,

$$\hat{\theta}_{EMV} = \overline{X_n}$$

- $\mathcal{E}(\theta)$, $\theta > 0$.

$$L(\theta) = \prod_{i=1}^n \theta e^{-\theta x_i} \mathbb{1}_{(0,+\infty)}(x_i) = \theta^n e^{\theta \sum x_i} \prod_{i=1}^n \mathbb{1}_{(0,+\infty)}(x_i)$$

sabemos que $\prod_{i=1}^n \mathbb{1}_{(0,+\infty)}(x_i)$ resulta ser una constante por lo que para el encontrar el estimador de máxima verosimilitud basta con maximizar $L'(\theta) = \theta^n e^{\theta \sum x_i}$.

Luego,

$$0 = \frac{\partial \ln(L'(\theta))}{\partial \theta} = \frac{\partial}{\partial \theta} \left(-n \ln(\theta) + \theta \sum_{i=1}^n x_i \right) = -\frac{n}{\theta} + \sum_{i=1}^n x_i \Leftrightarrow \theta = \frac{n}{\sum_{i=1}^n x_i}$$

y para chequear que es un punto máximo, notemos que

$$\frac{\partial^2 \ln(L(\theta))}{\partial^2 \theta} = -\frac{n}{\theta^2} < 0 \quad \forall \theta$$

Por lo tanto,

$$\hat{\theta}_{EMV} = \frac{n}{\sum_{i=1}^n x_i}$$

- $\mathcal{G}(\theta)$, $0 < \theta < 1$.

$$L(\theta) = \prod_{i=1}^n \theta(1-\theta)^{x_i-1} = \theta^n (1-\theta)^{\sum x_i - n}$$

Luego,

$$\begin{aligned} 0 = \frac{\partial \ln(L(\theta))}{\partial \theta} &= \frac{\partial}{\partial \theta} \left[n \ln(\theta) + \ln(1-\theta) \left(\sum_{i=1}^n x_i - n \right) \right] = \frac{n}{\theta} - \frac{1}{1-\theta} \left(\sum_{i=1}^n x_i - n \right) \Leftrightarrow \\ \frac{n}{\theta} &= \frac{1}{1-\theta} \left(\sum_{i=1}^n x_i - n \right) \Leftrightarrow (1-\theta)n = \theta \left(\sum_{i=1}^n x_i - n \right) \Leftrightarrow \theta = \frac{1}{\overline{X_n}} \end{aligned}$$

y para chequear que es un punto máximo, notemos que

$$\frac{\partial^2 \ln(L(\theta))}{\partial^2 \theta} = -\frac{n}{\theta^2} - \frac{1}{(1-\theta)^2} \left(\sum_{i=1}^n x_i - n \right) < 0 \quad \forall \theta$$

Por lo tanto,

$$\hat{\theta}_{EMV} = \frac{1}{\overline{X_n}}$$

2. Sea $X_1, \dots, X_n$ una m.a. de una distribución $N(\mu, \sigma^2)$. Consideremos el parámetro bivariado $\theta = (\mu, \sigma^2)$.
- Encontrar el EMV de θ .
 - Dado $\xi \in \mathbb{R}$ encontrar el EMV de $p = P_\theta(X_1 > \xi)$.
 - Dado $p \in (0, 1)$, encontrar el EMV del valor ξ tal que $P_\theta(X_1 > \xi) = p$.

Solución:

a) $L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$, luego

$$\ln(L(\mu, \sigma^2)) = \sum_{i=1}^n \left[\ln\left(\frac{1}{\sigma\sqrt{2\pi}}\right) + \ln\left(e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}\right) \right] = -\frac{n}{2} \ln(2\pi\sigma^2) - \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

$$0 = \frac{\partial \ln(L(\mu, \sigma^2))}{\partial \mu} = \sum_{i=1}^n \frac{(x_i - \mu)}{\sigma^2} \Leftrightarrow 0 = \sum_{i=1}^n x_i - n\mu \Leftrightarrow \mu = \overline{X_n}$$

$$0 = \frac{\partial \ln(L(\mu, \sigma^2))}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 \Leftrightarrow \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

Luego, $\hat{\theta}_{EMV} = \left(\frac{1}{n} \sum_{i=1}^n X_i, \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X_n})^2 \right)$

b) $p = P_\theta(X_1 > \xi) = P_\theta\left(\frac{X_1 - \hat{\mu}}{\hat{\sigma}} > \frac{\xi - \hat{\mu}}{\hat{\sigma}}\right) = P_\theta\left(Z > \frac{\xi - \mu}{\sigma}\right)$ con $Z \sim N(0, 1)$. Por lo tanto, basta con definir

$$p = 1 - \Phi\left(\frac{\xi - \hat{\mu}}{\hat{\sigma}}\right)$$

c) por el inciso anterior, sabemos que $p = 1 - \Phi\left(\frac{\xi - \hat{\mu}}{\hat{\sigma}}\right)$, luego, usando que Φ es biyectiva

$$1 - p = \Phi\left(\frac{\xi - \hat{\mu}}{\hat{\sigma}}\right) \Rightarrow \Phi^{-1}(1 - p) = \frac{\xi - \hat{\mu}}{\hat{\sigma}} \Rightarrow \hat{\sigma}\Phi^{-1}(1 - p) + \hat{\mu} = \hat{\xi}$$

3. Si $X_1, \dots, X_n$ es una m.a. de una distribución $\mathcal{U}[0, \theta]$

- Hallar el EMV de θ .
- Hallar el estimador de los momentos de θ .

Solución:

a) $L(\theta) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{1}_{[0, \theta]}(x_i) = \frac{1}{\theta^n} \prod_{i=1}^n \mathbb{1}_{[0, \theta]}(x_i)$.

Ahora, para poder maximizar estaríamos necesitando que $\prod_{i=1}^n \mathbb{1}_{[0, \theta]}(x_i) = 1$ y esto ocurre sólo si $x_i \in [0, \theta]$ si y sólo si $0 \leq \min_{1 \leq i \leq n} x_i$ y $\max_{1 \leq i \leq n} x_i \leq \theta$. Es decir,

$$\prod_{i=1}^n \mathbb{1}_{[0, \theta]}(x_i) = 1 \Leftrightarrow \mathbb{1}_{[\max x_i, +\infty)}(\theta)$$

Por lo tanto, $L(\theta) = \theta^{-n} \mathbb{1}_{[\max x_i, +\infty)}(\theta)$ y, haciendo el gráfico aproximado, deducimos que $\hat{\theta}_{EMV} = \max_{1 \leq i \leq n} X_i$.

- b) Para buscar el estimador de primer momento, recordemos que $\mathbb{E}(X_1) = \frac{\theta}{2}$ y, entonces,

$$\overline{X_n} = \frac{\hat{\theta}_{MO}}{2} \Rightarrow \hat{\theta}_{MO} = 2\overline{X_n}$$

4. Sea $X_1, \dots, X_n$ una m.a. de una distribución exponencial desplazada, cuya densidad es

$$f(x) = e^{-(x-\theta)} I_{[\theta, \infty)}(x).$$

- Encontrar el EMV de θ .

b) Encontrar el estimador de los momentos de θ .

Solución:

$$a) L(\theta) = \prod_{i=1}^n e^{-(x_i - \theta)} \mathbb{1}_{[\theta, \infty)}(x_i) = e^{n\theta} \prod_{i=1}^n e^{-x_i} \mathbb{1}_{[\theta, \infty)}(x_i).$$

Ahora, para poder maximizar estaríamos necesitando que $\prod_{i=1}^n \mathbb{1}_{[\theta, \infty)}(x_i) = 1$ y esto ocurre sólo si $x_i \geq \theta$ para todo $i \in \{1, \dots, n\}$ si y sólo si $\min_{1 \leq i \leq n} x_i \geq \theta$. Es decir,

$$\prod_{i=1}^n \mathbb{1}_{[\theta, \infty)}(x_i) = 1 \Leftrightarrow \mathbb{1}_{[0, \min x_i)}(\theta)$$

Por lo tanto, $L(\theta) = e^{n\theta} \prod_{i=1}^n e^{-x_i} \mathbb{1}_{[0, \min x_i)}(\theta)$ y, haciendo el gráfico aproximado, deducimos que

$$\hat{\theta}_{EMV} = \min_{1 \leq i \leq n} X_i.$$

b) Para buscar el estimador de primer momento, calculamos $\mathbb{E}(X_1)$

$$\mathbb{E}(X_1) = \int_{\theta}^{\infty} x e^{-(x-\theta)} = \theta + 1$$

entonces,

$$\overline{X_n} = \hat{\theta}_{MO} + 1 \Rightarrow \hat{\theta}_{MO} = \overline{X_n} - 1$$

5. Sean $X_1, \dots, X_n$ una m.a. de una distribución $N(\mu_1, \sigma^2)$ e $Y_1, \dots, Y_m$ una m.a. de una distribución $N(\mu_2, \sigma^2)$, independientes entre sí.

a) Hallar el EMV de $\theta = (\mu_1, \mu_2, \sigma^2)$.

b) Hallar el EMV de $\alpha = \mu_1 - \mu_2$.

Solución:

a) Por la independencia entre las muestras

$$\begin{aligned} L(\mu_1, \mu_2, \sigma^2) &= \prod_{i=1}^n \left(\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x_i - \mu_1)^2}{2\sigma^2}} \right) \prod_{i=1}^m \left(\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(y_i - \mu_2)^2}{2\sigma^2}} \right) \\ \Rightarrow L(\mu_1, \mu_2, \sigma^2) &= \frac{1}{(\sqrt{\sigma^2 2\pi})^{n+m}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_1)^2 - \frac{1}{2\sigma^2} \sum_{i=1}^m (y_i - \mu_2)^2 \right\} \\ \Rightarrow \ln(L(\mu_1, \mu_2, \sigma^2)) &= -\frac{n+m}{2} \ln(\sigma^2 2\pi) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_1)^2 - \frac{1}{2\sigma^2} \sum_{i=1}^m (y_i - \mu_2)^2 \\ \frac{\partial \ln(L(\mu_1, \mu_2, \sigma^2))}{\partial \mu_1} &= \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu_1) \Rightarrow 0 = \frac{\partial \ln(L(\mu_1, \mu_2, \sigma^2))}{\partial \mu_1} \Leftrightarrow \mu_1 = \overline{X_n} \\ \frac{\partial \ln(L(\mu_1, \mu_2, \sigma^2))}{\partial \mu_2} &= \frac{1}{\sigma^2} \sum_{i=1}^m (y_i - \mu_2) \Rightarrow 0 = \frac{\partial \ln(L(\mu_1, \mu_2, \sigma^2))}{\partial \mu_2} \Leftrightarrow \mu_2 = \overline{Y_n} \\ \frac{\partial \ln(L(\mu_1, \mu_2, \sigma^2))}{\partial \sigma^2} &= -\frac{n+m}{2\sigma^2} + \frac{1}{2\sigma^4} \left[\sum_{i=1}^n (x_i - \mu_1)^2 + \sum_{i=1}^m (y_i - \mu_2)^2 \right] \\ \Rightarrow 0 &= \frac{\partial \ln(L(\mu_1, \mu_2, \sigma^2))}{\partial \sigma^2} \Leftrightarrow 0 = -(n+m) + \frac{1}{\sigma^2} \left[\sum_{i=1}^n (x_i - \mu_1)^2 + \sum_{i=1}^m (y_i - \mu_2)^2 \right] \Leftrightarrow \\ \sigma^2 &= \frac{1}{n+m} \left[\sum_{i=1}^n (x_i - \mu_1)^2 + \sum_{i=1}^m (y_i - \mu_2)^2 \right] \end{aligned}$$

Luego, el estimador de máxima verosimilitud

$$\hat{\theta}_{EMV} = (\hat{\mu}_1, \hat{\mu}_2, \hat{\sigma}^2) = \left(\overline{X_n}, \overline{Y_n}, \frac{1}{n+m} \left[\sum_{i=1}^n (X_i - \overline{X_n})^2 + \sum_{i=1}^m (Y_i - \overline{Y_n})^2 \right] \right)$$

- b) Sea $h : \mathbb{R} \times \mathbb{R} \times (0, +\infty) \rightarrow \mathbb{R} \times \mathbb{R} \times (0, +\infty)$ biyectiva definida por $h(x, y, z) = (x - y, y, z)$. Por el teorema de invarianza, el EMV de α resulta

$$\hat{\alpha}_{EMV} = \Pi \circ h(\hat{\mu}_1, \hat{\mu}_2, \hat{\sigma}^2) = \hat{\mu}_1 - \hat{\mu}_2 = \overline{X_n} - \overline{Y_n}$$

6. Se tienen observaciones independientes $X_1, \dots, X_n$ de poblaciones normales con la misma media μ pero con varianzas $\sigma_1^2, \dots, \sigma_n^2$ respectivamente.
- a) ¿Es posible estimar todos los parámetros por máxima verosimilitud?
- b) Suponiendo $\sigma_1^2, \dots, \sigma_n^2$ conocidos, hallar el EMV de μ . Interpretar.

Solución:

- a) veamos cómo queda planteado el estimador usando que las observaciones son independientes,

$$L(\mu, \sigma_1^2, \dots, \sigma_n^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_i^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma_i^2}} \Rightarrow \ln(L(\mu, \sigma_1^2, \dots, \sigma_n^2)) = -\frac{1}{2} \sum_{i=1}^n \ln(2\pi\sigma_i^2) - \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma_i^2}$$

luego,

$$\frac{\partial \ln(L(\mu, \sigma_1^2, \dots, \sigma_n^2))}{\partial \mu} = \sum_{i=1}^n \frac{(x_i - \mu)}{\sigma_i^2} \Rightarrow 0 = \frac{\partial \ln(L(\mu, \sigma_1^2, \dots, \sigma_n^2))}{\partial \mu} \Leftrightarrow \sum_{i=1}^n \frac{x_i}{\sigma_i^2} = \mu \sum_{i=1}^n \frac{1}{\sigma_i^2}$$

por lo tanto,

$$\mu = \frac{\sum_{i=1}^n \frac{x_i}{\sigma_i^2}}{\sum_{i=1}^n \frac{1}{\sigma_i^2}} \Rightarrow \hat{\mu}_{EMV} = \frac{\sum_{i=1}^n \frac{X_i}{\sigma_i^2}}{\sum_{i=1}^n \frac{1}{\sigma_i^2}}$$

$$\frac{\partial \ln(L(\mu, \sigma_1^2, \dots, \sigma_n^2))}{\partial \sigma_i^2} = -\frac{1}{2\sigma_i^2} + \frac{1}{2\sigma_i^4} (x_i - \mu)^2 \Rightarrow 0 = \frac{\partial \ln(L(\mu, \sigma_1^2, \dots, \sigma_n^2))}{\partial \sigma_i^2} \Leftrightarrow \sigma_i^2 = (x_i - \mu)^2$$

7. Si $X_1, \dots, X_n$ es una m.a. de una distribución $\mathcal{U}[\theta - 1/2, \theta + 1/2]$, mostrar que cualquier T tal que $X_{(n)} - 1/2 \leq T \leq X_{(1)} + 1/2$ es un EMV de θ .

Aclaración: $X_{(1)} = \min\{X_1, \dots, X_n\}$ y $X_{(n)} = \max\{X_1, \dots, X_n\}$.

Solución:

$$L(\theta) = \prod_{i=1}^n \mathbb{1}_{[\theta-1/2, \theta+1/2]}(x_i)$$

Ahora, para poder maximizar estaríamos necesitando que $\prod_{i=1}^n \mathbb{1}_{[\theta-1/2, \theta+1/2]}(x_i) = 1$ y esto ocurre sólo si $x_i \in [\theta - 1/2, \theta + 1/2]$ si y sólo si $\theta - 1/2 \leq \min_{1 \leq i \leq n} x_i$ y $\max_{1 \leq i \leq n} x_i \leq \theta + 1/2$. Es decir,

$$\prod_{i=1}^n \mathbb{1}_{[\theta-1/2, \theta+1/2]}(x_i) = 1 \Leftrightarrow \mathbb{1}_{[\min x_i + 1/2, \max x_i - 1/2]}(\theta)$$

8. El número de microorganismos que se encuentran por grupo sobre una superficie sigue la siguiente distribución

$$p(x) = \theta \mathbb{1}_{\{1\}}(x) + \frac{1 - \theta}{k - 1} \mathbb{1}_{\{2, 3, \dots, k\}}(x), \quad \text{donde } 0 < \theta < 1$$

Supongamos que se examinan en forma independiente n grupos y se cuentan el número de microorganismos $X_1, \dots, X_n$ en cada uno de ellos. Calcular el estimador de máxima verosimilitud de θ .

Solución: $L(\theta) = \prod_{i=1}^n \left(\theta \mathbb{1}_{\{1\}}(x) + \frac{1 - \theta}{k - 1} \mathbb{1}_{\{2, 3, \dots, k\}}(x) \right) = \prod_{i=1}^n \left[\theta \mathbb{1}_{\{1\}}(x) \left(\frac{1 - \theta}{k - 1} \right)^{\mathbb{1}_{\{2, 3, \dots, k\}}(x)} \right]$, luego

$$L(\theta) = \theta^{\sum \mathbb{1}_{\{1\}}(x)} \left(\frac{1 - \theta}{k - 1} \right)^{\sum \mathbb{1}_{\{2, 3, \dots, k\}}(x)} = \theta^{\#\{i | x_i = 1\}} \left(\frac{1 - \theta}{k - 1} \right)^{\#\{i | x_i = 2, \dots, k\}}$$

si definimos $N_1 = \#\{i | x_i = 1\}$ y $N_2 = \#\{i | x_i = 2, \dots, k\}$ donde $N_1 + N_2 = n$ tenemos que

$$\begin{aligned} \ln(L(\theta)) &= N_1 \ln(\theta) + N_2 [\ln(1 - \theta) - \ln(k - 1)] \\ \frac{\partial \ln(L(\theta))}{\partial \theta} &= \frac{N_1}{\theta} - \frac{N_2}{1 - \theta} \end{aligned}$$

Buscamos $\hat{\theta}$ tal que $\frac{N_1}{\hat{\theta}} - \frac{N_2}{1 - \hat{\theta}} = 0$. Luego,

$$\frac{N_1}{\hat{\theta}} - \frac{N_2}{1 - \hat{\theta}} = 0 \Leftrightarrow 1 - \hat{\theta}N_1 - N_2\hat{\theta} = 0 \Leftrightarrow \hat{\theta}(N_1 + N_2) = N_1 \Leftrightarrow \hat{\theta} = \frac{N_1}{n}$$

1.11.3. Estimadores Bayesianos con Pérdida Cuadrática

En esta sección, todos los estimadores Bayes pedidos son respecto a la pérdida cuadrática. Más específicamente, sea $\mathbf{X} = (X_1, \dots, X_n)$ es una m.a. tal que $X_1 | \Theta = \theta \sim F_\theta$ y $\Theta \sim \Lambda$ es la distribución a priori de Θ . Dado un estimador $\delta(\mathbf{X})$ de $q(\theta)$, llamamos riesgo Bayes a

$$r(\Lambda, \delta) = \int \mathbb{E}_\theta[(\delta(\mathbf{X}) - q(\theta))^2] d\Lambda(\theta)$$

y estimador Bayes para $q(\theta)$ a

$$\delta_\Lambda(\mathbf{X}) = \underset{\delta}{\operatorname{argmin}} r(\Lambda, \delta).$$

En este caso, el estimador Bayes puede ser obtenido simplemente como la esperanza de la distribución a posteriori:

$$\delta_\Lambda(\mathbf{X}) = \mathbb{E}[q(\Theta) | \mathbf{X}].$$

1. a) Sea θ con distribución a priori Λ y $X_1, \dots, X_n$ una m.a. tal que $X_i | \theta = \theta \sim F_\theta$. Se desea estimar $q(\theta)$ utilizando la función de pérdida cuadrática. Demostrar que si el estimador de Bayes $\delta_\Lambda(\mathbf{X})$ es un estimador insesgado de $q(\theta)$, es decir

$$\mathbb{E}(\delta_\Lambda(\mathbf{X}) | \theta = \theta) = q(\theta) \quad \forall \theta \in \Theta$$

entonces $\mathbb{E}[(\delta_\Lambda(\mathbf{X}) - q(\theta))^2] = 0$.

- b) Mostrar que $\bar{X}$ no es un estimador de Bayes de θ para ninguna distribución a priori Λ cuando $X | \theta = \theta \sim N(\theta, 1)$ y cuando se usa la pérdida cuadrática.

Solución:

- a) desarrollando el cuadrado, nos queda que

$$\mathbb{E}[(\delta_\Lambda(\mathbf{X}) - q(\theta))^2] = \mathbb{E}(\delta_\Lambda^2(\mathbf{X})) - 2\mathbb{E}(\delta_\Lambda(\mathbf{X})q(\theta)) + \mathbb{E}(q^2(\theta))$$

y notemos que

$$\mathbb{E}(\delta_\Lambda(\mathbf{X})q(\theta)) = \mathbb{E}[q(\theta) \underbrace{\mathbb{E}(\delta_\Lambda(\mathbf{X}) | \theta)}_{=q(\theta)}] = \mathbb{E}(q^2(\theta))$$

$$\mathbb{E}(\delta_\Lambda(\mathbf{X})q(\theta)) = \mathbb{E}[\delta_\Lambda(\mathbf{X}) \underbrace{\mathbb{E}(q(\theta) | \mathbf{X})}_{=\delta_\Lambda(\mathbf{X}), \text{ por ser pérdida cuadrática}}] = \mathbb{E}(\delta_\Lambda^2(\mathbf{X}))$$

luego,

$$2\mathbb{E}(\delta_\Lambda(\mathbf{X})q(\theta)) = \mathbb{E}(\delta_\Lambda(\mathbf{X})q(\theta)) + \mathbb{E}(\delta_\Lambda(\mathbf{X})q(\theta)) = \mathbb{E}(\delta_\Lambda^2(\mathbf{X})) + \mathbb{E}(q^2(\theta)), \text{ entonces}$$

$$\mathbb{E}[(\delta_\Lambda(\mathbf{X}) - q(\theta))^2] = \mathbb{E}(\delta_\Lambda^2(\mathbf{X})) - \mathbb{E}(\delta_\Lambda^2(\mathbf{X})) - \mathbb{E}(q^2(\theta)) + \mathbb{E}(q^2(\theta)) = 0.$$

- b) Supongamos que $\bar{X}$ es un estimador de Bayes de θ para alguna distribución a priori Λ cuando $X | \theta = \theta \sim N(\theta, 1)$ y se usa la pérdida cuadrática. Notemos que $\bar{X}$ es un estimador insesgado, entonces $\mathbb{E}(\bar{X} | \theta = \theta) = \theta$ pues $\bar{X} | \theta = \theta \sim N(\theta, 1/n)$ y por el inciso anterior debería pasar que $\mathbb{E}[(\bar{X} - \theta)^2] = 0$. Sabemos que $(\bar{X} - \theta) \sim N(0, 1/n)$ entonces $\sqrt{n}(\bar{X} - \theta) \sim N(0, 1)$, luego

$$0 = \mathbb{E}[(\bar{X} - \theta)^2] = \frac{1}{n} \mathbb{E}(n(\bar{X} - \theta)^2) = \frac{1}{n} \mathbb{E}[(\sqrt{n}(\bar{X} - \theta))^2] = \frac{1}{n}$$

lo que resulta ser una contradicción.

2. Sea X una v.a. tal que $X|\theta=\theta \sim \mathcal{U}(0, \theta)$ y $\theta \sim \Gamma(2, 1)$. Encontrar el estimador Bayes de θ .

Aclaración: notar que tenemos una sola variable aleatoria, es decir, una muestra con $n = 1$.

Solución: Buscamos el estimador de la pinta $\delta_\Lambda(\mathbf{X}) = \mathbb{E}[q(\Theta)|\mathbf{X}]$, por lo tanto, necesitamos encontrar la distribución $f_{\theta|\mathbf{X}=x}$.

Con un abuso de notación, recordemos que

$$f_{\theta|\mathbf{X}=x} = \frac{f_{X|\theta=\theta} f_{\theta}}{\int_{\mathbb{R}} f_{X|\theta=\theta} f_{\theta} d\theta}$$

Como datos tenemos que

$$f_{X|\theta=\theta} = \frac{1}{\theta} \mathbb{1}_{(0,\theta)}(x) \quad \text{y} \quad f_{\theta}(\theta) = \frac{1}{\Gamma(2)} \theta e^{-\theta} \mathbb{1}_{(0,+\infty)}(\theta)$$

Luego,

$$\int_{\mathbb{R}} f_{X|\theta=\theta} f_{\theta} d\theta = \int_{\mathbb{R}} \frac{1}{\theta} \mathbb{1}_{(0,\theta)}(x) \frac{1}{\Gamma(2)} \theta e^{-\theta} \mathbb{1}_{(0,+\infty)}(\theta) d\theta = \frac{1}{\Gamma(2)} \int_0^{\infty} e^{-\theta} \mathbb{1}_{(0,\theta)}(x) d\theta$$

observemos que $\mathbb{1}_{(0,\theta)}(x) = \mathbb{1}_{(0,\infty)}(x) \mathbb{1}_{(x,\infty)}(\theta)$ y $\frac{1}{\Gamma(2)} = 1$, entonces

$$\int_{\mathbb{R}} f_{X|\theta=\theta} f_{\theta} d\theta = \int_x^{\infty} \mathbb{1}_{(0,\infty)}(x) e^{-\theta} d\theta = \mathbb{1}_{(0,\infty)}(x) (-e^{-\theta}) \Big|_x^{\infty} = e^{-x} \mathbb{1}_{(0,\infty)}(x)$$

Entonces, reemplazando

$$f_{\theta|\mathbf{X}=x} = \frac{e^{-\theta} \mathbb{1}_{(0,\theta)}(x) \mathbb{1}_{(0,+\infty)}(\theta)}{e^{-x} \mathbb{1}_{(0,\infty)}(x)} = \frac{e^{-\theta} \mathbb{1}_{(0,\infty)}(x) \mathbb{1}_{(x,\infty)}(\theta) \mathbb{1}_{(0,+\infty)}(\theta)}{e^{-x} \mathbb{1}_{(0,\infty)}(x)} = e^{x-\theta} \mathbb{1}_{(x,+\infty)}(\theta)$$

Volviendo al estimador, calculemos $\mathbb{E}(\theta|X=x)$

$$\mathbb{E}(\theta|X=x) = \int_x^{\infty} \theta e^{x-\theta} d\theta = e^x \int_x^{\infty} \theta e^{-\theta} d\theta = x + 1$$

Es decir, que el estimador de Bayes resulta

$$\delta_\Lambda(X) = X + 1$$

3. Sea $X_1, \dots, X_n$ una m.a. tal que $X_i|\theta=\theta \sim Bi(1, \theta)$ y $\theta \sim \Lambda$ continua. Consideremos la función de pérdida cuadrática.

- Probar que $\bar{X}$ no es un estimador de Bayes de θ para ninguna distribución a priori Λ .
- Hallar el estimador de Bayes δ_Λ cuando $\Lambda = \beta(r, s)$, con $r, s > 0$. Mostrar que δ_Λ es un promedio pesado entre $\bar{X}$ y $\frac{r}{r+s}$. Interpretar.

Recordar: que $\theta \sim \beta(r, s)$ si su función de densidad es

$$f(\theta) = \frac{\Gamma(r+s)}{\Gamma(r)\Gamma(s)} \theta^{r-1} (1-\theta)^{s-1} I_{(0,1)}(\theta)$$

Solución:

- Verifiquemos, primero, que el estimador $\bar{X}$ es insesgado; ie, $\mathbb{E}(\bar{X}|\theta=\theta) = \theta$:

$$\mathbb{E}(n\bar{X}|\theta=\theta) = n\theta, \text{ pues } n\bar{X} \sim Bi(n, \theta) \Rightarrow \mathbb{E}(\bar{X}|\theta=\theta) = \frac{1}{n} \mathbb{E}(n\bar{X}|\theta=\theta) = \theta$$

y, por lo visto anteriormente, debería pasar que $\mathbb{E}[(\bar{X} - \theta)^2] = 0$

$$\mathbb{E}[(\bar{X} - \theta)^2] = \mathbb{E}(\bar{X}^2) - 2\theta\mathbb{E}(\bar{X}) + \theta^2 = \mathbb{E}_\theta[\mathbb{E}(\bar{X}^2|\theta)] - 2\theta\mathbb{E}_\theta[\mathbb{E}(\bar{X}|\theta)] + \theta^2 \Rightarrow$$

$$\mathbb{E}[(\bar{X} - \theta)^2] = \mathbb{E}_\theta \left[\mathbb{V} \left(\frac{n}{n} \bar{X}^2 | \theta \right) + \mathbb{E}^2(\bar{X} | \theta) \right] - 2\theta^2 + \theta^2 = \mathbb{E}_\theta \left[\frac{1}{n^2} n\theta(1-\theta) + \theta^2 \right] - \theta^2 \Rightarrow$$

$$\mathbb{E}[(\bar{X} - \theta)^2] = \mathbb{E}_\theta \left[\frac{\theta(1-\theta)}{n} \right] > 0, \text{ pues } \theta(1-\theta) > 0 \Rightarrow \mathbb{E}[(\bar{X} - \theta)^2] \neq 0$$

es decir, $\bar{X}$ no es un estimador de Bayes de θ para ninguna distribución a priori Λ .

- b) Buscamos el estimador de la pinta $\delta_\Lambda(\mathbf{X}) = \mathbb{E}[q(\Theta)|\mathbf{X}]$, por lo tanto, necesitamos encontrar la distribución $f_{\theta|\mathbf{X}=x}$. Con un abuso de notación, recordemos que

$$f_{\theta|\mathbf{X}=x} = \frac{p_{X|\theta=\theta} f_{\theta}}{\int_{\mathbb{R}} p_{X|\theta=\theta} f_{\theta} d\theta}$$

Como datos tenemos que

$$p_{X_i|\theta=\theta} = \theta^{x_i} (1-\theta)^{1-x_i} \mathbb{1}_{\{0,1\}}(x_i) \Rightarrow p_{X|\theta=\theta} = \prod_{i=1}^n p_{X_i|\theta=\theta} = \theta^{\sum x_i} (1-\theta)^{1-\sum x_i} \prod_{i=1}^n \mathbb{1}_{\{0,1\}}(x_i)$$

$$f_{\theta}(\theta) = \frac{\Gamma(r+s)}{\Gamma(r)\Gamma(s)} \theta^{r-1} (1-\theta)^{s-1} \mathbb{1}_{(0,1)}(\theta)$$

Luego,

$$\int_{\mathbb{R}} p_{X|\theta=\theta} f_{\theta} d\theta = \int_{\mathbb{R}} \theta^{\sum x_i} (1-\theta)^{n-\sum x_i} \prod_{i=1}^n \mathbb{1}_{\{0,1\}}(x_i) \frac{\Gamma(r+s)}{\Gamma(r)\Gamma(s)} \theta^{r-1} (1-\theta)^{s-1} \mathbb{1}_{(0,1)}(\theta) d\theta$$

completemos para poder llevarla a una distribución $\beta\left(r + \sum_{i=1}^n x_i, n + s - \sum_{i=1}^n x_i\right)$ es decir,

$$\int_{\mathbb{R}} \frac{\Gamma(r+s+n)}{\Gamma(r+\sum x_i)\Gamma(n+s-\sum x_i)} \theta^{r+\sum x_i-1} (1-\theta)^{n+s-\sum x_i-1} \mathbb{1}_{(0,1)}(\theta) d\theta = 1$$

y, por lo tanto, nos queda que

$$\int_{\mathbb{R}} p_{X|\theta=\theta} f_{\theta} d\theta = \frac{\Gamma(r+s)}{\Gamma(r)\Gamma(s)} \frac{\Gamma(r+\sum x_i)\Gamma(n+s-\sum x_i)}{\Gamma(r+s+n)} \prod_{i=1}^n \mathbb{1}_{\{0,1\}}(x_i)$$

siguiendo con la misma cuenta, deducimos que

$$f_{\theta|\mathbf{X}=x} = \frac{\Gamma(r+s+n)}{\Gamma(r+\sum x_i)\Gamma(n+s-\sum x_i)} \theta^{r+\sum x_i-1} (1-\theta)^{n+s-\sum x_i-1} \mathbb{1}_{(0,1)}(\theta) d\theta \sim \beta\left(r + \sum_{i=1}^n x_i, n + s - \sum_{i=1}^n x_i\right)$$

Para buscar el estimador Bayes, sólo nos queda buscar $\delta_\Lambda(\mathbf{X})$

$$\delta_\Lambda(\mathbf{X}) = \mathbb{E}[\theta|\mathbf{X}=x] = \frac{1}{n+r+s} \left(r + \sum_{i=1}^n x_i\right)$$

Por último, para verificar que $\delta_\Lambda(\mathbf{X})$ es un promedio pesado, basta con verificar que si $0 < \alpha = \frac{n}{n+r+s}$, obtenemos que

$$\alpha \bar{X} + (1-\alpha) \frac{r}{r+s} = \frac{r}{n+r+s} + \frac{1}{n+r+s} \sum_{i=1}^n x_i$$

4. Consideremos una m.a. $X_1, \dots, X_n$ tal que $X_i|\theta=\theta \sim \mathcal{P}(\theta)$ y $\theta \sim \Gamma(r, \lambda)$, con $r, \lambda > 0$.

- Encontrar el estimador Bayes δ_Λ y calcular $r(\delta_\Lambda, \Lambda)$ el riesgo de Bayes.
- Mostrar que δ_Λ puede escribirse como un promedio pesado entre $\bar{X}$ y $\frac{r}{\lambda}$. Interpretar.
- Comparar $r(\delta_\Lambda, \Lambda)$ con $r(\bar{X}, \Lambda)$. Mostrar que $\frac{r(\bar{X}, \Lambda)}{r(\delta_\Lambda, \Lambda)} \rightarrow 1$ cuando $n \rightarrow \infty$.

Solución:

- Buscamos el estimador de la pinta $\delta_\Lambda(\mathbf{X}) = \mathbb{E}[q(\Theta)|\mathbf{X}]$, por lo tanto, necesitamos encontrar la distribución $f_{\theta|\mathbf{X}=x}$. Con un abuso de notación, recordemos que

$$f_{\theta|\mathbf{X}=x} = \frac{p_{X|\theta=\theta} f_{\theta}}{\int_{\mathbb{R}} p_{X|\theta=\theta} f_{\theta} d\theta}$$

Como datos tenemos que

$$p_{X_i|\theta=\theta} = \frac{\theta^{x_i} e^{-\theta}}{x_i!} \mathbb{1}_{\mathbb{N}}(x_i) \Rightarrow p_{X|\theta=\theta} = \prod_{i=1}^n p_{X_i|\theta=\theta} = \theta^{\sum x_i} e^{-n\theta} \prod_{i=1}^n \frac{1}{x_i!} \mathbb{1}_{\mathbb{N}}(x_i)$$

$$f_{\theta}(\theta) = \frac{\lambda^r}{\Gamma(r)} \theta^{r-1} e^{-\lambda\theta} \mathbb{1}_{(0,\infty)}(\theta)$$

Luego,

$$\int_{\mathbb{R}} p_{X|\theta=\theta} f_{\theta} d\theta = \int_{\mathbb{R}} \theta^{\sum x_i} e^{-n\theta} \prod_{i=1}^n \frac{1}{x_i!} \mathbb{1}_{\mathbb{N}}(x_i) \frac{\lambda^r}{\Gamma(r)} \theta^{r-1} e^{-\lambda\theta} \mathbb{1}_{(0,\infty)}(\theta) d\theta$$

completemos para poder llevarla a una distribución $\Gamma\left(r + \sum_{i=1}^n x_i, n + \lambda\right)$ es decir,

$$\int_{\mathbb{R}} \theta^{\sum x_i + r - 1} e^{-\theta(n + \lambda)} \frac{(n + \lambda)^{\sum x_i + r}}{\Gamma(\sum x_i + r)} d\theta = 1$$

y, por lo tanto, nos queda que

$$\int_{\mathbb{R}} p_{X|\theta=\theta} f_{\theta} d\theta = \frac{\lambda^r}{\Gamma(r)} \frac{\Gamma(\sum x_i + r)}{(n + \lambda)^{\sum x_i + r}} \prod_{i=1}^n \frac{1}{x_i!} \mathbb{1}_{\mathbb{N}}(x_i)$$

siguiendo con la misma cuenta, deducimos que

$$f_{\theta|\mathbf{X}=x} = \frac{(n + \lambda)^{\sum x_i + r}}{\Gamma(\sum x_i + r)} \theta^{\sum x_i + r - 1} e^{-\theta(n + \lambda)} \mathbb{1}_{(0,\infty)}(\theta) \sim \Gamma\left(r + \sum_{i=1}^n x_i, n + \lambda\right)$$

Para buscar el estimador Bayes, sólo nos queda buscar $\delta_{\Lambda}(\mathbf{X})$

$$\delta_{\Lambda}(\mathbf{X}) = \mathbb{E}[\theta|\mathbf{X} = x] = \frac{1}{n + \lambda} \left(r + \sum_{i=1}^n x_i\right)$$

Planteamos el riesgo Bayes

$$r(\Lambda, \delta) = \int \mathbb{E}_{\theta}[(\delta(\mathbf{X}) - q(\theta))^2] d\Lambda(\theta)$$

y busquemos $\mathbb{E}_{\theta}[(\delta(\mathbf{X}) - q(\theta))^2]$

$$\mathbb{E}_{\theta}[(\delta(\mathbf{X}) - \theta)^2] = \mathbb{E}_{\theta}[(\delta^2(\mathbf{X}) - 2\delta(\mathbf{X})\theta + \theta^2)] = \mathbb{E}_{\theta}\{\mathbb{E}[(\delta^2(\mathbf{X}) - 2\delta(\mathbf{X})\theta + \theta^2)|\theta]\} \Rightarrow$$

$$\mathbb{E}_{\theta}[(\delta(\mathbf{X}) - \theta)^2] = \mathbb{E}_{\theta}[\mathbb{E}(\delta^2(\mathbf{X})|\theta)] - 2\mathbb{E}_{\theta}[\theta\mathbb{E}(\delta(\mathbf{X})|\theta)] + \mathbb{E}_{\theta}(\theta^2)$$

recordando que si $X \sim \mathcal{P}(\theta_1)$, $Y \sim \mathcal{P}(\theta_2)$ entonces $X + Y \sim \mathcal{P}(\theta_1 + \theta_2)$, veamos las cuenta por separado

$$\mathbb{E}(\delta(\mathbf{X})|\theta) = \mathbb{E}\left[\frac{1}{n + \lambda} \left(r + \sum_{i=1}^n x_i\right) \middle| \theta\right] = \frac{1}{n + \lambda} \left[\mathbb{E}\left(\sum_{i=1}^n x_i \middle| \theta\right) + r\right] = \frac{1}{n + \lambda} (n\theta + r)$$

$$\mathbb{E}(\delta^2(\mathbf{X})|\theta) = \mathbb{V}(\delta(\mathbf{X})|\theta) + \mathbb{E}^2(\delta(\mathbf{X})|\theta) = \frac{1}{(n + \lambda)^2} \mathbb{V}\left(\sum_{i=1}^n x_i \middle| \theta\right) + \left(\frac{n\theta + r}{n + \lambda}\right)^2 = \frac{n\theta + (n\theta + r)^2}{(n + \lambda)^2}$$

Finalmente, juntado todo

$$\mathbb{E}_{\theta}[(\delta(\mathbf{X}) - \theta)^2] = \frac{n\theta + (n\theta + r)^2}{(n + \lambda)^2} - 2\frac{\theta(n\theta + r)}{n + \lambda} + \theta^2$$

b) Para verificar que $\delta_{\Lambda}(\mathbf{X})$ es un promedio pesado, basta con verificar que si $0 < \alpha = \frac{n}{n + \lambda}$, obtenemos que

$$\alpha \bar{X} + (1 - \alpha) \frac{r}{\lambda} = \frac{1}{n + \lambda} \left(r + \sum_{i=1}^n x_i\right)$$

c) calculemos $r(\bar{X}, \Lambda)$,

$$\begin{aligned}\mathbb{E}[(\bar{X} - \theta)^2] &= \mathbb{E}_\theta(\theta^2) - 2\mathbb{E}_\theta(\theta\bar{X}) + \mathbb{E}_\theta(\bar{X}^2) = \mathbb{E}_\theta(\theta^2) - 2\mathbb{E}_\theta[\theta\mathbb{E}(\bar{X}|\theta)] + \mathbb{E}_\theta[\mathbb{E}(\bar{X}^2|\theta)] \Rightarrow \\ \mathbb{E}[(\bar{X} - \theta)^2] &= \mathbb{E}_\theta[\mathbb{V}(\bar{X}|\theta) + \mathbb{E}^2(\bar{X}|\theta)] - 2\mathbb{E}_\theta\left(\theta\frac{1}{n}n\theta\right) + \theta^2 = \mathbb{E}_\theta\left(\frac{1}{n^2}n\theta^2 + \theta^2\right) - 2\mathbb{E}^2(\theta^2) + \theta^2 \Rightarrow \\ \mathbb{E}[(\bar{X} - \theta)^2] &= \mathbb{E}_\theta\left(\frac{\theta}{n} + \theta^2\right) - \theta^2 = \mathbb{E}_\theta\left(\frac{\theta}{n}\right) = \frac{r}{n\lambda}\end{aligned}$$

5. **Detección de SPAM.** Supongamos que la probabilidad de que un mail sea SPAM es $p \in (0, 1)$ (conocida). Supongamos también que los mails que son SPAM provienen de una distribución con densidad $f_1(x)$ y los mails que no lo son provienen de una distribución con densidad $f_0(x)$. Dado un nuevo mail X , la regla **MAP** (maximum a posteriori) clasifica a dicho mail como SPAM si y sólo si

$$\mathbb{P}(\text{el mail es SPAM}|X = x) > \mathbb{P}(\text{el mail no es SPAM}|X = x).$$

Demostrar que esta regla clasifica al mail X como SPAM si y sólo si

$$\frac{f_1(X)}{f_0(X)} > \frac{1-p}{p}.$$

Solución: Por el Teorema de Bayes sabemos que

$$\mathbb{P}(A_i|B) = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\mathbb{P}(B)}$$

donde,

$\mathbb{P}(A_i)$, son las probabilidades a priori.

$\mathbb{P}(B|A_i)$, es la probabilidad de B en la hipótesis A_i .

$\mathbb{P}(A_i|B)$, son las probabilidades a posteriori

$$\mathbb{P}(\text{el mail es SPAM}|X = x) > \mathbb{P}(\text{el mail no es SPAM}|X = x) \Leftrightarrow$$

$$\frac{\mathbb{P}(X = x|\text{el mail es SPAM})\mathbb{P}(\text{el mail es SPAM})}{\mathbb{P}(X = x)} > \frac{\mathbb{P}(X = x|\text{el mail no es SPAM})\mathbb{P}(\text{el mail no es SPAM})}{\mathbb{P}(X = x)} \Leftrightarrow$$

$$f_1(X)p > f_0(X)(1-p) \Leftrightarrow \frac{f_1(X)}{f_0(X)} > \frac{1-p}{p}$$

6. Estimadores de James-Stein.

a) Supongamos que tenemos una única observación X en el siguiente modelo Bayesiano: $X|\mu=\mu \sim N(\mu, 1)$ y $\mu \sim N(M, A)$. Hallar el estimador Bayes de μ .

b) Sea $X_1, \dots, X_n$ con $n \geq 4$ una muestra aleatoria tal que $X_i|\mu_i=\mu_i \sim N(\mu_i, 1)$ y $\mu_i \sim N(M, A)$ independientemente para $i = 1, \dots, n$. Notar que a diferencia del modelo Bayesiano tradicional, el parámetro μ_i varía con la observación. Sea $\mu = (\mu_1, \dots, \mu_n)^T$ y $\mathbf{X} = (X_1, \dots, X_n)$.

1) Hallar el EMV de μ .

2) Probar que el estimador Bayes para μ es

$$\hat{\mu}_{\text{bayes}} = \mathbf{M} + B(\mathbf{X} - \mathbf{M})$$

donde $\mathbf{M} = (M, M, \dots, M)^T$ y $B = A/(A+1)$.

En la práctica, M y B no son conocidos y se estiman con

$$\hat{M} = \bar{X} \quad \text{y} \quad \hat{B} = 1 - \frac{n-3}{\sum_{i=1}^n (X_i - \bar{X})^2}.$$

El estimador $\hat{\mu}_{JS} = \hat{\mathbf{M}} + \hat{B}(\mathbf{X} - \hat{\mathbf{M}})$ donde $\hat{\mathbf{M}} = (\hat{M}, \dots, \hat{M})^T$ se conoce como el estimador de James-Stein.

1.11.4. Riesgo, Error Cuadrático Medio, Estimadores Insesgados

1. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución con parámetro θ . Sea $\tilde{\theta}_n = \delta(\mathbf{X})$ un estimador de θ con varianza finita. Si $b(\tilde{\theta}_n)$ es el sesgo de θ_n , probar que $\text{ECM}(\tilde{\theta}_n) = \mathbb{V}(\tilde{\theta}_n) + b(\tilde{\theta}_n)^2$.

Solución: $\mathbb{E}[(\tilde{\theta}_n - \theta)^2] = \mathbb{V}(\tilde{\theta}_n - \theta) + [\mathbb{E}(\tilde{\theta}_n - \theta)]^2 = \mathbb{V}(\tilde{\theta}_n - \theta) + [\mathbb{E}(\tilde{\theta}_n) - \mathbb{E}(\theta)]^2$, entonces

$$\mathbb{E}[(\tilde{\theta}_n - \theta)^2] = \mathbb{V}(\tilde{\theta}_n) + \mathbb{V}(\theta) - 2\text{Cov}(\tilde{\theta}_n, \theta) + [\mathbb{E}(\tilde{\theta}_n) - \mathbb{E}(\theta)]^2$$

además $\mathbb{V}(\theta) = 0$, $\text{Cov}(\tilde{\theta}, \theta) = 0$ y $\mathbb{E}(\theta) = \theta$, entonces tenemos que

$$\mathbb{E}[(\tilde{\theta}_n - \theta)^2] = \mathbb{V}(\tilde{\theta}_n) + \underbrace{[\mathbb{E}(\tilde{\theta}_n) - \theta]^2}_{b(\tilde{\theta}_n)} = \mathbb{V}(\tilde{\theta}_n) + b^2(\tilde{\theta}_n)$$

2. Sea $X_1, \dots, X_n$ una m.a. de una distribución tal que existe $\mathbb{V}(X) = \sigma^2$.

a) Demostrar que

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

es un estimador insesgado de σ^2 .

- b) Sea $X_1, \dots, X_n$ es una m.a. de una distribución $N(\mu, \sigma^2)$, calcular el $\text{ECM}(s^2)$ y el $\text{ECM}(\tilde{\sigma}^2)$ donde $\tilde{\sigma}^2 = (n-1)s^2/(n+1)$.

Sugerencia: puede usar que si $X_1, \dots, X_n$ son i.i.d con distribución $N(\mu, \sigma^2)$, entonces

$$\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi_{n-1}^2.$$

- c) Probar que, aunque $\text{ECM}(s^2) > \text{ECM}(\tilde{\sigma}^2)$, la razón entre los ECM tiende a 1 cuando $n \rightarrow \infty$.

- d) Mostrar que la contribución del sesgo de $\tilde{\sigma}^2$ a $\text{ECM}(\tilde{\sigma}^2)$ es despreciable cuando $n \rightarrow \infty$ (en el sentido de que la razón entre $b(\tilde{\sigma}^2)^2$ y $\text{ECM}(\tilde{\sigma}^2)$ tiende a 0).

Solución:

- a) queremos ver que $\mathbb{E}(s^2) = \sigma^2$, entonces

$$\mathbb{E}(s^2) = \frac{1}{n-1} \mathbb{E} \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right]$$

por otra parte,

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2) = \sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2 \Rightarrow$$

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - 2n\bar{X} \frac{1}{n} \sum_{i=1}^n X_i + n\bar{X}^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$$

luego,

$$\mathbb{E}(s^2) = \frac{1}{n-1} \mathbb{E} \left[\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right] = \frac{1}{n-1} \left(\sum_{i=1}^n \mathbb{E}(X_i^2) - n\mathbb{E}(\bar{X}^2) \right) = \frac{1}{n-1} [n\mathbb{E}(X_1^2) - n(\mathbb{V}(\bar{X}) + \mathbb{E}(\bar{X})^2)]$$

entonces

$$\mathbb{E}(s^2) = \frac{1}{n-1} [n(\mathbb{V}(X_1) - \mathbb{V}(\bar{X})) + n(\mathbb{E}^2(X_1) - \mathbb{E}^2(\bar{X}))] = \frac{1}{n-1} n(\mathbb{V}(X_1) - \mathbb{V}(\bar{X})) \Rightarrow$$

$$\mathbb{E}(s^2) = \frac{n}{n-1} \left(\mathbb{V}(X_1) - \frac{1}{n} \mathbb{V}(X_1) \right) = \frac{1}{n-1} (n-1) \mathbb{V}(X_1) = \mathbb{V}(X_1) = \sigma^2$$

b) Como el estimador s^2 es insesgado, sabemos que $ECM(s^2) = \mathbb{V}(s^2)$.

Además, recordemos que $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi_{n-1}^2$ luego,

$$ECM(s^2) = \mathbb{V}(s^2) = \mathbb{V}\left(\frac{\sigma^2}{n-1} \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma^2}\right) = \left(\frac{\sigma^2}{n-1}\right)^2 2(n-1) = \frac{2(\sigma^2)^2}{n-1}$$

por otra parte,

$$\begin{aligned} ECM(\tilde{s}^2) &= \mathbb{V}\left(\frac{(n-1)s^2}{n+1}\right) + b^2 \left(\frac{(n-1)s^2}{n+1}\right) \Rightarrow \\ &\mathbb{V}\left(\frac{(n-1)s^2}{\sigma^2} \frac{\sigma^2}{n+1}\right) + \left[\mathbb{E}\left(\frac{(n-1)s^2}{n+1}\right) - \sigma^2\right]^2 = \left(\frac{\sigma^2}{n+1}\right)^2 2(n-1) + \left[\frac{n-1}{n+1}\mathbb{E}(s^2) - \sigma^2\right]^2 \\ &\Rightarrow ECM(\tilde{s}^2) = \left(\frac{\sigma^2}{n+1}\right)^2 2(n-1) + \left(\frac{n-1}{n+1}\sigma^2 - \sigma^2\right)^2 = \frac{2(\sigma^2)^2(n-1)}{(n+1)^2} + (\sigma^2)^2 \frac{4}{(n+1)^2} \\ &\Rightarrow ECM(\tilde{s}^2) = \frac{(\sigma^2)^2}{(n+1)^2} (2n-2+4) = \frac{2(\sigma^2)^2}{n+1} \end{aligned}$$

c) veamos el límite,

$$\lim_{n \rightarrow \infty} \frac{ECM(s^2)}{ECM(\tilde{s}^2)} = \lim_{n \rightarrow \infty} \frac{\frac{2(\sigma^2)^2}{n-1}}{\frac{2(\sigma^2)^2}{n+1}} = \lim_{n \rightarrow \infty} \frac{n+1}{n-1} = 1$$

d) veamos el límite,

$$\lim_{n \rightarrow \infty} \frac{b^2(\tilde{s}^2)}{ECM(\tilde{s}^2)} = \lim_{n \rightarrow \infty} \frac{\frac{4(\sigma^2)^2}{(n+1)^2}}{\frac{2(\sigma^2)^2}{n+1}} = \lim_{n \rightarrow \infty} \frac{2(n+1)}{(n+1)^2} = 0$$

3. Dada una m.a. $X_1, \dots, X_n$ de una distribución $\mathcal{U}(0, \theta)$, sea $\tilde{\theta}_n$ el EMV de θ y $\hat{\theta}_n$ el estimador de θ basado en el primer momento.

a) Probar que $\hat{\theta}_n$ es insesgado y que $\tilde{\theta}_n$ es asintóticamente insesgado.

b) Calcular el ECM de ambos estimadores. ¿Qué estimador preferiría desde este punto de vista?

c) ¿Cómo modificaría el estimador $\tilde{\theta}_n$ para que quede insesgado? Llamemos $\tilde{\theta}_n^{\text{mod}}$ a este estimador modificado.

d) (Para hacer con R) Para cada uno de los valores $n = 6, 10, 20, 40, 80, 200$ hacer lo siguiente:

1) Generar una muestra de tamaño n de una distribución $\mathcal{U}(0, \theta_0)$ con $\theta_0 = 3$.

2) Evaluar los tres estimadores $\hat{\theta}_n$, $\tilde{\theta}_n$ y $\tilde{\theta}_n^{\text{mod}}$ en dicha muestra.

3) Repetir los dos pasos anteriores $m = 1000$ veces, obteniendo así, para cada uno de los tres estimadores, repeticiones $\theta_1^*, \dots, \theta_m^*$.

4) Para cada estimador, computar el ECM

$$\frac{1}{m} \sum_{i=1}^m (\theta_i^* - \theta_0)^2$$

Finalmente, graficar n vs. el ECM de cada uno de los tres métodos anteriores (todo en un mismo gráfico). Hacer boxplots con los valores estimados $\theta_1^*, \dots, \theta_m^*$. ¿Tienen sentido estos resultados respecto de los resultados teóricos de los primeros items?

Solución:

a) Sabemos que $\hat{\theta} = 2\bar{X}_n$ y $\tilde{\theta} = \max_{1 \leq i \leq n} X_i$. Para ver que el estimador de momentos es insesgado veamos que $\mathbb{E}(\hat{\theta}) = \theta$,

$$\mathbb{E}(\hat{\theta}) = 2\mathbb{E}(\bar{X}_n) = \frac{2}{n} \sum_{i=1}^n \mathbb{E}(X_i) = 2\mathbb{E}(X_1) = 2\frac{\theta}{2} = \theta.$$

Por otra parte, para ver que el estimador de máxima verosimilitud es asintóticamente insesgado, veamos que $\mathbb{E}(\tilde{\theta}) \xrightarrow[n \rightarrow \infty]{} \theta$. Para ésto, comenzamos buscando la distribución del máximo,

$$\mathbb{P}\left(\max_{1 \leq i \leq n} X_i \leq t\right) = \left(\frac{t}{\theta}\right)^n, \quad \text{si } t \in (0, \theta) \Rightarrow f_{X^{(n)}}(t) = \frac{nt^{n-1}}{\theta^n} \mathbb{1}_{(0, \theta)}(t)$$

luego,

$$\mathbb{E}(X^{(n)}) = \int_0^\theta t \frac{nt^{n-1}}{\theta^n} dt = \frac{n}{\theta^n} \frac{t^{n+1}}{n+1} \Big|_0^\theta = \frac{n}{n+1} \theta \xrightarrow[n \rightarrow \infty]{} \theta$$

b) como el estimador de momentos es insesgado, se tiene que

$$ECM(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = \mathbb{V}(\hat{\theta}) = \frac{4}{n} \mathbb{V}(X_1) = \frac{4}{n} \frac{\theta^2}{12} = \frac{\theta^2}{3n}$$

para el estimador de máxima verosimilitud, notemos que

$$\begin{aligned} ECM(\tilde{\theta}) &= \mathbb{V}(\tilde{\theta}) + [\mathbb{E}(\tilde{\theta}) - \theta]^2 = \mathbb{E}(\tilde{\theta}^2) - \mathbb{E}^2(\tilde{\theta}) + \left[\frac{n\theta}{n+1} - \theta \right]^2 \Rightarrow \\ ECM(\tilde{\theta}) &= \int_0^\theta t^2 \frac{nt^{n-1}}{\theta^n} dt - \left(\frac{n\theta}{n+1} \right)^2 + \left(\frac{\theta}{n+1} \right)^2 = \frac{n}{n+2} \theta^2 - \left(\frac{n\theta}{n+1} \right)^2 + \left(\frac{\theta}{n+1} \right)^2 \Rightarrow \\ ECM(\tilde{\theta}) &= \theta^2 \frac{n(n+1)^2 - n(n+2) + n+2}{(n+2)(n+1)^2} = \theta^2 \frac{2}{(n+1)(n+2)} \end{aligned}$$

Para decidir con cuál nos quedaríamos, planteamos

$$ECM(\hat{\theta}) \leq ECM(\tilde{\theta}) \Leftrightarrow \frac{\theta^2}{3n} \leq \theta^2 \frac{2}{(n+1)(n+2)} \Leftrightarrow (n+1)(n+2) \leq 6n \Leftrightarrow n \leq 2$$

es decir que cuantos más datos se tengan, $ECM(\tilde{\theta}) \leq ECM(\hat{\theta})$ y, por lo tanto, se preferirá el estimador de máxima verosimilitud.

c) Para que el estimador de máxima verosimilitud bastaría con definir $\tilde{\theta}_n^{\text{mod}} = \frac{n+1}{n} \tilde{\theta}$.

4. Un estimador δ se dice **inadmisible** para una cierta función de riesgo $R(\delta, \theta)$ si existe otro estimador δ^* tal que $R(\delta, \theta) \geq R(\delta^*, \theta)$ para todo $\theta \in \Theta$ y $R(\delta, \theta) > R(\delta^*, \theta)$ para algún $\theta \in \Theta$. Un estimador es **admissible** si no es inadmissible.

a) Probar que los estimadores Bayes (respecto a la pérdida cuadrática) son admisibles para el ECM, o sea, para el riesgo $R(\delta, \theta) = \mathbb{E}[(\delta(\mathbf{X}) - \theta)^2]$.

b) Consideremos el riesgo cuadrático pesado, o sea $R(\delta, \theta) = \mathbb{E}[w(\theta)(\delta(\mathbf{X}) - \theta)^2]$ con w una función positiva. Sea $X_1, \dots, X_n$ una muestra aleatoria con $\mathbb{E}[X_1] = \mu$ y $\mathbb{V}(X_1) = \sigma^2 < \infty$.

1) Probar que los estimadores de la forma $a\bar{X} + b$ con $a > 1$ son inadmisibles respecto a esta función de riesgo.

2) Probar que los estimadores de la forma $\bar{X} + b$ con $b \neq 0$ son inadmisibles respecto a esta función de riesgo.

5. Sea $X_1, \dots, X_n$ una m.a. de una distribución tal que existe $\mathbb{E}(X_1) = \mu$. Consideremos la clase de estimadores

$$\mathcal{D} = \left\{ \delta(\mathbf{X}) = \sum_{i=1}^n \alpha_i X_i : \alpha_i \in \mathbb{R}, \sum_{i=1}^n \alpha_i = 1 \right\}.$$

a) Probar que todo $\delta \in \mathcal{D}$ es un estimador insesgado de μ .

b) Supongamos que existe $V(X) = \sigma^2$. Mostrar que $\bar{X} = \underset{\delta \in \mathcal{D}}{\operatorname{argmin}} V(\delta)$.

Solución:

a) Sea $\delta \in \mathcal{D}$, entonces

$$\mathbb{E}_\mu(\delta(\mathbf{X})) = \mathbb{E} \left(\sum_{i=1}^n \alpha_i X_i \right) = \sum_{i=1}^n \alpha_i \underbrace{\mathbb{E}(X_i)}_{=\mu} = \mu \sum_{i=1}^n \alpha_i = \mu$$

es decir, que resulta insesgado.

b) como el estimador es insesgado,

$$\mathbb{V}(\delta(\mathbf{X})) = \mathbb{E}[(\delta(\mathbf{X}) - \mu)^2] = \mathbb{E}[\delta^2(\mathbf{X}) - 2\delta(\mathbf{X})\mu + \mu^2] = \mathbb{E}[\delta^2(\mathbf{X})] - 2\mu \underbrace{\mathbb{E}(\delta(\mathbf{X}))}_{=\mu} + \mu^2 \Rightarrow$$

$$\mathbb{V}(\delta(\mathbf{X})) = \mathbb{E}[\delta^2(\mathbf{X})] - \mu^2$$

6. (Para hacer con R) Volvemos a los estimadores James-Stein de la práctica anterior. Vamos a comparar los estimadores Bayes y EMV para $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)$. Para cada uno de los valores $n = 6, 10, 20, 40, 80, 200$ hacer lo siguiente:

- Generar los $\mu_1, \dots, \mu_n$ independientemente a partir de una distribución $N(2, 4)$ y a partir de esto obtener $X_1, \dots, X_n$ donde $X_i | \mu_i \sim N(\mu_i, 1)$.
- Estimar μ con el método de máxima verosimilitud y con el estimador de James-Stein.
- Para cada estimador, obtener

$$e = \frac{1}{n} \sum_{i=1}^n (\hat{\mu}_i - \mu_i)^2.$$

- Replicar los últimos 3 pasos $m = 1000$ veces, obteniendo para cada estimador los errores $e_1, \dots, e_m$. Estimar el ECM para cada uno de los dos estimadores promediando estas m replicaciones.
- Graficar (en un único gráfico) n vs. el estimador del ECM obtenido en el ítem anterior para cada método.

1.11.5. Consistencia y distribución asintótica

- Sea δ_n un estimador de $q(\theta)$. Probar que si $\text{ECM}_\theta(\delta_n) \rightarrow 0$, entonces δ_n es débilmente consistente.
 - Sea $X_1, \dots, X_n$ una m.a. tal que $E_\theta(X) = \theta$ y $V_\theta(X) < \infty$. Consideremos el siguiente estimador aleatorizado de θ :

$$\delta_n = (1 - \varepsilon_n) \bar{X} + \varepsilon_n n$$

donde $\varepsilon_n \sim Bi(1, 1/n)$ y es independiente de las X_i . Probar que δ_n es débilmente consistente, aunque $\text{ECM}_\theta(\delta_n) \rightarrow \infty$.

Solución:

- Queremos ver que para todo $\varepsilon > 0$ se tiene que $\mathbb{P}(|\delta_n - q(\theta)| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0$.

$$\mathbb{P}(|\delta_n - q(\theta)| > \varepsilon) \underset{\text{Markov}}{\leq} \frac{\mathbb{E}[(\delta_n - q(\theta))^2]}{\varepsilon^2} = \frac{\text{ECM}_\theta(\delta_n)}{\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

- como en el inciso anterior queremos ver que para todo $\varepsilon > 0$ se tiene que

$$\mathbb{P}(|\delta_n - \theta| > \varepsilon) = \mathbb{P}[(1 - \varepsilon_n) \bar{X}_n + \varepsilon_n n - \theta > \varepsilon] \xrightarrow{n \rightarrow \infty} 0$$

entonces,

$$\begin{aligned} & \mathbb{P}[(1 - \varepsilon_n) \bar{X}_n + \varepsilon_n n - \theta > \varepsilon] = \\ &= \mathbb{P}[(1 - \varepsilon_n) \bar{X}_n + \varepsilon_n n - \theta > \varepsilon | \varepsilon_n = 0] \mathbb{P}(\varepsilon_n = 0) + \mathbb{P}[(1 - \varepsilon_n) \bar{X}_n + \varepsilon_n n - \theta > \varepsilon | \varepsilon_n = 1] \mathbb{P}(\varepsilon_n = 1) \\ &\Rightarrow \mathbb{P}[(1 - \varepsilon_n) \bar{X}_n + \varepsilon_n n - \theta > \varepsilon] = \mathbb{P}(|\bar{X}_n - \theta| > \varepsilon) \left(1 - \frac{1}{n}\right) + \mathbb{P}(|n - \theta| > \varepsilon) \frac{1}{n} \end{aligned}$$

Por la Ley Fuerte de los Grandes Números sabemos que $\bar{X}_n \xrightarrow[n \rightarrow \infty]{p} \theta$, por lo tanto,

$$\mathbb{P}(|\bar{X}_n - \theta| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0 \Rightarrow \mathbb{P}(|\bar{X}_n - \theta| > \varepsilon) \left(1 - \frac{1}{n}\right) \xrightarrow{n \rightarrow \infty} 0$$

por otra parte, como $\mathbb{P}(|n - \theta| > \varepsilon) \leq 1$ por una probabilidad. Luego,

$$\mathbb{P}(|n - \theta| > \varepsilon) \frac{1}{n} \xrightarrow{n \rightarrow \infty} 0$$

Es decir,

$$\mathbb{P}[(1 - \varepsilon_n) \bar{X}_n + \varepsilon_n n - \theta > \varepsilon] \xrightarrow{n \rightarrow \infty} 0.$$

Por último, sólo nos hace falta ver que $\text{ECM}_\theta(\delta_n) \rightarrow \infty$,

$$\text{ECM}_\theta(\delta_n) = \mathbb{E}[(\delta_n - \theta)^2] = \mathbb{E}[\delta_n^2 - 2\delta_n\theta + \theta^2] = \mathbb{E}[(1 - \varepsilon_n) \bar{X}_n + \varepsilon_n n]^2 - 2\theta\mathbb{E}(\delta_n) + \theta^2 \Rightarrow$$

$$\text{ECM}_\theta(\delta_n) = \mathbb{E}[(1 - \varepsilon_n)^2 \bar{X}_n^2] + \mathbb{E}(2(1 - \varepsilon_n) \bar{X}_n \varepsilon_n n) + n\mathbb{E}(\varepsilon_n^2) - 2\theta\mathbb{E}(\delta_n) + \theta^2 \Rightarrow$$

$$\text{ECM}_\theta(\delta_n) = \mathbb{E}[(1 - \varepsilon_n)^2 \bar{X}_n^2] + 2\mathbb{E}(\bar{X}_n \varepsilon_n n) - 2\mathbb{E}(\varepsilon_n^2 \bar{X}_n n) + n^2\mathbb{E}(\varepsilon_n^2) - 2\theta\mathbb{E}(\delta_n) + \theta^2$$

Por hipótesis, sabemos que

- $\varepsilon_n \sim Bi(1, 1/n)$, entonces $\varepsilon_n^2 \sim \varepsilon_n$ y $(1 - \varepsilon_n)^2 \sim (1 - \varepsilon_n)$

(ii) ε_n es independiente de las X_i .

luego,

$$ECM_\theta(\delta_n) = \mathbb{E}[(1 - \varepsilon_n)^2] \mathbb{E}(\overline{X_n}^2) + 2n\mathbb{E}(\overline{X_n})\mathbb{E}(\varepsilon_n) - 2n\mathbb{E}(\overline{X_n})\mathbb{E}(\varepsilon_n) + n^2\mathbb{E}(\varepsilon_n) - 2\theta\mathbb{E}(\delta_n) + \theta^2 \Rightarrow$$

$$ECM_\theta(\delta_n) = \left(1 - \frac{1}{n}\right) (\mathbb{V}(\overline{X_n}) + \mathbb{E}^2(\overline{X_n})) + 2n\frac{1}{n}\theta + n^2\frac{1}{n} - 2\theta [\mathbb{E}(1 - \varepsilon_n)\mathbb{E}(\overline{X_n}) + n\mathbb{E}(\varepsilon_n)] + \theta^2 \Rightarrow$$

$$ECM_\theta(\delta_n) = \left(1 - \frac{1}{n}\right) \left(\frac{1}{n}\mathbb{V}(X_1) + \theta^2\right) + 2\theta + n - 2\theta^2 \left(1 - \frac{1}{n}\right) - 2n\theta\frac{1}{n} + \theta^2$$

Es decir,

$$ECM_\theta(\delta_n) = \underbrace{\left(1 - \frac{1}{n}\right) \left(\frac{1}{n}\mathbb{V}(X_1) + \theta^2\right)}_{\xrightarrow{n \rightarrow \infty} \theta^2} + \underbrace{n - 2\theta^2 \left(1 - \frac{1}{n}\right)}_{\xrightarrow{n \rightarrow \infty} 2\theta^2} + \theta^2 \xrightarrow{n \rightarrow \infty} \infty$$

2. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución $\mathcal{E}(\theta)$. Probar que el EMV de θ es fuertemente consistente y hallar su distribución asintótica.

Solución: Sabemos que $\tilde{\theta}_{EMV} = \frac{n}{\sum X_i}$ y ahora queremos ver que $\tilde{\theta}_{EMV} \xrightarrow[n \rightarrow \infty]{c.s.} \theta$.

Por la Ley Fuerte de los Grandes Números se sabe que $\overline{X_n} \xrightarrow[n \rightarrow \infty]{c.s.} \frac{1}{\theta}$ y como $\mathbb{P}(1/\theta = 0) = 0$ se tiene que

$$\frac{1}{\overline{X_n}} \xrightarrow[n \rightarrow \infty]{c.s.} \frac{1}{1/\theta} = \theta \Rightarrow \frac{n}{\sum X_i} \xrightarrow[n \rightarrow \infty]{c.s.} \theta \Rightarrow \tilde{\theta}_{EMV} \xrightarrow[n \rightarrow \infty]{c.s.} \theta$$

es decir, que el estimador $\tilde{\theta}_{EMV}$ es fuertemente consistente.

Para encontrar su distribución asintótica, usaremos el Teorema Central del Límite recordando que $\mathbb{E}(X_1) = \frac{1}{\theta}$ y $\mathbb{V}(X_1) = \frac{1}{\theta^2}$,

$$\frac{\sqrt{n}(\overline{X_n} - \frac{1}{\theta})}{1/\theta} \xrightarrow[n \rightarrow \infty]{D} N(0, 1) \Leftrightarrow \sqrt{n}\left(\overline{X_n} - \frac{1}{\theta}\right) \xrightarrow[n \rightarrow \infty]{D} N(0, 1/\theta^2)$$

por otra parte, sea $g: \mathbb{R} \rightarrow \mathbb{R}$ derivable en θ definida como $g(x) = 1/x$ tal que $g'(\theta) \neq 0$, entonces

$$\sqrt{n}\left(g(\overline{X_n}) - g\left(\frac{1}{\theta}\right)\right) \xrightarrow[n \rightarrow \infty]{D} g'(\theta)N\left(0, \frac{1}{\theta^2}\right) \Rightarrow \sqrt{n}\left(\frac{n}{\sum X_i} - \theta\right) \xrightarrow[n \rightarrow \infty]{D} (-\theta^2)N\left(0, \frac{1}{\theta^2}\right) = N(0, \theta^2)$$

es decir que la distribución asintótica para $\tilde{\theta}_{EMV}$ es una $N(0, \theta^2)$.

3. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución $\mathcal{P}(\lambda)$. Consideremos $\delta_n = \overline{X_n}$ y

$$\delta_n^* = -\frac{1}{2} + \sqrt{\frac{1}{4} + \frac{1}{n} \sum_{i=1}^n X_i^2}$$

a) Analizar si estos estimadores de λ son fuertemente consistentes.

b) Hallar sus distribuciones asintóticas. Decir si alguno de los dos es asintóticamente eficiente.

(NOTA: $\mathbb{E}(X^4) = \lambda^4 + 6\lambda^3 + 7\lambda^2 + \lambda$)

Solución:

a) Por la Ley Fuerte de los Grandes Números sabemos que $\overline{X_n} \xrightarrow[n \rightarrow \infty]{c.s.} \mathbb{E}(X_i) = \lambda$, entonces $\delta_n \xrightarrow[n \rightarrow \infty]{c.s.} \lambda$ y, por lo tanto, resulta ser fuertemente consistente.

b) Por el Teorema Central del Límite sabemos que

$$\sqrt{n} \frac{\overline{X_n} - \lambda}{\sqrt{\lambda}} \xrightarrow[n \rightarrow \infty]{D} N(0, 1) \Rightarrow \sqrt{n}(\overline{X_n} - \lambda) \xrightarrow[n \rightarrow \infty]{D} N(0, \lambda)$$

para saber la distribución asintótica de δ_n^* veamos cuál es la esperanza y varianza de $\sum_{i=1}^n X_i^2$.

$$\mathbb{E}(X_1^2) = \mathbb{V}(X_1) + \mathbb{E}^2(X_1) = \lambda + \lambda^2$$

$$\mathbb{V}(X_1^2) = \mathbb{E}(X_1^4) - \mathbb{E}^2(X_1^2) = \lambda^4 + 6\lambda^3 + 7\lambda^2 + \lambda - (\lambda^2 + 2\lambda^3 + \lambda^4) = 4\lambda^3 + 6\lambda^2 + \lambda$$

luego, por el Teorema Central del Límite,

$$\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n X_i^2 - (\lambda + \lambda^2) \right) \xrightarrow[n \rightarrow \infty]{D} N(0, 4\lambda^3 + 6\lambda^2 + \lambda)$$

Sea $g: \mathbb{R} \rightarrow \mathbb{R}$ continua y derivable definida como $g(x) = -\frac{1}{2} + \sqrt{\frac{1}{4} + x}$. Notemos que $g(\lambda + \lambda^2) = \lambda$

$$\sqrt{n}(\delta_n^* - \lambda) = \sqrt{n} \left[g \left(\frac{1}{n} \sum_{i=1}^n X_i^2 \right) - g(\lambda + \lambda^2) \right] \xrightarrow[n \rightarrow \infty]{D} g'(\lambda + \lambda^2) N(0, 4\lambda^3 + 6\lambda^2 + \lambda)$$

4. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución $U(0, \theta)$.

- (Para hacer con el R) Hacer histogramas para los valores $\theta_1^*, \dots, \theta_1^*$ para cada n y cada uno de los tres estimadores del ejercicio A.3 de esta práctica. ¿A qué familia intuye que pertenecen las distribuciones asintóticas de dichos estimadores?
- Probar que el EMV de θ es débilmente y fuertemente consistente y hallar su distribución asintótica.
- Probar que el estimador de momentos para θ es fuertemente consistente y hallar su distribución asintótica.
- ¿Cuál de estos dos estimadores preferiría? ¿Por qué?

Solución:

- b) Recordemos que $\tilde{\theta}_{EMV} = \max_{1 \leq i \leq n} X_i$. Para ver que es fuertemente consistente usaremos Borel-Cantelli, por lo tanto, queremos ver que $\sum_{n \in \mathbb{N}} \mathbb{P}(|\tilde{\theta}_{EMV} - \theta| > \varepsilon) < \infty$

$$\mathbb{P}(|\tilde{\theta}_{EMV} - \theta| > \varepsilon) = \mathbb{P}\left(\left|\max_{1 \leq i \leq n} X_i - \theta\right| > \varepsilon\right) = \mathbb{P}\left(\theta - \max_{1 \leq i \leq n} X_i > \varepsilon\right), \text{ pues } X_i \leq \theta \quad \forall i \in \{1, \dots, n\}$$

luego,

$$\mathbb{P}(|\tilde{\theta}_{EMV} - \theta| > \varepsilon) = \mathbb{P}\left(\max_{1 \leq i \leq n} X_i < \theta - \varepsilon\right) = [\mathbb{P}(X_1 < \theta - \varepsilon)]^n = \left(\frac{\theta - \varepsilon}{\theta}\right)^n$$

por lo tanto, como $\frac{\theta - \varepsilon}{\theta} < 1$

$$\sum_{n \in \mathbb{N}} \mathbb{P}(|\tilde{\theta}_{EMV} - \theta| > \varepsilon) = \underbrace{\sum_{n \in \mathbb{N}} \left(\frac{\theta - \varepsilon}{\theta}\right)^n}_{\text{serie geométrica}} < \infty$$

Entonces, por Borel-Cantelli, $\tilde{\theta}_{EMV} \xrightarrow[n \rightarrow \infty]{c.s.} \theta \Rightarrow \tilde{\theta}_{EMV} \xrightarrow[n \rightarrow \infty]{p} \theta$.

Para hallar su distribución asintótica,

$$\begin{aligned} \mathbb{P}\left(n^\alpha \left(\theta - \max_{1 \leq i \leq n} X_i\right) \leq t\right) &= \mathbb{P}\left(-\max_{1 \leq i \leq n} X_i \leq \frac{t}{n^\alpha} - \theta\right) = 1 - \mathbb{P}\left(\max_{1 \leq i \leq n} X_i \leq \theta - \frac{t}{n^\alpha}\right) \Rightarrow \\ \mathbb{P}\left(n^\alpha \left(\theta - \max_{1 \leq i \leq n} X_i\right) \leq t\right) &= 1 - \left[\mathbb{P}\left(X_1 \leq \theta - \frac{t}{n^\alpha}\right)\right]^n = 1 - \left(\frac{\theta - t/n^\alpha}{\theta}\right)^n = 1 - \left(1 - \frac{t}{n^\alpha \theta}\right)^n \end{aligned}$$

y vemos que

$$\lim_{n \rightarrow \infty} \left(1 - \frac{t}{n^\alpha \theta}\right)^n = \lim_{n \rightarrow \infty} \underbrace{\left(1 - \frac{t}{n^\alpha \theta}\right)^{-\frac{n^\alpha \theta}{t}}}_{\xrightarrow[n \rightarrow \infty]{e}}^{\underbrace{-n \frac{t}{n^\alpha \theta}}_{\xrightarrow[n \rightarrow \infty]{\alpha=1} -\frac{t}{\theta}}} = e^{-t/\theta}, \text{ si } \alpha = 1.$$

luego,

$$\mathbb{P}\left(n^\alpha \left(\theta - \max_{1 \leq i \leq n} X_i\right) \leq t\right) = 1 - \left(1 - \frac{t}{n^\alpha \theta}\right)^n = \begin{cases} 0 & t \leq 0 \\ 1 - e^{-t/\theta} & t > 0 \end{cases}$$

Es decir, $n \left(\theta - \max_{1 \leq i \leq n} X_i\right) \xrightarrow[n \rightarrow \infty]{D} \mathcal{E}(1/\theta)$, entonces $n \left(\max_{1 \leq i \leq n} X_i - \theta\right) \xrightarrow[n \rightarrow \infty]{D} -\mathcal{E}(1/\theta)$.

- c) Queremos ver que $2\overline{X}_n \xrightarrow[n \rightarrow \infty]{c.s.} \theta$. Por la Ley Fuerte de los Grandes Números se sabe que $\overline{X}_n \xrightarrow[n \rightarrow \infty]{c.s.} \frac{\theta}{2}$ y por Slutsky $2 \xrightarrow[n \rightarrow \infty]{c.s.} 2$, entonces

$$2\overline{X}_n \xrightarrow[n \rightarrow \infty]{c.s.} 2 \frac{\theta}{2} = \theta.$$

Para ver su distribución asintótica, por el Teorema Central del Límite

$$\sqrt{n} \left(\overline{X}_n - \frac{\theta}{2} \right) \xrightarrow[n \rightarrow \infty]{D} N \left(0, \frac{\theta^2}{12} \right)$$

y sea $g : \mathbb{R} \rightarrow \mathbb{R}$ derivable definida como $g(x) = 2x$, entonces

$$\begin{aligned} \sqrt{n} \left(g(\overline{X}_n) - g\left(\frac{\theta}{2}\right) \right) &\xrightarrow[n \rightarrow \infty]{D} g'(\theta) N \left(0, \frac{\theta^2}{12} \right) \Rightarrow \\ \sqrt{n} (2\overline{X}_n - \theta) &\xrightarrow[n \rightarrow \infty]{D} 2N \left(0, \frac{\theta^2}{12} \right) \end{aligned}$$

- d) Deberíamos preferir el $\hat{\theta}_{EMV}$ puesto que tiene mayor tasa de convergencia con $\alpha = 1$.

5. Sea $X_1, \dots, X_n$ una m.a. de una distribución exponencial desplazada, cuya densidad es

$$f(x) = e^{-(x-\theta)} I_{[\theta, \infty)}(x).$$

- a) Probar que el EMV de θ es débilmente y fuertemente consistente y hallar su distribución asintótica.
b) Probar que el estimador de momentos para θ es consistente y hallar su distribución asintótica.
c) ¿Cuál de estos dos estimadores preferiría? ¿Por qué?

Solución:

- a) Sabemos que $\hat{\theta}_{EMV} = \min_{1 \leq i \leq n} X_i$. Para ver que es fuertemente consistente usaremos Borel-Cantelli, por lo tanto, queremos ver que $\sum_{n \in \mathbb{N}} \mathbb{P}(|\tilde{\theta}_{EMV} - \theta| > \varepsilon) < \infty$

$$\mathbb{P}(|\tilde{\theta}_{EMV} - \theta| > \varepsilon) = \mathbb{P}\left(\left|\min_{1 \leq i \leq n} X_i - \theta\right| > \varepsilon\right) = \mathbb{P}\left(\min_{1 \leq i \leq n} X_i - \theta > \varepsilon\right), \text{ pues } \theta \leq X_i \quad \forall i \in \{1, \dots, n\}$$

luego,

$$\mathbb{P}(|\tilde{\theta}_{EMV} - \theta| > \varepsilon) = \mathbb{P}\left(\min_{1 \leq i \leq n} X_i > \varepsilon + \theta\right) = [\mathbb{P}(X_1 > \varepsilon + \theta)]^n = [1 - \mathbb{P}(X_1 \leq \varepsilon + \theta)]^n$$

Además,

$$1 - \mathbb{P}(X_1 \leq \varepsilon + \theta) = 1 - \int_{\theta}^{\theta + \varepsilon} e^{-(x-\theta)} dx = 1 + (e^{-\varepsilon} - 1) = e^{-\varepsilon} < 1$$

por lo tanto,

$$\mathbb{P}(|\tilde{\theta}_{EMV} - \theta| > \varepsilon) = (e^{-\varepsilon})^n \Rightarrow \sum_{n \in \mathbb{N}} \mathbb{P}(|\tilde{\theta}_{EMV} - \theta| > \varepsilon) = \underbrace{\sum_{n \in \mathbb{N}} (e^{-\varepsilon})^n}_{\text{serie geométrica}} < \infty$$

Entonces, por Borel-Cantelli, $\tilde{\theta}_{EMV} \xrightarrow[n \rightarrow \infty]{c.s.} \theta \Rightarrow \tilde{\theta}_{EMV} \xrightarrow[n \rightarrow \infty]{p} \theta$.

Para hallar su distribución asintótica,

$$\begin{aligned} \mathbb{P}\left(n^\alpha \left(\min_{1 \leq i \leq n} X_i - \theta\right) \leq t\right) &= \mathbb{P}\left(\min_{1 \leq i \leq n} X_i \leq \frac{t}{n^\alpha} + \theta\right) = 1 - \mathbb{P}\left(\min_{1 \leq i \leq n} X_i \geq \frac{t}{n^\alpha} + \theta\right) \Rightarrow \\ \mathbb{P}\left(n^\alpha \left(\min_{1 \leq i \leq n} X_i - \theta\right) \leq t\right) &= 1 - \left[\mathbb{P}\left(X_1 \geq \frac{t}{n^\alpha} + \theta\right)\right]^n = 1 - \left[1 - \mathbb{P}\left(X_1 \leq \frac{t}{n^\alpha} + \theta\right)\right]^n \Rightarrow \\ \mathbb{P}\left(n^\alpha \left(\min_{1 \leq i \leq n} X_i - \theta\right) \leq t\right) &= \begin{cases} 1 - (e^{t/n^\alpha})^n & t > 0 \\ 0 & t \leq 0 \end{cases} \Rightarrow \text{si } \alpha = 1, \mathbb{P}\left(n^\alpha \left(\min_{1 \leq i \leq n} X_i - \theta\right) \leq t\right) = 1 - e^{-t} \end{aligned}$$

$$\text{Es decir, } n \left(\min_{1 \leq i \leq n} X_i - \theta\right) \xrightarrow[n \rightarrow \infty]{D} \mathcal{E}(1).$$

- b) Queremos ver que $\overline{X}_n - 1 \xrightarrow[n \rightarrow \infty]{c.s.} \theta$. Por la Ley Fuerte de los Grandes Números, sabemos que $\overline{X}_n \xrightarrow[n \rightarrow \infty]{c.s.} \theta + 1$ y por Slutsky, sabemos que $\overline{X}_n - 1 \xrightarrow[n \rightarrow \infty]{c.s.} \theta + 1 - 1$. Entonces,

$$\tilde{\theta}_{EMM} = \overline{X}_n - 1 \xrightarrow[n \rightarrow \infty]{c.s.} \theta.$$

Para ver su distribución asintótica, por el Teorema Central del Límite

$$\sqrt{n}(\overline{X}_n - \theta) \xrightarrow[n \rightarrow \infty]{D} N\left(0, \frac{\theta^2}{12}\right)$$

y sea $g: \mathbb{R} \rightarrow \mathbb{R}$ derivable definida como $g(x) = 2x$, entonces

$$\sqrt{n}\left(g(\overline{X}_n) - g\left(\frac{\theta}{2}\right)\right) \xrightarrow[n \rightarrow \infty]{D} g'(\theta)N\left(0, \frac{\theta^2}{12}\right) \Rightarrow$$

$$\sqrt{n}(2\overline{X}_n - \theta) \xrightarrow[n \rightarrow \infty]{D} 2N\left(0, \frac{\theta^2}{12}\right)$$

- c) Deberíamos preferir el $\hat{\theta}_{EMV}$ puesto que tiene mayor tasa de convergencia con $\alpha = 1$.

6. Sea $X_1, \dots, X_n$ una m.a. de una distribución $F_\theta(x - \theta)$ con F_θ una función de distribución fija y $\theta \in \mathbb{R}$. Sea δ_n un estimador de θ equivariante por traslaciones (i.e.: para cualquier constante $c \in \mathbb{R}$ se verifica que $\delta_n(x_1 + c, \dots, x_n + c) = \delta_n(x_1, \dots, x_n) + c$).

- a) Mostrar que $\delta_n - \theta$ tiene una distribución que no depende de θ .
 b) Deducir que la varianza asintótica de δ_n (si existe) no depende de θ .

Solución:

- a) $\delta_n(X_1, \dots, X_n) - \theta = \delta_n(X_1 - \theta, \dots, X_n - \theta)$, por lo tanto, basta con ver que cada $Y_i = X_i - \theta$ tiene una distribución que no depende de θ , es decir, para cada $i \in \{1, \dots, n\}$

$$\mathbb{P}(Y_i \leq t) = \mathbb{P}(X_i - \theta \leq t) = \mathbb{P}(X_i \leq t + \theta) = F_\theta(t + \theta - \theta) = F_\theta(t) \rightarrow \text{no depende de } \theta.$$

- b) Asumiendo que la varianza existe como la distribución no depende de θ deducimos que su varianza tampoco.

7. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución F con densidad $f(x - \mu)$ donde $f(x)$ satisface:

- (i) $f(x) = f(-x)$,
 ii) $f(x)$ continua en $x = 0$.

Probar que,

- a) Sea $Z_{a,i} = \mathbb{1}\{X_i \leq a\}$. Mostrar que $Z_{a,i}$ tiene distribución $Bi(1, F(a))$.
 b) Sea $Z_a = \sum Z_{a,i}$. Mostrar que Z_a tiene distribución $Bi(n, F(a))$.
 c) Probar que $\mathbb{P}(Z_a \geq \lfloor \frac{n}{2} \rfloor + 1) \leq \mathbb{P}(\text{mediana}(X_1, \dots, X_n) \leq a) \leq \mathbb{P}(Z_a \geq \lfloor \frac{n}{2} \rfloor)$
 d) Mostrar que $\text{mediana}(X_1, \dots, X_n)$ es un estimador débilmente consistente de μ .

1.11.6. Estadísticos Suficientes

1. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución $\mathcal{P}(\lambda)$. Demostrar que $T = \sum_{i=1}^n X_i$ es un estadístico suficiente para λ :

- a) Aplicando la definición.
 b) Aplicando el Teorema de Factorización.

Solución:

(a) por definición,

$$p\left(X_1 = k_1, \dots, X_n = k_n \left| \sum_{i=1}^n X_i = t \right.\right) = \frac{p\left(X_1 = k_1, \dots, X_n = t - \sum_{i=1}^{n-1} k_i\right)}{p\left(\sum_{i=1}^n X_i = t\right)}$$

y puesto que $X_1, \dots, X_n$ es una muestra aleatoria,

$$p\left(X_1 = k_1, \dots, X_n = k_n \left| \sum_{i=1}^n X_i = t \right.\right) = \frac{\lambda^{k_1} e^{-\lambda}}{k_1!} \cdots \frac{\lambda^{t - \sum k_i} e^{-\lambda}}{(t - \sum k_i)!} \frac{t!}{(\lambda n)^t e^{n\lambda}} = \frac{t!}{n^t k_1! k_2! \cdots (t - \sum k_i)!}$$

que no depende de λ .

(b)

$$p(x_1, \dots, x_n, \lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} \mathbb{1}_{\mathbb{N}}(x_i) = \underbrace{e^{-n\lambda} \lambda^{\sum x_i}}_{g(T, \lambda)} \underbrace{\prod_{i=1}^n \frac{\mathbb{1}_{\mathbb{N}}(x_i)}{x_i!}}_{h(x_1, \dots, x_n)}$$

luego, por el Teorema de Factorización $T = \sum_{i=1}^n X_i$ es un estadístico suficiente para λ .

2. Sean $X_1, \dots, X_n$ variables aleatorias independientes. Probar que:

a) Si $X_i \sim Bi(n_i, p)$, $1 \leq i \leq n$, con n_i conocidos, entonces $\sum_{i=1}^n X_i$ es suficiente para p .

b) Si $X_i \sim \Gamma(\alpha, \lambda)$ entonces $\left(\prod_{i=1}^n X_i, \sum_{i=1}^n X_i\right)$ es suficiente para (α, λ) .

Si α es conocido, entonces $\sum_{i=1}^n X_i$ es suficiente para λ .

Si λ es conocido, entonces $\prod_{i=1}^n X_i$ es suficiente para α .

c) Si $X_i \sim \beta(r, s)$ entonces $\left(\prod_{i=1}^n X_i, \prod_{i=1}^n (1 - X_i)\right)$ es suficiente para (r, s) .

Si r es conocido, entonces $\prod_{i=1}^n (1 - X_i)$ es suficiente para s .

Si s es conocido, entonces $\prod_{i=1}^n X_i$ es suficiente para r .

d) Si X_i tiene función de probabilidad puntual

$$f(x; \theta, p) = (1 - p) p^{x - \theta} \text{ para } x = \theta, \theta + 1, \theta + 2, \dots$$

con $(\theta, p) \in \mathbb{R} \times (0, 1)$ entonces $\left(X_{(1)}, \sum_{i=1}^n X_i\right)$ es suficiente para (θ, p) .

Si p es conocido, entonces $X_{(1)}$ es suficiente para θ .

Si θ es conocido, entonces $\sum_{i=1}^n X_i$ es suficiente para p .

Solución:

(a)

$$p(x_1, \dots, x_n, p) = \prod_{i=1}^n p_{X_i}(x_i, p) = \prod_{i=1}^n \binom{n_i}{x_i} p^{x_i} (1 - p)^{n_i - x_i} \mathbb{1}_{\mathbb{N}}(x_i) = p^{\sum x_i} (1 - p)^{\sum (n_i - x_i)} \prod_{i=1}^n \binom{n_i}{x_i} \mathbb{1}_{\mathbb{N}}(x_i).$$

Luego, por el Teorema de Factorización con

$$T = \sum_{i=1}^n X_i, \quad g(T, p) = p^T (1 - p)^{\sum n_i - T} \text{ y } h(x_1, \dots, x_n) = \prod_{i=1}^n \binom{n_i}{x_i} \mathbb{1}_{\mathbb{N}}(x_i)$$

se tiene que T es un estadístico suficiente para p .

(b)

$$p(x_1, \dots, x_n, (\alpha, \lambda)) = \prod_{i=1}^n \frac{\lambda^\alpha}{\Gamma(\alpha)} x_i^{\alpha-1} e^{-\lambda x_i} \mathbb{1}_{(0,+\infty)}(x_i) = \underbrace{\left(\frac{\lambda^\alpha}{\Gamma(\alpha)} \right)^n \left(\prod_{i=1}^n x_i \right)^{\alpha-1}}_{g((\prod X_i, \sum X_i), (\alpha, \lambda))} \underbrace{\exp \left\{ -\lambda \sum_{i=1}^n x_i \right\} \prod_{i=1}^n \mathbb{1}_{(0,+\infty)}(x_i)}_{h(x_1, \dots, x_n)}$$

Luego, por el Teorema de Factorización $\left(\prod_{i=1}^n X_i, \sum_{i=1}^n X_i \right)$ es suficiente para (α, λ) .

si α es conocido:

$$p(x_1, \dots, x_n, \alpha) = \underbrace{\lambda^{n\alpha} \exp \left\{ -\lambda \sum_{i=1}^n x_i \right\}}_{g(\sum x_i, \lambda)} \underbrace{\frac{1}{\Gamma^n(\alpha)} \left(\prod_{i=1}^n x_i \right)^{\alpha-1} \prod_{i=1}^n \mathbb{1}_{(0,+\infty)}(x_i)}_{h(x_1, \dots, x_n)}$$

Luego, por el Teorema de Factorización $\sum_{i=1}^n X_i$ es suficiente para λ .

si λ es conocido:

$$p(x_1, \dots, x_n, \lambda) = \underbrace{\frac{\lambda^{n\alpha}}{\Gamma^n(\alpha)} \left(\prod_{i=1}^n x_i \right)^{\alpha-1}}_{g(\prod x_i, \lambda)} \underbrace{\prod_{i=1}^n e^{-\lambda x_i} \mathbb{1}_{(0,+\infty)}(x_i)}_{h(x_1, \dots, x_n)}$$

Luego, por el Teorema de Factorización $\prod_{i=1}^n X_i$ es suficiente para α .

(c)

$$p(x_1, \dots, x_n, (r, s)) = \prod_{i=1}^n \frac{\Gamma(r+s)}{\Gamma(r)\Gamma(s)} x_i^{r-1} (1-x_i)^{s-1} \mathbb{1}_{(0,1)}(x_i) \Rightarrow$$

$$p(x_1, \dots, x_n, (r, s)) = \underbrace{\left(\prod_{i=1}^n x_i \right)^{r-1} \left(\prod_{i=1}^n (1-x_i) \right)^{s-1}}_{g((\prod X_i, \prod(1-X_i)), (r, s))} \underbrace{\left(\frac{\Gamma(r+s)}{\Gamma(r)\Gamma(s)} \right)^n \prod_{i=1}^n \mathbb{1}_{(0,1)}(x_i)}_{h(x_1, \dots, x_n)}$$

Luego, por el Teorema de Factorización $\left(\prod_{i=1}^n X_i, \prod_{i=1}^n (1-X_i) \right)$ es suficiente para (r, s) .

si r es conocido:

$$p(x_1, \dots, x_n, s) = \underbrace{\left(\prod_{i=1}^n (1-x_i) \right)^{s-1} \left(\frac{\Gamma(r+s)}{\Gamma(s)} \right)^n}_{g(\prod(1-X_i), s)} \underbrace{\left(\prod_{i=1}^n x_i \right)^{r-1} \frac{1}{\Gamma^n(r)} \prod_{i=1}^n \mathbb{1}_{(0,1)}(x_i)}_{h(x_1, \dots, x_n)}$$

Luego, por el Teorema de Factorización $\prod_{i=1}^n (1-X_i)$ es suficiente para s .

si s es conocido:

$$p(x_1, \dots, x_n, r) = \underbrace{\left(\prod_{i=1}^n x_i \right)^{r-1} \left(\frac{\Gamma(r+s)}{\Gamma(r)} \right)^n}_{g(\prod x_i, r)} \underbrace{\left(\prod_{i=1}^n (1-x_i) \right)^{s-1} \frac{1}{\Gamma^n(s)} \prod_{i=1}^n \mathbb{1}_{(0,1)}(x_i)}_{h(x_1, \dots, x_n)}$$

Luego, por el Teorema de Factorización $\prod_{i=1}^n X_i$ es suficiente para r .

(d)

$$p(x_1, \dots, x_n, \theta, p) = \prod_{i=1}^n (1-p) p^{x_i-\theta} \mathbb{1}_{\mathbb{N}+\theta}(x_i)$$

Por otra parte,

$$1 = \prod_{i=1}^n \mathbb{1}_{\mathbb{N}+\theta}(x_i) = \prod_{i=1}^n \mathbb{1}_{\mathbb{N}}(x_i - \theta) \Leftrightarrow \forall i \in \mathbb{N} x_i - \theta \geq 0 \Leftrightarrow x_i \geq \theta \forall i \in \mathbb{N} \Leftrightarrow \min_{i \in \mathbb{N}} x_i \geq \theta \Leftrightarrow$$

$$\min_{i \in \mathbb{N}} x_i - \theta \geq 0 \text{ tal que } x_j - X_{(1)} \in \mathbb{N}$$

$$\text{Luego, } 1 = \prod_{i=1}^n \mathbb{1}_{\mathbb{N}}(x_i - \theta) \Leftrightarrow 1 = \mathbb{1}_{\mathbb{N}}\left(\min_{i \in \mathbb{N}} x_i - \theta\right) \prod_{i=1}^n \mathbb{1}_{\mathbb{N}}(x_j - X_{(1)}).$$

Volviendo a la cuenta original,

$$p(x_1, \dots, x_n, \theta, p) = (1-p)^n p^{n\theta - \sum x_i} \prod_{i=1}^n \mathbb{1}_{\mathbb{N}+\theta}(x_i) = (1-p)^n p^{-n\theta + \sum x_i} \mathbb{1}_{\mathbb{N}+\theta}\left(\min_{i \in \mathbb{N}} x_i\right) \prod_{i=1}^n \mathbb{1}_{\mathbb{N}}(x_j - X_{(1)})$$

Entonces,

$$p(x_1, \dots, x_n, \theta, p) = \underbrace{\left(\frac{1-p}{p^\theta}\right)^n p^{\sum x_i} \mathbb{1}_{(-\infty, X_{(1)})}(\theta)}_{g(X_{(1)}, \sum X_i, (\theta, p))} \underbrace{\prod_{i=1}^n \mathbb{1}_{\mathbb{N}}(x_j - X_{(1)})}_{h(x_1, \dots, x_n)}$$

si p es conocido:

$$p(x_1, \dots, x_n, \theta) = \underbrace{\left(\frac{1-p}{p^\theta}\right)^n \mathbb{1}_{(-\infty, X_{(1)})}(\theta)}_{g(X_{(1)}, \theta)} \underbrace{p^{\sum x_i} \prod_{i=1}^n \mathbb{1}_{\mathbb{N}}(x_j - X_{(1)})}_{h(x_1, \dots, x_n)}$$

Luego, por el Teorema de Factorización $X_{(1)}$ es suficiente para θ .

si θ es conocido:

$$p(x_1, \dots, x_n, p) = \underbrace{\left(\frac{1-p}{p^\theta}\right)^n p^{\sum x_i} \mathbb{1}_{(-\infty, X_{(1)})}(\theta)}_{g(\sum X_i, p)} \underbrace{\prod_{i=1}^n \mathbb{1}_{\mathbb{N}}(x_j - X_{(1)})}_{h(x_1, \dots, x_n)}$$

Luego, por el Teorema de Factorización $\sum_{i=1}^n X_i$ es suficiente para p .

3. Sean $X_1, \dots, X_n$ v.a.i.i.d. $\mathcal{U}(\theta_1, \theta_2)$. Mostrar que $(X_{(1)}, X_{(n)})$ es suficiente para (θ_1, θ_2) .

Solución:

$$p(x_1, x_n, \theta_1, \theta_2) = \prod_{i=1}^n \frac{1}{\theta_2 - \theta_1} \mathbb{1}_{(\theta_1, \theta_2)}(x_i) = \left(\frac{1}{\theta_2 - \theta_1}\right)^n \prod_{i=1}^n \mathbb{1}_{(\theta_1, \theta_2)}(x_i)$$

y puesto que

$$1 = \prod_{i=1}^n \mathbb{1}_{(\theta_1, \theta_2)}(x_i) \Leftrightarrow \theta_1 \leq x_i \leq \theta_2 \forall 1 \leq i \leq n \Leftrightarrow X_{(n)} = \max_{1 \leq i \leq n} x_i \leq \theta_2 \text{ y } X_{(1)} = \min_{1 \leq i \leq n} x_i \geq \theta_1$$

entonces

$$p(x_1, x_n, \theta_1, \theta_2) = \left(\frac{1}{\theta_2 - \theta_1}\right)^n \mathbb{1}_{(-\infty, X_{(1)})}(\theta_1) \mathbb{1}_{(X_{(n)}, \infty)}(\theta_2)$$

por lo tanto, por el Teorema de Factorización con

$$g((X_{(1)}, X_{(n)}), (\theta_1, \theta_2)) = \left(\frac{1}{\theta_2 - \theta_1}\right)^n \mathbb{1}_{(-\infty, X_{(1)})}(\theta_1) \mathbb{1}_{(X_{(n)}, \infty)}(\theta_2) \text{ y } h(x_1, \dots, x_n) = 1$$

se sigue que $(X_{(1)}, X_{(n)})$ es suficiente para (θ_1, θ_2) .

4. Sea $X_1, \dots, X_n$ una m.a. de una distribución con densidad

$$f(x; \mu, \sigma) = \frac{1}{\sigma} \exp\left\{-\frac{(x - \mu)}{\sigma}\right\} \mathbb{1}_{[\mu, \infty)}(x)$$

con $\mu \in \mathbb{R}$ y $\sigma > 0$.

a) Exhibir un estadístico suficiente bidimensional para (μ, σ) .

- b) Hallar un estadístico suficiente para μ cuando σ es fijo y conocido.
 c) Hallar un estadístico suficiente para σ cuando μ es fijo y conocido.

Solución:

(a)

$$p(x_1, \dots, x_n, \mu, \sigma) = \prod_{i=1}^n \frac{1}{\sigma} \exp \left\{ -\frac{(x_i - \mu)}{\sigma} \right\} \mathbb{1}_{[\mu, \infty)}(x_i) = \frac{1}{\sigma^n} \exp \left\{ -\frac{1}{\sigma} \sum_{i=1}^n (x_i - \mu) \right\} \prod_{i=1}^n \mathbb{1}_{[\mu, \infty)}(x_i) \Rightarrow$$

$$p(x_1, \dots, x_n, \mu, \sigma) = \underbrace{\frac{e^{\frac{n\mu}{\sigma}}}{\sigma^n} \exp \left\{ -\frac{1}{\sigma} \sum_{i=1}^n x_i \right\} \mathbb{1}_{(-\infty, X^{(1)})}(\mu)}_{g((X_{(1)}, \sum X_i), (\mu, \sigma))} \underbrace{1}_{h(x_1, \dots, x_n)}$$

Luego, por el Teorema de Factorización $\left(X_{(1)}, \sum_{i=1}^n X_i \right)$ es suficiente para (μ, σ) .

(b) Si σ es fijo y conocido,

$$p(x_1, \dots, x_n, \mu, \sigma) = \underbrace{\mathbb{1}_{(-\infty, X^{(1)})}(\mu) e^{\frac{n\mu}{\sigma}}}_{g(X_{(1)}, \mu)} \underbrace{\frac{1}{\sigma^n} \exp \left\{ -\frac{1}{\sigma} \sum_{i=1}^n x_i \right\}}_{h(x_1, \dots, x_n)}$$

Luego, por el Teorema de Factorización $(X_{(1)})$ es suficiente para μ .

(c) Si μ es fijo y conocido,

$$p(x_1, \dots, x_n, \mu, \sigma) = \underbrace{\frac{e^{\frac{n\mu}{\sigma}}}{\sigma^n} \exp \left\{ -\frac{1}{\sigma} \sum_{i=1}^n x_i \right\}}_{g(\sum X_i, \sigma)} \underbrace{\mathbb{1}_{(-\infty, X^{(1)})}(\mu)}_{h(x_1, \dots, x_n)}$$

Luego, por el Teorema de Factorización $\sum_{i=1}^n X_i$ es suficiente para σ .

5. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución P_θ discreta o absolutamente continua. Supóngase que $T(\mathbf{X})$ es un estadístico suficiente para θ . Demostrar que el EMV de θ depende de $\mathbf{X}$ sólo a través de $T(\mathbf{X})$.

Solución: Sabemos que el estadístico de máxima verosimilitud para θ es de la pinta

$$L(x_1, \dots, x_n, \theta) = p(x_1, \dots, x_n, \theta)$$

y por el Teorema de Factorización también sabemos que

$$p(x_1, \dots, x_n, \theta) = g(T(x_1, \dots, x_n), \theta) h(x_1, \dots, x_n).$$

Luego,

$$L(x_1, \dots, x_n, \theta) = g(T(x_1, \dots, x_n), \theta) h(x_1, \dots, x_n) \Rightarrow \frac{\partial L(x_1, \dots, x_n, \theta)}{\partial \theta} = g'(T(x_1, \dots, x_n), \theta) h(x_1, \dots, x_n)$$

como buscamos el valor para el cual $\frac{\partial L(x_1, \dots, x_n, \theta)}{\partial \theta} = 0$, se tiene que $g'(T(x_1, \dots, x_n), \theta) = 0$ o $h(x_1, \dots, x_n) = 0$.

En este caso, $h(x_1, \dots, x_n) \neq 0$ puesto que de lo contrario $p(x_1, \dots, x_n, \theta) = 0$. Entonces

$$0 = \frac{\partial L(x_1, \dots, x_n, \theta)}{\partial \theta} \Leftrightarrow g'(T(x_1, \dots, x_n), \theta) = 0 \Rightarrow \text{el EMV de } \theta \text{ depende de } \mathbf{X} \text{ sólo a través de } T(\mathbf{X}).$$

1.11.7. Teorema de Rao-Blackwell

1. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución $Bi(1, \theta)$. Luego, $\delta(\mathbf{X}) = X_1$ es un estimador insesgado de θ y $T(\mathbf{X}) = \sum_{i=1}^n X_i$ es un estadístico suficiente.

- a) Usando el Teorema de Rao-Blackwell, hallar un estimador insesgado $\delta^*(T)$ que sea mejor que δ .
 b) Probar que $V_\theta(\delta^*) < V_\theta(\delta) \quad \forall \theta$ si $n > 1$.

Solución:

- (a) Sea
- $\delta^*(\mathbf{X}) = \mathbb{E}(X_1|T)$
- , además

$$t = \mathbb{E} \left(\sum_{i=1}^n X_i \middle| \sum_{i=1}^n X_i = t \right) = \sum_{i=1}^n \mathbb{E} \left(X_i \middle| \sum_{i=1}^n X_i \right) \underset{X_i \text{ m.a.}}{=} n \mathbb{E} \left(X_1 \middle| \sum_{i=1}^n X_i \right)$$

luego,

$$\mathbb{E} \left(X_1 \middle| \sum_{i=1}^n X_i \right) = \frac{t}{n}$$

entonces, $\delta^*(\mathbf{X}) = \mathbb{E}(X_1|T) = \frac{T}{n}$ que resulta insesgado tal que $ECM(\delta^*(\mathbf{X})) \leq ECM(\delta(\mathbf{X}))$.

- (b) Como
- $\delta^*(\mathbf{X})$
- y
- $\delta(\mathbf{X})$
- resultan insesgados, entonces
- $ECM(\delta^*(\mathbf{X})) = \mathbb{V}(\delta^*(\mathbf{X}))$
- y
- $ECM(\delta(\mathbf{X})) = \mathbb{V}(\delta(\mathbf{X}))$
- .

Por el Teorema de Rao-Blackwell, $\mathbb{V}(\delta^*(\mathbf{X})) \leq \mathbb{V}(\delta(\mathbf{X}))$. Mientras que valdrá la igualdad solo si

$$\mathbb{P}(\delta^*(\mathbf{X}) = \delta(\mathbf{X})) = 1 \text{ pero } \delta^*(\mathbf{X}) \neq \delta(\mathbf{X}) \text{ puesto que } \forall n \in \mathbb{N}, \frac{1}{n} \sum_{i=1}^n X_i \neq \sum_{i=1}^n X_i.$$

2. Sea
- $X_1, \dots, X_n$
- una m.a. de una distribución
- $\mathcal{P}(\lambda)$
- y
- $T = \sum_{i=1}^n X_i$
- el estadístico suficiente.

a) Sea $\mu = e^{-\lambda}$. Mostrar que $\hat{\mu} = \mathbb{1}\{X_1 = 0\}$ es un estimador insesgado de μ .b) Aplicar el Teorema de Rao-Blackwell para obtener un estimador insesgado $\delta^*(T)$ mejor que $\hat{\mu}$ y comparar los ECM de ambos estimadores.**Solución:**

- (a)
- $\mathbb{E}(\hat{\mu}) = \mathbb{E}(\mathbb{1}\{X_1 = 0\}) = p(X_1 = 0) = \frac{\lambda^0 e^{-\lambda}}{0!} = e^{-\lambda} = \mu$
- . Entonces
- $\hat{\mu}$
- es un estimador insesgado de
- μ
- .

$$(b) \text{ Sea } \mathbb{E} \left(\mathbb{1}\{X_1 = 0\} \middle| \sum_{i=1}^n X_i = t \right) = p \left(X_1 = 0 \middle| \sum_{i=1}^n X_i = t \right) \underset{X_i \text{ m.a.}}{=} \frac{p(X_1 = 0)p \left(\sum_{i=2}^n X_i = t \right)}{p \left(\sum_{i=1}^n X_i = t \right)},$$

$$\text{entonces } \mathbb{E} \left(\mathbb{1}\{X_1 = 0\} \middle| \sum_{i=1}^n X_i = t \right) = \frac{e^{-\lambda}[(n-1)\lambda]^t e^{-(n-1)\lambda}}{t!} \frac{t!}{e^{-n\lambda}(n\lambda)^t} = \left(\frac{n-1}{n} \right)^t.$$

Luego, veamos que $\delta^*(T) = \left(\frac{n-1}{n} \right)^T$ resulta insesgado para μ .

$$\begin{aligned} \mathbb{E} \left[\left(\frac{n-1}{n} \right)^T \right] &= \sum_{i \in \mathbb{N}_0} \left(\frac{n-1}{n} \right)^i p(T = i) = \sum_{i \in \mathbb{N}_0} \left(\frac{n-1}{n} \right)^i \frac{(n\lambda)^i e^{-\lambda n}}{i!} = e^{-\lambda n} \sum_{i \in \mathbb{N}_0} \frac{[(n-1)\lambda]^i}{i!} \\ &\Rightarrow \mathbb{E}(\delta^*(T)) = e^{-\lambda n} e^{(n-1)\lambda} = e^{-\lambda}. \end{aligned}$$

Por último,

$$ECM(\hat{\mu}) = \mathbb{V}(\mathbb{1}\{X_1 = 0\}) = \mathbb{E}([\mathbb{1}\{X_1 = 0\}]^2) - \mathbb{E}^2(\mathbb{1}\{X_1 = 0\}) = \mathbb{E}(\mathbb{1}\{X_1 = 0\}) - \mathbb{E}^2(\mathbb{1}\{X_1 = 0\}) \Rightarrow$$

$$ECM(\hat{\mu}) = e^{-\lambda} - e^{-2\lambda} = e^{-\lambda}(1 - e^{-\lambda}).$$

$$ECM(\delta^*(T)) = \mathbb{V}(\delta^*(T)) = \mathbb{E} \left[\left(\frac{n-1}{n} \right)^{2T} \right] - \mathbb{E}^2 \left[\left(\frac{n-1}{n} \right)^T \right] = \sum_{i \in \mathbb{N}_0} \left(\frac{n-1}{n} \right)^{2i} p(T = i) - e^{-2\lambda} \Rightarrow$$

$$ECM(\delta^*(T)) = \sum_{i \in \mathbb{N}_0} \left(\frac{n-1}{n} \right)^{2i} \frac{(n\lambda)^i e^{-\lambda n}}{i!} - e^{-2\lambda} = e^{-\lambda n} \sum_{i \in \mathbb{N}_0} \frac{[(n-1)^2 \lambda]^i}{i!} - e^{-2\lambda} \Rightarrow$$

$$ECM(\delta^*(T)) = e^{-\lambda n} e^{\frac{(n-1)^2 \lambda}{n}} - e^{-2\lambda} = e^{\lambda(\frac{1-2n}{n})} - e^{-2\lambda}.$$

Finalmente,

$$ECM(\delta^*(T)) \leq ECM(\hat{\mu}) \Leftrightarrow e^{\lambda(\frac{1-2n}{n})} - e^{-2\lambda} \leq e^{-\lambda}(1 - e^{-\lambda}) \Leftrightarrow e^{\lambda(\frac{1-2n}{n})} \leq e^{-\lambda} \Leftrightarrow$$

$$\left(\frac{1-2n}{n} \right) \leq -1 \Leftrightarrow \frac{1}{n} \leq 1.$$

3. Sea $X_1, \dots, X_n$ una m.a. de una distribución $Bi(1, \theta)$. Dados m y k tales que $k \leq m < n$, se quiere estimar $q(\theta) = \binom{m}{k} \theta^k (1 - \theta)^{m-k}$. Sea $S = \sum_{i=1}^m X_i$ y $h(S) = \mathbb{1}\{S = k\}$.
- a) Probar que $h(S)$ es un estimador insesgado de $q(\theta)$.
- b) Construir un estimador insesgado de $q(\theta)$ mejor que $h(S)$.

Solución:

$$(a) \mathbb{E}(h(S)) = \mathbb{E}(\mathbb{1}\{S = k\}) = p(S = k) = p\left(\sum_{i=1}^m X_i = k\right).$$

Como $X_i \sim Bi(1, \theta)$ para todo $i \in \{1, \dots, n\}$, entonces $S \sim Bi(m, \theta)$. Luego,

$$\mathbb{E}(h(S)) = p\left(\sum_{i=1}^m X_i = k\right) = \binom{m}{k} \theta^k (1 - \theta)^{m-k}.$$

que resulta ser un estimador insesgado de $q(\theta)$.

- (b) Por el Teorema de Factorización

$$p(x_1, \dots, x_n, \theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} \mathbb{1}_{\{0,1\}}(x_i) = \underbrace{\theta^{\sum x_i} (1 - \theta)^{n - \sum x_i}}_{g(\sum X_i, \theta)} \underbrace{\prod_{i=1}^n \mathbb{1}_{\{0,1\}}(x_i)}_{h(x_1, \dots, x_n)}$$

entonces, $T = \sum_{i=1}^n X_i$ es un estimador suficiente para θ .

Luego, por el Teorema de Rao-Blackwell, sea $\delta^*(T) = \mathbb{E}\left(h(S) \left| \sum_{i=1}^n X_i \right.\right)$.

$$\mathbb{E}\left(h(S) \left| \sum_{i=1}^n X_i = t \right.\right) = \mathbb{E}\left(\mathbb{1}\{S = k\} \left| \sum_{i=1}^n X_i = t \right.\right) = p\left(\sum_{i=1}^m X_i = k \left| \sum_{i=1}^n X_i = t \right.\right) \Rightarrow$$

$$\mathbb{E}(h(S)|T = t) = \frac{1}{p\left(\sum_{i=1}^n X_i = t\right)} p\left(\sum_{i=1}^m X_i = k\right) p\left(\sum_{i=m+1}^n X_i = t - k\right) = \frac{\binom{m}{k} \binom{n-m}{t-k}}{\binom{n}{t}}.$$

$$\text{Entonces, } \delta^*(T) = \frac{\binom{m}{k} \binom{n-m}{T-k}}{\binom{n}{T}}.$$

4. Sea $X_1, \dots, X_n$ una m.a. de una distribución $N(\mu, 1)$ y $\xi \in \mathbb{R}$ un número fijo y conocido. Se desea estimar $p = P(X_1 \leq \xi)$.
- a) Mostrar que $\mathbb{1}\{X_1 \leq \xi\}$ es un estimador insesgado de p .
- b) A partir de $T = \bar{X}$, construir otro estimador insesgado $\delta^*(T)$ mejor que el anterior.
- Sugerencia:* probar y usar que $\bar{X}$ y $X_1 - \bar{X}$ son independientes.

Solución:

$$a) \mathbb{E}(\mathbb{1}\{X_1 \leq \xi\}) = \mathbb{P}(X_1 \leq \xi) = p.$$

1.11.8. Familias Exponenciales

1. Mostrar que las siguientes familias de distribuciones son exponenciales. En cada caso, hacer una elección explícita de $a(\theta)$, $h(\mathbf{x})$, $c_j(\theta)$ y $t_j(\mathbf{x})$ y exhibir un estadístico suficiente para θ .

- a) $\mathcal{P}(\theta)$; $\theta > 0$.
- b) $N(\mu, \sigma^2)$; $\theta = (\mu, \sigma^2)$, con $\mu \in \mathbb{R}$ y $\sigma^2 > 0$.
- c) $\Gamma(\alpha, \lambda)$; $\theta = (r, \lambda)$, con $\alpha, \lambda > 0$.
- d) $BN(r, \theta)$; $0 < \theta < 1$ y r conocido.
- e) $\beta(r, s)$; $\theta = (r, s)$, con $r, s > 0$.

Solución:

(a)

$$p(x, \theta) = \frac{\theta^x e^{-\theta}}{x!} \mathbb{1}_{\mathbb{N}}(x) = e^{x \ln(\theta)} e^{-\theta} \frac{\mathbb{1}_{\mathbb{N}}(x)}{x!}$$

Luego, con $c_1(\theta) = \ln(\theta)$, $t_1(x) = x$, $a(\theta) = e^{-\theta}$ y $h(\mathbf{x}) = \frac{\mathbb{1}_{\mathbb{N}}(x)}{x!}$ se tiene que un estadístico suficiente para θ es $T = r_1(x) = X$.

(b)

$$p(x, (\mu, \sigma^2)) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/2\sigma^2} = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{x^2}{2\sigma^2} + \frac{x\mu}{\sigma^2} - \frac{\mu^2}{2\sigma^2}\right\} = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{\mu^2}{2\sigma^2}} \exp\left\{-\frac{x^2}{2\sigma^2} + \frac{x\mu}{\sigma^2}\right\}$$

Luego, con $c_1(\theta) = -\frac{1}{2\sigma^2}$, $c_2(\theta) = \frac{\mu}{\sigma^2}$, $t_1(x) = x^2$, $t_2(x) = x$, $a(\theta) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{\mu^2}{2\sigma^2}}$ y $h(\mathbf{x}) = 1$ se tiene que un estadístico suficiente para $\theta = (\mu, \sigma^2)$ es $T = (X^2, X)$.

(c)

$$p(x, (\alpha, \lambda)) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \mathbb{1}_{(0,+\infty)}(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} e^{(\alpha-1)\ln(x)} e^{-\lambda x} \mathbb{1}_{(0,+\infty)}(x)$$

Luego, con $c_1(\theta) = (\alpha - 1)$, $c_2(\theta) = -\lambda$, $t_1(x) = \ln(x)$, $t_2(x) = x$, $a(\theta) = \frac{\lambda^\alpha}{\Gamma(\alpha)}$ y $h(\mathbf{x}) = \mathbb{1}_{(0,+\infty)}(x)$ se tiene que un estadístico suficiente para $\theta = (\alpha, \lambda)$ es $T = (\ln(X), X)$.

(d)

$$p(x, (t, \theta)) = \binom{x-1}{r-1} \theta^r (1-\theta)^{x-r} \mathbb{1}_{\mathbb{N}+r}(x) = \theta^r e^{-r \ln(1-\theta)} e^{x \ln(1-\theta)} \binom{x-1}{r-1} \mathbb{1}_{\mathbb{N}+r}(x)$$

Luego, con $c_1(\theta) = \ln(1-\theta)$, $t_1(x) = x$, $a(\theta) = \theta^r e^{-r \ln(1-\theta)}$ y $h(\mathbf{x}) = \binom{x-1}{r-1} \mathbb{1}_{\mathbb{N}+r}(x)$ se tiene que un estadístico suficiente para θ es $T = X$.

(e)

$$p(x, (r, s)) = \frac{\Gamma(r+s)}{\Gamma(r)\Gamma(s)} x^{r-1} (1-x)^{s-1} \mathbb{1}_{(0,1)}(x) = \frac{\Gamma(r+s)}{\Gamma(r)\Gamma(s)} e^{r \ln(x)} e^{s \ln(1-x)} e^{-\ln(x) - \ln(1-x)} \mathbb{1}_{(0,1)}(x)$$

Luego, con $c_1(\theta) = r$, $c_2(\theta) = s$, $t_1(x) = \ln(x)$, $t_2(x) = \ln(1-x)$, $a(\theta) = \frac{\Gamma(r+s)}{\Gamma(r)\Gamma(s)}$ y

$h(\mathbf{x}) = e^{-\ln(x) - \ln(1-x)} \mathbb{1}_{(0,1)}(x)$ se tiene que un estadístico suficiente para $\theta = (r, s)$ es $T = (\ln(X), \ln(1-X))$.

2. Sea $\{f(x; \theta) : \theta \in \Theta\}$ una familia exponencial. Probar que el soporte de $f(x; \theta)$ no depende de θ . Mostrar que la familia $\{\mathcal{U}(0, \theta) : \theta > 0\}$ no es exponencial.

Solución: Puesto que es una familia exponencial, entonces x perteneces al soporte de $f(x; \theta)$ si y sólo si $a(\theta)h(\mathbf{X}) > 0$.

Entonces, x perteneces al soporte de $f(x; \theta)$ si y sólo si $a(\theta), h(\mathbf{X}) > 0$ o $a(\theta), h(\mathbf{X}) < 0$. Pero, como $a(\theta)$ es un número fijo que no depende de x , se tiene que $a(\theta) \geq 0$. Luego, x perteneces al soporte de $f(x; \theta)$ si y sólo si $h(\mathbf{X}) > 0$; ie, el soporte de $f(x; \theta)$ no depende de θ .

Por otra parte, Sea la familia $\{\mathcal{U}(0, \theta) : \theta > 0\}$ y supongamos que es exponencial. En este caso, x perteneces al soporte si y sólo si $\mathbb{1}_{(0, \theta)}(x) > 0$. Entonces, x perteneces al soporte si y sólo si $x \in (0, \theta)$.

Luego, la familia $\{\mathcal{U}(0, \theta) : \theta > 0\}$ no puede ser exponencial puesto que su soporte depende de θ .

1.11.9. Completitud y Estimadores IMVU

1. Analizar si los estadísticos suficientes hallados en 2 son completos.

Solución:

- (a) Como $\mathcal{P}(\theta)$ es una familia exponencial y $T(\mathbf{X}) = X$ es estadístico suficiente, entonces definiendo $\Lambda = \{\ln(\theta) : \theta > 0\} = \mathbb{R}$ se puede observar que contiene una bola de $\mathbb{R}$ y, por lo tanto, el estadístico $T(\mathbf{X}) = X$ es completo.
- (b) Como $N(\mu, \sigma^2)$ es una familia exponencial y $T(\mathbf{X}) = (X^2, X)$ es estadístico suficiente, entonces definiendo $\Lambda = \left\{ \left(-\frac{1}{2\sigma^2}, \frac{\mu}{\sigma^2} \right) : \sigma^2 > 0, \mu \in \mathbb{R} \right\} = \mathbb{R}_{<0} \times \mathbb{R}$ se puede observar que contiene una bola de $\mathbb{R}^2$ y, por lo tanto, el estadístico $T(\mathbf{X}) = (X^2, X)$ es completo.
- (c) Como $\Gamma(\alpha, \lambda)$ es una familia exponencial y $T(\mathbf{X}) = (\ln(X), X)$ es estadístico suficiente, entonces definiendo $\Lambda = \{(\alpha - 1, -\lambda) : \alpha, \lambda > 0\} = \mathbb{R}_{>-1} \times \mathbb{R}_{<0}$ se puede observar que contiene una bola de $\mathbb{R}^2$ y, por lo tanto, el estadístico $T(\mathbf{X}) = (\ln(X), X)$ es completo.
- (d) Como $BN(r, \theta)$ es una familia exponencial y $T(\mathbf{X}) = X$ es estadístico suficiente, entonces definiendo $\Lambda = \{\ln(1 - \theta) : \theta \in (0, 1)\} = \mathbb{R}_{<0}$ se puede observar que contiene una bola de $\mathbb{R}$ y, por lo tanto, el estadístico $T(\mathbf{X}) = X$ es completo.
- (e) Como $\beta(r, s)$ es una familia exponencial y $T(\mathbf{X}) = (\ln(X), \ln(1 - X))$ es estadístico suficiente, entonces definiendo $\Lambda = \{(r, s) : r, s > 0\} = \mathbb{R}_{>0} \times \mathbb{R}_{>0}$ se puede observar que contiene una bola de $\mathbb{R}$ y, por lo tanto, el estadístico $T(\mathbf{X}) = (\ln(X), \ln(1 - X))$ es completo.
2. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución $N(\mu, 1)$.

- a) Mostrar que $T = \left(X_1, \sum_{i=2}^n X_i \right)$ es suficiente para μ pero no completo.
- b) Hallar un estadístico completo y un estimador IMVU de μ .

Solución:

- (a)

$$p(x_1, \dots, x_n, \mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} e^{-(x_i - \mu)^2/2} = \frac{1}{(\sqrt{2\pi})^n} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (x_i^2 - 2x_i\mu + \mu^2) \right\} \Rightarrow$$

$$p(x_1, \dots, x_n, \mu) = \underbrace{\frac{1}{(\sqrt{2\pi})^n} e^{-\frac{n\mu^2}{2}}}_{a(\mu)} e^{\mu \sum_{i=1}^n x_i} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n x_i^2 \right\} = \underbrace{\frac{1}{(\sqrt{2\pi})^n} e^{-\frac{n\mu^2}{2}}}_{a(\mu)} \underbrace{e^{\mu \sum_{i=1}^n x_i} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n x_i^2 \right\}}_{h(x_1, \dots, x_n)}$$

Luego, $T = \left(X_1, \sum_{i=2}^n X_i \right)$ es un estadístico suficiente para μ .

Para ver que no es completo, sea g medible definida por $g(t_1, t_2) = t_1 - \frac{t_2}{n-1}$ y $\mu > 0$. Entonces,

$$\mathbb{E}(g(T)) = \mathbb{E} \left(T_1 - \frac{T_2}{n-1} \right) = \mathbb{E}(T_1) - \mathbb{E} \left(\frac{T_2}{n-1} \right) = \mathbb{E}(X_1) - \mathbb{E} \left(\frac{1}{n-1} \sum_{i=2}^n X_i \right) = \mu - (n-1) \frac{\mu}{n-1} = 0$$

pero $p \left(T_1 - \frac{T_2}{n-1} = 0 \right) \neq 1$. Por lo tanto, no es completo.

- (b)

$$p(x_1, \dots, x_n, \mu) = \underbrace{\frac{1}{(\sqrt{2\pi})^n} e^{-\frac{n\mu^2}{2}}}_{a(\mu)} \exp \left\{ \mu \sum_{i=1}^n x_i \right\} \underbrace{\exp \left\{ -\frac{1}{2} \sum_{i=1}^n x_i^2 \right\}}_{h(x_1, \dots, x_n)}$$

Puesto que $N(\mu, 1)$ es una familia exponencial, definiendo $\Lambda = \{\mu : \mu \in \mathbb{R}\} = \mathbb{R}$ se puede observar que contiene una bola de $\mathbb{R}$ y, por lo tanto, el estadístico $T(\mathbf{X}) = \sum_{i=1}^n X_i$ es suficiente y completo para μ .

Por otra parte, $\mathbb{E}(T) = n\mu \Rightarrow \mathbb{E} \left(\frac{T}{n} \right) = \mu$. Como T es suficiente y completo, definiendo $\delta(T) = \frac{T}{n}$ por el Teorema de Lehmann-Scheffé se tiene que $\delta(T) = \frac{T}{n}$ es IMVU.

3. Sea $X_1, \dots, X_n$ una m.a. de una distribución $\mathcal{U}(0, \theta)$. Probar que $X_{(n)}$ es completo para θ .

Solución:

$$p(X_{(n)} \leq t) = (p(X_1 \leq t))^n = \begin{cases} 0 & t \leq 0 \\ \left(\frac{t}{\theta}\right)^n & t \in (0, \theta) \\ 1 & t \geq \theta \end{cases} \Rightarrow f_{X_{(n)}}(t) = \frac{n}{\theta^n} t^{n-1} \mathbb{1}_{(0, \theta)}(t)$$

Luego,

$$\mathbb{E}(g(T)) = \mathbb{E}(g(X_{(n)})) = \int_0^\theta \frac{n}{\theta^n} t^{n-1} g(t) dt = \frac{n}{\theta^n} \int_0^\theta t^{n-1} g(t) dt = 0 \Leftrightarrow \int_0^\theta t^{n-1} g(t) dt = 0 \quad \forall \theta \in \mathbb{R}_{>0}$$

Sea g medible, entonces $G(\theta) = \int_0^\theta t^{n-1} g(t) dt \Rightarrow 0 = \frac{\partial G(\theta)}{\partial \theta} = \theta^{n-1} g(\theta)$ para todo $\theta \in \mathbb{R}_{>0}$, entonces $g(\theta) = 0$ para todo $\theta \in \mathbb{R}_{>0}$.

4. Sea $X_1, \dots, X_n$ una m.a. de una distribución $Bi(1, \theta)$, con $\theta \in \Theta \subset (0, 1)$.

- a) Mostrar que si Θ tiene más de n puntos, el estadístico $T = \sum_{i=1}^n X_i$ es completo.
 b) Deducir que $\bar{X}$ es IMVU de θ .
 c) Mostrar que $q(\theta) = \frac{\theta}{1-\theta}$ no es estimable mediante un estimador insesgado.

Solución:

(a)

$$\mathbb{E}(g(T)) = \sum_{k=0}^n g(T) \binom{n}{k} \theta^k (1-\theta)^{n-k} = (1-\theta)^n \sum_{k=0}^n g(T) \binom{n}{k} \left(\frac{\theta}{1-\theta}\right)^k.$$

$$\text{Como } (1-\theta)^n > 0 \Rightarrow \mathbb{E}(g(T)) = 0 \Leftrightarrow 0 = \sum_{k=0}^n g(T) \binom{n}{k} \left(\frac{\theta}{1-\theta}\right)^k.$$

Por otra parte, $h(y) = \sum_{k=0}^n g(T) \binom{n}{k} y^k$ es un polinomio de grado n . Como Θ tiene más de n puntos, entonces el polinomio h tiene más de n raíces. Luego,

$$0 = \sum_{k=0}^n g(T) \binom{n}{k} \left(\frac{\theta}{1-\theta}\right)^k \Rightarrow g(T) \binom{n}{k} = 0 \quad \forall k \in \{0, \dots, n\}$$

y como $\binom{n}{k} > 0$ para todo $n, k \in \mathbb{N}$, se sigue que $g(T) = 0$.

(b) Sea T estadístico suficiente y completo.

$$\bar{X} = \frac{T}{n} \Rightarrow \mathbb{E}(\bar{X}) = \frac{1}{n} \mathbb{E}(T) = \theta \Rightarrow \bar{X} \text{ es insesgado}$$

Luego, $\bar{X}$ es un estimador insesgado para θ basado en T entonces por el Teorema de Lehmann-Scheffé se tiene que $\bar{X}$ es IMVU.

(c) Sea $\delta(\mathbf{X})$ estadístico insesgado de $\frac{\theta}{1-\theta}$.

Luego, por Lehmann-Scheffé definimos $\delta^*(\mathbf{X}) = \mathbb{E}(\delta(\mathbf{X})|T)$ es IMVU para $\frac{\theta}{1-\theta}$.

Por otra parte,

$$\mathbb{E}(\delta^*(\mathbf{X})) = \mathbb{E}[\mathbb{E}(\delta(\mathbf{X})|T = t)] = \sum_{k=0}^n \delta(k) \binom{n}{k} \theta^k (1-\theta)^{n-k} \neq \theta \sum_{k \in \mathbb{N}_0} \theta^k = \frac{\theta}{1-\theta}$$

Por lo tanto, $\frac{\theta}{1-\theta}$ no es estimable mediante un estimador insesgado.

5. Sea $X_1, \dots, X_n$ una m.a. de una distribución $N(\mu, \sigma^2)$.

- a) Mostrar que si σ^2 es conocido, $\bar{X}$ es IMVU para μ .
- b) Mostrar que si μ es conocido, $\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$ es IMVU para σ^2 .
- c) Mostrar que si ambos parámetros son desconocidos, entonces $\bar{X}$ es IMVU para μ y s^2 es IMVU para σ^2 .

Solución:

$$p(x_1, \dots, x_n, \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sigma \sqrt{2\pi}} \exp \left\{ -\frac{(x_i - \mu)^2}{2\sigma^2} \right\} = \frac{1}{\sigma^n} \left(\frac{1}{\sqrt{2\pi}} \right)^n \exp \left\{ -\sum_{i=1}^n \frac{(x_i^2 - 2x_i\mu + \mu^2)}{2\sigma^2} \right\} \Rightarrow$$

$$p(x_1, \dots, x_n, \mu, \sigma^2) = \frac{1}{\sigma^n} \left(\frac{1}{\sqrt{2\pi}} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 \right\} \exp \left\{ \frac{\mu}{\sigma^2} \sum_{i=1}^n x_i \right\} \exp \left\{ -\frac{n\mu^2}{2\sigma^2} \right\}$$

- (a) Supongamos σ^2 es conocido y como $N(\mu, \sigma^2)$ es una familia de exponenciales con $c_1(\mu) = -\frac{\mu}{2\sigma^2}$, $t_1(x) = \sum_{i=1}^n x_i$,

$$a(\mu) = \exp \left\{ -\frac{n\mu^2}{2\sigma^2} \right\} \text{ y } h(\mathbf{x}) = \frac{1}{\sigma^n} \left(\frac{1}{\sqrt{2\pi}} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 \right\} \text{ se tiene que un estadístico suficiente para } \mu \text{ es}$$

$$T_1 = \sum_{i=1}^n X_i.$$

Por otra parte, definiendo $\Lambda = \left\{ \frac{\mu}{\sigma^2} : \mu \in \mathbb{R} \right\} = \mathbb{R}$ se puede observar que contiene una bola de $\mathbb{R}$ y, por lo tanto, el estadístico $T_1 = \sum_{i=1}^n X_i$ es completo.

Por último, $\mathbb{E} \left(\frac{T_1}{n} \right) = \mu$ entonces $\frac{T_1}{n}$ es un estimador insesgado para μ basado en T_1 .

Por lo tanto, por el Teorema de Lehmann-Scheffé se tiene que $\delta(T) = \frac{T_1}{n} = \frac{1}{n} \sum_{i=1}^n X_i$ es IMVU para μ .

- (b) Supongamos μ es conocido y como $N(\mu, \sigma^2)$ es una familia de exponenciales con $c_1(\sigma^2) = -\frac{1}{2\sigma^2}$, $t_2(x) = \sum_{i=1}^n x_i^2$,

$$a(\sigma^2) = \frac{1}{\sigma^n} \exp \left\{ -\frac{n\mu^2}{2\sigma^2} \right\} \text{ y } h(\mathbf{x}) = \left(\frac{1}{\sqrt{2\pi}} \right)^n \exp \left\{ -\frac{n\mu}{\sum_{i=1}^n (x_i - \mu)^2} \sum_{i=1}^n x_i \right\} \text{ se tiene que un estadístico suficiente para}$$

$$\sigma^2 \text{ es } T_2 = \sum_{i=1}^n X_i^2.$$

Por otra parte, definiendo $\Lambda = \left\{ -\frac{1}{\sigma^2} : \mu \in \mathbb{R} \right\} = \mathbb{R}_{<0}$ se puede observar que contiene una bola de $\mathbb{R}_{<0}$ y, por lo tanto, el estadístico $T_2 = \sum_{i=1}^n X_i^2$ es completo.

Por último, $\mathbb{E}(T_2) = n\mathbb{E}(X_1^2) = n[\mathbb{V}(X_1) + \mathbb{E}^2(X_1)] = n(\sigma^2 + \mu^2)$ entonces $\frac{T_2 - n\mu^2}{n} = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$ es un estimador insesgado para σ^2 basado en T_2 .

Por lo tanto, por el Teorema de Lehmann-Scheffé se tiene que $\delta(T) = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$ es IMVU para σ^2 .

6. Sea $X_1, \dots, X_n$ una m.a. de una distribución $\mathcal{E}(\theta)$. Hallar un estimador IMVU de θ .

Solución: Puesto que $\mathcal{E}(\theta)$ es una familia de exponenciales,

$$p(x_1, \dots, x_n, \theta) = \prod_{i=1}^n \theta e^{-\theta x_i} \mathbb{1}_{(0, +\infty)}(x_i) = \underbrace{\theta^n}_{a(\theta)} \exp \left\{ -\theta \sum_{i=1}^n x_i \right\} \underbrace{\prod_{i=1}^n \mathbb{1}_{(0, +\infty)}(x_i)}_{h(x_1, \dots, x_n)}$$

entonces $T = \sum_{i=1}^n X_i$ es un estadístico suficiente para θ .

Además, definiendo $\Lambda = \{-\theta : \theta \in \mathbb{R}_{>0}\} = \mathbb{R}_{<0}$ se puede observar que contiene una bola de $\mathbb{R}_{<0}$ y, por lo tanto, el estadístico $T = \sum_{i=1}^n X_i$ es completo.

Por otra parte, $\mathbb{E}(T) = \frac{n}{\theta}$ entonces calculemos

$$\mathbb{E}\left(\frac{1}{T}\right) = \int_0^{+\infty} \frac{1}{t} \frac{\theta^n}{\Gamma(n)} t^{n-1} e^{\theta t} dt = \frac{\theta}{n-1} \underbrace{\int_0^{+\infty} \frac{\theta^{n-1}}{\Gamma(n-1)} t^{n-2} e^{\theta t} dt}_{=1} = \frac{\theta}{n-1}.$$

Luego, $\delta(T) = \frac{n-1}{T}$ es un estimador para θ insesgado basado en T , por lo tanto, por el Teorema de Lehmann-Scheffé se tiene que $\delta(T) = \frac{n-1}{T}$ es IMVU para θ .

7. En el ejercicio 2 de la parte B), hallar estimadores IMVU para λ, λ^2 y μ .

Solución: Sabemos que

$$p(x_1, \dots, x_n, \lambda) = \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} \mathbb{1}_{\mathbb{N}}(x_i) = \prod_{i=1}^n e^{x_i \ln(\lambda)} e^{-\lambda} \frac{\mathbb{1}_{\mathbb{N}}(x)}{x_i!} = \underbrace{e^{-n\lambda}}_{a(\lambda)} \exp\left\{\ln(\lambda) \sum_{i=1}^n x_i\right\} \underbrace{\prod_{i=1}^n \frac{\mathbb{1}_{\mathbb{N}}(x)}{x_i!}}_{h(x_1, \dots, x_n)}$$

Puesto que $\mathcal{P}(\lambda)$ es una familia exponencial, definiendo $\Lambda = \{\ln(\lambda) : \lambda > 0\} = \mathbb{R}$ se puede observar que contiene una bola de $\mathbb{R}$ y, por lo tanto, el estadístico $T(\mathbf{X}) = \sum_{i=1}^n X_i$ es suficiente y completo para λ .

- (a) Para λ : Sabemos que $\mathbb{E}\left(\frac{T}{n}\right) = \lambda$, entonces puesto que T es suficiente y completo, definiendo el estimador insesgado $\delta_1(T) = \frac{T}{n}$ se tiene que, por el Teorema de Lehmann-Scheffé, $\delta_1(T)$ es IMVU para λ .
- (b) Para λ^2 : Observemos que $\mathbb{E}(T^2) = \mathbb{E}^2(T) + \mathbb{V}(T) = (n\lambda)^2 + n\lambda$, entonces

$$\mathbb{E}\left(\frac{T^2 - T}{n^2}\right) = \frac{n^2\lambda^2 + n\lambda - n\lambda}{n^2} = \lambda^2.$$

Como T es suficiente y completo, definiendo el estimador insesgado $\delta_2(T) = \frac{T^2 - T}{n^2}$ se tiene que, por el Teorema de Lehmann-Scheffé, $\delta_2(T)$ es IMVU para λ^2 .

- (c) Para μ : Siendo T es suficiente y completo, definiendo el estimador insesgado $\delta(T) = \left(\frac{n-1}{n}\right)^T$ se tiene que, por el Teorema de Lehmann-Scheffé, $\delta(T)$ es IMVU para μ .
8. En el ejercicio 3 de la parte **Teorema de Rao-Blackwell**, hallar un estimador IMVU para $q(\theta)$.

Solución: Sabemos que el estadístico $T(\mathbf{X}) = \sum_{i=1}^n X_i$ es suficiente y completo para θ y que $\delta(T) = \frac{\binom{m}{k} \binom{n-m}{T-k}}{\binom{n}{T}}$

es un estimador insesgado de $q(\theta)$ basado en T .

Luego, por el Teorema de Lehmann-Scheffé, $\delta(T)$ es IMVU para θ .

9. En el ejercicio 4 de la parte **Teorema de Rao-Blackwell**, hallar un estimador IMVU para p .
10. Sean δ_1 y δ_2 dos estimadores IMVU de $q_1(\theta)$ y $q_2(\theta)$ respectivamente, y $c_1, c_2 \in \mathbb{R}$. Demostrar que $c_1\delta_1 + c_2\delta_2$ es IMVU de $c_1q_1(\theta) + c_2q_2(\theta)$.

1.11.10. Desigualdad de Rao-Cramer

1. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución $Bi(1, \theta)$.

- a) Calcular el número de información de Fisher $I_1(\theta)$.
- b) Mostrar que $\bar{X}$ alcanza la cota de Rao-Cramer y deducir que es IMVU para θ .

Solución:

(a) Recordemos que $I_1(\theta) = -\mathbb{E}_\theta \left(\frac{\partial^2}{\partial \theta^2} \ln(p(X, \theta)) \right)$.

$$\frac{\partial^2}{\partial \theta^2} \ln \left(\theta^x (1-\theta)^{(1-x)} \right) = \frac{\partial^2}{\partial \theta^2} (x \ln \theta + (1-x) \ln(1-\theta)) = \frac{\partial}{\partial \theta} \left(\frac{x}{\theta} - \frac{1-x}{1-\theta} \right) = -\frac{x}{\theta^2} - \frac{1-x}{(1-\theta)^2} \Rightarrow$$

$$I_1(\theta) = -\mathbb{E}_\theta \left(-\frac{X}{\theta^2} - \frac{1-X}{(1-\theta)^2} \right) = \mathbb{E}_\theta \left(\frac{X}{\theta^2} \right) + \mathbb{E}_\theta \left(\frac{1-X}{(1-\theta)^2} \right) = \frac{1}{\theta} + \frac{1}{1-\theta}$$

(b) $\mathbb{V}(\bar{X}) = \frac{1}{n} \mathbb{V}(X_1) = \frac{\theta(1-\theta)}{n}$ y, por otra parte, $|q'(\theta)|^2 = 1$ y $I(\theta) = nI_1(\theta) = \frac{n}{\theta(1-\theta)}$.

$$\frac{|q'(\theta)|^2}{I(\theta)} = \frac{1}{\frac{n}{\theta(1-\theta)}} = \frac{\theta(1-\theta)}{n} = \mathbb{V}(\bar{X})$$

Luego, como $\bar{X}$ es insesgado y alcanza la cota de Rao–Cramer, se sigue que $\bar{X}$ es IMVU.

2. Sea $X_1, \dots, X_n$ una m.a. de una distribución $N(\mu, \sigma_0^2)$, con σ_0^2 conocido.

a) Mostrar que $\bar{X}$ es un estimador IMVU para μ , usando la desigualdad de Rao–Cramer.

b) Mostrar que $\bar{X}^2 - \frac{\sigma_0^2}{n}$ es un estimador IMVU de μ^2 , aunque no alcanza la cota de Rao–Cramer.

Solución:

(a) En primer lugar, notamos que $\mathbb{E}(\bar{X}) = \mu$ por lo tanto $\bar{X}$ resulta insesgado.

Por otra parte, $\mathbb{V}(\bar{X}) = \frac{1}{n} \mathbb{V}(X_1) = \frac{\sigma_0^2}{n}$, $|q'(\mu)|^2 = 1$ y $I(\mu) = nI_1(\mu) = -n\mathbb{E}_\mu \left(\frac{\partial^2}{\partial \mu^2} \ln(f(X, \mu)) \right)$.

$$\frac{\partial^2}{\partial \mu^2} \ln \left(\frac{1}{\sigma_0^2 \sqrt{2\pi}} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma_0^2} \right\} \right) = -\frac{1}{\sigma_0^2} \Rightarrow I(\mu) = -n\mathbb{E}_\mu \left(-\frac{1}{\sigma_0^2} \right) = \frac{n}{\sigma_0^2}$$

$$\Rightarrow \frac{|q'(\mu)|^2}{I(\mu)} = \frac{\sigma_0^2}{n} = \mathbb{V}(\bar{X})$$

Por lo tanto, $\bar{X}$ es insesgado y alcanza la cota Rao–Cramer, entonces $\bar{X}$ es IMVU para μ .

(b) Sea $\delta(T) = \bar{X}^2 - \frac{\sigma_0^2}{n}$,

$$\mathbb{E}_{\mu^2} \left(\bar{X}^2 - \frac{\sigma_0^2}{n} \right) = \mathbb{V}(\bar{X}) + \mathbb{E}^2(\bar{X}) - \frac{\sigma_0^2}{n} = \frac{\sigma_0^2}{n} + \mu^2 - \frac{\sigma_0^2}{n} = \mu^2$$

Entonces, como $\delta(T)$ resulta insesgado basado en un estadístico completo y suficiente, por el Teorema de Lehmann–Scheffé, $\delta(T)$ es IMVU para μ^2 .

3. Sea X una v.a. con distribución $\mathcal{P}(\lambda)$ y sean μ y $\delta^*(T)$ como en el ejercicio 2 de la parte B). Mostrar que aunque $\delta^*(T)$ es un estimador IMVU de μ , la cota de Rao–Cramer es estrictamente menor que $\mathbb{V}_\lambda(\hat{\mu})$.

Solución: Por ejercicio 7, sabemos que $\delta^*(T) = \left(\frac{n-1}{n} \right)^T$ es IMVU de $\mu = e^{-\lambda}$.

Luego, $q(\lambda) = e^{-\lambda}$ entonces $q'(\lambda) = -e^{-\lambda}$ y $|q'(\lambda)| = e^{-\lambda} \Rightarrow |q'(\lambda)|^2 = e^{-2\lambda}$.

$$I(\lambda) = -\mathbb{E}_\lambda \left[\frac{\partial^2}{\partial \lambda^2} \ln(p(X, \lambda)) \right] = -\mathbb{E}_\lambda \left[\frac{\partial^2}{\partial \lambda^2} \ln \left(\frac{\lambda^x e^{-\lambda}}{x!} \right) \right] = -\mathbb{E}_\lambda \left[\frac{\partial^2}{\partial \lambda^2} (\ln(\lambda^x) + \ln(e^{-\lambda}) - \ln(x!)) \right]$$

$$\Rightarrow I(\lambda) = -\mathbb{E}_\lambda \left[\frac{\partial}{\partial \lambda} \left(\frac{x}{\lambda} - 1 \right) \right] = -\mathbb{E}_\lambda \left(\frac{-X}{\lambda^2} \right) = \frac{1}{\lambda^2} \mathbb{E}_\lambda(X) = \frac{1}{\lambda}$$

$$\Rightarrow I_n(\lambda) = nI(\lambda) = \frac{n}{\lambda}$$

Por lo tanto, $\mathbb{V}_\lambda(\delta^*(T)) \geq \frac{\lambda e^{-2\lambda}}{n}$.

Por otra parte,

$$\mathbb{V}(\hat{\mu}) = \mathbb{E}(\hat{\mu}^2) - \mathbb{E}^2(\hat{\mu}) = 0p(\hat{\mu} = 0) + 1p(\hat{\mu} = 1) - \mu^2 = p(X = 0) - \mu^2 = e^{-\lambda} - e^{-2\lambda}$$

y queremos ver que

$$\frac{\lambda e^{-2\lambda}}{n} < e^{-\lambda} - e^{-2\lambda} \Leftrightarrow \frac{\lambda e^{-2\lambda}}{n} < e^{-\lambda}(1 - e^{-\lambda}) \Leftrightarrow \frac{\lambda e^{-\lambda}}{n} < 1 - e^{-\lambda} \Leftrightarrow e^{-\lambda}(\lambda + n) < n \Leftrightarrow \lambda + n < ne^\lambda.$$

Capítulo 2

Intervalos y Regiones de Confianza

Definición 2.1. Dado un vector $\mathbf{X}$ con distribución perteneciente a la familia $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$, una región de confianza $S(\mathbf{X})$ para $\boldsymbol{\theta}$ con nivel de confianza $1 - \alpha$ será una función que a cada $\mathbf{X}$ le hace corresponder un subconjunto de Θ de manera que $\mathbb{P}_{\boldsymbol{\theta}}(\boldsymbol{\theta} \in S(\mathbf{X})) = 1 - \alpha$ para todo $\boldsymbol{\theta} \in \Theta$.

Observación 2.2.

(i) Recordemos que un estimador puntual de $\boldsymbol{\theta}$ es una función $\hat{\boldsymbol{\theta}} = \delta(\mathbf{X})$ que representa un único valor que aproxima a $\boldsymbol{\theta}$. Si se da solamente ese valor no se tendrá ninguna idea de las posibles diferencias entre $\boldsymbol{\theta}$ y $\hat{\boldsymbol{\theta}}$.

Una forma de obtener información sobre la precisión de la estimación, en el caso de que $\boldsymbol{\theta}$ sea unidimensional, es proporcionar un intervalo $[a(\mathbf{X}), b(\mathbf{X})]$ de manera que la probabilidad de que dicho intervalo contenga el verdadero valor $\boldsymbol{\theta}$ sea alta.

(ii) Cuando $\boldsymbol{\theta}$ sea unidimensional se dirá que $S(\mathbf{X})$ es un intervalo de confianza si $S(\mathbf{X})$ es de la forma

$$S(\mathbf{X}) = [a(\mathbf{X}), b(\mathbf{X})],$$

cuya longitud está dada por

$$\mathcal{L} = b(\mathbf{X}) - a(\mathbf{X}).$$

2.1. Procedimientos generales para obtener regiones de confianza

Teorema 2.3. Sea $\mathbf{X}$ un vector aleatorio cuya distribución pertenece a la familia $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$, y sea $U = G(\mathbf{X}, \boldsymbol{\theta})$ una variable aleatoria cuya distribución es independiente de $\boldsymbol{\theta}$.

Sean A y B tales que $\mathbb{P}(A \leq U \leq B) = 1 - \alpha$. Luego, si se define $S(\mathbf{X}) = \{\boldsymbol{\theta} : A \leq G(\mathbf{X}, \boldsymbol{\theta}) \leq B\}$, se tiene que $S(\mathbf{X})$ es una región de confianza a nivel $(1 - \alpha)$ para $\boldsymbol{\theta}$.

Demostración. $\mathbb{P}_{\boldsymbol{\theta}}(\boldsymbol{\theta} \in S(\mathbf{X})) = \mathbb{P}_{\boldsymbol{\theta}}(A \leq G(\mathbf{X}, \boldsymbol{\theta}) \leq B) = \mathbb{P}_{\boldsymbol{\theta}}(A \leq U \leq B)$ y puesto que la distribución de U es independiente de $\boldsymbol{\theta}$ se tiene que $\mathbb{P}_{\boldsymbol{\theta}}(A \leq U \leq B) = \mathbb{P}(A \leq U \leq B) = 1 - \alpha$. $\square$

Teorema 2.4. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución $N(\mu, \sigma^2)$. Luego,

(i) $V = \sqrt{n} \frac{\bar{X}_n - \mu}{\sigma}$ tiene distribución $N(0, 1)$.

(ii) $W = \sum_{i=1}^n \frac{X_i - \bar{X}_n}{\sigma^2}$ tiene distribución χ^2 con $n - 1$ grados de libertad.

(iii) V y W son independientes.

(iv) Sean $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ y $U = \sqrt{n} \frac{\bar{X}_n - \mu}{s}$. Luego, U tiene distribución $\mathcal{T}_{n-1}$ con $n - 1$ grados de libertad.

Demostración. Sea $Y_i = \frac{X_i - \mu}{\sigma}$, $1 \leq i \leq n$. Luego estas variables forman una muestra aleatoria de una distribución $N(0, 1)$. Además, es fácil verificar que

$$V = \sqrt{n} \bar{Y}_n, \quad W = \sum_{i=1}^n (Y_i - \bar{Y}_n)^2, \quad U = \sqrt{n-1} \frac{V}{\sqrt{W}}.$$

Sea $\mathbf{a}_1$ el vector fila n -dimensional con todas sus componentes iguales a $1/\sqrt{n}$. Como $\|\mathbf{a}_1\| = 1$, se puede completar una base ortonormal $\mathbf{a}_1, \dots, \mathbf{a}_n$.

Sea A la matriz de $n \times n$ cuyas filas son $\mathbf{a}_1, \dots, \mathbf{a}_n$. Como las filas de A son ortogonales y de norma 1, la matriz A resulta ortogonal. Consideremos la transformación $\mathbf{Z} = A\mathbf{Y}$, donde $\mathbf{Y} = (Y_1, \dots, Y_n)'$ y $\mathbf{Z} = (Z_1, \dots, Z_n)'$. Luego, por una propiedad de los vectores normales respecto de transformaciones ortogonales, las variables $Z_1, \dots, Z_n$ son también independientes con distribución $N(0, 1)$.

(i) Puesto que $V = \sqrt{n\bar{Y}_n} = \frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i = Z_1$ se tiene que $V \sim N(0, 1)$.

$$(ii) \sum_{i=1}^n (Y_i - \bar{Y}_n)^2 = \sum_{i=1}^n (Y_i^2 - 2Y_i\bar{Y}_n + Y_i - \bar{Y}_n^2) = \sum_{i=1}^n Y_i^2 - 2\bar{Y}_n \underbrace{\sum_{i=1}^n Y_i}_{n\bar{Y}_n} + n\bar{Y}_n^2 = \sum_{i=1}^n Y_i^2 - n\bar{Y}_n^2 = \sum_{i=1}^n Y_i^2 - Z_1^2.$$

Como A es ortogonal se deduce que $\sum_{i=1}^n Y_i^2 = \sum_{i=1}^n Z_i^2$, entonces

$$W = \sum_{i=1}^n (Y_i - \bar{Y}_n)^2 = \sum_{i=1}^n Y_i^2 - Z_1^2 = \sum_{i=1}^n Z_i^2 - Z_1^2 = \sum_{i=2}^n Z_i^2$$

y, por lo tanto, W tiene distribución χ^2 con $n - 1$ grados de libertad pues si $X_i \sim N(0, 1)$ entonces $\sum_{i=1}^n X_i^2 \sim \chi_n^2$.

(iii) Se deduce del hecho de que V depende sólo de Z_1 mientras que W depende sólo de $Z_2, \dots, Z_n$.

(iv) Se deduce del hecho de que $V \sim N(0, 1)$ y $W \sim \chi_{n-1}^2$, entonces $U = \frac{V}{\sqrt{W/(n-1)}} \sim \mathcal{T}_{n-1}$. □

Teorema 2.5. Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria cuya distribución pertenece a la familia $N(\mu, \sigma^2)$ con μ y σ^2 desconocidos. Luego si

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \quad y \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

se tiene que un intervalo de confianza con nivel $(1 - \alpha)$ para μ está dado por:

$$\left[\bar{X}_n - \mathcal{T}_{n-1, \frac{\alpha}{2}} \frac{s}{\sqrt{n}}; \bar{X}_n + \mathcal{T}_{n-1, \frac{\alpha}{2}} \frac{s}{\sqrt{n}} \right].$$

Demostración. Por el teorema anterior, se tiene que $U = \sqrt{n} \frac{(\bar{X}_n - \mu)}{s}$ tiene distribución $\mathcal{T}_{n-1}$ y luego

$$\mathbb{P}(-\mathcal{T}_{n-1, \frac{\alpha}{2}} \leq U \leq \mathcal{T}_{n-1, \frac{\alpha}{2}}) = 1 - \alpha,$$

entonces, el conjunto

$$\left\{ \mu : -\mathcal{T}_{n-1, \frac{\alpha}{2}} \leq \frac{\bar{X}_n - \mu}{s} \sqrt{n} \leq \mathcal{T}_{n-1, \frac{\alpha}{2}} \right\}$$

es una región de confianza para μ con nivel $(1 - \alpha)$. Pero esta región es equivalente a

$$\left\{ \mu : \bar{X}_n - \mathcal{T}_{n-1, \frac{\alpha}{2}} \frac{s}{\sqrt{n}} \leq \mu \leq \bar{X}_n + \mathcal{T}_{n-1, \frac{\alpha}{2}} \frac{s}{\sqrt{n}} \right\}.$$

□

Teorema 2.6. Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria cuya distribución pertenece a la familia $N(\mu, \sigma^2)$. Sean β y γ tales que $\beta + \gamma = \alpha$.

(i) Si μ es conocido, un intervalo de confianza de nivel $(1 - \alpha)$ para σ^2 está dado por:

$$\left[\frac{1}{\chi_{n, \beta}^2} \sum_{i=1}^n (X_i - \mu)^2 \leq \sigma^2 \leq \frac{1}{\chi_{n, 1-\gamma}^2} \sum_{i=1}^n (X_i - \mu)^2 \right].$$

(ii) Si μ es desconocido, un intervalo de confianza de nivel $(1 - \alpha)$ para σ^2 está dado por:

$$\left[\frac{1}{\chi_{n-1, \beta}^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \leq \sigma^2 \leq \frac{1}{\chi_{n-1, 1-\gamma}^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \right].$$

Demostración.

- (i) Sea $W = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2$. Como las variables $Y_i = \frac{(X_i - \mu)}{\sigma}$ son independientes, con distribución $N(0, 1)$ y $W = \sum_{i=1}^n Y_i^2$, entonces W tiene distribución χ_n^2 . Luego,

$$\mathbb{P}(\chi_{n,1-\gamma}^2 \leq W \leq \chi_{n,\beta}^2) = \mathbb{P}(W \geq \chi_{n,1-\gamma}^2) - \mathbb{P}(W > \chi_{n,\beta}^2) = 1 - \gamma - \beta = 1 - \alpha.$$

Entonces, una región de confianza a nivel $(1 - \alpha)$ está dada por

$$\left\{ \sigma^2 : \chi_{n,1-\gamma}^2 \leq \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \leq \chi_{n,\beta}^2 \right\} = \left\{ \sigma^2 : \frac{1}{\chi_{n,\beta}^2} \leq \sigma^2 \frac{1}{\sum_{i=1}^n (X_i - \mu)^2} \leq \frac{1}{\chi_{n,1-\gamma}^2} \right\}$$

esto es equivalente a la región

$$\left[\frac{1}{\chi_{n,\beta}^2} \sum_{i=1}^n (X_i - \mu)^2 \leq \sigma^2 \leq \frac{1}{\chi_{n,1-\gamma}^2} \sum_{i=1}^n (X_i - \mu)^2 \right].$$

- (ii) Sea $W = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ tal que $W \sim \chi_{n-1}^2$, por lo tanto

$$\mathbb{P}(\chi_{n-1,1-\gamma}^2 \leq W \leq \chi_{n-1,\beta}^2) = \mathbb{P}(W \geq \chi_{n-1,1-\gamma}^2) - \mathbb{P}(W > \chi_{n-1,\beta}^2) = 1 - \gamma - \beta = 1 - \alpha.$$

Entonces, una región de confianza a nivel $(1 - \alpha)$ está dada por

$$\left\{ \sigma^2 : \chi_{n-1,1-\gamma}^2 \leq \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \leq \chi_{n-1,\beta}^2 \right\} = \left\{ \sigma^2 : \frac{1}{\chi_{n-1,\beta}^2} \leq \sigma^2 \frac{1}{\sum_{i=1}^n (X_i - \bar{X}_n)^2} \leq \frac{1}{\chi_{n-1,1-\gamma}^2} \right\}$$

esto es equivalente a la región

$$\left[\frac{1}{\chi_{n-1,\beta}^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \leq \sigma^2 \leq \frac{1}{\chi_{n-1,1-\gamma}^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \right].$$

□

2.2. Procedimiento en dos pasos para encontrar un intervalo de longitud prefijada para la media de una $N(\mu, \sigma^2)$, μ y σ^2 desconocidos

Sea intervalo de confianza para μ cuando σ^2 es desconocido, la longitud de dicho intervalo, $\mathcal{L}(X_1, \dots, X_n)$, está dada por

$$\mathcal{L}(X_1, \dots, X_n) = 2\mathcal{T}_{n-1, \frac{\alpha}{2}} \frac{s}{\sqrt{n}}$$

Este intervalo tiene longitud variable, ya que depende de s , que es una variable aleatoria dependiente de los valores que toma la muestra. Luego, es imposible calcular n de modo que la longitud del intervalo sea igual a un número prefijado.

Como σ^2 no es conocida, no se podrá asegurar con una muestra de tamaño fijo una determinada precisión, es decir, una determinada longitud del intervalo. Una manera de solucionar este problema es tomando dos muestras, una inicial para estimar σ^2 , y en base a esta estimación, determinar el tamaño de otra muestra complementaria que nos permita obtener un intervalo con la longitud deseada.

Teorema 2.7. Sea una muestra inicial de tamaño fijo m , $X_1, \dots, X_m$ y sean $X_1, \dots, X_n$ variables aleatorias independientes con distribución $N(\mu, \sigma^2)$, donde n se elige de manera tal que satisfaga

$$2\mathcal{T}_{m-1, \frac{\alpha}{2}} \frac{s_m}{\sqrt{m+n}} \leq \mathcal{L}.$$

donde $s_m^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X}_m)^2$.

Luego el intervalo dado por

$$\left[\bar{X}_{m+n} - \mathcal{T}_{m-1, \frac{\alpha}{2}} \frac{s_m}{\sqrt{m+n}}; \bar{X}_{m+n} + \mathcal{T}_{m-1, \frac{\alpha}{2}} \frac{s_m}{\sqrt{m+n}} \right]$$

es un intervalo de confianza de nivel $(1 - \alpha)$ de longitud menor o igual que $\mathcal{L}$.

Demostración. Sean $W = \frac{(m-1)s_m^2}{\sigma^2}$ (con distribución χ_{m-1}^2) y $V = \frac{\sqrt{m+n}}{\sigma}(\bar{X}_{m+n} - \mu)$ cuya distribución conjunta se define por

$$F_{VW}(v, w) = \mathbb{P}(V \leq v, W \leq w).$$

Llamemos A_i al evento $\{n = i\}$. Los sucesos A_i son obviamente disjuntos y además $\bigcup_{i \in \mathbb{N}} A_i = \Omega$, donde Ω es el espacio muestral.

Dado un evento cualquiera A , se tiene

$$A = \bigcup_{i \in \mathbb{N}} A_i \cap A \Rightarrow \mathbb{P}(A) = \sum_{i \in \mathbb{N}} \mathbb{P}(A_i \cap A) \Rightarrow$$

$$F_{VW}(v, w) = \mathbb{P}(V \leq v, W \leq w) = \sum_{i \in \mathbb{N}_0} \mathbb{P}(V \leq v, W \leq w, n = i) = \sum_{i \in \mathbb{N}_0} \mathbb{P}\left(\sqrt{m+i} \frac{(\bar{X}_{m+i} - \mu)}{\sigma}, W \leq w, n = i\right)$$

Sabemos que $\sum_{j=1}^m X_j$ es independiente de s_m y, por otra parte, cada X_j con $j > m$ también es independiente de s_m . Por

lo tanto, como $\bar{X}_{m+i} = \frac{1}{m+i} \left(\sum_{j=1}^m X_j + \sum_{j=m+1}^{m+i} X_j \right)$ se deduce que $\bar{X}_{m+i}$ es independiente de s_m .

Por otro lado, de acuerdo con su definición, n depende sólo de s_m . Luego, el suceso $\left\{ \sqrt{m+i} \frac{(\bar{X}_{m+i} - \mu)}{\sigma} \leq v \right\}$ es independiente de $\{W \leq w\} \cap \{n = i\}$. Luego,

$$F_{VW}(v, w) = \sum_{i \in \mathbb{N}_0} \mathbb{P}\left(\sqrt{m+i} \frac{(\bar{X}_{m+i} - \mu)}{\sigma}\right) \mathbb{P}(W \leq w, n = i).$$

además, para cada i fijo $\sqrt{m+i} \frac{(\bar{X}_{m+i} - \mu)}{\sigma}$ tiene distribución $N(0, 1)$. Luego, si $\Phi(v)$ es la función de distribución de una variable $N(0, 1)$, se tendrá

$$F_{VW}(v, w) = \sum_{i \in \mathbb{N}_0} \Phi(v) \mathbb{P}(W \leq w, n = i) = \Phi(v) \underbrace{\sum_{i \in \mathbb{N}_0} \mathbb{P}(W \leq w, n = i)}_{=\mathbb{P}(W \leq w)} = \Phi(v) F_W(w)$$

y como $F_V(v) = \lim_{n \rightarrow \infty} F_{VW}(v, w) = \Phi(v) \lim_{n \rightarrow \infty} F_W(w) = \Phi(v)$, entonces $V = \frac{\sqrt{m+n}}{\sigma}(\bar{X}_{m+n} - \mu)$ tiene distribución $N(0, 1)$.

Por otra parte, se puede observar que si se reemplaza $\Phi(v)$ por $F_V(v)$ se obtiene que V y W son independientes. Entonces, teniendo en cuenta que

$$\frac{\sqrt{m+n}(\bar{X}_{m+n} - \mu)}{s_m} = \frac{\sqrt{m+n}(\bar{X}_{m+n} - \mu)/\sigma}{[(m-1)s_m^2/(m-1)\sigma^2]^{1/2}} := U$$

se puede deducir que U tiene distribución independiente de μ y σ^2 tal que, además,

$$\mathbb{P}\left(-\mathcal{T}_{m-1, \frac{\alpha}{2}} \leq U \leq \mathcal{T}_{m-1, \frac{\alpha}{2}}\right) = 1 - \alpha$$

Luego, de acuerdo con el método general para obtener regiones de confianza, se tendrá que una región de confianza para μ de nivel $(1 - \alpha)$ estará dada por:

$$\left\{ \mu : -\mathcal{T}_{m-1, \frac{\alpha}{2}} \leq \frac{\sqrt{m+n}(\bar{X}_{m+n} - \mu)}{s_m} \leq \mathcal{T}_{m-1, \frac{\alpha}{2}} \right\} = \left\{ \mu : \bar{X}_{m+n} - \mathcal{T}_{m-1, \frac{\alpha}{2}} \frac{s_m}{\sqrt{m+n}} \leq \mu \leq \bar{X}_{m+n} + \mathcal{T}_{m-1, \frac{\alpha}{2}} \frac{s_m}{\sqrt{m+n}} \right\}.$$

□

2.3. Optimalidad de los intervalos de confianza

Definición 2.8. Se dirá que una región $S(\mathbf{X})$ es insesgada si

$$\mathbb{P}_\theta(\theta \in S(\mathbf{X})) \geq \mathbb{P}_{\theta'}(\theta' \in S(\mathbf{X})), \quad \forall \theta, \theta' \in \Theta$$

Definición 2.9. Se dirá que un intervalo de confianza $S(\mathbf{X})$ es insesgado de mínima longitud esperada uniformemente en θ (IMLEU) con nivel $(1 - \alpha)$ si

(a) $S(\mathbf{X})$ es insesgado y tiene nivel $(1 - \alpha)$.

(b) Sea $S(\mathbf{X}) = [a(\mathbf{X}), b(\mathbf{X})]$. Luego, si $S'(\mathbf{X}) = [a'(\mathbf{X}), b'(\mathbf{X})]$ es otro intervalo insesgado de nivel $(1 - \alpha)$, se tiene

$$\mathbb{E}_\theta(b(\mathbf{X}) - a(\mathbf{X})) \leq \mathbb{E}_\theta(b'(\mathbf{X}) - a'(\mathbf{X})), \quad \forall \theta \in \Theta$$

2.4. Regiones de confianza con nivel asintótico $(1 - \alpha)$

Definición 2.10. Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria cuya distribución pertenece a la familia $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$. Se dice que $S_n(X_1, X_2, \dots, X_n)$ es una sucesión de regiones de confianza con nivel asintótico $(1 - \alpha)$ si:

$$\lim_{n \rightarrow \infty} \mathbb{P}_{\boldsymbol{\theta}}(\boldsymbol{\theta} \in S_n(X_1, X_2, \dots, X_n)) = 1 - \alpha, \quad \forall \boldsymbol{\theta} \in \Theta.$$

Teorema 2.11. Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria cuya distribución pertenece a la familia $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$. Supongamos que para cada n se tienen definidas funciones $U_n = G_n(X_1, X_2, \dots, X_n, \boldsymbol{\theta})$ tales que U_n converge a U en distribución, donde U es una variable aleatoria con distribución independiente de $\boldsymbol{\theta}$. Sean A y B puntos de continuidad de F_U , tales que $\mathbb{P}(A \leq U \leq B) = 1 - \alpha$. Definamos

$$S_n(X_1, X_2, \dots, X_n) = \{\boldsymbol{\theta} : A \leq G_n(X_1, X_2, \dots, X_n, \boldsymbol{\theta}) \leq B\}.$$

Luego, $S_n(X_1, X_2, \dots, X_n)$ es una sucesión de regiones de confianza con nivel asintótico $(1 - \alpha)$.

Demostración. $\mathbb{P}_{\boldsymbol{\theta}}(\boldsymbol{\theta} \in S_n(X_1, X_2, \dots, X_n)) = \mathbb{P}_{\boldsymbol{\theta}}(A \leq G_n(X_1, X_2, \dots, X_n, \boldsymbol{\theta}) \leq B) = \mathbb{P}_{\boldsymbol{\theta}}(A \leq U_n \leq B)$.

Luego,

$$\lim_{n \rightarrow \infty} \mathbb{P}_{\boldsymbol{\theta}}(\boldsymbol{\theta} \in S_n(X_1, X_2, \dots, X_n)) = \lim_{n \rightarrow \infty} \mathbb{P}_{\boldsymbol{\theta}}(A \leq U_n \leq B) = \mathbb{P}_{\boldsymbol{\theta}}(A \leq U \leq B) = \mathbb{P}(A \leq U \leq B) = 1 - \alpha.$$

□

2.5. Ejercicios

A lo largo de esta práctica puede usar los siguientes resultados sin probarlos.

- Si $X \sim N(\mu, \sigma^2)$, entonces $(X - \mu)/\sigma \sim N(0, 1)$.
- Si $X \sim N(0, 1)$, entonces $X^2 \sim \chi_1^2$. Además, si $Y \sim \chi_n^2$ y $Z \sim \chi_m^2$ son independientes, entonces $Y + Z \sim \chi_{n+m}^2$.
- Si $X \sim N(0, 1)$ y $Y \sim \chi_n$ son independientes, entonces $\frac{X}{\sqrt{Y/n}} \sim t_n$.
- Si $X_1, \dots, X_n$ son i.i.d. con distribución $N(\mu, \sigma^2)$, entonces $\bar{X}$ y $S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ son independientes. Además, $\frac{n-1}{\sigma^2} S_X^2 \sim \chi_{n-1}^2$.

2.5.1. Intervalos de Confianza de Nivel Exacto

1. Se trata de medir el período de un péndulo y se tiene un cronómetro de precisión conocida (es decir, se conoce la varianza del error). Se supone que las observaciones son de la forma $Y_i = \mu + \varepsilon_i$, donde los ε_i tienen distribución $N(0, 1/4)$ y son independientes. Los datos obtenidos son:

5,1 5,2 5,6 5,1 5,5 5,8 5,9 4,9 5,2 5,6

(Observar que la media muestral es 5,39 y la varianza muestral es 0,11)

- a) Encontrar un intervalo de confianza para μ de nivel 0,95 y probar que para esta muestra la estimación por intervalo (es decir, el intervalo de confianza observado) es $[5,08, 5,70]$.
- b) ¿Podría haber anticipado cuál era la longitud de dicho intervalo antes de conocer la muestra?
- c) ¿Cuál debería haber sido el tamaño de la muestra si se hubiera deseado que la longitud del intervalo fuese a lo sumo 0,10?
- d) Responder verdadero o falso y justificar: si tomamos una nueva observación, tendrá probabilidad 0,95 de pertenecer al intervalo $[5,08, 5,70]$.

Solución:

- (a) Sabemos que $Y_i \sim N(\mu, 1/4)$ y, por lo tanto, si $T = \bar{Y}_n - \mu$ entonces

$$T \sim N\left(\frac{n\mu}{n}, \frac{n}{4n^2}\right) - \mu = N\left(\mu, \frac{1}{4n}\right) - \mu = N\left(0, \frac{1}{4n}\right).$$

Entonces, $\sqrt{4n}T \sim N(0, 1)$ y tomando $A = z_{\alpha/2}$ y $B = -z_{\alpha/2}$ se tiene que

$$0,95 = p\left(z_{\alpha/2} \leq \sqrt{4n}T \leq -z_{\alpha/2}\right) = p\left(\bar{Y}_n - \frac{z_{\alpha/2}}{\sqrt{4n}} \geq \mu \geq \bar{Y}_n + \frac{z_{\alpha/2}}{\sqrt{4n}}\right)$$

$$\Rightarrow IC_{0,95}(\mu) = \left[\bar{Y}_n + \frac{z_{\alpha/2}}{\sqrt{4n}}, \bar{Y}_n - \frac{z_{\alpha/2}}{\sqrt{4n}}\right] \Rightarrow$$

$$C_{0,95}(\mu) = \left[\bar{Y}_n + \frac{z_{0,025}}{\sqrt{40}}, \bar{Y}_n - \frac{z_{0,025}}{\sqrt{40}}\right] = [\bar{Y}_n - 0,31, \bar{Y}_n + 0,31] = [5,08; 5,7]$$

(c) Buscamos que $Long(IC) = -2 \frac{z_{0,025}}{\sqrt{4n}} \leq 0,1$. Luego,

$$-2 \frac{z_{0,025}}{\sqrt{4n}} \leq 0,1 \Leftrightarrow \frac{1,96}{0,1} \leq \sqrt{n} \Leftrightarrow 19,6 \leq \sqrt{n} \Leftrightarrow 385 \leq n$$

2. Sea $X_1, \dots, X_n$ una muestra aleatoria de una población con distribución $N(\mu, \sigma_0^2)$ (σ_0^2 conocido). Supóngase que se pide un intervalo de confianza para μ de nivel $1 - \alpha$. Mostrar que al elegir $A = z_{\frac{\alpha}{2}}$ y $B = -z_{\frac{\alpha}{2}}$ se obtiene el intervalo de longitud mínima entre los contruidos considerando $A = z_\beta$ y $B = z_{1-\delta}$, con $\beta + \delta = \alpha$.

Solución: Sea $T = \frac{1}{\sigma_0^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi_n^2$. Luego,

$$\begin{aligned} 1 - \alpha &= p(A \leq T \leq B) = p\left(A \leq \frac{1}{\sigma_0^2} \sum_{i=1}^n (X_i - \mu)^2 \leq B\right) = p\left(A\sigma_0^2 \leq \sum_{i=1}^n (X_i - \mu)^2 \leq B\sigma_0^2\right) \Rightarrow \\ 1 - \alpha &= p\left(A\sigma_0^2 \leq \sum_{i=1}^n (X_i - \bar{X}_n + \bar{X}_n - \mu)^2 \leq B\sigma_0^2\right) = p\left(A\sigma_0^2 \leq \sum_{i=1}^n (X_i - \bar{X}_n)^2 + n(\bar{X}_n - \mu)^2 \leq B\sigma_0^2\right) \Rightarrow \\ 1 - \alpha &= p\left[\frac{1}{n} \left(A\sigma_0^2 - \sum_{i=1}^n (X_i - \bar{X}_n)^2\right) \leq (\bar{X}_n - \mu)^2 \leq \frac{1}{n} \left(B\sigma_0^2 - \sum_{i=1}^n (X_i - \bar{X}_n)^2\right)\right] \end{aligned}$$

3. La distribución del índice de colesterol en cierta población es $N(\mu, \sigma^2)$, donde μ y σ^2 son desconocidos. Se hacen análisis a 25 personas elegidas al azar entre esta población y se obtienen los siguientes valores:

1,52	1,65	1,72	1,65	1,72	1,83	1,62	1,75	1,72	1,68	1,51	1,65	1,58
1,65	1,61	1,70	1,60	1,73	1,61	1,52	1,81	1,72	1,50	1,82	1,65	

- Encontrar un intervalo de confianza para μ de nivel 0,95. ¿Es cierto que su longitud no depende de la muestra?
- ¿Cuántos datos adicionales deben obtenerse para poder construir un intervalo de confianza para μ de nivel 0,95, pero con una longitud no mayor que 0,05? ¿Qué forma tendrían este intervalo?
- Encontrar un intervalo de confianza para σ de nivel 0,90.
- Encontrar un intervalo de confianza para $\exp(-\mu)$ de nivel 0,95.

Solución:

- (a) Sea el estadístico $T = \frac{\sqrt{n}}{s}(\bar{X}_n - \mu) \sim t_{n-1}$ y buscamos A y B tal que $p(A \leq T \leq B) = 0,95$.

Luego, si $A = t_{n-1, \alpha/2}$ y $B = -t_{n-1, \alpha/2}$, entonces

$$1 - 0,05 = p(A \leq T \leq B) = F_{t_{n-1}}(B) - F_{t_{n-1}}(A) = 1 - \alpha/2 - \alpha/2 = 1 - \alpha.$$

$$0,95 = p(t_{n-1, \alpha/2} \leq T \leq -t_{n-1, \alpha/2}) = p\left(\frac{s}{\sqrt{n}} t_{n-1, \alpha/2} \leq \bar{X}_n - \mu \leq -\frac{s}{\sqrt{n}} t_{n-1, \alpha/2}\right) \Rightarrow$$

$$0,95 = p\left(\bar{X}_n + \frac{s}{\sqrt{n}} t_{n-1, \alpha/2} \geq \mu \geq \bar{X}_n - \frac{s}{\sqrt{n}} t_{n-1, \alpha/2}\right) \Rightarrow IC_{0,95}(\mu) = \left[\bar{X}_n - \frac{s}{\sqrt{n}} t_{n-1, \alpha/2}, \bar{X}_n + \frac{s}{\sqrt{n}} t_{n-1, \alpha/2}\right].$$

- (c) Sea el estadístico $T = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \sim \chi_{n-1}^2$ y buscamos A y B tal que $p(A \leq T \leq B) = 0,90$.

Luego, si $A = \chi_{n-1, 1-\alpha/2}^2$ y $B = \chi_{n-1, \alpha/2}^2$ (ambos positivos), entonces

$$p(A \leq T \leq B) = F_{\chi_{n-1}^2}(B) - F_{\chi_{n-1}^2}(A) = 1 - \alpha/2 - (1 - (1 - \alpha/2)) = 1 - \alpha.$$

$$0,90 = p(A \leq T \leq B) = p\left(A \leq \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \leq B\right) = p\left(\frac{1}{A} \geq \frac{\sigma^2}{\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2} \geq \frac{1}{B}\right) \Rightarrow$$

$$0,90 = p\left(\frac{1}{A} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \geq \sigma^2 \geq \frac{1}{B} \sum_{i=1}^n (X_i - \bar{X}_n)^2\right) = p\left(\sqrt{\frac{1}{A} \sum_{i=1}^n (X_i - \bar{X}_n)^2} \geq \sigma \geq \sqrt{\frac{1}{B} \sum_{i=1}^n (X_i - \bar{X}_n)^2}\right).$$

$$\Rightarrow IC_{0,90}(\sigma) = \left[\sqrt{\frac{1}{\chi_{n-1, \alpha/2}^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2}, \sqrt{\frac{1}{\chi_{n-1, 1-\alpha/2}^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2}\right].$$

(d) Por el inciso (a), sabemos que

$$\begin{aligned} 0,95 &= p\left(\frac{s}{\sqrt{n}}t_{n-1,\alpha/2} \leq \overline{X}_n - \mu \leq -\frac{s}{\sqrt{n}}t_{n-1,\alpha/2}\right) = p\left(-\overline{X}_n + \frac{s}{\sqrt{n}}t_{n-1,\alpha/2} \leq -\mu \leq -\overline{X}_n - \frac{s}{\sqrt{n}}t_{n-1,\alpha/2}\right) \Rightarrow \\ 0,95 &= p\left[\exp\left\{-\overline{X}_n + \frac{s}{\sqrt{n}}t_{n-1,\alpha/2}\right\} \leq e^{-\mu} \leq \exp\left\{-\overline{X}_n - \frac{s}{\sqrt{n}}t_{n-1,\alpha/2}\right\}\right]. \\ \Rightarrow IC_{0,95}(\mu) &= \left[\exp\left\{-\overline{X}_n + \frac{s}{\sqrt{n}}t_{n-1,\alpha/2}\right\}, \exp\left\{-\overline{X}_n - \frac{s}{\sqrt{n}}t_{n-1,\alpha/2}\right\}\right]. \end{aligned}$$

4. a) Probar que si X tiene distribución $\varepsilon(\lambda)$, entonces $Y = 2\lambda X$ tiene distribución χ^2_2 .

b) Sean $X_1, \dots, X_n$ una muestra aleatoria de una población con distribución $\varepsilon(\lambda)$. Mostrar que $T = 2\lambda \sum_{i=1}^n X_i$ tiene distribución χ^2_{2n} .

c) En base a b) hallar una familia de intervalos de confianza para λ de nivel $1 - \alpha$.

Solución:

(a) Como $X \sim \varepsilon(\lambda) \Rightarrow X \sim \Gamma(1, \lambda) \Rightarrow 2\lambda X \sim \Gamma\left(1, \frac{\lambda}{2\lambda}\right) = \Gamma\left(\frac{2}{2}, \frac{1}{2}\right) = \chi^2_2$.

(b) Sabemos que $\sum_{i=1}^n X_i \sim \Gamma(n, \lambda) \Rightarrow 2\lambda \sum_{i=1}^n X_i \sim \Gamma\left(n, \frac{\lambda}{2\lambda}\right) = \Gamma\left(\frac{2n}{2}, \frac{1}{2}\right) = \chi^2_{2n}$.

(c) Sea el estadístico $T = 2\lambda \sum_{i=1}^n X_i \sim \chi^2_{2n}$. Luego, si $A = \chi^2_{2n, 1-\beta}$ y $B = \chi^2_{2n, \gamma}$ (ambos positivos) tal que $\beta + \gamma = \alpha$, entonces

$$p(A \leq T \leq B) = F_{\chi^2_{2n}}(B) - F_{\chi^2_{2n}}(A) = 1 - \gamma - (1 - (1 - \beta)) = 1 - \gamma - \beta = 1 - \alpha.$$

$$1 - \alpha = p(A \leq T \leq B) = p\left(A \leq 2\lambda \sum_{i=1}^n X_i \leq B\right) = p\left(\frac{A}{\sum_{i=1}^n X_i} \leq \lambda \leq \frac{B}{\sum_{i=1}^n X_i}\right).$$

$$\Rightarrow IC_{1-\alpha}(\lambda) = \left[\frac{\chi^2_{2n, 1-\beta}}{\sum_{i=1}^n X_i}, \frac{\chi^2_{2n, \gamma}}{\sum_{i=1}^n X_i} \right].$$

5. Sean $X_1, \dots, X_n$ una muestra aleatoria con distribución $U[0, \theta]$ y sea $T = \max(X_1, \dots, X_n) = X^{(n)}$.

a) Mostrar que T/θ tiene distribución independiente de θ .

b) Usando a) hallar un intervalo de confianza de longitud mínima para θ de nivel $1 - \alpha$.

Solución:

$$(a) \quad p\left(\frac{T}{\theta} \leq t\right) = p(T \leq t\theta) = p(X^{(n)} \leq t\theta) \underset{i.i.d.}{=} p(X_1 \leq t\theta)^n = \begin{cases} 0 & t\theta \leq 0 \\ t^n & t\theta \in [0, \theta] \\ 1 & t\theta > \theta \end{cases}.$$

Luego, $\frac{T}{\theta} \sim F$ que no depende de θ .

(b) Buscamos A y B tal que $p\left(A \leq \frac{T}{\theta} \leq B\right) = 1 - \alpha$. Sea, entonces, A y B tales que $p\left(\frac{T}{\theta} \leq A\right) = \beta$ y $p\left(\frac{T}{\theta} \geq B\right) = \gamma$ con $\beta + \gamma = \alpha$.

Luego, $p\left(A \leq \frac{T}{\theta} \leq B\right) = F(B) - F(A) = 1 - \gamma - \beta = 1 - \alpha$.

$$p\left(A \leq \frac{T}{\theta} \leq B\right) = p\left(\frac{1}{A} \geq \frac{\theta}{T} \geq \frac{1}{B}\right) = p\left(\frac{X^{(n)}}{A} \geq \theta \geq \frac{X^{(n)}}{B}\right) \Rightarrow IC_{1-\alpha}(\theta) = \left[\frac{X^{(n)}}{B}, \frac{X^{(n)}}{A}\right].$$

Finalmente, para minimizar la longitud del intervalo de confianza basta con minimizar

$$\frac{1}{F^{-1}(\beta)} - \frac{1}{F^{-1}(1-\gamma)}.$$

6. Se desea comparar los rendimientos de dos variedades de trigo A y B . Se han cultivado 15 parcelas elegidas al azar con la variedad A y 20 con la variedad B , obteniéndose los siguientes rendimientos por hectárea:

Var. A:	250	252	245	258	240	247	251	249	250	243	247	260	238	241	239
Var. B:	330	335	327	329	320	332	337	328	334	326	331	332	328	329	337
	341	336	338	325	321										

Se supone que los rendimientos de la variedad A tienen distribución $N(\mu_1, \sigma^2)$ y los de la otra variedad $N(\mu_2, \sigma^2)$, independientes entre sí. Notar que ambas muestras tienen la misma varianza (desconocida).

- Hallar un intervalo de confianza para $\mu_1 - \mu_2$ de nivel 0,99.
- ¿Qué le sugeriría el hecho de que el 0 no pertenezca al intervalo hallado? ¿Qué pensaría en caso contrario?

Sugerencia: Probar que si $X_1, \dots, X_n$ son i.i.d. con distribución $N(\mu_1, \sigma^2)$ y $Y_1, \dots, Y_m$ son i.i.d. con distribución $N(\mu_2, \sigma^2)$ (también independientes de las X_i), entonces

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sigma \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim N(0, 1) \quad \text{y} \quad \frac{(n-1)S_1^2 + (m-1)S_2^2}{\sigma^2} \sim \chi_{n+m-2}^2, \quad (2.1)$$

donde $S_1^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ y $S_2^2 = \frac{1}{m-1} \sum_{i=1}^m (Y_i - \bar{Y})^2$. Probar también que ambas cantidades en (2.1) son independientes y deducir que

$$\sqrt{\frac{nm}{n+m}} \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_P} \sim t_{n+m-2},$$

donde $S_P^2 = ((n-1)S_1^2 + (m-1)S_2^2)/(n+m-2)$ es la varianza muestral “ponderada”.

7. Se tienen dos variedades de trigo A y B . Se eligen al azar 15 parcelas, y cada una de ellas se divide en dos partes iguales. En una parte se cultiva la variedad A y en la otra la B . Se obtienen así 15 pares de datos:

Parcela:	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Var. A:	41	37	36	39	44	42	38	37	35	32	39	30	40	41	37
Var. B:	39	35,3	33,5	36	42,5	38	36	34,8	33,2	29	29	36,6	28,4	38,5	39

Sea X_i el rendimiento de la variedad A en la parcela i y Y_i el rendimiento de la variedad B en la misma parcela. Se supone que (X_i, Y_i) , $1 \leq i \leq 15$, es una muestra de una distribución normal bivariada con parámetros desconocidos. Hallar un intervalo de confianza para $\mu_X - \mu_Y$ de nivel 0,95.

Solución:

Sean $Z_i = X_i - Y_i$ tal que $Z_i \sim N(\mu_X - \mu_Y, \sigma_z^2)$ y el estadístico $T = \frac{\sqrt{n}}{s_z} (\bar{Z} - (\mu_X - \mu_Y)) \sim t_{n-1}$.

Definiendo $A = t_{n-1, 1-\alpha/2}$ y $B = t_{n-1, \alpha/2}$ se tiene que

$$\begin{aligned} 1 - \alpha &= p(A \leq T \leq B) = p\left(A \leq \frac{\sqrt{15}}{\frac{1}{14} \sum_{i=1}^{15} (Z_i - \bar{Z})^2} (\bar{Z} - (\mu_X - \mu_Y)) \leq B\right) \Rightarrow \\ 1 - \alpha &= p\left(-\frac{A}{14\sqrt{15}} \sum_{i=1}^{15} (Z_i - \bar{Z})^2 + \bar{Z} \geq \mu_X - \mu_Y \geq \bar{Z} - \frac{B}{14\sqrt{15}} \sum_{i=1}^{15} (Z_i - \bar{Z})^2\right). \\ \Rightarrow IC_{0,95}(\mu_X - \mu_Y) &= \left[\bar{Z} - \frac{t_{n-1, \alpha/2}}{14\sqrt{15}} \sum_{i=1}^{15} (Z_i - \bar{Z})^2, \bar{Z} - \frac{t_{n-1, 1-\alpha/2}}{14\sqrt{15}} \sum_{i=1}^{15} (Z_i - \bar{Z})^2\right]. \end{aligned}$$

2.5.2. Intervalos de Confianza de Nivel Asintótico

- Dada una muestra aleatoria de una distribución $Bi(1, p)$, construir un intervalo de confianza de nivel asintótico $1 - \alpha$.
 - Una droga cura cierta enfermedad con probabilidad p . En una prueba con 100 enfermos, se curaron 30.
 - Hallar un intervalo de confianza para p de nivel asintótico 0,95.
 - ¿Qué tamaño de muestra debería tomarse si se desea una longitud menor que 0,1?

Solución:

- (a) Sean $X_1, \dots, X_n$ una muestra aleatoria tal que para todo $i \in \{1, \dots, n\}$ se tiene que $X_i \sim Bi(1, p)$.

Por Teorema Central del Límite y usando Slutsky se sabe que $\frac{\sqrt{n}(\bar{X}_n - p)}{s} \xrightarrow[n \rightarrow \infty]{D} N(0, 1)$.

Entonces, busquemos A y B tal que

$$p\left(A \leq \frac{\sqrt{n}(\bar{X}_n - p)}{s} \leq B\right) \xrightarrow[n \rightarrow \infty]{} 1 - \alpha.$$

Si $A = -z_{\alpha/2}$ y $B = z_{\alpha/2}$, entonces

$$\begin{aligned} p\left(-z_{\alpha/2} \leq \frac{\sqrt{n}(\bar{X}_n - p)}{s} \leq z_{\alpha/2}\right) &= p\left(-\frac{s}{\sqrt{n}} z_{\alpha/2} \leq (\bar{X}_n - p) \leq \frac{s}{\sqrt{n}} z_{\alpha/2}\right) \Rightarrow \\ p\left(\frac{s}{\sqrt{n}} z_{\alpha/2} + \bar{X}_n \geq p \geq -\frac{s}{\sqrt{n}} z_{\alpha/2} + \bar{X}_n\right) &\xrightarrow[n \rightarrow \infty]{} 1 - \alpha \Rightarrow IC_{1-\alpha}(p) = \left[-\frac{s}{\sqrt{n}} z_{\alpha/2} + \bar{X}_n, \frac{s}{\sqrt{n}} z_{\alpha/2} + \bar{X}_n\right]. \end{aligned}$$

- (b) Sea la variable $X_i \sim Be(p)$ para todo $i \in \{1, \dots, 100\}$ definida como $X_i = \begin{cases} 1 & \text{si el paciente } i \text{ se cura} \\ 0 & \text{cc} \end{cases}$.

Sea $z_{\alpha/2} = 1,96$, $n = 100$, $\bar{X}_n = \frac{3}{10}$ y $s = \sqrt{\bar{X}_n(1 - \bar{X}_n)} = \sqrt{\frac{3}{10}(1 - \frac{3}{10})} \approx 0,4582$. Luego, por el inciso anterior

$$IC_{0,95}(p) = \left[\frac{3}{10} - \frac{1,96 \cdot 0,4582}{\sqrt{100}}, \frac{3}{10} + \frac{1,96 \cdot 0,4582}{\sqrt{100}}\right] = [0,2101; 0,3898].$$

Por otra parte, si quisiéramos que la longitud de dicho intervalo sea menor que 0,1 busquemos que

$$0,1 > \frac{2 \cdot s \cdot z_{\alpha/2}}{\sqrt{n}} = \frac{2 \cdot 0,4582 \cdot 1,96}{\sqrt{n}} = \frac{1,796}{\sqrt{n}} \Rightarrow n > \sqrt{17,96} \approx 4,237.$$

2. a) Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución $\mathcal{P}(\lambda)$. Hallar un intervalo de confianza para λ de nivel asintótico $1 - \alpha$.
b) El número de llamadas diarias a una central telefónica sigue un proceso de Poisson con media λ . Se ha registrado el número de llamadas durante 20 días, obteniéndose los siguientes valores:

35	41	38	40	34	36	41	48	42	46
39	37	41	35	37	38	42	43	44	67

Hallar un intervalo de confianza para λ de nivel asintótico 0.90.

Solución:

- (a) Por Teorema Central del Límite y usando Slutsky se sabe que $\frac{\sqrt{n}(\bar{X}_n - \lambda)}{\sqrt{\bar{X}_n}} \xrightarrow[n \rightarrow \infty]{D} N(0, 1)$ puesto que como

$$\bar{X}_n \xrightarrow[n \rightarrow \infty]{P} \lambda, \text{ entonces } \sqrt{\bar{X}_n} \xrightarrow[n \rightarrow \infty]{P} \sqrt{\lambda}.$$

Busquemos A y B tal que

$$p\left(A \leq \frac{\sqrt{n}(\bar{X}_n - \lambda)}{\sqrt{\bar{X}_n}} \leq B\right) \xrightarrow[n \rightarrow \infty]{} 1 - \alpha.$$

Si $A = -z_{\alpha/2}$ y $B = z_{\alpha/2}$, entonces

$$\begin{aligned} p\left(-\frac{\sqrt{\bar{X}_n}}{\sqrt{n}} z_{\alpha/2} \leq (\bar{X}_n - \lambda) \leq \frac{\sqrt{\bar{X}_n}}{\sqrt{n}} z_{\alpha/2}\right) &= p\left(\bar{X}_n + \frac{\sqrt{\bar{X}_n}}{\sqrt{n}} z_{\alpha/2} \geq \lambda \geq \bar{X}_n - \frac{\sqrt{\bar{X}_n}}{\sqrt{n}} z_{\alpha/2}\right) \xrightarrow[n \rightarrow \infty]{} 1 - \alpha. \\ \Rightarrow IC_{1-\alpha}(\lambda) &= \left[\bar{X}_n - \frac{\sqrt{\bar{X}_n}}{\sqrt{n}} z_{\alpha/2}, \bar{X}_n + \frac{\sqrt{\bar{X}_n}}{\sqrt{n}} z_{\alpha/2}\right]. \end{aligned}$$

- (b) Sea $n = 20$, $z_{\alpha/2} = 1,65$ y $\bar{X}_n = 41,20$ entonces

$$IC_{0,90}(\lambda) = \left[41,2 - \frac{1,65}{\sqrt{20}} 6,4187, 41,2 + \frac{1,65}{\sqrt{20}} 6,4187\right] = [38,83; 43,56].$$

3. a) Supóngase que $X_1, \dots, X_{n_1}$ es una m.a. de una distribución $N(\mu_1, \sigma_1^2)$ y que $Y_1, \dots, Y_{n_2}$ es una m.a. de una distribución $N(\mu_2, \sigma_2^2)$, independiente de la anterior. Mostrar que

$$\frac{\overline{X_n} - \overline{Y_n} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \xrightarrow[n \rightarrow \infty]{D} N(0, 1)$$

cuando $n_1 \rightarrow \infty$ y $n_2 \rightarrow \infty$ de modo que $n_1/n_2 \rightarrow \lambda$ constante.

- b) Hallar un intervalo de confianza de nivel asintótico $(1 - \alpha)$ para $\mu_1 - \mu_2$.

Solución:

- (a) Por Teorema Central del Límite, sabemos que

$$\frac{\sqrt{n_1}(\overline{X_n} - \mu_1)}{\sqrt{\sigma_1^2}} \xrightarrow[n \rightarrow \infty]{D} N(0, 1) \quad \text{y} \quad \frac{\sqrt{n_2}(\overline{Y_n} - \mu_2)}{\sqrt{\sigma_2^2}} \xrightarrow[n \rightarrow \infty]{D} N(0, 1)$$

entonces,

$$(\overline{X_n} - \mu_1) \xrightarrow[n \rightarrow \infty]{D} N\left(0, \frac{\sigma_1^2}{n_1}\right) \quad \text{y} \quad (\overline{Y_n} - \mu_2) \xrightarrow[n \rightarrow \infty]{D} N\left(0, \frac{\sigma_2^2}{n_2}\right)$$

por independencia y usando Slutsky

$$\begin{aligned} (\overline{X_n} - \mu_1) - (\overline{Y_n} - \mu_2) &\xrightarrow[n \rightarrow \infty]{D} N\left(0, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right) \Rightarrow \\ (\overline{X_n} - \overline{Y_n}) - (\mu_1 - \mu_2) &\xrightarrow[n \rightarrow \infty]{D} \left(\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}\right) N(0, 1) \Rightarrow \frac{\overline{X_n} - \overline{Y_n} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \xrightarrow[n \rightarrow \infty]{D} N(0, 1). \end{aligned}$$

- (b) Sea $A = -z_{\alpha/2}$ y $B = z_{\alpha/2}$ entonces

$$\begin{aligned} p \left(-z_{\alpha/2} \leq \frac{\overline{X_n} - \overline{Y_n} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \leq z_{\alpha/2} \right) &\xrightarrow[n \rightarrow \infty]{} 1 - \alpha \Rightarrow \\ p \left(-z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \leq \overline{X_n} - \overline{Y_n} - (\mu_1 - \mu_2) \leq z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right) &\Rightarrow \\ p \left(z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} + (\overline{X_n} - \overline{Y_n}) \geq \mu_1 - \mu_2 \geq (\overline{X_n} - \overline{Y_n}) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right) &\xrightarrow[n \rightarrow \infty]{} 1 - \alpha \\ \Rightarrow IC_{1-\alpha}(\mu_1 - \mu_2) &= \left[(\overline{X_n} - \overline{Y_n}) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} + (\overline{X_n} - \overline{Y_n}) \right] \end{aligned}$$

4. (Para hacer con el R) Realizar el siguiente estudio de simulación. Generar una muestra aleatoria de variables $X_1, \dots, X_n \sim Bi(1, p)$. Para esta muestra, construir los dos intervalos de confianza para p de nivel asintótico 0,95 vistos en clase. Repetir todo este procedimiento k veces, obteniendo así k muestras independientes y k intervalos para cada uno de los dos métodos.

- Método 1: de nivel asintótico cuando se sustituye el valor de p en la varianza por $\bar{X}$.
- Método 2: de nivel asintótico cuando no se sustituye a p y se calcula los extremos del intervalo como raíces de una cuadrática.

Tomar $k = 2000$ y los siguientes valores de n y p .

- $n = 20; 50; 100$.
- $p = 0,10; 0,50$.

Para cada muestra, guardar los siguientes resultados: el intervalo de confianza obtenido, la longitud de dicho intervalo, un 1 si el IC hallado contiene al verdadero valor de p y un 0 en caso contrario.

Para cada combinación de n y p :

- a) Estimar la longitud esperada para ambos métodos.
- b) Estimar la probabilidad de cobertura para ambos métodos.
- c) Sacar conclusiones.

2.5.3. Intervalos Bootstrap

Es muy común querer calcular un intervalo de confianza para un cierto parámetro θ basándonos en un estimador $\hat{\theta}$. El problema es que muchas veces la distribución (exacta o asintótica) de $\hat{\theta}$ no es conocida o contiene parámetros que desconocemos. Vamos a considerar los siguientes dos métodos:

- **Método 1.** Supongamos que $\hat{\theta}$ tiene distribución aproximadamente normal con media θ . Luego, un intervalo de nivel aproximado $1 - \alpha$ es

$$[\hat{\theta} - z_{\alpha/2}\sqrt{v^2}, \hat{\theta} + z_{\alpha/2}\sqrt{v^2}],$$

donde v^2 es un estimador de la varianza de $\hat{\theta}$. Por otra parte, el estimador v^2 puede obtenerse con Bootstrap, es decir, considerando realizaciones $\hat{\theta}_1^*, \dots, \hat{\theta}_{n_{boot}}^*$ del estimador basadas en remuestreos de la distribución empírica y tomando $v^2 = \mathbb{V}(\hat{\theta}_1^*, \dots, \hat{\theta}_{n_{boot}}^*)$.

- **Método 2.** Se consideran realizaciones $\hat{\theta}_1^*, \dots, \hat{\theta}_{n_{boot}}^*$ del estimador $\hat{\theta}$ obtenidos haciendo Bootstrap como en el método anterior. Luego, un posible intervalo de nivel aproximado $1 - \alpha$ es

$$[\hat{\theta}_{(\alpha/2)}^*, \hat{\theta}_{(1-\alpha/2)}^*],$$

donde $\hat{\theta}_{(\gamma)}^*$ es el γ -percentil de la muestra $\hat{\theta}_1^*, \dots, \hat{\theta}_{n_{boot}}^*$.

1. (Para hacer con el R) (Intervalos de confianza bootstrap para la mediana)

- a) Se quiere hacer intervalos de confianza para la mediana m de una distribución X usando a la mediana muestral como estimador. Para eso, implementar dos funciones `boot.metodo.1` y `boot.metodo.2` que tengan como input el nivel $1 - \alpha$ y datos $x_1, \dots, x_n$ y devuelvan el intervalo de confianza siguiendo la estrategia del método correspondiente.
- b) Para cada $n = 30, 50, 100, 1000$, generar 1000 muestras de una distribución $N(0, 1)$ y para cada una de ellas obtener los intervalos de nivel 0,95 con el método 1. Luego, para cada n completar la siguiente tabla. Hacer lo

	n=30	n=50	n=100	n=1000
Longitud promedio				
Proporción de cubrimiento				

mismo para el método 2 y comparar ambos métodos.

- c) Repetir el ítem anterior para muestras de distribución Cauchy (también llamada t_1). Esta distribución es simétrica respecto del 0 y no tiene esperanza finita.
2. (Para hacer con el R) Modificando levemente el código del ejercicio anterior, obtener intervalos de confianza de nivel 0,95 para los percentiles 0,25, 0,5 y 0,75 del precio del ticket del Titanic (usar los datos que están subidos a la página de la materia).

Capítulo 3

Tests de hipótesis

Un test de hipótesis es una manera formal de decidir entre dos opciones, es decir, es una manera de distinguir entre distribuciones de probabilidad en base a variables aleatorias generadas por una de ellas.

3.1. Formulación general del problema del test de hipótesis

Definición 3.1. Supongamos que se obtiene un vector aleatorio $\mathbf{X} = (X_1, \dots, X_n)$ cuya función de distribución pertenece a la familia $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta \subset \mathbb{R}^p$. Sean Θ_1 y Θ_2 tales que $\Theta_1 \cap \Theta_2 = \emptyset$ y $\Theta_1 \cup \Theta_2 = \Theta$. Un test para este problema será una regla basada en $\mathbf{X}$ para decidir entre las dos hipótesis

$$H : \boldsymbol{\theta} \in \Theta_1 \text{ contra } K : \boldsymbol{\theta} \in \Theta_2$$

Se llama test a una función $\varphi : \mathbb{R}^n \rightarrow [0, 1]$.

Se dice que un test φ es no aleatorizado si toma solamente los valores 0 o 1.

Observación 3.2.

(i) Cuando $\varphi(\mathbf{X}) = 1$ se rechazará la hipótesis H y, por lo tanto, se aceptará K . En cambio, $\varphi(\mathbf{X}) = 0$ indicará que se acepta H .

Si el test toma valores distintos de 0 y 1 se dice que es un test aleatorizado. En este caso, el valor $\varphi(\mathbf{x}) = 1$ indica con que probabilidad se rechaza H si se observa $\mathbf{X} = \mathbf{x}$, es decir, $\varphi(\mathbf{x}) = \mathbb{P}(\text{rechazar } H | \mathbf{X} = \mathbf{x})$.

(ii) En la mayoría de las situaciones, los tests vienen dados como funciones de un estadístico, llamado estadístico del test. En general, el estadístico del test sirve para medir la diferencia entre los datos y lo que se espera de ellos bajo H .

Definición 3.3. La región crítica $\mathcal{R}$ de un test φ es el conjunto de puntos $\mathbf{X}$ que llevan a la decisión de rechazar H y la región de aceptación $\mathcal{A}$ es el conjunto de puntos $\mathbf{X}$ que llevan a aceptar H .

Definición 3.4. Se llamará error de tipo I al que se comete al rechazar la hipótesis H , cuando es verdadera.

Se llamará error de tipo II al que se comete al aceptar H , cuando esta hipótesis es falsa.

Observación 3.5.

(i) Para un test no aleatorizado, la probabilidad de cometer un error de tipo I será $\mathbb{P}_{\boldsymbol{\theta}}(\mathcal{R})$, cuando $\boldsymbol{\theta} \in \Theta_1$. Mientras que la probabilidad de error de tipo II, $\mathbb{P}_{\boldsymbol{\theta}}(\mathcal{A}) = 1 - \mathbb{P}_{\boldsymbol{\theta}}(\mathcal{R})$, cuando $\boldsymbol{\theta} \in \Theta_2$.

(ii) El test se basa en un estadístico cuya distribución es conocida cuando H es cierta. Conocer esa distribución hace posible definir la región de rechazo que tendrá probabilidad α prefijada bajo H . El valor elegido como cota o punto de corte para tomar la decisión se llama valor crítico y, por lo tanto, separa la región de aceptación de la región de rechazo.

Definición 3.6. Sea $\varphi(\mathbf{X})$ un test para las hipótesis

$$H : \boldsymbol{\theta} \in \Theta_1 \text{ contra } K : \boldsymbol{\theta} \in \Theta_2.$$

entonces, se llama función de potencia del test $\varphi(\mathbf{X})$ a la función

$$\beta_{\varphi}(\boldsymbol{\theta}) = \mathbb{P}_{\boldsymbol{\theta}}(\text{rechazar } H),$$

donde $\mathbb{P}_{\boldsymbol{\theta}}$ indica la probabilidad cuando $\boldsymbol{\theta}$ es el valor verdadero.

Observación 3.7.

(i) En general, $\beta_\varphi(\boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{\theta}}(\varphi(\mathbf{X}))$.

Es decir, en el caso que φ es un test no aleatorizado se tiene

$$\beta_\varphi(\boldsymbol{\theta}) = \mathbb{P}_{\boldsymbol{\theta}}(\varphi(\mathbf{X}) = 1) = \mathbb{E}_{\boldsymbol{\theta}}(\varphi(\mathbf{X}))$$

Si φ es aleatorizado, $\varphi(\mathbf{X})$ puede interpretarse como la probabilidad de rechazar H , condicional a observar $\mathbf{X}$; luego se tiene

$$\varphi(\mathbf{X}) = \mathbb{P}(\text{rechazar } H | \mathbf{X}) \Rightarrow \beta_\varphi(\boldsymbol{\theta}) = \mathbb{P}_{\boldsymbol{\theta}}(\text{rechazar } H) = \mathbb{E}_{\boldsymbol{\theta}}(\mathbb{P}(\text{rechazar } H | \mathbf{X})) = \mathbb{E}_{\boldsymbol{\theta}}(\varphi(\mathbf{X})).$$

(ii) Expresemos ahora las probabilidades de los errores de un test en términos de $\beta_\varphi(\boldsymbol{\theta})$,

(a) La probabilidad que ocurra un error de tipo I será $\beta_\varphi(\boldsymbol{\theta})$ para $\boldsymbol{\theta} \in \Theta_1$.

(b) La probabilidad que ocurra un error de tipo II será $(1 - \beta_\varphi(\boldsymbol{\theta}))$ para $\boldsymbol{\theta} \in \Theta_2$.

(iii) Un buen test deberá tener errores de tipo I y II pequeños y, por lo tanto, debe tener una función de potencia $\beta_\varphi(\boldsymbol{\theta})$ que tome valores cercanos a 0 para $\boldsymbol{\theta} \in \Theta_1$ y valores cercanos a 1 para $\boldsymbol{\theta} \in \Theta_2$.

En realidad, no podemos hacer ambos errores pequeños simultáneamente. Más aún, para un tamaño de muestra dado para que decrezca la probabilidad de que ocurra un error de tipo I, debemos aumentar la probabilidad de que ocurra un error de tipo II (o sea disminuir la potencia). Si queremos que ambos sean pequeños debemos aumentar la cantidad de observaciones.

3.2. Nivel de significación de un test

Definición 3.8. El nivel de significación de un test φ está definido por

$$\alpha = \sup_{\boldsymbol{\theta} \in \Theta_1} \beta_\varphi(\boldsymbol{\theta})$$

Luego, α es el supremo de la probabilidad de cometer un error de tipo I.

Definición 3.9. El nivel de significación de un test φ está definido por

$$\alpha = \sup_{\boldsymbol{\theta} \in \Theta_1} \beta_\varphi(\boldsymbol{\theta})$$

Luego, α es el supremo de la probabilidad de cometer un error de tipo I.

Definición 3.10. Sea el vector $\mathbf{X} = (X_1, \dots, X_n)$ cuya función de distribución pertenece a la familia $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$ y se tiene que decidir entre las hipótesis

$$H : \boldsymbol{\theta} \in \Theta_1 \text{ contra } K : \boldsymbol{\theta} \in \Theta_2$$

Diremos que un test φ es el test más potente de nivel menor o igual que α para una alternativa fija $\boldsymbol{\theta}_2 \in \Theta_2$ si

(a) $\sup_{\boldsymbol{\theta} \in \Theta_1} \beta_\varphi(\boldsymbol{\theta}) \leq \alpha$, es decir si φ tiene nivel de significación menor o igual que α .

(b) Dado otro test φ^* de nivel menor o igual que α entonces se tiene

$$\beta_{\varphi^*}(\boldsymbol{\theta}_2) \leq \beta_\varphi(\boldsymbol{\theta}_2).$$

Observación 3.11. Es claro que si cambiamos la alternativa $\boldsymbol{\theta}_2 \in \Theta_2$ por otro $\boldsymbol{\theta}'_2 \in \Theta_2$, el test más potente para esta $\boldsymbol{\theta}'_2$ no tiene porque coincidir con el correspondiente a $\boldsymbol{\theta}_2$.

Definición 3.12. Diremos que un φ es un test uniformemente más potente (UMP) de nivel menor o igual que α para $H : \boldsymbol{\theta} \in \Theta_1$ contra $K : \boldsymbol{\theta} \in \Theta_2$, si φ es el más potente de nivel menor o igual que α para todo $\boldsymbol{\theta}_2 \in \Theta_2$. Es decir, si el mismo test es óptimo cualquiera sea la alternativa fija $\boldsymbol{\theta}_2 \in \Theta_2$ considerada.

Definición 3.13. El nivel crítico o p-valor es el menor valor de significación para el que rechazamos la hipótesis H para una observación dada $\mathbf{x}$.

Observación 3.14. Cuanto menor sea el p-valor más evidencia en contra de H tenemos, suponiendo que H es cierta.

3.3. Tests óptimos para el caso de hipótesis simple contra hipótesis simple

Definición 3.15. El caso más simple de problema de test de hipótesis es la situación donde Θ_1 y Θ_2 contengan cada uno un elemento. En este caso, se dice, H y K son hipótesis simples. Si Θ_1 tuviera más de un elemento, H se llamará hipótesis compuesta, y lo mismo vale para K en relación a Θ_2 .

Teorema 3.16. (Teorema de Neyman-Pearson):

(i) Dado $0 \leq \alpha \leq 1$ se puede elegir k_α y γ_α con $\gamma_\alpha \in [0, 1]$ tales que el test de la forma (conocido como test del cociente de verosimilitud)

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) > k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \\ \gamma_\alpha & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) = k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \\ 0 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) < k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \end{cases}, \text{ satisfaga } \mathbb{E}_{\boldsymbol{\theta}_1}(\varphi(\mathbf{X})) = \alpha$$

(ii) Sea un test del cociente de verosimilitud que satisface $\mathbb{E}_{\boldsymbol{\theta}_1}(\varphi(\mathbf{X})) = \alpha$ para $\alpha > 0$ y de la forma

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) = 0 \\ 0 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) > 0 \end{cases} \text{ para } \alpha = 0.$$

Luego ese test es el más potente de nivel menor o igual que α para

$$H : \theta \in \Theta_1 \text{ contra } K : \theta \in \Theta_2$$

(iii) Si φ^* es un test uniformemente más potente de nivel $\alpha > 0$ para

$$H : \theta \in \Theta_1 \text{ contra } K : \theta \in \Theta_2$$

entonces φ^* es de la forma

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) > k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \\ \gamma_\alpha & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) = k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \\ 0 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) < k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \end{cases}$$

excepto, quizás, en un conjunto $\mathcal{N}$ tal que $\mathbb{P}_{\boldsymbol{\theta}_1}(\mathcal{N}) = \mathbb{P}_{\boldsymbol{\theta}_2}(\mathcal{N}) = 0$.

Si φ^* es un test uniformemente más potente de nivel $\alpha = 0$ para

$$H : \theta \in \Theta_1 \text{ contra } K : \theta \in \Theta_2$$

entonces φ^* es de la forma $\varphi(\mathbf{X}) = \begin{cases} 1 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) = 0 \\ 0 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) > 0 \end{cases}$ excepto, quizás, en un conjunto $\mathcal{N}$ tal que $\mathbb{P}_{\boldsymbol{\theta}_1}(\mathcal{N}) = \mathbb{P}_{\boldsymbol{\theta}_2}(\mathcal{N}) = 0$.

Demostración.

(i) Si $\alpha = 0$ el test $\varphi(\mathbf{X}) = \begin{cases} 1 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) = 0 \\ 0 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) > 0 \end{cases}$ tiene nivel 0. Sea, entonces, $\alpha \in (0, 1]$ y definimos la variable aleatoria

$$L = \begin{cases} \frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2)}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)} & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) > 0 \\ 1 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) = 0 \end{cases}.$$

Luego,

$$\mathbb{E}_{\boldsymbol{\theta}_1}(\varphi(\mathbf{X})) = \mathbb{P}_{\boldsymbol{\theta}_1}(L > k_\alpha) + \gamma_\alpha \mathbb{P}_{\boldsymbol{\theta}_1}(L = k_\alpha) = 1 - \mathbb{P}_{\boldsymbol{\theta}_1}(L \leq k_\alpha) + \gamma_\alpha \mathbb{P}_{\boldsymbol{\theta}_1}(L = k_\alpha).$$

Si existe una constante k_α tal que $\mathbb{P}_{\boldsymbol{\theta}_1}(L \leq k_0) = \alpha$ tomamos $k_0 = k_\alpha$ y γ_α . En caso contrario, siempre existe k_0 tal que

$$\mathbb{P}_{\boldsymbol{\theta}_1}(L \leq k_0) \leq 1 - \alpha < \mathbb{P}_{\boldsymbol{\theta}_1}(L < k_0)$$

y se cumple $\mathbb{P}_{\boldsymbol{\theta}_1}(L = k_0) = 0$.

Definiendo $k_0 = k_\alpha$ y

$$\gamma_\alpha = \frac{\mathbb{P}_{\boldsymbol{\theta}_1}(L \leq k_0) - (1 - \alpha)}{\mathbb{P}_{\boldsymbol{\theta}_1}(L = k_0)}.$$

Luego, como $\mathbb{P}_{\boldsymbol{\theta}_1}(L \leq k_0) \leq 1 - \alpha < \mathbb{P}_{\boldsymbol{\theta}_1}(L < k_0)$, se tiene que $\gamma_\alpha \in (0, 1]$ y, además, $\mathbb{E}_{\boldsymbol{\theta}_1}(\varphi(\mathbf{X})) = \alpha$.

(ii) Sólo se demostrará el caso continuo puesto que el caso discreto es análogo reemplazando las integrales por sumatorias.

Supongamos que φ es un test de cociente de verosimilitud, o sea, es de la forma

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) > k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \\ \gamma_\alpha & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) = k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \\ 0 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) < k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \end{cases}$$

y que, además, satisface $\mathbb{E}_{\boldsymbol{\theta}_1}(\varphi(\mathbf{X})) = \alpha$ (por lo que se deduce que su nivel es igual a α).

Para mostrar que φ es el test más potente de nivel menor o igual que α , sólo falta mostrar que dado otro test φ^* de nivel menor o igual que α se tiene $\beta_\varphi(\boldsymbol{\theta}_2) \geq \beta_{\varphi^*}(\boldsymbol{\theta}_2)$.

(a) Supongamos primero $\alpha > 0$, con lo cual

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) > k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \\ \gamma_\alpha & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) = k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1), \text{ con } k_\alpha < \infty. \\ 0 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) < k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \end{cases}$$

Sea φ^* de nivel menor o igual que α . Consideremos la expresión

$$U(\mathbf{x}) = [\varphi(\mathbf{x}) - \varphi^*(\mathbf{x})][\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) - k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)], \text{ y se mostrará que } U(\mathbf{x}) \geq 0.$$

Supongamos primero que $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) > k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)$. Luego, se tendrá $\varphi(\mathbf{x}) = 1$ y, por lo tanto,

$$\varphi(\mathbf{x}) \geq \varphi^*(\mathbf{x}) \Rightarrow U(\mathbf{x}) \geq 0.$$

Si $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) = k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)$, es claro que $U(\mathbf{x}) = 0$.

Finalmente, si $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) < k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)$, entonces $\varphi(\mathbf{x}) = 0$. Luego, $\varphi(\mathbf{x}) \leq \varphi^*(\mathbf{x})$ y, por lo tanto, $U(\mathbf{x}) \geq 0$.

$$\begin{aligned} \int [\varphi(\mathbf{x}) - \varphi^*(\mathbf{x})][\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) - k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)] d\mathbf{x} &= \int U(\mathbf{x}) d\mathbf{x} \geq 0 \Rightarrow \\ \int [\varphi(\mathbf{x}) - \varphi^*(\mathbf{x})] \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) d\mathbf{x} &\geq \int [\varphi(\mathbf{x}) - \varphi^*(\mathbf{x})] \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) d\mathbf{x} \end{aligned}$$

o, equivalentemente,

$$\beta_\varphi(\boldsymbol{\theta}_2) - \beta_{\varphi^*}(\boldsymbol{\theta}_2) \geq k_\alpha (\beta_\varphi(\boldsymbol{\theta}_1) - \beta_{\varphi^*}(\boldsymbol{\theta}_1)).$$

Como $\mathbb{E}_{\boldsymbol{\theta}_1}(\varphi(\mathbf{X})) = \alpha$, se tiene que $\beta_\varphi(\boldsymbol{\theta}_1) = \alpha$. Además, como φ^* es un test de nivel de significación menor o igual que α (es decir, $\beta_{\varphi^*}(\boldsymbol{\theta}_1) \leq \alpha$), entonces resulta

$$\beta_\varphi(\boldsymbol{\theta}_1) - \beta_{\varphi^*}(\boldsymbol{\theta}_1) \geq 0 \Rightarrow \beta_\varphi(\boldsymbol{\theta}_2) \geq \beta_{\varphi^*}(\boldsymbol{\theta}_2)$$

Entonces φ es el test más potente de nivel de significación menor o igual que α si su nivel no es cero.

(b) Si $\alpha = 0$, como el test dado por

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) = 0 \\ 0 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) > 0 \end{cases}$$

tiene nivel cero queremos ver que dado φ^* con nivel 0 se cumple $\beta_\varphi(\boldsymbol{\theta}_2) \geq \beta_{\varphi^*}(\boldsymbol{\theta}_2)$.

Como φ^* tiene nivel 0,

$$\int \varphi^*(\mathbf{x}) \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) d\mathbf{x} = 0 \Rightarrow \varphi^*(\mathbf{x}) = 0, \text{ en el conjunto } \{\mathbf{x} : \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) > 0\}$$

excepto, quizás, en un conjunto de medida 0.

Por lo tanto,

$$\begin{aligned} \beta_\varphi(\boldsymbol{\theta}_2) - \beta_{\varphi^*}(\boldsymbol{\theta}_2) &= \mathbb{E}_{\boldsymbol{\theta}_2}(\varphi(\mathbf{X})) - \mathbb{E}_{\boldsymbol{\theta}_2}(\varphi^*(\mathbf{X})) \Rightarrow \\ \beta_\varphi(\boldsymbol{\theta}_2) - \beta_{\varphi^*}(\boldsymbol{\theta}_2) &= \int_{\{\mathbf{x}:\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)=0\}} [\varphi(\mathbf{X}) - \varphi^*(\mathbf{X})] \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) d\mathbf{x} + \int_{\{\mathbf{x}:\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)>0\}} [\varphi(\mathbf{X}) - \varphi^*(\mathbf{X})] \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) d\mathbf{x} \Rightarrow \\ \beta_\varphi(\boldsymbol{\theta}_2) - \beta_{\varphi^*}(\boldsymbol{\theta}_2) &= \int_{\{\mathbf{x}:\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)=0\}} [1 - \varphi^*(\mathbf{X})] \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) d\mathbf{x} \geq 0. \end{aligned}$$

(iii) Haremos primero el caso $\alpha = 0$.

Sea φ el test de la forma

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) = 0 \\ 0 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) > 0 \end{cases}$$

y φ^* un test de nivel 0. Ya se ha visto que, entonces, $\varphi^*(\mathbf{x}) = 0$ en el conjunto $\{\mathbf{x} : \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) > 0\}$ excepto, quizás, en un conjunto $\mathcal{N}_1$ de medida 0. Luego,

$$\mathbb{P}_{\boldsymbol{\theta}_1}(\mathcal{N}_1) = \mathbb{P}_{\boldsymbol{\theta}_2}(\mathcal{N}_1) = 0 \text{ y } \varphi^*(\mathbf{x}) = \varphi(\mathbf{x}) \text{ en } \{\mathbf{x} : \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) > 0\} \setminus \mathcal{N}_1.$$

Falta ver que $\varphi^*(\mathbf{x}) = \varphi(\mathbf{x}) = 1$ en $\{\mathbf{x} : \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) = 0\}$ excepto quizás un conjunto de medida 0.

Como $\mathbb{E}_{\boldsymbol{\theta}_2}(\varphi(\mathbf{X})) = \mathbb{E}_{\boldsymbol{\theta}_2}(\varphi^*(\mathbf{X}))$, se cumple

$$0 = \int_{\{\mathbf{x}:\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)=0\}} [\varphi(\mathbf{X}) - \varphi^*(\mathbf{X})] \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) d\mathbf{x} + \int_{\{\mathbf{x}:\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)>0\}} [\varphi(\mathbf{X}) - \varphi^*(\mathbf{X})] \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) d\mathbf{x} \Rightarrow$$

$$0 = \int_{\{\mathbf{x}: \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) = 0\}} [1 - \varphi^*(\mathbf{X})] \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) d\mathbf{x}.$$

pero si $\varphi^*(\mathbf{x}) \leq 1$ el integrando es no negativo. Por lo tanto, la integral es cero si y sólo si $\varphi^*(\mathbf{x}) = 1$ en el conjunto $\{\mathbf{x} : \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) = 0\} \cap \{\mathbf{x} : \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) > 0\}$ excepto quizás en un conjunto $\mathcal{N}_2$ de medida 0.

Sea $\mathcal{N} = \mathcal{N}_1 \cup \mathcal{N}_2 \cap (\{\mathbf{x} : \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) = 0\} \cap \{\mathbf{x} : \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) > 0\})$, se tiene

$$\mathbb{P}_{\boldsymbol{\theta}_1}(\mathcal{N}) = \mathbb{P}_{\boldsymbol{\theta}_2}(\mathcal{N}) = 0 \text{ y } \varphi^*(\mathbf{x}) = \varphi(\mathbf{x}), \text{ para } \mathbf{x} \notin \mathcal{N}.$$

Supongamos ahora $\alpha > 0$. Sea φ^* un test de nivel α uniformemente más potente para H versus K y φ el test dado por

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) > k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \\ \gamma_\alpha & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) = k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \\ 0 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) < k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) \end{cases}$$

que también es uniformemente más potente para H versus K por lo visto en (ii). Luego se cumple

$$\mathbb{E}_{\boldsymbol{\theta}_1}(\varphi(\mathbf{X})) = \mathbb{E}_{\boldsymbol{\theta}_1}(\varphi^*(\mathbf{X})) \text{ y } e_{\boldsymbol{\theta}_2}(\varphi(\mathbf{X})) = \mathbb{E}_{\boldsymbol{\theta}_2}(\varphi^*(\mathbf{X})).$$

Por otra parte, la función

$$U(\mathbf{x}) = [\varphi(\mathbf{x}) - \varphi^*(\mathbf{x})][\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) - k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)]$$

es no negativa y $\int U(\mathbf{x}) d\mathbf{x} = 0$ puesto que $\mathbb{E}_{\boldsymbol{\theta}_1}(\varphi(\mathbf{X})) = \mathbb{E}_{\boldsymbol{\theta}_1}(\varphi^*(\mathbf{X}))$ y $e_{\boldsymbol{\theta}_2}(\varphi(\mathbf{X})) = \mathbb{E}_{\boldsymbol{\theta}_2}(\varphi^*(\mathbf{X}))$.

Luego, $U(\mathbf{x})$ debe ser nula excepto en un conjunto $\mathcal{N}$ de medida 0. Es decir,

$$[\varphi(\mathbf{X}) - \varphi^*(\mathbf{X})][\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) - k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)] = 0, \text{ para } \mathbf{x} \notin \mathcal{N}$$

Por lo tanto, $\varphi(\mathbf{X}) = \varphi^*(\mathbf{X})$ en el conjunto $\{\mathbf{x} : \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) \neq k_\alpha \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)\} \cap \mathcal{N}^c$. □

Observación 3.17. Si $\frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2)}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)}$ resulta ser una variable continua, no hay que preocuparse por γ_α ya que

$$\mathbb{P}\left(\frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2)}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)} = k_\alpha\right) = 0.$$

Teorema 3.18. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución perteneciente a $N(\mu, \sigma_0^2)$ donde σ_0^2 es conocido,

(i) El test φ dado como

$$\varphi(X_1, \dots, X_n) = \begin{cases} 1 & \sqrt{n} \frac{(\bar{X}_n - \mu_1)}{\sigma_0} \geq z_\alpha \\ 0 & \sqrt{n} \frac{(\bar{X}_n - \mu_1)}{\sigma_0} < z_\alpha \end{cases}$$

es el uniformemente más potente de nivel menor o igual que α para

(a) $H : \mu = \mu_1$ contra $K : \mu > \mu_1$.

(b) $H : \mu \leq \mu_1$ contra $K : \mu > \mu_1$.

Su función de potencia viene dada por

$$\beta_\varphi(\mu) = 1 - \Phi\left(z_\alpha + \sqrt{n} \frac{(\mu_1 - \mu)}{\sigma_0}\right).$$

(ii) El test φ dado como

$$\varphi(X_1, \dots, X_n) = \begin{cases} 1 & \sqrt{n} \frac{(\bar{X}_n - \mu_1)}{\sigma_0} \leq -z_\alpha \\ 0 & \sqrt{n} \frac{(\bar{X}_n - \mu_1)}{\sigma_0} > -z_\alpha \end{cases}$$

es el uniformemente más potente de nivel menor o igual que α para

(a) $H : \mu = \mu_1$ contra $K : \mu < \mu_1$.

(b) $H : \mu \geq \mu_1$ contra $K : \mu < \mu_1$.

Su función de potencia viene dada por

$$\beta_\varphi(\mu) = \Phi\left(-z_\alpha + \sqrt{n} \frac{(\mu_1 - \mu)}{\sigma_0}\right).$$

Demostración. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución perteneciente a $N(\mu, \sigma_0^2)$ donde σ_0^2 es conocido, y supongamos que se quiere decidir entre

$$H : \mu = \mu_1 \text{ contra } K : \mu = \mu_2$$

Supongamos primero que $\mu_2 > \mu_1$. En este caso, el test más potente rechaza H si

$$\frac{\mathbb{P}(\mathbf{X}, \mu_2)}{\mathbb{P}(\mathbf{X}, \mu_1)} \geq k_\alpha.$$

donde $\mathbb{P}(\mathbf{X}, \mu)$ indica la densidad conjunta de $\mathbf{X} = (X_1, \dots, X_n)$ cuando X_i tiene distribución $N(\mu, \sigma_0^2)$.

Luego, $\varphi(\mathbf{X}) = 1$ si

$$L = \frac{(2\pi\sigma_0)^{-n/2} \exp\left\{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (X_i - \mu_2)^2\right\}}{(2\pi\sigma_0)^{-n/2} \exp\left\{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (X_i - \mu_1)^2\right\}} \geq k_\alpha$$

entonces, $\varphi(\mathbf{X}) = 1$ si

$$\begin{aligned} \exp\left\{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n [(X_i - \mu_2)^2 + (X_i - \mu_1)^2]\right\} &\geq k_\alpha \Leftrightarrow -\sum_{i=1}^n [(X_i - \mu_2)^2 + (X_i - \mu_1)^2] \geq 2\sigma_0^2 \ln(k_\alpha). \\ \Leftrightarrow 2(\mu_2 - \mu_1) \sum_{i=1}^n X_i &\geq 2\sigma_0^2 \ln(k_\alpha) + n(\mu_2^2 - \mu_1^2) \Leftrightarrow \sum_{i=1}^n X_i \geq \frac{2\sigma_0^2 \ln(k_\alpha) + n(\mu_2^2 - \mu_1^2)}{2(\mu_2 - \mu_1)} := k'_\alpha \end{aligned}$$

Luego, el test más potente es de la forma

$$\varphi(\mathbf{X}) = 1 \text{ si } \sum_{i=1}^n X_i \geq k'_\alpha.$$

y la constante k'_α deberá elegirse de modo que $\mathbb{E}_{\mu_1}(\varphi(\mathbf{X})) = \alpha$.

Para encontrar esta constante, necesitaríamos una tabla de la distribución $N(n\mu, n\sigma_0^2)$, pero para trabajar más cómodamente transformamos el estadístico $\sum_{i=1}^n X_i$ en otro cuya distribución sea $N(0, 1)$.

Para esto escribimos el test de la siguiente forma $\varphi(\mathbf{X}) = 1$ si

$$\sqrt{n} \frac{(\bar{X}_n - \mu_1)}{\sigma_0} \geq \sqrt{n} \frac{(k'_\alpha/n - \mu_1)}{\sigma_0} := k''_\alpha.$$

Calculemos k''_α . De acuerdo con el Teorema de Neyman-Pearson, se debería tener que

$$\alpha = \mathbb{E}_{\mu_1}(\varphi(\mathbf{X})) = \mathbb{P}_{\mu_1}(\varphi(\mathbf{X}) = 1) = \mathbb{P}_{\mu_1}\left(\sqrt{n} \frac{(\bar{X}_n - \mu_1)}{\sigma_0} \geq k''_\alpha\right).$$

Pero cuando $\mu = \mu_1$, se tiene que $\sqrt{n} \frac{(\bar{X}_n - \mu_1)}{\sigma_0} \sim N(0, 1)$ por lo que k''_α debe ser igual a z_α .

Es decir, que el test queda como

$$\varphi(X_1, \dots, X_n) = \begin{cases} 1 & \sqrt{n} \frac{(\bar{X}_n - \mu_1)}{\sigma_0} \geq z_\alpha \\ 0 & \sqrt{n} \frac{(\bar{X}_n - \mu_1)}{\sigma_0} < z_\alpha \end{cases}$$

En una cuenta análoga se obtiene que si $\mu_2 < \mu_1$, el test más potente de nivel de significación α hubiese resultado

$$\varphi(X_1, \dots, X_n) = \begin{cases} 1 & \sqrt{n} \frac{(\bar{X}_n - \mu_1)}{\sigma_0} \leq -z_\alpha \\ 0 & \sqrt{n} \frac{(\bar{X}_n - \mu_1)}{\sigma_0} > -z_\alpha \end{cases}$$

A través del test $\varphi(X_1, \dots, X_n) = \begin{cases} 1 & \sqrt{n} \frac{(\bar{X}_n - \mu_1)}{\sigma_0} \geq z_\alpha \\ 0 & \sqrt{n} \frac{(\bar{X}_n - \mu_1)}{\sigma_0} < z_\alpha \end{cases}$, resulta que el test más potente para

$$H : \mu = \mu_1 \text{ contra } K : \mu = \mu_2$$

no depende de μ_2 , es decir es el mismo cualquiera sea $\mu_2 > \mu_1$. Por lo tanto, el test anterior el test uniformemente más potente de nivel menor o igual que α para

$$H : \mu = \mu_1 \text{ contra } K : \mu > \mu_1.$$

Análogamente el test dado por $\varphi(X_1, \dots, X_n) = \begin{cases} 1 & \sqrt{n} \frac{(\overline{X_n} - \mu_1)}{\sigma_0} \leq -z_\alpha \\ 0 & \sqrt{n} \frac{(\overline{X_n} - \mu_1)}{\sigma_0} > -z_\alpha \end{cases}$ resulta ser el test uniformemente más potente de nivel menor o igual que α para

$$H : \mu = \mu_1 \text{ contra } K : \mu < \mu_1.$$

Calculemos ahora la función de potencia del test φ dado por

$$\varphi(X_1, \dots, X_n) = \begin{cases} 1 & \sqrt{n} \frac{(\overline{X_n} - \mu_1)}{\sigma_0} \geq z_\alpha \\ 0 & \sqrt{n} \frac{(\overline{X_n} - \mu_1)}{\sigma_0} < z_\alpha \end{cases} \Leftrightarrow \varphi(X_1, \dots, X_n) = \begin{cases} 1 & \sqrt{n} \frac{(\overline{X_n} - \mu)}{\sigma_0} \geq z_\alpha + \sqrt{n} \frac{(\mu_1 - \mu)}{\sigma_0} \\ 0 & \sqrt{n} \frac{(\overline{X_n} - \mu)}{\sigma_0} < z_\alpha + \sqrt{n} \frac{(\mu_1 - \mu)}{\sigma_0} \end{cases}$$

Luego, la función de potencia del test φ definido por

$$\beta_\varphi(\mu) = \mathbb{E}_\mu(\varphi(\mathbf{X})) = \mathbb{P}_\mu \left(\sqrt{n} \frac{(\overline{X_n} - \mu)}{\sigma_0} \geq z_\alpha + \sqrt{n} \frac{(\mu_1 - \mu)}{\sigma_0} \right)$$

Pero cuando el valor de la media es μ , $\sqrt{n} \frac{(\overline{X_n} - \mu)}{\sigma_0}$ tiene distribución $N(0, 1)$. Luego si Φ es la función de distribución de una variable aleatoria $N(0, 1)$, se tendrá

$$\beta_\varphi(\mu) = 1 - \Phi \left(z_\alpha + \sqrt{n} \frac{(\mu_1 - \mu)}{\sigma_0} \right).$$

tal que

(*) $\beta_\varphi(\mu)$ para n fijo es una función creciente de μ , ya que Φ es una función creciente.

(**) $\beta_\varphi(\mu) = \alpha$.

(***) $\lim_{\mu \rightarrow +\infty} \beta_\varphi(\mu) = 1 - \lim_{x \rightarrow -\infty} \Phi(x) = 1$.

(****) $\lim_{\mu \rightarrow -\infty} \beta_\varphi(\mu) = 1 - \lim_{x \rightarrow +\infty} \Phi(x) = 0$.

(*****) Para μ_2 fijo tal que $\mu_2 > \mu_1$, se tiene que $\lim_{\mu \rightarrow +\infty} \beta_\varphi(\mu_2) = 1 - \lim_{n \rightarrow \infty} \Phi(x) = 1$.

De aquí se deduce que tomando n grande, para un μ_2 fijo, la probabilidad de error de tipo II se puede hacer tan pequeño como se quiera.

De (*) y (**) resulta que $\sup_{\mu \leq \mu_1} \beta_\varphi(\mu) = \alpha$. Luego, φ resulta un test de nivel igual que α para

$$H : \mu \leq \mu_1 \text{ contra } K : \mu > \mu_1.$$

Por último, veamos ahora que φ es el test de nivel $\leq \alpha$, uniformemente más potente para estas mismas hipótesis. Sea φ^* otro test de nivel menor o igual que α para

$$H : \mu \leq \mu_1 \text{ contra } K : \mu > \mu_1,$$

también tendrá este nivel para

$$H : \mu = \mu_1 \text{ contra } K : \mu > \mu_1,$$

pero φ es el test uniformemente más potente para

$$H : \mu = \mu_1 \text{ contra } K : \mu > \mu_1.$$

Entonces se tiene $\beta_\varphi(\mu) \leq \beta_{\varphi^*}(\mu)$, $\forall \mu > \mu_1$ y φ resulta el test más potente de nivel menor o igual que α para

$$H : \mu \leq \mu_1 \text{ contra } K : \mu > \mu_1.$$

□

3.4. Tests uniformemente más potentes para hipótesis unilaterales

Definición 3.19. Una familia de distribuciones discretas o continuas con densidad (o función de probabilidad puntual) $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta \subset \mathbb{R}$ se dice de cociente de verosimilitud monótono (CVM) en el estadístico $\mathbf{T} = r(\mathbf{X})$ (donde r toma valores reales), si para todo par $\theta_1 < \theta_2$ se tiene

(i) Las distribuciones correspondientes a $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)$ y $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2)$ son distintas.

(ii) $\frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2)}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)} = g_{\boldsymbol{\theta}_1 \boldsymbol{\theta}_2}(r(\mathbf{X}))$, donde $g_{\boldsymbol{\theta}_1 \boldsymbol{\theta}_2}(t)$ es una función no decreciente en el conjunto

$$\mathcal{S} = \{t : t = r(\mathbf{x}) \text{ con } \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) > 0 \text{ ó } \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) > 0\}$$

Observación 3.20. A los efectos de la definición anterior si $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) = 0$ y $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2) > 0$, el cociente $\frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2)}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)}$ se considerará igual a 1.

Teorema 3.21. Sea la familia exponencial a un parámetro con función de densidad o probabilidad

$$\mathbb{P}(\mathbf{x}, \theta) = A(\theta)e^{c(\theta)r(\mathbf{x})}h(\mathbf{x}), \text{ con } \theta \in \Theta \subset \mathbb{R}.$$

Luego,

(i) Si $c(\theta)$ es estrictamente creciente la familia dada es de CVM en $r(\mathbf{X})$.

(ii) Si $c(\theta)$ es estrictamente decreciente la familia dada es de CVM en $-r(\mathbf{X})$.

Demostración. Sólo demostraremos (i). La parte (ii) se demuestra idénticamente.

Sea $\boldsymbol{\theta}_1 < \boldsymbol{\theta}_2$,

$$\frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2)}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)} = \frac{A(\boldsymbol{\theta}_2)}{A(\boldsymbol{\theta}_1)} e^{(c(\boldsymbol{\theta}_2) - c(\boldsymbol{\theta}_1))r(\mathbf{x})} = g(\boldsymbol{\theta}_1, \boldsymbol{\theta}_2)(r(\mathbf{x})), \text{ donde } g(\boldsymbol{\theta}_1, \boldsymbol{\theta}_2)(t) = \frac{A(\boldsymbol{\theta}_2)}{A(\boldsymbol{\theta}_1)} e^{(c(\boldsymbol{\theta}_2) - c(\boldsymbol{\theta}_1))t} \text{ es una función creciente.}$$

Como c es estrictamente monótona, si $\boldsymbol{\theta}_1 \neq \boldsymbol{\theta}_2$ entonces $c(\boldsymbol{\theta}_1) \neq c(\boldsymbol{\theta}_2)$ y luego $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)$ y $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2)$ corresponden a distribuciones diferentes. Luego, la familia dada es de cociente de verosimilitud monótono en $\mathbf{T} = r(\mathbf{X})$. $\square$

Teorema 3.22. Sea $\mathbf{X}$ un vector aleatorio con función de probabilidad o densidad perteneciente a la familia $\mathbb{P}(\mathbf{x}, \theta)$ con $\theta \in \Theta \subset \mathbb{R}$, que tiene la propiedad de ser de CVM en $\mathbf{T} = r(\mathbf{X})$. Luego

(i) Existen k_α y γ_α tales que si definimos

$$\varphi(\mathbf{X}) = \begin{cases} 1 & T > k_\alpha \\ \gamma_\alpha & T = k_\alpha \\ 0 & T < k_\alpha \end{cases}, \text{ se satisface } \mathbb{E}_{\boldsymbol{\theta}_1}(\varphi(\mathbf{X})) = \alpha.$$

(ii) Sea φ es un test de la forma

$$\varphi(\mathbf{X}) = \begin{cases} 1 & T > k_\alpha \\ \gamma_\alpha & T = k_\alpha \\ 0 & T < k_\alpha \end{cases}$$

que satisface $\mathbb{E}_{\boldsymbol{\theta}_1}(\varphi(\mathbf{X})) = \alpha$. Luego, φ es el test uniformemente más potente UMP de nivel menor o igual que α para

$$H : \theta = \boldsymbol{\theta}_1 \text{ contra } K : \theta > \boldsymbol{\theta}_1$$

(iii) $\beta_\varphi(\theta)$ es monótona no decreciente para todo θ y estrictamente creciente para todo θ tal que $\beta_\varphi(\theta) \in (0, 1)$.

(iv) Sea φ es un test de la forma

$$\varphi(\mathbf{X}) = \begin{cases} 1 & T > k_\alpha \\ \gamma_\alpha & T = k_\alpha \\ 0 & T < k_\alpha \end{cases}$$

que satisface $\mathbb{E}_{\boldsymbol{\theta}_1}(\varphi(\mathbf{X})) = \alpha$. Luego, φ es el test uniformemente más potente UMP de nivel menor o igual que α para

$$H : \theta \leq \boldsymbol{\theta}_1 \text{ contra } K : \theta > \boldsymbol{\theta}_1$$

Demostración.

(i) Si $\alpha = 0$ el test $\varphi(\mathbf{X}) = \begin{cases} 1 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) = 0 \\ 0 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) > 0 \end{cases}$ tiene nivel 0. Sea, entonces, $\alpha \in (0, 1]$ y definimos la variable aleatoria

$$L = \begin{cases} \frac{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_2)}{\mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1)} & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) > 0 \\ 1 & \mathbb{P}(\mathbf{x}, \boldsymbol{\theta}_1) = 0 \end{cases}.$$

Luego,

$$\mathbb{E}_{\boldsymbol{\theta}_1}(\varphi(\mathbf{X})) = \mathbb{P}_{\boldsymbol{\theta}_1}(L > k_\alpha) + \gamma_\alpha \mathbb{P}_{\boldsymbol{\theta}_1}(L = k_\alpha) = 1 - \mathbb{P}_{\boldsymbol{\theta}_1}(L \leq k_\alpha) + \gamma_\alpha \mathbb{P}_{\boldsymbol{\theta}_1}(L = k_\alpha).$$

Si existe una constante k_α tal que $\mathbb{P}_{\boldsymbol{\theta}_1}(L \leq k_0) = \alpha$ tomamos $k_0 = k_\alpha$ y γ_α . En caso contrario, siempre existe k_0 tal que

$$\mathbb{P}_{\boldsymbol{\theta}_1}(L \leq k_0) \leq 1 - \alpha < \mathbb{P}_{\boldsymbol{\theta}_1}(L < k_0)$$

y se cumple $\mathbb{P}_{\boldsymbol{\theta}_1}(L = k_0) = 0$.

Definiendo $k_0 = k_\alpha$ y

$$\gamma_\alpha = \frac{\mathbb{P}_{\boldsymbol{\theta}_1}(L \leq k_0) - (1 - \alpha)}{\mathbb{P}_{\boldsymbol{\theta}_1}(L = k_0)}.$$

Luego, como $\mathbb{P}_{\boldsymbol{\theta}_1}(L \leq k_0) \leq 1 - \alpha < \mathbb{P}_{\boldsymbol{\theta}_1}(L < k_0)$, se tiene que $\gamma_\alpha \in (0, 1]$ y, además, $\mathbb{E}_{\boldsymbol{\theta}_1}(\varphi(\mathbf{X})) = \alpha$.

(ii) Suponiendo que $\theta_2 > \theta_1$,

$$\frac{\mathbb{P}(\mathbf{x}, \theta_2)}{\mathbb{P}(\mathbf{x}, \theta_1)} = g_{\theta_2 \theta_1}(r(\mathbf{x}))$$

con $g_{\theta_2 \theta_1}(t)$ estrictamente creciente (esta hipótesis no es necesaria, basta con que sea no decreciente). En este caso, dado

$$\theta_2 > \theta_1 \text{ el test dado por } \varphi(\mathbf{X}) = \begin{cases} 1 & T > k_\alpha \\ \gamma_\alpha & T = k_\alpha \\ 0 & T < k_\alpha \end{cases}, \text{ se puede escribir como}$$

$$\varphi(\mathbf{X}) = \begin{cases} 1 & g_{\theta_2 \theta_1}(r(\mathbf{x})) > g_{\theta_2 \theta_1}(k_\alpha) \\ \gamma_\alpha & g_{\theta_2 \theta_1}(r(\mathbf{x})) = g_{\theta_2 \theta_1}(k_\alpha) \\ 0 & g_{\theta_2 \theta_1}(r(\mathbf{x})) < g_{\theta_2 \theta_1}(k_\alpha) \end{cases} \Leftrightarrow \varphi(\mathbf{X}) = \begin{cases} 1 & \frac{\mathbb{P}(\mathbf{x}, \theta_2)}{\mathbb{P}(\mathbf{x}, \theta_1)} > k'_\alpha \\ \gamma_\alpha & \frac{\mathbb{P}(\mathbf{x}, \theta_2)}{\mathbb{P}(\mathbf{x}, \theta_1)} = k'_\alpha \\ 0 & \frac{\mathbb{P}(\mathbf{x}, \theta_2)}{\mathbb{P}(\mathbf{x}, \theta_1)} < k'_\alpha \end{cases}$$

Sabemos que $\varphi(\mathbf{X})$ satisface $\mathbb{E}_{\theta_1}(\varphi(\mathbf{X})) = \alpha$ y por el Teorema de Neyman-Pearson, resulta que $\varphi(\mathbf{X})$ es el test más potente de nivel menor o igual que α para

$$H : \theta = \theta_1 \text{ contra } K : \theta = \theta_2.$$

Como φ no depende de θ_2 , este resultado vale para todo $\theta_2 > \theta_1$, luego φ es el test UMP de nivel menor o igual que α para

$$H : \theta = \theta_1 \text{ contra } K : \theta > \theta_1.$$

(iii) Sólo demostraremos que $\beta_\varphi(\theta)$ es monótona no decreciente.

Sean θ^* y θ^{**} cualesquiera, tales que $\theta^* < \theta^{**}$. Si llamamos $\mathbb{E}_{\theta^*}(\varphi(\mathbf{X})) = \alpha^*$, resulta por el inciso anterior que $\varphi(\mathbf{X})$ es el test más potente a nivel menor o igual que α^* para las hipótesis simples

$$H : \theta = \theta^* \text{ contra } K : \theta = \theta^{**}.$$

Consideremos el test $\varphi^*(\mathbf{X}) = \alpha^*$ (φ^* es un test de nivel α^*), luego φ^* es menos potente que φ en θ^{**} . Es decir, $\mathbb{E}_{\theta^{**}}(\varphi^*(\mathbf{X})) \leq \mathbb{E}_{\theta^{**}}(\varphi(\mathbf{X}))$. Además

$$\mathbb{E}_{\theta^{**}}(\varphi^*(\mathbf{X})) = \alpha^* = \mathbb{E}_{\theta^*}(\varphi(\mathbf{X})) = \beta_\varphi(\theta^*) \text{ y } \mathbb{E}_{\theta^{**}}(\varphi(\mathbf{X})) = \beta_\varphi(\theta^{**}) \Rightarrow \beta_\varphi(\theta^*) \leq \beta_\varphi(\theta^{**})$$

con lo que queda demostrado que $\beta_\varphi(\theta)$ es monótona no decreciente.

(iv) Primero mostraremos que $\varphi(\mathbf{X})$ es un test de nivel menor o igual que α para

$$H : \theta \leq \theta_1 \text{ contra } K : \theta > \theta_1.$$

o sea que, $\sup_{\theta \leq \theta_1} \beta_\varphi(\theta) \leq \alpha$.

Como $\beta_\varphi(\theta)$ es monótona no decreciente se tiene que

$$\sup_{\theta \leq \theta_1} \beta_\varphi(\theta) = \beta_\varphi(\theta_1) \underbrace{=}_{\mathbb{E}_{\theta_1}(\varphi(\mathbf{X})) = \alpha} \alpha.$$

Consideremos ahora otro test $\varphi^*(\mathbf{X})$ de nivel menor o igual que α para

$$H : \theta \leq \theta_1 \text{ contra } K : \theta > \theta_1,$$

luego $\varphi^*(\mathbf{X})$ es de nivel menor o igual que α para

$$H : \theta = \theta_1 \text{ contra } K : \theta > \theta_1,$$

pero, por el inciso (ii), $\varphi(\mathbf{X})$ es el test uniformemente más potente para este problema, por lo tanto

$$\beta_\varphi(\theta) \geq \beta_{\varphi^*}(\theta), \quad \forall \theta > \theta_1.$$

□

Teorema 3.23. Sea $\mathbf{X}$ un vector aleatorio con función de probabilidad o densidad perteneciente a la familia $\mathbb{P}(\mathbf{x}, \theta)$ con $\theta \in \Theta \subset \mathbb{R}$, que tiene la propiedad de ser de CVM en $\mathbf{T} = r(\mathbf{X})$. Luego

(i) Existen k_α y γ_α tales que si definimos

$$\varphi(\mathbf{X}) = \begin{cases} 1 & T < k_\alpha \\ \gamma_\alpha & T = k_\alpha \\ 0 & T > k_\alpha \end{cases}, \text{ se satisface } \mathbb{E}_{\theta_1}(\varphi(\mathbf{X})) = \alpha.$$

(ii) Sea φ es un test de la forma

$$\varphi(\mathbf{X}) = \begin{cases} 1 & T < k_\alpha \\ \gamma_\alpha & T = k_\alpha \\ 0 & T > k_\alpha \end{cases}$$

que satisface $\mathbb{E}_{\theta_1}(\varphi(\mathbf{X})) = \alpha$. Luego, φ es el test uniformemente más potente UMP de nivel menor o igual que α para

$$H : \theta = \theta_1 \text{ contra } K : \theta < \theta_1.$$

(iii) $\beta_\varphi(\theta)$ es monótona no creciente para todo θ y estrictamente decreciente para todo θ tal que $\beta_\varphi(\theta) \in (0, 1)$.

(iv) Sea φ es un test de la forma

$$\varphi(\mathbf{X}) = \begin{cases} 1 & T < k_\alpha \\ \gamma_\alpha & T = k_\alpha \\ 0 & T > k_\alpha \end{cases}$$

que satisface $\mathbb{E}_{\theta_1}(\varphi(\mathbf{X})) = \alpha$. Luego, φ es el test uniformemente más potente UMP de nivel menor o igual que α para

$$H : \theta \geq \theta_1 \text{ contra } K : \theta < \theta_1.$$

3.5. Tests Inesgados

Definición 3.24. Sea una familia de distribuciones $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$. Se dirá que un test φ para testear

$$H : \boldsymbol{\theta} \in \Theta_1 \text{ contra } K : \boldsymbol{\theta} \in \Theta_2,$$

es *inesgado* si

$$\sup_{\boldsymbol{\theta} \in \Theta_1} \beta_\varphi(\boldsymbol{\theta}) \leq \inf_{\boldsymbol{\theta} \in \Theta_2} \beta_\varphi(\boldsymbol{\theta}).$$

Observación 3.25.

(i) El sentido de esta desigualdad es que la probabilidad de rechazar H cuando $\boldsymbol{\theta} \in \Theta_2$ (es decir, cuando H es falsa), no puede ser menor que cuando $\boldsymbol{\theta} \in \Theta_1$ (es decir, cuando H es verdadera).

Por lo tanto, un test inesgado de nivel α tiene función de potencia menor o igual que α para $\boldsymbol{\theta} \in \Theta_1$ y mayor o igual que α para $\boldsymbol{\theta} \in \Theta_2$.

Observemos que un test UMP de nivel α es inesgado.

(ii) Si la función de potencia $\beta_\varphi(\boldsymbol{\theta})$ del test φ es una función continua de $\boldsymbol{\theta}$ y φ es un test inesgado de nivel α , entonces $\beta_\varphi(\boldsymbol{\theta})$ debe valer α en la frontera Θ_F entre Θ_1 y Θ_2 .

En particular, si estamos testeando

$$H : \theta = \theta_1 \text{ contra } K : \theta \neq \theta_1$$

y φ es un test inesgado de nivel α se tiene $\forall \theta \neq \theta_1$,

$$\begin{cases} \beta_\varphi(\theta_1) = \alpha \\ \beta_\varphi(\theta) \geq \alpha \end{cases}$$

Por lo tanto, si la función de potencia $\beta_\varphi(\theta)$ es derivable respecto de θ , φ debe cumplir

$$\beta'_\varphi(\theta_1) = \frac{\partial}{\partial \theta} \beta_\varphi(\theta) |_{\theta=\theta_1} = 0$$

En el caso particular de las familias exponenciales, la función de potencia de cualquier test es derivable y, por lo tanto, los tests inesgados cumplen $\beta'_\varphi(\theta_1) = 0$.

Definición 3.26. Se dirá que un test φ para testear

$$H : \boldsymbol{\theta} \in \Theta_1 \text{ contra } K : \boldsymbol{\theta} \in \Theta_2$$

es *uniformemente más potente de nivel α entre los inesgados (IUMP)* si

(i) φ tiene nivel α ; es decir,

$$\sup_{\boldsymbol{\theta} \in \Theta_1} \beta_\varphi(\boldsymbol{\theta}) = \alpha.$$

(ii) φ es inesgado; es decir,

$$\beta_\varphi(\boldsymbol{\theta}) \geq \alpha \quad \forall \boldsymbol{\theta} \in \Theta_2.$$

(iii) Dado otro test φ^* inesgado y de nivel α se verifica

$$\beta_\varphi(\boldsymbol{\theta}) \geq \beta_{\varphi^*}(\boldsymbol{\theta}) \quad \forall \boldsymbol{\theta} \in \Theta_2.$$

3.6. Test del cociente de máxima verosimilitud

Supongamos que se observa un vector $\mathbf{X}$, cuya distribución tiene función de densidad $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta})$, $\boldsymbol{\theta} \in \Theta$ y se quiere testear

$$H : \boldsymbol{\theta} \in \Theta_1 \text{ contra } K : \boldsymbol{\theta} \in \Theta_2$$

con $\Theta_1 \cup \Theta_2 = \Theta$.

Un procedimiento intuitivamente razonable y que da buenos resultados en una gran variedad de situaciones es el siguiente. Tomemos estimadores de máxima verosimilitud de $\boldsymbol{\theta}$, suponiendo $\boldsymbol{\theta} \in \Theta_1$, llamémoslo $\widehat{\boldsymbol{\theta}}_1$ y análogamente suponiendo $\boldsymbol{\theta} \in \Theta_1, \widehat{\boldsymbol{\theta}}_2$; luego

$$\mathbb{P}(\mathbf{X}, \widehat{\boldsymbol{\theta}}_1) = \max_{\boldsymbol{\theta} \in \Theta_1} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta}) \text{ y } \mathbb{P}(\mathbf{X}, \widehat{\boldsymbol{\theta}}_2) = \max_{\boldsymbol{\theta} \in \Theta_2} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta}).$$

Si $\widehat{\boldsymbol{\theta}}_1$ y $\widehat{\boldsymbol{\theta}}_2$ no dependieran de la muestra, podríamos considerar el test más potente para testear

$$H^* : \boldsymbol{\theta} = \widehat{\boldsymbol{\theta}}_1 \text{ contra } K^* : \boldsymbol{\theta} = \widehat{\boldsymbol{\theta}}_2.$$

el cual es de la forma

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \frac{\mathbb{P}(\mathbf{X}, \widehat{\boldsymbol{\theta}}_1)}{\mathbb{P}(\mathbf{X}, \widehat{\boldsymbol{\theta}}_2)} < k_\alpha \\ \gamma_\alpha & \frac{\mathbb{P}(\mathbf{X}, \widehat{\boldsymbol{\theta}}_1)}{\mathbb{P}(\mathbf{X}, \widehat{\boldsymbol{\theta}}_2)} = k_\alpha \\ 0 & \frac{\mathbb{P}(\mathbf{X}, \widehat{\boldsymbol{\theta}}_1)}{\mathbb{P}(\mathbf{X}, \widehat{\boldsymbol{\theta}}_2)} > k_\alpha \end{cases}$$

y k_α se elige de manera que el test resulte de nivel α .

Observación 3.27.

(i) En algunos casos $\widehat{\boldsymbol{\theta}}_1$ y $\widehat{\boldsymbol{\theta}}_2$ pueden no existir, pero siempre tiene sentido hablar de $\frac{\mathbb{P}(\mathbf{X}, \widehat{\boldsymbol{\theta}}_1)}{\mathbb{P}(\mathbf{X}, \widehat{\boldsymbol{\theta}}_2)}$ definido por

$$\frac{\sup_{\boldsymbol{\theta} \in \Theta_1} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta})}{\sup_{\boldsymbol{\theta} \in \Theta_2} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta})}$$

Este test puede interpretarse como rechazando $H : \boldsymbol{\theta} \in \Theta_1$ cuando “el valor más probable de Θ_2 ” tiene probabilidad considerablemente más grande que “el valor más probable de Θ_1 ”.

(ii) En muchos casos, como por ejemplo cuando la dimensión de Θ_1 es menor que la dimensión de $\Theta_1 \cup \Theta_2 = \Theta$, y $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta})$ es continua, resulta que

$$\sup_{\boldsymbol{\theta} \in \Theta_2} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta}) = \sup_{\boldsymbol{\theta} \in \Theta} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta})$$

En este caso, el test del cociente de máxima verosimilitud resulta equivalente a

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \frac{\sup_{\boldsymbol{\theta} \in \Theta_1} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta})}{\sup_{\boldsymbol{\theta} \in \Theta} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta})} < k_\alpha \\ \gamma_\alpha & \frac{\sup_{\boldsymbol{\theta} \in \Theta_1} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta})}{\sup_{\boldsymbol{\theta} \in \Theta} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta})} = k_\alpha \\ 0 & \frac{\sup_{\boldsymbol{\theta} \in \Theta_1} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta})}{\sup_{\boldsymbol{\theta} \in \Theta} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta})} > k_\alpha \end{cases}$$

3.7. Test con nivel de significación asintótico

Definición 3.28. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución perteneciente a la familia $F(\mathbf{x}, \boldsymbol{\theta})$, $\boldsymbol{\theta} \in \Theta$ y supongamos que se quiere testear la hipótesis

$$H : \boldsymbol{\theta} \in \Theta_1 \text{ contra } K : \boldsymbol{\theta} \in \Theta_2.$$

Se dirá que una sucesión de test $\varphi_n(X_1, \dots, X_n)$ tiene nivel de significación asintótico α si

$$\lim_{n \rightarrow \infty} \sup_{\boldsymbol{\theta} \in \Theta_1} \beta_{\varphi_n}(\boldsymbol{\theta}) = \alpha.$$

Es decir, que el nivel del test $\varphi_n(X_1, \dots, X_n)$ se acerca a α cuando el tamaño de la muestra tiende a infinito.

3.8. Distribución asintótica del test del cociente de máxima verosimilitud

Sea $\mathbf{X} = (X_1, \dots, X_n)$ una muestra aleatoria de una distribución de densidad o probabilidad dada por $\mathbb{P}(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p) \in \Theta$ donde Θ es un conjunto de $\mathbb{R}^p$ que contiene una esfera.

Supongamos que Θ_1 es un conjunto de dimensión menor que p , digamos de dimensión $p - j$, donde $1 \leq j \leq p$. Θ_1 puede venir expresado de varias formas diferentes. Por ejemplo, puede venir dado por j relaciones funcionales entre los parámetros $\theta_1, \dots, \theta_p$; es decir,

$$\Theta_1 = \{\boldsymbol{\theta} \in \Theta : g_1(\boldsymbol{\theta}) = 0; g_2(\boldsymbol{\theta}) = 0, \dots, g_l(\boldsymbol{\theta}) = 0\}$$

o bien en forma paramétrica

$$\Theta_1 = \{\boldsymbol{\theta} = (\theta_1, \dots, \theta_p) : \theta_1 = h_1(\boldsymbol{\lambda}), \dots, \theta_p = h_p(\boldsymbol{\lambda}), \boldsymbol{\lambda} \in \Lambda\}$$

donde $\boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_{p-j})$ y $\Lambda \subset \mathbb{R}^{p-j}$ de dimensión $p - j$.

Supongamos que se está interesado en el siguiente problema de test de hipótesis:

$$H : \boldsymbol{\theta} \in \Theta_1 \text{ contra } K : \boldsymbol{\theta} \in \Theta_2$$

con $\Theta_1 \cup \Theta_2 = \Theta$. Luego, el test del cociente de máxima verosimilitud es de la forma

$$\varphi(\mathbf{X}) = \begin{cases} 1 & L^*(\mathbf{X}) \leq k_\alpha \\ 0 & L^*(\mathbf{X}) > k_\alpha \end{cases}$$

donde

$$L^*(\mathbf{X}) = \frac{\sup_{\boldsymbol{\theta} \in \Theta_1} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta})}{\sup_{\boldsymbol{\theta} \in \Theta} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta})}$$

de manera que para determinar k_α es necesario conocer la distribución de $L^*(\mathbf{X})$ bajo H .

Teorema 3.29. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución discreta o continua con densidad perteneciente a la familia $\mathbb{P}(\mathbf{x}, \theta)$, $\theta \in \Theta \subset \mathbb{R}$ abierto. Indiquemos por $\mathbb{P}(\mathbf{x}, \theta)$ la densidad conjunta del vector $\mathbf{X} = (X_1, \dots, X_n)$

Supongamos que se cumplen las siguientes condiciones (en lo que sigue suponemos que $\mathbf{X}$ es continuo, para el caso discreto habrá que reemplazar todos los signos $\int$ por $\sum$):

- (i) El conjunto $\mathcal{S} = \{\mathbf{x} : p(\mathbf{x}, \theta) > 0\}$ es independiente de θ .
- (ii) Para todo $\mathbf{x}$, $\mathbb{P}(\mathbf{x}, \theta)$ tiene derivada tercera respecto de θ continua y tal que

$$\left| \frac{\partial^3 \ln(\mathbb{P}(\mathbf{x}, \theta))}{\partial \theta^3} \right| = \left| \frac{\partial^2 \psi(\mathbf{x}, \theta)}{\partial \theta^2} \right| \leq K$$

para todo $\mathbf{x} \in \mathcal{S}$ y para todo $\theta \in \Theta$, donde

$$\psi(\mathbf{x}, \theta) = \frac{\partial \ln(\mathbb{P}(\mathbf{x}, \theta))}{\partial \theta}.$$

- (iii) Si $h(\mathbf{X})$ es un estadístico tal que $\mathbb{E}_\theta[|h(\mathbf{X})|] < \infty$ para todo $\theta \in \Theta$ entonces se tiene

$$\frac{\partial}{\partial \theta} \left[\int_{\mathbb{R}} \dots \int_{\mathbb{R}} h(\mathbf{x}) \mathbb{P}(\mathbf{x}, \theta) d\mathbf{x} \right] = \int_{\mathbb{R}} \dots \int_{\mathbb{R}} h(\mathbf{x}) \frac{\partial \mathbb{P}(\mathbf{x}, \theta)}{\partial \theta} d\mathbf{x}$$

- (iv) $0 < I_1(\theta) = \mathbb{E}_\theta \left[\left(\frac{\partial \ln(\mathbb{P}(X_1, \theta))}{\partial \theta} \right)^2 \right]$.

Finalmente, sea $\widehat{\theta}_n$ un estimador de máxima verosimilitud de θ consistente, entonces si

$$L^*(\mathbf{X}) = \frac{\mathbb{P}(\mathbf{X}, \theta_0)}{\sup_{\boldsymbol{\theta} \in \Theta} \mathbb{P}(\mathbf{X}, \boldsymbol{\theta})} = \frac{\mathbb{P}(\mathbf{X}, \theta_0)}{\mathbb{P}(\mathbf{X}, \widehat{\theta}_n)}.$$

se tiene que $Z = -2 \ln(L^*(\mathbf{X}))$ tiene distribución asintótica χ^2 con lo cual el test

$$\varphi(\mathbf{X}) = \begin{cases} 1 & Z \geq \chi_{1, \alpha}^2 \\ 0 & Z < \chi_{1, \alpha}^2 \end{cases}$$

tiene nivel de significación asintótico α .

Demostración. Sea $\ell(\theta) = \ln(\mathbb{P}(\mathbf{X}, \theta)) = \sum_{i=1}^n \ln(\mathbb{P}(X_i, \theta))$. Indicamos, además, por ℓ' , ℓ'' y ℓ''' las derivadas hasta el orden tres respecto de θ de la función ℓ y por

$$\psi'(\mathbf{x}, \theta) = \frac{\partial \psi(\mathbf{x}, \theta)}{\partial \theta} \text{ y } \psi''(\mathbf{x}, \theta) = \frac{\partial \psi'(\mathbf{x}, \theta)}{\partial \theta}.$$

Luego, $\widehat{\theta}_n$ verifica

$$\ell'(\widehat{\theta}_n) = \sum_{i=1}^n \psi(X_i, \widehat{\theta}_n) = 0.$$

Con lo cual, desarrollando en serie de Taylor alrededor de $\widehat{\theta}_n$ se obtiene:

$$\ell(\theta_0) - \ell(\widehat{\theta}_n) = \ell'(\widehat{\theta}_n)(\theta_0 - \widehat{\theta}_n) + \frac{1}{2} \ell''(\xi_{n,1})(\theta_0 - \widehat{\theta}_n)^2 = \frac{1}{2}(\theta_0 - \widehat{\theta}_n)^2 \left(\sum_{i=1}^n \psi'(X_i, \xi_{n,1}) \right) = \frac{n}{2}(\theta_0 - \widehat{\theta}_n)^2 \frac{1}{n} \sum_{i=1}^n \psi'(X_i, \theta_0) + R_n$$

donde $\xi_{n,1}$ es un punto intermedio entre θ_0 y $\widehat{\theta}_n$ y

$$R_n = \frac{n}{2}(\theta_0 - \widehat{\theta}_n)^2 \left(\frac{1}{n} \sum_{i=1}^n \psi'(X_i, \xi_{n,1}) - \frac{1}{n} \sum_{i=1}^n \psi'(X_i, \theta_0) \right).$$

aplicando el Teorema del Valor Medio,

$$R_n = \frac{n}{2}(\theta_0 - \widehat{\theta}_n)^2 \left(\frac{1}{n} \sum_{i=1}^n \psi''(X_i, \xi_{n,2})[\xi_{n,1} - \theta_0] \right)$$

donde $\xi_{n,2}$ es un punto intermedio entre $\xi_{n,1}$ y θ_0 . Se puede observar que $\xi_{n,j} \xrightarrow[n \rightarrow \infty]{p} \theta_0$ para $j = 1, 2$ puesto que $\widehat{\theta}_n$ es consistente.

Luego,

$$Z = 2 \left(\ell(\widehat{\theta}_n) - \ell(\theta_0) \right) = \left(n(\widehat{\theta}_n - \theta_0)^2 \right) \underbrace{\left(-\frac{1}{n} \sum_{i=1}^n \psi'(X_i, \theta_0) \right)}_{=A_n} - R_n.$$

Además, $I_1(\theta)n(\widehat{\theta}_n - \theta_0)^2 \xrightarrow[n \rightarrow \infty]{D} \chi_1^2$ puesto que $\sqrt{n}(\widehat{\theta}_n - \theta_0) \xrightarrow[n \rightarrow \infty]{D} N\left(0, \frac{1}{I_1(\theta_0)}\right)$. De donde se deduce que $n(\widehat{\theta}_n - \theta_0)^2$ está acotado en probabilidad.

Por otra parte, la Ley de los Grandes Números implica que

$$\frac{1}{n} \sum_{i=1}^n \psi'(X_i, \theta_0) \xrightarrow[n \rightarrow \infty]{p} \mathbb{E}(\psi'(X_i, \theta_0)) = -I_1(\theta_0).$$

entonces,

$$\left(n(\widehat{\theta}_n - \theta_0)^2 \right) A_n \xrightarrow[n \rightarrow \infty]{D} \chi_1^2.$$

y, por lo tanto, basta con ver que $R_n \xrightarrow[n \rightarrow \infty]{p} 0$.

Como $|\psi''(X_i, \theta)| \leq K$ para todo θ , se tiene que

$$\left| \frac{1}{2n} \sum_{i=1}^n \psi''(X_i, \xi_{n,2}) (\xi_{n,1} - \theta_0) \right| \leq \frac{K}{2} |\xi_{n,1} - \theta_0|$$

y, puesto que $\xi_{n,1} \xrightarrow[n \rightarrow \infty]{p} \theta_0$, se deduce que

$$\frac{1}{n} \sum_{i=1}^n \psi''(X_i, \xi_{n,2}) (\xi_{n,1} - \theta_0) \xrightarrow[n \rightarrow \infty]{p} 0,$$

Finalmente,

$$R_n = \underbrace{\frac{n}{2}(\theta_0 - \widehat{\theta}_n)^2}_{\text{acotado en probabilidad}} \underbrace{\left(\frac{1}{n} \sum_{i=1}^n \psi''(X_i, \xi_{n,2})[\xi_{n,1} - \theta_0] \right)}_{\xrightarrow[n \rightarrow \infty]{p} 0} \xrightarrow[n \rightarrow \infty]{p} 0.$$

□

3.9. Relación entre regiones de confianza y test

Supongamos que se tiene un vector aleatorio $\mathbf{X}$ con distribución perteneciente a la familia $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$ y supongamos que para cada θ_0 se tiene un test no aleatorizado de nivel α , φ_{θ_0} , para

$$H : \boldsymbol{\theta} = \boldsymbol{\theta}_0 \text{ contra } K : \boldsymbol{\theta} \neq \boldsymbol{\theta}_0.$$

Se puede construir una región de confianza de nivel $(1 - \alpha)$ para $\boldsymbol{\theta}$ definiendo $S(\mathbf{X}) = \{\boldsymbol{\theta} : \varphi_{\boldsymbol{\theta}}(\mathbf{X}) = 0\}$.

Es decir, $S(\mathbf{X})$ es el conjunto de todos los $\boldsymbol{\theta} \in \Theta$ tales que la hipótesis de que el valor verdadero es $\boldsymbol{\theta}$, es aceptada cuando se observa $\mathbf{X}$.

Demostremos que $S(\mathbf{X})$ así definida, es una región de confianza de nivel $(1 - \alpha)$ para $\boldsymbol{\theta}$,

$$\mathbb{P}_{\boldsymbol{\theta}}(\boldsymbol{\theta} \in S(\mathbf{X})) = \mathbb{P}_{\boldsymbol{\theta}}(\varphi_{\boldsymbol{\theta}}(\mathbf{X}) = 0) = 1 - \mathbb{P}_{\boldsymbol{\theta}}(\varphi_{\boldsymbol{\theta}}(\mathbf{X}) = 1) = 1 - \alpha.$$

Recíprocamente, si se tiene una región de confianza $S(\mathbf{X})$ de nivel $(1 - \alpha)$ para $\boldsymbol{\theta}$, se puede construir un test de nivel α , φ_{θ_0} , para

$$H : \boldsymbol{\theta} = \boldsymbol{\theta}_0 \text{ contra } K : \boldsymbol{\theta} \neq \boldsymbol{\theta}_0.$$

Se define $\varphi_{\theta_0}(\mathbf{X}) = \begin{cases} 1 & \boldsymbol{\theta}_0 \notin S(\mathbf{X}) \\ 0 & \boldsymbol{\theta}_0 \in S(\mathbf{X}) \end{cases}$ tal que

$$\mathbb{P}_{\boldsymbol{\theta}_0}(\varphi_{\boldsymbol{\theta}_0}(\mathbf{X}) = 1) = \mathbb{P}_{\boldsymbol{\theta}_0}(\boldsymbol{\theta}_0 \notin S(\mathbf{X})) = 1 - \mathbb{P}_{\boldsymbol{\theta}_0}(\boldsymbol{\theta}_0 \in S(\mathbf{X})) = 1 - (1 - \alpha) = \alpha.$$

Es decir, φ tiene realmente nivel de significación α .

3.10. Cotas de confianza óptimas

Teorema 3.30. Sea φ_{θ_0} el test no aleatorizado (si existe) UMP de nivel α para

$$H : \theta = \theta_0 \text{ contra } K : \theta > \theta_0.$$

Dada $X_1, \dots, X_n$ y siendo $S(\mathbf{X}) = \{\boldsymbol{\theta} : \varphi_{\boldsymbol{\theta}}(\mathbf{X}) = 0\}$.

- (i) $S(\mathbf{X})$ es una región de confianza de nivel $(1 - \alpha)$ para θ .
- (ii) Si $\varphi_{\theta_0}^*$ es cualquier otro test no aleatorizado de nivel α para esas hipótesis y $S^*(\mathbf{X}) = \{\boldsymbol{\theta} : \varphi_{\boldsymbol{\theta}}^*(\mathbf{X}) = 0\}$. Entonces, $\mathbb{P}_{\theta}\{\theta_0 \in S(\mathbf{X})\} \leq \mathbb{P}_{\theta}\{\theta_0 \in S^*(\mathbf{X})\}$ para todo $\theta > \theta_0$.

Demostración.

- (i) Por la definición de $S(\mathbf{X})$ sabemos que $\theta \in S(\mathbf{X})$ si y sólo si $\varphi_{\theta}(\mathbf{X}) = 0$, luego

$$\mathbb{P}_{\theta}\{\theta \in S(\mathbf{X})\} = \mathbb{P}_{\theta}\{\varphi_{\theta}(\mathbf{X}) = 0\} = 1 - \alpha$$

por ser φ_{θ} de nivel α .

- (ii) Igual que en el inciso anterior, $S^*(\mathbf{X})$ será una región de confianza de nivel $(1 - \alpha)$. Por ser φ_{θ_0} el test UMP para

$$H : \theta = \theta_0 \text{ contra } K : \theta > \theta_0,$$

resulta que

$$\beta_{\varphi_{\theta_0}}(\theta) \geq \beta_{\varphi_{\theta_0}^*}(\theta), \forall \theta \in \Theta \Rightarrow \mathbb{P}_{\theta}\{\varphi_{\theta}(\mathbf{X}) = 1\} \geq \mathbb{P}_{\theta}\{\varphi_{\theta}^*(\mathbf{X}) = 1\}, \forall \theta \in \Theta \Rightarrow \mathbb{P}_{\theta}\{\varphi_{\theta}(\mathbf{X}) = 0\} \leq \mathbb{P}_{\theta}\{\varphi_{\theta}^*(\mathbf{X}) = 0\}, \forall \theta \in \Theta$$

pero como $\theta_0 \in S(\mathbf{X})$ si y sólo si $\varphi_{\theta_0}(\mathbf{X}) = 0$ y $\theta_0 \in S^*(\mathbf{X})$ si y sólo si $\varphi_{\theta_0}^*(\mathbf{X}) = 0$, se tiene que

$$\mathbb{P}_{\theta}\{\varphi_{\theta}(\mathbf{X}) = 0\} \leq \mathbb{P}_{\theta}\{\varphi_{\theta}^*(\mathbf{X}) = 0\}, \forall \theta \in \Theta \Leftrightarrow \mathbb{P}_{\theta}\{\theta_0 \in S(\mathbf{X})\} \leq \mathbb{P}_{\theta}\{\theta_0 \in S^*(\mathbf{X})\}, \forall \theta \in \Theta.$$

□

Teorema 3.31. Sea $\mathbf{X}$ con distribución perteneciente a una familia $F(\mathbf{x}, \theta)$ de cociente de verosimilitud monótono en $T = r(\mathbf{X})$. Supongamos que la función de distribución $F_T(t, \theta)$ de T es continua para todo θ . Sea, para cada $\theta_0 \in \Theta$, $\varphi_{\theta_0}(\mathbf{X})$ el test UMP para

$$H : \theta = \theta_0 \text{ contra } K : \theta > \theta_0,$$

o sea,

$$\varphi_{\theta_0}(\mathbf{X}) = \begin{cases} 1 & T > k_{\alpha}(\theta_0) \\ 0 & T \leq k_{\alpha}(\theta_0) \end{cases}$$

Si además $F_T(t, \theta)$ es continua en θ para cada t fijo, la región de confianza

$$S(\mathbf{X}) = \{\theta \in \Theta : \varphi_{\theta_0}(\mathbf{X}) = 0\} = \{\theta \in \Theta : T = r(\mathbf{X}) \leq k_{\alpha}(\theta_0)\}$$

es el intervalo $I = [\underline{\theta}(\mathbf{X}), +\infty]$, donde $\underline{\theta}(\mathbf{X}) = \inf\{S(\mathbf{X})\}$.

Demostración. Ya se ha demostrado que si se tiene una familia de cociente de verosimilitud monótono en $\mathbf{T} = r(\mathbf{X})$, el test UMP para

$$H : \theta = \theta_0 \text{ contra } K : \theta > \theta_0,$$

es de la forma

$$\varphi_{\theta_0}(\mathbf{X}) = \begin{cases} 1 & \mathbf{T} > k_\alpha(\theta_0) \\ \gamma_\alpha(\theta_0) & \mathbf{T} = k_\alpha(\theta_0) \\ 0 & \mathbf{T} < k_\alpha(\theta_0) \end{cases}, \text{ con } \gamma_\alpha(\theta_0), k_\alpha(\theta_0) \text{ tales que } \mathbb{E}_{\theta_0}(\varphi_{\theta_0}(\mathbf{X})) = \alpha.$$

Como $\mathbf{T}$ tiene distribución continua, no es necesario aleatorizar y, por lo tanto, el test UMP resulta

$$\varphi_{\theta_0}(\mathbf{X}) = \begin{cases} 1 & \mathbf{T} > k_\alpha(\theta_0) \\ 0 & \mathbf{T} \leq k_\alpha(\theta_0) \end{cases}$$

(i) $k_\alpha(\theta_0)$ es una función no decreciente de θ :

Sabemos que por ser φ_{θ_0} el test UMP de nivel α para H_1 contra K_1 , la función de potencia de φ_{θ_0} es mayor o igual que el nivel para todo $\theta > \theta_0$. Luego, dado cualquier $\theta_1 > \theta_0$ se cumple

$$\alpha = \mathbb{E}_{\theta_0}(\varphi_{\theta_0}(\mathbf{X})) = \mathbb{P}_{\theta_0}(\mathbf{T} \geq k_\alpha(\theta_0)) \leq \mathbb{E}_{\theta_1}(\varphi_{\theta_0}(\mathbf{X})) = \mathbb{P}_{\theta_1}(\mathbf{T} \geq k_\alpha(\theta_0)).$$

Como, además, $\alpha = \mathbb{E}_{\theta_1}(\varphi_{\theta_1}(\mathbf{X})) = \mathbb{P}_{\theta_1}(\mathbf{T} \geq k_\alpha(\theta_1))$ se tiene que $\alpha = \mathbb{P}_{\theta_1}(\mathbf{T} \geq k_\alpha(\theta_1)) \leq \mathbb{P}_{\theta_1}(\mathbf{T} \geq k_\alpha(\theta_0))$, entonces es posible tomar $k_\alpha(\theta_1)$ tal que $k_\alpha(\theta_1) \geq k_\alpha(\theta_0)$.

De donde se deduce que $k_\alpha(\theta)$ es una función no decreciente de θ .

(ii) $k_\alpha(\theta_0)$ es una función continua a derecha:

Sea θ_n una sucesión decreciente que converge a θ y como $k_\alpha(\cdot)$ es no decreciente se tiene $k_\alpha(\theta_n) \geq k_\alpha(\theta)$.

Sea $k = \lim_{n \rightarrow \infty} k_\alpha(\theta_n) = \inf_{n \in \mathbb{N}} k_\alpha(\theta_n)$. Luego $k \geq k_\alpha(\theta_n) \geq k_\alpha(\theta)$ y bastará mostrar que $k \leq k_\alpha(\theta)$.

Como $k \leq k_\alpha(\theta_n)$ vale que

$$\left. \begin{aligned} \mathbb{P}_{\theta_n}(\mathbf{T} \leq k) &\leq \mathbb{P}_{\theta_n}(\mathbf{T} \leq k_\alpha(\theta_n)) = \alpha \\ \mathbb{P}_\theta(\mathbf{T} \leq k) &= \lim_{n \rightarrow \infty} \mathbb{P}_{\theta_n}(\mathbf{T} \leq k) \end{aligned} \right\} \Rightarrow \mathbb{P}_\theta(\mathbf{T} \leq k) \leq \alpha = \mathbb{P}_\theta(\mathbf{T} \leq k_\alpha(\theta))$$

luego, es posible tomar $k_\alpha(\theta)$ tal que $k \leq k_\alpha(\theta)$. Con lo cual, $k = k_\alpha(\theta)$ y $k_\alpha(\theta)$ es continua a derecha.

Veamos que $\theta \in S(\mathbf{X})$ si y sólo si $\theta \geq \underline{\theta}(\mathbf{X})$:

($\Rightarrow$): Si $\theta \in S(\mathbf{X})$ entonces $\mathbf{T} \leq k_\alpha(\theta)$ de donde $\theta \in \{\theta \in \Theta : \mathbf{T} \leq k_\alpha(\theta)\}$ y $\theta \geq \underline{\theta}(\mathbf{X})$.

($\Leftarrow$): Si $\theta > \underline{\theta}(\mathbf{X})$ entonces existe $\theta' \in \Theta$ tal que $\mathbf{T} \leq k_\alpha(\theta')$ con $\underline{\theta}(\mathbf{X}) < \theta' \leq \theta$. Pero como $k_\alpha(\cdot)$ es creciente, resulta que $\mathbf{T} \leq k_\alpha(\theta)$ y, por lo tanto, $\theta \in S(\mathbf{X})$.

Si $\theta = \underline{\theta}(\mathbf{X})$, existe una sucesión θ_n decreciente que converge a θ y tal que $\theta_n \in \{\theta \in \Theta : \mathbf{T} \leq k_\alpha(\theta)\}$. Por lo tanto, $\mathbf{T} \leq k_\alpha(\theta_n)$.

Luego, la continuidad a derecha de $k_\alpha(\theta)$ implica que $\mathbf{T} \leq k_\alpha(\theta)$ y, por lo tanto, $\theta \in S(\mathbf{X})$. $\square$

Teorema 3.32. Sea $\mathbf{X} = (X_1, \dots, X_n)$ una muestra aleatoria de una distribución perteneciente a una familia $F(\mathbf{x}, \theta)$ de cociente de verosimilitud monótono en $\mathbf{T} = r(\mathbf{X})$ y sea, para cada $\theta_0 \in \Theta$, φ_{θ_0} el test UMP para

$$H : \theta = \theta_0 \text{ contra } K : \theta > \theta_0,$$

o sea,

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \mathbf{T} > k_\alpha(\theta_0) \\ 0 & \mathbf{T} \leq k_\alpha(\theta_0) \end{cases}$$

suponiendo que la distribución $F_T(t, \theta)$ de $\mathbf{T}$ es continua para todo θ . Supongamos además $F_T(t, \theta)$ es continua en θ para cada t fijo. En estas condiciones

$$\underline{\theta}(\mathbf{X}) = \inf\{\theta \in \Theta : \mathbf{T} \leq k_\alpha(\theta)\}$$

es una cota inferior para θ uniformemente óptima.

Demostración. De acuerdo a la definición de cota inferior con nivel de confianza $(1 - \alpha)$ uniformemente óptima deberá demostrarse que

(i) $\mathbb{P}_\theta(\theta \geq \underline{\theta}(\mathbf{X})) = 1 - \alpha$ para todo θ

(ii) Si $\underline{\theta}^*$ es otra cota inferior a nivel α para θ

$$\mathbb{E}_\theta(D(\theta, \underline{\theta})) \leq \mathbb{E}_\theta(D(\theta, \underline{\theta}^*)), \text{ para todo } \theta$$

donde D es una medida de la subevaluación de $\underline{\theta}$ respecto de θ , definida por

$$D(\theta, \underline{\theta}) = \begin{cases} \theta - \underline{\theta} & \theta > \underline{\theta} \\ 0 & \theta \leq \underline{\theta} \end{cases}.$$

- (i) Esto se deduce del hecho de que $S(\mathbf{X}) = \{\theta \in \Theta : \theta \geq \underline{\theta}(\mathbf{X})\}$ es un intervalo de nivel de confianza $1 - \alpha$.
(ii) Se demostrará que dada cualquier otra cota $\underline{\theta}^*$ a nivel $1 - \alpha$.

$$\mathbb{P}_\theta\{\theta' \geq \underline{\theta}\} \leq \mathbb{P}_\theta\{\theta' \geq \underline{\theta}^*\}, \text{ para todo } \theta' \leq \theta.$$

Dado $\theta' \in \Theta$ se define

$$\varphi_{\theta'}^*(\mathbf{X}) = \begin{cases} 1 & \theta' \leq \underline{\theta}^* \\ 0 & \theta' > \underline{\theta}^* \end{cases}$$

Luego, $\varphi_{\theta'}^*(\mathbf{X})$ es un test de nivel α para

$$H : \theta = \theta' \text{ contra } K : \theta > \theta'$$

Como $\varphi_{\theta'}(\mathbf{X})$ es el UMP para estas hipótesis y por un Teorema visto anteriormente sabemos que

$$\mathbb{P}_\theta\{\theta' \geq \underline{\theta}(\mathbf{X})\} \leq \mathbb{P}_\theta\{\theta' \geq \underline{\theta}^*(\mathbf{X})\}, \text{ para todo } \theta' \leq \theta.$$

y como esto se puede hacer para todo $\theta' \in \Theta$ resulta que $\mathbb{P}_\theta\{\theta' \geq \underline{\theta}\} \leq \mathbb{P}_\theta\{\theta' \geq \underline{\theta}^*\}$, para todo $\theta' \leq \theta$. $\square$

3.11. Relación entre intervalos de confianza con nivel asintótico $1 - \alpha$ y test con nivel de significación asintótico α

Supongamos que $X_1, \dots, X_n$ es una muestra aleatoria de una distribución perteneciente a la familia $F(\mathbf{x}, \boldsymbol{\theta})$ y que para cada $\boldsymbol{\theta}_0$ se tenga una sucesión de test $\varphi_{n, \boldsymbol{\theta}_0}(X_1, \dots, X_n)$ con nivel de significación asintótico $1 - \alpha$ para

$$H : \boldsymbol{\theta} = \boldsymbol{\theta}_0 \text{ contra } K : \boldsymbol{\theta} \neq \boldsymbol{\theta}_0.$$

Luego, puede construirse una sucesión de intervalos de confianza con nivel asintótico $1 - \alpha$ definiendo

$$S_n(X_1, \dots, X_n) = \{\boldsymbol{\theta} : \varphi_{n, \boldsymbol{\theta}}(\mathbf{X}) = 0\}.$$

Recíprocamente, dada una sucesión de intervalos de confianza $S_n(X_1, \dots, X_n)$ de nivel asintótico $1 - \alpha$, si definimos

$$\varphi_{n, \boldsymbol{\theta}_0}(X_1, \dots, X_n) = \begin{cases} 1 & \boldsymbol{\theta}_0 \notin S_n(X_1, \dots, X_n) \\ 0 & \boldsymbol{\theta}_0 \in S_n(X_1, \dots, X_n) \end{cases}$$

se tiene que $\varphi_{n, \boldsymbol{\theta}_0}$ es una sucesión de test con nivel de significación asintótico α para

$$H : \boldsymbol{\theta} = \boldsymbol{\theta}_0 \text{ contra } K : \boldsymbol{\theta} \neq \boldsymbol{\theta}_0.$$

3.12. Ejercicios

3.12.1. Conceptos Básicos y Tests Bajo Normalidad

- Una colonia de ratones de laboratorio tiene varios cientos de animales. El peso en gramos de los ratones adultos sigue una distribución normal con media igual a $30g$ y desvío estándar de $5g$. Como parte de un experimento, se les pidió a algunos estudiantes que eligieran 25 ratones adultos, sin ninguna premisa. Se asume que el peso de los ratones elegidos por estos estudiantes sigue una distribución normal con desvío estándar (poblacional) igual a $5g$ y media no menor a $30g$. Se quiere hacer un test de hipótesis para ver si hay evidencia de que los estudiantes tienden a elegir los ratones más pesados, es decir, si el peso medio de los ratones elegidos por los estudiantes es mayor a $30g$.
 - Plantear un test de hipótesis de nivel $0,05$ para esta situación. Recordar definir las variables involucradas, las hipótesis a testear, el estadístico del test, su distribución bajo la hipótesis nula y la región de rechazo.
 - Si el peso promedio de los 25 ratones elegidos fue de $33g$, ¿hay evidencia a nivel $0,05$ de que los estudiantes tienden a elegir ratones más pesados? Hallar el p -valor del test.

Solución: Sea $X_i := \{\text{peso del ratón } i\}$ tal que $X_i \sim N(\mu, 5)$ con $\mu \geq 30$ para todo $i \in \{1, \dots, 25\}$.

- (a) Sea el test $H_0 : \mu = 30$ vs. $H_1 : \mu > 30$.

Buscamos p_{30} (rechazar H_0) = $\beta_\varphi(30) = \alpha = 0,05$ con estadístico $T(\mathbf{X}) = \sqrt{n} \frac{\overline{X_n} - 30}{5} \sim N(0, 1)$ bajo H_0 .

Luego,

$$\varphi(\mathbf{X}) = \begin{cases} 1 & T(\mathbf{X}) \geq z_\alpha \\ 0 & T(\mathbf{X}) < z_\alpha \end{cases} = \begin{cases} 1 & T(\mathbf{X}) \geq z_{0,05} = 1,65 \\ 0 & T(\mathbf{X}) < z_\alpha = 1,65 \end{cases}$$

Por lo tanto, la región de rechazo es $[1,65, +\infty)$.

- (b) Notemos que $T_{obs}(\mathbf{X}) = \sqrt{25} \frac{33 - 30}{5} = 3 > 1,65$. Por lo tanto, hay evidencia a nivel 0,05 de rechazar H_0 .

Por último, sea $Z \sim N(0, 1)$ entonces el p -valor es $p(Z \geq 3) = 0,0013$.

2. El precio del viaje en taxi (en pesos) desde Aeroparque hasta el Obelisco es una variable aleatoria con distribución $N(350, 625)$ cuando el taxímetro no está alterado. La CNRT (Comisión Nacional de Regulación de Transporte) sospecha que un determinado taxista (llamémoslo Rubén) alteró el taxímetro de su vehículo para cobrar más caro. Supongamos que la CNRT tiene acceso al valor de los viajes que hace Rubén desde Aeroparque hasta el Obelisco.

Asumiremos que estos viajes tienen distribución normal con la misma varianza que la de los taxímetros no alterados. En el caso en que haya evidencia de que el taxímetro de Rubén fue alterado, se le quitará la licencia al conductor.

Se quiere que la probabilidad de error de tipo I (es decir, que se alteró el taxímetro cuando esto es falso) sea de $\alpha = 0,05$. Por otra parte, se quiere tener una probabilidad de al menos 0,99 de quitarle la licencia a Rubén cuando la media del valor de sus viajes es 375 pesos.

- Determinar cuántos viajes necesita observar la CNRT para poder armar un test con estas propiedades. Indicar claramente cuáles son las variables involucradas, las hipótesis del test, su estadístico y su distribución bajo la hipótesis nula y la región de rechazo.
- Supongamos que se observaron $n = 30$ viajes y el valor promedio de los mismos fue de 360 pesos. ¿Qué decisión se toma en este caso? Hallar el p -valor para estos datos.

Solución:

- (a) Sea $X_1, \dots, X_n$ una m.a. tal que $X_i \sim N(\mu, 625)$ para todo $i \in \{1, \dots, n\}$.

Se quiere testear $H_0 : \mu = 350$ vs. $H_1 : \mu > 350$ tal que

$$p_{\mu=350}(\text{rechazar } H_0) = \beta_{\varphi}(350) = \alpha = 0,05 \text{ y } p_{\mu=375}(\text{rechazar } H_0) = \beta_{\varphi}(375) \geq 0,99$$

usando el estadístico $T(\mathbf{X}) = \sqrt{n} \frac{\bar{X}_n - 350}{25} \sim N(0, 1)$ bajo H_0 . Luego,

$$\varphi(\mathbf{X}) = \begin{cases} 1 & T(\mathbf{X}) \geq z_{\alpha} \\ 0 & T(\mathbf{X}) < z_{\alpha} \end{cases} = \begin{cases} 1 & T(\mathbf{X}) \geq z_{0,05} = 1,65 \\ 0 & T(\mathbf{X}) < z_{\alpha} = 1,65 \end{cases}$$

Por lo tanto, la región de rechazo es $[1,65, +\infty)$.

Además, buscamos $p_{\mu=375}(\text{rechazar } H_0) \geq 0,99$,

$$p_{\mu=375}(\text{rechazar } H_0) = p_{\mu=375} \left(\sqrt{n} \frac{\bar{X}_n - 350}{25} \geq 1,65 \right) = p_{\mu=375} \left(\sqrt{n} \frac{\bar{X}_n - 375}{25} \geq 1,65 - \sqrt{n} \right) \Rightarrow$$

$$p(Z \geq 1,65 - \sqrt{n}) \geq 0,99 \Leftrightarrow p(Z \leq 1,65 - \sqrt{n}) \geq 0,01 \Leftrightarrow$$

$$1,65 - \sqrt{n} \leq -z_{0,01} \Leftrightarrow 1,65 - \sqrt{n} \leq -2,32 \Leftrightarrow n \geq 16.$$

Es decir, la CNRT necesita observar por lo menos 16 viajes.

- (b) Notemos que $T_{obs}(\mathbf{X}) = \sqrt{30} \frac{360 - 350}{25} \approx 2,19 > 1,65$. Por lo tanto, hay evidencia a nivel 0,05 de rechazar H_0 .

Por último, sea $Z \sim N(0, 1)$ entonces el p -valor es $p(Z \geq 2,19) = 0,0143$.

3. Consideremos un procedimiento para medir el contenido de manganeso en un mineral. A este procedimiento se lo ha usado muchas veces y se sabe que las mediciones siguen una distribución normal cuya desviación estándar (poblacional) es 0,15. Se está estudiando si el método tiene error sistemático (es decir, si su media es distinta de lo que debería ser).

- Se hacen 8 determinaciones de un mineral preparado que tiene 7% de manganeso y se obtienen los siguientes resultados:

$$6,90 \quad 7,10 \quad 7,20 \quad 7,07 \quad 7,15 \quad 7,04 \quad 7,18 \quad 6,95 \quad (\bar{x} = 7,074)$$

¿Cuál es su conclusión si desea que la probabilidad de equivocarse al decir que el método tiene error sistemático cuando en realidad no lo tiene sea 0,05?

- Si el método tiene un error sistemático de 0,10 (o sea, si la media es 7,10), ¿cuál es la probabilidad de cometer error de tipo II?

- c) Se quiere aplicar un test estadístico de modo que, al igual que en el inciso a), la probabilidad de decir que hay error sistemático cuando no lo hay sea 0,05. Además, se desea que si hay un error sistemático de 0,10, la probabilidad de detectarlo sea $\geq 0,80$ (o lo que es equivalente, la probabilidad de error tipo II sea $\leq 0,20$).

- 1) El test del inciso a) ¿cumple con este requisito?
- 2) En caso contrario, ¿cuántas determinaciones habría que hacer como mínimo?

Solución:

- (a) Sea $X_1, \dots, X_n$ una m.a. tal que $X_i \sim N(\mu, (0,15)^2)$ para todo $i \in \{1, \dots, n\}$.

Se quiere testear $H_0 : \mu = \mu_0$ vs. $H_1 : \mu \neq \mu_0$ usando el estadístico $T(\mathbf{X}) = \sqrt{n} \left| \frac{\bar{X}_n - \mu_0}{0,15} \right|$. Luego,

$$\varphi(\mathbf{X}) = \begin{cases} 1 & T(\mathbf{X}) \geq z_{\alpha/2} \\ 0 & T(\mathbf{X}) < z_{\alpha/2} \end{cases} = \begin{cases} 1 & T(\mathbf{X}) \geq 0,674 \\ 0 & T(\mathbf{X}) < 0,674 \end{cases}$$

Notemos que $T_{obs}(\mathbf{X}) = \sqrt{8} \left| \frac{7,074 - 7}{0,15} \right| \approx 1,3953 > 0,6745$. Por lo tanto, hay evidencia para concluir que el método tiene error sistemático.

- (b) $p_{\mu=7,10}(\text{rechazar } H_0) = 1 - \beta_{\varphi}(7,10) = 1 - \left[1 - \phi \left(0,674 + 0,10 \frac{\sqrt{8}}{0,15} \right) \right] = \phi(2,5596)$.

4. Una asociación de consumidores, preocupada por el porcentaje de grasa contenida en una marca de hamburguesas, envía a un laboratorio independiente una muestra aleatoria de 12 hamburguesas para su análisis. El porcentaje de grasa en cada una de las hamburguesas de la muestra es:

21 18 19 16 18 24 22 19 24 14 18 15

El fabricante afirma que el contenido medio de grasa de este tipo de hamburguesas es menor al 18 %. Basándose en la salida de R que figura más abajo, resuelva los siguientes items.

- a) La asociación de consumidores quiere saber si tiene motivos para decir que la afirmación del fabricante es falsa. Asumiendo que el contenido de grasa de cada hamburguesa de esta marca es una v.a con distribución normal con varianza desconocida y media no menor a 18 %, proponer un test para resolver este problema. Calcular el p -valor. ¿Rechazaría la hipótesis nula a nivel 0,08?
- b) Intentar calcular la potencia del test en este caso cuando el contenido medio de grasa es 20 %. Respecto del ejercicio anterior, ¿qué dificultad aparece cuando uno intenta hacer esta cuenta? Opcional: pensar alguna forma computacional de hacer esta cuenta.

```
hamburguesas<-scan()
```

```
21 18 19 16 18 24 22 19 24 14 18 15
```

```
c(mean(hamburguesas),var(hamburguesas),sd(hamburguesas))
```

```
[1] 19.000000 10.545455 3.247377
```

Sugerencia: usar que si $X_1, \dots, X_n$ son i.i.d. $N(\mu, \sigma^2)$, entonces

$$\sqrt{n} \frac{\bar{X} - \mu}{s} \sim T_{n-1}$$

donde T_{n-1} es una T de Student con $n - 1$ grados de libertad y $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$.

5. Se mide el grado de impurezas de un producto químico. El método de medición está afectado por un error que se supone $N(0, \sigma^2)$, σ^2 desconocido. Además, los errores correspondientes a diferentes mediciones son independientes entre sí. Se hicieron 12 observaciones obteniendo que el promedio es 0,85 con un desvío estándar muestral de 0,05.

- a) A partir de estos datos, ¿hay evidencia significativa para decir que el grado de impurezas del producto es distinto de 0,7 a nivel 0,05? Hallar el p -valor.
- b) Consideremos las hipótesis $H_0 : \sigma = 0,03$ vs. $H_1 : \sigma > 0,03$. ¿Hay evidencia para rechazar H_0 a nivel 0,05? Calcular el p -valor.

Sugerencia: usar que si $X_1, \dots, X_n$ son i.i.d. $N(\mu, \sigma^2)$, entonces

$$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \sim \chi_n^2$$

donde χ_n^2 es una Chi Cuadrado con n grados de libertad.

6. (Para hacer con R) Sea $X_1, \dots, X_n$ una muestra aleatoria de distribución $N(\mu, \sigma^2)$ con μ y σ^2 desconocidos. Queremos testear $H_0 : \mu = 0$ vs. $H_1 : \mu \neq 0$ a nivel $\alpha = 0,05$ y para esto se desea aplicar el test t , usado en el ejercicio 3a). Supongamos fijados ciertos parámetros n, γ y c , donde $n \in \mathbb{N}$, $0 \leq \gamma$ y $c \in \mathbb{R}$. El objetivo de este ejercicio es comprobar empíricamente cuán robusto es el nivel de significación de este test bajo la presencia de datos atípicos. Consideramos el siguiente procedimiento para la simulación:

- Generar una muestra de tamaño n de una distribución $N(0, 1)$.
- Agregarle a dicha muestra una proporción γ de valores atípicos, cada uno de ellos con el valor c . Es decir, agregarle a la muestra original $n\gamma$ veces el número c .
- Aplicarle el test t a la muestra del item anterior (se puede usar el comando `t.test` de R). Rechazar H_0 si el p -valor es menor al nivel nominal 0,05.
- Repetir los items anteriores $N = 10000$ veces, contando el total de veces en que se rechazó H_0 . Se puede estimar el nivel de este test como la proporción empírica de rechazos, es decir, dividiendo la cantidad total de rechazos por N (notar que si no hubiera datos atípicos, esto debería dar cerca de 0,05).

Completar la tabla con los niveles de significación estimados para $n = 100$ y los valores indicados para γ y c . El test para estos modelos, ¿cuándo resulta liberal y cuando resulta conservador?

	c					
γ	1	3	6	10	15	20
0						
0.01						
0.05						
0.1						

7. (Para hacer con el R) A un científico le interesa analizar una cierta variable aleatoria X que tiene distribución $N(\mu, 1)$ con μ desconocido. Quiere testear $H_0 : \mu = 0$ vs. $H_1 : \mu > 0$ a nivel $\alpha = 0,05$ (en el fondo, el científico quiere rechazar la hipótesis nula). Para una muestra $X_1, \dots, X_n$, considera el estadístico $T = \sqrt{n} \bar{X}$, (que bajo H_0 tiene distribución normal estándar). El científico rechaza H_0 cuando $T > z_{0,05}$, donde z_α es el percentil $1 - \alpha$ de la normal estándar. En principio planea tomar una muestra de tamaño $n = 30$. Supongamos que en este problema en particular, las muestras se van observando secuencialmente y obtener cada una de ellas es muy caro. Por eso, para ver si puede ahorrar dinero, el científico detiene el proceso que obtiene las muestras cuando $n = 20$ y “espía” el valor del estadístico T usando estas 20 observaciones. Al mirar este valor, se da cuenta de que no supera el valor de corte $z_{0,05}$, por lo tanto continúa obteniendo las 10 observaciones restantes (si hubiera observado un valor de T mayor a $z_{0,05}$, hubiera rechazado H_0 sin necesidad de buscar más muestras). Ahora, con las 30 observaciones, vuelve a calcular el valor del estadístico T y en este caso, sí supera el valor de corte $z_{0,05}$. El científico entonces asegura que todo este procedimiento le permite rechazar H_0 a nivel 0,05.
- Probar empíricamente, a través de una simulación, que lo que dice el científico es falso. ¿A qué nivel puede rechazar H_0 con este procedimiento?
 - Hallar (a través de una simulación) la función de potencia del test correspondiente a este procedimiento, evaluada en los siguientes valores de μ : 0,5, 1, 2, 5, 10.

3.12.2. Teorema de Neyman-Pearson para Hipótesis Simples

1. Una empresa vende dos variedades de soja. La variedad 1 tiene un rendimiento por *ha.* que puede considerarse una variable aleatoria con distribución $N(37, 25)$, y la variedad 2 tiene un rendimiento por *ha.* que puede considerarse $N(40, 25)$. Un cliente realizó una compra de semillas de la variedad 2 y antes de continuar comprando a esta empresa, quiere asegurarse de que las semillas que le enviaron realmente pertenecen a esa variedad. Con ese fin, cultiva 10 parcelas de 1 *ha.* y obtiene los siguientes rendimientos:

37 39,5 41,7 42 40 41,25 43 44,05 38 38,5

El cliente quiere que la probabilidad de seguir comprando a esta empresa cuando las semillas no son de la variedad pedida sea 0,05.

- Plantear el test MP para este problema. ¿Qué decisión se toma?
- Hallar el valor p . ¿Se hubiera rechazado H_0 para $\alpha = 0,01$?
- Calcular la probabilidad del error de tipo II.
- Determinar el número n de parcelas a cultivar para que el error de tipo II tenga probabilidad menor o igual que 0,05.

Solución:

- (a) Sea $X_i = \{ \text{cultivo de la parcela } i \}$ con $i \in \{1, \dots, n\}$ y busquemos que

$$0,05 = \alpha = p(\text{rechazar } H_0 | H_0 \text{ es verdadera}) = p \left(\begin{array}{c|c} \text{seguir comprando} & \text{las semillas no son de} \\ \text{a la empresa} & \text{la variedad pedida} \end{array} \right).$$

Se quiere testear $H_0 : \mu_1 = 37$ vs. $H_0 : \mu_2 = 40$.

Veamos primero,

$$\frac{p(\mathbf{X}, \mu_2)}{p(\mathbf{X}, \mu_1)} = \frac{\left(\frac{1}{5\sqrt{2\pi}}\right)^{10} \exp \left\{ -\frac{1}{50} \sum_{i=1}^{10} (x_i - 40)^2 \right\}}{\left(\frac{1}{5\sqrt{2\pi}}\right)^{10} \exp \left\{ -\frac{1}{50} \sum_{i=1}^{10} (x_i - 37)^2 \right\}} = \exp \left\{ -\sum_{i=1}^{10} \frac{(x_i - 40)^2}{50} + \sum_{i=1}^{10} \frac{(x_i - 37)^2}{50} \right\} \Rightarrow$$

$$\frac{p(\mathbf{x}, \mu_2)}{p(\mathbf{x}, \mu_1)} = \exp \left\{ -\sum_{i=1}^{10} \frac{-80x_i + 40^2}{50} + \sum_{i=1}^{10} \frac{-37x_i + 37^2}{50} \right\}.$$

Luego,

$$\alpha = \mathbb{E}_{\mu_1}(\varphi(\mathbf{X})) = p_{\mu_1} \left(\exp \left\{ -\sum_{i=1}^{10} \frac{-80X_i + 40^2}{50} + \sum_{i=1}^{10} \frac{-37X_i + 37^2}{50} \right\} \geq k_\alpha \right) =$$

$$0,05 = p_{\mu_1} \left(6 \sum_{i=1}^{10} X_i - 10 \times 40^2 + 10 \times 37^2 \geq 50 \ln(k_\alpha) \right) = p_{\mu_1} \left(\sum_{i=1}^{10} X_i \geq \frac{10 \times 40^2 - 10 \times 37^2 + 50 \ln(k_\alpha)}{6} \right)$$

$$\Rightarrow 0,05 = p_{\mu_1} \left[\frac{1}{\sqrt{250}} \left(\sum_{i=1}^{10} X_i - 370 \right) \geq \frac{10 \times 40^2 - 10 \times 37^2 + 50 \ln(k_\alpha) - 370}{6\sqrt{250}} \right].$$

con $\frac{1}{\sqrt{250}} \left(\sum_{i=1}^{10} X_i - 370 \right) \sim N(0, 1)$. Entonces

$$\frac{10 \times 40^2 - 10 \times 37^2 + 50 \ln(k_\alpha) - 370}{6\sqrt{250}} = 1,65 \Rightarrow \ln(k_\alpha) \approx \frac{156,53 - 90}{50} \Rightarrow k_\alpha e^{1,33} \approx 3,78.$$

Finalmente,

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \frac{p(\mathbf{X}, \mu_2)}{p(\mathbf{X}, \mu_1)} \geq 3,78 \\ 0 & \text{cc} \end{cases}$$

Como $\sum_{i=1}^{10} X_i = 405$ y $e^{\frac{1}{50}(6 \times 405 - 10 \times 40^2 + 10 \times 37^2)} \geq 3,78$ se rechaza H_0 ; es decir, que se sigue comprando a la empresa.

- (b) Su p -valor es $1 - \phi \left(\frac{\sqrt{10}(40,5 - 37)}{5} \right) = 0,0136$.

Por lo tanto, no se hubiese rechazado H_0 si $\alpha = 0,01$ puesto que $\alpha < 0,0136$.

- (c)

$$p(\text{error II}) = 1 - \beta_\varphi(40) = 1 - \left[1 - \phi \left(\left(z_{0,05} \right) + \frac{\sqrt{10}(37 - 40)}{5} \right) \right] = 1 - \phi(0,2573) = 0,4013.$$

- (d) Se busca $n \in \mathbb{N}$ tal que $p(\text{error II}) \leq 0,05$.

$$\phi \left[1,65 + \frac{\sqrt{n}}{5} (37 - 40) \right] \leq 0,05 \Leftrightarrow 1,65 - \frac{3\sqrt{n}}{5} \leq \phi^{-1}(0,05).$$

2. Consideremos dos funciones de probabilidad puntual $P_0(x)$ y $P_1(x)$ dadas por la siguiente tabla:

	x_1	x_2	x_3	x_4
P_0	0.05	0.00	0.05	0.90
P_1	0.00	0.05	0.90	0.05

Se observa una v.a. X y se quiere testear $H_0 : X \sim P_0$ vs $H_1 : X \sim P_1$.

- Encontrar los 4 tests no aleatorizados de nivel $\alpha = 0,05$ para este problema.
- Entre estos 4 tests de nivel α , ¿cuál es el mejor?
- Probar que el test hallado en el inciso anterior es el más potente de nivel α .
- ¿Hay algún test no aleatorizado de nivel menor que α ? ¿Qué potencia tiene?
- Encontrar el test más potente de nivel $\alpha = 0,10$.

Solución:

- (a) Sea $\varphi(\mathbf{X}) = \begin{cases} 1 & x \in \mathbb{R} \\ 0 & cc \end{cases}$.

Se busca $0,95 = \alpha = \mathbb{E}(\varphi(\mathbf{X})) = p(\text{rechazar } H_0)$ entonces sean $R_1 = \{x_1\}$, $R_2 = \{x_1, x_2\}$, $R_3 = \{x_3\}$ y $R_4 = \{x_2, x_3\}$.

Luego, los test no aleatorizados de nivel $\alpha = 0,95$ son

$$\varphi_i(\mathbf{X}) = \begin{cases} 1 & x \in \mathbb{R}_i \\ 0 & cc \end{cases}$$

- (b) El mejor de los test será el que tenga mayor potencia, por lo tanto

$$\beta_{\varphi_i} = \mathbb{E}_{p_i}(\varphi_i) = p(x \in R_i) = \begin{cases} 0 & i = 1 \\ 0,05 & i = 2 \\ 0,90 & i = 3 \\ 0,95 & i = 4 \end{cases}$$

$\Rightarrow \varphi_4(x)$ es el mejor.

- (c)

$$\frac{p_1(\mathbf{X})}{p_0(\mathbf{X})} = \begin{cases} 0 & X = x_1 \\ +\infty & X = x_2 \\ 18 & X = x_3 \\ \frac{1}{18} & X = x_4 \end{cases}$$

Si $k_\alpha = 0$:

$$\begin{aligned} 0,05 &= \mathbb{E}_{p_0}(\varphi(\mathbf{X})) = p_0\left(\frac{p_1(\mathbf{X})}{p_0(\mathbf{X})} > 0\right) + \gamma_\alpha p_0\left(\frac{p_1(\mathbf{X})}{p_0(\mathbf{X})} = 0\right) \Rightarrow \\ 0,05 &= \mathbb{E}_{p_0}(\varphi(\mathbf{X})) = p_0(X = x_2) + p_0(X = x_3) + p_0(X = x_4) + \gamma_\alpha p_0(X = x_1), \\ 0,05 &= 0,05 + 0,9\gamma_\alpha 0,05 \Rightarrow \gamma_\alpha < 0 \end{aligned}$$

lo que resulta ser una contradicción.

Si $k_\alpha = 18$:

$$\begin{aligned} 0,05 &= \mathbb{E}_{p_0}(\varphi(\mathbf{X})) = p_0\left(\frac{p_1(\mathbf{X})}{p_0(\mathbf{X})} > 18\right) + \gamma_\alpha p_0\left(\frac{p_1(\mathbf{X})}{p_0(\mathbf{X})} = 18\right) \Rightarrow \\ 0,05 &= \mathbb{E}_{p_0}(\varphi(\mathbf{X})) = p_0(X = x_2) + \gamma_\alpha p_0(X = x_3), \\ 0,05 &= 0 + \gamma_\alpha 0,05 \Rightarrow \gamma_\alpha = 1 \\ \varphi(\mathbf{X}) &= \begin{cases} 0 & X = x_2 \text{ o } X = x_3 \\ 0 & cc \end{cases} \end{aligned}$$

Si $k_\alpha = \frac{1}{18}$:

$$\begin{aligned} 0,05 &= \mathbb{E}_{p_0}(\varphi(\mathbf{X})) = p_0\left(\frac{p_1(\mathbf{X})}{p_0(\mathbf{X})} > \frac{1}{18}\right) + \gamma_\alpha p_0\left(\frac{p_1(\mathbf{X})}{p_0(\mathbf{X})} = \frac{1}{18}\right) \Rightarrow \\ 0,05 &= \mathbb{E}_{p_0}(\varphi(\mathbf{X})) = p_0(X = x_2) + p_0(X = x_3) + \gamma_\alpha p_0(X = x_4), \\ 0,05 &= 0,05 + \gamma_\alpha 0,90 \Rightarrow \gamma_\alpha = 0 \\ \varphi(\mathbf{X}) &= \begin{cases} 0 & X = x_2 \text{ o } X = x_3 \\ 0 & cc \end{cases} \end{aligned}$$

Por lo tanto, por Neyman-Pearson, $\varphi_4(\mathbf{X})$ es el test MP de nivel α .

(d) Sea $\varphi(\mathbf{X}) = \begin{cases} 1 & X = x_2 \\ 0 & cc \end{cases}$, entonces

$$\alpha = \mathbb{E}_{P_0}(\varphi(\mathbf{X})) = p_0(X = x_2) = 0 \text{ y } \beta(\varphi(\mathbf{X})) = \mathbb{E}_{p_1}(\varphi(\mathbf{X})) = p_1(X = x_2) = 0,05$$

Es decir, existe un test no aleatorizado de nivel menor que α .

(e) Por Neyman-Pearson para $\alpha = 0,01$,

Si $k_\alpha = 0$:

$$\begin{aligned} 0,1 &= p_0\left(\frac{p_1(\mathbf{X})}{p_0(\mathbf{X})} > 0\right) + \gamma_\alpha p_0\left(\frac{p_1(\mathbf{X})}{p_0(\mathbf{X})} = 0\right) \Rightarrow \\ 0,1 &= p_0(X = x_2) + p_0(X = x_3) + p_0(X = x_4) + \gamma_\alpha p_0(X = x_1), \\ 0,1 &= 0,05 + 0,9\gamma_\alpha 0,05 \Rightarrow \gamma_\alpha < 0 \end{aligned}$$

lo que resulta ser una contradicción.

Si $k_\alpha = 18$:

$$\begin{aligned} 0,1 &= \mathbb{E}_{p_0}(\varphi(\mathbf{X})) = p_0\left(\frac{p_1(\mathbf{X})}{p_0(\mathbf{X})} > 18\right) + \gamma_\alpha p_0\left(\frac{p_1(\mathbf{X})}{p_0(\mathbf{X})} = 18\right) \Rightarrow \\ 0,1 &= \mathbb{E}_{p_0}(\varphi(\mathbf{X})) = p_0(X = x_2) + \gamma_\alpha p_0(X = x_3), \\ 0,1 &= 0 + \gamma_\alpha 0,05 \Rightarrow \gamma_\alpha = 2 \end{aligned}$$

lo que resulta ser una contradicción.

Si $k_\alpha = \frac{1}{18}$:

$$\begin{aligned} 0,1 &= \mathbb{E}_{p_0}(\varphi(\mathbf{X})) = p_0\left(\frac{p_1(\mathbf{X})}{p_0(\mathbf{X})} > \frac{1}{18}\right) + \gamma_\alpha p_0\left(\frac{p_1(\mathbf{X})}{p_0(\mathbf{X})} = \frac{1}{18}\right) \Rightarrow \\ 0,1 &= \mathbb{E}_{p_0}(\varphi(\mathbf{X})) = p_0(X = x_2) + p_0(X = x_3) + \gamma_\alpha p_0(X = x_4), \\ 0,1 &= 0,05 + \gamma_\alpha 0,90 \Rightarrow \gamma_\alpha = \frac{1}{18} \\ \varphi(\mathbf{X}) &= \begin{cases} 1 & X = \{x_2, x_3\} \\ \frac{1}{18} & X = x_4 \\ 0 & cc \end{cases} \end{aligned}$$

3.12.3. Tests para Familias con Cociente de Verosimilitud Monótono

1. Probar que las siguientes familias son de cociente de verosimilitud monótono:

a) $\mathcal{U}(\theta, \theta + 1)$

b) Las familias exponenciales a un parámetro con densidad o probabilidad

$$p(x|\theta) = a(\theta)h(x)\exp(c(\theta)t(x))$$

siempre que $c(\theta)$ sea estrictamente creciente. Luego las familias: binomial, binomial negativa, Poisson, Gamma, Beta y Normal (estas 3 últimas considerando uno de los parámetros fijos) son de CVM.

c) La familia doble exponencial

$$f(x|\alpha, \beta) = \frac{1}{2\beta} \exp \left\{ -\frac{|x - \alpha|}{\beta} \right\}$$

con β desconocido.

d) La familia exponencial negativa

$$f(x|\alpha) = \exp \{-(x - \alpha)\} I_{(\alpha, \infty)}(x)$$

2. a) Dada $X_1, \dots, X_n$ una m.a. de una distribución $\mathcal{E}(\lambda)$, hallar el test UMP de nivel α para $H_0 : \lambda \geq \lambda_0$ vs $H_1 : \lambda < \lambda_0$.
- b) Se sabe que el tiempo de duración de cierto tipo de lamparitas sigue una distribución $\mathcal{E}(\lambda)$. La empresa garantiza que el tiempo medio de vida es mayor que 50 días y quiere asegurarse que la producción satisface este requerimiento antes de sacarla a la venta. Para ello toma una muestra de 10 lamparitas y observa un tiempo promedio de duración de 41 días.
- i) Si se quiere tener un 95 % de seguridad de no vender cuando no se satisfacen los requerimientos, ¿qué decisión se toma en base a estos datos?
- ii) Calcular el p -valor.
- iii) ¿Cuál es la probabilidad de no sacar la producción a la venta si el tiempo medio de vida es de 57 días?

Solución:

- (a) $\mathbf{X}$ es una familia exponencial a un parámetro y $T(\mathbf{X}) = -\sum_{i=1}^n X_i$ es un estadístico suficiente. Entonces, $\mathbf{X}$ es CVM en $T(\mathbf{X})$ y

$$\varphi(\mathbf{X}) = \begin{cases} 1 & T(\mathbf{X}) < k_\alpha \\ \gamma_\alpha & T(\mathbf{X}) = k_\alpha \\ 0 & T(\mathbf{X}) > k_\alpha \end{cases}$$

es el test UMP de nivel menor o igual a α para $H_0 : \lambda \geq \lambda_0$ vs. $H_1 : \lambda < \lambda_0$.

Para saber el valor de k_α ,

$$\alpha = \sup_{\lambda \geq \lambda_0} \mathbb{E}_\lambda(\varphi(\mathbf{X})) = \sup_{\lambda \geq \lambda_0} \{p(T(\mathbf{X}) > k_\alpha) + \gamma_\alpha p(T(\mathbf{X}) = k_\alpha)\}$$

y puesto que $T(\mathbf{X})$ es continua, $p(T(\mathbf{X}) = k_\alpha) = 0 \Rightarrow \gamma_\alpha = 1$.

$$\begin{aligned} \alpha &= \sup_{\lambda \geq \lambda_0} p(T(\mathbf{X}) > k_\alpha) = \sup_{\lambda \geq \lambda_0} p\left(\sum_{i=1}^n X_i \geq -k_\alpha\right) = 1 - p\left(\sum_{i=1}^n X_i \leq -k_\alpha\right) \\ &\Rightarrow F^{-1}(1 - \alpha) = -k_\alpha \mid F \sim \Gamma(n, \lambda). \end{aligned}$$

(b) (i)

$$0,95 = p\left(\text{no vender} \mid \begin{array}{c} \text{no se satisfacen} \\ \text{los requisitos} \end{array}\right) \Rightarrow 0,05 = p\left(\text{vender} \mid \begin{array}{c} \text{no se satisfacen} \\ \text{los requisitos} \end{array}\right) \Rightarrow$$

$$H_0 : \lambda \geq \lambda_0 \text{ y, además, } \mathbb{E}(X) = \frac{1}{\lambda} \leq 50 \text{ por lo tanto, } H_0 : \lambda \geq \frac{1}{50}.$$

Sea el test,

$$\begin{aligned} H_0 : \lambda \geq \frac{1}{50} \text{ vs. } H_1 : \lambda < \frac{1}{50} \\ \varphi(\mathbf{X}) = \begin{cases} 1 & \sum_{i=1}^n X_i \geq -F^{-1}(1 - \alpha) \\ 0 & \sum_{i=1}^n X_i < -F^{-1}(1 - \alpha) \end{cases} \text{ con } F \sim \Gamma\left(10, \frac{1}{50}\right) \end{aligned}$$

Podemos aproximar $F^{-1}(0,95) \approx 785,26$ y, por otra parte, $\sum_{i=1}^n X_i = 410$. Entonces, $\varphi(\mathbf{X}) = 0$ y la decisión será no vender.

(ii)

$$p_{\lambda=\lambda_0}(T\mathbf{X} \geq T_{obs}) = p_{\lambda=\lambda_0}\left(\sum_{i=1}^n X_i \geq 410\right) = 1 - p_{\lambda=\lambda_0}\left(\sum_{i=1}^n X_i < 410\right) \approx 1 - 0,30848 \approx 0,69152.$$

(iii) si $\lambda_0 = \frac{1}{57}$,

$$p_{\lambda=\lambda_0}(\text{error tipo II}) = 1 - \beta_{\varphi}(1/57) = 1 - \mathbb{E}_{\lambda_0}(\varphi(\mathbf{X})) = 1 - p_{\lambda_0} \left(\sum_{i=1}^n X_i \geq 785,6908 \right) \Rightarrow$$

$$p_{\lambda=\lambda_0}(\text{error tipo II}) = p_{\lambda_0} \left(\sum_{i=1}^n X_i \leq 785,6908 \right) \approx 0,87959.$$

3. a) Sea $X_1, \dots, X_n$ una m.a. de una distribución $Bi(1, p)$. Encontrar el test UMP de nivel α para $H_0 : p \leq p_0$ vs $H_1 : p > p_0$.
- b) Para curar cierta enfermedad se emplea actualmente un tratamiento que tiene un 40% de éxito. Un nuevo tratamiento es probado en 10 pacientes elegidos al azar y 9 de ellos se curan.
- Si se quiere que la probabilidad de adoptar el nuevo tratamiento cuando no es mejor que el actual sea 0,05, ¿qué decisión se toma?
 - Calcular el p -valor.
 - ¿Cuál es la probabilidad de no cambiar de tratamiento si el nuevo en realidad tiene una probabilidad de éxito del 45%?
- c) Seis estudiantes se pusieron a dieta para bajar de peso, con los siguientes resultados:

Nombre	Abdul	Ed	Jim	Max	Phil	Ray
Peso antes (X)	87	95	94	91	100	94
Peso después (Y)	83	93	91	89	102	90

¿Puede concluirse que esta dieta es efectiva? ¿Cuál es el p -valor para estos datos?
(AYUDA: La dieta es efectiva cuando $P(X > Y) > P(X \leq Y)$.)

Solución:

- (a) Por ser una clase de familia exponencial a un parámetro, $T(\mathbf{X}) = \sum_{i=1}^n X_i$ es suficiente y

$$c(p) = \ln(p) - \ln(1-p) = \ln\left(\frac{p}{1-p}\right) \text{ resulta creciente.}$$

Por lo tanto, $\mathbf{X}$ es CVM para T y el test UMP de nivel menor o igual a α es

$$\varphi(\mathbf{X}) = \begin{cases} 1 & T(\mathbf{X}) > k_{\alpha} \\ \gamma_{\alpha} & T(\mathbf{X}) = k_{\alpha} \text{ con } T \sim Bi(n, p) \text{ y } k_{\alpha} = F^{-1}(1-\alpha) \mid F \sim Bi(n, p). \\ 0 & T(\mathbf{X}) < k_{\alpha} \end{cases}$$

$$\alpha = \mathbb{E}_{p=p_0}(\varphi(\mathbf{X})) = p_{p_0}(T(\mathbf{X}) > k_{\alpha}) + \gamma_{\alpha} p_{p_0}(T(\mathbf{X}) = k_{\alpha}) \Rightarrow \gamma_{\alpha} = \frac{\alpha - p_{p_0}(T(\mathbf{X}) > k_{\alpha})}{p_{p_0}(T(\mathbf{X}) = k_{\alpha})}.$$

- (b) (i) $p(\text{adoptar nuevo tratamiento} \mid \text{no es mejor que el actual}) = 0,05$,
 H_0 : el nuevo tratamiento no es mejor y sabemos que "el tratamiento viejo" $\sim Be(4/10)$. Entonces

$$H_0 : p \leq 0,4 \text{ vs. } H_1 : p > 0,4$$

$$\varphi(\mathbf{X}) = \begin{cases} 1 & T(\mathbf{X}) > k_{\alpha} \\ \gamma_{\alpha} & T(\mathbf{X}) = k_{\alpha} \text{ con } T \sim Bi(10, 0,4) \text{ y } k_{\alpha} = F^{-1}(0,95) \mid F \sim Bi(10, 0,4). \\ 0 & T(\mathbf{X}) < k_{\alpha} \end{cases}$$

$$k_{\alpha} = 7 \text{ y } \gamma_{\alpha} = \frac{\alpha - p_{p_0}(T(\mathbf{X}) > k_{\alpha})}{p_{p_0}(T(\mathbf{X}) = k_{\alpha})} = \frac{0,05 - 1 + p_{p_0} \left(\sum_{i=1}^n X_i \leq 7 \right)}{p_{p_0} \left(\sum_{i=1}^n X_i = 7 \right)} \approx 0,8879695.$$

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \sum_{i=1}^{10} X_i > 7 \\ 0,88 & \sum_{i=1}^{10} X_i = 7 \\ 0 & cc \end{cases}$$

En este caso, $\sum_{i=1}^{10} X_i = 9$ entonces $\varphi(\mathbf{X}) = 1$. Por lo tanto, rechazamos H_0 ; es decir, se adoptará el nuevo tratamiento.

(ii)

$$p_{0,4} \left(\sum_{i=1}^{10} X_i > T_{obs} \right) = p_{0,4} \left(\sum_{i=1}^{10} X_i > 9 \right) = p_{0,4} \left(\sum_{i=1}^{10} X_i = 10 \right) = \binom{10}{10} (0,4)^{10} (0,6)^{10-10} = 0,00010485.$$

(iii)

$$p \left(\begin{array}{c} \text{mantener el} \\ \text{viejo tratamiento} \end{array} \middle| \begin{array}{c} \text{el nuevo tratamiento} \\ \text{es mejor} \end{array} \right) = p(\text{error tipo II}) = 1 - \beta_{\varphi}(0,45) \Rightarrow$$

$$1 - \mathbb{E}_{0,45}(\varphi(\mathbf{X})) = 1 - \left[p_{0,45} \left(\sum_{i=1}^{10} X_i > 7 \right) + 0,8878695 \times p_{0,45} \left(\sum_{i=1}^{10} X_i = 7 \right) \right] \approx 0,90637.$$

(c) Sea $X_i = \begin{cases} 1 & \text{si bajó de peso} \\ 0 & \text{cc} \end{cases}$ y $p(X > Y) \leq p(X \leq Y) \Leftrightarrow p \leq 1 - p \Leftrightarrow p \leq \frac{1}{2}$.

Luego,

$$H_0 : p \leq \frac{1}{2} \text{ vs. } H_1 : p > \frac{1}{2}$$

Además,

$$k_{\alpha} = F^{-1}(0,95) = 5 \text{ con } F \sim Bi(6, 1/2) \text{ y } \gamma_{\alpha} = \frac{\alpha - 1 + p \left(\sum_{i=1}^6 X_i \leq 5 \right)}{p_{p_0} \left(\sum_{i=1}^6 X_i = 5 \right)} \approx 0,37$$

Por lo tanto,

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \sum_{i=1}^6 X_i > 5 \\ 0,37 & \sum_{i=1}^6 X_i = 5 \\ 0 & \text{cc} \end{cases}$$

y, entonces, se rechaza H_0 con probabilidad 0,37; es decir, la dieta es efectiva con probabilidad 0,37.

3.12.4. Tests de Cociente de Máxima Verosimilitud

1. a) Sea $X_1, \dots, X_n$ una m.a. de una distribución $N(\mu, \sigma^2)$ con varianza σ^2 desconocida. Hallar el test de cociente de máxima verosimilitud de nivel α para $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$.
- b) Se diseñó un sistema de riego de manera que el tiempo promedio de activación sea exactamente 25 segundos. Se lo probó 11 veces, obteniéndose los siguientes tiempos de activación:

27 41 22 27 23 35 30 24 27 28 22

Se supone que el tiempo de activación es una v.a. con distribución normal.

- 1) A nivel 0,05, ¿contradicen estos datos las especificaciones del sistema?
- 2) Calcular el p -valor.
2. a) Sea $X_1, \dots, X_n$ una m.a. de una distribución $N(\mu_1, \sigma^2)$ e $Y_1, \dots, Y_m$ una m.a. de una distribución $N(\mu_2, \sigma^2)$ independiente de la anterior. Si llamamos $\Delta = \mu_1 - \mu_2$, probar que el test de CMV de nivel α para $H_0 : \Delta = 0$ vs $H_1 : \Delta \neq 0$ rechaza H_0 si y sólo si

$$\frac{|\bar{X} - \bar{Y}|}{S_p \sqrt{\frac{1}{n} + \frac{1}{m}}} > t_{n+m-2, \alpha/2}.$$

- b) Un terreno se divide en 20 lotes semejantes. Se pone a prueba un nuevo fertilizante (I) colocándolo por aspersión en 10 lotes elegidos al azar. En los otros 10 lotes se utiliza como control un fertilizante de uso corriente (II). En cada parcela se planta el mismo número de plantas de tomate, y se observa el rendimiento (en kg/ha) en cada lote, obteniéndose

$$\begin{array}{lll} \bar{X} & = & 130 \quad s_X = 10 \quad \text{para el fertilizante I} \\ \bar{Y} & = & 120 \quad s_Y = 8 \quad \text{para el fertilizante II} \end{array}$$

Se supone que los datos provienen de muestras aleatorias con distribución normal y varianzas iguales. Se asume además que los rendimientos en los 20 lotes son independientes.

- 1) Testear a nivel 0,05 si hay diferencia entre los rendimientos entre los dos fertilizantes.
 - 2) Calcular el p -valor. ¿Qué decisión se hubiera tomado a nivel 0,01?
3. Se tomaron aleatoriamente 8 pares de pollos hermanos y se eligió al azar dentro de cada par cuál iba a la muestra A y cuál a la B. Los pollos de la muestra A han sido criados en encierro, mientras que los de la muestra B al aire libre. Los datos siguientes corresponden al peso de los pollos de 7 semanas:

Muestra A	255	481	360	368	425	283	311	368
Muestra B	226	425	311	311	255	340	311	284

- a) ¿Existe alguna diferencia en el peso medio a las 7 semanas entre los métodos de crianza? Aplicar un test de cociente de máxima verosimilitud. ¿Para qué variable tuvo que asumir normalidad? Testear a nivel 0,01.
- b) Calcular el p -valor.

Sugerencia: ¿se trata de muestras independientes o apareadas?

3.12.5. Tests con Nivel de Significación Asintótica

1. Se supone que en cierta población de insectos la cantidad de hembras es igual a la de machos. Para poner a prueba esta creencia, un entomólogo tomó una muestra de 100 de estos insectos, resultando machos 43 de ellos.
 - a) Utilizando un test de nivel asintótico, decidir si hay suficiente evidencia a nivel 0,05 para rechazar la suposición. Calcular el valor p aproximado.
 - b) Si el porcentaje de hembras fuera 0,55, ¿cuál sería la probabilidad de tomar una decisión incorrecta?

Solución:

- (a) Sea $X_1, \dots, X_n$ tal que $X_i \sim Be(p)$ con $X_i = \begin{cases} 1 & \text{si es hembra} \\ 0 & \text{cc} \end{cases}$ y supongamos $p = 1/2$.

$$H_0 : p = \frac{1}{2} \text{ vs. } H_1 : p \neq \frac{1}{2}$$

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \left| \frac{\sqrt{n}(\bar{X}_n - \mu_0)}{\sigma} \right| > z_{\alpha/2} \\ 0 & \text{cc} \end{cases}$$

en este caso: $n = 100$, $\mu_0 = \frac{1}{2}$, $\sigma = \sqrt{\frac{1}{2} \left(1 - \frac{1}{2}\right)} = \frac{1}{2}$, $\bar{X}_n = \frac{57}{100}$ y

$$z_{\alpha/2} = F^{-1} \left(1 - \frac{\alpha}{2}\right) \approx 1,959 \text{ con } F \sim N(0, 1).$$

Como $T = 1,4 < 1,9599$ no rechazamos H_0 ; es decir, que hay suficiente evidencia para sumir que $p = \frac{1}{2}$.

Para calcular el p -valor,

$$p_{1/2}(T > T_{obs}) = p_{1/2} \left(\left| \frac{\sqrt{100}(\bar{X}_n - 1/2)}{1/2} \right| > 1,4 \right) = 2p_{1/2} \left(\frac{\sqrt{100}(\bar{X}_n - 1/2)}{1/2} > 1,4 \right) \Rightarrow$$

$$p_{1/2}(T > T_{obs}) = p_{1/2}(Z > 1,4) \approx 2 \times 0,0807 = 0,1614$$

- (b) Si $p = 0,55$,

$$p(\text{error tipo II}) = 1 - \mathbb{E}_{0,55}(\varphi(\mathbf{X})) = 1 - p \left(\left| \frac{\sqrt{100}(\bar{X}_n - 0,5)}{0,5} \right| > 1,9599 \right) \Rightarrow$$

$$p(\text{error tipo II}) = p \left(-1,96 \leq \frac{10}{1/2}(\bar{X}_n - 1/2) \leq 1,96 \right) = p \left(-\frac{1,96}{20} + \frac{1}{2} \leq \bar{X}_n \leq \frac{1,96}{20} + \frac{1}{2} \right) \Rightarrow$$

$$p(\text{error tipo II}) = p \left[(0,402 - 0,55) \frac{10}{\sqrt{0,55 \times 0,45}} \leq \frac{10(\bar{X}_n - 0,55)}{\sqrt{0,55 \times 0,45}} \leq (0,598 - 0,55) \frac{10}{\sqrt{0,55 \times 0,45}} \right] \approx 0,83.$$

2. El número de personas que llega a la boletería de una estación de trenes entre las 14 y 14 : 30 hs. tiene distribución de Poisson. El jefe de la estación está evaluando la posibilidad de abrir otra ventanilla en ese horario y considera que es necesario sólo si la media de arribos es superior a 20 individuos. Además, quiere que la probabilidad de abrir una nueva ventanilla cuando en realidad no es necesario sea a lo sumo 0,01. Durante 45 días se observa el número de personas que arriba en dicho horario y se calcula una media muestral de 21 individuos.
- Proponer un test asintótico para este problema usando el TCL. ¿Qué decisión toma en base a estos datos? ¿Cuál es el valor p aproximado?
 - Para el test del ítem anterior, ¿cuál es la probabilidad de dejar una sola boletería cuando en realidad la media verdadera es de 22 personas?
 - Si se hubiera querido que la probabilidad calculada en (b) fuera a lo sumo 0,05, ¿qué tamaño muestral debería haberse tomado?
3. a) Sean $X_1, \dots, X_n \sim \varepsilon(\lambda)$. Consideramos las hipótesis $H_0 : \lambda = \lambda_0$ vs. $H_1 : \lambda \neq \lambda_0$. Diseñar un test asintótico de nivel α para estas hipótesis usando la distribución asintótica del cociente de máxima verosimilitud.
- b) Tenemos $k \geq 2$ muestras $X_1^j, \dots, X_n^j$ para $j = 1, \dots, k$, todas independientes. Asumimos que $X_i^j \sim \varepsilon(\lambda_j)$. Se quiere testear $H_0 : \lambda_1 = \dots = \lambda_k$ vs $H_1 : \exists i \neq j / \lambda_i \neq \lambda_j$. Usando la distribución asintótica del cociente de máxima verosimilitud, plantear un test asintótico de nivel α para estas hipótesis.
4. Se ha tomado una muestra aleatoria de tamaño 30 de los días que demora una empresa en instalar una línea telefónica a partir del momento de su solicitud. Los datos obtenidos fueron los siguientes:

3, 4, 5, 3, 2, 7, 6, 4, 6, 4, 7, 2, 3, 4, 6,
7, 3, 5, 6, 6, 4, 5, 5, 7, 3, 2, 2, 4, 3, 5.

La compañía, por contrato, debe tener un valor medio de demora no mayor que 4 días. El gobierno le inició juicio a la compañía porque cree que ésta no cumplió con el contrato. El juez considera que su veredicto debe ser hecho de manera tal que la probabilidad de fallar contra la compañía cuando ésta ha cumplido con lo estipulado en el contrato sea aproximadamente 0,05.

- Suponiendo que la distribución de los tiempos de espera es $\mathcal{E}(\lambda)$, encontrar el test asintótico usando el TCL en el cual el juez debe basar su decisión y el veredicto al que arribaría con la muestra dada.
- Expresar la función de potencia del test en términos de una función de distribución conocida.
- ¿Qué tamaño de muestra debería utilizarse si se quiere que la probabilidad de condenar a la compañía sea mayor o igual a 0,99 cuando el valor medio de la demora es de 5 días?

Solución:

- (a) Sea

$$H_0 : \lambda \geq \frac{1}{4} \text{ vs. } H_1 : \lambda < \frac{1}{4}$$

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \frac{\sqrt{n}(\bar{X}_n - \frac{1}{\lambda})}{\frac{1}{\lambda}} = \frac{\sqrt{30}(\bar{X}_n - 4)}{4} \geq z_\alpha \\ 0 & \text{cc} \end{cases}$$

Luego,

$$\frac{\sqrt{30}(\bar{X}_n - 4)}{4} \approx 0,588 \text{ y } < z_\alpha = 1,65$$

por lo que como $0,588 < 1,65$, se tiene que $\varphi(\mathbf{X}) = 0$. Entonces no se rechaza H_0 .

- (b)

$$\beta_\varphi(\lambda) = p_\lambda \left(\frac{\sqrt{n}}{4} (\bar{X}_n - 4) \geq 1,65 \right) = p_\lambda \left[\frac{\sqrt{n}(\bar{X}_n - \lambda)}{\lambda} \geq \left(\frac{(\mathbf{X})}{\sqrt{n}} + 4 - \frac{1}{\lambda} \right) \frac{\sqrt{n}}{1/\lambda} \right] \Rightarrow$$

$$\beta_\varphi(\lambda) = 1 - \phi(6,6\lambda + 4\lambda\sqrt{n} - \sqrt{n}).$$

- (c)

$$0,99 \leq 1 - p(\text{error tipo II}) = \mathbb{E}_{\frac{1}{\lambda}=5}(\varphi(\mathbf{X})) = 1 - \phi\left(\frac{6,6 - \sqrt{n}}{5}\right) \Rightarrow$$

$$\phi\left(\frac{6,6 - \sqrt{n}}{5}\right) \leq 0,01 \Leftrightarrow \frac{6,6 - \sqrt{n}}{5} \leq -2,326 \Leftrightarrow n \geq 331.$$

5. Una planta de energía atómica en una ciudad de Mongolia tuvo un problema de contaminación en el año 2000. Se sabe que antes de dicho año, el 20 % de las causas de muerte tenían que ver con cáncer.

El gobierno mongol quiere estudiar si el problema contaminante aumentó la proporción poblacional de muertes por cáncer (se asume, lógicamente, que dicha proporción no pudo haber disminuido después de la contaminación).

En caso que se decida que efectivamente dicha proporción aumentó, se aplicará una multimillonaria multa a la empresa responsable. Para eso, se quiere planter un test de hipótesis de modo que la probabilidad de multar a la empresa cuando la proporción de muertes por cancer no aumentó sea 0,05.

Se tomó una muestra de 200 personas fallecidas después del año 2000 y se observó que exactamente 50 de ellas tuvieron al cáncer como causa.

- Plantear un test para esta situación. Indicar con cuidado cuáles son las variables involucradas (con su distribución), los parámetros introducidos, las hipótesis, el estadístico del test, su distribución asintótica bajo la hipótesis nula y la región de rechazo del test.
- ¿Qué decisión se toma en este caso? Hallar el p -valor.
- Hallar un valor α tal que si el test se hubiera tomado de nivel α , entonces la decisión sería la contraria al item anterior.
- Hallar la probabilidad de no multar a la empresa si después del año 2000, el 22 % de las muertes tiene al cáncer como causante.

Solución:

- (a) Sea $X_1, \dots, X_n$ tal que $X_i \sim Be(p)$ para todo $i \in \{1, \dots, 200\}$ definido como $X_i = \begin{cases} 1 & \text{si la persona tuvo cáncer} \\ 0 & \text{cc} \end{cases}$ y suponiendo que $p = 0,2$ (es decir, el 20 %).

Luego,

$$H_0 : p = 0,2 \text{ vs. } H_1 : p > 0,2$$

entonces, el tst asintótico resulta ser

$$\varphi(\mathbf{X}) = \begin{cases} 1 & T(\mathbf{X}) = \frac{\sqrt{n}}{\sigma}(\bar{X}_n - \mu_0) \geq z_\alpha \\ 0 & \text{cc} \end{cases}$$

en este caso, el estadístico T tiene una distribución asintótica normal. Es decir, $T \sim N(0,1)$ bajo H_0 ; donde su región de rechazo resulta ser $[1,65, +\infty)$.

- (b) En este caso,

$$T_{obs}(\mathbf{X}) = \frac{\sqrt{200}}{0,4} \left(\frac{50}{200} - 0,2 \right) \approx 1,7677$$

Por lo tanto, hay suficiente evidencia para rechazar H_0 ; es decir, $p > 0,2$.

Por otro lado, su p -valor resulta

$$p(T > T_{obs}) = 1 - p(T \leq T_{obs}) = 1 - 0,9608 = 0,0392.$$

- (c) Sea $\alpha = 0,02$, entonces $z_\alpha = 3,49$ y, por lo tanto, $T_{obs} < z_\alpha$. Entonces, habría suficiente evidencia para no rechazar H_0 .
- (d) Si $p = 0,22$, entonces la probabilidad aproximada será,

$$p(\text{error tipo II}) = 1 - \mathbb{E}_{p=0,22}(\varphi(\mathbf{X})) = 1 - p \left(\frac{\sqrt{200}}{0,4}(\bar{X}_n - 0,2) \geq 1,65 \right) = p \left(\frac{\sqrt{200}}{0,4}(\bar{X}_n - 0,2) \leq 1,65 \right) \Rightarrow$$

$$p(\text{error tipo II}) = p \left[\frac{\sqrt{200}}{0,414}(\bar{X}_n - 0,22) \leq \frac{1,65 \times 0,4}{0,414} - \frac{\sqrt{200}}{0,414}(0,22 - 0,2) \right] \approx p(Z \leq 0,92)$$

con $Z \sim N(0,1)$, entonces

$$p(\text{error tipo II}) = p(Z \leq 0,92) \approx 0,8212.$$

6. Un dado se tira 600 veces y se obtienen los siguientes resultados:

Número	1	2	3	4	5	6
Frecuencia	87	96	108	89	122	98

¿Puede decirse que el dado no es balanceado? Calcular el valor p aproximado.

7. (Para hacer con el R) Se tiene una muestra de tamaño n de una distribución $Bi(1, p)$. Se quiere testear $H_0 : p = p_0$ vs. $H_1 : p \neq p_0$ a nivel asintótico 0,05. Se considera el test con estadístico

$$W = \sqrt{n} \frac{\bar{X} - p_0}{\sqrt{p_0(1 - p_0)}}$$

y región de rechazo $\{|W| > z_{\alpha/2}\}$. Vamos a considerar los pares (n, p_0) con n variando en el conjunto $\{10, 70, 200\}$ y p_0 variando en el conjunto $\{0,5, 0,8, 0,97\}$ (9 pares en total). Para el test correspondiente a cada par (n, p_0) , calcular mediante una simulación la función de potencia $\beta(p)$ en los valores $p = 0,03, 0,1, 0,2, 0,3, 0,4, 0,5, 0,6, 0,7, 0,8, 0,9, 0,97$ del test correspondiente y graficarla interpolando en los valores de p indicados. ¿Qué se puede decir sobre el nivel de significación en cada caso? ¿En que casos es buena la aproximación normal?