

Práctica 1 - Estadística Descriptiva

Rodrigo Quirno Costa

2026-03-25

1. Cáncer de páncreas

a) Tabla de frecuencias

```
datos <- read.csv("../datos/Debernardi.csv")

frec_abs <- table(datos$diagnosis)
frec_rel <- prop.table(frec_abs)

tabla_diagnosis <- data.frame(
  Diagnosis      = names(frec_abs),
  Frecuencia     = as.integer(frec_abs),
  Frec_Relativa  = round(as.numeric(frec_rel), 4)
)

kable(tabla_diagnosis,
      caption = "Frecuencia relativa de diagnosis",
      col.names = c("Diagnosis", "Frecuencia", "Frec. Relativa"),
      align = c("c", "c", "c"))
```

Table 1: Frecuencia relativa de diagnosis

Diagnosis	Frecuencia	Frec. Relativa
1	183	0.3102
2	208	0.3525
3	199	0.3373


b) Gráfico de barras

```
par(
  mar = c(3, 3, 2, 1),
  mgp = c(2, 0.7, 0)
)
barplot(frec_rel,
      main = "Frecuencia relativa de diagnosis",
      xlab = "Diagnosis",
      ylab = "Frecuencia relativa",
      col = c("steelblue", "darkorange", "firebrick"),
```

```

names.arg = c("Control (1)", "Benigno (2)", "Cancer (3)"),
ylim      = c(0, max(frec_rel) + 0.05),
border    = "white",
cex.main  = 0.8,
cex.names = 0.8,
cex.lab   = 0.8,
cex.axis  = 0.8
)
# agregar los valores encima de cada barra
text(
  x      = barplot(frec_rel, plot = FALSE),
  y      = as.numeric(frec_rel) + 0.02,
  labels = paste0(round(frec_rel * 100, 1), "%"),
  cex    = 0.8,
  font   = 2
)

```



2. Titanic

a) Probabilidad supervivencia mujer

```

titanic <- read.csv("../datos/datos_titanic.csv")
p_mujer <- mean(titanic$Sex == "female")
cat("**P(mujer):**", round(p_mujer, 4), "\n")

```

P(mujer): 0.3524

```

sobrevivientes <- titanic[titanic$Survived == 1, ]
p_mujer_survived <- mean(sobrevivientes$Sex == "female")
cat("**P(mujer | sobrevivio):**", round(p_mujer_survived, 4), "\n")

```

$P(\text{mujer} \mid \text{sobrevivio}): 0.6813$

b) Probabilidad de sobrevivir dada la clase

```
tabla_cont <- table(titanic$Survived, titanic$Pclass)
rownames(tabla_cont) <- c("No sobrevivió", "Sobrevivió")
kable(tabla_cont,
      caption = "Sobrevivientes por clase",
      align = c("c", "c", "c"))
```

Table 2: Sobrevivientes por clase

	1	2	3
No sobrevivió	80	97	372
Sobrevivió	136	87	119

```
p_survived_clase <- prop.table(tabla_cont, margin = 2)
for (i in 1:3) {
  cat("**P(sobrevivió | Pclass ==", i, "**)) ==", round(p_survived_clase[2, i], 4), "\n\n")
}
```


$P(\text{sobrevivió} \mid \text{Pclass} = 1) = 0.6296$

$P(\text{sobrevivió} \mid \text{Pclass} = 2) = 0.4728$

$P(\text{sobrevivió} \mid \text{Pclass} = 3) = 0.2424$

c) Gráfico de barras

```
par(
  mar = c(3, 3, 2, 1),
  mgp = c(2, 0.7, 0)
)
barplot(tabla_cont,
  beside = FALSE,
  legend = c("No sobrevivio", "Sobrevivio"),
  col = c("firebrick", "steelblue"),
  main = "Proporcion de supervivencia por clase",
  xlab = "Clase",
  ylab = "Proporcion",
  args.legend = list(x = "topleft", cex = 0.7),
  border = "white",
  cex.main = 0.8,
  cex.names = 0.8,
  cex.lab = 0.8,
  cex.axis = 0.8
)
```



3. Temperatura de sublimación del iridio y del rodio

a) Histogramas y boxplots

```


iridio <- scan("../datos/iridio.txt", skip = 1)
rodio  <- scan("../datos/rodio.txt", skip = 1)

par(mfrow = c(1, 2),          # divide la ventana en 1 fila, 2 columnas
    mar    = c(3, 3, 2, 1), # tight_layout
    mgp     = c(2, 0.7, 0)
)

hist(iridio,
     main    = "Iridio",
     xlab    = "Temperatura de sublimacion",
     col     = "firebrick",
     border  = "white",
     cex.main = 0.8,
     cex.names = 0.8,
     cex.lab  = 0.8,
     cex.axis = 0.8
)
hist(rodio,
     main    = "Rodio",
     xlab    = "Temperatura de sublimacion",
     col     = "steelblue",
     border  = "white",
     cex.main = 0.8,
     cex.names = 0.8,
     cex.lab  = 0.8,

```


```
cex.axis = 0.8
)
```



```
par(mfrow = c(1, 2),
    mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)

boxplot(iridio,
        col = "firebrick",
        main = "Iridio",
        ylab = "Temperatura de sublimacion",
        cex.main = 0.8,
        cex.names = 0.8,
        cex.lab = 0.8,
        cex.axis = 0.8
)

boxplot(rodio,
        col = "steelblue",
        main = "Rodio",
        ylab = "Temperatura de sublimacion",
        cex.main = 0.8,
        cex.names = 0.8,
        cex.lab = 0.8,
        cex.axis = 0.8
)
```



b) Medidas resumen

```
tabla_medidas <- data.frame(
  Medida = c("Media", "Mediana", "Media 0.1-podada", "Media 0.2-podada"),
  Iridio = c(mean(iridio), median(iridio), mean(iridio, 0.1), mean(iridio, 0.2)),
  Rodio = c(mean(rodio), median(rodio), mean(rodio, 0.1), mean(rodio, 0.2))
)
kable(tabla_medidas,
  caption = "Medidas resumen",
  align = c("l", "c", "c"),
  row.names = FALSE,
  digits = 2
)
```

Table 3: Medidas resumen

Medida	Iridio	Rodio
Media	159.92	131.88
Mediana	160.00	131.60
Media 0.1-podada	159.89	131.82
Media 0.2-podada	159.87	131.77

c) Medidas de dispersion

```
tabla_dispersion <- data.frame(
  Medida = c("SD", "IQR", "MAD"),
  Iridio = c(sd(iridio), IQR(iridio), mad(iridio, constant = 1)),
  Rodio = c(sd(rodio), IQR(rodio), mad(rodio, constant = 1))
)
kable(tabla_dispersion,
  caption = "Medidas de dispersion",
  align = c("l", "c", "c"),
)
```

```

    row.names = FALSE,
    digits    = 2
)

```

Table 4: Medidas de dispersion

Medida	Iridio	Rodio
SD	0.49	0.75
IQR	0.70	1.30
MAD	0.40	0.50

d) Cuantiles

```

cuantiles <- c(0.10, 0.25, 0.50, 0.75, 0.90)

tabla_cuantiles <- data.frame(
  Cuantil = cuantiles,
  Iridio  = quantile(iridio, cuantiles),
  Rodio   = quantile(rodio, cuantiles)
)

kable(tabla_cuantiles,
      caption = "Cuantiles muestrales",
      align   = c("c", "c", "c"),
      row.names = FALSE,
      digits   = 2
)

```

Table 5: Cuantiles muestrales

Cuantil	Iridio	Rodio
0.10	159.46	131.1
0.25	159.50	131.2
0.50	160.00	131.6
0.75	160.20	132.5
0.90	160.44	133.0

4. Salchichas

a) Unir datos

```

s_a <- read.table("../datos/salchichas_A.txt", header = TRUE, col.names = c("Calorias", "Sodio"))
s_b <- read.table("../datos/salchichas_B.txt", header = TRUE, col.names = c("Calorias", "Sodio"))
s_c <- read.table("../datos/salchichas_C.txt", header = TRUE, col.names = c("Calorias", "Sodio"))

s_a$Tipo <- "A"

```

```

s_b$Tipo <- "B"
s_c$Tipo <- "C"

salchichas <- rbind(s_a, s_b, s_c)

```

b) Histogramas calorías

```

par(mfrow = c(1, 3),
    mar    = c(3, 3, 2, 1),
    mgp    = c(2, 0.7, 0)
)

rango_plot <- c(80, 220)           # para misma escala
rango <- range(salchichas$Calorias)
breaks <- seq(floor(rango[1] - 1), # bins
               ceiling(rango[2] + 20),
               by = 20)


hist(s_a$Calorias,
     xlim      = rango_plot,
     breaks    = breaks,
     main      = "Tipo A",
     xlab      = "Calorias",
     col       = "steelblue",
     border    = "white",
     cex.main  = 0.8,
     cex.names = 0.8,
     cex.lab   = 0.8,
     cex.axis  = 0.8
)

hist(s_b$Calorias,
     xlim      = rango_plot,
     breaks    = breaks,
     main      = "Tipo B",
     xlab      = "Calorias",
     col       = "firebrick",
     border    = "white",
     cex.main  = 0.8,
     cex.names = 0.8,
     cex.lab   = 0.8,
     cex.axis  = 0.8
)

hist(s_c$Calorias,
     xlim      = rango_plot,
     breaks    = breaks,
     main      = "Tipo C",
     xlab      = "Calorias",
     col       = "darkgreen",
     border    = "white",
     cex.main  = 0.8,
     cex.names = 0.8,
     cex.lab   = 0.8,
     cex.axis  = 0.8
)

```


)



¿Observa grupos en algún gráfico?

En las salchichas tipo B se pueden observar 2 grupos, uno al rededor de 120-140 calorías y otro al rededor de 160-180, lo que sugiere una distribución bimodal. En las de tipo C también se ven dos grupos, uno entre 80-100 y otro entre 120-140.

¿Candidato a dato atípico?

En el tipo A, la barra alrededor de 100-110 parece un candidato a dato atípico, ya que está bastante separada del resto. La barra de la derecha del último gráfico, alrededor de 160-180, podría ser un candidato, ya que el grueso de los datos se concentra en valores más bajos.


¿Algún histograma tiene característica particular?

El gráfico de tipo C está sesgado a la derecha (asimétrico), ya que la mayoría de los datos se concentran en valores bajos y la frecuencia cae hacia la derecha.

c) Boxplot calorías

```
par(mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0))

boxplot(Calorias ~ Tipo, data = salchichas,
        col = c("steelblue", "firebrick", "darkgreen"),
        main = "Calorias por tipo de salchicha",
        xlab = "Tipo",
        ylab = "Calorias",
        cex.main = 0.8,
        cex.names = 0.8,
        cex.lab = 0.8,
        cex.axis = 0.8)
```



d) Lo mismo pero con el calcio.

5. Concentracion ion nitrato

a) Estudiar distribucion y QQ-Plot

```
estudiantes <- read.table("../datos/estudiantes.txt", header = TRUE)
grupo1      <- estudiantes$GRUP01
grupo2      <- estudiantes$GRUP02

par(mfrow = c(1, 2),
    mar   = c(3, 3, 2, 1),
    mgp   = c(2, 0.7, 0)
)


hist(grupo1,
    main      = "Grupo 1",
    xlab      = "Concentracion de nitrato",
    col       = "skyblue",
    border    = "white",
    cex.main  = 0.8,
    cex.names = 0.8,
    cex.lab   = 0.8,
    cex.axis  = 0.8,
    probability = TRUE
)
curve(dnorm(x, mean = mean(grupo1), sd = sd(grupo1)),
    add = TRUE, col = "blue", lwd = 2)

hist(grupo2,
```

```

    main      = "Grupo 2",
    xlab      = "Concentracion de nitrato",
    col       = "orange",
    border    = "white",
    cex.main  = 0.8,
    cex.names = 0.8,
    cex.lab   = 0.8,
    cex.axis  = 0.8,
    probability = TRUE
)
curve(dnorm(x, mean = mean(grupo2), sd = sd(grupo2)),
      add = TRUE, col = "red", lwd = 2)

```



```

par(mfrow = c(1, 2),
    mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)


qqnorm(grupo1,
    main      = "QQ-Plot - Grupo 1",
    xlab      = "Concentracion de nitrato",
    col       = "skyblue",
    border    = "white",
    cex.main  = 0.8,
    cex.names = 0.8,
    cex.lab   = 0.8,
    cex.axis  = 0.8,
)
qqline(grupo1, col = "blue", lwd = 2)
qqnorm(grupo2,
    main      = "QQ-Plot - Grupo 2",
    xlab      = "Concentracion de nitrato",
    col       = "orange",
    border    = "white",
)

```

```

    cex.main = 0.8,
    cex.names = 0.8,
    cex.lab = 0.8,
    cex.axis = 0.8,
  )
  qqline(grupo2, col = "red", lwd = 2)

```



b) ¿Ambos grupos están midiendo lo mismo?

```

tabla_resumen <- data.frame(
  Medida = c("Media", "Mediana", "Media 0.1-podada",
             "Desvio estandar", "IQR", "MAD"),
  Grupo1 = c(mean(grupo1),
             median(grupo1),
             mean(grupo1, trim = 0.10),
             sd(grupo1),
             IQR(grupo1),
             mad(grupo1, constant = 1)),
  Grupo2 = c(mean(grupo2),
             median(grupo2),
             mean(grupo2, trim = 0.10),
             sd(grupo2),
             IQR(grupo2),
             mad(grupo2, constant = 1))
)

kable(tabla_resumen,
      caption = "Medidas de centralidad y dispersion",
      align = c("l", "c", "c"),
      row.names = FALSE,
      digits = 4
)

```

Table 6: Medidas de centralidad y dispersion


Medida	Grupo1	Grupo2
Media	0.5000	0.6136
Mediana	0.5000	0.6100
Media 0.1-podada	0.5005	0.6112
Desvio estandar	0.0164	0.0675
IQR	0.0200	0.0875
MAD	0.0100	0.0450

```

par(mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)

boxplot(grupo1, grupo2,
        names = c("Grupo 1", "Grupo 2"),
        col = c("skyblue", "orange"),
        main = "Concentracion de nitrato",
        ylab = "ug/l",
        cex.main = 0.8,
        cex.names = 0.8,
        cex.lab = 0.8,
        cex.axis = 0.8
)

```



Mirando el boxplot queda claro que no estan midiendo lo mismo. El grupo 1 tiene valores concentrados alrededor de 0.50 $\mu\text{g/l}$ con muy poca dispersion, mientras que el grupo 2 tiene valores mas dispersos, centrados alrededor de 0,60 $\mu\text{g/l}$.


6. Nubes bombardeadas

a) Boxplots

```
nubes <- read.table("../datos/nubes.txt", header = TRUE)
control <- nubes$CONTROLES
tratadas <- nubes$TRATADAS

par(mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)

boxplot(control, tratadas,
    names = c("Controles", "Tratadas"),
    col = c("lightgreen", "cyan"),
    main = "Agua caída por nube",
    ylab = "Cantidad de agua caída",
    cex.main = 0.8,
    cex.names = 0.8,
    cex.lab = 0.8,
    cex.axis = 0.8
)
```



b) QQ-Plot e Histograma

```
par(mfrow = c(1, 2),
    mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)


qqnorm(control,
    main = "Controles",
    xlab = "Agua caída",

```

```

    col      = "lightgreen",
    border    = "white",
    cex.main  = 0.8,
    cex.names = 0.8,
    cex.lab   = 0.8,
    cex.axis  = 0.8,
  )
  qqline(control, col = "green", lwd = 2)
  qqnorm(tratadas,
    main      = "Tratadas",
    xlab      = "Agua caida",
    col       = "cyan",
    border     = "white",
    cex.main  = 0.8,
    cex.names = 0.8,
    cex.lab   = 0.8,
    cex.axis  = 0.8,
  )
  qqline(tratadas, col = "darkcyan", lwd = 2)

```



```

par(mfrow = c(1, 2),
    mar    = c(3, 3, 2, 1),
    mgp    = c(2, 0.7, 0)
)

hist(control,
  main      = "Controles",
  xlab      = "Agua caida",
  col       = "lightgreen",
  border     = "white",
  cex.main  = 0.8,
  cex.names = 0.8,
  cex.lab   = 0.8,
  cex.axis  = 0.8,


```

```

    probability = TRUE
  )
  curve(dnorm(x, mean = mean(control), sd = sd(control)),
        add = TRUE, col = "green", lwd = 2)

hist(tratadas,
     main      = "Tratadas",
     xlab      = "Agua caida",
     col       = "cyan",
     border    = "white",
     cex.main  = 0.8,
     cex.names = 0.8,
     cex.lab   = 0.8,
     cex.axis  = 0.8,
     probability = TRUE
  )
  curve(dnorm(x, mean = mean(tratadas), sd = sd(tratadas)),
        add = TRUE, col = "darkcyan", lwd = 2)

```



c) log(nubes) y repetir b)

```

log_control <- log(control)
log_tratadas <- log(tratadas)

par(mfrow = c(1, 2),
    mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
  )

qqnorm(log_control,
     main      = "Controles",
     xlab      = "Agua caida",
     col       = "lightgreen",


```



```

border    = "white",
cex.main  = 0.8,
cex.names = 0.8,
cex.lab   = 0.8,
cex.axis  = 0.8,
)
qqline(log_control, col = "green", lwd = 2)
qqnorm(log_tratadas,
  main      = "Tratadas",
  xlab      = "Agua caida",
  col       = "cyan",
  border    = "white",
  cex.main  = 0.8,
  cex.names = 0.8,
  cex.lab   = 0.8,
  cex.axis  = 0.8,
)
qqline(log_tratadas, col = "darkcyan", lwd = 2)

```



```

par(mfrow = c(1, 2),
  mar  = c(3, 3, 2, 1),
  mgp  = c(2, 0.7, 0)
)

hist(log_control,
  main      = "Controles",
  xlab      = "log(agua caida)",
  col       = "lightgreen",
  border    = "white",
  cex.main  = 0.8,
  cex.names = 0.8,
  cex.lab   = 0.8,
  cex.axis  = 0.8,
  probability = TRUE
)


```

```

)
curve(dnorm(x, mean = mean(log_control), sd = sd(log_control)),
      add = TRUE, col = "green", lwd = 2)

hist(log_tratadas,
     main = "Tratadas",
     xlab = "log(agua caida)",
     col = "cyan",
     border = "white",
     cex.main = 0.8,
     cex.names = 0.8,
     cex.lab = 0.8,
     cex.axis = 0.8,
     probability = TRUE
)
curve(dnorm(x, mean = mean(log_tratadas), sd = sd(log_tratadas)),
      add = TRUE, col = "darkcyan", lwd = 2)

```




d) Repetir boxplots con log

```

par(mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)

boxplot(log_control, log_tratadas,
       names = c("Controles", "Tratadas"),
       col = c("lightgreen", "cyan"),
       main = "Agua caida por nube",
       ylab = "log(agua caida)",
       cex.main = 0.8,
       cex.names = 0.8,
       cex.lab = 0.8,
       cex.axis = 0.8
)

```



7. Tarjetas de credito

a) Funcion de distribucion empirica

```
data <- read.csv("../datos/data_credit_card.csv")

purchases <- data$purchases
credit_limit <- data$credit_limit
purchases_freq <- data$purchases_freq
tenure <- data$tenure

par(mfrow = c(2, 2),
    mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)





plot(ecdf(purchases),
    main = "ECDF - Compras",
    xlab = "Compras",
    col = "#0066cc",
    cex.main = 0.8,
    cex.names = 0.8,
    cex.lab = 0.8,
    cex.axis = 0.8
)

plot(ecdf(credit_limit),
    main = "ECDF - Limite",
    xlab = "Limite",
    col = "#009999",
    cex.main = 0.8,
    cex.names = 0.8,
```

```

    cex.lab = 0.8,
    cex.axis = 0.8
)
plot(ecdf(purchases_freq),
     main = "ECDF - Frecuencia compras",
     xlab = "Semanas/año",
     col = "#993333",
     cex.main = 0.8,
     cex.names = 0.8,
     cex.lab = 0.8,
     cex.axis = 0.8
)
plot(ecdf(tenure),
     main = "ECDF - Antigüedad",
     xlab = "Meses",
     col = "#669933",
     cex.main = 0.8,
     cex.names = 0.8,
     cex.lab = 0.8,
     cex.axis = 0.8
)

```




b) Histograma y densidad de *credit_limit*

```
par(mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)

hist(credit_limit,
     main = "Limite credito",
     xlab = "Limite",
     col = "#009999",
     border = "white",
     cex.main = 0.8,
     cex.names = 0.8,
     cex.lab = 0.8,
     cex.axis = 0.8,
     probability = TRUE
)

lines(density(credit_limit), # bw = "nrd0", kernel = "gaussian" por default
      col = "#006666",
      lwd = 2
)
```



c) Barplot *tenure*

```
par(mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)


frec_tenure <- prop.table(table(tenure))

barplot(frec_tenure,
        main = "Frecuencia relativa de antigüedad",
        xlab = "Meses",
)
```

```

ylab      = "Frecuencia relativa",
col       = "#669933",
border    = "white",
cex.main  = 0.8,
cex.names = 0.8,
cex.lab   = 0.8,
cex.axis  = 0.8
)

```



d) Media, mediana y media podada

```

variables <- list(purchases, credit_limit, purchases_freq, tenure)
nombres   <- c("Compras", "Limite Credito", "Frec compras", "Antigüedad")

tabla_centralidad <- data.frame(
  Variable      = nombres,
  Media         = sapply(variables, mean),
  Mediana       = sapply(variables, median),
  Media_podada  = sapply(variables, mean, trim = 0.1)
)

kable(tabla_centralidad,
      caption = "Medidas de centralidad",
      align   = c("l", "c", "c", "c"),
      row.names = FALSE,
      digits   = 2)

```

Table 7: Medidas de centralidad

Variable	Media	Mediana	Media_podada
Compras	932.15	332.44	542.50
Limite Credito	4517.98	3000.00	3926.97

Variable	Media	Mediana	Media_podada
Frec compras	0.47	0.42	0.47
Antigüedad	11.44	12.00	11.88

e) Cuantiles, IQR, MAD y boxplots

```

tabla_dispersion <- data.frame(
  Variable = nombres,
  Q25      = sapply(variables, quantile, probs = 0.25),
  Q75      = sapply(variables, quantile, probs = 0.75),
  IQR      = sapply(variables, IQR),
  MAD      = sapply(variables, mad, constant = 1)
)

kable(tabla_dispersion,
      caption = "Cuantiles y dispersion",
      align   = c("l", "c", "c", "c", "c"),
      row.names = FALSE,
      digits   = 4)

```


Table 8: Cuantiles y dispersion

Variable	Q25	Q75	IQR	MAD
Compras	37.3900	1081.4950	1044.1050	332.4350
Limite Credito	1500.0000	6500.0000	5000.0000	1800.0000
Frec compras	0.0833	0.9167	0.8333	0.4167
Antigüedad	12.0000	12.0000	0.0000	0.0000

```

par(mfrow = c(2,2),
    mar    = c(3, 3, 2, 1),
    mgp    = c(2, 0.7, 0)
)
# "#0066cc", "#009999", "#993333", "#669933"
boxplot(purchases,
        main = "Compras",
        col = "#0066cc")
boxplot(credit_limit,
        main = "Limite Credito",
        col = "#009999")
boxplot(purchases_freq,
        main = "Frecuencia compras",
        col = "#993333")
boxplot(tenure,
        main = "Antigüedad",
        col = "#669933")

```



f) Desvío, asimetría y curtosis

```
# install.packages("e1071") en consola
library(e1071) # para skewness y kurtosis

tabla_forma <- data.frame(
  Variable = nombres,
  Desvio = sapply(variables, sd),
  Asimetria = sapply(variables, skewness),
  Curtosis = sapply(variables, kurtosis)
)

kable(tabla_forma,
      caption = "Desvio, asimetria y curtosis",
      align = c("l", "c", "c", "c"),
      row.names = FALSE,
      digits = 4)
```


Table 9: Desvio, asimetria y curtosis

Variable	Desvio	Asimetria	Curtosis
Compras	2042.8382	7.6547	82.9780
Limite Credito	3711.3466	1.4244	1.8625
Frec compras	0.3947	0.1241	-1.6102
Antigüedad	1.4459	-2.6119	5.5414

g) Identificar datos atípicos

```
# Función para detectar atípicos por regla del boxplot
atipicos <- function(x) {
  lim_inf <- quantile(x, 0.25) - 1.5 * IQR(x)
  lim_sup <- quantile(x, 0.75) + 1.5 * IQR(x)

  sum(x < lim_inf | x > lim_sup)
}

tabla_atipicos <- data.frame(
  Variable = nombres,
  N_atipicos = sapply(variables, atipicos)
)

kable(tabla_atipicos,
  caption = "Cantidad de datos atipicos",
  align = c("l", "c"),
  row.names = FALSE)
```

Table 10: Cantidad de datos atipicos

Variable	N_atipicos
Compras	39
Limite Credito	19
Frec compras	0
Antigüedad	86

8. Central termica de ciclo combinado

a) Histograma y densidad de potencia max entregada (PME)

```
# install.packages("readxl")
library(readxl)
potencia <- read_excel("../datos/ciclocombinado.xlsx")

pe <- potencia$PE
ht <- potencia$HighTemp
```


```

par(mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)

hist(pe,
     main = "Potencia max entregada",
     xlab = "Potencia eléctrica (MW)",
     col = "#996699",
     border = "white",
     cex.main = 0.8,
     cex.names = 0.8,
     cex.lab = 0.8,
     cex.axis = 0.8,
     probability = TRUE
)

lines(density(pe),
      col = "#993699",
      lwd = 2
)

```



b) Separar en `HighTemp = 1` o `0`, graficar densidad y comparar

```

ht1 <- pe[ht == 1]
ht0 <- pe[ht == 0]

d1 <- density(ht1) # bw = "nrd0", kernel = "gaussian" por default
d0 <- density(ht0)

par(mfrow = c(1,2),
    mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)


```

```

rango_x <- c(min(pe), max(pe))
rango_y <- range(c(d0$y, d1$y))

plot(d1,
      main      = "PME con Temp media diaria > 20°C",
      col       = "firebrick",
      xlab      = "MW",
      xlim      = rango_x,
      ylim      = rango_y,
      lwd       = 2,
      cex.main  = 0.8,
      cex.names = 0.8,
      cex.lab   = 0.8,
      cex.axis  = 0.8
)
polygon(d1,
        col    = rgb(1, 0, 0, 0.3),
        border = NA
)
plot(d0,
      main      = "PME con Temp media diaria < 20°C",
      col       = "steelblue",
      xlab      = "MW",
      xlim      = rango_x,
      ylim      = rango_y,
      lwd       = 2,
      cex.main  = 0.8,
      cex.names = 0.8,
      cex.lab   = 0.8,
      cex.axis  = 0.8
)
polygon(d0,
        col    = rgb(0, 0, 1, 0.2),
        border = NA
)

```



c) Estimar $P(PE < 450 | \text{HighTemp} = 0)$ y $P(PE < 300 | \text{HighTemp} = 1)$

OBS: Los valores de PE van de 420 a 496 aprox, por que la segunda probabilidad es 0. Voy a suponer que es un error y calcular $P(PE < 450 | \text{HighTemp} = 1)$.

```
p1 <- ecdf(ht0)(449.99)
p2 <- ecdf(ht1)(449.99)

cat("**P(PE < 450|HighTemp = 0) **", round(p1, 4), "\n\n",
     "**P(PE < 450|HighTemp = 1) **", round(p2, 4))
```

$P(\text{PE} < 450 | \text{HighTemp} = 0) = 0.0376$

$P(\text{PE} < 450 | \text{HighTemp} = 1) = 0.8915$

d) Estimar $P(\text{PE} < 450)$

```
p3 <- ecdf(pe)(450)

cat("**P(PE < 450) **", round(p3, 4))
```

$P(\text{PE} < 450) = 0.4763$

e) Estimar x tal que $P(\text{PE} \leq x | \text{HighTemp} = 1) = 0.9$

Equivale a: $P(\text{PE} < x | \text{HighTemp} = 1) = 0.1$, es decir, el cuantil 0.10 de la distribución.

```
PMG_ht1 <- quantile(ht1, 0.1)

cat("**P(PE < x) = 0.1 <=> x **", round(PMG_ht1, 4))
```

$P(\text{PE} < x) = 0.1 \Leftrightarrow x = 430.88$

f) Estimar x tal que $P(\text{PE} \leq x) = 0.9$

```
PMG <- quantile(pe, 0.1)

cat("**x / P(PE < x) = 0.1 **", round(PMG, 4))
```

$x / P(\text{PE} < x) = 0.1 \Rightarrow 433.437$

9. Niveles de LYVE1 (de Ejercicio 1)

a) Histogramas por diagnosis

```
datos <- read.csv("../datos/Debernardi.csv")

LYVE1 <- datos$LYVE1
diag <- datos$diagnosis

LYVE1_1 <- LYVE1[diag == 1] # control sano
LYVE1_2 <- LYVE1[diag == 2] # pancreatitis benigna
```

```


LYVE1_3 <- LYVE1[diag == 3] # cancer de pancreas

par(mfrow = c(1, 3),
    mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)

rango <- c(min(LYVE1)-1, max(LYVE1) + 1)
breaks <- seq(floor(rango[1] - 1),
               ceiling(rango[2] + 2),
               by = 2)

hist(LYVE1_1,
     xlim      = rango,
     breaks    = breaks,
     main      = "Nivel urinario LYVE1 (sano)",
     xlab      = "ng / ml",
     col       = "#669900",
     border    = "white",
     cex.main  = 0.8,
     cex.names = 0.8,
     cex.lab   = 0.8,
     cex.axis  = 0.8
)
hist(LYVE1_2,
     xlim      = rango,
     breaks    = breaks,
     main      = "Nivel urinario LYVE1 (benigno)",
     xlab      = "ng/ml",
     col       = "#FFCC33",
     border    = "white",
     cex.main  = 0.8,
     cex.names = 0.8,
     cex.lab   = 0.8,
     cex.axis  = 0.8
)
hist(LYVE1_3,
     xlim      = rango,
     breaks    = breaks,
     main      = "Nivel urinario LYVE1 (cancer)",
     xlab      = "ng/ml",
     col       = "firebrick",
     border    = "white",
     cex.main  = 0.8,
     cex.names = 0.8,
     cex.lab   = 0.8,
     cex.axis  = 0.8
)

```



- **Diagnosis 1 (sano):** valores muy bajos y concentrados, con asimetría a derecha.
- **Diagnosis 2 (benigno):** similar pero más disperso y con valores algo mayores.
- **Diagnosis 3 (cáncer):** valores más altos y mucho más dispersos.

Conclusión: a mayor LYVE1, mayor asociación con cáncer; hay una clara diferencia entre los grupos.


b) Funciones de distribución empíricas superpuestas

```
par(mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)

plot(ecdf(LYVE1_1),
     main = "Empirica de LYVE1 por diagnosis",
     xlab = "ng/ml",
     col = "#669900",
     xlim = range(c(LYVE1_1, LYVE1_2, LYVE1_3)),
     ylim = c(0,1),
     lwd = 2,
     cex.main = 0.8,
     cex.names = 0.8,
     cex.lab = 0.8,
     cex.axis = 0.8
)

# las otras funciones hay que agregarlas a parte
lines(ecdf(LYVE1_2), col = "#FFCC33", lwd = 2)
lines(ecdf(LYVE1_3), col = "firebrick", lwd = 2)

legend("bottomright",
      legend = c("Diagnosis 1", "Diagnosis 2", "Diagnosis 3"),
      col = c("#669900", "#FFCC33", "firebrick"),
      lwd = 2,
      cex = 0.7)
```




Decidir si la siguiente afirmación es verdadera o falsa y justificar: “los valores de la variable LYVE1 tienden a ser más altos entre quienes tienen cáncer de páncreas que entre quienes sufren otras enfermedades asociadas al páncreas”

La función empírica de $\text{diagnosis}=3$ está más desplazada hacia la derecha $\rightarrow$ acumula probabilidad más lentamente $\rightarrow$ Valores mas altos de LYVE1 $\rightarrow$ **Verdadera**

c) **Boxplots paralelos por diagnosis y sexo**

```
par(mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)

boxplot(LYVE1 ~ diagnosis + sex,
        data = datos,
        names = c("D1-F", "D1-M",
                  "D2-F", "D2-M",
                  "D3-F", "D3-M"),
        col = c("#669900", "#669900",
                "#FFCC33", "#FFCC33",
                "firebrick", "firebrick"),
        main = "Niveles de LYVE1 por diagnosis y sexo",
        ylab = "ng/ml",
        cex.main = 0.8,
        cex.names = 0.8,
        cex.lab = 0.8,
        cex.axis = 0.8
)
```



Decidir si la siguiente afirmación es verdadera o falsa y justificar: “en términos generales, el sexo del paciente no afecta los niveles de la proteína que se mide en la variable LYVE1”.

Como el efecto del sexo no es consistente, no hay una tendencia general clara → **Verdadera**

d) Densidades superpuestas

```
d_l1 <- density(LYVE1_1)
d_l2 <- density(LYVE1_2)
d_l3 <- density(LYVE1_3)

par(mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0)
)

xlim_comun <- range(c(d_l1$x, d_l2$x, d_l3$x))
ylim_comun <- range(c(d_l1$y, d_l2$y, d_l3$y))

plot(d_l1,
     xlim = xlim_comun,
     ylim = ylim_comun,
     main = "Densidad de LYVE1 por diagnosis",
     xlab = "ng/ml",
     col = "#669900",
     lwd = 1.5,
     cex.main = 0.8,
     cex.names = 0.8,
     cex.lab = 0.8,
     cex.axis = 0.8
)
```



```


)
polygon(d_l1, col = rgb(0.4, 0.6, 0, 0.2), border = NA)

# las otras funciones hay que agregarlas a parte
lines(d_l2, col = "#FFCC33", lwd = 1.5)
polygon(d_l2, col = rgb(1, 0.8, 0.2, 0.2), border = NA)

lines(d_l3, col = "firebrick", lwd = 1.5)
polygon(d_l3, col = rgb(0.7, 0.13, 0.13, 0.2), border = NA)

legend("topright",
      legend = c("Diagnosis 1", "Diagnosis 2", "Diagnosis 3"),
      col = c("#669900", "#FFCC33", "firebrick"),
      lwd = 2,
      cex = 0.7)

```



e) Repetir a) y d) con $\log(\text{LYVE1})$

10. Boxplot para la distribución normal

Sea $X \sim N(\mu, \sigma^2)$. Usamos que si $Z \sim N(0, 1)$, entonces $X = \mu + \sigma Z$ y los cuantiles cumplen $F_X^{-1}(p) = \mu + \sigma z_p$ donde z_p es el cuantil p de la normal estándar.

a) Mediana:

$$\text{Med}(X) = \mu$$

b) Cuartil superior:

$$QS = \mu + \sigma z_{0.75}$$

c) Cuartil inferior:

$$QI = \mu + \sigma z_{0.25}$$

d) Distancia intercuartil:

$$IQR = \sigma(z_{0.75} - z_{0.25}) = 2\sigma z_{0.75}$$

e) Bigote superior:

$$QS + 1.5IQR = \mu + 4\sigma z_{0.75}$$

f) Bigote inferior:

$$QI - 1.5IQR = \mu - 4\sigma z_{0.75}$$

g) Probabilidad entre QI y QS:

$$P(QI \leq X \leq QS) = 0.75 - 0.25 = 0.5$$

h) Probabilidad entre QS y QS + 1.5IQR:

$$\begin{aligned} P(\mu + \sigma z_{0.75} \leq X \leq \mu + 4\sigma z_{0.75}) &= P(z_{0.75} \leq Z \leq 4z_{0.75}) \\ &\approx P(0.674 \leq Z \leq 2.697) \\ &\approx 0.24565 \end{aligned}$$

11. Relación entre distintas medidas de dispersión para la distribución normal

Sea $X \sim F = N(\mu, \sigma^2)$ Escribir, en términos de μ y σ

a) El desvío estándar poblacional:

$$sd_F(X) = \sigma$$

b) La MAD (*Median Absolute Deviation*) poblacional:

$$MAD_F(X) = Med_F\{|X - Med_F(X)|\}$$

donde $Med_F(W)$ es la notación para indicar la mediana poblacional de la variable aleatoria W que tiene distribución F , es decir Es decir, $Med_F(W) = F^{-1}(1/2)$.

i. Escribir a $Med_F(X)$ terminos de μ y σ .

$$Med_F(X) = \mu$$

ii. Escribir la función de distribución acumulada de $W = |X - \mu|$ en terminos de μ , σ y Φ . Chequear que vale:

$$F_W(t) = 2[\Phi(t/\sigma) - 1]I_{(0,+\infty)}(t)$$

OBS: creo que hay un error, el -1 va fuera del parentesis.

Para $t > 0$:

$$\begin{aligned} F_W(t) &= P(|X - \mu| \leq t) \\ &= P\left(|Z| \leq \frac{t}{\sigma}\right) \\ &= \Phi\left(\frac{t}{\sigma}\right) - \Phi\left(-\frac{t}{\sigma}\right) \\ &= 2\Phi\left(\frac{t}{\sigma}\right) - 1 \quad \forall t > 0 \end{aligned}$$

iii. Deducir del item anterior que la MAD de X resulta ser $\Phi^{-1}(0.75)\sigma$. La MAD es la mediana de W , osea el t tal que:

$$F_W(t) = 0.5$$

Entonces:

$$2\Phi\left(\frac{t}{\sigma}\right) - 1 = 0.5$$

$$\Phi\left(\frac{t}{\sigma}\right) = 0.75$$

$$t = \Phi^{-1}(0.75)\sigma$$

c) El rango intercuartil de X .

$$IQR_F(X) = Q_3 - Q_2 = 2\Phi^{-1}(0.75)\sigma$$

d) Explique por que el IQR y la MAD se dividen por 1.35 y 0.675, respectivamente, para poder ser comparados con el desvio estandar en el caso de tener una muestra normal.

Porque:

$$- MAD \sim 0.675\sigma$$

$$- IQR \sim 1.35\sigma$$