

Estadística *descriptiva* o análisis exploratorio de datos

¿Qué es la estadística?

- La ciencia de recolectar, describir y analizar datos.
(de libro de Lock, "Unlocking the power of data")

Estadística Descriptiva

1. En Estadística Descriptiva se exploran los datos mediante:
 - gráficos
 - medidas de resumen.

La idea es **visualizar** en forma rápida las principales características del conjunto de datos.

2. Con frecuencia los conjuntos de datos provienen de medir una o más variables en un conjunto de individuos.
3. Comenzaremos con un análisis individual de cada variable medida y posteriormente estudiaremos las relaciones entre variables.

Estadística descriptiva: Variables y datos

- **VARIABLE**: es una característica que varía de individuo en individuo.
(edad, peso, altura, género, concentración de colesterol en sangre, club de fútbol preferido, etc.)
- Tipos de variables:
 - Numéricas: discretas, continuas
 - Categóricas: nominales, ordinales
- **DATOS**: son los valores observados de las variables en estudio.

Estadística descriptiva

Medidas resumen

Medidas de resumen - Posición

Datos: $x_1, \dots, x_n$

- **Media de los datos** $\bar{x}$: es el promedio de los datos
- **Mediana de los datos** $\tilde{x}$: es el valor "del medio" del conjunto de datos ordenados de menor a mayor si n es impar y el promedio de los dos valores "del medio" si n es par.
- **Cuantil α de los datos**: es el valor que ocupa el lugar $[\alpha(n+1)]$ si ordeno los datos de menor a mayor.
- **Cuartiles de los datos**: Primero: Q_1 es el cuantil 0.25; Segundo: Q_2 mediana; Tercero: Q_3 es el cuantil 0.75.
- **Media α -podada de los datos**: es el promedio de los datos que quedan luego de eliminar el cuantil α y todos los datos menores que él y el cuantil $1 - \alpha$ y todos los datos mayores que él.

Ejemplo 1.1 (Del libro de Devore "Probability and statistics for engineering and the sciences")

La caridad es un gran negocio en Estados Unidos. Ver charitynavigator.com Algunas organizaciones benéficas operan de manera muy eficiente, con gastos de recaudación de fondos y administrativos que representan solo un pequeño porcentaje del total de gastos, mientras que otras destinan un alto porcentaje de lo que reciben a dichas actividades. A continuación se presentan datos sobre los gastos de recaudación de fondos como porcentaje del gasto total para 60 organizaciones benéficas

Ejemplo 1.1 (Continuación)

6.10	2.20	7.50	6.40	8.80	15.30
12.60	3.10	3.90	10.80	5.10	16.60
34.70	1.30	10.10	83.10	3.70	8.80
1.60	1.10	8.10	3.60	26.30	12.00
18.80	14.10	19.50	6.20	6.00	4.70
2.20	4.00	5.20	6.30	48.00	14.70
3.00	21.00	12.00	16.30	8.20	6.40
2.20	6.10	15.80	12.70	11.70	17.00
5.60	1.30	10.40	1.30	7.20	2.50
3.80	20.40	5.20	0.80	3.90	16.20

Ejemplo 1.1 (Continuación)

Cálculo de medidas de posición en R

```
x <- scan()  
6.1 12.6 34.7 1.6 18.8 2.2 3.0 2.2 5.6 3.8  
2.2 3.1 1.3 1.1 14.1 4.0 21.0 6.1 1.3 20.4  
7.5 3.9 10.1 8.1 19.5 5.2 12.0 15.8 10.4 5.2  
6.4 10.8 83.1 3.6 6.2 6.3 16.3 12.7 1.3 0.8  
8.8 5.1 3.7 26.3 6.0 48.0 8.2 11.7 7.2 3.9  
15.3 16.6 8.8 12.0 4.7 14.7 6.4 17.0 2.5 16.2
```

```
mean(x)  
median(x)  
quantile(x, 0.8)  
quantile(x, 0.1)  
summary(x)
```

Ejemplo 1.1 (Continuación)

```
> x <- scan()
1: 6.1 12.6 34.7 1.6 18.8 2.2 3.0 2.2 5.6 3.8
11: 2.2 3.1 1.3 1.1 14.1 4.0 21.0 6.1 1.3 20.4
21: 7.5 3.9 10.1 8.1 19.5 5.2 12.0 15.8 10.4 5.2
31: 6.4 10.8 83.1 3.6 6.2 6.3 16.3 12.7 1.3 0.8
41: 8.8 5.1 3.7 26.3 6.0 48.0 8.2 11.7 7.2 3.9
51: 15.3 16.6 8.8 12.0 4.7 14.7 6.4 17.0 2.5 16.2
61:
Read 60 items
> mean(x)
[1] 10.89167
> median(x)
[1] 6.8
> quantile(x, 0.8)
80%
15.88
> summary(x)
Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
0.800   3.875   6.800  10.892  14.250  83.100
```

Medidas de resumen - *Dispersión*

Datos: $x_1, \dots, x_n$

- Varianza de los datos:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

- Desviación estandar de los datos:

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

- Distancia intercuartil de los datos: $Q_3 - Q_1$
- Mediana de desviaciones absolutas (MAD) de los datos:
 $\text{mediana}\{|x_i - \tilde{x}|\}.$

Ejemplo 1.1 (Continuación)

Cálculo de medidas de dispersión en R

```
> var(x)
[1] 162.3357
> sd(x)
[1] 12.7411
> IQR(x)
[1] 10.375
> mad(x)
[1] 6.59757
> mad(x, constant = 1)
[1] 4.45
```

Estadística descriptiva

Gráficos

Histograma: AREA=FRECUENCIA RELATIVA

1. datos: $x_1, \dots, x_n$
2. datos ordenados: $x_{(1)} \leq \dots, \leq x_{(n)}$
3. $I_1, \dots, I_K$, K intervalos que particionan $[x_{(1)}, x_{(n)}]$
4. Graficamos una constante sobre cada intervalo de forma tal que el area del rectángulo coincida con la frecuencia relativa en el intervalo:


$$\text{Altura sobre } I_j \times \text{longitud } (I_j) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}_{x_i \in I_j}$$

Si $I_j = (a, b)$, entonces longitud $(I_j) = |I_j| = b - a$


$$\text{Altura sobre } I_j = \frac{1}{|I_j|} \frac{1}{n} \sum_{i=1}^n \mathbf{I}_{x_i \in I_j}$$

Ejemplo 1.1 (Continuación)


```
hist(x, probability = TRUE)
```



Boxplot




Boxplot



Ejemplo 1.1 (Continuación)

```
hist(x, probability = TRUE)
```



QQ-plot

El qq-plot es un gráfico que nos sirve para comparar la distribución que genere un conjunto de datos (desconocida) a la distribución normal.

Para realizarlo los cuantiles del conjunto de datos se grafican versus los cuantiles teóricos de la normal.


Si los datos provienen de una distribución $N(0, 1)$ esperamos que el gráfico sea parecido a la recta $y = x$.

Si los datos provienen de una distribución $N(\mu, \sigma^2)$ el gráfico será parecido a una recta por las propiedades de la distribución normal. (Ejercicio 12 de la práctica 1.)

El alejamiento de la normalidad se ve reflejado por la forma del gráfico.

Ejemplo 1.1 (Continuación)

`qqnorm(x)`



Estadística descriptiva

Datos bivariados

Datos bivariados: relación entre dos variables numéricas

- ¿Hay relación entre las variables?
- ¿Cuán fuerte es la relación entre las variables?
- ¿Es la relación entre las variables lineal?

Datos bivariados

Ejemplo 1.2

Departamentos en venta en Buenos Aires en 2016

Fuente: <https://data.buenosaires.gob.ar/>

```
> departamentos<-read.csv("departamentos.txt",  
header = TRUE)
```


```
> head(departamentos)
```

M2	M2CUB	DOLARES	U_S_M2
42	38	75000	1973
80	74	165000	2229
45	39	138000	3538
230	210	580000	2761
40	40	73615	1840
50	50	88600	1772

.....

Ejemplo 1.2 (Cotinuación)

```
with(data=departamentos, plot(M2,DOLARES))
```



Correlación

- **Recuerdo:** La correlación de un vector aleatorio (X, Y) :

$$\rho(X, Y) = \frac{E((X - E(X))(Y - E(Y)))}{\sqrt{V(X)V(Y)}}$$

Definition 1.3

La correlación entre dos conjuntos de datos $(x_1, \dots, x_n)$ e $(y_1, \dots, y_n)$:

$$\hat{\rho} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})/n}{\sqrt{\sum (x_i - \bar{x})^2/n \sum (y_i - \bar{y})^2/n}}$$

que es lo mismo que

$$\hat{\rho} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Correlación

Ejemplo 1.2 (Cotinuación)

La correlación en R

```
> cor(departamentos$M2,departamentos$DOLARES)  
[1] 0.8003153
```

Correlación

Ejercicio 1.4

Probar que

1. $-1 \leq \hat{\rho} \leq 1$
2. Si $y_i = ax_i + b$ para todo i entonces $\hat{\rho} = \text{sign}(a)$.

Muestra y datos

Datos bivariados

Muestra y datos

Definition 1.5

Dado un espacio muestral Ω y una variable aleatoria de interés X con distribución F . Decimos que $X_1, \dots, X_n$ es una muestra aleatoria de F si son v.a. i.i.d con distribución F .

Un conjunto de datos u observaciones es un conjunto de números reales $x_1, \dots, x_n$ que constituyen una realización de una muestra aleatoria, es decir son los resultados obtenidos al realizar el "experimento".

Muestra y datos

Definition 1.5

Dado un espacio muestral Ω y una variable aleatoria de interés X con distribución F . Decimos que $X_1, \dots, X_n$ es una muestra aleatoria de F si son v.a. i.i.d con distribución F .

Un conjunto de datos u observaciones es un conjunto de números reales $x_1, \dots, x_n$ que constituyen una realización de una muestra aleatoria, es decir son los resultados obtenidos al realizar el "experimento".

A partir de las observaciones vamos a querer estimar F o alguna característica de F , como $F(3)$, $\mathbb{E}_F(X)$, etc.

Notación

Notación

1. $X \sim F$ quiere decir que F es la función de distribución acumulada de X , es decir, que $F(t) = \mathbb{P}(X \leq t)$
2. $\mathbb{E}_F(X)$ quiere decir la esperanza de X , donde $X \sim F$.

Ejemplos de Muestra y Datos

Ejemplo 1.6 (Datos)

Experimento: Tirar un dado 10 veces.

X_i = resultado de la i -ésima tirada

$X_1, \dots, X_{10}$ es una **muestra aleatoria** de la distribución F
quiere decir que X_i son i.i.d. con $X_i \sim F$.

Cada vez que realizo el experimento obtengo un **conjunto de datos u observaciones** $x_1, \dots, x_{10}$ que son simplemente números reales:

Por ejemplo 1, 6, 6, 5, 6, 3, 4, 5, 1, 1

A partir de las observaciones queremos estimar F o alguna característica de F .

Por ejemplo, $F(2)$, $F(1)$ o $\mathbb{E}_F(X)$.

Ejemplos de Muestra y Datos

Ejemplo 1.7 (Departamentos)

Experimento: Elegir n departamentos en venta en la Ciudad de Buenos Aires.

X_i = metros cuadrados del i -ésimo departamento

*$X_1, \dots, X_n$ es una **muestra aleatoria**.*

*Cada vez que realizo el experimento obtengo un **conjunto de datos u observaciones** $x_1, \dots, x_n$ que son simplemente números reales:*

Por ejemplo 45, 100, 230, 155, 32,250

A partir de las observaciones queremos estimar F o alguna característica de F .

Por ejemplo, $F(100)$, $F^{-1}(1/2)$ o $\mathbb{E}_F(X)$.

Ejemplos de Muestra y Datos

Ejemplo 1.7 (Departamentos - Continuación)

Experimento: Elegir al azar n departamentos en venta en la Ciudad de Buenos Aires.

$X_i = m^2$ del i -ésimo departamento

$Y_i = m^2$ cubiertos del i -ésimo departamento

$Z_i =$ precio en dólares del i -ésimo departamento

$W_i =$ precio en dólares por m^2 del i -ésimo departamento

$$(X_1, Y_1, Z_1, W_1) \dots (X_n, Y_n, Z_n, W_n)$$

es una **muestra aleatoria de vectores**.

Cada vez que realizo el experimento obtengo un **conjunto de datos u observaciones** $(x_1, y_1, z_1, w_1), \dots, (x_n, y_n, z_n, w_n)$ que son simplemente vectores numéricos.

Ejemplos de Muestra y Datos

Ejemplo 1.7 (Departamentos - Continuación)

Supongamos que $(X_1, Y_1, Z_1, W_1) \sim F$.

A partir de las observaciones queremos estimar F o alguna característica de F .

Por ejemplo $F(100, 100, 100000, 1000)$, $\rho_F(X, W)$, $\mathbb{P}(W \leq 1000)$.

Notación

$(X_1, \dots, X_k) \sim F$ quiere decir que F es la función de distribución acumulada conjunta de $(X_1, \dots, X_k)$, es decir, que

$$F(t_1, \dots, t_k) = \mathbb{P}(X_1 \leq t_1, \dots, X_k \leq t_k)$$

Ejemplo 1.7 (Departamentos 2 - Continuación)

Experimento: Elegir al azar 6 departamentos en venta en Buenos Aires

	<i>M2</i>	<i>M2CUB</i>	<i>DOLARES</i>	<i>U_S_M2</i>
1	42	38	75000	1973
2	80	74	165000	2229
3	45	39	138000	3538
4	230	210	580000	2761
5	40	40	73615	1840
6	50	50	88600	1772

Es una realización de

$$(X_1, Y_1, Z_1, W_1) \dots (X_6, Y_6, Z_6, W_6)$$

Fuente: <https://data.buenosaires.gob.ar/>

La función de distribución empírica

Estimando la función de distribución acumulada

Ejemplo 1.8 (Estimación de F en un conjunto de datos)

1. Supongamos que tenemos una realización de una muestra aleatoria $X_1, \dots, X_5$ de una distribución F :

165.03 , 162.37 , 156.67 , 167.84 , 172.47

2. Estimar $F(160)$
3. Estimar $F(168)$.
4. Proponer una fórmula para estimar $F(t)$

$$\hat{F}_{obs}(t) = \dots\dots\dots$$

5. Grafique la función $\hat{F}_{obs} : \mathbb{R} \rightarrow [0, 1]$.

Estimando la función de distribución acumulada

Ejemplo 1.8 (Estimación de F . Resolución)

Considere los siguientes datos, generados por una distribución F .

165.03 , 162.37 , 156.67 , 167.84 , 172.47


1. Estimación de $F(160)$: $1/5$
2. Estimación $F(168)$: $4/5$
3. Fórmula para estimar $F(t)$

$$\hat{F}_{obs}(t) = \frac{1}{5} \sum_{i=1}^5 I\{x_i \leq t\}.$$

Estimando la función de distribución acumulada

Ejemplo 1.9 (Estimación de F . Resolución)

4. Gráfico de $\hat{F}_{obs}$:



Estimando la función de distribución acumulada

Ejemplo 1.10 (Estimación de F)

Observar que

$$\hat{F}_{obs}(t) = \frac{1}{5} \sum_{i=1}^5 I\{x_i \leq t\}$$

es la función de distribución acumulada de una v.a. discreta con rango $\{156.67, 162.37, 165.03, 167.84, 172.47\}$.

5. Hallar su función de probabilidad puntual.

valores	156.67	162.37	165.03	167.84	172.47
prob puntual					

Función de distribución empírica basada en observaciones

$x_1, \dots, x_n$

Definition 1.11

Llamamos función de distribución empírica basada en las observaciones $x_1, \dots, x_n$ a la función

$$\hat{F}_{obs}(t) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}\{x_i \leq t\}$$

Observación 1.12

$\hat{F}_{obs}$ es la función de distribución acumulada de la variable aleatoria discreta que asigna probabilidad $1/n$ a cada valor $x_1, \dots, x_n$.

valores	x_1	$\dots$	$\dots$	$\dots$	x_n
prob puntual	$1/n$	$1/n$	$1/n$	$1/n$	$1/n$

La función de distribución empírica

basada en una muestra aleatoria

Definition 1.13

Dada una **muestra aleatoria**: $X_1, \dots, X_n$, su función de distribución empírica es

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I_{(-\infty, x]}(X_i)$$

donde

$$I_{(-\infty, x]}(X_i) = \begin{cases} 1, & \text{if } X_i \leq x \\ 0, & \text{if } X_i > x \end{cases}$$

La función de distribución empírica

basada en una muestra aleatoria

Observación 1.14 (Propiedades)

Las variables aleatorias $I_{(-\infty, x]}(X_i)$ son i.i.d con distribución de Bernoulli.

$$I_{(-\infty, x]}(X_i) = \begin{cases} 1, & \text{con probabilidad } F(x) \\ 0, & \text{con probabilidad } 1 - F(x) \end{cases}$$

Para todo $x \in \mathbb{R}$ fijo, se tiene

$$E \left[\hat{F}_n(x) \right] = F(x)$$

$$\text{Var} \left[\hat{F}_n(x) \right] = \frac{1}{n} F(x) [1 - F(x)]$$

$$\hat{F}_n(x) \xrightarrow{P} F(x)$$

Relación entre $\hat{F}_{obs}$ y medidas resumen

Ejercicio 1.15

Sea $\hat{F} = \hat{F}_{obs}$ la función de distribución empírica basada en las observaciones $x_1 \dots x_n$. Sea $X \sim \hat{F}$. Probar que:

1. $\mathbb{E}_{\hat{F}}(X) = \bar{x}$
2. $\mathbb{V}_{\hat{F}}(X) = \frac{n-1}{n} s^2$

Relación entre $\hat{F}_{obs}$ y medidas resumen: mediana y cuantiles

Definition 1.16 (Inversa generalizada)

Si F es una función de distribución acumulada

$$F^{-1}(p) = \inf\{x/F(x) \geq p\}$$

Proposición 1.17

Si $\hat{F} = \hat{F}_{obs}$ es la función de distribución empírica basada en las observaciones $x_1 \dots x_n$, y $X \sim \hat{F}$, entonces

1. $\hat{F}^{-1}(1/2) = x_{((n+1)/2)}$

2. $\hat{F}^{-1}(\alpha) = x_{([\alpha(n+1)])}$

donde $x_{(1)} \leq \dots \leq x_{(n)}$.

Relación entre $\hat{F}_{obs}$ y medidas resumen: mediana y cuantiles

Definition 1.16 (Inversa generalizada)

Si F es una función de distribución acumulada

$$F^{-1}(p) = \inf\{x/F(x) \geq p\}$$

Proposición 1.17

Si $\hat{F} = \hat{F}_{obs}$ es la función de distribución empírica basada en las observaciones $x_1 \dots x_n$, y $X \sim \hat{F}$, entonces

1. $\hat{F}^{-1}(1/2) = x_{((n+1)/2)}$

2. $\hat{F}^{-1}(\alpha) = x_{([\alpha(n+1)])}$

donde $x_{(1)} \leq \dots \leq x_{(n)}$.

Proof.

Ejercicio optativo



Estimación de la densidad

Estimación de la densidad

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$.

$X \sim F$ v.a. continua con densidad $f(x)$

Sabemos estimar F mediante $\hat{F}_n =$ la función de distribución empírica.

¿Cómo estimamos f ?

Queremos estimar f sin asumir una determinada forma:
solo asumimos que f es suave.

La forma más sencilla: el **histograma**

Histograma

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

- Sea I un intervalo que contiene a todos los datos y $\mathcal{C} = \{C_1, \dots, C_k\}$ una partición de I en intervalos o clases acotados (bins) y disjuntos. Es decir,

$$I = \cup_{j=1}^k C_j$$


- Para cada $x \in \mathbb{R}$

$$\hat{f}(x) = \begin{cases} \frac{\#\{X_i: X_i \in C_j\}}{n|C_j|} & \text{si } x \in C_j \\ 0 & \text{si } x \notin I \end{cases}$$

con $|C_j|$ longitud del intervalo C_j




Histogramas con distintas particiones de I

Ejemplo 1.18 (Caída de nieve anual en Buffalo (EEUU) en inviernos entre 1910/11 to 1972/73.)







Histogramas con distintas particiones de I

Ejemplo 1.18 (Caída de nieve anual en Buffalo (EEUU) en inviernos entre 1910/11 to 1972/73.)



Histogramas con distinto punto inicial

Ejemplo 1.19 (Datos simulados)



Desventajas del histograma

- el estimador de la densidad depende del punto inicial de los bins:
- la densidad estimada no es suave, es *escalonada* y esto no es propio de la densidad sino de la herramienta de estimación
- por estas razones, el histograma es usado sólo para visualización

Idea 1: Enfoque Frecuentista


$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

$$\mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$$

Idea 2: Enfoque analítico

Si h es pequeño y f es continua.

$$\mathbb{P}(X \in [x-h, x+h]) = \int_{x-h}^{x+h} f(t) dt \approx 2hf(x)$$



Juntemos las dos ideas...

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

- $\mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$
- $\mathbb{P}(X \in [x - h, x + h]) \approx 2h f(x)$

Juntemos las dos ideas...

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

- $\mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$
- $\mathbb{P}(X \in [x - h, x + h]) \approx 2h f(x)$
- Entonces, podemos aproximar

$$2h f(x) \approx \mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$$

Juntemos las dos ideas...

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

- $\mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$
- $\mathbb{P}(X \in [x - h, x + h]) \approx 2h f(x)$
- Entonces, podemos aproximar

$$2h f(x) \approx \mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$$

$$f(x) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{2h n}$$

Propuesta

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

$$\hat{f}_h(x) = \frac{\#\{X_i \in [x - h, x + h]\}}{2h n}$$

Hagamos algunas pruebas y pongamos manos a la obra en:

https://glmconr2.shinyapps.io/app_ker2/

Propuesta

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

$$\hat{f}_h(x) = \frac{\#\{X_i \in [x - h, x + h]\}}{2h n}$$

Propuesta

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

$$\hat{f}_h(x) = \frac{\#\{X_i \in [x-h, x+h]\}}{2h n}$$

Podemos reescribir esta expresión como:

$$\hat{f}_h(x) = \frac{1}{2h n} \sum_{i=1}^n I_{[x-h, x+h]}(X_i)$$

- Estimador de Rosenblatt-Parzen

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n \frac{1}{2} I_{[-1,1]} \left(\frac{x - X_i}{h} \right)$$

Propuesta

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

$$\hat{f}_h(x) = \frac{\#\{X_i \in [x-h, x+h]\}}{2h n}$$

Podemos reescribir esta expresión como:

$$\hat{f}_h(x) = \frac{1}{2h n} \sum_{i=1}^n I_{[x-h, x+h]}(X_i)$$

- Estimador de Rosenblatt-Parzen

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n \frac{1}{2} I_{[-1,1]} \left(\frac{x - X_i}{h} \right)$$

- si $K(t) = \frac{1}{2} I_{[-1,1]}(t) \Rightarrow$

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K \left(\frac{x - X_i}{h} \right)$$

Estimador de Rosenblatt-Parzen

Definition 1.20 (Estimador de Rosenblatt-Parzen con núcleo rectangular)

Dadas $X_1, \dots, X_n$, i.i.d.,

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)$$

donde $K(t) = \frac{1}{2}I_{[-1,1]}(t)$

Ejercicio 1.21

Probar que

- $\hat{f}_h(x) \geq 0$
- $\int \hat{f}_h(x) dx = 1$

Núcleo y ventana

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

Estimador de Rosenblatt-Parzen:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right), \text{ con } K(t) = \frac{1}{2}I_{[-1,1]}(t)$$

- K : núcleo
- h : ventana



Núcleo y ventana

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

Estimador de Rosenblatt-Parzen:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right), \text{ con } K(t) = \frac{1}{2}I_{[-1,1]}(t)$$

- K : núcleo
- h : ventana




Tipos de núcleos


- Núcleo Rectangular: $K(t) = \frac{1}{2}I_{[-1,1]}(t)$
- Núcleo Triangular: $K(t) = (1 - |t|)I_{[-1,1]}(t)$
- Núcleo Gaussiano: $K(t) = \frac{1}{\sqrt{2\pi}}e^{-\frac{1}{2}t^2}$
- Núcleo Epanechnikov: $K(t) = \frac{3}{4}(1 - t^2)I_{[-1,1]}(t)$

Núcleos


Uniforme




Epanechnikov



Triangular



Normal





Volvemos al shiny a probar con el núcleo normal

https://glmconr2.shinyapps.io/app_ker2/

Estimadores de núcleos (Rosenblatt-Parzen)

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-X_i}{h}\right)$$

- K núcleo: * $K \geq 0$ y * $\int K(x)dx = 1$.
- h : ventana o parámetro de suavizado
- Notemos que $\hat{f}(x)$ depende de n , del núcleo K y de h



¿Cómo elegimos h ? Lo veremos más adelante