

Estimadores de núcleos: Selección de ventana

En estimación de la densidad la elección de la ventana es crucial.

- Una ventana h demasiado pequeña dará un estimador muy rugoso, con muchos picos y difícil de interpretar
- una ventana h demasiado grande sobresuaviza al estimador de la densidad y enmascara estructuras de los datos.

$\hat{f}_h(x)$: estimador de Parzen

$$\hat{f}_h(x) = \frac{1}{2hn} \sum_{i=1}^n \mathcal{I}_{[x-h, x+h]}(X_i) \quad \text{con} \quad \sum_{i=1}^n \mathcal{I}_{[x-h, x+h]}(X_i) \sim Bi(n, p)$$

donde $p = \mathbb{P}(x - h \leq X \leq x + h) = F(x + h) - F(x - h) = p_{x,h}$

Luego, usando las propiedades de esperanza y varianza:

$$\begin{aligned}\mathbb{E}[\hat{f}_h(x)] &= \frac{F(x + h) - F(x - h)}{2h} \\ \mathbb{V}\text{ar}[\hat{f}_h(x)] &= \frac{F(x + h) - F(x - h)}{4nh^2} - \frac{(F(x + h) - F(x - h))^2}{4nh^2}\end{aligned}$$

Si

- $h \rightarrow 0 \Rightarrow \mathbb{E}[\hat{f}_h(x)] \rightarrow f(x)$ y $\mathbb{V}\text{ar}[\hat{f}_h(x)] \approx \frac{f(x)}{2nh} - \frac{f(x)^2}{n} \rightarrow \infty$
- $nh \rightarrow \infty, n \rightarrow \infty, h \rightarrow 0$, entonces sesgo y varianza se reducen.

Sesgo y Varianza del estimador de Rosenblatt–Parzen

Supongamos que:

- la densidad f es de cuadrado integrable, dos veces continuamente diferenciable y su segunda derivada es de cuadrado integrable.
- el núcleo K es simétrico, es una densidad acotada, de cuadrado integrable y con segundo momento finito.
- $h = h_n \rightarrow 0$, $n \rightarrow \infty$ y $nh \rightarrow \infty$.

Luego,

$$\mathbb{B} \left(\hat{f}_h(x) \right) = \frac{1}{2} \mu_2(K) f''(x) h^2 + o(h^2)$$

$$\mathbb{V} \left(\hat{f}_h(x) \right) = \frac{\|K\|_2^2}{nh} f(x) + o((nh)^{-1})$$

Recomendamos:

Tesis de Licenciatura de Romina Cornistein: *Estimadores de Naradaya Watson aplicados a datos funcionales*

Disponible en:

<https://web.dm.uba.ar/index.php/509-tesis-de-licenciatura>

Sesgo del estimador de Rosenblatt–Parzen (Video 1)

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h} K\left(\frac{x - X_i}{h}\right)$$

$$\begin{aligned}\mathbb{E}\left(\hat{f}_h(x)\right) &= \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n \frac{1}{h} K\left(\frac{x - X_i}{h}\right)\right] \\&= \frac{1}{n} \sum_{i=1}^n \frac{1}{h} \mathbb{E}\left[K\left(\frac{x - X_i}{h}\right)\right] \\&= \mathbb{E}\left[\frac{1}{h} K\left(\frac{x - X_1}{h}\right)\right] \\&= \int \frac{1}{h} K\left(\frac{x - s}{h}\right) f(s) ds\end{aligned}$$

Resolvemos la integral (Video 1)

$$\mathbb{E} \left(\hat{f}_h(x) \right) = \int \frac{1}{h} K \left(\frac{x-s}{h} \right) f(s) ds$$

hacemos el cambio de variables: $s = x - ht \rightarrow ds = -h dt$

$$= \int K(t) f(x - ht) dt$$

ahora sumamos y restamos $f(x)$

$$= f(x) + \int K(t) f(x - ht) dt - \int f(x) K(t) dt$$

$$= f(x) + \int [f(x - ht) - f(x)] K(t) dt$$

Seguimos.... (Video 1)

Mediante un desarrollo de Taylor obtenemos

$$f(x - ht) = f(x) - f'(x)ht + \frac{f''(x)}{2}h^2t^2 + o(h^2t^2).$$

Luego,

$$\begin{aligned} & \int K(t)[f(x - ht) - f(x)] dt \\ &= \int K(t) \left\{ -f'(x)ht + \frac{f''(x)}{2}h^2t^2 + o(h^2t^2) \right\} dt \\ &= \frac{1}{2}\mu_2(K)f''(x)h^2 + o(h^2), \end{aligned}$$

siendo $\mu_2(K) = \int K(t)t^2 dt$ el segundo momento de K .

Varianza del estimador de Rosenblatt–Parzen (Video 1)

$$\mathbb{V} \left(\hat{f}_h(x) \right) = \mathbb{V} \left(\frac{1}{n} \sum_{i=1}^n \frac{1}{h} K \left(\frac{x - X_i}{h} \right) \right) = \frac{1}{n} \mathbb{V} \left(\frac{1}{h} K \left(\frac{x - X_1}{h} \right) \right) \text{ por qué?}$$

$$\begin{aligned} & \swarrow \mathbb{V}(Z) = \mathbb{E}(Z^2) - \mathbb{E}^2(Z) \\ &= \frac{1}{n} \int \frac{1}{h^2} K^2 \left(\frac{x-s}{h} \right) f(s) ds - \frac{1}{n} \left[\int K(t) f(x-h t) dt \right]^2 \\ &= \frac{1}{nh} \int K^2(t) f(x-h t) dt - \frac{1}{n} \left[\int K(t) f(x-h t) dt \right]^2 \end{aligned}$$

Continuación

$$\begin{aligned}\frac{1}{h} \int K^2(t) f(x - ht) dt &= \\ &= \frac{1}{h} \int K^2(t) \{f(x) + O(ht)\} dt \\ &= \frac{\|K\|_2^2}{h} f(x) + O(1).\end{aligned}$$

siendo $\|K\|_2^2 = \int K^2(t) dt$. Por lo tanto, reemplazando

$$\begin{aligned}\mathbb{V}\text{ar}[\hat{f}_h(x)] &= \frac{1}{n} \left\{ \frac{\|K\|_2^2}{h} f(x) + O(1) - O(1) \right\} \\ &= \frac{\|K\|_2^2}{nh} f(x) + O(n^{-1}) \\ &= \frac{\|K\|_2^2}{nh} f(x) + o((nh)^{-1}),\end{aligned}$$

ya que $n^{-1} = o((nh)^{-1})$.

Compromiso Sesgo–Varianza

Luego,

$$\mathbb{B} \left(\hat{f}_h(x) \right) = \frac{1}{2} \mu_2(K) f''(x) h^2 + o(h^2)$$

$$\mathbb{V} \left(\hat{f}_h(x) \right) = \frac{\|K\|_2^2}{nh} f(x) + o((nh)^{-1})$$

Para n fijo:

$h \rightarrow 0$ implica $E \left(\hat{f}_h(x) \right) \rightarrow f(x)$ y $\mathbb{V} \left(\hat{f}_h(x) \right) \rightarrow \infty$

Sesgo y Varianza de $\hat{f}_h(x)$

Comprobamos en el caso fácil que para que todo funcione bien deben pasar dos cosas:

- $h \rightarrow 0$
- $nh \rightarrow \infty$
- Se puede probar que bajo condiciones generales del núcleo K

$$\begin{aligned}\mathbb{E}[\hat{f}_h(x)] &\approx \frac{h^2}{2} \mu_2(K) f''(x) \\ \text{Var}[\hat{f}_h(x)] &\approx \frac{1}{nh} \|K\|_2^2 f(x)\end{aligned}$$

- El sesgo es proporcional a $h^2 \Rightarrow$ elijamos h pequeña
- El sesgo depende de $f''(x)$ que mide la curvatura de f en x
- La varianza disminuye a medida que nh crece
- Para disminuir la varianza necesitamos h o n grandes.

Error Cuadrático Medio de $\hat{f}_h(x)$

Compromiso Sesgo-Varianza

Tenemos que

$$\text{MSE}[\hat{f}_h(x)] = (\mathbb{B}[\hat{f}_h(x)])^2 + \text{Var}[\hat{f}_h(x)]$$

Por otro lado:

$$\mathbb{B}[\hat{f}_h(x)] \approx \frac{h^2}{2} \mu_2(K) f''(x)$$

$$\text{Var}[\hat{f}_h(x)] \approx \frac{1}{nh} \|K\|_2^2 f(x)$$

$$\Rightarrow \text{MSE}[\hat{f}_h(x)] \approx \frac{h^4}{4} \mu_2^2(K) (f''(x))^2 + \frac{1}{nh} \|K\|_2^2 f(x)$$

Si $h \rightarrow 0$ y $nh \rightarrow \infty$, entonces $\text{MSE}[\hat{f}_h(x)] \rightarrow 0$.

Compromiso Sesgo-Varianza $\longleftrightarrow$ relación con sobreajuste

Error Cuadrático Integrado y Medio Integrado de $\hat{f}_h$

Como medida global: **Error Cuadrático Integrado**

$$\text{ISE}[\hat{f}_h] = \int \left(\hat{f}_h(x) - f(x) \right)^2 dx$$

Como medida global: **Error Cuadrático Medio Integrado**

$$\text{MISE}[\hat{f}_h] = \int \text{MSE}[\hat{f}_h(x)] dx$$

Asintóticamente: **Error Cuadrático Medio Integrado Asintótico**

$$\text{AMISE}[\hat{f}_h(x)] = \frac{h^4}{4} \mu_2^2(K) \int (f''(x))^2 dx + \frac{1}{nh} \|K\|_2^2$$

Error Cuadrático Medio Integrado de $\hat{f}_h$

$$\text{AMISE}[\hat{f}_h(x)] = \frac{h^4}{4} \mu_2^2(K) \|f''\|_2^2 + \frac{1}{nh} \|K\|_2^2$$

- Notemos que es una función de la ventana h .
- Derivando a AMISE respecto de h e igualando a 0, obtenemos que el valor de h que minimiza el AMISE es

$$h = \left\{ \frac{\|K\|_2^2}{\mu_2^2(K) \|f''\|_2^2 n} \right\}^{\frac{1}{5}} = \text{algo} * \left(\frac{1}{n} \right)^{\frac{1}{5}} \sim n^{-\frac{1}{5}}$$

Selección de h : Regla de Silverman

El $\text{AMISE}[\hat{f}_h(x)]$ se minimiza en

$$h = \left\{ \frac{\|K\|_2^2}{\mu_2^2(K) \|f''\|_2^2 n} \right\}^{\frac{1}{5}}$$

- Silverman propone reemplazar a $\|f''\|_2^2$ por su valor cuando f es normal:

$$\|f''\|_2^2 = \frac{3}{8} \pi^{-1/2} \sigma^{-5} \approx 0.212 \sigma^{-5}$$

y a σ por un estimador $\hat{\sigma}$

$$h_{Sil} = \left(\frac{4\hat{\sigma}^5}{3n} \right)^{\frac{1}{5}} \approx 1.06 \hat{\sigma} n^{-\frac{1}{5}}$$

- Si f es normal, la ventana h_{Sil} es óptima.
- Si f no es normal, h_{Sil} dará una ventana no muy alejada de la óptima cuando la distribución no es muy diferente a la normal.

Selección de h : Regla de Silverman

$$h_{Sil} = \left(\frac{4\hat{\sigma}^5}{3n} \right)^{\frac{1}{5}} \approx 1.06 \hat{\sigma} n^{-\frac{1}{5}}$$

- σ puede estimarse por S (sd(datos) en R).
o
- σ puede estimarse por la distancia intercuartil IQR (IQR(datos) en R). Para que coincida con σ bajo la distribución normal debe dividirse por 1.349
- La ventana óptima de acuerdo a la regla de Silverman resulta:

$$h_{Sil} = 1.06 \min \left(S, \frac{IQR}{1.349} \right) n^{-\frac{1}{5}}$$

- Algunos autores sugieren reducir el factor 1.06 a 0.90 para aumentar la posibilidad de detectar bimodalidad. (Explorar bw.nrd y bw.nrd0 en R)