

Compromiso sesgo-varianza

Theorem 2.35

$$ECM_{\theta}(T_n) = \mathbb{V}_{\theta}(T_n) + (\mathbb{B}_{\theta}(T_n))^2$$

Compromiso sesgo-varianza

Theorem 2.35

$$ECM_{\theta}(T_n) = \mathbb{V}_{\theta}(T_n) + (\mathbb{B}_{\theta}(T_n))^2$$

Proof.

$$\begin{aligned} ECM_{\theta}(T_n) &= \mathbb{E}_{\theta} [(T_n - q(\theta))^2] \\ &= \mathbb{V}_{\theta} [(T_n - q(\theta))] + [\mathbb{E}_{\theta}(T_n - q(\theta))]^2 \\ &= \mathbb{V}_{\theta}(T_n) + [\mathbb{E}_{\theta}(T_n) - q(\theta)]^2 \\ &= \mathbb{V}_{\theta}(T_n) + (\mathbb{B}_{\theta}(T_n))^2, \text{ como queríamos demostrar.} \end{aligned}$$



Estimadores:
Comportamiento Asintótico de un Estimador

September 4, 2025

Repasemos

$\mathbf{X}_n = (X_1 \dots X_n)$ m.a. $X_i \sim F$, $F \in \mathcal{F}$, $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$.
Queremos estimar $q(\theta)$.

Sea $T_n = T(X_1 \dots X_n)$ un estimador de $q(\theta)$

- Sesgo: $\mathbb{B}_\theta(T_n) = \mathbb{E}_\theta(T_n) - q(\theta)$
- Error cuadrático medio: $ECM_\theta(T_n) = \text{Var}_\theta(T_n) + \mathbb{B}_\theta^2(T_n)$
- Error standard: $se(T_n) = \sqrt{\text{Var}_\theta(T_n)}$

Recordemos: Estimación de una proporción

Ejemplo 2.36

Queremos estimar la proporción p de ciudadanos de Argentina que cumple cierta condición. Para, elegimos n ciudadanos al azar y verificamos si cumple o no la condición

$$X_i = \begin{cases} 1 & \text{si el } i - \text{ésimo cumple la condición de interés} \\ 0 & \text{si no} \end{cases}$$

- $X_1, \dots, X_n$ son variables aleatorias i.i.d. con distribución $B(1, p)$, siendo p la verdadera proporción que queremos estimar.

- Un estimador puntual (EMM o EMV) de p es $\hat{p}_n = \frac{1}{n} \sum_{i=1}^n X_i$

- ¿Por qué tomamos $n = 1000$? ¿Sería más conveniente tomar $n = 2000$? Si es mejor una elección que otra, ¿donde se ve?

- $se(\hat{p}_n) = \sqrt{\text{Var}_p(\hat{p}_n)} = \sqrt{\frac{p(1-p)}{n}}$

Distribución de muestreo y error standard

Definition 2.37

- La distribución de T_n se llama **distribución de muestreo** (sample distribution).
- La desviación estandar de T_n se llama **error standard**, es por lo general desconocida y se utiliza un estimador del error estandar, lo notamos $\hat{se}(T_n)$.
 - Error standard: $se(T_n) = \sqrt{\mathbb{V}ar_{\theta}(T_n)}$
 - Estimador del error standard: $\hat{se}(T_n) = \sqrt{\widehat{\mathbb{V}ar}_{\theta}(T_n)}$

Consistencia

Tenemos:

$\mathbf{X}_n = (X_1 \dots X_n)$ m.a. $X_i \sim F$, $F \in \mathcal{F}$, $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$.

Queremos estimar $q(\theta)$.

Sea $T_n = T(X_1 \dots X_n)$ un estimador de $q(\theta)$

Definition 2.38

T_n es una sucesión fuertemente consistente de estimadores de $q(\theta)$ si

$$T_n \xrightarrow{\text{c.s.}} q(\theta)$$

es decir si $\lim_{n \rightarrow \infty} T_n = q(\theta)$ c.s. (o c.t.p.), o sea si para todo $\theta \in \Theta$

$$\mathbb{P}_\theta \left(\omega \in \Omega : \lim_{n \rightarrow \infty} T_n = q(\theta) \right) = 1,$$

Consistencia

Tenemos:

$\mathbf{X}_n = (X_1 \dots X_n)$ m.a. $X_i \sim F$, $F \in \mathcal{F}$, $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$.
Queremos estimar $q(\theta)$.

Sea $T_n = T(X_1 \dots X_n)$ un estimador de $q(\theta)$

Definition 2.39

T_n es una sucesión débilmente consistente de estimadores de $q(\theta)$ si

$$T_n \xrightarrow{P} q(\theta)$$

o sea, si para todo $\varepsilon > 0$ y $\theta \in \Theta$

$$\lim_{n \rightarrow \infty} \mathbb{P}_\theta(|T_n - q(\theta)| > \varepsilon) = 0.$$

¿Quién puede ayudarnos? Ley de los Grandes Números

- **Ley fuerte:** Sean $X_1, X_2, \dots$ v.a. independientes de a pares e idénticamente distribuidas con $E|X_1| < \infty$. Si $E(X_1) = \mu$, entonces

$$\overline{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{c.s.} \mu .$$

Ver libro “Probability theory and examples” de Rich Durrett.

¿Quién puede ayudarnos? Ley de los Grandes Números

- **Ley débil:** Sean $\{X_n\}_{n \geq 1}$ variables aleatorias no correlacionadas, es decir $\text{Cov}(X_i, X_j) = 0$ para $i \neq j$, tales que $\mathbb{E}(X_j) = \mu_j$ y $\text{Var}(X_j) = \sigma_j^2$.

Denotemos $\bar{\mu}_n = \frac{1}{n} \sum_{j=1}^n \mu_j = \mathbb{E}(\bar{X}_n)$.

Entonces, si $\lim_{n \rightarrow \infty} \frac{1}{n^2} \sum_{j=1}^n \sigma_j^2 = 0$, tenemos que

$$\bar{X}_n - \bar{\mu}_n \xrightarrow{p} 0 .$$

Aplicación en Estadística

Dada una muestra aleatoria $X_1, \dots, X_n$, tenemos que:

- Primer momento: por la L.G.N. fuerte si $E|X_i| < \infty$, tenemos en forma directa un estimador consistente para $\mu = E(X_i)$, ya que si tomamos $\hat{\mu} = \bar{X}_n$, tenemos que

$$\bar{X}_n \xrightarrow{c.s.} \mu$$

y por lo tanto,

$$\bar{X}_n \xrightarrow{P} \mu$$

- Segundo momento: también da un estimador consistente para, por ejemplo, $\theta = E(X_i^2) (= \mu_2) < \infty$, ya que como antes

$$\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} E(X_i^2) = \theta$$

Recordemos algunas propiedades útiles

Algunas transformaciones preservan la convergencia casi segura y en probabilidad.

Si g es una función continua en μ , entonces

- $X_n \xrightarrow{c.s.} \mu \Rightarrow g(X_n) \xrightarrow{c.s.} g(\mu)$

Además, si $X_n \xrightarrow{c.s.} X$ y $Y_n \xrightarrow{c.s.} Y$,

- $X_n \pm Y_n \xrightarrow{c.s.} X \pm Y$

- $X_n Y_n \xrightarrow{c.s.} XY$

- si además $\mathbb{P}(Y = 0) = 0$, $X_n/Y_n \xrightarrow{c.s.} X/Y$

Estos resultados también son válidos en probabilidad.

Estimación de $\sigma^2 = \text{Var}_F(X_i)$

- ¿Cómo estimamos σ^2 ?
- Un estimador posible es:

$$\hat{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

(se llega por el método de los momentos y por el de máxima verosimilitud)

Estimación de σ^2

- Por la L.G.N., $\bar{X}_n \xrightarrow{c.s.} \mu$ y $\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{c.s.} \mathbb{E}(X_1^2)$
- Como las funciones continuas preservan la convergencia c.s., $\bar{X}_n \xrightarrow{c.s.} \mathbb{E}(X_1)$, luego $\bar{X}_n^2 \xrightarrow{c.s.} \mathbb{E}^2(X_1)$ y en consecuencia

Estimación de σ^2

- Por la L.G.N., $\bar{X}_n \xrightarrow{c.s.} \mu$ y $\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{c.s.} \mathbb{E}(X_1^2)$
- Como las funciones continuas preservan la convergencia c.s., $\bar{X}_n \xrightarrow{c.s.} \mathbb{E}(X_1)$, luego $\bar{X}_n^2 \xrightarrow{c.s.} \mathbb{E}^2(X_1)$ y en consecuencia

$$\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \xrightarrow{c.s.} \mathbb{E}(X_1^2) - \mathbb{E}^2(X_1) = \text{Var}(X_1) = \sigma^2$$

Estimación de σ^2

- Por la L.G.N., $\bar{X}_n \xrightarrow{c.s.} \mu$ y $\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{c.s.} \mathbb{E}(X_1^2)$
- Como las funciones continuas preservan la convergencia c.s., $\bar{X}_n \xrightarrow{c.s.} \mathbb{E}(X_1)$, luego $\bar{X}_n^2 \xrightarrow{c.s.} \mathbb{E}^2(X_1)$ y en consecuencia

$$\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \xrightarrow{c.s.} \mathbb{E}(X_1^2) - \mathbb{E}^2(X_1) = \mathbb{V}ar(X_1) = \sigma^2$$

- Varianza Muestral: $S_n^2 = \frac{n}{n-1} \hat{\sigma}_n^2$.

Como la sucesión $\frac{n}{n-1} \rightarrow 1$, S_n^2 también resulta consistente.

Error cuadrático medio y consistencia

Theorem 2.40

Sea T_n un estimador de $q(\theta)$ basado en una muestra aleatoria de tamaño n . Si $ECM_\theta(T_n) \rightarrow 0$ cuando $n \rightarrow \infty$, entonces T_n es un estimador débilmente consistente de $q(\theta)$.

Proof.

Recordemos la **desigualdad de Markov**: Sea $h : \mathbb{R} \rightarrow \mathbb{R}^+$ tal que h es par y restringida a $\mathbb{R}^+$ es creciente y sea Y una v.a. tal que $\mathbb{E}(h(Y))$ existe. Entonces, para todo $\epsilon > 0$

$$\mathbb{P}(|Y| \geq \epsilon) \leq \frac{\mathbb{E}[h(Y)]}{h(\epsilon)}$$

Error cuadrático medio y consistencia

Theorem 2.40

Sea T_n un estimador de $q(\theta)$ basado en una muestra aleatoria de tamaño n . Si $ECM_\theta(T_n) \rightarrow 0$ cuando $n \rightarrow \infty$, entonces T_n es un estimador débilmente consistente de $q(\theta)$.

Proof.

Recordemos la **desigualdad de Markov**: Sea $h : \mathbb{R} \rightarrow \mathbb{R}^+$ tal que h es par y restringida a $\mathbb{R}^+$ es creciente y sea Y una v.a. tal que $\mathbb{E}(h(Y))$ existe. Entonces, para todo $\epsilon > 0$

$$\mathbb{P}(|Y| \geq \epsilon) \leq \frac{\mathbb{E}[h(Y)]}{h(\epsilon)}$$

Dado $\epsilon > 0$, por la desigualdad de Markov tenemos

$$0 \leq \mathbb{P}(|T_n - q(\theta)| \geq \epsilon) \leq \frac{1}{\epsilon^2} \mathbb{E}_\theta \left[(|T_n - q(\theta)|)^2 \right] = \frac{1}{\epsilon^2} ECM_\theta(T_n)$$



Corolario

Corollary 2.41

Sea $T_n = T_n(X_1, \dots, X_n)$ un estimador de $q(\theta)$ basado en una muestra aleatoria de tamaño n . Si cuando $n \rightarrow \infty$

- $\mathbb{E}_\theta(T_n) \rightarrow q(\theta),$
- $\text{Var}_\theta(T_n) \rightarrow 0$

entonces T_n es débilmente consistente para $q(\theta)$.

Ejemplo: Modelo de posición con errores normales

Ejemplo 2.42

Un investigador desea determinar cuanto vale cierta magnitud y para ello realiza n mediciones.

Supone que

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde $\epsilon_i \sim N(0, \sigma_0^2)$ independientes, con σ_0^2 conocida.

¿Cómo estimamos a θ ?

¿Cómo es la distribución de muestreo del estimador propuesto?

¿Cuál es su error estandar?

¿Y si σ_0^2 es desconocida?

Ejemplo: ¿y si los errores no son normales?

Supone que

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde $\mathbb{E}(\epsilon_i) = 0$ y $\text{Var}(\epsilon_i) = \sigma^2$ e independientes.

- $\hat{\theta}_n = \bar{X}_n$
- $\text{Var}(\hat{\theta}_n) = \sigma^2/n \Rightarrow se(\hat{\theta}_n) = \sqrt{\sigma^2/n}$
- $\frac{\bar{X}_n - \theta}{\sqrt{\sigma^2/n}} \sim ??$

Distribución Asintótica

Definition 2.43

Sea $T_n = T(\mathbf{X}_n) = T(X_1, \dots, X_n)$ un estimador de θ basado en la m.a. $X_1, \dots, X_n$.

Supongamos que para cierta sucesión numérica c_n tal que $c_n \rightarrow \infty$ y cierta variable aleatoria W , tenemos que cuando $n \rightarrow \infty$

$$c_n(T_n - \theta) \xrightarrow{\mathcal{D}} W,$$

entonces diremos que T_n **converge en distribución a W a tasa c_n** .

Distribución Asintótica

Definition 2.43

Sea $T_n = T(\mathbf{X}_n) = T(X_1, \dots, X_n)$ un estimador de θ basado en la m.a. $X_1, \dots, X_n$.

Supongamos que para cierta sucesión numérica c_n tal que $c_n \rightarrow \infty$ y cierta variable aleatoria W , tenemos que cuando $n \rightarrow \infty$

$$c_n(T_n - \theta) \xrightarrow{\mathcal{D}} W,$$

entonces diremos que T_n **converge en distribución a W a tasa c_n** .

Típicamente, tenemos que $c_n = \sqrt{n}$, ¿por qué?

Ejemplo: ¿y si los errores no son normales?

Supone que

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde $\mathbb{E}(\epsilon_i) = 0$ y $\text{Var}(\epsilon_i) = \sigma^2$ e independientes.

- $\hat{\theta}_n = \bar{X}_n$

Ejemplo: ¿y si los errores no son normales?

Supone que

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde $\mathbb{E}(\epsilon_i) = 0$ y $\text{Var}(\epsilon_i) = \sigma^2$ e independientes.

- $\hat{\theta}_n = \bar{X}_n$
- $\text{Var}(\hat{\theta}_n) = \sigma^2/n \Rightarrow \text{se}(\hat{\theta}_n) = \sqrt{\sigma^2/n}$

Ejemplo: ¿y si los errores no son normales?

Supone que

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde $\mathbb{E}(\epsilon_i) = 0$ y $\text{Var}(\epsilon_i) = \sigma^2$ e independientes.

- $\hat{\theta}_n = \bar{X}_n$
- $\text{Var}(\hat{\theta}_n) = \sigma^2/n \Rightarrow se(\hat{\theta}_n) = \sqrt{\sigma^2/n}$
- por el T.C.L. tenemos que $\frac{\bar{X}_n - \theta}{\sqrt{\sigma^2/n}} \xrightarrow{\mathcal{D}} N(0, 1)$

Ejemplo: ¿y si los errores no son normales?

Supone que

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde $\mathbb{E}(\epsilon_i) = 0$ y $\text{Var}(\epsilon_i) = \sigma^2$ e independientes.

- $\hat{\theta}_n = \bar{X}_n$
- $\text{Var}(\hat{\theta}_n) = \sigma^2/n \Rightarrow se(\hat{\theta}_n) = \sqrt{\sigma^2/n}$
- por el T.C.L. tenemos que $\frac{\bar{X}_n - \theta}{\sqrt{\sigma^2/n}} \xrightarrow{\mathcal{D}} N(0, 1)$
- ¿Qué pasa si estimamos el $se(\hat{\theta}_n)$? Por ejemplo, ¿si usamos $\hat{se}(\hat{\theta}_n) = \sqrt{S_n^2/n}$?

$$\frac{\bar{X}_n - \mu}{\sqrt{S_n^2/n}} \xrightarrow{\mathcal{D}} ?$$

¿Quién puede ayudarnos? Teorema de Slutsky

Theorem 2.44

Sean $\{X_n\}_{n \geq 1}$ e $\{Y_n\}_{n \geq 1}$ sucesiones de variables aleatorias, tales que $X_n \xrightarrow{\mathcal{D}} X$ e $Y_n \xrightarrow{P} c$, entonces

- $X_n + Y_n \xrightarrow{\mathcal{D}} X + c$
- $X_n - Y_n \xrightarrow{\mathcal{D}} X - c$
- $X_n \cdot Y_n \xrightarrow{\mathcal{D}} X \cdot c$
- Si $c \neq 0$, entonces $X_n/Y_n \xrightarrow{\mathcal{D}} X/c$

Proposición 2.45

Supongamos que $\widehat{se}(\hat{\theta}_n)$ es un estimador tal que $\frac{\widehat{se}(\hat{\theta}_n)}{se(\hat{\theta}_n)} \xrightarrow{P} 1$.

Luego, si

$$\frac{\hat{\theta}_n - \theta}{se(\hat{\theta}_n)} \xrightarrow{\mathcal{D}} N(0, 1) \Rightarrow \frac{\hat{\theta}_n - \theta}{\widehat{se}(\hat{\theta}_n)} \xrightarrow{\mathcal{D}} N(0, 1)$$

Proposición 2.45

Supongamos que $\widehat{se}(\hat{\theta}_n)$ es un estimador tal que $\frac{\widehat{se}(\hat{\theta}_n)}{se(\hat{\theta}_n)} \xrightarrow{P} 1$.

Luego, si

$$\frac{\hat{\theta}_n - \theta}{se(\hat{\theta}_n)} \xrightarrow{\mathcal{D}} N(0, 1) \Rightarrow \frac{\hat{\theta}_n - \theta}{\widehat{se}(\hat{\theta}_n)} \xrightarrow{\mathcal{D}} N(0, 1)$$

Proof.

$$\frac{\hat{\theta}_n - \theta}{\hat{se}(\hat{\theta}_n)} = \frac{se(\hat{\theta}_n)}{\hat{se}(\hat{\theta}_n)} \frac{\hat{\theta}_n - \theta}{se(\hat{\theta}_n)}$$

Proof.

$$\frac{\hat{\theta}_n - \theta}{\hat{se}(\hat{\theta}_n)} = \frac{se(\hat{\theta}_n)}{\hat{se}(\hat{\theta}_n)} \frac{\hat{\theta}_n - \theta}{se(\hat{\theta}_n)}$$

Como

$$\frac{se(\hat{\theta}_n)}{\hat{se}(\hat{\theta}_n)} \xrightarrow{P} 1 \text{ y } \frac{\hat{\theta}_n - \theta}{se(\hat{\theta}_n)} \xrightarrow{D} N(0, 1)$$

Proof.

$$\frac{\hat{\theta}_n - \theta}{\hat{se}(\hat{\theta}_n)} = \frac{se(\hat{\theta}_n)}{\hat{se}(\hat{\theta}_n)} \frac{\hat{\theta}_n - \theta}{se(\hat{\theta}_n)}$$

Como

$$\frac{se(\hat{\theta}_n)}{\hat{se}(\hat{\theta}_n)} \xrightarrow{P} 1 \text{ y } \frac{\hat{\theta}_n - \theta}{se(\hat{\theta}_n)} \xrightarrow{D} N(0, 1)$$

por Slutsky, se llega a lo que queríamos probar:

$$\frac{\hat{\theta}_n - \theta}{\hat{se}(\hat{\theta}_n)} = \frac{se(\hat{\theta}_n)}{\hat{se}(\hat{\theta}_n)} \frac{\hat{\theta}_n - \theta}{se(\hat{\theta}_n)} \xrightarrow{D} N(0, 1)$$



Consistencia de los Estimadores de Momentos

- Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución perteneciente a la familia $\mathcal{F} = \{F_\theta, \theta \in \Theta \subset \mathbb{R}\}$,
- $g(x)$ una función continua con valores en $\mathbb{R}$
- Supongamos que $M(\theta) = \mathbb{E}_\theta(g(X_1))$ es, como función de θ , continua y estrictamente monótona.

Consistencia de los Estimadores de Momentos

Proposición 2.46

Sea el estimador de momentos $\hat{\theta}_n$ definido como la solución de

$$\frac{1}{n} \sum_{i=1}^n g(X_i) = M(\hat{\theta}_n) \quad (1)$$

Supongamos que M es continua y estrictamente monótona y que g es continua. Luego con probabilidad 1 existe n_0 tal que para todo $n \geq n_0$ la ecuación (??) tiene una solución, $\hat{\theta}_n$, y $\hat{\theta}_n$ es fuertemente consistente para θ .

Proof.



Ejemplo 2.47

Sea $X_1, \dots, X_n$ i.i.d

1. Si $X_i \sim U(0, \theta)$ entonces el estimador de momentos de θ es consistente y hallar su distribución asintótica.
2. Si $X_i \sim \mathcal{E}(\theta)$ entonces el estimador de momentos de θ es consistente y hallar su distribución asintótica.

Método Delta

Theorem 2.48 (Método Delta)

Sea $\{Z_n\}_{n \geq 1}$, una sucesión de variables aleatorias tales que para una sucesión numérica $a_n \uparrow \infty$

$$a_n (Z_n - \theta) \xrightarrow{\mathcal{D}} Z .$$

Sea $q : \mathbb{R} \rightarrow \mathbb{R}$ una función de clase $\mathcal{C}^1$ tal que $q'(\theta) \neq 0$, entonces

$$a_n (q(Z_n) - q(\theta)) \xrightarrow{\mathcal{D}} q'(\theta)Z .$$

Método Delta

Proof.

Esto resulta de un desarrollo de Taylor. En efecto,

$$q(Z_n) = q(\theta) + q'(\theta_n^*) (Z_n - \theta) ,$$

donde θ_n^* es un punto intermedio entre Z_n y θ .

Veamos en primera instancia que entonces $\theta_n^* \xrightarrow{P} \theta$. En efecto,

$$|\theta_n^* - \theta| < |Z_n - \theta| = a_n |Z_n - \theta| \xrightarrow{P} 0$$

y por lo tanto, por la continuidad de q' , $|q'(\theta_n^*) - q'(\theta)| \xrightarrow{P} 0$. Luego, usando el Teorema de Slutsky tenemos

$$a_n (q(Z_n) - q(\theta)) = q'(\theta_n^*) a_n (Z_n - \theta) \xrightarrow{\mathcal{D}} q'(\theta) Z$$



Método Delta

Por ejemplo, si

$$\sqrt{n} (Z_n - \theta) \xrightarrow{\mathcal{D}} N(0, \sigma^2) .$$

y $q : \mathbb{R} \rightarrow \mathbb{R}$ una función de clase $\mathcal{C}^1$ tal que $q'(\theta) \neq 0$.

Entonces

$$\sqrt{n} (q(Z_n) - q(\theta)) \xrightarrow{\mathcal{D}} N \left(0, \sigma^2 [q'(\theta)]^2 \right)$$