

Ejemplo

El número de información de Fisher de un vector aleatorio

Definition 2.60

Sea una $\mathbf{X}$ un vector aleatorio con densidad o función de probabilidad puntual f . Llamamos número de información de Fisher de $\mathbf{X}$ a

$$I(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}, \theta) \right)^2 \right]$$

Ejemplo

El número de información de Fisher de un vector aleatorio

Definition 2.60

Sea una $\mathbf{X}$ un vector aleatorio con densidad o función de probabilidad puntual f . Llamamos número de información de Fisher de $\mathbf{X}$ a

$$I(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}, \theta) \right)^2 \right]$$

Observación 2.61

Las proposiciones ?? y ?? también valen para vectores aleatorios y las demostraciones son idénticas al caso univariado.

El número de información de Fisher de un vector aleatorio

Theorem 2.62

Sea $\mathbf{X}_1, \dots, \mathbf{X}_n$ una muestra aleatoria de una distribución con densidad $p(\mathbf{x}, \theta)$ con $\theta \in \Theta \subset \mathbb{R}$. Luego, si se denomina $I_n(\theta)$ al número de información de $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ e $I_1(\theta)$ al número de información de $\mathbf{X}_1$, entonces se tiene $I_n(\theta) = nI_1(\theta)$.

El número de información de Fisher de un vector aleatorio

Proof.

$$p(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n, \theta) = \prod_{i=1}^n p(\mathbf{x}_i, \theta) \Rightarrow$$

$$\ln p(\mathbf{x}_1, \dots, \mathbf{x}_n, \theta) = \sum_{i=1}^n \ln p(\mathbf{x}_i, \theta) \Rightarrow$$

$$\frac{\partial \ln p(\mathbf{x}_1, \dots, \mathbf{x}_n, \theta)}{\partial \theta} = \sum_{i=1}^n \frac{\partial \ln p(\mathbf{x}_i, \theta)}{\partial \theta}$$

Por ser $\mathbf{X}_1, \dots, \mathbf{X}_n$ independientes, se tiene

$$\begin{aligned} I_n(\theta) &= \text{Var}_{\theta} \left(\frac{\partial \ln p(\mathbf{X}_1, \dots, \mathbf{X}_n, \theta)}{\partial \theta} \right) = \sum_{i=1}^n \text{Var}_{\theta} \left(\frac{\partial \ln p(\mathbf{X}_i, \theta)}{\partial \theta} \right) \\ &= nI_1(\theta) \end{aligned}$$



Distribución Asintótica del EMV

Consideremos además la siguiente condición

R5. $f(x, \theta)$ es tres veces diferenciable respecto de θ . Además, existe una constante K tal que $\left| \frac{\partial^3}{\partial \theta^3} \log f(x, \theta) \right| \leq K$, para todo $\theta \in \Theta$ y todo $x \in S$.

Distribución asintótica del EMV

Theorem 2.63

Si

- *se cumplen R1 a R5*
- *$\hat{\theta}_n$ un estimador de máxima verosimilitud consistente de θ_0 , entonces, $\hat{\theta}_n$ es asintóticamente normal para estimar θ_0 , o sea,*

$$\sqrt{n} \left(\hat{\theta}_n - \theta_0 \right) \xrightarrow{\mathcal{D}} N \left(0, \frac{1}{I(\theta_0)} \right)$$

Bosquejo de la demo

Demostración.

Notamos: $\ell'(\theta) = \frac{\partial \ell_n(\theta, \mathbf{X}_n)}{\partial \theta}$ $\ell''(\theta) = \frac{\partial^2 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^2}$ $\ell'''(\theta) = \frac{\partial^3 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^3}$

Bosquejo de la demo

Demostración.

Notamos: $\ell'(\theta) = \frac{\partial \ell_n(\theta, \mathbf{X}_n)}{\partial \theta}$ $\ell''(\theta) = \frac{\partial^2 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^2}$ $\ell'''(\theta) = \frac{\partial^3 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^3}$

Desarrollo de Taylor:

$$0 = \ell'(\hat{\theta}_n) = \ell'(\theta_0) + (\hat{\theta}_n - \theta_0) \ell''(\theta_0) + \frac{1}{2} \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)^2$$

donde ξ_n es un punto intermedio entre $\hat{\theta}_n$ y θ_0

Bosquejo de la demo

Demostración.

Notamos: $\ell'(\theta) = \frac{\partial \ell_n(\theta, \mathbf{X}_n)}{\partial \theta}$ $\ell''(\theta) = \frac{\partial^2 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^2}$ $\ell'''(\theta) = \frac{\partial^3 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^3}$

Desarrollo de Taylor:

$$0 = \ell'(\hat{\theta}_n) = \ell'(\theta_0) + (\hat{\theta}_n - \theta_0) \ell''(\theta_0) + \frac{1}{2} \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)^2$$

donde ξ_n es un punto intermedio entre $\hat{\theta}_n$ y θ_0

$$(\hat{\theta}_n - \theta_0) = \frac{-\ell'(\theta_0)}{\ell''(\theta_0) + 1/2 \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)}$$

Bosquejo de la demo

Demostración.

Notamos: $\ell'(\theta) = \frac{\partial \ell_n(\theta, \mathbf{X}_n)}{\partial \theta}$ $\ell''(\theta) = \frac{\partial^2 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^2}$ $\ell'''(\theta) = \frac{\partial^3 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^3}$

Desarrollo de Taylor:

$$0 = \ell'(\hat{\theta}_n) = \ell'(\theta_0) + (\hat{\theta}_n - \theta_0) \ell''(\theta_0) + \frac{1}{2} \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)^2$$

donde ξ_n es un punto intermedio entre $\hat{\theta}_n$ y θ_0

$$(\hat{\theta}_n - \theta_0) = \frac{-\ell'(\theta_0)}{\ell''(\theta_0) + 1/2 \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)}$$

$$n^{1/2} (\hat{\theta}_n - \theta_0) = \frac{-n^{1/2} \ell'(\theta_0)}{n^{-1} \ell''(\theta_0) + 1/2 n^{-1} \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)}$$



Bosquejo de la demo

Continuación de la dem.

Primero, consideremos el numerador:

$$\left[n^{-1/2} \ell'(\theta_0) \right] = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{\partial \log f(X_i, \theta_0)}{\partial \theta}$$

Bosquejo de la demo

Continuación de la dem.

Primero, consideremos el numerador:

$$\left[n^{-1/2} \ell'(\theta_0) \right] = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{\partial \log f(X_i, \theta_0)}{\partial \theta}$$

Los sumandos son i.i.d. con

$$\mathbb{E}_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = 0$$

y

$$\text{Var}_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = \mathbb{E}_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right]^2 = I(\theta_0)$$



Bosquejo de la demo

Continuación de la dem.

Los sumandos son i.i.d. con

$$\mathbb{E}_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = 0$$

y

$$\mathbb{V}ar_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = I(\theta_0)$$

Luego, por el TCL,

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \xrightarrow{\mathcal{D}} N(0, I(\theta_0))$$



Bosquejo de la demo

Continuación de la dem.

Consideremos el denominador.

$$-\frac{1}{n}\ell''(\theta_0) = \frac{1}{n} \sum_{i=1}^n \frac{\partial^2 \log f(X_i, \theta_0)}{\partial \theta^2} \xrightarrow{P} I(\theta_0) \text{ por LGN}$$

Además, por R5 y la consistencia de $\hat{\theta}_n$,

$$\frac{1}{2n}\ell'''(\xi_n) (\hat{\theta}_n - \theta) \xrightarrow{P} 0$$

Entonces

$$-\frac{1}{n}\ell''(\theta_0) + \frac{1}{2n}\ell'''(\xi_n) (\hat{\theta}_n - \theta) \xrightarrow{P} I(\theta_0)$$

y por Slutsky $\sqrt{n} (\hat{\theta}_n - \theta_0) \xrightarrow{\mathcal{D}} N\left(0, \frac{1}{I(\theta_0)}\right)$



Distribución asintótica del EMV

Proposición 2.64

Supongamos que se cumplen R1 a R5 y que

- $\hat{\theta}_n$ un estimador de máxima verosimilitud consistente de θ_0
- $q(\theta)$ derivable con $q'(\theta) \neq 0$ para todo θ ,

entonces, $q(\hat{\theta}_n)$ es asintóticamente normal para estimar $q(\theta)$, o sea,

$$\sqrt{n} \left(q(\hat{\theta}_n) - q(\theta_0) \right) \xrightarrow{\mathcal{D}} N \left(0, \frac{[q'(\theta_0)]^2}{I(\theta_0)} \right)$$

Distribución asintótica del EMV

Proposición 2.64

Supongamos que se cumplen R1 a R5 y que

- $\hat{\theta}_n$ un estimador de máxima verosimilitud consistente de θ_0
- $q(\theta)$ derivable con $q'(\theta) \neq 0$ para todo θ ,

entonces, $q(\hat{\theta}_n)$ es asintóticamente normal para estimar $q(\theta)$, o sea,

$$\sqrt{n} \left(q(\hat{\theta}_n) - q(\theta_0) \right) \xrightarrow{\mathcal{D}} N \left(0, \frac{[q'(\theta_0)]^2}{I(\theta_0)} \right)$$

Definition 2.65

Decimos que una sucesión de estimadores T_n de $q(\theta)$ es **asintóticamente normal y eficiente (A.N.E.)** si

$$\sqrt{n} (T_n - q(\theta_0)) \xrightarrow{\mathcal{D}} N \left(0, \frac{[q'(\theta_0)]^2}{I(\theta_0)} \right)$$

Desventajas del EMV

1. Varianza mínima no necesariamente implica ECM mínimo.
Un ejemplo interesante es el EMV de σ^2 en el caso normal.
(Ver apunte de Boente y Yohai, página 40) .

Desventajas del EMV

1. Varianza mínima no necesariamente implica ECM mínimo. Un ejemplo interesante es el EMV de σ^2 en el caso normal. (Ver apunte de Boente y Yohai, página 40) .
2. Hay estimadores famosos que dan menor error cuadrático medio que el EMV en otros modelos. Algunos casos conocidos en alta dimensión: ridge, lasso.

Desventajas del EMV

1. Varianza mínima no necesariamente implica ECM mínimo. Un ejemplo interesante es el EMV de σ^2 en el caso normal. (Ver apunte de Boente y Yohai, página 40) .
2. Hay estimadores famosos que dan menor error cuadrático medio que el EMV en otros modelos. Algunos casos conocidos en alta dimensión: ridge, lasso.
3. Si hay una pequeña proporción de outliers, es decir, de observaciones que no siguen el modelo asumido, los resultados se ven muy alterados.

La mediana

Theorem 2.66

Sea $x_1, \dots, x_n$ una muestra aleatoria de una distribución F con una única mediana μ y con una densidad f tal que $f(\mu) > 0$. Entonces si $\tilde{\mu}_n$ es la mediana de la muestra, se tiene que

$$n^{1/2} (\tilde{\mu}_n - \mu) \xrightarrow{D} N \left(0, \frac{1}{4f^2(\mu)} \right)$$

Proof.

Ver Sección 7.1 del apunte de Boente y Yohai. (opcional)



La mediana

Theorem 2.66

Sea $x_1, \dots, x_n$ una muestra aleatoria de una distribución F con una única mediana μ y con una densidad f tal que $f(\mu) > 0$. Entonces si $\tilde{\mu}_n$ es la mediana de la muestra, se tiene que

$$n^{1/2} (\tilde{\mu}_n - \mu) \xrightarrow{D} N \left(0, \frac{1}{4f^2(\mu)} \right)$$

Proof.

Ver Sección 7.1 del apunte de Boente y Yohai. (opcional)



Observación 2.67

Del teorema anterior se deduce que $\tilde{\mu}_n \xrightarrow{p} \mu$. También puede probarse que $\tilde{\mu}_n \xrightarrow{\text{a.s.}} \mu$.

Ejemplo: media y mediana

Ejemplo 2.68

Si $X_1, \dots, X_n \dots N(\mu, \sigma^2)$, la media y la mediana son dos estimadores consistentes y asintóticamente normales de μ .

Ejemplo: media y mediana

Ejemplo 2.68

Si $X_1, \dots, X_n \dots N(\mu, \sigma^2)$, la media y la mediana son dos estimadores consistentes y asintóticamente normales de μ .

Ejemplo 2.69

Conocemos dos estimadores consistentes de σ^2 : El EMV y S^2 . Otro es

$$\widehat{\sigma^2} = \frac{n-1}{n+1} S^2$$

Comparemos el desempeño de estos estimadores a través de una simulación. ¿Qué pasa si hay datos atípicos?

Capítulo 3: Intervalos de confianza

Intervalos exactos

September 15, 2025

Ejemplo: duración de baterías

Ejemplo 3.1



Los siguientes datos corresponden a la duración en horas de 18 baterías eléctricas:

*237 242 232 242 248 230 244 243 254
262 234 220 225 246 232 218 228 240*

Queremos estimar la duración media.

Ejemplo: duración de baterías

Ejemplo 3.1 (continuación)



Ejemplo: duración de baterías

Ejemplo 3.1 (Continuación)

- *Modelo:* $X_i \sim \mathcal{N}(\mu, \sigma^2)$
- *Asumimos por ahora:* $\sigma = \sigma_o = 10$
- *Estimación con los datos:* $\bar{x}_n = 237.6111$
- *¿ μ vale 237.6111?*
- **Objetivo:** pasar de la **estimación puntual** a la **estimación por intervalo**.
- Daremos un **intervalo de valores compatibles con μ** .

Intervalos de confianza

Definition 3.2

Sea $\mathbf{X}_n = \{X_1, \dots, X_n\}$ una muestra aleatoria.

Diremos que $(a(\mathbf{X}_n), b(\mathbf{X}_n))$ es un intervalo de confianza de nivel $1 - \alpha$ para el parámetro θ sii

$$\mathbb{P}(a(\mathbf{X}_n) < \theta < b(\mathbf{X}_n)) = 1 - \alpha .$$

Caso normal con $\sigma^2 = \sigma_0^2$ conocida

Ejemplo 3.3

- $X_1, \dots, X_n \sim N(\mu, \sigma_0^2)$.
- *Buscamos intervalo de confianza para μ*
- *Pivote: función de la muestra y del parámetro de interés, cuya distribución es conocida.*

$$\frac{\bar{X}_n - \mu}{\sqrt{\sigma_0^2/n}} \sim N(0, 1)$$


- Sea z_β con $P(Z > z_\beta) = \beta$: (veamos el gráfico)

$$z_\beta = \phi^{-1}(1 - \beta) = \text{qnorm}(1 - \beta)$$

- *Luego, tenemos que*

$$\mathbb{P} \left(-z_{\alpha/2} < \frac{\bar{X}_n - \mu}{\sqrt{\sigma_0^2/n}} < z_{\alpha/2} \right) = 1 - \alpha$$

Area bajo la $N(0, 1)$



Caso normal con $\sigma^2 = \sigma_0^2$ conocida

Ejemplo 3.3 (Continuación)

Por lo tanto, tenemos que

$$\mathbb{P} \left(\bar{X}_n - z_{\alpha/2} \sqrt{\frac{\sigma_0^2}{n}} < \mu < \bar{X}_n + z_{\alpha/2} \sqrt{\frac{\sigma_0^2}{n}} \right) = 1 - \alpha$$

Así, obtenemos que

$$\left(\bar{X}_n - z_{\alpha/2} \sqrt{\frac{\sigma_0^2}{n}} , \quad \bar{X}_n + z_{\alpha/2} \sqrt{\frac{\sigma_0^2}{n}} \right)$$

es un intervalo de confianza de nivel $1 - \alpha$ para μ bajo el modelo normal cuando la varianza es σ_0^2 conocida.

Bajo Normalidad: σ^2 conocida

Ejemplo 3.3 (Continuación)

Intervalo de confianza de nivel $1 - \alpha$ para μ

$$\left(\bar{X}_n - z_{\alpha/2} \sqrt{\frac{\sigma_0^2}{n}} \quad , \quad \bar{X}_n + z_{\alpha/2} \sqrt{\frac{\sigma_0^2}{n}} \right)$$

Algunas preguntas

- ¿Qué longitud tiene el intervalo? $l =$
- ¿Qué ocurre con l a medida que n aumenta?
- ¿Qué ocurre con l cuando el nivel $1 - \alpha$ aumenta?
- ¿Qué ocurre con l cuando aumenta la varianza σ_0^2 ?

Ejemplo: Duración de baterías

Ejemplo 3.1 (Continuación)

Hallar un intervalo de confianza para la duración de las baterías suponiendo que dicha duración sigue una distribución normal con varianza $\sigma_0^2 = 100$

Regiones de confianza

Definition 3.4

Dado un vector $\mathbf{X}$ con distribución perteneciente a la familia $F(\mathbf{x}, \theta)$ con $\theta \in \Theta$, *una región de confianza $\mathcal{S}(\mathbf{X})$ para θ con nivel de confianza $1 - \alpha$* será una función que a cada $\mathbf{X}$ le asigne un subconjunto $\mathcal{S}(\mathbf{X}) \subset \Theta$ de manera que

$$\mathbb{P}_{\theta}(\theta \in \mathcal{S}(\mathbf{X})) = 1 - \alpha, \quad \forall \theta \in \Theta$$

Es decir, $\mathcal{S}(\mathbf{X})$ cubre el valor verdadero del parámetro con probabilidad $1 - \alpha$.

Caso particular: Si $\theta \in \mathbb{R}$ y $\mathcal{S}(\mathbf{X}) = [a(\mathbf{X}), b(\mathbf{X})]$ se llama intervalo de confianza.

Procedimiento general: Método del Pivote

Sea $\mathbf{X}$ un vector aleatorio cuya distribución pertenece a la familia $F(\mathbf{x}, \theta)$, $\theta \in \Theta$.

Una función $G(\mathbf{X}, \theta)$ se llama un **pivote** sii la distribución de $G(\mathbf{X}, \theta)$ no depende de θ .

Procedimiento general: Método del Pivote

Sea $\mathbf{X}$ un vector aleatorio cuya distribución pertenece a la familia $F(\mathbf{x}, \theta)$, $\theta \in \Theta$.

Una función $G(\mathbf{X}, \theta)$ se llama un **pivote** sii la distribución de $G(\mathbf{X}, \theta)$ no depende de θ .

Theorem 3.5

Sea $\mathbf{X}$ un vector aleatorio cuya distribución pertenece a la familia $F(\mathbf{x}, \theta)$, $\theta \in \Theta$. Sea

- $U = G(\mathbf{X}, \theta)$ una variable aleatoria cuya distribución es independiente de θ .*
- A y B tales que $\mathbb{P}(A \leq U \leq B) = 1 - \alpha$.*

Luego, si $\mathcal{S}(\mathbf{X}) = \{\theta : A \leq G(\mathbf{X}, \theta) \leq B\}$, $\mathcal{S}(\mathbf{X})$ es una región de confianza a nivel $(1 - \alpha)$ para θ .

¿Qué hacemos si σ es desconocida?

Si no conocemos la varianza σ^2 , deberemos reemplazar a σ^2 por un estimador....

Usemos $S_n^2 = \frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{n-1}$, pero...

$$\frac{\bar{X}_n - \mu}{\sqrt{S_n^2/n}} \sim ?$$

Distribución χ_k^2

Definition 3.6

Llamamos χ_k^2 (chi cuadrado con k -grados de libertad) a la distribución $\Gamma(\frac{k}{2}, \frac{1}{2})$

Proposición 3.7


Sean $Z_1, \dots, Z_k$ i.i.d., $Z_i \sim N(0, 1)$. Entonces

$$Z_1^2 + Z_2^2 + \dots + Z_k^2 \sim \chi_k^2 .$$

Proof.

Ver libro de Casella-Berger.



χ_k^2 

Distribución t

Definition 3.8

Una variable aleatoria tiene distribución t_k de Student con k grados de libertad si para todo $u \in \mathbb{R}$ su densidad es de la forma

$$f(u, k) = \frac{\Gamma\left(\frac{k+1}{2}\right)}{\sqrt{k\pi}\Gamma\left(\frac{k}{2}\right)} \left(1 + \frac{u^2}{k}\right)^{-\frac{k+1}{2}}$$

Distribución t

Definition 3.8

Una variable aleatoria tiene distribución t_k de Student con k grados de libertad si para todo $u \in \mathbb{R}$ su densidad es de la forma

$$f(u, k) = \frac{\Gamma\left(\frac{k+1}{2}\right)}{\sqrt{k\pi}\Gamma\left(\frac{k}{2}\right)} \left(1 + \frac{u^2}{k}\right)^{-\frac{k+1}{2}}$$


¿Cuándo aparece una t_k ?

$Z \sim N(0, 1)$ y $U \sim \chi_k^2$ independientes:


$$\frac{Z}{\sqrt{U/k}} \sim t_k$$

Demostración. Ver libro de Casella-Berger, pag 223.

Mirando percentiles...



Comparando con la normal...



Superteorema - parte 1

Superteorema - parte 1

Theorem 3.9

Sean $X_1, \dots, X_n$ variables aleatorias independientes donde $X_i \sim N(\mu, \sigma^2)$. Luego $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ es independiente de $\bar{X}_n$.

Superteorema - parte 1

Theorem 3.9

Sean $X_1, \dots, X_n$ variables aleatorias independientes donde $X_i \sim N(\mu, \sigma^2)$. Luego $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ es independiente de $\bar{X}_n$.

Lemma 3.10

Sea $Y_1, \dots, Y_n$ una muestra aleatoria de una distribución $N(\mu, \sigma^2)$, sea A una matriz ortogonal y $\mathbf{Z} = A\mathbf{Y}$, donde $\mathbf{Y} = (Y_1, \dots, Y_n)^\top$ y $\mathbf{Z} = (Z_1, \dots, Z_n)^\top$. Luego, las variables $Z_1, \dots, Z_n$ son también independientes con distribución $N(0, 1)$. Además $\|\mathbf{X}\| = \|\mathbf{Z}\|$.

Dem del teorema 3.9.



Superteorema - parte 2

Theorem 3.11

Sean $X_1, \dots, X_n$ variables aleatorias independientes donde $X_i \sim N(\mu, \sigma^2)$. Luego

a) $Z = \sqrt{n} \frac{\bar{X}_n - \mu}{\sigma} \sim N(0, 1)$

b) $\frac{(n-1)S_n^2}{\sigma^2} \sim \chi_{n-1}^2$.

c) $\sqrt{n} \frac{(\bar{X}_n - \mu)}{S_n} \sim t_{n-1}$.

Proof.

Pizarrón



Recordemos que:

- Si Z es una v.a. con distribución normal standard, $Z^2 \sim \Gamma(1/2, 1/2)$, o sea χ_1^2 .
- Si $U_1, \dots, U_k$ independientes., $U_i \sim \Gamma(\alpha_i, \lambda)$, entonces

$$U_1 + U_2 + \dots + U_k \sim \Gamma\left(\sum_{i=1}^k \alpha_i, \lambda\right)$$

- La suma de n v.a. independientes χ_1^2 tiene distribución χ_n^2 .
- Si $Z_1, \dots, Z_n$ i.i.d., $Z_i \sim \mathcal{N}(0, 1)$, entonces

$$Z_1^2 + Z_2^2 + \dots + Z_n^2 \sim \Gamma(n/2, 1/2) = \chi_n^2$$

Bajo Normalidad con σ^2 desconocida

Buscamos un intervalo de confianza para μ con σ^2 desconocida.

- Pivote:

$$\frac{\bar{X}_n - \mu}{\sqrt{S_n^2/n}} \sim t_{n-1}$$

- Sea $t_{k,\beta}$ tal que $\mathbb{P}(Y > t_{k,\beta}) = \beta$ cuando $Y \sim t_k$, entonces

$$\mathbb{P}\left(-t_{n-1,\alpha/2} < \frac{\bar{X}_n - \mu}{\sqrt{S_n^2/n}} < t_{n-1,\alpha/2}\right) = 1 - \alpha$$

Luego,

$$\left(\bar{X}_n - t_{n-1,\alpha/2}\sqrt{\frac{S_n^2}{n}}, \quad \bar{X}_n + t_{n-1,\alpha/2}\sqrt{\frac{S_n^2}{n}}\right)$$

es un intervalo de confianza de nivel $1 - \alpha$ para μ bajo el modelo normal, con varianza σ^2 desconocida.

Duración de Baterías

Ejemplo 3.12

En el ejemplo de las baterías, dar una estimación por intervalo de la duración media de las baterías, suponiendo σ desconocido.

```
#Intervalo de nivel 0.95
```

```
duracion<- c(237,242,232,242,248,230,244,262,234,220,225,246,232,218,228,240)
ene<- length(duracion)
mean(duracion)
[1] 237.6111
sd(duracion)
[1] 11.46934
t.alpha2<- qt(1-0.025, ene-1)
semi<- t.alpha2*sd(duracion)/sqrt(ene)
c(mean(duracion)- semi, mean(duracion)+ semi)
[1] 231.9075 243.3147
```

Intervalos de confianza para σ^2 con μ desconocido

Tenemos $X_1, \dots, X_n$ i.i.d., $X_i \sim N(\mu, \sigma^2)$. Ahora buscamos intervalo de confianza para σ^2 .

- Pivote: $\frac{(n-1)S_n^2}{\sigma^2} \sim \chi_{n-1}^2$
- Sea $\chi_{k,\beta}^2$ tal que $\mathbb{P}(U > \chi_{k,\beta}^2) = \beta$ cuando $U \sim \chi_k^2$, entonces

$$\mathbb{P}\left(\chi_{n-1,1-\alpha/2}^2 < \frac{(n-1)S_n^2}{\sigma^2} < \chi_{n-1,\alpha/2}^2\right) = 1 - \alpha$$

Luego,

$$\left(\frac{(n-1)S_n^2}{\chi_{n-1,\alpha/2}^2}, \quad \frac{(n-1)S_n^2}{\chi_{n-1,1-\alpha/2}^2} \right)$$

es un intervalo de confianza de nivel $1 - \alpha$ para σ^2 bajo el modelo normal cuando μ desconocida.

Intervalos de confianza para σ^2 con μ conocida

$$\mu = \mu_o$$

Buscamos intervalo de confianza para σ^2

- Pivote:

$$\frac{\sum_{i=1}^n (X_i - \mu_o)^2}{\sigma^2} \sim \chi_n^2$$

- Entonces:

$$\mathbb{P} \left(\chi_{n,1-\alpha/2}^2 < \frac{\sum_{i=1}^n (X_i - \mu_o)^2}{\sigma^2} < \chi_{n,\alpha/2}^2 \right) = 1 - \alpha$$

y por lo tanto,

$$\left(\frac{\sum_{i=1}^n (X_i - \mu_o)^2}{\chi_{n,\alpha/2}^2}, \frac{\sum_{i=1}^n (X_i - \mu_o)^2}{\chi_{n,1-\alpha/2}^2} \right)$$

es un intervalo de confianza de nivel $1 - \alpha$ para σ^2 bajo el modelo normal cuando $\mu = \mu_o$ conocida.