

Bootstrap

IECD

Introducción

El Bootstrap, introducido por Bradley Efron en 1979, refiere a la idea de aproximar la precisión de un estimador vía simulación. Es una técnica que ha tenido mucho impacto y le ha dado a Efron gran reconocimiento académico.

Hay distintas maneras de hacerlo: hay variantes del bootstrap, por eso es más una colección de métodos que una única técnica.

Motivación

Supongamos que tenemos $X_1, \dots, X_n$ v.a.i.i.d., con $X_i \sim F(\theta)$.
Luego, podemos tener un estimador $\hat{\theta}$ de θ .

Motivación

Supongamos que tenemos $X_1, \dots, X_n$ v.a.i.i.d., con $X_i \sim F(\theta)$.
Luego, podemos tener un estimador $\hat{\theta}$ de θ .

Nos gustaría saber cuál es el desvío estándar del estimador $\hat{\theta}$
(también llamado “error estándar”).

Motivación

Supongamos que tenemos $X_1, \dots, X_n$ v.a.i.i.d., con $X_i \sim F(\theta)$. Luego, podemos tener un estimador $\hat{\theta}$ de θ .

Nos gustaría saber cuál es el desvío estándar del estimador $\hat{\theta}$ (también llamado “error estándar”).

- ▶ En algunas situaciones sencillas, podemos calcular el error estándar directamente.

Motivación

Supongamos que tenemos $X_1, \dots, X_n$ v.a.i.i.d., con $X_i \sim F(\theta)$. Luego, podemos tener un estimador $\hat{\theta}$ de θ .

Nos gustaría saber cuál es el desvío estándar del estimador $\hat{\theta}$ (también llamado “error estándar”).

- ▶ En algunas situaciones sencillas, podemos calcular el error estándar directamente.
- ▶ En situaciones más complejas,
 - ▶ si el n es grande, podremos tener una aproximación (asintótica) del error estándar.

Motivación

Supongamos que tenemos $X_1, \dots, X_n$ v.a.i.i.d., con $X_i \sim F(\theta)$.
Luego, podemos tener un estimador $\hat{\theta}$ de θ .

Nos gustaría saber cuál es el desvío estándar del estimador $\hat{\theta}$
(también llamado “error estándar”).

- ▶ En algunas situaciones sencillas, podemos calcular el error estándar directamente.
- ▶ En situaciones más complejas,
 - ▶ si el n es grande, podremos tener una aproximación (asintótica) del error estándar.
 - ▶ vía *simulación*:

Supongamos que logramos generar nuevas muestras

$$X_1^*, \dots, X_n^* \quad i.i.d. \quad X_i^* \sim F(\theta)$$

Supongamos que logramos generar nuevas muestras

$$X_1^*, \dots, X_n^* \quad i.i.d. \quad X_i^* \sim F(\theta)$$

$$\longrightarrow \hat{\theta}^*$$

Supongamos que logramos generar nuevas muestras

$$X_1^*, \dots, X_n^* \quad i.i.d. \quad X_i^* \sim F(\theta)$$

$\longrightarrow \quad \hat{\theta}^*$

Si esto lo repetimos B veces, tendremos

$$\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$$

y, por lo tanto, calculándole el desvío estándar a estos estimadores, podríamos tener una aproximación del error estándar de $\hat{\theta}$.

Supongamos que logramos generar nuevas muestras

$$X_1^*, \dots, X_n^* \quad i.i.d. \quad X_i^* \sim F(\theta)$$

$\longrightarrow \quad \hat{\theta}^*$

Si esto lo repetimos B veces, tendremos

$$\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$$

y, por lo tanto, calculándole el desvío estándar a estos estimadores, podríamos tener una aproximación del error estándar de $\hat{\theta}$.

¿Pero cómo hacemos para tener esas muestras $X_1^*, \dots, X_n^*$ (también llamadas *muestras bootstrap*) si no conocemos $F(\theta)$?

Distribución empírica (o, simplemente, “empírica”)

X es una variable aleatoria con distribución acumulada

$F : \mathbb{R} \rightarrow [0; 1]$ definida por

$$F(x) = P(X \leq x)$$

Distribución empírica (o, simplemente, “empírica”)

X es una variable aleatoria con distribución acumulada
 $F : \mathbb{R} \rightarrow [0; 1]$ definida por

$$F(x) = P(X \leq x)$$

Dada una muestra aleatoria $X_1, \dots, X_n$ de la distribución F , su función de distribución empírica $\hat{F}_n$ se define como

$$\hat{F}_n(x) = \frac{\sum_{i=1}^n I(X_i \leq x)}{n}$$

- ▶ $\hat{F}_n(x)$ es una función aleatoria.
- ▶ Para cada realización $x_1, \dots, x_n$ de la muestra $\hat{F}_{n,obs}(x)$ es una f.d.a. que asigna probabilidad $1/n$ a cada x_i .

Para cada x fijo

- ▶ $\mathbb{E}(\hat{F}_n(x)) = F(x)$ (es un estimador insesgado de $F(x)$)

Para cada x fijo

- ▶ $\mathbb{E}(\hat{F}_n(x)) = F(x)$ (es un estimador insesgado de $F(x)$)
- ▶ $\mathbb{V}(\hat{F}_n(x)) =$

Para cada x fijo

- ▶ $\mathbb{E}(\hat{F}_n(x)) = F(x)$ (es un estimador insesgado de $F(x)$)
- ▶ $\mathbb{V}(\hat{F}_n(x)) = \frac{1}{n}F(x)(1 - F(x))$

Para cada x fijo

- ▶ $\mathbb{E}(\hat{F}_n(x)) = F(x)$ (es un estimador insesgado de $F(x)$)
- ▶ $\mathbb{V}(\hat{F}_n(x)) = \frac{1}{n}F(x)(1 - F(x))$
- ▶ $\hat{F}_n(x)$ un estimador consistente de $F(x)$

Para cada x fijo

- ▶ $\mathbb{E}(\hat{F}_n(x)) = F(x)$ (es un estimador insesgado de $F(x)$)
- ▶ $\mathbb{V}(\hat{F}_n(x)) = \frac{1}{n}F(x)(1 - F(x))$
- ▶ $\hat{F}_n(x)$ un estimador consistente de $F(x)$
- ▶ Distribución asintótica:

$$\sqrt{n}(\hat{F}_n(x) - F(x)) \xrightarrow{D} N(0, F(x)(1 - F(x)))$$

Para cada x fijo

- ▶ $\mathbb{E}(\hat{F}_n(x)) = F(x)$ (es un estimador insesgado de $F(x)$)
- ▶ $\mathbb{V}(\hat{F}_n(x)) = \frac{1}{n}F(x)(1 - F(x))$
- ▶ $\hat{F}_n(x)$ un estimador consistente de $F(x)$
- ▶ Distribución asintótica:

$$\sqrt{n}(\hat{F}_n(x) - F(x)) \xrightarrow{D} N(0, F(x)(1 - F(x)))$$

Teorema (Glivenko - Cantelli) Sea $X_1, \dots, X_n \sim F$. Entonces

$$\sup_x \left| \hat{F}_n(x) - F(x) \right| \xrightarrow{c.s.} 0$$

Funcionales estadísticos

Un funcional, en este caso, un funcional estadístico, es una aplicación que se calcula sobre el conjunto de las funciones de distribución acumuladas ($\mathcal{F}$):

$$T : \mathcal{F} \rightarrow \mathbb{R}$$

Ejemplos

- ▶ La esperanza: $T(F) = \mathbb{E}_F(X)$

Funcionales estadísticos

Un funcional, en este caso, un funcional estadístico, es una aplicación que se calcula sobre el conjunto de las funciones de distribución acumuladas ($\mathcal{F}$):

$$T : \mathcal{F} \rightarrow \mathbb{R}$$

Ejemplos

- ▶ La esperanza: $T(F) = \mathbb{E}_F(X)$
 - ▶ Si X es absolutamente continua, $F' = f$, y entonces $T(F) = \mathbb{E}_F(X) = \int t f(t) dt$.
 - ▶ Si X es discreta con f.p.p. p_X , entonces $T(F) = \mathbb{E}_F(X) = \sum_{k \in R_X} k \cdot p_X(k)$.

Funcionales estadísticos

Un funcional, en este caso, un funcional estadístico, es una aplicación que se calcula sobre el conjunto de las funciones de distribución acumuladas ($\mathcal{F}$):

$$T : \mathcal{F} \rightarrow \mathbb{R}$$

Ejemplos

- ▶ La esperanza: $T(F) = \mathbb{E}_F(X)$
 - ▶ Si X es absolutamente continua, $F' = f$, y entonces $T(F) = \mathbb{E}_F(X) = \int t f(t) dt$.
 - ▶ Si X es discreta con f.p.p. p_X , entonces $T(F) = \mathbb{E}_F(X) = \sum_{k \in R_X} k \cdot p_X(k)$.
- ▶ La varianza: $T(F) = \mathbb{V}_F(X)$

- La mediana: $T(F) = F^{-1}(1/2)$, con F^{-1} la inversa generalizada, definida como

$$F^{-1}(p) = \inf\{y : F(y) \geq p\}$$

- ▶ La mediana: $T(F) = F^{-1}(1/2)$, con F^{-1} la inversa generalizada, definida como

$$F^{-1}(p) = \inf\{y : F(y) \geq p\}$$

- ▶ El cuantil: $T(F) = F^{-1}(p)$

El estimador plug-in

Observación: Dado que $\hat{F}_n(t) \xrightarrow{c.s.} F(t)$ uniformemente, siempre que la aplicación T sea lo suficientemente “buena” (continua), tiene sentido pensar que

$$T(\hat{F}_n) \rightarrow T(F)$$

en algún sentido (por ejemplo, casi seguramente).

El estimador plug-in

Observación: Dado que $\hat{F}_n(t) \xrightarrow{c.s.} F(t)$ uniformemente, siempre que la aplicación T sea lo suficientemente “buena” (continua), tiene sentido pensar que

$$T(\hat{F}_n) \rightarrow T(F)$$

en algún sentido (por ejemplo, casi seguramente).

El **estimador plug-in** de $T = T(F)$ se define como

$$\hat{T} = T(\hat{F}_n)$$

Ejemplo: estimador plug-in de la esperanza

Sea $X_1, \dots, X_n \sim F$ y $T = T(F) = \mathbb{E}_F(X)$ entonces el estimador plug-in de T es

$$\hat{T} = \mathbb{E}_{\hat{F}_n}(X).$$

Veamos que

$$\mathbb{E}_{\hat{F}_n}(X) = \bar{X}$$

Sup. que tenemos $x_1, \dots, x_n$ observadas (como tener $\hat{F}_{n, \text{obs}}$).

Luego, $X \sim \hat{F}_{n, \text{obs}}$ significa que tiene una distribución que asigna prob. $\frac{1}{n}$ a cada $x_1, \dots, x_n$. Entonces,

$$\mathbb{E}_{\hat{F}_{n, \text{obs}}}(X) = \sum_{i=1}^n x_i \cdot \frac{1}{n} = \bar{x} \Rightarrow \mathbb{E}_{\hat{F}_n}(X) = \bar{X}$$

Estimador plug-in de los cuantiles

Supongamos que F es continua y estrictamente creciente, el p -ésimo cuantil se define como $T(F) = F^{-1}(p)$.

Su estimador plug-in es

$$\hat{T} = T(\hat{F}_n) = \hat{F}_n^{-1}(p)$$

Observación: $\hat{F}_n$ no es inversible (¡es escalonada!) y, por lo tanto, usaremos la inversa generalizada.

Luego, $\hat{F}_n^{-1}(p)$ se llama **p -ésimo cuantil muestral**.

Ejemplo: Tiempo de Vida de Lámparas

Se quiere estudiar el tiempo de vida de ciertas lámparas. Para ello se observa en 30 de ellas el tiempo de vida en días:

```
tiempos
```


```
##
```

```
## 3.5 4.5 3.1 4.2 2.4 2.8 3.0 3.8 2.5 2.7
```

```
## 2.8 2.6 3.4 2.5 3.6 2.6 3.1 4.0 2.3 3.5
```

```
## 4.1 2.9 2.6 2.0 3.0 2.5 2.9 3.1 2.3 2.8
```

```
boxplot(tiempos)
```



Nos interesa la mediana poblacional: m

¿Cuál es el tiempo de vida mediano de las lámparas?

Podríamos estimarlo

- ▶ a) asumiendo una distribución,
- ▶ b) mediante la mediana muestral.

Nos interesa la mediana poblacional: m

¿Cuál es el tiempo de vida mediano de las lámparas?

Podríamos estimarlo

- ▶ a) asumiendo una distribución,
- ▶ b) mediante la mediana muestral.

Caso a): si la distribución fuera $\mathcal{E}(\lambda)$

Entonces $F(m) = 0.5$

Nos interesa la mediana poblacional: m

¿Cuál es el tiempo de vida mediano de las lámparas?

Podríamos estimarlo

- ▶ a) asumiendo una distribución,
- ▶ b) mediante la mediana muestral.

Caso a): si la distribución fuera $\mathcal{E}(\lambda)$

Entonces $F(m) = 0.5 \Rightarrow 1 - \exp(-\lambda m) = 0.5$ entonces
 $m = -\log(0.5)/\lambda$.

Nos interesa la mediana poblacional: m

¿Cuál es el tiempo de vida mediano de las lámparas?

Podríamos estimarlo

- ▶ a) asumiendo una distribución,
- ▶ b) mediante la mediana muestral.

Caso a): si la distribución fuera $\mathcal{E}(\lambda)$

Entonces $F(m) = 0.5 \Rightarrow 1 - \exp(-\lambda m) = 0.5$ entonces
 $m = -\log(0.5)/\lambda$.

Luego, un estimador de m se consigue con un estimador de λ , por ejemplo, el EMV.

Caso b): utilizando la mediana muestral

Pero, en este caso, ¿cuán preciso es el estimador? ¿Cómo estimamos su error estándar? ¿Cómo calculamos un intervalo de confianza para la mediana?

Caso b): utilizando la mediana muestral

Pero, en este caso, ¿cuán preciso es el estimador? ¿Cómo estimamos su error estándar? ¿Cómo calculamos un intervalo de confianza para la mediana?

En general, para responder estas preguntas tenemos distintas posibilidades:

1 - Conocemos algo de F pero $\hat{T}_n$ es una función complicada de $X_1, \dots, X_n$ y es difícil hallar su distribución o su desvío estándar.

Caso b): utilizando la mediana muestral

Pero, en este caso, ¿cuán preciso es el estimador? ¿Cómo estimamos su error estándar? ¿Cómo calculamos un intervalo de confianza para la mediana?

En general, para responder estas preguntas tenemos distintas posibilidades:

- 1 - Conocemos algo de F pero $\hat{T}_n$ es una función complicada de $X_1, \dots, X_n$ y es difícil hallar su distribución o su desvío estándar.
- 2 - No conocemos nada de F .

Pensemos en la mediana poblacional

- a) Estimar la mediana poblacional asumiendo un modelo paramétrico.
- b) Estimar la mediana poblacional sin asumir ningún modelo.
- ▶ ¿Cómo estimamos el error estándar de un estimador?

Pensemos en la mediana poblacional

- a) Estimar la mediana poblacional asumiendo un modelo paramétrico.
- b) Estimar la mediana poblacional sin asumir ningún modelo.
 - ▶ ¿Cómo estimamos el error estándar de un estimador?

Usando **BOOTSTRAP**.

Podemos hacer bootstrap de distintas maneras.

Escenario simulación: generamos tantos datos con distribución F como queremos

- ▶ Nos interesa $T = T(F)$, estimamos con $\hat{T}_n$ a partir de una muestra de tamaño n .
- ▶ ¿Cómo hallamos la distribución de $\hat{T}_n$?

Escenario simulación: generamos tantos datos con distribución F como queremos

- ▶ Nos interesa $T = T(F)$, estimamos con $\hat{T}_n$ a partir de una muestra de tamaño n .
- ▶ ¿Cómo hallamos la distribución de $\hat{T}_n$?

1 - Generamos muchos (digamos $B = 1000$) conjuntos de datos de tamaño muestral n . Para cada conjunto de datos calculamos el valor de $\hat{T}_n^*$.

Escenario simulación: generamos tantos datos con distribución F como queremos

- ▶ Nos interesa $T = T(F)$, estimamos con $\hat{T}_n$ a partir de una muestra de tamaño n .
- ▶ ¿Cómo hallamos la distribución de $\hat{T}_n$?

1 - Generamos muchos (digamos $B = 1000$) conjuntos de datos de tamaño muestral n . Para cada conjunto de datos calculamos el valor de $\hat{T}_n^*$.

2 - La distribución empírica de los valores resultantes:

$$\hat{T}_{n,1}^*, \hat{T}_{n,2}^*, \dots, \hat{T}_{n,B}^*$$

es una aproximación a la distribución de $\hat{T}_n$.

Escenario simulación: generamos tantos datos con distribución F como queremos

- ▶ Nos interesa $T = T(F)$, estimamos con $\hat{T}_n$ a partir de una muestra de tamaño n .
- ▶ ¿Cómo hallamos la distribución de $\hat{T}_n$?

1 - Generamos muchos (digamos $B = 1000$) conjuntos de datos de tamaño muestral n . Para cada conjunto de datos calculamos el valor de $\hat{T}_n^*$.

2 - La distribución empírica de los valores resultantes:

$$\hat{T}_{n,1}^*, \hat{T}_{n,2}^*, \dots, \hat{T}_{n,B}^*$$

es una aproximación a la distribución de $\hat{T}_n$.

A partir de estos datos podemos o bien obtener un estimador del error estándar de $\hat{T}_n$ o hallar un intervalo de confianza (de nivel asintótico) para $T(F)$.

Escenario real: sólo tenemos $X_1, \dots, X_n$ con distribución F desconocida

Alternativa 1: $F = F(\theta)$ *Bootstrap paramétrico*

- Tenemos una muestra: $X_1, \dots, X_n$, $X_i \sim F(\theta)$, podemos utilizar el **método bootstrap paramétrico**

Escenario real: sólo tenemos $X_1, \dots, X_n$ con distribución F desconocida

Alternativa 1: $F = F(\theta)$ *Bootstrap paramétrico*

- Tenemos una muestra: $X_1, \dots, X_n$, $X_i \sim F(\theta)$, podemos utilizar el **método bootstrap paramétrico**

Bootstrap paramétrico

1 - Estimar el parámetro $\hat{\theta}_n$ y luego $\hat{T}_n$ usando la muestra.

Escenario real: sólo tenemos $X_1, \dots, X_n$ con distribución F desconocida *parcialmente*

Alternativa 1: $F = F(\theta)$ *Bootstrap paramétrico*

- Tenemos una muestra: $X_1, \dots, X_n$, $X_i \sim F(\theta)$, podemos utilizar el **método bootstrap paramétrico** *quiero estimar $T(F)$*

Bootstrap paramétrico

- 1 - Estimar el parámetro $\hat{\theta}_n$ y luego $\hat{T}_n$ usando la muestra.
- 2 - Generar B remuestras de tamaño n de $F(\hat{\theta}_n)$. Para cada una de ellas calcular el estimador de interés: $\hat{T}_n^*$.

Escenario real: sólo tenemos $X_1, \dots, X_n$ con distribución F desconocida

Alternativa 1: $F = F(\theta)$ *Bootstrap paramétrico*

- Tenemos una muestra: $X_1, \dots, X_n$, $X_i \sim F(\theta)$, podemos utilizar el **método bootstrap paramétrico**

Bootstrap paramétrico

- 1 - Estimar el parámetro $\hat{\theta}_n$ y luego $\hat{T}_n$ usando la muestra.
- 2 - Generar B remuestras de tamaño n de $F(\hat{\theta}_n)$. Para cada una de ellas calcular el estimador de interés: $\hat{T}_n^*$.
- 3 - La distribución empírica de los valores resultantes: $\hat{T}_{n,1}^*, \hat{T}_{n,2}^*, \dots, \hat{T}_{n,B}^*$ es una aproximación a la distribución de $\hat{T}_n$.

En nuestro ejemplo: lámparas

- ▶ Nos interesa la mediana poblacional
- ▶ Tenemos una muestra: $X_1, \dots, X_n$
- ▶ Asumimos un modelo paramétrico: $X_i \sim \Gamma(\alpha, \lambda)$.

En nuestro ejemplo: lámparas

- ▶ Nos interesa la mediana poblacional
- ▶ Tenemos una muestra: $X_1, \dots, X_n$
- ▶ Asumimos un modelo paramétrico: $X_i \sim \Gamma(\alpha, \lambda)$.

Bootstrap paramétrico

1 - Estimar los parámetros usando la muestra $\rightarrow \hat{\alpha}_n$ y $\hat{\lambda}_n \Rightarrow \hat{T}_n$

En nuestro ejemplo: lámparas

- ▶ Nos interesa la mediana poblacional
- ▶ Tenemos una muestra: $X_1, \dots, X_n$
- ▶ Asumimos un modelo paramétrico: $X_i \sim \Gamma(\alpha, \lambda)$.

Bootstrap paramétrico

1 - Estimar los parámetros usando la muestra $\rightarrow \hat{\alpha}_n$ y $\hat{\lambda}_n$.

2 - Generar B remuestras de tamaño n de $F(\hat{\alpha}_n, \hat{\lambda}_n)$:

$\mathbf{X}^* = X_1^*, \dots, X_n^*$. Para cada una de ellas, estimar la mediana con el mismo método que hayamos usado para $\hat{T}_n$

En nuestro ejemplo: lámparas

- ▶ Nos interesa la mediana poblacional
- ▶ Tenemos una muestra: $X_1, \dots, X_n$
- ▶ Asumimos un modelo paramétrico: $X_i \sim \Gamma(\alpha, \lambda)$.

Bootstrap paramétrico

1 - Estimar los parámetros usando la muestra $\rightarrow \hat{\alpha}_n$ y $\hat{\lambda}_n$.

2 - Generar B remuestras de tamaño n de $F(\hat{\alpha}_n, \hat{\lambda}_n)$:

$\mathbf{X}^* = X_1^*, \dots, X_n^*$. Para cada una de ellas, estimar la mediana con el mismo método que hayamos usado para $\hat{T}_n \rightarrow$ tenemos B valores $\hat{T}_n^*$.

En nuestro ejemplo: lámparas

- ▶ Nos interesa la mediana poblacional
- ▶ Tenemos una muestra: $X_1, \dots, X_n$
- ▶ Asumimos un modelo paramétrico: $X_i \sim \Gamma(\alpha, \lambda)$.

Bootstrap paramétrico

1 - Estimar los parámetros usando la muestra $\rightarrow \hat{\alpha}_n$ y $\hat{\lambda}_n$.

2 - Generar B remuestras de tamaño n de $F(\hat{\alpha}_n, \hat{\lambda}_n)$:

$\mathbf{X}^* = X_1^*, \dots, X_n^*$. Para cada una de ellas, estimar la mediana con el mismo método que hayamos usado para $\hat{T}_n \rightarrow$ tenemos B valores $\hat{T}_n^*$.

3 - La distribución empírica de los valores resultantes:

$\hat{T}_{n,1}^*, \hat{T}_{n,2}^*, \dots, \hat{T}_{n,B}^*$ es una aproximación a la distribución de $\hat{T}_n$.

Y desde acá podemos obtener lo que querramos.

Ejemplo de las lámparas: bootstrap paramétrico

Supongamos que $X_i \sim \Gamma(\alpha, \lambda)$.

```
library(MASS)
B <- 1000; estmed <- 0
est.param <- fitdistr(tiempos, densfun = "gamma")$estimate
est.param

##      shape      rate
## 25.661823  8.450657
#### mediana
qgamma(0.5, shape = est.param[1], rate = est.param[2])

## [1] 2.997314
n<- length(tiempos)
for(i in 1:B){
  xboot <- rgamma(n, shape = est.param[1], rate = est.param[2])
  estboot <- fitdistr(xboot, densfun = "gamma")
  estshape <- estboot$estimate[1]
  estrate <- estboot$estimate[2]
  estmed[i] <- qgamma(0.5, shape = estshape,
                    rate = estrate)
}
head(estmed)

## [1] 2.998185 2.990779 3.068146 3.096810 2.936587 2.941222
```

Podríamos aproximar el desvío estándar calculando:

$$\hat{se}_{boot} = \sqrt{\frac{1}{B} \sum_{b=1}^B \left(\hat{T}_{n,b}^* - \frac{1}{B} \sum_{r=1}^B \hat{T}_{n,r}^* \right)^2}$$

```
se_boot <- sqrt(mean( (estmed - mean(estmed))^2 ))  
se_boot
```

```
## [1] 0.1082603
```

F caso general

Alternativa 2: Bootstrap uniforme o no paramétrico

- ▶ Supongamos que tenemos un conjunto de datos $x_1, \dots, x_n$.
Suponemos que los datos son una realización de una muestra $\mathbf{X} = X_1, \dots, X_n$.
- ▶ Sabiendo que la empírica $\hat{F}_n$ es un estimador consistente de la distribución F , la solución bootstrap es generar muestras con distribución $\hat{F}_n$.

F caso general

Alternativa 2: Bootstrap uniforme o no paramétrico

- ▶ Supongamos que tenemos un conjunto de datos $x_1, \dots, x_n$.
Suponemos que los datos son una realización de una muestra $\mathbf{X} = X_1, \dots, X_n$.
- ▶ Sabiendo que la empírica $\hat{F}_n$ es un estimador consistente de la distribución F , la solución bootstrap es generar muestras con distribución $\hat{F}_n$.

¿Pero qué sería tomar una muestra con distribución $\hat{F}_n$?

Recordemos que la función de distribución empírica $\hat{F}_n$ asigna probabilidad $1/n$ a cada observación X_i .

F caso general

Alternativa 2: Bootstrap uniforme o no paramétrico

- ▶ Supongamos que tenemos un conjunto de datos $x_1, \dots, x_n$.
Suponemos que los datos son una realización de una muestra $\mathbf{X} = X_1, \dots, X_n$.
- ▶ Sabiendo que la empírica $\hat{F}_n$ es un estimador consistente de la distribución F , la solución bootstrap es generar muestras con distribución $\hat{F}_n$.

¿Pero qué sería tomar una muestra con distribución $\hat{F}_n$?

Recordemos que la función de distribución empírica $\hat{F}_n$ asigna probabilidad $1/n$ a cada observación X_i .

Luego, una muestra aleatoria de tamaño n de la distribución $\hat{F}_n$ es una muestra de tamaño n tomada **con reposición** de $X_1, \dots, X_n$

F caso general

Alternativa 2: Bootstrap uniforme o no paramétrico

- ▶ Supongamos que tenemos un conjunto de datos $x_1, \dots, x_n$.
Suponemos que los datos son una realización de una muestra $\mathbf{X} = X_1, \dots, X_n$.
- ▶ Sabiendo que la empírica $\hat{F}_n$ es un estimador consistente de la distribución F , la solución bootstrap es generar muestras con distribución $\hat{F}_n$.

¿Pero qué sería tomar una muestra con distribución $\hat{F}_n$?

Recordemos que la función de distribución empírica $\hat{F}_n$ asigna probabilidad $1/n$ a cada observación X_i .

Luego, una muestra aleatoria de tamaño n de la distribución $\hat{F}_n$ es una muestra de tamaño n tomada **con reposición** de $X_1, \dots, X_n$

→ *Muestra bootstrap*

$$\mathbf{X}^* = X_1^*, \dots, X_n^*$$

F caso general

Alternativa 2: Bootstrap uniforme o no paramétrico

- ▶ Supongamos que tenemos un conjunto de datos $x_1, \dots, x_n$.
Suponemos que los datos son una realización de una muestra $\mathbf{X} = X_1, \dots, X_n$.
- ▶ Sabiendo que la empírica $\hat{F}_n$ es un estimador consistente de la distribución F , la solución bootstrap es generar muestras con distribución $\hat{F}_n$.

¿Pero qué sería tomar una muestra con distribución $\hat{F}_n$?

Recordemos que la función de distribución empírica $\hat{F}_n$ asigna probabilidad $1/n$ a cada observación X_i .

Luego, una muestra aleatoria de tamaño n de la distribución $\hat{F}_n$ es una muestra de tamaño n tomada **con reposición** de $X_1, \dots, X_n$

→ *Muestra bootstrap*

$$\mathbf{X}^* = X_1^*, \dots, X_n^*$$

Para cada muestra bootstrap hay una replicación bootstrap de $\hat{T}_n$: $\hat{T}_n^*$ (estadístico bootstrap) y podemos calcular lo que necesitemos.

Ejemplo de las lámparas: bootstrap no paramétrico

```
median(tiempos)
```

```
## [1] 2.9
```

```
B <- 1000
```

```
n <- length(tiempos)
```

```
estmed <- 0
```

```
for(i in 1:B){
```

```
  xboot <- sample(tiempos, n, replace = TRUE)
```

```
  estmed[i] <- median(xboot)
```

```
}
```

```
head(estmed)
```

```
## [1] 2.95 2.80 2.80 3.00 3.00 2.80
```

```
se_boot <- sqrt(mean( (estmed - mean(estmed))^2 ))
```


```
se_boot
```

```
## [1] 0.1232211
```

Aproximación de la distribución de $\hat{T}_n$

A continuación, tenemos un estimador de la densidad de $\hat{T}_n$ obtenida con los datos $\hat{T}_{n,1}^*, \dots, \hat{T}_{n,B}^*$.

```
plot(density(estmed, bw=0.5))
```



El algoritmo bootstrap

Este algoritmo permite estimar el error estándar de un estimador $\hat{T}_n = \delta(X_1, \dots, X_n)$.

1 - Generar $X_1^*, \dots, X_n^*$ a partir de $\hat{F}_n$ (de la forma que se desee: paramétrica o no paramétricamente).

2 - Calcular $\hat{T}_n^* = \delta(X_1^*, \dots, X_n^*)$.

3 - Repetir los pasos 1 y 2, B veces, para obtener $\hat{T}_{n,1}^*, \dots, \hat{T}_{n,B}^*$.

4 - Calcular

$$\widehat{\text{se}}_{\text{boot}} = \sqrt{\frac{1}{B} \sum_{b=1}^B \left(\hat{T}_{n,b}^* - \frac{1}{B} \sum_{r=1}^B \hat{T}_{n,r}^* \right)^2}$$

Si bien el Bootstrap nos da un camino para estimar el desvío estándar de un estimador, también nos permite calcular *intervalos de confianza* de nivel asintótico $1 - \alpha$ (para el parámetro θ que, en nuestra notación, es $T = T(F)$).

Método 1. Intervalo bootstrap normal

- ▶ $\hat{T}_n$ asintóticamente normal si

$$\frac{\hat{T}_n - T(F)}{\text{se}(\hat{T}_n)} \xrightarrow{D} N(0, 1)$$

- ▶ Sea $\hat{\text{se}}_{\text{boot}}$ el estimador bootstrap de $\text{se}(\hat{T}_n)$, luego

intervalo bootstrap normal nivel aproximado $1 - \alpha$:

$$\hat{T}_n \pm z_{\alpha/2} \hat{\text{se}}_{\text{boot}}$$

Método 1. Intervalo bootstrap normal

- ▶ $\hat{T}_n$ asintóticamente normal si

$$\frac{\hat{T}_n - T(F)}{\text{se}(\hat{T}_n)} \xrightarrow{D} N(0, 1)$$

- ▶ Sea $\hat{\text{se}}_{\text{boot}}$ el estimador bootstrap de $\text{se}(\hat{T}_n)$, luego

intervalo bootstrap normal nivel aproximado $1 - \alpha$:

$$\hat{T}_n \pm z_{\alpha/2} \hat{\text{se}}_{\text{boot}}$$

Por ejemplo, bajo condiciones de regularidad, los cuantiles tienen distribución aproximadamente normal, en particular, si

$\hat{M}_n = \text{med}_{1 \leq i \leq n}(X_i)$, se tiene que

$$\sqrt{n} \left(\hat{M}_n - m \right) \xrightarrow{D} N \left(0, \frac{1}{4f^2(m)} \right)$$

y tanto m como, en general, f son desconocidas, por lo que usar el intervalo de confianza bootstrap pareciera ser una buena estrategia.

Ejemplo

Objetivo: Estimar el ingreso familiar mediano en Argentina en 2019 mediante un intervalo de confianza.

```
median(ingresos)
```

```
## [1] 33000
```

Estimación bootstrap del error estándar de la mediana

```
estimar_se_mediana <- function(x, B = 1000){  
  titahatboot <- rep(0, B)  
  for(i in 1:B){  
    Xboot <- sample(x, length(x), replace = TRUE)  
    titahatboot[i] <- median(Xboot)  
  }  
  salida <- list(  
    se= sqrt(mean((titahatboot-mean(titahatboot))^2)),  
    boot=titahatboot)  
  return(salida)  
}
```

IC para la mediana por bootstrap uniforme

Intervalo bootstrap normal de nivel aproximado 0.95

```
x <- ingresos
set.seed(12345)
ingresos.boot <- estimar_se_mediana(x)
se_boot <- ingresos.boot$se
se_boot

## [1] 129.6055

intervalo_boot <- c(median(x) - 1.96*se_boot,
                    median(x) + 1.96*se_boot)
intervalo_boot

## [1] 32745.97 33254.03
```

Método 2: Intervalo bootstrap percentil

- ▶ B : número de iteraciones bootstrap
- ▶ Sean $\hat{T}_{n,1}^*, \dots, \hat{T}_{n,B}^*$ estadísticos bootstrap del estimador.

intervalo bootstrap percentil $1 - \alpha$: $\left(\hat{T}_{\alpha/2}^*, \hat{T}_{1-\alpha/2}^* \right)$

donde $\hat{T}_{\beta}^*$ es el β -cuantil muestral de los estadísticos bootstrap.

¿Cómo quedaría el intervalo bootstrap percentil de nivel 0.95 para el ingreso?

```
lim.inf <- quantile(ingresos.boot$boot, 0.025)
lim.sup <- quantile(ingresos.boot$boot, 0.975)

intervalo_boot_percentil <- c(lim.inf, lim.sup)
intervalo_boot_percentil

## 2.5% 97.5%
## 33000 33400
```

Ejemplo a modo de cierre: DasGupta (2008).

- ▶ $X_1, \dots, X_n$ i.i.d. Cauchy con mediana μ .
- ▶ El promedio muestral $\bar{X}_n$ es un mal estimador de μ (¿por qué?), por eso usamos la mediana muestral $\tilde{X}_n$.
- ▶ Para n impar, digamos $n = 2k + 1$, existe una fórmula exacta :

$$\mathbb{V}(\tilde{X}_n) = \frac{2n!}{(k!)^2 \pi^n} \int_0^{\pi/2} x^k (\pi - x)^k (\cot x)^2 dx.$$

- ▶ Mediante una aproximación asintótica obtenemos que

$$\widehat{\mathbb{V}(\tilde{X}_n)} = \pi^2/4n$$

Ejemplo a modo de cierre: DasGupta (2008).

Consideremos $n = 21$. Luego,

$$\mathbb{V}(\tilde{X}_n) = 0.1367$$

Ejemplo a modo de cierre: DasGupta (2008).

Consideremos $n = 21$. Luego,

$$\mathbb{V}(\tilde{X}_n) = 0.1367$$

Sin embargo, la aproximación asintótica (aunque el n no es muy grande) da

$$\widehat{\mathbb{V}(\tilde{X}_n)} = 0.1175$$

Ejemplo a modo de cierre: DasGupta (2008).

Consideremos $n = 21$. Luego,

$$\mathbb{V}(\tilde{X}_n) = 0.1367$$

Sin embargo, la aproximación asintótica (aunque el n no es muy grande) da

$$\widehat{\mathbb{V}(\tilde{X}_n)} = 0.1175$$

► ¿Qué nos daría una aproximación bootstrap?

Un estimador bootstrap de $\mathbb{V}(\tilde{X}_n)$ usando $B = 5000$ es

$$\widehat{\mathbb{V}(\tilde{X}_n)}_{\text{boot}} = 0.1356251$$

En definitiva, podemos obtener una buena aproximación con muy poco esfuerzo.

```
set.seed(345)
```

```
x21 <- rcauchy(21)
```

```
median(x21)
```

```
## [1] 0.28433
```

```
estimar_se_mediana <- function(x, B = 1000){  
  titahatboot <- rep(NA,B)  
  for(i in 1:B){  
    Xboot <- sample(x, length(x), replace = TRUE)  
    titahatboot[i] <- median(Xboot)  
  }  
  sqrt(mean((titahatboot-mean(titahatboot))^2))  
}
```

```
se.est<-estimar_se_mediana(x21, B = 5000)
```

```
se.est*se.est
```

```
## [1] 0.1356251
```

Ejercicio (tarea):

Sea T una v.a. con distribución $\mathcal{E}(\lambda)$. A partir de un ejercicio de simulación se busca estudiar a los estimadores de la media y la mediana, usando Bootstrap.

- a) Generar una muestra de tamaño $n = 500$ de una v.a. con distribución $\mathcal{E}(1)$, que llamaremos *muestra original*. Recordar setear la semilla. Esta será la muestra en la que se basará todo el ejercicio.
- b) Hallar una estimación de la media y de la mediana de T basada en la muestra original.
- c) Para entender el comportamiento de los estimadores, a partir de la muestra generada en el primer ítem, generar 1000 muestras bootstrap del mismo tamaño ($n = 500$), tomando subconjuntos *con reposición* de la muestra original. Para cada una de las 1000 muestras bootstrap, calcular el promedio y la mediana y guardar los resultados en dos vectores (uno que contendrá los 1000 promedios y otro con las 1000 medianas).

Ejercicio (tarea):

- d) Para cada uno de los vectores generados en el ítem anterior, realizar un histograma y hallar una estimación por núcleos de la función de densidad.
- e) Hallar intervalos de confianza de nivel aproximado 0.95 para la media y para la mediana de X mediante los dos métodos vistos en clase.