

Habíamos visto: el Método del Pivote para Tests

Teorema: Sea $U = U(\mathbf{X}, \theta)$ un pivote decreciente en θ con distribución conocida G independiente de θ , y u_β su cuantil β .
Dados θ_0 y α tenemos:

- a) El test φ con región de rechazo $U(\mathbf{X}, \theta_0) > u_{1-\alpha}$ es un test de nivel α para chequear $H_0 : \theta \leq \theta_0$ (o de $H_0 : \theta = \theta_0$) vs. $H_1 : \theta > \theta_0$.
- b) El test φ con región de rechazo $U(\mathbf{X}, \theta_0) < u_{\alpha/2}$ o $U(\mathbf{X}, \theta_0) > u_{1-\alpha/2}$ es un test de nivel α de $H_0 : \theta = \theta_0$ vs. $H_1 : \theta \neq \theta_0$.

Un teorema similar tenemos para las hipótesis $H_0 : \theta \geq \theta_0$ vs. $H_1 : \theta < \theta_0$.

Ejemplo del método de pivote para tests

- $X_1, \dots, X_n$ i.i.d., $X_i \sim N(\mu, \sigma^2)$, σ^2 desconocida.

$$H_0 : \mu = \mu_0 \text{ vs. } H_1 : \mu \neq \mu_0$$

El test

$$\varphi(X_1, \dots, X_n) = \begin{cases} 1 & \text{si } \sqrt{n} \frac{|\bar{X} - \mu_0|}{S} \geq t_{n-1, \alpha/2} \\ 0 & \text{si } \sqrt{n} \frac{|\bar{X} - \mu_0|}{S} < t_{n-1, \alpha/2} \end{cases}$$

tiene nivel α .

Test para $H_0 : \mu \leq \mu_0$ vs. $H_1 : \mu > \mu_0$

De forma análoga se puede ver que si:

- $X_1, \dots, X_n$ i.i.d., $X_i \sim N(\mu, \sigma^2)$, σ^2 desconocida.

$$\phi(X_1, \dots, X_n) = \begin{cases} 1 & \text{si } \sqrt{n} \frac{\bar{X} - \mu_0}{S} \geq t_{n-1, \alpha} \\ 0 & \text{si } \sqrt{n} \frac{\bar{X} - \mu_0}{S} < t_{n-1, \alpha} \end{cases}$$

Test para $H_0 : \mu \leq \mu_0$ vs. $H_1 : \mu > \mu_0$

De forma análoga se puede ver que si:

- $X_1, \dots, X_n$ i.i.d., $X_i \sim N(\mu, \sigma^2)$, σ^2 desconocida.

$$\phi(X_1, \dots, X_n) = \begin{cases} 1 & \text{si } \sqrt{n} \frac{\bar{X} - \mu_0}{S} \geq t_{n-1, \alpha} \\ 0 & \text{si } \sqrt{n} \frac{\bar{X} - \mu_0}{S} < t_{n-1, \alpha} \end{cases}$$

¿Cuál es la potencia de este test?

Para responder esta pregunta, necesitaremos la distribución t de Student no central con k grados de libertad y parámetro de no centralidad Δ : $t_k(\Delta)$.

Test para $H_0 : \sigma^2 \leq \sigma_0^2$ vs. $H_1 : \sigma^2 > \sigma_0^2$

- $X_1, \dots, X_n$ i.i.d., $X_i \sim N(\mu, \sigma^2)$, μ desconocida.

Sabemos que

$$U(\chi, \sigma^2) = (n-1) \frac{S^2}{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \sim \chi_{n-1}^2$$

y además es una función decreciente de σ^2 . Por lo tanto, usando el método del pivote, el test

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \text{si } \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma_0^2} \geq \chi_{n-1, \alpha}^2 \\ 0 & \text{si } \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma_0^2} < \chi_{n-1, \alpha}^2 . \end{cases}$$

tiene nivel α .

Test para $H_0 : \sigma^2 \leq \sigma_0^2$ vs. $H_1 : \sigma^2 > \sigma_0^2$

- $X_1, \dots, X_n$ i.i.d., $X_i \sim N(\mu, \sigma^2)$, μ desconocida.

Sabemos que

$$(n-1) \frac{S^2}{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \sim \chi_{n-1}^2$$

y además es una función decreciente de σ^2 . Por lo tanto, usando el método del pivote, el test

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \text{si } \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma_0^2} \geq \chi_{n-1, \alpha}^2 \\ 0 & \text{si } \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma_0^2} < \chi_{n-1, \alpha}^2 . \end{cases}$$

tiene nivel α .

¿Cuál es la potencia de este test?

Test para $H_0 : \sigma^2 \leq \sigma_0^2$ vs. $H_1 : \sigma^2 > \sigma_0^2$

La potencia de este test es

$$\pi_{\varphi}(\sigma^2) = \mathbb{P}_{\sigma^2} \left(\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma_0^2} \geq \chi_{n-1, \alpha}^2 \right)$$

Test para $H_0 : \sigma^2 \leq \sigma_0^2$ vs. $H_1 : \sigma^2 > \sigma_0^2$

La potencia de este test es

$$\begin{aligned}\pi_{\varphi}(\sigma^2) &= \mathbb{P}_{\sigma^2} \left(\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma_0^2} \geq \chi_{n-1, \alpha}^2 \right) \\ &= \mathbb{P}_{\sigma^2} \left(\sum_{i=1}^n (X_i - \bar{X})^2 \geq \sigma_0^2 \chi_{n-1, \alpha}^2 \right)\end{aligned}$$

Test para $H_0 : \sigma^2 \leq \sigma_0^2$ vs. $H_1 : \sigma^2 > \sigma_0^2$

La potencia de este test es

$$\begin{aligned}\pi_{\varphi}(\sigma^2) &= \mathbb{P}_{\sigma^2} \left(\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma_0^2} \geq \chi_{n-1, \alpha}^2 \right) \\ &= \mathbb{P}_{\sigma^2} \left(\sum_{i=1}^n (X_i - \bar{X})^2 \geq \sigma_0^2 \chi_{n-1, \alpha}^2 \right) \\ &= \mathbb{P}_{\sigma^2} \left(\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \geq \frac{\sigma_0^2 \chi_{n-1, \alpha}^2}{\sigma^2} \right)\end{aligned}$$

Test para $H_0 : \sigma^2 \leq \sigma_0^2$ vs. $H_1 : \sigma^2 > \sigma_0^2$

La potencia de este test es

$$\begin{aligned}\pi_{\varphi}(\sigma^2) &= \mathbb{P}_{\sigma^2} \left(\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma_0^2} \geq \chi_{n-1, \alpha}^2 \right) \\&= \mathbb{P}_{\sigma^2} \left(\sum_{i=1}^n (X_i - \bar{X})^2 \geq \sigma_0^2 \chi_{n-1, \alpha}^2 \right) \\&= \mathbb{P}_{\sigma^2} \left(\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \geq \frac{\sigma_0^2 \chi_{n-1, \alpha}^2}{\sigma^2} \right) \\&= \mathbb{P} \left(V \geq \frac{\sigma_0^2 \chi_{n-1, \alpha}^2}{\sigma^2} \right) = 1 - F_V \left(\frac{\sigma_0^2 \chi_{n-1, \alpha}^2}{\sigma^2} \right) ,\end{aligned}$$

siendo $V \sim \chi_{n-1}^2$.

- $\pi_{\varphi}(\sigma^2)$ es una función creciente de σ^2 .



Ejemplo de duración de baterías

- Los siguientes datos corresponden a la duración en horas de 18 baterías eléctricas:

237	242	232	242	248	230	244	243	254
262	234	220	225	246	232	218	228	240

- Supongamos que un comprador quiere adquirir el lote de baterías si el vendedor demuestra que su vida media es mayor a 235 hs, con una probabilidad 0.01 de adquirir un lote malo. Solo para ilustración, como antes, suponemos que los datos tienen distribución normal.

Ejemplo de duración de baterías



Ejemplo de duración de baterías

Si llamamos X_i = “duración de la i -ésima batería (en horas)”, estamos pensando que tenemos $X_1, \dots, X_n$ son v.a.i.i.d. con distribución $N(\mu, \sigma^2)$. El comprador quiere distinguir entre

$$\mu \leq 235 \quad \text{y} \quad \mu > 235.$$

Ejemplo de duración de baterías

Si llamamos X_i = “duración de la i -ésima batería (en horas)”, estamos pensando que tenemos $X_1, \dots, X_n$ son v.a.i.i.d. con distribución $N(\mu, \sigma^2)$. El comprador quiere distinguir entre

$$\mu \leq 235 \quad \text{y} \quad \mu > 235 .$$

Además, dice que quiere adquirir un lote malo con probabilidad 0.01, es decir,

$$\mathbb{P}(\text{“adquirir el lote”} \mid \text{“el lote es malo”}) = 0.01 .$$

Ejemplo de duración de baterías

Si llamamos X_i = “duración de la i -ésima batería (en horas)”, estamos pensando que tenemos $X_1, \dots, X_n$ son v.a.i.i.d. con distribución $N(\mu, \sigma^2)$. El comprador quiere distinguir entre

$$\mu \leq 235 \quad \text{y} \quad \mu > 235.$$

Además, dice que quiere adquirir un lote malo con probabilidad 0.01, es decir,

$$\mathbb{P}(\text{“adquirir el lote”} \mid \text{“el lote es malo”}) = 0.01.$$

Como nosotros sólo podemos controlar el nivel del test y dado que la probabilidad de error de tipo I es la probabilidad de Rechazar H_0 cuando H_0 es cierta, estamos diciendo que el hecho de que *el lote sea malo* es H_0 .

Ejemplo de duración de baterías

Si llamamos X_i = “duración de la i -ésima batería (en horas)”, estamos pensando que tenemos $X_1, \dots, X_n$ son v.a.i.i.d. con distribución $N(\mu, \sigma^2)$. El comprador quiere distinguir entre

$$\mu \leq 235 \quad \text{y} \quad \mu > 235.$$

Además, dice que quiere adquirir un lote malo con probabilidad 0.01, es decir,

$$\mathbb{P}(\text{“adquirir el lote”} \mid \text{“el lote es malo”}) = 0.01.$$

Como nosotros sólo podemos controlar el nivel del test y dado que la probabilidad de error de tipo I es la probabilidad de Rechazar H_0 cuando H_0 es cierta, estamos diciendo que el hecho de que *el lote sea malo* es H_0 . Luego, las hipótesis del test son

$$H_0 : \mu \leq 235 \quad \text{vs.} \quad H_1 : \mu > 235$$

y el nivel del test es 0.01.

Ejemplo de duración de baterías

Luego, por lo que vimos, el estadístico del test es

$$T = \sqrt{n} \frac{\bar{X} - \mu_0}{S}$$

y el test de nivel α es

$$\phi(X_1, \dots, X_n) = \begin{cases} 1 & \text{si } \sqrt{n} \frac{\bar{X} - \mu_0}{S} \geq t_{n-1, \alpha} \\ 0 & \text{c.c.} \end{cases}$$

Ejemplo de duración de baterías

Luego, por lo que vimos, el estadístico del test es

$$T = \sqrt{n} \frac{\bar{X} - \mu_0}{S}$$

y el test de nivel α es

$$\phi(X_1, \dots, X_n) = \begin{cases} 1 & \text{si } \sqrt{n} \frac{\bar{X} - \mu_0}{S} \geq t_{n-1, \alpha} \\ 0 & \text{c.c.} \end{cases}$$

Como en este caso $n = 18$, entonces el valor $t_{n-1, \alpha}$ es

```
> n <- length(datos)
> qt(1-0.01, n-1)
[1] 2.566934
```

Ejemplo de duración de baterías

Por otro lado, el $T_{\text{obs}} = \sqrt{18}(\bar{x} - 235)/s$ es

```
> Tobs <- sqrt(18)*(mean(datos)-235)/sd(datos)
```

```
> Tobs
```

```
[1] 0.96588
```

¿Qué decisión tomamos?

Ejemplo de duración de baterías

Por otro lado, el $T_{\text{obs}} = \sqrt{18}(\bar{x} - 235)/s$ es

```
> Tobs <- sqrt(18)*(mean(datos)-235)/sd(datos)
> Tobs
[1] 0.96588
```

¿Qué decisión tomamos? Como el T_{obs} es menor que 2.57, no rechazamos H_0 , es decir, no hay evidencia estadística suficiente para decir que las baterías son provenientes de un lote bueno. Luego, si queremos determinar si compramos o no compramos las baterías, la respuesta es **no compramos**.

Ejemplo de duración de baterías

Por otro lado, el $T_{\text{obs}} = \sqrt{18}(\bar{x} - 235)/s$ es

```
> Tobs <- sqrt(18)*(mean(datos)-235)/sd(datos)
> Tobs
[1] 0.96588
```

¿Qué decisión tomamos? Como el T_{obs} es menor que 2.57, no rechazamos H_0 , es decir, no hay evidencia estadística suficiente para decir que las baterías son provenientes de un lote bueno. Luego, si queremos determinar si compramos o no compramos las baterías, la respuesta es **no compramos**.

Ahora, ¿cuánto vale el p-valor? ¿Cómo lo calculamos?

Ejemplo de duración de baterías

Por otro lado, el $T_{\text{obs}} = \sqrt{18}(\bar{x} - 235)/s$ es


```
> Tobs <- sqrt(18)*(mean(datos)-235)/sd(datos)
> Tobs
[1] 0.96588
```

¿Qué decisión tomamos? Como el T_{obs} es menor que 2.57, no rechazamos H_0 , es decir, no hay evidencia estadística suficiente para decir que las baterías son provenientes de un lote bueno. Luego, si queremos determinar si compramos o no compramos las baterías, la respuesta es **no compramos**.

Ahora, ¿cuánto vale el p-valor? ¿Cómo lo calculamos?

En este caso de interés, la evidencia en contra de la hipótesis nula se obtiene con valores grandes del estadístico:

$$p = \mathbb{P}_{\mu_0}(T \geq T_{\text{obs}})$$



Ejemplo de duración de baterías

Como habíamos obtenido que el $T_{obs} = 0.96588$

$$\text{p-valor : } \mathbb{P}(t \geq 0.96588)$$

con $t \sim t_{n-1}$.

Ejemplo de duración de baterías

Como habíamos obtenido que el $T_{obs} = 0.96588$

$$\text{p-valor} : \mathbb{P}(t \geq 0.96588)$$

con $t \sim t_{n-1}$.

En R, esto se calcula como

```
> 1-pt(Tobs, n-1)  
[1] 0.1738224
```

Observemos que este p-valor es más grande que los valores de α con los que trabajamos habitualmente, así que a los niveles habituales no rechazaríamos H_0 . En particular, es más grande que el nivel deseado que era 0.01 y, por esta razón, es que decidíamos no rechazar la hipótesis nula.

Ejemplo de duración de baterías

Usando la función `t.test`:

```
> t.test(datos, alternative="greater", mu=235)
```

One Sample t-test

```
data:  datos
```

```
t = 0.96588, df = 17, p-value = 0.1738
```

```
alternative hypothesis: true mean is greater than 235
```

```
95 percent confidence interval:
```

```
232.9083      Inf
```

```
sample estimates:
```

```
mean of x
```

```
237.6111
```

Tests de nivel asintótico

- $X_1, \dots, X_n$ m.a. $X_i \sim F(\mathbf{x}, \boldsymbol{\theta})$, $\boldsymbol{\theta} \in \Theta$.
- $H_0 : \boldsymbol{\theta} \in \Theta_0$ vs. $H_1 : \boldsymbol{\theta} \in \Theta_1$.

Se dirá que una sucesión de tests $\phi_n(X_1, \dots, X_n)$ tiene **nivel de significación asintótico α** si

$$\lim_{n \rightarrow \infty} \sup_{\boldsymbol{\theta} \in \Theta_0} \pi_{\phi_n}(\boldsymbol{\theta}) = \alpha$$

En otras palabras: el nivel del test $\phi_n(X_1, \dots, X_n)$ se acerca a α cuando el tamaño de la muestra tiende a infinito.

Ejemplo

- $X_1, \dots, X_n$ i.i.d. con $\mathbb{E}(X_i) = \mu$ y $\mathbb{V}ar(X_i) = \sigma^2$.

Queremos testear $H_0 : \mu = \mu_0$ vs. $H_1 : \mu < \mu_0$.

Tenemos

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n} \quad \text{y} \quad S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}.$$

Sabemos que cuando la esperanza de las variables X_i es μ_0

$$\sqrt{n} \frac{\bar{X} - \mu_0}{S} \xrightarrow{D} N(0, 1)$$

Ejemplo

- $X_1, \dots, X_n$ i.i.d. con $\mathbb{E}(X_i) = \mu$ y $\mathbb{V}ar(X_i) = \sigma^2$.

Queremos testear $H_0 : \mu = \mu_0$ vs. $H_1 : \mu < \mu_0$.

Tenemos

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n} \quad y \quad S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}.$$

Sabemos que cuando la esperanza de las variables X_i es μ_0

$$\sqrt{n} \frac{\bar{X} - \mu_0}{S} \xrightarrow{D} N(0, 1)$$

Luego,

$$\phi_n(X_1, \dots, X_n) = \begin{cases} 1 & \text{si } \sqrt{n} \frac{\bar{X} - \mu_0}{S} \leq -z_\alpha \\ 0 & \text{c.c.} \end{cases}$$

es un test de nivel de significación asintótico α .

$$\alpha_n = P(\text{"Error tipo I"}) = P_{\mu_0}(\Phi_n = 1) = P_{\mu_0} \left(\underbrace{\frac{\sqrt{n} \bar{X} - \mu_0}{S}}_{\sim F_n} \leq -z_\alpha \right) = F_n(-z_\alpha)$$

Como bajo H_0 , $\frac{\sqrt{n} \bar{X} - \mu_0}{S} \xrightarrow{D} N(0, 1)$

$$\Rightarrow F_n(t) \xrightarrow{n \rightarrow +\infty} \Phi(t) \quad \forall t$$

$$\Rightarrow \alpha_n = F_n(-z_\alpha) \xrightarrow{n \rightarrow +\infty} \Phi(-z_\alpha) = \alpha \quad \checkmark$$

Test del Cociente de Máxima Verosimilitud

Este método puede verse como una extensión del Lema de Neyman-Pearson.

Bajo condiciones de regularidad sobre las distribuciones involucradas se puede deducir la distribución límite de $\Lambda(\mathbf{X})$ cuando $n \rightarrow \infty$ es χ^2 .

Por lo tanto, cuando la distribución exacta no se conoce, se puede usar esta aproximación.

Test del Cociente de Máxima Verosimilitud

$\mathbf{X} \sim f(\mathbf{x}, \boldsymbol{\theta})$, f.d. o bien f.p.p., $\boldsymbol{\theta} \in \Theta$ y queremos testear

$$H_0 : \boldsymbol{\theta} \in \Theta_0 \text{ vs. } H_1 : \boldsymbol{\theta} \in \Theta_1$$

con $\Theta_0 \cup \Theta_1 = \Theta$.

Veamos cuál es la motivación de este método.

Reparam.: N-P : $X_1, \dots, X_n \sim F(\underline{x}, \boldsymbol{\theta})$ $H_0: \boldsymbol{\theta} = \boldsymbol{\theta}_0$ vs $H_1: \boldsymbol{\theta} = \boldsymbol{\theta}_1$

$$\Lambda(\mathbf{X}) = \frac{f(\mathbf{x}, \boldsymbol{\theta}_1)}{f(\mathbf{x}, \boldsymbol{\theta}_0)}$$

$$\{\Lambda(\mathbf{X}) > k\} = \mathcal{R}$$

donde k se elige para que $P_{\boldsymbol{\theta}_0}(\Lambda(\mathbf{X}) > k) = \alpha$, o sea,
sepa nivel α .

Ahora vamos a testear: $H_0: \boldsymbol{\theta} \in \Theta_0$ vs $H_1: \boldsymbol{\theta} \in \Theta_1$

Idea: haremos el cociente con el "mejor" valor en Θ_1 y el mejor valor en Θ_0 .

Test del Cociente de Máxima Verosimilitud

$\mathbf{X} \sim f(\mathbf{x}, \boldsymbol{\theta})$, f.d. o bien f.p.p., $\boldsymbol{\theta} \in \Theta$ y queremos testear

$$H_0 : \boldsymbol{\theta} \in \Theta_0 \text{ vs. } H_1 : \boldsymbol{\theta} \in \Theta_1$$

con $\Theta_0 \cup \Theta_1 = \Theta$.

Veamos cuál es la motivación de este método.

- $\hat{\boldsymbol{\theta}}_0$: EMV de $\boldsymbol{\theta}$, suponiendo $\boldsymbol{\theta} \in \Theta_0$.

Test del Cociente de Máxima Verosimilitud

$\mathbf{X} \sim f(\mathbf{x}, \boldsymbol{\theta})$, f.d. o bien f.p.p., $\boldsymbol{\theta} \in \Theta$ y queremos testear

$$H_0 : \boldsymbol{\theta} \in \Theta_0 \text{ vs. } H_1 : \boldsymbol{\theta} \in \Theta_1$$

con $\Theta_0 \cup \Theta_1 = \Theta$.

Veamos cuál es la motivación de este método.

- $\hat{\boldsymbol{\theta}}_0$: EMV de $\boldsymbol{\theta}$, suponiendo $\boldsymbol{\theta} \in \Theta_0$.
- $\hat{\boldsymbol{\theta}}_1$: EMV de $\boldsymbol{\theta}$, suponiendo $\boldsymbol{\theta} \in \Theta_1$.

Test del Cociente de Máxima Verosimilitud

$\mathbf{X} \sim f(\mathbf{x}, \boldsymbol{\theta})$, f.d. o bien f.p.p., $\boldsymbol{\theta} \in \Theta$ y queremos testear

$$H_0 : \boldsymbol{\theta} \in \Theta_0 \text{ vs. } H_1 : \boldsymbol{\theta} \in \Theta_1$$

con $\Theta_0 \cup \Theta_1 = \Theta$.

Veamos cuál es la motivación de este método.

- $\hat{\boldsymbol{\theta}}_0$: EMV de $\boldsymbol{\theta}$, suponiendo $\boldsymbol{\theta} \in \Theta_0$.
- $\hat{\boldsymbol{\theta}}_1$: EMV de $\boldsymbol{\theta}$, suponiendo $\boldsymbol{\theta} \in \Theta_1$.

$$\begin{aligned} f(\mathbf{X}, \hat{\boldsymbol{\theta}}_0) &= \max_{\boldsymbol{\theta} \in \Theta_0} f(\mathbf{X}, \boldsymbol{\theta}) \\ f(\mathbf{X}, \hat{\boldsymbol{\theta}}_1) &= \max_{\boldsymbol{\theta} \in \Theta_1} f(\mathbf{X}, \boldsymbol{\theta}) \end{aligned}$$

Si “nos olvidásemos” que $\hat{\boldsymbol{\theta}}_0$ y $\hat{\boldsymbol{\theta}}_1$ son aleatorios y procediésemos como en el Lema de Neyman-Pearson, podríamos considerar el cociente:

Test del Cociente de Máxima Verosimilitud

$\mathbf{X} \sim f(\mathbf{x}, \boldsymbol{\theta})$, $\boldsymbol{\theta} \in \Theta$ y queremos testear

$$H_0 : \boldsymbol{\theta} \in \Theta_0 \text{ versus } H_1 : \boldsymbol{\theta} \in \Theta_1$$

Entonces, el test rechaza H_0 si

$$\frac{f(\mathbf{x}, \hat{\boldsymbol{\theta}}_1)}{f(\mathbf{x}, \hat{\boldsymbol{\theta}}_0)} > k$$

Test del Cociente de Máxima Verosimilitud

$\mathbf{X} \sim f(\mathbf{x}, \boldsymbol{\theta})$, $\boldsymbol{\theta} \in \Theta$ y queremos testear

$$H_0 : \boldsymbol{\theta} \in \Theta_0 \text{ versus } H_1 : \boldsymbol{\theta} \in \Theta_1$$

Entonces, el test rechaza H_0 si

$$\frac{f(\mathbf{x}, \hat{\boldsymbol{\theta}}_1)}{f(\mathbf{x}, \hat{\boldsymbol{\theta}}_0)} > k$$

En definitiva, se puede tener un test de nivel asintótico con

$$\lambda(\mathbf{X}) = \frac{\sup_{\boldsymbol{\theta} \in \Theta_0} f(\mathbf{X}, \boldsymbol{\theta})}{\sup_{\boldsymbol{\theta} \in \Theta_1} f(\mathbf{X}, \boldsymbol{\theta})} .$$

Observación: Por comodidad para lo que sigue, cambiamos el orden del numerador y del denominador, así que, en este caso, rechazamos si $\lambda(\mathbf{X}) < k'$.

Test del Cociente de Máxima Verosimilitud

$\mathbf{X} \sim f(\mathbf{x}, \boldsymbol{\theta})$, $\boldsymbol{\theta} \in \Theta$ y queremos testear

$$H_0 : \boldsymbol{\theta} \in \Theta_0 \text{ versus } H_1 : \boldsymbol{\theta} \in \Theta_1$$

Entonces, el test rechaza H_0 si

$$\frac{f(\mathbf{x}, \hat{\boldsymbol{\theta}}_1)}{f(\mathbf{x}, \hat{\boldsymbol{\theta}}_0)} > k$$

En definitiva, se puede tener un test de nivel asintótico con

$$\lambda(\mathbf{X}) = \frac{\sup_{\boldsymbol{\theta} \in \Theta_0} f(\mathbf{X}, \boldsymbol{\theta})}{\sup_{\boldsymbol{\theta} \in \Theta_1} f(\mathbf{X}, \boldsymbol{\theta})} .$$

Observación: Por comodidad para lo que sigue, cambiamos el orden del numerador y del denominador, así que, en este caso, rechazamos si $\lambda(\mathbf{X}) < k'$.

Problema de este planteo: necesitamos calcular dos supremos con restricciones.

Test del Cociente de Máxima Verosimilitud

En muchos casos, como por ejemplo, cuando la dimensión de Θ_0 es menor que la dimensión de $\Theta = \Theta_0 \cup \Theta_1$, y $f(\mathbf{x}, \boldsymbol{\theta})$ es continua, resulta que

$$\sup_{\boldsymbol{\theta} \in \Theta_1} f(\mathbf{X}, \boldsymbol{\theta}) = \sup_{\boldsymbol{\theta} \in \Theta} f(\mathbf{X}, \boldsymbol{\theta}). \quad (1)$$

El test del cociente de máxima verosimilitud resulta

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \text{si } \lambda^*(\mathbf{X}) \leq k_\alpha \\ 0 & \text{si } \lambda^*(\mathbf{X}) > k_\alpha \end{cases}$$

donde

$$\lambda^*(\mathbf{X}) = \frac{\sup_{\boldsymbol{\theta} \in \Theta_0} f(\mathbf{X}, \boldsymbol{\theta})}{\sup_{\boldsymbol{\theta} \in \Theta} f(\mathbf{X}, \boldsymbol{\theta})}.$$

Ejemplo: caso distribución exacta

Sean $X_1, \dots, X_n$ i.i.d. $N(\mu, \sigma^2)$, donde μ y σ son desconocidos. Queremos testear con nivel α

NO es una hipótesis simple

$$H_0 : \sigma^2 = \sigma_0^2 \quad \text{vs.} \quad H_1 : \sigma^2 \neq \sigma_0^2$$


Vamos a ver que el test de CMV es equivalente al test χ^2 .

¿Quiénes son Θ_0 y Θ_1 en este caso?

$$\Theta = \{ (\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 \in (0; +\infty) \} = \mathbb{R} \times (0; +\infty)$$

$$\Theta_0 = \{ (\mu, \sigma_0^2) : \mu \in \mathbb{R} \} = \mathbb{R} \times \{ \sigma_0^2 \}$$

$$\Theta_1 = \{ (\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 \neq \sigma_0^2 \} = \mathbb{R} \times [(0; \sigma_0^2) \cup (\sigma_0^2; +\infty)]$$



Ejemplo: caso distribución exacta

Hallaremos el supremo de f en Θ_0 y Θ .

Para la distribución normal tenemos

$$f(\mathbf{X}, \theta) = f(\mathbf{X}, \mu, \sigma^2) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left\{ - \sum_{i=1}^n \frac{(X_i - \mu)^2}{2\sigma^2} \right\}$$

Ejemplo: caso distribución exacta

Hallaremos el supremo de f en Θ_0 y Θ .

Para la distribución normal tenemos

$$f(\mathbf{X}, \theta) = f(\mathbf{X}, \mu, \sigma^2) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left\{ - \sum_{i=1}^n \frac{(X_i - \mu)^2}{2\sigma^2} \right\}$$

En Θ_0 , $\sigma^2 = \sigma_0^2$. Tendríamos que encontrar el valor de μ que maximiza $f(\mathbf{X}, \mu, \sigma^2)$ sujeto a que $\sigma^2 = \sigma_0^2$. Hemos visto que el máximo de $f(\mathbf{X}, \mu, \sigma_0^2)$ se realiza en $\hat{\mu} = \bar{X}$.

Ejemplo: caso distribución exacta

Hallaremos el supremo de f en Θ_0 y Θ .

Para la distribución normal tenemos

$$f(\mathbf{X}, \theta) = f(\mathbf{X}, \mu, \sigma^2) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left\{ - \sum_{i=1}^n \frac{(X_i - \mu)^2}{2\sigma^2} \right\}$$

En Θ_0 , $\sigma^2 = \sigma_0^2$. Tendríamos que encontrar el valor de μ que maximiza $f(\mathbf{X}, \mu, \sigma_0^2)$ sujeto a que $\sigma^2 = \sigma_0^2$. Hemos visto que el máximo de $f(\mathbf{X}, \mu, \sigma_0^2)$ se realiza en $\hat{\mu} = \bar{X}$.

Luego, en Θ_0 , el supremo (que es un máximo) es

$$\sup_{\theta \in \Theta_0} f(\mathbf{X}, \theta) =$$

Ejemplo: caso distribución exacta

Hallaremos el supremo de f en Θ_0 y Θ .

Para la distribución normal tenemos

$$f(\mathbf{X}, \theta) = f(\mathbf{X}, \mu, \sigma^2) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left\{ - \sum_{i=1}^n \frac{(X_i - \mu)^2}{2\sigma^2} \right\}$$

En Θ_0 , $\sigma^2 = \sigma_0^2$. Tendríamos que encontrar el valor de μ que maximiza $f(\mathbf{X}, \mu, \sigma_0^2)$ sujeto a que $\sigma^2 = \sigma_0^2$. Hemos visto que el máximo de $f(\mathbf{X}, \mu, \sigma_0^2)$ se realiza en $\hat{\mu} = \bar{X}$.

Luego, en Θ_0 , el supremo (que es un máximo) es

$$\sup_{\theta \in \Theta_0} f(\mathbf{X}, \theta) = \sup_{\mu \in \mathbb{R}} f(\mathbf{X}, \mu, \sigma_0^2) =$$

Ejemplo: caso distribución exacta

Hallaremos el supremo de f en Θ_0 y Θ .

Para la distribución normal tenemos

$$f(\mathbf{X}, \theta) = f(\mathbf{X}, \mu, \sigma^2) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left\{ - \sum_{i=1}^n \frac{(X_i - \mu)^2}{2\sigma^2} \right\}$$

En Θ_0 , $\sigma^2 = \sigma_0^2$. Tendríamos que encontrar el valor de μ que maximiza $f(\mathbf{X}, \mu, \sigma^2)$ sujeto a que $\sigma^2 = \sigma_0^2$. Hemos visto que el máximo de $f(\mathbf{X}, \mu, \sigma_0^2)$ se realiza en $\hat{\mu} = \bar{X}$.

Luego, en Θ_0 , el supremo (que es un máximo) es

$$\sup_{\boldsymbol{\theta} \in \Theta_0} f(\mathbf{X}, \boldsymbol{\theta}) = \sup_{\mu \in \mathbb{R}} f(\mathbf{X}, \mu, \sigma_0^2) = f(\mathbf{X}, \hat{\mu}, \sigma_0^2)$$

Ejemplo: caso distribución exacta

Hallaremos el supremo de f en Θ_0 y Θ .

Para la distribución normal tenemos

$$f(\mathbf{X}, \theta) = f(\mathbf{X}, \mu, \sigma^2) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left\{ - \sum_{i=1}^n \frac{(X_i - \mu)^2}{2\sigma^2} \right\}$$

En Θ_0 , $\sigma^2 = \sigma_0^2$. Tendríamos que encontrar el valor de μ que maximiza $f(\mathbf{X}, \mu, \sigma^2)$ sujeto a que $\sigma^2 = \sigma_0^2$. Hemos visto que el máximo de $f(\mathbf{X}, \mu, \sigma_0^2)$ se realiza en $\hat{\mu} = \bar{X}$.

Luego, en Θ_0 , el supremo (que es un máximo) es

$$\begin{aligned} \sup_{\theta \in \Theta_0} f(\mathbf{X}, \theta) &= \sup_{\mu \in \mathbb{R}} f(\mathbf{X}, \mu, \sigma_0^2) = f(\mathbf{X}, \hat{\mu}, \sigma_0^2) \\ &= \left(\frac{1}{\sqrt{2\pi}\sigma_0} \right)^n \exp \left\{ - \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{2\sigma_0^2} \right\} \end{aligned}$$

Ejemplo: caso distribución exacta

Por otro lado, ya hemos calculado el máximo sin restricciones, es decir, en Θ , sabemos que se alcanza en

$$\hat{\mu} = \overline{X} \quad \text{y} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X})^2 .$$

Ejemplo: caso distribución exacta

Por otro lado, ya hemos calculado el máximo sin restricciones, es decir, en Θ , sabemos que se alcanza en

$$\hat{\mu} = \overline{X} \quad \text{y} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X})^2 .$$

Entonces

$$\max_{\boldsymbol{\theta} \in \Theta} f(\mathbf{X}, \boldsymbol{\theta}) =$$

Ejemplo: caso distribución exacta

Por otro lado, ya hemos calculado el máximo sin restricciones, es decir, en Θ , sabemos que se alcanza en

$$\hat{\mu} = \overline{X} \quad y \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X})^2 .$$

Entonces

$$\max_{\boldsymbol{\theta} \in \Theta} f(\mathbf{X}, \boldsymbol{\theta}) = f(\mathbf{X}, \hat{\mu}, \hat{\sigma}^2)$$

Ejemplo: caso distribución exacta

Por otro lado, ya hemos calculado el máximo sin restricciones, es decir, en Θ , sabemos que se alcanza en

$$\hat{\mu} = \overline{X} \quad y \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X})^2 .$$

Entonces

$$\begin{aligned} \max_{\boldsymbol{\theta} \in \Theta} f(\mathbf{X}, \boldsymbol{\theta}) &= f(\mathbf{X}, \hat{\mu}, \hat{\sigma}^2) \\ &= \left(\frac{1}{\sqrt{2\pi\hat{\sigma}}} \right)^n \exp \left\{ - \sum_{i=1}^n \frac{(X_i - \overline{X})^2}{2\hat{\sigma}^2} \right\} \\ &= \end{aligned}$$

Ejemplo: caso distribución exacta

Por otro lado, ya hemos calculado el máximo sin restricciones, es decir, en Θ , sabemos que se alcanza en

$$\hat{\mu} = \overline{X} \quad \text{y} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X})^2 .$$

Entonces

$$\begin{aligned} \max_{\boldsymbol{\theta} \in \Theta} f(\mathbf{X}, \boldsymbol{\theta}) &= f(\mathbf{X}, \hat{\mu}, \hat{\sigma}^2) \\ &= \left(\frac{1}{\sqrt{2\pi\hat{\sigma}}} \right)^n \exp \left\{ - \sum_{i=1}^n \frac{(X_i - \overline{X})^2}{2\hat{\sigma}^2} \right\} \\ &= \left(\frac{1}{\sqrt{2\pi\hat{\sigma}}} \right)^n e^{-n/2} \end{aligned}$$

Ejemplo: caso distribución exacta

Así, obtenemos que el cociente de máxima verosimilitud es

$$\lambda^*(\mathbf{X}) = \frac{\left(\frac{1}{\sqrt{2\pi}\sigma_0}\right)^n \exp\left\{-\sum_{i=1}^n \frac{(X_i - \bar{X})^2}{2\sigma_0^2}\right\}}{\left(\frac{1}{\sqrt{2\pi}\hat{\sigma}}\right)^n e^{-n/2}} = \frac{f(\mathbf{x}, \bar{x}, \sigma_0^2)}{f(\mathbf{x}, \bar{x}, \hat{\sigma}^2)}$$

=

Ejemplo: caso distribución exacta

Así, obtenemos que el cociente de máxima verosimilitud es $n\hat{\sigma}^2$

$$\begin{aligned}\lambda^*(\mathbf{X}) &= \frac{\left(\frac{1}{\sqrt{2\pi}\sigma_0}\right)^n \exp\left\{-\sum_{i=1}^n \frac{(X_i - \bar{X})^2}{2\sigma_0^2}\right\}}{\left(\frac{1}{\sqrt{2\pi}\hat{\sigma}}\right)^n e^{-n/2}} \\ &= e^{n/2} \left(\frac{\hat{\sigma}^2}{\sigma_0^2}\right)^{n/2} \exp\left\{-\frac{n}{2} \frac{\hat{\sigma}^2}{\sigma_0^2}\right\}\end{aligned}$$

Notemos que $0 < \lambda^*(\mathbf{X}) \leq 1$ ya que $\Theta_0 \subset \Theta$, entonces rechazaremos H_0 si $\lambda^*(\mathbf{X}) \leq k$, donde $k < 1$.

Ejemplo: caso distribución exacta

Así, obtenemos que el cociente de máxima verosimilitud es

$$\begin{aligned}\lambda^*(\mathbf{X}) &= \frac{\left(\frac{1}{\sqrt{2\pi}\sigma_0}\right)^n \exp\left\{-\sum_{i=1}^n \frac{(X_i - \bar{X})^2}{2\sigma_0^2}\right\}}{\left(\frac{1}{\sqrt{2\pi}\hat{\sigma}}\right)^n e^{-n/2}} \\ &= e^{n/2} \left(\frac{\hat{\sigma}^2}{\sigma_0^2}\right)^{n/2} \exp\left\{-\frac{n}{2} \frac{\hat{\sigma}^2}{\sigma_0^2}\right\}\end{aligned}$$

Notemos que $0 < \lambda^*(\mathbf{X}) \leq 1$ ya que $\Theta_0 \subset \Theta$, entonces rechazaremos H_0 si $\lambda^*(\mathbf{X}) \leq k$, donde $k < 1$.

La región de rechazo, $\lambda^*(\mathbf{X}) \leq k$ es equivalente a


$$\underbrace{\left(\frac{\hat{\sigma}^2}{\sigma_0^2}\right)}_{\mathcal{U}}^{n/2} \exp\left\{-\frac{n}{2} \underbrace{\frac{\hat{\sigma}^2}{\sigma_0^2}}_{\mathcal{U}}\right\} \leq k e^{-n/2} = k'$$

Función de Potencia ($n = 10$)

La función $g(u) = u^c e^{-cu}$ tiene la siguiente forma. Estamos tomando $u = \hat{\sigma}^2 / \sigma_0^2$ y $c = n/2$.


CHEQUEAR
↓

der! $g'(u) = c u^{-c} e^{-cu}$



Función de Potencia ($n = 10$)

La función $g(u) = u^c e^{-cu}$ tiene la siguiente forma. Estamos tomando $u = \hat{\sigma}^2 / \sigma_0^2$ y $c = n/2$.



¿Cuál es la región de rechazo del test? Rechazamos si

$$g\left(\underbrace{\frac{\hat{\sigma}^2}{\sigma_0^2}}_u\right) \leq k'$$

Ejemplo: caso distribución exacta

La condición

$$g\left(\frac{\hat{\sigma}^2}{\sigma_0^2}\right) \leq k'$$

que era

$$\left(\frac{\hat{\sigma}^2}{\sigma_0^2}\right)^{n/2} \exp\left\{-\frac{n}{2} \frac{\hat{\sigma}^2}{\sigma_0^2}\right\} \leq k e^{-n/2} = k'$$

se cumple si

$$\frac{\hat{\sigma}^2}{\sigma_0^2} \leq a \quad \text{o} \quad \frac{\hat{\sigma}^2}{\sigma_0^2} \geq b$$

Ejemplo: caso distribución exacta

La condición

$$g\left(\frac{\hat{\sigma}^2}{\sigma_0^2}\right) \leq k'$$

que era

$$\left(\frac{\hat{\sigma}^2}{\sigma_0^2}\right)^{n/2} \exp\left\{-\frac{n}{2} \frac{\hat{\sigma}^2}{\sigma_0^2}\right\} \leq k e^{-n/2} = k'$$

se cumple si

$$\frac{\hat{\sigma}^2}{\sigma_0^2} \leq a \quad \text{o} \quad \frac{\hat{\sigma}^2}{\sigma_0^2} \geq b$$

o, equivalentemente, si

$$\frac{n\hat{\sigma}^2}{\sigma_0^2} \leq na \quad \text{o} \quad \frac{n\hat{\sigma}^2}{\sigma_0^2} \geq nb.$$


Ejemplo: caso distribución exacta

Finalmente, como bajo H_0 se tiene que

$$\frac{n\hat{\sigma}^2}{\sigma_0^2} = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi_{n-1}^2,$$

obtenemos que el **test de cociente de máxima verosimilitud** es

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \text{si } \frac{n\hat{\sigma}^2}{\sigma_0^2} \leq \chi_{n-1, 1-\alpha/2}^2 \text{ o } \frac{n\hat{\sigma}^2}{\sigma_0^2} \geq \chi_{n-1, \alpha/2}^2 \\ 0 & \text{c.c.} \end{cases}$$



Distribución asintótica del test de CMV

En muchos casos la distribución de $\lambda^*(\mathbf{X})$ puede ser muy compleja y, en consecuencia, es difícil determinar la constante k_α necesaria para que el test tenga el nivel deseado.

En estas circunstancias, se puede optar por un test de nivel aproximado que surge de estudiar la distribución asintótica de $\lambda^*(\mathbf{X})$ y que será útil para muestras de tamaño suficientemente grande.

Distribución asintótica del test de CMV

- $\mathbf{X} = (X_1, \dots, X_n) \sim f(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p) \in \Theta \subseteq \mathbb{R}^p$ que contiene una esfera.
- Θ_0 es un conjunto de dimensión $p - j$, $1 \leq j \leq p$.
- $H_0 : \boldsymbol{\theta} \in \Theta_0$ vs. $H_1 : \boldsymbol{\theta} \in \Theta_1$, con $\Theta = \Theta_0 \cup \Theta_1$.

$$\lambda^*(\mathbf{X}) = \frac{\sup_{\boldsymbol{\theta} \in \Theta_0} f(\mathbf{X}, \boldsymbol{\theta})}{\sup_{\boldsymbol{\theta} \in \Theta} f(\mathbf{X}, \boldsymbol{\theta})}.$$

Bajo condiciones de regularidad generales en $f(\mathbf{x}, \boldsymbol{\theta})$, se tiene que

$$-2 \ln \lambda^*(\mathbf{X}) \xrightarrow{D} \chi_j^2 \quad \text{cuando } \boldsymbol{\theta} \in \Theta_0.$$

Observación: los grados de libertad de la distribución límite se corresponden con restar las dimensiones: $j = \dim(\Theta) - \dim(\Theta_0)$.

Distribución asintótica del test de CMV

Luego, un test de nivel de significación asintótico α está dado por

$$\phi(\mathbf{X}) = \begin{cases} 1 & \text{si } -2 \ln \lambda^*(\mathbf{X}) \geq \chi_{j,\alpha}^2 \\ 0 & \text{si } -2 \ln \lambda^*(\mathbf{X}) < \chi_{j,\alpha}^2 \end{cases}$$

Distribución asintótica del test de CMV

Luego, un test de nivel de significación asintótico α está dado por

$$\phi(\mathbf{X}) = \begin{cases} 1 & \text{si } -2 \ln \lambda^*(\mathbf{X}) \geq \chi_{j,\alpha}^2 \\ 0 & \text{si } -2 \ln \lambda^*(\mathbf{X}) < \chi_{j,\alpha}^2 \end{cases}$$

En el video de la Prof. Ana Bianco se encuentra la demostración de este resultado para el caso particular en que

$$H_0 : \theta = \theta_0 \quad \text{vs.} \quad H_1 : \theta \neq \theta_0 .$$

Disponible en

<https://drive.google.com/file/d/1TdTZJ6JSya0gC0QC-9SkQ-mWZQ0lrHNg/view>

¿Cuáles el resultado que prueba?

Distribución asintótica del test de CMV

$X_1, \dots, X_n$ i.i.d. $X_1 \sim f(x, \theta)$ con $\theta \in \Theta$ y Θ un abierto en $\mathbb{R}$.
Sea $f(\mathbf{x}, \theta)$ la densidad conjunta de $\mathbf{X} = (X_1, \dots, X_n)$.

Supongamos que se cumplen las siguientes condiciones

(A) El conjunto $\mathcal{S} = \{x : f(x, \theta) > 0\}$ es independiente de θ .

(B) Para todo $x \in \mathcal{S}$, $f(x, \theta)$ tiene derivada tercera respecto de θ continua y tal que

$$\left| \frac{\partial^3 \ln f(x, \theta)}{\partial \theta^3} \right| = \left| \frac{\partial^2 \psi(x, \theta)}{\partial \theta^2} \right| \leq K \quad \forall x \in \mathcal{S} \quad \forall \theta \in \Theta$$
$$\psi(x, \theta) = \frac{\partial \ln f(x, \theta)}{\partial \theta}.$$

Distribución asintótica del test de CMV

(C) Si $h(\mathbf{X})$ es un estadístico tal que $\mathbb{E}_\theta[|h(\mathbf{X})|] < \infty, \forall \theta \in \Theta$

$$\frac{\partial}{\partial \theta} \left[\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} h(\mathbf{x}) f(\mathbf{x}, \theta) d\mathbf{x} \right] = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} h(\mathbf{x}) \frac{\partial f(\mathbf{x}, \theta)}{\partial \theta} d\mathbf{x}$$

(D) $0 < I(\theta) = \mathbb{E}_\theta \left[\left(\frac{\partial \ln f(X_1, \theta)}{\partial \theta} \right)^2 \right] < \infty .$

Sea $\hat{\theta}_n$ un EMV de θ consistente y definamos

$$H_0: \theta = \theta_0 \text{ vs } H_1: \theta \neq \theta_0$$

$$\lambda^*(\mathbf{X}) = \frac{f(\mathbf{X}, \theta_0)}{\sup_{\theta \in \Theta} f(\mathbf{X}, \theta)} = \frac{f(\mathbf{X}, \theta_0)}{f(\mathbf{X}, \hat{\theta}_n)} .$$

Luego, resulta que

$$U = -2 \ln (\lambda^*(\mathbf{X})) \xrightarrow{D} \chi_1^2$$

Distribución asintótica del test de CV

El test

$$\phi(\mathbf{X}) = \begin{cases} 1 & \text{si } U \geq \chi_{1,\alpha}^2 \\ 0 & \text{si } U < \chi_{1,\alpha}^2 \end{cases}$$

donde $U = -2 \ln (\lambda^*(\mathbf{X}))$, tiene nivel de significación asintótico α .

Ejemplo con v.a. Bernoulli

$$b_{\theta}(\theta)$$

Sean $X_1, \dots, X_n$ v.a.i.i.d. $X_i \sim \text{Bi}(1, \theta)$, $0 < \theta < 1$.

Queremos testear $H_0 : \theta = \theta_0$ vs. $\theta \neq \theta_0$.

Luego, el test del cociente de máxima verosimilitud se basa en

$$\lambda^*(\mathbf{X}) = \frac{f(\mathbf{x}, \theta_0)}{\sup_{\theta \in \Theta} f(\mathbf{x}, \theta)} = \frac{\theta_0^T (1 - \theta_0)^{n-T}}{\bar{X}^T (1 - \bar{X})^{n-T}},$$

donde $T = \sum_{i=1}^n X_i$.

$$\Theta_0 = \{\theta_0\}$$

$$\Theta = (0, 1)$$

$$\begin{aligned} \text{Numerador: } \sup_{\theta \in \Theta_0} f(\mathbf{x}, \theta) &= f(\mathbf{x}, \theta_0) = \prod_{i=1}^n f(x_i, \theta_0) = \prod_{i=1}^n \theta_0^{x_i} (1 - \theta_0)^{1-x_i} \\ &= \theta_0^{\sum x_i} (1 - \theta_0)^{n - \sum x_i} \end{aligned}$$

$$\Rightarrow f(\mathbf{x}, \theta_0) = \theta_0^T (1 - \theta_0)^{n-T}$$

$$\text{Denominador: } \sup_{\theta \in \Theta} f(\mathbf{x}, \theta) = f(\mathbf{x}, \bar{X}) = \bar{X}^T (1 - \bar{X})^{n-T}$$

$$\hat{\theta}_{\text{mv}} = \bar{X}$$

Ejemplo con v.a. Bernoulli

Sean $X_1, \dots, X_n$ v.a.i.i.d. $X_i \sim \text{Bi}(1, \theta)$, $0 < \theta < 1$.

Queremos testear $H_0 : \theta = \theta_0$ vs. $\theta \neq \theta_0$.

Luego, el test del cociente de máxima verosimilitud se basa en

$$\lambda^*(\mathbf{X}) = \frac{f(\mathbf{x}, \theta_0)}{\sup_{\theta \in \Theta} f(\mathbf{x}, \theta)} = \frac{\theta_0^T (1 - \theta_0)^{n-T}}{\bar{X}^T (1 - \bar{X})^{n-T}},$$

donde $T = \sum_{i=1}^n X_i$. Luego,

$$U = -2 \ln \lambda^*(\mathbf{X}) = 2T \ln \left(\frac{\bar{X}}{\theta_0} \right) + 2(n - T) \ln \left(\frac{1 - \bar{X}}{1 - \theta_0} \right)$$

$$\begin{aligned} -2 \ln \lambda^*(\mathbf{x}) &= -2 \ln \left[\left(\frac{\theta_0}{\bar{x}} \right)^T \cdot \left(\frac{1 - \theta_0}{1 - \bar{x}} \right)^{n-T} \right] = \\ &= -2 \left(\ln \left(\left(\frac{\theta_0}{\bar{x}} \right)^T \right) + \ln \left(\left(\frac{1 - \theta_0}{1 - \bar{x}} \right)^{n-T} \right) \right) = -2 \left[T \ln \left(\frac{\theta_0}{\bar{x}} \right) + (n-T) \ln \left(\frac{1 - \theta_0}{1 - \bar{x}} \right) \right] \\ &= 2T \ln \left(\frac{\bar{x}}{\theta_0} \right) + 2(n-T) \ln \left(\frac{1 - \bar{x}}{1 - \theta_0} \right) \end{aligned}$$

Ejemplo con v.a. Bernoulli

Sean $X_1, \dots, X_n$ v.a.i.i.d. $X_i \sim Bi(1, \theta)$, $0 < \theta < 1$.

Queremos testear $H_0 : \theta = \theta_0$ vs. $\theta \neq \theta_0$.

Luego, el test del cociente de máxima verosimilitud se basa en

$$\lambda^*(\mathbf{X}) = \frac{f(\mathbf{x}, \theta_0)}{\sup_{\theta \in \Theta} f(\mathbf{x}, \theta)} = \frac{\theta_0^T (1 - \theta_0)^{n-T}}{\bar{X}^T (1 - \bar{X})^{n-T}},$$

donde $T = \sum_{i=1}^n X_i$. Luego,

$$U = -2 \ln \lambda^*(\mathbf{X}) = 2T \ln \left(\frac{\bar{X}}{\theta_0} \right) + 2(n - T) \ln \left(\frac{1 - \bar{X}}{1 - \theta_0} \right)$$

tiene una distribución asintótica χ^2_1 bajo H_0 y, por lo tanto, un test de nivel asintótico α estará dado por $\dim(\Theta) - \dim(\Theta_0)$

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \text{si } U \geq \chi^2_{1,\alpha} \\ 0 & \text{si } U < \chi^2_{1,\alpha} \end{cases}$$