

Propiedades del Estimador de Mínimos Cuadrados

Recordemos que $\hat{\boldsymbol{\theta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$ si $\mathbf{X}$ tiene rango p (completo).

Habíamos visto el siguiente resultado:

Lema 6.3: Si se cumple el modelo Ω y $\text{rg}(\mathbf{X}) = p$, tenemos que

- ★ $\hat{\boldsymbol{\theta}}$ es un estimador insesgado de $\boldsymbol{\theta}$, es decir, $\mathbb{E}(\hat{\boldsymbol{\theta}}) = \boldsymbol{\theta}$.
- ★ $\Sigma_{\hat{\boldsymbol{\theta}}} = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$

Es decir, la varianza de los estimadores depende del diseño (de $\mathbf{X}$) y de σ^2 que es desconocida.

Estimación de σ^2

Dado que $\sigma^2 = \mathbb{E}(\varepsilon^2)$, parece natural estimarla mediante el promedio de los cuadrados de los residuos. El vector de residuos es

$$\begin{aligned} \mathbf{r} &= \mathbf{Y} - \hat{\mathbf{Y}} \\ &= \mathbf{Y} - \mathbf{P}\mathbf{Y}, \end{aligned} \quad \text{with } \hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\theta}} \text{ and } \mathbf{P} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$$

Veamos que, bajo el modelo Ω ,

$$S^2 = \frac{\|\mathbf{Y} - \hat{\mathbf{Y}}\|^2}{n - p} = \frac{\|\mathbf{Y} - \mathbf{P}\mathbf{Y}\|^2}{n - p} = \frac{\mathbf{Y}^T(\mathbf{I} - \mathbf{P})\mathbf{Y}}{n - p}$$

es un estimador insesgado de σ^2 .

Estimación de σ^2

Recordemos algunas propiedades de la matriz de proyección $\mathbf{P}$:

- $\mathbf{P}$ es simétrica,
- $\mathbf{P}$ es idempotente, es decir, $\mathbf{P}^2 = \mathbf{P}$,
- $tr(\mathbf{P}) = rg(\mathbf{P})$, y $rg(\mathbf{P}) = rg(\mathbf{X}) = p$ en este caso

Lo mismo ocurre con $\mathbf{I} - \mathbf{P}$, que también es una matriz de proyección y $tr(\mathbf{I} - \mathbf{P}) = n - p$.

Necesitaremos, para la demostración, el siguiente resultado:

Lema: Sea $\mathbf{x}$ un vector aleatorio n -dimensional y sea $\mathbf{A} \in \mathbb{R}^{n \times n}$ una matriz de constantes simétrica. Si $E(\mathbf{x}) = \boldsymbol{\mu}$ y su matriz de covarianza es $\boldsymbol{\Sigma}_x$ entonces

$$E(\mathbf{x}^T \mathbf{A} \mathbf{x}) = tr(\mathbf{A} \boldsymbol{\Sigma}_x) + \boldsymbol{\mu}^T \mathbf{A} \boldsymbol{\mu}$$

Demo: $x^T A x = (x - \mu)^T A (x - \mu) + \mu^T A x + x^T A \mu - \mu^T A \mu$

Aplicando esperanças, por linealidade, temos

$$E(x^T A x) = E((x - \mu)^T A (x - \mu)) + \underbrace{\mu^T A}_{\mu} E(x) + \underbrace{E(x^T)}_{\mu^T} A \mu - \cancel{\mu^T A \mu}$$

$$= E((x - \mu)^T A (x - \mu)) + \mu^T A \mu$$

Ademais,

$$E([(x - \mu)^T A] (x - \mu)) = E\left[\sum_{i=1}^n \sum_{j=1}^n (x_i - \mu_i) A_{ij} (x_j - \mu_j)\right] = \textcircled{1}$$

$$(x - \mu)^T A = (x_1 - \mu_1, \dots, x_n - \mu_n) \begin{pmatrix} A \\ \end{pmatrix} = \left(\sum_{i=1}^n (x_i - \mu_i) A_{i1}, \dots, \sum_{i=1}^n (x_i - \mu_i) A_{in} \right)$$

$$\textcircled{1} = \sum_{i=1}^n \sum_{j=1}^n A_{ij} \underbrace{E((x_i - \mu_i)(x_j - \mu_j))}_{(\Sigma_x)_{ij}} = \sum_{i=1}^n \sum_{j=1}^n A_{ij} (\Sigma_x)_{ji}$$

Σ_x é simétrica $(A \Sigma_x)_{ii}$

$$= \text{tr}(A \Sigma_x)$$

Então $E(x^T A x) = \text{tr}(A \Sigma_x) + \mu^T A \mu$ ✓



- s^2 es un estimador insesgado de σ^2 .

Demo: $s^2 = \frac{\|y - X\hat{\theta}\|^2}{n-p} = \frac{\|y - \hat{y}\|^2}{n-p} = \frac{y^T(I-P)y}{n-p}$

$I-P$ es una matriz simétrica (e idempotente).

$$E(s^2) = \frac{1}{n-p} E(y^T(I-P)y) \stackrel{\uparrow}{=} \frac{1}{n-p} \left(\text{tr}((I-P)\Sigma_y) + \mu_y^T(I-P)\mu_y \right)$$

$$\stackrel{\uparrow}{=} \frac{1}{n-p} \left(\underbrace{\text{tr}((I-P) \cdot \sigma^2 I)}_{\sigma^2 \text{tr}(I-P)} + \overset{\times \text{Lema}}{(X\theta)^T \underbrace{(I-P)X\theta}_{=0}} \right) = \sigma^2$$

$$\Sigma_y = \sigma^2 I$$

$$\mu_y = X\theta$$

$$\text{rg}(I-P) = n-p$$

porque $I-P$ proyecta en el ortogonal del subespacio generado por las columnas de X



Errores Normales

Si los errores además de ser independientes con media 0 y varianza σ^2 , son normales, es decir

$$\varepsilon_i \sim N(0, \sigma^2) \quad i = 1, \dots, n,$$

el modelo Ω puede formularse de la siguiente forma:

$$\Omega : \quad \mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I}) \quad \text{or} \quad N_n(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I})$$

En este caso puede demostrarse que el estimador de máxima verosimilitud de $\boldsymbol{\theta}$ coincide con el de mínimos cuadrados.

(Ejercicio del TP)

Normal Multivariada

Normal Multivariada

- $Z_1, \dots, Z_p$ i.i.d $Z_j \sim N(0, 1)$ $\mathbf{Z} = (Z_1, \dots, Z_p)^T$

¿Cuál es su distribución conjunta?

$$f(\mathbf{z}) = f(z_1, z_2, \dots, z_p) = f_1(z_1) f_2(z_2) \cdots f_p(z_p)$$

Normal Multivariada

- $Z_1, \dots, Z_p$ i.i.d $Z_j \sim N(0, 1)$ $\mathbf{Z} = (Z_1, \dots, Z_p)^T$

¿Cuál es su distribución conjunta?

$$\begin{aligned} f(\mathbf{z}) &= f(z_1, z_2, \dots, z_p) = f_1(z_1) f_2(z_2) \cdots f_p(z_p) \\ &= \prod_{j=1}^p f(z_j) = \prod_{j=1}^p \frac{1}{(2\pi)^{\frac{1}{2}}} e^{-\frac{1}{2}z_j^2} \end{aligned}$$

Normal Multivariada

- $Z_1, \dots, Z_p$ i.i.d $Z_j \sim N(0, 1)$ $\mathbf{Z} = (Z_1, \dots, Z_p)^T$

¿Cuál es su distribución conjunta?

$$\begin{aligned} f(\mathbf{z}) &= f(z_1, z_2, \dots, z_p) = f_1(z_1) f_2(z_2) \cdots f_p(z_p) \\ &= \prod_{j=1}^p f(z_j) = \prod_{j=1}^p \frac{1}{(2\pi)^{\frac{1}{2}}} e^{-\frac{1}{2}z_j^2} \\ &= \frac{1}{(2\pi)^{\frac{p}{2}}} e^{-\frac{1}{2} \sum_{j=1}^p z_j^2} = \frac{1}{(2\pi)^{\frac{p}{2}}} e^{-\frac{1}{2} \|\mathbf{z}\|^2} \end{aligned}$$

Normal Multivariada

- $Z_1, \dots, Z_p$ i.i.d $Z_j \sim N(0, 1)$ $\mathbf{Z} = (Z_1, \dots, Z_p)^T$


¿Cuál es su distribución conjunta?

$$\begin{aligned} f(\mathbf{z}) &= f(z_1, z_2, \dots, z_p) = f_1(z_1) f_2(z_2) \cdots f_p(z_p) \\ &= \prod_{j=1}^p f(z_j) = \prod_{j=1}^p \frac{1}{(2\pi)^{\frac{1}{2}}} e^{-\frac{1}{2}z_j^2} \\ &= \frac{1}{(2\pi)^{\frac{p}{2}}} e^{-\frac{1}{2} \sum_{j=1}^p z_j^2} = \frac{1}{(2\pi)^{\frac{p}{2}}} e^{-\frac{1}{2} \|\mathbf{z}\|^2} \\ &= \frac{1}{(2\pi)^{\frac{p}{2}}} e^{-\frac{1}{2} \mathbf{z}^T \mathbf{z}} \end{aligned}$$

Diremos que $\mathbf{Z} \sim N(\mathbf{0}_p, \mathbf{I}_p)$ o $\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I})$.

Normal Multivariada $p = 2$

Densidad de $\mathbf{Z} \sim N(\mathbf{0}_2, \mathbf{I}_2)$



¿Cuál es la conjunta?

- $X_1, \dots, X_p$ i.i.d $X_j \sim N(0, \sigma_j^2)$ $\mathbf{X} = (X_1, \dots, X_p)^T$

¿Cuál es su distribución conjunta?

Sea $\Sigma = \text{DIAG}(\sigma_1^2, \dots, \sigma_p^2)$, luego

$$f(\mathbf{x}) = f_1(x_1) f_2(x_2) \cdots f_p(x_p) = \prod_{j=1}^p \frac{1}{(2\pi\sigma_j^2)^{\frac{1}{2}}} e^{-\frac{x_j^2}{2\sigma_j^2}}$$

¿Cuál es la conjunta?

- $X_1, \dots, X_p$ i.i.d $X_j \sim N(0, \sigma_j^2)$ $\mathbf{X} = (X_1, \dots, X_p)^T$

¿Cuál es su distribución conjunta?

Sea $\Sigma = \text{DIAG}(\sigma_1^2, \dots, \sigma_p^2)$, luego $\Sigma^{-1} = \begin{pmatrix} \frac{1}{\sigma_1^2} & & 0 \\ & \ddots & \\ 0 & & \frac{1}{\sigma_p^2} \end{pmatrix}$

$$\begin{aligned} f(\mathbf{x}) &= f_1(x_1) f_2(x_2) \cdots f_p(x_p) = \prod_{j=1}^p \frac{1}{(2\pi\sigma_j^2)^{\frac{1}{2}}} e^{-\frac{x_j^2}{2\sigma_j^2}} \\ &= \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{\prod_{j=1}^p \sigma_j} e^{-\frac{1}{2} \sum_{j=1}^p \frac{x_j^2}{\sigma_j^2}} = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{\prod_{j=1}^p \sigma_j} e^{-\frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x}} \end{aligned}$$

$$\mathbf{x}^T \Sigma^{-1} \mathbf{x} = (x_1 \dots x_p) \underbrace{\begin{pmatrix} \frac{1}{\sigma_1^2} & & 0 \\ & \ddots & \\ 0 & & \frac{1}{\sigma_p^2} \end{pmatrix}}_{\text{matrix}} \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} = (x_1 \dots x_p) \begin{pmatrix} \frac{x_1}{\sigma_1^2} \\ \vdots \\ \frac{x_p}{\sigma_p^2} \end{pmatrix} = \sum_{j=1}^p \frac{x_j^2}{\sigma_j^2}$$

¿Cuál es la conjunta?

- $X_1, \dots, X_p$ i.i.d. $X_j \sim N(0, \sigma_j^2)$ $\mathbf{X} = (X_1, \dots, X_p)^T$

¿Cuál es su distribución conjunta?

Sea $\Sigma = \text{DIAG}(\sigma_1^2, \dots, \sigma_p^2)$, luego


$$\begin{aligned} f(\mathbf{x}) &= f_1(x_1) f_2(x_2) \cdots f_p(x_p) = \prod_{j=1}^p \frac{1}{(2\pi\sigma_j^2)^{\frac{1}{2}}} e^{-\frac{x_j^2}{2\sigma_j^2}} \\ &= \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{\prod_{j=1}^p \sigma_j} e^{-\frac{1}{2} \sum_{j=1}^p \frac{x_j^2}{\sigma_j^2}} = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{\prod_{j=1}^p \sigma_j} e^{-\frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x}} \\ &= \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{|\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x}} \end{aligned}$$

Diremos que $\mathbf{X} \sim N(\mathbf{0}_p, \Sigma)$ o $\mathbf{X} \sim N_p(\mathbf{0}, \Sigma)$.

Normal Multivariada $p = 2$

Densidad de $\mathbf{X} \sim N(\mathbf{0}_2, \Sigma)$, $\Sigma = \text{DIAG}(1, 0.25)$

↙ Más claro



¿Cuál es la conjunta?

- $X_1, \dots, X_p$ i.i.d. $X_j \sim N(\mu_j, \sigma_j^2)$ $\mathbf{X} = (X_1, \dots, X_p)^T$

¿Cuál es su distribución conjunta?

Sean $\Sigma = \text{DIAG}(\sigma_1^2, \dots, \sigma_p^2)$, $\mu = (\mu_1, \dots, \mu_p)^T$

$$f(\mathbf{x}) = f_1(x_1) f_2(x_2) \cdots f_p(x_p) = \prod_{j=1}^p \frac{1}{(2\pi\sigma_j^2)^{\frac{1}{2}}} e^{-\frac{(x_j - \mu_j)^2}{2\sigma_j^2}}$$

¿Cuál es la conjunta?

- $X_1, \dots, X_p$ i.i.d $X_j \sim N(\mu_j, \sigma_j^2)$ $\mathbf{X} = (X_1, \dots, X_p)^T$

¿Cuál es su distribución conjunta?

Sean $\Sigma = \text{DIAG}(\sigma_1^2, \dots, \sigma_p^2)$, $\mu = (\mu_1, \dots, \mu_p)^T$

$$\begin{aligned} f(\mathbf{x}) &= f_1(x_1) f_2(x_2) \cdots f_p(x_p) = \prod_{j=1}^p \frac{1}{(2\pi\sigma_j^2)^{\frac{1}{2}}} e^{-\frac{(x_j - \mu_j)^2}{2\sigma_j^2}} \\ &= \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{\prod_{j=1}^p \sigma_j} e^{-\frac{1}{2} \sum_{j=1}^p \frac{(x_j - \mu_j)^2}{\sigma_j^2}} \end{aligned}$$

¿Cuál es la conjunta?

- $X_1, \dots, X_p$ i.i.d. $X_j \sim N(\mu_j, \sigma_j^2)$ $\mathbf{X} = (X_1, \dots, X_p)^T$

¿Cuál es su distribución conjunta?

Sean $\Sigma = \text{DIAG}(\sigma_1^2, \dots, \sigma_p^2)$, $\mu = (\mu_1, \dots, \mu_p)^T$

$$\begin{aligned} f(\mathbf{x}) &= f_1(x_1) f_2(x_2) \cdots f_p(x_p) = \prod_{j=1}^p \frac{1}{(2\pi\sigma_j^2)^{\frac{1}{2}}} e^{-\frac{(x_j - \mu_j)^2}{2\sigma_j^2}} \\ &= \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{\prod_{j=1}^p \sigma_j} e^{-\frac{1}{2} \sum_{j=1}^p \frac{(x_j - \mu_j)^2}{\sigma_j^2}} \\ &= \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{|\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu)} \end{aligned}$$

Diremos que $\mathbf{X} \sim N(\mu, \Sigma)$.

Definición 1

Sean $\boldsymbol{\mu} \in \mathbb{R}^p$ y $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ **simétrica y definida positiva**.

Se dice que $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si su densidad está dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{|\boldsymbol{\Sigma}|^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})}$$

Definición 1

Sean $\boldsymbol{\mu} \in \mathbb{R}^p$ y $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ **simétrica y definida positiva**.

Se dice que $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si su densidad está dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{|\boldsymbol{\Sigma}|^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})}$$

- Si $\mathbf{x} \sim N(\mathbf{0}, \text{diag}(\lambda_1, \dots, \lambda_p))$

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{\prod_{j=1}^p \lambda_j^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} \sum_{j=1}^p \frac{x_j^2}{\lambda_j} \right\}$$

Por lo tanto, $x_1, \dots, x_p$ son independientes y $x_j \sim N(0, \lambda_j)$.

Definición 1

Sean $\boldsymbol{\mu} \in \mathbb{R}^p$ y $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ **simétrica y definida positiva**.

Se dice que $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si su densidad está dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{|\boldsymbol{\Sigma}|^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})}$$

- Si $\mathbf{x} \sim N(\mathbf{0}, \text{diag}(\lambda_1, \dots, \lambda_p))$

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{\prod_{j=1}^p \lambda_j^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} \sum_{j=1}^p \frac{x_j^2}{\lambda_j} \right\}$$

Por lo tanto, $x_1, \dots, x_p$ son independientes y $x_j \sim N(0, \lambda_j)$.

- En particular, si $\mathbf{x} \sim N(\mathbf{0}, \mathbf{I}_p)$, $x_1, \dots, x_p$ son i.i.d. $N(0, 1)$.

Normal Multivariada

Sean $\boldsymbol{\mu} \in \mathbb{R}^p$ y $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ **simétrica y definida positiva**.

Se dice que $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si su densidad está dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{|\boldsymbol{\Sigma}|^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})}$$

Observación: La densidad conjunta depende de $\mathbf{x}$ a través de

$$D^2 = (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}),$$

que es el cuadrado de la **distancia de Mahalanobis**


Distancia de Mahalanobis $(x, y) \sim \mathcal{N}(\mu, \Sigma)$ $= \frac{x^2}{a^2} + \frac{y^2}{b^2} = 1$

$\Sigma = \begin{pmatrix} a^2 & 0 \\ 0 & b^2 \end{pmatrix} = \Sigma^{-1} = \begin{pmatrix} \frac{1}{a^2} & 0 \\ 0 & \frac{1}{b^2} \end{pmatrix}$

- La distancia de Mahalanobis de un punto x a la media μ es D , siendo

$$D^2 = (x - \mu)^T \Sigma^{-1} (x - \mu)$$

- De esta forma, dos puntos tienen la misma distancia de Mahalanobis si están en el mismo elipsoide centrado en μ



Propiedad: Sea $\mathbf{x} = (x_1, \dots, x_p)^T \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, entonces $x_1, \dots, x_p$ son independientes $\iff \boldsymbol{\Sigma}$ es diagonal.

Veremos el caso $p=2$

$$\text{Obs: } (\boldsymbol{\Sigma})_{ij} = \text{cov}(x_i, x_j) \Rightarrow \boldsymbol{\Sigma} = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$

$$\underline{p=2} \quad \boldsymbol{\Sigma} = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix} \quad \rho: \text{ correlación entre } x_1 \text{ y } x_2.$$

$$\det \boldsymbol{\Sigma} = \sigma_1^2 \sigma_2^2 - \rho^2 \sigma_1^2 \sigma_2^2 = \sigma_1^2 \sigma_2^2 (1 - \rho^2)$$

$$\underline{\text{Recu:}} \quad A = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \Rightarrow A^{-1} = \frac{1}{\det(A)} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

$$\Rightarrow \boldsymbol{\Sigma}^{-1} = \frac{1}{\det(\boldsymbol{\Sigma})} \begin{pmatrix} \sigma_2^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_1^2 \end{pmatrix} \Rightarrow$$

Propiedad: Sea $\mathbf{x} = (x_1, \dots, x_p)^T \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, entonces $x_1, \dots, x_p$ son independientes $\iff \boldsymbol{\Sigma}$ es diagonal.

Caso $p = 2$

Sea $\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} \in \mathbb{R}^2$ y $\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$ definida positiva ($|\rho| < 1$), luego

$$f(\mathbf{x}) = \frac{1}{2\pi} \frac{1}{\sigma_1\sigma_2(1-\rho^2)^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2\underbrace{(1-\rho^2)}_{=1}} \left[\left(\frac{x_1 - \mu_1}{\sigma_1} \right)^2 + \left(\frac{x_2 - \mu_2}{\sigma_2} \right)^2 - 2\rho \left(\frac{x_1 - \mu_1}{\sigma_1} \right) \left(\frac{x_2 - \mu_2}{\sigma_2} \right) \right] \right\}$$

$\Rightarrow$ si $\boldsymbol{\Sigma}$ es diagonal, entonces $\rho=0$


$\Rightarrow$ se factoriza y probamos ($\Leftarrow$) ✓

($\Rightarrow$) inmediata porque si x_1 y x_2 son indep $\Rightarrow \text{cov}(x_1, x_2) = 0$.


□

Caso $p = 2$, $\mathbf{x} = (x_1, x_2)^T \sim N(\mathbf{0}, \Sigma)$

$$\Sigma = \mathbf{I}_2$$




$$\Sigma = \begin{pmatrix} 1 & 0 \\ 0 & 0.25 \end{pmatrix}$$




Caso $p = 2$, $\mathbf{x} = (x_1, x_2)^T \sim N(\mathbf{0}, \mathbf{I}_2)$


$$\rho = 0$$




$$\rho = 0.3$$



$$\rho = 0.6$$




$$\rho = 0.9$$




Caso $p = 2$, $\mathbf{x} = (x_1, x_2)^T \sim N(\mathbf{0}, \mathbf{I}_2)$


$$\rho = 0$$




$$\rho = -0.3$$



$$\rho = -0.6$$



$$\rho = -0.9$$



Propiedades

- Si $\mathbf{x} \sim N(\mathbf{0}, \mathbf{I}_p) \implies \varphi_{\mathbf{x}}(\mathbf{t}) = \exp\{-\frac{1}{2}\|\mathbf{t}\|^2\}$

Propiedades

- Si $\mathbf{x} \sim N(\mathbf{0}, \mathbf{I}_p) \implies \varphi_{\mathbf{x}}(\mathbf{t}) = \exp\{-\frac{1}{2}\|\mathbf{t}\|^2\}$
- Si $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \implies \varphi_{\mathbf{x}}(\mathbf{t}) = \exp\{i\mathbf{t}^T \boldsymbol{\mu}\} \exp\{-\frac{1}{2}\mathbf{t}^T \boldsymbol{\Sigma} \mathbf{t}\}$

Propiedades

- Si $\mathbf{x} \sim N(\mathbf{0}, \mathbf{I}_p) \implies \varphi_{\mathbf{x}}(\mathbf{t}) = \exp\{-\frac{1}{2}\|\mathbf{t}\|^2\}$

- Si $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \implies \varphi_{\mathbf{x}}(\mathbf{t}) = \exp\{i\mathbf{t}^T \boldsymbol{\mu}\} \exp\{-\frac{1}{2}\mathbf{t}^T \boldsymbol{\Sigma} \mathbf{t}\}$

- $\mathbf{x} = (x_1, \dots, x_p)^T \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \implies \mathbb{E}(\mathbf{x}) = \boldsymbol{\mu}$ y
 $\text{Var}(\mathbf{x}) = \text{COV}(\mathbf{x}) = (\text{COV}(x_i, x_j))_{1 \leq i, j \leq p} = \boldsymbol{\Sigma}$

Propiedades

- Si $\mathbf{x} \sim N(\mathbf{0}, \mathbf{I}_p) \implies \varphi_{\mathbf{x}}(\mathbf{t}) = \exp\{-\frac{1}{2}\|\mathbf{t}\|^2\}$
- Si $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \implies \varphi_{\mathbf{x}}(\mathbf{t}) = \exp\{i\mathbf{t}^T \boldsymbol{\mu}\} \exp\{-\frac{1}{2}\mathbf{t}^T \boldsymbol{\Sigma} \mathbf{t}\}$
- $\mathbf{x} = (x_1, \dots, x_p)^T \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \implies \mathbb{E}(\mathbf{x}) = \boldsymbol{\mu}$ y
 $\text{COV}(\mathbf{x}) = (\text{COV}(x_i, x_j))_{1 \leq i, j \leq p} = \boldsymbol{\Sigma}$
- $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si y sólo si $\mathbf{x} = \mathbf{B}\mathbf{z} + \boldsymbol{\mu}$, donde $\mathbf{z} \sim N(\mathbf{0}, \mathbf{I}_p)$ y $\mathbf{B}$ es una matriz de $p \times p$ no singular tal que $\mathbf{B}\mathbf{B}^T = \boldsymbol{\Sigma}$.

Propiedades

- Si $\mathbf{x} \sim N(\mathbf{0}, \mathbf{I}_p) \implies \varphi_{\mathbf{x}}(\mathbf{t}) = \exp\{-\frac{1}{2}\|\mathbf{t}\|^2\}$
- Si $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \implies \varphi_{\mathbf{x}}(\mathbf{t}) = \exp\{i\mathbf{t}^T \boldsymbol{\mu}\} \exp\{-\frac{1}{2}\mathbf{t}^T \boldsymbol{\Sigma} \mathbf{t}\}$
- $\mathbf{x} = (x_1, \dots, x_p)^T \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \implies \mathbb{E}(\mathbf{x}) = \boldsymbol{\mu}$ y
 $\text{COV}(\mathbf{x}) = (\text{COV}(x_i, x_j))_{1 \leq i, j \leq p} = \boldsymbol{\Sigma}$
- $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si y sólo si $\mathbf{x} = \mathbf{B}\mathbf{z} + \boldsymbol{\mu}$, donde $\mathbf{z} \sim N(\mathbf{0}, \mathbf{I}_p)$ y
 $\mathbf{B}$ es una matriz de $p \times p$ no singular tal que $\mathbf{B}\mathbf{B}^T = \boldsymbol{\Sigma}$.
- Sea $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Dada $\mathbf{A} \in \mathbb{R}^{q \times p}$, $rg(\mathbf{A}) = q \implies$
 $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b} \sim N(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T)$.
 $\mathbf{x} \in \mathbb{R}^p$ $\mathbf{y} \in \mathbb{R}^q$

Propiedades

- Si $\mathbf{x} \sim N(\mathbf{0}, \mathbf{I}_p) \implies \varphi_{\mathbf{x}}(\mathbf{t}) = \exp\{-\frac{1}{2}\|\mathbf{t}\|^2\}$
- Si $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \implies \varphi_{\mathbf{x}}(\mathbf{t}) = \exp\{i\mathbf{t}^T \boldsymbol{\mu}\} \exp\{-\frac{1}{2}\mathbf{t}^T \boldsymbol{\Sigma} \mathbf{t}\}$
- $\mathbf{x} = (x_1, \dots, x_p)^T \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \implies \mathbb{E}(\mathbf{x}) = \boldsymbol{\mu}$ y
 $\text{COV}(\mathbf{x}) = (\text{COV}(x_i, x_j))_{1 \leq i, j \leq p} = \boldsymbol{\Sigma}$
- $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si y sólo si $\mathbf{x} = \mathbf{B}\mathbf{z} + \boldsymbol{\mu}$, donde $\mathbf{z} \sim N(\mathbf{0}, \mathbf{I}_p)$ y $\mathbf{B}$ es una matriz de $p \times p$ no singular tal que $\mathbf{B}\mathbf{B}^T = \boldsymbol{\Sigma}$.
- Sea $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Dada $\mathbf{A} \in \mathbb{R}^{q \times p}$, $\text{rg}(\mathbf{A}) = q \implies$
 $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b} \sim N(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T)$.
- $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \iff \mathbf{a}^T \mathbf{x} \sim N(\mathbf{a}^T \boldsymbol{\mu}, \mathbf{a}^T \boldsymbol{\Sigma} \mathbf{a}), \forall \mathbf{a} \in \mathbb{R}^p$

Normal Multivariada

Definición 2

Se dice que $\mathbf{x}$ es normal multivariada si y sólo si $\forall \mathbf{a} \in \mathbb{R}^p$ se tiene que $\mathbf{a}^T \mathbf{x}$ es normal univariada.

Normal Multivariada

Definición 2

Se dice que $\mathbf{x}$ es normal multivariada si y sólo si $\forall \mathbf{a} \in \mathbb{R}^p$ se tiene que $\mathbf{a}^T \mathbf{x}$ es normal univariada.

Definición 3

Se dice que $\mathbf{x}$ es normal multivariada si y sólo si $\exists \boldsymbol{\mu} \in \mathbb{R}^p$, $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ simétrica $\boldsymbol{\Sigma} > 0$, tal que

$$\varphi_{\mathbf{x}}(\mathbf{t}) = \exp\{i\mathbf{t}^T \boldsymbol{\mu}\} \exp\left\{-\frac{1}{2}\mathbf{t}^T \boldsymbol{\Sigma} \mathbf{t}\right\}$$

Casos Particulares

En definitiva,

- Combinaciones lineales de sus componentes también tiene distribución normal:
Si $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ y $\mathbf{a} \in \mathbb{R}^p$, entonces $\mathbf{a}^T \mathbf{x} \sim N(\mathbf{a}^T \boldsymbol{\mu}, \mathbf{a}^T \boldsymbol{\Sigma} \mathbf{a})$.
- Sea $\mathbf{x}^T = (x_1, \dots, x_p)$ un vector p -dimensional con distribución normal multivariada, luego la distribución marginal de cualquier subconjunto de componentes tiene distribución normal multivariada.
- En particular, cada componente es normal:
Si $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ y $\mathbf{a} = \mathbf{e}_i \in \mathbb{R}^p$ es el i -ésimo vector canónico en $\mathbb{R}^p$, entonces $\mathbf{e}_i^T \mathbf{x} = x_i \sim N(\mu_i, \sigma_i^2)$, donde $\Sigma_{ii} = \sigma_i^2$.

Relación con la χ^2

$$\underline{\text{def}} \quad \mathcal{N}_p^{\perp}(\mathbf{x}|\boldsymbol{\mu}) \sim \mathcal{N}_p(\mathbf{0}, \mathbf{I})$$

- Si $\mathbf{x}$ es $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, entonces

$$(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \sim \chi_p^2$$

- ¿Cómo quedaría esto en el caso $N(\mathbf{0}, \mathbf{I}_p)$?

$$\boldsymbol{\Sigma}^{-1} = \mathbf{I} \quad \boldsymbol{\mu} = \vec{0} \quad \boldsymbol{\Sigma}$$

$$(\mathbf{x} - \vec{0})^T \mathbf{I} (\mathbf{x} - \vec{0}) = \sum_{i=1}^p x_i^2 \nearrow \chi_p^2$$

$$x_i \sim \mathcal{N}(0, 1) \text{ indep}$$