

Estimación puntual

Métodos

April 8, 2026

Estimador de mínimos cuadrados

Definition 1.1

Sea $X_1, \dots, X_n$ una muestra aleatoria que sigue el modelo de posición $X_i = \theta_0 + \epsilon_i$ con $\mathbb{E}(\epsilon_i) = 0$. El estimador de mínimos cuadrados de θ_0 se define como

$$\hat{\theta} = \operatorname{argmin}_{\theta} \sum_{i=1}^n (X_i - \theta)^2.$$

Proposición 1.2

Sea $X_1, \dots, X_n$ una muestra aleatoria con esperanza finita θ_0 . El estimador de mínimos cuadrados de θ_0 es $\bar{X}$.

Proof.



Estimador de mínimos desviaciones absolutas

Definition 1.3

Sea $X_1, \dots, X_n$ una muestra aleatoria que sigue el modelo de posición $X_i = \theta_0 + \epsilon_i$ donde ϵ_i tiene una distribución simétrica alrededor de 0. El estimador de mínimas desviaciones absolutas de θ_0 se define como

$$\hat{\theta} = \operatorname{argmin}_{\theta} \sum_{i=1}^n |X_i - \theta|.$$

Proposición 1.4

Sea $X_1, \dots, X_n$ una muestra aleatoria que sigue el modelo de posición $X_i = \theta_0 + \epsilon_i$ donde ϵ_i tiene una distribución simétrica alrededor de 0. El estimador de mínimas desviaciones absolutas de θ_0 es la mediana muestral de $X_1 \dots X_n$.

Proof.

No la veremos en el curso



M-estimadores

Definition 1.5

Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución $F(., \theta_0)$.
Un M-estimador de θ_0 es un estimador definido como

$$\hat{\theta} = \operatorname{argmin}_{\theta} \sum_{i=1}^n \rho(X_i, \theta)$$

Observación 1.6

Los estimadores de mínimos cuadrados, de mínimas desviaciones absolutas y de máxima verosimilitud son M-estimadores.

Criterios de bondad de un estimador

Sesgo, varianza y error cuadrático medio

April 8, 2026

Criterios de bondad de un estimador: Sesgo

Definition 1.7

Sea $\mathbf{X}_n = (X_1 \dots X_n)$ una muestra aleatoria de una distribución $F \in \mathcal{F}$, $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$ y supongamos que queremos estimar $q(\theta)$, una función real del parámetro de F .

Criterios de bondad de un estimador: Sesgo

Definition 1.7

Sea $\mathbf{X}_n = (X_1 \dots X_n)$ una muestra aleatoria de una distribución $F \in \mathcal{F}$, $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$ y supongamos que queremos estimar $q(\theta)$, una función real del parámetro de F .

Un estimador de $q(\theta)$, $T_n = T(\mathbf{X}_n)$, se dice **insesgado** para $q(\theta)$ si

$$\mathbb{E}_\theta(T_n) = q(\theta) \text{ para todo } \theta \in \Theta.$$

Caso contrario, decimos que es **sesgado**.

Criterios de bondad de un estimador: Sesgo

Definition 1.7

Sea $\mathbf{X}_n = (X_1 \dots X_n)$ una muestra aleatoria de una distribución $F \in \mathcal{F}$, $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$ y supongamos que queremos estimar $q(\theta)$, una función real del parámetro de F .

Un estimador de $q(\theta)$, $T_n = T(\mathbf{X}_n)$, se dice **insesgado** para $q(\theta)$ si

$$\mathbb{E}_\theta(T_n) = q(\theta) \text{ para todo } \theta \in \Theta.$$

Caso contrario, decimos que es **sesgado**.

Un estimador de $q(\theta)$, T_n , se dice **asintóticamente insesgado** para $q(\theta)$ si

$$\lim_{n \rightarrow \infty} \mathbb{E}_\theta(T_n) = q(\theta) \text{ para todo } \theta \in \Theta.$$

Criterios de bondad de un estimador: Sesgo

Definition 1.7

Sea $\mathbf{X}_n = (X_1 \dots X_n)$ una muestra aleatoria de una distribución $F \in \mathcal{F}$, $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$ y supongamos que queremos estimar $q(\theta)$, una función real del parámetro de F .

Un estimador de $q(\theta)$, $T_n = T(\mathbf{X}_n)$, se dice **insesgado** para $q(\theta)$ si

$$\mathbb{E}_\theta(T_n) = q(\theta) \text{ para todo } \theta \in \Theta.$$

Caso contrario, decimos que es **sesgado**.

Un estimador de $q(\theta)$, T_n , se dice **asintóticamente insesgado** para $q(\theta)$ si

$$\lim_{n \rightarrow \infty} \mathbb{E}_\theta(T_n) = q(\theta) \text{ para todo } \theta \in \Theta.$$

Llamamos **sesgo** de un estimador T_n de $q(\theta)$ a

$$\mathbb{B}_\theta(T_n) = \mathbb{E}_\theta(T_n) - q(\theta).$$

Ejemplo: Caso general - F con media y varianza

Ejemplo 1.8

Sea $\mathbf{X}_n = (X_1 \dots X_n)$ una muestra aleatoria de una distribución $F \in \mathcal{F}$, y supongamos que queremos estimar $\mu = \mathbb{E}_F(X_1)$ y $\sigma^2 = \mathbb{V}_F(X_1)$.

- Vimos que los estimadores de momentos son:

$$\begin{aligned}\hat{\mu} &= \bar{X}_n \\ \hat{\sigma}^2 &= \frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{n} = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2\end{aligned}$$

- ¿Son insesgados?

Ejemplo: Calculemos el sesgo de cada uno

Ejemplo 1.8 (Continuación)

- $E_F(\bar{X}_n) = \frac{1}{n} \mathbb{E}_F\left(\sum_{i=1}^n X_i\right) = \frac{n}{n} \mathbb{E}_F(X_1) = \mathbb{E}_F(X_1) = \mu$
 $\Rightarrow \bar{X}_n$ es insesgado

Ejemplo: Calculemos el sesgo de cada uno

Ejemplo 1.8 (Continuación)

- $E_F(\bar{X}_n) = \frac{1}{n} \mathbb{E}_F\left(\sum_{i=1}^n X_i\right) = \frac{n}{n} \mathbb{E}_F(X_1) = \mathbb{E}_F(X_1) = \mu$
 $\Rightarrow \bar{X}_n$ es insesgado
- $\mathbb{E}_F\left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2\right)$

Ejemplo: Calculemos el sesgo de cada uno

Ejemplo 1.8 (Continuación)

- $E_F(\bar{X}_n) = \frac{1}{n} \mathbb{E}_F\left(\sum_{i=1}^n X_i\right) = \frac{n}{n} \mathbb{E}_F(X_1) = \mathbb{E}_F(X_1) = \mu$

$\Rightarrow \bar{X}_n$ es insesgado

- $\mathbb{E}_F\left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2\right)$

$$= \frac{1}{n} \sum_{i=1}^n \mathbb{E}_F(X_i^2) - \mathbb{E}_F(\bar{X}^2) = \frac{n}{n} E_F(X_1^2) - \mathbb{E}_F(\bar{X}^2)$$

Ejemplo: Calculemos el sesgo de cada uno

Ejemplo 1.8 (Continuación)

- $E_F(\bar{X}_n) = \frac{1}{n} \mathbb{E}_F\left(\sum_{i=1}^n X_i\right) = \frac{n}{n} \mathbb{E}_F(X_1) = \mathbb{E}_F(X_1) = \mu$

$\Rightarrow \bar{X}_n$ es insesgado

- $\mathbb{E}_F\left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2\right)$

$$= \frac{1}{n} \sum_{i=1}^n \mathbb{E}_F(X_i^2) - \mathbb{E}_F(\bar{X}^2) = \frac{n}{n} \mathbb{E}_F(X_1^2) - \mathbb{E}_F(\bar{X}^2)$$

$$= \mathbb{V}_F(X_1) + \mathbb{E}_F(X_1)^2 - \left\{ \mathbb{V}_F(\bar{X}) + \mathbb{E}_F(\bar{X})^2 \right\}$$

Ejemplo: Calculemos el sesgo de cada uno

Ejemplo 1.8 (Continuación)

- $E_F(\bar{X}_n) = \frac{1}{n} \mathbb{E}_F\left(\sum_{i=1}^n X_i\right) = \frac{n}{n} \mathbb{E}_F(X_1) = \mathbb{E}_F(X_1) = \mu$

$\Rightarrow \bar{X}_n$ es insesgado

- $\mathbb{E}_F\left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2\right)$

$$= \frac{1}{n} \sum_{i=1}^n \mathbb{E}_F(X_i^2) - \mathbb{E}_F(\bar{X}^2) = \frac{n}{n} \mathbb{E}_F(X_1^2) - \mathbb{E}_F(\bar{X}^2)$$

$$= \mathbb{V}_F(X_1) + \mathbb{E}_F(X_1)^2 - \left\{ \mathbb{V}_F(\bar{X}) + \mathbb{E}_F(\bar{X})^2 \right\}$$

$$= \mathbb{V}_F(X_1) + \mathbb{E}_F(X_1)^2 - \frac{\mathbb{V}_F(X_1)}{n} - \mathbb{E}_F(X_1)^2 = \frac{n-1}{n} \mathbb{V}_F(X_1)$$

Ejemplo: Calculemos el sesgo de cada uno

Ejemplo 1.8 (Continuación)

- *El sesgo es*

$$\begin{aligned}\mathbb{E}_F \left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \right) &= \frac{n-1}{n} \mathbb{V}_F(X_1) - \mathbb{V}_F(X_1) \\ &= -\mathbb{V}_F(X_1)/n < 0\end{aligned}$$

*$\Rightarrow$ el estimador de momentos es sesgado
siempre subestima la varianza*

Ejemplo: Calculemos el sesgo de cada uno

Ejemplo 1.8 (Continuación)

- *El sesgo es*

$$\begin{aligned}\mathbb{E}_F \left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \right) &= \frac{n-1}{n} \mathbb{V}_F(X_1) - \mathbb{V}_F(X_1) \\ &= -\mathbb{V}_F(X_1)/n < 0\end{aligned}$$

*⇒ el estimador de momentos es sesgado
siempre subestima la varianza*

- *El sesgo puede corregirse*

$$\frac{n}{n-1} \widehat{\sigma^2} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = S^2$$

*que hemos llamado **varianza muestral**.*

Error cuadrático medio

Definition 1.9

Sea $\mathbf{X}_n = (X_1 \dots X_n)$ una m. a. de una distribución $F \in \mathcal{F}$,
 $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$ y queremos estimar $q(\theta)$.

Sea $T_n = T(\mathbf{X}_n)$ un estimador de $q(\theta)$. Llamamos error de estimación a

$$T_n - q(\theta)$$

Error cuadrático medio

Definition 1.9

Sea $\mathbf{X}_n = (X_1 \dots X_n)$ una m. a. de una distribución $F \in \mathcal{F}$,
 $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$ y queremos estimar $q(\theta)$.

Sea $T_n = T(\mathbf{X}_n)$ un estimador de $q(\theta)$. Llamamos error de estimación a

$$T_n - q(\theta) \quad \text{es una v.a.}$$

y **error cuadrático medio** a

$$ECM_{\theta}(T_n) = \mathbb{E}_{\theta} \left((T_n - q(\theta))^2 \right)$$

Error cuadrático medio

Definition 1.9

Sea $\mathbf{X}_n = (X_1 \dots X_n)$ una m. a. de una distribución $F \in \mathcal{F}$, $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$ y queremos estimar $q(\theta)$.

Sea $T_n = T(\mathbf{X}_n)$ un estimador de $q(\theta)$. Llamamos error de estimación a

$$T_n - q(\theta) \quad \text{es una v.a.}$$

y **error cuadrático medio** a

$$ECM_{\theta}(T_n) = \mathbb{E}_{\theta} \left((T_n - q(\theta))^2 \right)$$

El **Error Cuadrático Medio** da un criterio para determinar si un estimador T_n de $q(\theta)$ es mejor que otro W_n , pues basta verificar si

$$ECM_{\theta}(T_n) \leq ECM_{\theta}(W_n) \quad \forall \theta \in \Theta$$

Compromiso sesgo-varianza

Theorem 1.10

$$ECM_{\theta}(T_n) = \mathbb{V}_{\theta}(T_n) + (\mathbb{B}_{\theta}(T_n))^2$$

Compromiso sesgo-varianza

Theorem 1.10

$$ECM_{\theta}(T_n) = \mathbb{V}_{\theta}(T_n) + (\mathbb{B}_{\theta}(T_n))^2$$

Proof.

$$\begin{aligned} ECM_{\theta}(T_n) &= \mathbb{E}_{\theta} [(T_n - q(\theta))^2] \\ &= \mathbb{V}_{\theta} [(T_n - q(\theta))] + [\mathbb{E}_{\theta}(T_n - q(\theta))]^2 \\ &= \mathbb{V}_{\theta}(T_n) + [\mathbb{E}_{\theta}(T_n) - q(\theta)]^2 \\ &= \mathbb{V}_{\theta}(T_n) + (\mathbb{B}_{\theta}(T_n))^2, \text{ como queríamos demostrar.} \end{aligned}$$



Error cuadrático medio de estimadores insesgados

Notemos que

- si el estimador T_n es insesgado, $ECM_\theta(T_n) = \mathbb{V}_\theta(T_n)$
- comparar el ECM de dos estimadores insesgados, se reduce a comparar sus varianzas.

Ejemplo: estimadores de θ en el caso $U[0, \theta]$

Ejemplo 1.11

(1) *Estimador de momentos: $\hat{\theta} = 2\bar{X}_n$. Para todo θ tenemos*

$$E_{\theta}(\hat{\theta}) = 2E_{\theta}(\bar{X}_n) = 2 \frac{\theta}{2} = \theta$$

$$V_{\theta}(\hat{\theta}) = 4\mathbb{V}_{\theta}(\bar{X}_n) = 4 \frac{\theta^2}{12n} = \frac{\theta^2}{3n}$$

$$ECM_{\theta}(\hat{\theta}) = \mathbb{V}_{\theta}(\hat{\theta}) = \frac{\theta^2}{3n}$$

Ejemplo: estimadores de θ en el caso $U[0, \theta]$

Ejemplo 1.11

(1) *Estimador de momentos: $\hat{\theta} = 2\bar{X}_n$. Para todo θ tenemos*

$$E_{\theta}(\hat{\theta}) = 2E_{\theta}(\bar{X}_n) = 2 \frac{\theta}{2} = \theta$$

$$V_{\theta}(\hat{\theta}) = 4V_{\theta}(\bar{X}_n) = 4 \frac{\theta^2}{12n} = \frac{\theta^2}{3n}$$

$$ECM_{\theta}(\hat{\theta}) = V_{\theta}(\hat{\theta}) = \frac{\theta^2}{3n}$$

(2) *Estimador de máxima verosimilitud: $\tilde{\theta} = \max \{X_1, \dots, X_n\}$*

Ejercicio:

$$ECM_{\theta}(\tilde{\theta}) = \frac{n}{(n+2)(n+1)^2} \theta^2 + \left(\frac{n}{n+1} \theta - \theta \right)^2 = \frac{2\theta^2}{(n+1)(n+2)}$$

$$\frac{2\theta^2}{(n+1)(n+2)} \leq \frac{\theta^2}{3n} \quad \forall n$$

Distribución de muestreo y error standard

Definition 1.12

- La distribución de T_n se llama **distribución de muestreo**
- La desviación estandar de T_n se llama **error standard**, es por lo general desconocida y se utiliza un estimador del error estandar, lo notamos $\hat{se}(T_n)$.
 - Error standard: $se(T_n) = \sqrt{\text{Var}_\theta(T_n)}$
 - Estimador del error standard: $\hat{se}(T_n) = \sqrt{\widehat{\text{Var}_\theta(T_n)}}$

Comportamiento Asintótico de un Estimador

Consistencia

April 8, 2026

Consistencia

Tenemos:

$\mathbf{X}_n = (X_1 \dots X_n)$ m.a. $X_i \sim F$, $F \in \mathcal{F}$, $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$.

Queremos estimar $q(\theta)$.

Sea $T_n = T(X_1 \dots X_n)$ un estimador de $q(\theta)$

Definition 1.13

T_n es una sucesión débilmente consistente de estimadores de $q(\theta)$ si

$$T_n \xrightarrow{P} q(\theta)$$

o sea, si para todo $\varepsilon > 0$ y $\theta \in \Theta$

$$\lim_{n \rightarrow \infty} \mathbb{P}_\theta(|T_n - q(\theta)| > \varepsilon) = 0.$$

Consistencia

Tenemos:

$\mathbf{X}_n = (X_1 \dots X_n)$ m.a. $X_i \sim F$, $F \in \mathcal{F}$, $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$.

Queremos estimar $q(\theta)$.

Sea $T_n = T(X_1 \dots X_n)$ un estimador de $q(\theta)$

Definition 1.14

T_n es una sucesión fuertemente consistente de estimadores de $q(\theta)$ si

$$T_n \xrightarrow{c.s.} q(\theta)$$

es decir si $\lim_{n \rightarrow \infty} T_n = q(\theta)$ c.s. (o c.t.p.), o sea si para todo $\theta \in \Theta$

$$\mathbb{P}_\theta \left(w \in \mathbf{\Omega} : \lim_{n \rightarrow \infty} T_n = q(\theta) \right) = 1,$$

Ley Fuerte de los Grandes Números

- **Ley fuerte:** Sean $X_1, X_2, \dots$ v.a. independientes de a pares e idénticamente distribuidas con $E|X_1| < \infty$. Si $E(X_1) = \mu$, entonces

$$\overline{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{c.s.} \mu .$$

Ver libro “Probability theory and examples” de Rich Durrett.

Ley Débil de los Grandes Números

- **Ley débil:** Sean $\{X_n\}_{n \geq 1}$ variables aleatorias no correlacionadas, es decir $\text{Cov}(X_i, X_j) = 0$ para $i \neq j$, tales que $\mathbb{E}(X_j) = \mu_j$ y $\text{Var}(X_j) = \sigma_j^2$.

Denotemos $\bar{\mu}_n = \frac{1}{n} \sum_{j=1}^n \mu_j = \mathbb{E}(\bar{X}_n)$.

Entonces, si $\lim_{n \rightarrow \infty} \frac{1}{n^2} \sum_{j=1}^n \sigma_j^2 = 0$, tenemos que

$$\bar{X}_n - \bar{\mu}_n \xrightarrow{p} 0 .$$

Aplicación en Estadística

Dada una muestra aleatoria $X_1, \dots, X_n$, tenemos que:

- Primer momento: por la L.G.N. fuerte si $E|X_i| < \infty$, tenemos en forma directa un estimador consistente para $\mu = E(X_i)$, ya que si tomamos $\hat{\mu} = \bar{X}_n$, tenemos que

$$\bar{X}_n \xrightarrow{c.s.} \mu$$

y por lo tanto,

$$\bar{X}_n \xrightarrow{P} \mu$$

- Segundo momento: también da un estimador consistente para, por ejemplo, $\theta = E(X_i^2) (= \mu_2) < \infty$, ya que como antes

$$\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} E(X_i^2) = \theta$$

Recordemos algunas propiedades útiles

Algunas transformaciones preservan la convergencia casi segura y en probabilidad.

Si g es una función continua en μ , entonces

- $X_n \xrightarrow{c.s.} \mu \Rightarrow g(X_n) \xrightarrow{c.s.} g(\mu)$

Además, si $X_n \xrightarrow{c.s.} X$ y $Y_n \xrightarrow{c.s.} Y$,

- $X_n \pm Y_n \xrightarrow{c.s.} X \pm Y$

- $X_n Y_n \xrightarrow{c.s.} XY$

- si además $\mathbb{P}(Y = 0) = 0$, $X_n/Y_n \xrightarrow{c.s.} X/Y$

Estos resultados también son válidos en probabilidad.

Estimación de $\sigma^2 = \mathbb{V}ar_F(X_i)$

- ¿Cómo estimamos σ^2 ?
- Un estimador posible es:

$$\hat{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

(se llega por el método de los momentos y por el de máxima verosimilitud)

Estimación de σ^2

- Por la L.G.N., $\bar{X}_n \xrightarrow{c.s.} \mu$ y $\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{c.s.} \mathbb{E}(X_1^2)$
- Como las funciones continuas preservan la convergencia c.s., $\bar{X}_n \xrightarrow{c.s.} \mathbb{E}(X_1)$, luego $\bar{X}_n^2 \xrightarrow{c.s.} \mathbb{E}^2(X_1)$ y en consecuencia

Estimación de σ^2

- Por la L.G.N., $\bar{X}_n \xrightarrow{c.s.} \mu$ y $\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{c.s.} \mathbb{E}(X_1^2)$
- Como las funciones continuas preservan la convergencia c.s., $\bar{X}_n \xrightarrow{c.s.} \mathbb{E}(X_1)$, luego $\bar{X}_n^2 \xrightarrow{c.s.} \mathbb{E}^2(X_1)$ y en consecuencia

$$\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \xrightarrow{c.s.} \mathbb{E}(X_1^2) - \mathbb{E}^2(X_1) = \mathbb{V}ar(X_1) = \sigma^2$$

Estimación de σ^2

- Por la L.G.N., $\bar{X}_n \xrightarrow{c.s.} \mu$ y $\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{c.s.} \mathbb{E}(X_1^2)$
- Como las funciones continuas preservan la convergencia c.s., $\bar{X}_n \xrightarrow{c.s.} \mathbb{E}(X_1)$, luego $\bar{X}_n^2 \xrightarrow{c.s.} \mathbb{E}^2(X_1)$ y en consecuencia

$$\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \xrightarrow{c.s.} \mathbb{E}(X_1^2) - \mathbb{E}^2(X_1) = \text{Var}(X_1) = \sigma^2$$

- Varianza Muestral: $S_n^2 = \frac{n}{n-1} \hat{\sigma}_n^2$.

Como la sucesión $\frac{n}{n-1} \rightarrow 1$, S_n^2 también resulta consistente.

Error cuadrático medio y consistencia

Theorem 1.15

Sea T_n un estimador de $q(\theta)$ basado en una muestra aleatoria de tamaño n . Si $ECM_\theta(T_n) \rightarrow 0$ cuando $n \rightarrow \infty$, entonces T_n es un estimador débilmente consistente de $q(\theta)$.

Proof.

Recordemos la **desigualdad de Markov**: Sea $h : \mathbb{R} \rightarrow \mathbb{R}^+$ tal que h es par y restringida a $\mathbb{R}^+$ es creciente y sea Y una v.a. tal que $\mathbb{E}(h(Y))$ existe. Entonces, para todo $\epsilon > 0$

$$\mathbb{P}(|Y| \geq \epsilon) \leq \frac{\mathbb{E}[h(Y)]}{h(\epsilon)}$$

Error cuadrático medio y consistencia

Theorem 1.15

Sea T_n un estimador de $q(\theta)$ basado en una muestra aleatoria de tamaño n . Si $ECM_\theta(T_n) \rightarrow 0$ cuando $n \rightarrow \infty$, entonces T_n es un estimador débilmente consistente de $q(\theta)$.

Proof.

Recordemos la **desigualdad de Markov**: Sea $h : \mathbb{R} \rightarrow \mathbb{R}^+$ tal que h es par y restringida a $\mathbb{R}^+$ es creciente y sea Y una v.a. tal que $\mathbb{E}(h(Y))$ existe. Entonces, para todo $\epsilon > 0$

$$\mathbb{P}(|Y| \geq \epsilon) \leq \frac{\mathbb{E}[h(Y)]}{h(\epsilon)}$$

Dado $\epsilon > 0$, por la desigualdad de Markov tenemos

$$0 \leq \mathbb{P}(|T_n - q(\theta)| \geq \epsilon) \leq \frac{1}{\epsilon^2} \mathbb{E}_\theta \left[(|T_n - q(\theta)|)^2 \right] = \frac{1}{\epsilon^2} ECM_\theta(T_n)$$



Corolario

Corollary 1.16

Sea $T_n = T_n(X_1, \dots, X_n)$ un estimador de $q(\theta)$ basado en una muestra aleatoria de tamaño n . Si cuando $n \rightarrow \infty$

- $\mathbb{E}_\theta(T_n) \rightarrow q(\theta),$
- $\text{Var}_\theta(T_n) \rightarrow 0$

entonces T_n es débilmente consistente para $q(\theta)$.

Ver Ejemplos en el apunte de Bianco y Martinez y en el de Boente y Yohai.

Comportamiento asintótico de un estimador

Consistencia de los EMV

April 8, 2026

Consistencia de los EMV

Resultados previos

Esta parte está basada en el libro "Asymptotic Statistics" de Van der Vaart (1998)

Theorem 1.17 (Desigualdad de Jensen)

Sea Y una variable aleatoria y $h : \mathbb{R} \rightarrow \mathbb{R}$ una función convexa, luego se tiene

$$E(h(Y)) \geq h(E(Y))$$

Además si h es estrictamente convexa y Y no es constante con probabilidad 1 se tiene:

$$E(h(Y)) > h(E(Y))$$

Proof.

Proba (no se da en este curso)



Consistencia de los EMV

Resultados previos

Lemma 1.18

Sean p y q dos densidades o dos funciones de probabilidad distintas. Entonces,

$$\mathbb{E}_p \left(\ln \frac{q(X)}{p(X)} \right) < 0$$

Consistencia de los EMV

Resultados previos

Lemma 1.18

Sean p y q dos densidades o dos funciones de probabilidad distintas. Entonces,

$$\mathbb{E}_p \left(\ln \frac{q(X)}{p(X)} \right) < 0$$

Proof.

Pizarrón



Consistencia de los EMV

Resultados previos

Lemma 1.18

Sean p y q dos densidades o dos funciones de probabilidad distintas. Entonces,

$$\mathbb{E}_p\left(\ln \frac{q(X)}{p(X)}\right) < 0$$

Proof.

Pizarrón



Corollary 1.19

Sea $\{f(., \boldsymbol{\theta}) : \boldsymbol{\theta} \in \Theta\}$ una familia paramétrica de densidades o funciones de probabilidad puntual. Supongamos que $f(X, \boldsymbol{\theta}) = f(X, \boldsymbol{\theta}_0)$ c.s. $\Rightarrow \boldsymbol{\theta} = \boldsymbol{\theta}_0$. Entonces la función $M(\boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{\theta}_0}(\log(f(X, \boldsymbol{\theta})))$ tiene un único máximo absoluto y se alcanza en $\boldsymbol{\theta}_0$.

Consistencia de los EMV

Observaciones

- $\mathbb{E}_p \left(\ln \frac{p(X)}{q(X)} \right)$ se llama la divergencia de Kullback Leibler entre q y p y se suele usar como una medida de la distancia entre las distribuciones.
- Si $f(X, \boldsymbol{\theta}) = f(X, \boldsymbol{\theta}_0)$ c.s. $\Rightarrow \boldsymbol{\theta} = \boldsymbol{\theta}_0$ decimos que el parámetro $\boldsymbol{\theta}_0$ es identificable.
- Llamemos

$$M_n(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n \log (f(X_i, \boldsymbol{\theta})) , \quad M(\boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{\theta}_0} (\log (f(X_1, \boldsymbol{\theta})))$$

Por la LGN, para todo $\boldsymbol{\theta} \in \Theta$,

$$M_n(\boldsymbol{\theta}) \xrightarrow{\text{c.s.}} M(\boldsymbol{\theta}).$$

Queremos probar que

$$\widehat{\boldsymbol{\theta}}_n \xrightarrow{\text{c.s.}} \boldsymbol{\theta}_0$$

Consistencia de estimadores de máxima verosimilitud

Theorem 1.20 (Consistencia de EMV)

Sea $\hat{\theta}_n$ el EMV de θ_0 . Supongamos que $f(X, \theta) = f(X, \theta_0)$ c.s.
 $\Rightarrow \theta = \theta_0$, que $f(x, \theta)$ es medible para todo $\theta \in \Theta$ y que se cumplen las siguientes condiciones

$$\sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| \xrightarrow{\text{c.s.}} 0, \quad (1)$$

$$\sup_{\{\theta: \|\theta - \theta_0\| \geq \varepsilon\}} M(\theta) < M(\theta_0) \quad \forall \varepsilon > 0, \quad (2)$$

donde $M_n(\theta) = \frac{1}{n} \sum_{i=1}^n \log(f(X_i, \theta))$ y $M(\theta) = \mathbb{E}_{\theta_0}(\log(f(X_1, \theta)))$.

Entonces $\hat{\theta}_n$ es una sucesión de estimadores fuertemente consistente.

Proof.

Pizarrón



$$\hat{\theta}_n = \operatorname{argmax}_{\theta} \prod F(x_i, \theta)$$

$$M_n(\theta) = \frac{1}{n} \sum \log F(x_i, \theta)$$

↓ c.s.

$$M(\theta) = E(\log F(x_i, \theta))$$

$\hat{\theta}_n$ maximiza

θ_0 maximiza.

D/ Sabemos

$$(1) C = \{ \omega \in \Omega / \sup_{\theta \in \Theta} |M_n(\theta)(\omega) - M(\theta)(\omega)| \rightarrow 0 \}$$

Tiene probabilidad 1.

$$(2) \forall \varepsilon > 0, \exists \eta > 0 / \sup_{\|\theta - \theta_0\| \geq \varepsilon} M(\theta) < M(\theta_0) - \eta$$

En otras palabras,

$$\forall \varepsilon > 0, \exists \eta > 0 \text{ tal } \|\theta - \theta_0\| \geq \varepsilon \Rightarrow M(\theta) < M(\theta_0) - \eta$$

$$\Rightarrow M(\theta_0) - M(\theta) > \eta$$

$$(3) M(\hat{\theta}) > M(\theta_0)$$

$$\text{Sea } \varepsilon > 0, \exists \eta > 0 / \|\theta - \theta_0\| \geq \varepsilon \Rightarrow M(\theta_0) - M(\theta) > \eta \quad (4)$$

$$M(\theta_0) - M(\hat{\theta}_n) \leq M(\theta_0) - M_n(\hat{\theta}_n) + M_n(\hat{\theta}_n) - M(\hat{\theta}_n)$$

$$\left[M_n(\hat{\theta}_n) \geq M_n(\theta_0) \right] \leq M(\theta_0) - M_n(\theta_0) + M_n(\hat{\theta}_n) - M(\hat{\theta}_n)$$

$$\leq |M(\theta_0) - M_n(\theta_0)| + |M_n(\hat{\theta}_n) - M(\hat{\theta}_n)|$$

$$\leq 2 \sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| < \eta$$

Pero, sabemos que, en C

$$\exists n_0 / \sup |M_n(\theta) - M(\theta)| < \eta/2$$

Como $M(\theta_0) - M(\hat{\theta}_n) < \eta \Rightarrow \|\hat{\theta}_n - \theta_0\|$

REF: Van der Vaart, Asymptotic Statistics

Consistencia de EMV

Observación 1.21

Si Θ es compacto, la función $\theta \mapsto f(x, \theta)$ es continua en θ para todo x y está mayorada por una función con esperanza finita y θ_0 es el único máximo de la función M entonces se cumplen las condiciones del Teorema 1.20.

Proof.

Ejercicio



Observación 1.22

Demostraciones de la consistencia de los EMV con supuestos más débiles pueden verse en el libro de Ferguson y en el apunte de Boente y Yohai.

Consistencia de M-estimadores

Dada una función ρ medible y un M-estimador

$\hat{\theta}_n = \operatorname{argmin}_{\theta} \sum_{i=1}^n \rho(X_i, \theta)$, llamemos

$$M_n(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n \rho(X_i, \boldsymbol{\theta}), \quad M(\boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{\theta}_0} (\rho(X_1, \boldsymbol{\theta}))$$

Theorem 1.23 (Consistencia de M-estimadores)

Sea $\hat{\boldsymbol{\theta}}_n$ un M-estimador de $\boldsymbol{\theta}_0$. Si

$$\sup_{\boldsymbol{\theta} \in \Theta} |M_n(\boldsymbol{\theta}) - M(\boldsymbol{\theta})| \xrightarrow{\text{c.s.}} 0, \quad (3)$$

$$\sup_{\{\boldsymbol{\theta}: \|\boldsymbol{\theta} - \boldsymbol{\theta}_0\| \geq \epsilon\}} M(\boldsymbol{\theta}) > M(\boldsymbol{\theta}_0) \quad \forall \epsilon > 0, \quad (4)$$

Entonces $\hat{\boldsymbol{\theta}}_n$ es una sucesión de estimadores fuertemente consistente.

Proof.

Análoga a la dem anterior (1.20)



Consistencia de EMV

Observación 1.24

Si Θ es compacto, la función $\theta \mapsto \rho(x, \theta)$ es continua para todo x y está mayorada por una función con esperanza finita y θ_0 es el único máximo de la función M entonces se cumplen las condiciones del Teorema 1.23.

Proof.

Ejercicio



Comportamiento asintótico de un estimador

Distribución asintótica

April 8, 2026

Ejemplo: Modelo de posición con errores normales

(Predicción)

Ejemplo 1.25

Un investigador desea determinar cuanto vale cierta magnitud y para ello realiza n mediciones.

Supone que

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde $\epsilon_i \sim N(0, \sigma_0^2)$ independientes, con σ_0^2 conocida.

- a) ¿Cómo estimamos a θ ?
- b) ¿Cómo es la distribución de muestreo del estimador propuesto?
- c) ¿Cuál es su error estandar?
- d) ¿Y si σ_0^2 es desconocida?

$$X_i \sim \theta + N(0, \sigma_0^2) = N(\theta, \sigma_0^2)$$

$$a) b) \hat{\theta}_n = \bar{X}_n \sim N\left(\theta, \frac{\sigma_0^2}{n}\right)$$

$$c) \underbrace{Se(\hat{\theta}_n)}_{\substack{\text{STANDARD} \\ \text{ERROR}}} = Sd(\hat{\theta}_n) = \frac{\sigma_0}{\sqrt{n}}$$

$$\hat{Se}(\hat{\theta}_n) = \frac{s}{\sqrt{n}}$$

d) ET

Ejemplo: ¿y si los errores no son normales?

Ejemplo 1.25 (Continuación)

Supone que

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde $\mathbb{E}(\epsilon_i) = 0$ y $\text{Var}(\epsilon_i) = \sigma^2$ e independientes.

- $\hat{\theta}_n = \bar{X}_n$
- $\text{Var}(\hat{\theta}_n) = \sigma^2/n \Rightarrow \text{se}(\hat{\theta}_n) = \sqrt{\sigma^2/n}$
- $\frac{\bar{X}_n - \theta}{\sqrt{\sigma^2/n}} \sim ??$

Si X_i no son normales, por TCL

$$\frac{\hat{\theta}_n - \theta}{\sqrt{\sigma^2/n}} \xrightarrow{D} N(0,1)$$

Distribución Asintótica

Definition 1.26

Sea $T_n = T(\mathbf{X}_n) = T(X_1, \dots, X_n)$ un estimador de θ basado en la m.a. $X_1, \dots, X_n$.

Supongamos que para cierta sucesión numérica c_n tal que $c_n \rightarrow \infty$ y cierta variable aleatoria W , tenemos que cuando $n \rightarrow \infty$

$$c_n(T_n - \theta) \xrightarrow{\mathcal{D}} W,$$

entonces diremos que T_n **converge en distribución a W a tasa c_n** .

Típicamente, tenemos que $c_n = \sqrt{n}$, ¿por qué?

Por T.C.L.

Ejemplo: ¿y si los errores no son normales?

Ejemplo 1.25 (Continuación)

Supone que

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde $\mathbb{E}(\epsilon_i) = 0$ y $\text{Var}(\epsilon_i) = \sigma^2$ e independientes.

- $\hat{\theta}_n = \bar{X}_n$
- $\text{Var}(\hat{\theta}_n) = \sigma^2/n \Rightarrow \text{se}(\hat{\theta}_n) = \sqrt{\sigma^2/n}$
- *por el T.C.L. tenemos que $\frac{\bar{X}_n - \theta}{\sqrt{\sigma^2/n}} \xrightarrow{\mathcal{D}} Z \sim N(0, 1)$*
- *¿Qué pasa si estimamos el $\text{se}(\hat{\theta}_n)$? Por ejemplo, ¿si usamos $\widehat{\text{se}}(\hat{\theta}_n) = \sqrt{S_n^2/n}$?*

$$\frac{\bar{X}_n - \theta}{\sqrt{S_n^2/n}} \xrightarrow{\mathcal{D}} ?$$

Teorema de Slutsky

Theorem 1.27

Sean $\{X_n\}_{n \geq 1}$ e $\{Y_n\}_{n \geq 1}$ sucesiones de variables aleatorias, tales que $X_n \xrightarrow{\mathcal{D}} X$ e $Y_n \xrightarrow{P} c$, entonces

- $X_n + Y_n \xrightarrow{\mathcal{D}} X + c$
- $X_n - Y_n \xrightarrow{\mathcal{D}} X - c$
- $X_n \cdot Y_n \xrightarrow{\mathcal{D}} X \cdot c$
- Si $c \neq 0$, entonces $X_n/Y_n \xrightarrow{\mathcal{D}} X/c$

Ejemplo: ¿y si los errores no son normales?

Ejemplo 1.25 (Continuación)

Supone que

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$


donde $\mathbb{E}(\epsilon_i) = 0$ y $\text{Var}(\epsilon_i) = \sigma^2$ e independientes.

- $\hat{\theta}_n = \bar{X}_n$
- $\text{Var}(\hat{\theta}_n) = \sigma^2/n \Rightarrow \text{se}(\hat{\theta}_n) = \sqrt{\sigma^2/n}$
- por el T.C.L. tenemos que $\frac{\bar{X}_n - \theta}{\sqrt{\sigma^2/n}} \xrightarrow{\mathcal{D}} Z \sim N(0, 1)$

Entonces

$$\sqrt{n}(\bar{X}_n - \theta) \xrightarrow{\mathcal{D}} \sigma Z \sim N(0, \sigma^2)$$

- ¿Qué pasa si estimamos el $\text{se}(\hat{\theta}_n)$? Por ejemplo, ¿si usamos $\hat{\text{se}}(\hat{\theta}_n) = \sqrt{S_n^2/n}$?

$$\frac{\bar{X}_n - \theta}{\sqrt{S_n^2/n}} \xrightarrow{\mathcal{D}} ?$$


$$\frac{\sigma}{\sigma} \frac{\bar{X}_n - \theta}{s_n/\sqrt{n}} = \underbrace{\frac{\sigma}{s_n}}_{\xrightarrow{P} 1} \underbrace{\frac{\bar{X}_n - \theta}{\sigma/\sqrt{n}}}_{\xrightarrow{D} N(0,1)} \xrightarrow{D} N(0,1)$$

$\swarrow$ SLUTSKY

Proposición 1.28

Supongamos que $\widehat{se}(\hat{\theta}_n)$ es un estimador tal que $\frac{\widehat{se}(\hat{\theta}_n)}{se(\hat{\theta}_n)} \xrightarrow{P} 1$.

Luego, si

$$\frac{\hat{\theta}_n - \theta}{se(\hat{\theta}_n)} \xrightarrow{D} N(0, 1) \Rightarrow \frac{\hat{\theta}_n - \theta}{\widehat{se}(\hat{\theta}_n)} \xrightarrow{D} N(0, 1)$$

Proof.

$$\frac{\hat{\theta}_n - \theta}{\hat{se}(\hat{\theta}_n)} = \frac{se(\hat{\theta}_n)}{\hat{se}(\hat{\theta}_n)} \frac{\hat{\theta}_n - \theta}{se(\hat{\theta}_n)}$$

Como

$$\frac{se(\hat{\theta}_n)}{\hat{se}(\hat{\theta}_n)} \xrightarrow{P} 1 \text{ y } \frac{\hat{\theta}_n - \theta}{se(\hat{\theta}_n)} \xrightarrow{D} N(0, 1)$$

por Slutsky, se llega a lo que queríamos probar:

$$\frac{\hat{\theta}_n - \theta}{\hat{se}(\hat{\theta}_n)} = \frac{se(\hat{\theta}_n)}{\hat{se}(\hat{\theta}_n)} \frac{\hat{\theta}_n - \theta}{se(\hat{\theta}_n)} \xrightarrow{D} N(0, 1)$$



Ejemplo 1.29

Sea $X_1, \dots, X_n$ i.i.d

1. Si $X_i \sim U(0, \theta)$ entonces el estimador de momentos de θ es consistente y hallar su distribución asintótica.
2. Si $X_i \sim \mathcal{E}(\theta)$ entonces el estimador de momentos de θ es consistente y hallar su distribución asintótica.

1. $\hat{\theta}_n = 2 \bar{X}_n$

Por TCL, $\frac{\bar{X}_n - \frac{\theta}{2}}{\sqrt{\frac{\theta^2/12}{n}}} \xrightarrow{D} N(0,1)$

$$\therefore \frac{\sqrt{n} \left(\bar{X}_n - \frac{\theta}{2} \right)}{\theta/\sqrt{12}} \xrightarrow{D} Z$$

$$\underbrace{2\sqrt{n} \left(\bar{X}_n - \frac{\theta}{2} \right)}_{= \sqrt{n} \hat{\theta}_n - \theta} \xrightarrow{D} 2 \frac{\theta}{\sqrt{12}} Z \sim N\left(0, \frac{\theta^2}{3}\right)$$

Método Delta

Theorem 1.30 (Método Delta)

Sea $\{Z_n\}_{n \geq 1}$, una sucesión de variables aleatorias tales que para una sucesión numérica $a_n \uparrow \infty$

$$a_n (Z_n - \theta) \xrightarrow{\mathcal{D}} Z .$$

Sea $q : \mathbb{R} \rightarrow \mathbb{R}$ una función de clase $\mathcal{C}^1$ tal que $q'(\theta) \neq 0$, entonces

$$a_n (q(Z_n) - q(\theta)) \xrightarrow{\mathcal{D}} q'(\theta) Z .$$

Proof.

Proba *Ver DEMO de PROBA*



D/ θ cerca de x , por TVM
HEURÍSTICA

$$c_n(q(x) - q(\theta)) \approx c_n q'(\theta)(x - \theta)$$

$$\Rightarrow c_n(q(z_n) - q(\theta)) \approx c_n q'(\theta) \cdot (z_n - \theta)$$

$$\text{Comme } c_n(z_n - \theta) \xrightarrow{D} Z$$

$$c_n q'(\theta)(z_n - \theta) \xrightarrow{D} q'(\theta) Z$$

$$c_n(q(z_n) - q(\theta)) \xrightarrow{D} q'(\theta) Z$$

Ejemplo 1.29

Sea $X_1, \dots, X_n$ i.i.d

1. Si $X_i \sim U(0, \theta)$ entonces el estimador de momentos de θ es consistente y hallar su distribución asintótica.
2. Si $X_i \sim \mathcal{E}(\theta)$ entonces el estimador de momentos de θ es consistente y hallar su distribución asintótica.

2.

Método Delta

Por ejemplo, si

$$\sqrt{n} (Z_n - \theta) \xrightarrow{\mathcal{D}} N(0, \sigma^2) .$$

y $q : \mathbb{R} \rightarrow \mathbb{R}$ una función de clase $\mathcal{C}^1$ tal que $q'(\theta) \neq 0$.

Entonces

$$\sqrt{n} (q(Z_n) - q(\theta)) \xrightarrow{\mathcal{D}} N \left(0, \sigma^2 [q'(\theta)]^2 \right)$$

Ejemplo 1.31

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población con densidad de la forma

$$f(x, \theta) = (1 - \theta) \mathbb{I}_{(-\frac{1}{2}, 0)}(x) + (1 + \theta) \mathbb{I}_{(0, \frac{1}{2})}(x), \quad -1 < \theta < 1$$

¿Cuál es la distribución asintótica del estimador de momentos generalizado que hallamos para $\mathbb{P}_\theta(X > 0)$?

Cota de Rao–Cramer y Eficiencia

(Ver ~~ap~~apunte de Boente y Yohai.)

- Estableceremos la conocida desigualdad de Rao–Cramer que da una cota inferior para la varianza de todo estimador insesgado bajo condiciones de regularidad.
- Veremos luego que, bajo condiciones de regularidad, los EMV alcanzan esta cota asintóticamente.

Estimador de máxima verosimilitud

Recordemos que el estimador de máxima verosimilitud de θ es el valor que maximiza

$$\ell_n(\theta, \mathbf{X}) = \sum_{i=1}^n \log f(X_i, \theta)$$

Bajo **condiciones de regularidad** el EMV se puede hallar como un cero de

$$\frac{\partial}{\partial \theta} \ell_n(\theta, \mathbf{X}_n) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(X_i, \theta)$$

Definition 1.32

Llamamos **función de score**:

$$\frac{\partial}{\partial \theta} \log f(X, \theta)$$

Número de información de Fisher

Definition 1.33

Sea una X variable aleatoria con densidad o función de probabilidad puntual f . Llamamos número de información de Fisher de X a

$$I(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(X, \theta) \right)^2 \right]$$

Condiciones de regularidad

- Sea $X_1, \dots, X_n$ i.i.d. ~~X_i~~ $f(x, \theta)$ con $\theta \in \Theta$, $X \sim X_i$, donde Θ es un intervalo abierto de $\mathbb{R}$. Supongamos que:

R0. $f(x, \theta)$ es derivable respecto de θ  SOPORTE

R1. el conjunto $\mathcal{S} = \{x : f(x, \theta) \neq 0\}$ es independiente de θ .

R2. $\theta_1 \neq \theta_2$ implica que $\mathbb{P}(f(X, \theta_1) \neq f(X, \theta_2)) > 0$.

R3. $f(x, \theta)$ es dos veces diferenciable respecto de θ

R4. La integral $\int f(x, \theta) dx$ es dos veces diferenciable respecto de θ y estas derivadas son intercambiables con el signo integral.

Número de Información de Fisher

Proposición 1.34

Si se cumplen *R1 - R4*

$$\mathbb{E}_\theta \left[\frac{\partial}{\partial \theta} \log f(X, \theta) \right] = 0 \text{ y } \mathbb{V}_\theta \left[\frac{\partial}{\partial \theta} \log f(X, \theta) \right] = I(\theta)$$

Proof.

Pizarrón



$$\text{D/ } \mathbb{E}_\theta \left(\frac{\partial}{\partial \theta} \log f(x, \theta) \right) = \int \frac{\partial}{\partial \theta} \log f(x, \theta) \cdot f(x, \theta) dx =$$

$$= \int \frac{\frac{\partial}{\partial \theta} f(x, \theta)}{\cancel{f(x, \theta)}} \cancel{f(x, \theta)} dx = \frac{\partial}{\partial \theta} \underbrace{\int f(x, \theta) dx}_{=1} = 0$$

$$\Rightarrow V(x) = E(x^2)$$

Número de Información de Fisher

Proposición 1.35

*Si se cumplen **R1** a **R4** entonces*

$$I(\theta) = -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log f(X, \theta) \right]$$

Proof.

Pizarrón



Ejemplo: $X \sim B(1, \theta)$

Ejemplo 1.36

$$\log f(x, \theta) = x \log \theta + (1 - x) \log(1 - \theta)$$

$$\frac{\partial}{\partial \theta} \log f(x, \theta) = \frac{x}{\theta} - \frac{1 - x}{1 - \theta}$$

$$\frac{\partial^2}{\partial \theta^2} \log f(x; \theta) = -\frac{x}{\theta^2} - \frac{1 - x}{(1 - \theta)^2}$$

El número de información es

$$\begin{aligned} I(\theta) &= -E \left[\frac{-X}{\theta^2} - \frac{1 - X}{(1 - \theta)^2} \right] \\ &= \frac{\theta}{\theta^2} + \frac{1 - \theta}{(1 - \theta)^2} = \frac{1}{\theta} + \frac{1}{(1 - \theta)} = \frac{1}{\theta(1 - \theta)}. \end{aligned}$$

Algunas observaciones

- El número de información indica la curvatura de la función que maximizamos al calcular el EMV en θ .
- A mayor curvatura mayor precisión en la estimación.

Cota de Rao–Cramer

Theorem 1.37

*Bajo las condiciones de regularidad **R1** a **R4** , si $\hat{\theta}_n = \hat{\theta}_n(\mathbf{X}_n)$ es un estimador insesgado de θ , entonces*

$$\text{Var}(\hat{\theta}_n) \geq \frac{1}{nI(\theta)}$$

Cota de Rao–Cramer

Theorem 1.37

Bajo las condiciones de regularidad R1 a R4 , si $\hat{\theta}_n = \hat{\theta}_n(\mathbf{X}_n)$ es un estimador insesgado de θ , entonces

$$\text{Var}(\hat{\theta}_n) \geq \frac{1}{nI(\theta)}$$

Proof.

No la veremos en el curso, pueden encontrarla en el apunte de Boente y yohai. □

Cota de Rao–Cramer

Theorem 1.37

Bajo las condiciones de regularidad *R1* a *R4*, si $\hat{\theta}_n = \hat{\theta}_n(\mathbf{X}_n)$ es un estimador insesgado de θ , entonces

$$\text{Var}(\hat{\theta}_n) \geq \frac{1}{nI(\theta)}$$

Proof.

No la veremos en el curso, pueden encontrarla en el apunte de Boente y yohai. □

Definition 1.38

Decimos que un estimador insesgado de θ , $\hat{\theta}_n$, es *eficiente* si su varianza alcanza la cota de Rao–Cramer.

Volviendo al caso binomial:

¿Qué pasa con $\bar{X}_n$?

Ejemplo 1.39

Sea $X_1, \dots, X_n \sim B(1, \theta)$. Decidir si $\overline{X}_n$ es eficiente.

Ejemplo

El número de información de Fisher de un vector aleatorio

Definition 1.40

Sea una $\mathbf{X}$ un vector aleatorio con densidad o función de probabilidad puntual f . Llamamos número de información de Fisher de $\mathbf{X}$ a

$$I(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}, \theta) \right)^2 \right]$$

Ejemplo

El número de información de Fisher de un vector aleatorio

Definition 1.40

Sea un $\mathbf{X}$ un vector aleatorio con densidad o función de probabilidad puntual f . Llamamos número de información de Fisher de $\mathbf{X}$ a

$$I(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}, \theta) \right)^2 \right]$$

Observación 1.41

Las proposiciones 1.34 y 1.35 también valen para vectores aleatorios y las demostraciones son idénticas al caso univariado.

El número de información de Fisher de un vector aleatorio

Theorem 1.42

Sea $\mathbf{X}_1, \dots, \mathbf{X}_n$ una muestra aleatoria de una distribución con densidad $p(\mathbf{x}, \theta)$ con $\theta \in \Theta \subset \mathbb{R}$. Luego, si se denomina $I_n(\theta)$ al número de información de $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ e $I_1(\theta)$ al número de información de $\mathbf{X}_1$, entonces se tiene $I_n(\theta) = nI_1(\theta)$.

El número de información de Fisher de un vector aleatorio

Proof.

$$p(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n, \theta) = \prod_{i=1}^n p(\mathbf{x}_i, \theta) \Rightarrow$$

$$\ln p(\mathbf{x}_1, \dots, \mathbf{x}_n, \theta) = \sum_{i=1}^n \ln p(\mathbf{x}_i, \theta) \Rightarrow$$

$$\frac{\partial \ln p(\mathbf{x}_1, \dots, \mathbf{x}_n, \theta)}{\partial \theta} = \sum_{i=1}^n \frac{\partial \ln p(\mathbf{x}_i, \theta)}{\partial \theta}$$

Por ser $\mathbf{X}_1, \dots, \mathbf{X}_n$ independientes, se tiene


$$\begin{aligned} I_n(\theta) &= \text{Var}_\theta \left(\frac{\partial \ln p(\mathbf{X}_1, \dots, \mathbf{X}_n, \theta)}{\partial \theta} \right) = \sum_{i=1}^n \text{Var}_\theta \left(\frac{\partial \ln p(\mathbf{X}_i, \theta)}{\partial \theta} \right) \\ &= nI_1(\theta) \end{aligned}$$



Gráfico del número de información en función de θ para $n = 1, 5, 30$

```
I <- function(n, tita){  
  n/(tita*(1-tita))  
}  
titas<-seq(0.01, 1, 0.01)  
plot(titas, I(1, titas), type = "l", lwd=2, ylim=c(0, 200),  
      ylab=expression(paste(I[n](theta))))  
lines(titas, I(5, titas), lwd=2, col=2)  
lines(titas, I(30, titas), lwd=2, col=3)
```

Gráfico del número de información en función de θ para $n = 1, 5, 30$



Distribución Asintótica del EMV

Consideremos además la siguiente condición

R5. $f(x, \theta)$ es tres veces diferenciable respecto de θ . Además, existe una constante K tal que $\left| \frac{\partial^3}{\partial \theta^3} \log f(x, \theta) \right| \leq K$, para todo $\theta \in \Theta$ y todo $x \in S$.

Distribución asintótica del EMV

Theorem 1.43

Si

- se cumplen *R1* a *R5*
- $\hat{\theta}_n$ un estimador de máxima verosimilitud consistente de θ_0 , entonces, $\hat{\theta}_n$ es asintóticamente normal para estimar θ_0 , o sea,

$$\sqrt{n} \left(\hat{\theta}_n - \theta_0 \right) \xrightarrow{\mathcal{D}} N \left(0, \frac{1}{I(\theta_0)} \right)$$

Bosquejo de la demo

Demostración.

Notamos: $\ell'(\theta) = \frac{\partial \ell_n(\theta, \mathbf{X}_n)}{\partial \theta}$ $\ell''(\theta) = \frac{\partial^2 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^2}$ $\ell'''(\theta) = \frac{\partial^3 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^3}$

Bosquejo de la demo

Demostración.

Notamos: $\ell'(\theta) = \frac{\partial \ell_n(\theta, \mathbf{X}_n)}{\partial \theta}$ $\ell''(\theta) = \frac{\partial^2 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^2}$ $\ell'''(\theta) = \frac{\partial^3 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^3}$

Desarrollo de Taylor:

$$0 = \ell'(\hat{\theta}_n) = \ell'(\theta_0) + (\hat{\theta}_n - \theta_0) \ell''(\theta_0) + \frac{1}{2} \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)^2$$

donde ξ_n es un punto intermedio entre $\hat{\theta}_n$ y θ_0

Bosquejo de la demo

Demostración.

Notamos: $\ell'(\theta) = \frac{\partial \ell_n(\theta, \mathbf{X}_n)}{\partial \theta}$ $\ell''(\theta) = \frac{\partial^2 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^2}$ $\ell'''(\theta) = \frac{\partial^3 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^3}$

Desarrollo de Taylor:

$$0 = \ell'(\hat{\theta}_n) = \ell'(\theta_0) + (\hat{\theta}_n - \theta_0) \ell''(\theta_0) + \frac{1}{2} \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)^2$$

donde ξ_n es un punto intermedio entre $\hat{\theta}_n$ y θ_0

$$(\hat{\theta}_n - \theta_0) = \frac{-\ell'(\theta_0)}{\ell''(\theta_0) + 1/2 \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)}$$

Bosquejo de la demo

Demostración.

Notamos: $\ell'(\theta) = \frac{\partial \ell_n(\theta, \mathbf{X}_n)}{\partial \theta}$ $\ell''(\theta) = \frac{\partial^2 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^2}$ $\ell'''(\theta) = \frac{\partial^3 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^3}$

Desarrollo de Taylor:

$$0 = \ell'(\hat{\theta}_n) = \ell'(\theta_0) + (\hat{\theta}_n - \theta_0) \ell''(\theta_0) + \frac{1}{2} \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)^2$$

donde ξ_n es un punto intermedio entre $\hat{\theta}_n$ y θ_0

$$(\hat{\theta}_n - \theta_0) = \frac{-\ell'(\theta_0)}{\ell''(\theta_0) + 1/2 \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)}$$

$$n^{1/2} (\hat{\theta}_n - \theta_0) = \frac{-n^{-1/2} \ell'(\theta_0)}{n^{-1} \ell''(\theta_0) + 1/2 n^{-1} \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)}$$



Bosquejo de la demo

Continuación de la dem.

Primero, consideremos el numerador:

$$\left[n^{-1/2} \ell'(\theta_0) \right] = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{\partial \log f(X_i, \theta_0)}{\partial \theta}$$

Bosquejo de la demo

Continuación de la dem.

Primero, consideremos el numerador:

$$\left[n^{-1/2} \ell'(\theta_0) \right] = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{\partial \log f(X_i, \theta_0)}{\partial \theta}$$

Los sumandos son i.i.d. con

$$\mathbb{E}_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = 0$$

y

$$\text{Var}_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = \mathbb{E}_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right]^2 = I(\theta_0)$$



Bosquejo de la demo

Continuación de la dem.

Los sumandos son i.i.d. con

$$\mathbb{E}_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = 0$$

y

$$\mathbb{V}ar_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = I(\theta_0)$$

Luego, por el TCL,

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \xrightarrow{\mathcal{D}} N(0, I(\theta_0))$$



Bosquejo de la demo

Continuación de la dem.

Consideremos el denominador.

$$-\frac{1}{n}\ell''(\theta_0) = \frac{1}{n} \sum_{i=1}^n \frac{\partial^2 \log f(X_i, \theta_0)}{\partial \theta^2} \xrightarrow{P} I(\theta_0) \text{ por LGN}$$

Además, por R5 y la consistencia de $\hat{\theta}_n$,

$$\frac{1}{2n}\ell'''(\xi_n) (\hat{\theta}_n - \theta) \xrightarrow{P} 0$$

Entonces

$$-\frac{1}{n}\ell''(\theta_0) + \frac{1}{2n}\ell'''(\xi_n) (\hat{\theta}_n - \theta) \xrightarrow{P} I(\theta_0)$$

y por Slutsky $\sqrt{n} (\hat{\theta}_n - \theta_0) \xrightarrow{\mathcal{D}} N\left(0, \frac{1}{I(\theta_0)}\right)$



Distribución asintótica del EMV

Proposición 1.44

Supongamos que se cumplen *R1* a *R5* y que

- $\hat{\theta}_n$ un estimador de máxima verosimilitud consistente de θ_0
- $q(\theta)$ derivable con $q'(\theta) \neq 0$ para todo θ ,

entonces, $q(\hat{\theta}_n)$ es asintóticamente normal para estimar $q(\theta)$, o sea,

$$\sqrt{n} \left(q(\hat{\theta}_n) - q(\theta_0) \right) \xrightarrow{\mathcal{D}} N \left(0, \frac{[q'(\theta_0)]^2}{I(\theta_0)} \right)$$

Distribución asintótica del EMV

Proposición 1.44

Supongamos que se cumplen *R1* a *R5* y que

- $\hat{\theta}_n$ un estimador de máxima verosimilitud consistente de θ_0
- $q(\theta)$ derivable con $q'(\theta) \neq 0$ para todo θ ,

entonces, $q(\hat{\theta}_n)$ es asintóticamente normal para estimar $q(\theta)$, o sea,

$$\sqrt{n} \left(q(\hat{\theta}_n) - q(\theta_0) \right) \xrightarrow{\mathcal{D}} N \left(0, \frac{[q'(\theta_0)]^2}{I(\theta_0)} \right)$$

Definition 1.45

Decimos que una sucesión de estimadores T_n de $q(\theta)$ es **asintóticamente normal y eficiente (A.N.E.)** si

$$\sqrt{n} (T_n - q(\theta_0)) \xrightarrow{\mathcal{D}} N \left(0, \frac{[q'(\theta_0)]^2}{I(\theta_0)} \right)$$

Desventajas del EMV

1. Varianza mínima no necesariamente implica ECM mínimo.
Un ejemplo interesante es el EMV de σ^2 en el caso normal.
(Ver apunte de Boente y Yohai, página 40) .

Desventajas del EMV

1. Varianza mínima no necesariamente implica ECM mínimo. Un ejemplo interesante es el EMV de σ^2 en el caso normal. (Ver apunte de Boente y Yohai, página 40) .
2. Hay estimadores famosos que dan menor error cuadrático medio que el EMV en otros modelos. Algunos casos conocidos en alta dimensión: ridge, lasso.

Desventajas del EMV

1. Varianza mínima no necesariamente implica ECM mínimo. Un ejemplo interesante es el EMV de σ^2 en el caso normal. (Ver apunte de Boente y Yohai, página 40) .
2. Hay estimadores famosos que dan menor error cuadrático medio que el EMV en otros modelos. Algunos casos conocidos en alta dimensión: ridge, lasso.
3. Si hay una pequeña proporción de outliers, es decir, de observaciones que no siguen el modelo asumido, los resultados se ven muy alterados.

La mediana

Theorem 1.46

Sea $x_1, \dots, x_n$ una muestra aleatoria de una distribución F con una única mediana μ y con una densidad f tal que $f(\mu) > 0$. Entonces si $\tilde{\mu}_n$ es la mediana de la muestra, se tiene que

$$n^{1/2} (\tilde{\mu}_n - \mu) \xrightarrow{D} N \left(0, \frac{1}{4f^2(\mu)} \right)$$

Proof.

Ver Sección 7.1 del apunte de Boente y Yohai. (opcional)



La mediana

Theorem 1.46

Sea $x_1, \dots, x_n$ una muestra aleatoria de una distribución F con una única mediana μ y con una densidad f tal que $f(\mu) > 0$. Entonces si $\tilde{\mu}_n$ es la mediana de la muestra, se tiene que

$$n^{1/2} (\tilde{\mu}_n - \mu) \xrightarrow{D} N \left(0, \frac{1}{4f^2(\mu)} \right)$$

Proof.

Ver Sección 7.1 del apunte de Boente y Yohai. (opcional)



Observación 1.47

Del teorema anterior se deduce que $\tilde{\mu}_n \xrightarrow{p} \mu$.

Ejemplo: media y mediana

Ejemplo 1.48

Si $X_1, \dots, X_n \dots N(\mu, \sigma^2)$, la media y la mediana son dos estimadores consistentes y asintóticamente normales de μ .

Ejemplo: media y mediana

Ejemplo 1.48

Si $X_1, \dots, X_n \dots N(\mu, \sigma^2)$, la media y la mediana son dos estimadores consistentes y asintóticamente normales de μ .

Ejemplo 1.49

Conocemos dos estimadores consistentes de σ^2 : El EMV y S^2 . Otro es

$$\widehat{\sigma^2} = \frac{n-1}{n+1} S^2$$

Comparemos el desempeño de estos estimadores a través de una simulación. ¿Qué pasa si hay datos atípicos?