

La función de distribución empírica

basada en una muestra aleatoria

Definition 1.1

Dada una **muestra aleatoria**: $X_1, \dots, X_n$, su función de distribución empírica es

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I_{(-\infty, x]}(X_i)$$

donde

$$I_{(-\infty, x]}(X_i) = \begin{cases} 1, & \text{if } X_i \leq x \\ 0, & \text{if } X_i > x \end{cases}$$

La función de distribución empírica

basada en una muestra aleatoria

Observación 1.2 (Propiedades)

Las variables aleatorias $I_{(-\infty, x]}(X_i)$ son i.i.d con distribución de Bernoulli.

$$I_{(-\infty, x]}(X_i) = \begin{cases} 1, & \text{con probabilidad } F(x) \\ 0, & \text{con probabilidad } 1 - F(x) \end{cases}$$

Para todo $x \in \mathbb{R}$ fijo, se tiene

$$E \left[\hat{F}_n(x) \right] = F(x)$$

$$\text{Var} \left[\hat{F}_n(x) \right] = \frac{1}{n} F(x) [1 - F(x)]$$

$$\hat{F}_n(x) \xrightarrow{P} F(x)$$

Relación entre $\hat{F}_{obs}$ y medidas resumen

Ejercicio 1.3

Sea $\hat{F} = \hat{F}_{obs}$ la función de distribución empírica basada en las observaciones $x_1 \dots x_n$. Sea $X \sim \hat{F}$. Probar que:

1. $\mathbb{E}_{\hat{F}}(X) = \bar{x}$
2. $\mathbb{V}_{\hat{F}}(X) = \frac{n-1}{n} s^2$

Relación entre $\hat{F}_{obs}$ y medidas resumen: mediana y cuantiles

Definition 1.4 (Inversa generalizada)

Si F es una función de distribución acumulada

$$F^{-1}(p) = \inf\{x/F(x) \geq p\}$$

Proposición 1.5

Si $\hat{F} = \hat{F}_{obs}$ es la función de distribución empírica basada en las observaciones $x_1 \dots x_n$, y $X \sim \hat{F}$, entonces

1. $\hat{F}^{-1}(1/2) = x_{((n+1)/2)}$

2. $\hat{F}^{-1}(\alpha) = x_{([\alpha(n+1)])}$

donde $x_{(1)} \leq \dots \leq x_{(n)}$.

Relación entre $\hat{F}_{obs}$ y medidas resumen: mediana y cuantiles

Definition 1.4 (Inversa generalizada)

Si F es una función de distribución acumulada

$$F^{-1}(p) = \inf\{x/F(x) \geq p\}$$

Proposición 1.5

Si $\hat{F} = \hat{F}_{obs}$ es la función de distribución empírica basada en las observaciones $x_1 \dots x_n$, y $X \sim \hat{F}$, entonces

1. $\hat{F}^{-1}(1/2) = x_{((n+1)/2)}$

2. $\hat{F}^{-1}(\alpha) = x_{([\alpha(n+1)])}$

donde $x_{(1)} \leq \dots \leq x_{(n)}$.

Proof.

Ejercicio optativo



Tercera parte: Estimación no paramétrica de la densidad

August 21, 2025

Estimación de la densidad

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$.

$X \sim F$ v.a. continua con densidad $f(x)$

Sabemos estimar F mediante $\hat{F}_n =$ la función de distribución empírica.

¿Cómo estimamos f ?

Queremos estimar f sin asumir una determinada forma:
solo asumimos que f es suave.

La forma más sencilla: el **histograma**

Histograma

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

- Sea I un intervalo que contiene a todos los datos y $\mathcal{C} = \{C_1, \dots, C_k\}$ una partición de I en intervalos o clases acotados (bins) y disjuntos. Es decir,

$$I = \cup_{j=1}^k C_j$$


- Para cada $x \in \mathbb{R}$

$$\hat{f}(x) = \begin{cases} \frac{\#\{X_i: X_i \in C_j\}}{n|C_j|} & \text{si } x \in C_j \\ 0 & \text{si } x \notin I \end{cases}$$

con $|C_j|$ longitud del intervalo C_j




Histogramas con distintas particiones de I

Ejemplo 1.6 (Caída de nieve anual en Buffalo (EEUU) en inviernos entre 1910/11 to 1972/73.)







Histogramas con distintas particiones de I

Ejemplo 1.6 (Caída de nieve anual en Buffalo (EEUU) en inviernos entre 1910/11 to 1972/73.)



Histogramas con distinto punto inicial

Ejemplo 1.7 (Datos simulados)



Desventajas del histograma

- el estimador de la densidad depende del punto inicial de los bins:
- la densidad estimada no es suave, es *escalonada* y esto no es propio de la densidad sino de la herramienta de estimación
- por estas razones, el histograma es usado sólo para visualización

Idea 1: Enfoque Frecuentista


$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

$$\mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$$

Idea 2: Enfoque analítico

Si h es pequeño y f es continua.

$$\mathbb{P}(X \in [x-h, x+h]) = \int_{x-h}^{x+h} f(t) dt \approx 2hf(x)$$



Juntemos las dos ideas...

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

- $\mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$
- $\mathbb{P}(X \in [x - h, x + h]) \approx 2h f(x)$

Juntemos las dos ideas...

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

- $\mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$
- $\mathbb{P}(X \in [x - h, x + h]) \approx 2h f(x)$
- Entonces, podemos aproximar

$$2h f(x) \approx \mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$$

Juntemos las dos ideas...

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

- $\mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$
- $\mathbb{P}(X \in [x - h, x + h]) \approx 2h f(x)$
- Entonces, podemos aproximar

$$2h f(x) \approx \mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$$

$$f(x) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{2h n}$$

Propuesta

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

$$\hat{f}_h(x) = \frac{\#\{X_i \in [x - h, x + h]\}}{2h n}$$

Ver https://glmconr2.shinyapps.io/app_ker2/

Propuesta

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

$$\hat{f}_h(x) = \frac{\#\{X_i \in [x - h, x + h]\}}{2h n}$$

Propuesta

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

$$\hat{f}_h(x) = \frac{\#\{X_i \in [x-h, x+h]\}}{2hn}$$

Podemos reescribir esta expresión como:

$$\hat{f}_h(x) = \frac{1}{2hn} \sum_{i=1}^n I_{[x-h, x+h]}(X_i)$$

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n \frac{1}{2} I_{[-1, 1]} \left(\frac{x - X_i}{h} \right)$$

Propuesta

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

$$\hat{f}_h(x) = \frac{\#\{X_i \in [x-h, x+h]\}}{2h n}$$

Podemos reescribir esta expresión como:

$$\hat{f}_h(x) = \frac{1}{2h n} \sum_{i=1}^n I_{[x-h, x+h]}(X_i)$$

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n \frac{1}{2} I_{[-1,1]} \left(\frac{x - X_i}{h} \right)$$

$$\text{si } K(t) = \frac{1}{2} I_{[-1,1]}(t) \quad \Rightarrow$$

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K \left(\frac{x - X_i}{h} \right)$$

Estimador de Rosenblatt-Parzen

Definition 1.8 (Estimador de Rosenblatt-Parzen)

Dadas $X_1, \dots, X_n$, i.i.d.,

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)$$

donde $K \geq 0$ y $\int K(x)dx = 1$.

Ejercicio 1.9

- $\hat{f}_h(x) \geq 0$
- $\int \hat{f}_h(x)dx = 1$

Núcleo y ventana

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

Estimador de Rosenblatt-Parzen:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right), \text{ con } K(t) = \frac{1}{2}I_{[-1,1]}(t)$$

- K : núcleo
- h : ventana



Núcleo y ventana

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

Estimador de Rosenblatt-Parzen:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right), \text{ con } K(t) = \frac{1}{2}I_{[-1,1]}(t)$$

- K : núcleo
- h : ventana




Tipos de núcleos


- Núcleo Rectangular: $K(t) = \frac{1}{2}I_{[-1,1]}(t)$
- Núcleo Triangular: $K(t) = (1 - |t|)I_{[-1,1]}(t)$
- Núcleo Gaussiano: $K(t) = \frac{1}{\sqrt{2\pi}}e^{-\frac{1}{2}t^2}$
- Núcleo Epanechnikov: $K(t) = \frac{3}{4}(1 - t^2)I_{[-1,1]}(t)$

Núcleos


Uniforme




Epanechnikov



Triangular



Normal



Ejemplo: Ingreso total familiar en Argentina

[https://campus.exactas.uba.ar/pluginfile.php/150710/
mod_resource/content/1/estimaciondensidad.pdf](https://campus.exactas.uba.ar/pluginfile.php/150710/mod_resource/content/1/estimaciondensidad.pdf)



y

https://glmconr2.shinyapps.io/app_ker2/

Estimadores de núcleos (Rosenblatt-Parzen)

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-X_i}{h}\right)$$

- K núcleo: * $K \geq 0$ y * $\int K(x)dx = 1$.
- h : ventana o parámetro de suavizado
- Notemos que $\hat{f}(x)$ depende de n , del núcleo K y de h



¿Cómo elegimos h ? Lo veremos más adelante

Capítulo 2. Estimación puntual

August 21, 2025

Métodos de Estimación

- **Métodos de Estimación:** métodos que nos permiten aproximar o inferir el valor de una característica desconocida de interés de una población a partir de una muestra aleatoria de dicha población.
- Existen dos abordajes: la **estimación puntual** y la **estimación por intervalos**.

Estimación puntual y por intervalos

- En **estimación puntual** buscamos dar un único valor para la característica desconocida.
- En **estimación por intervalos** buscamos dar un rango de valores donde esperamos que esté la característica desconocida con un cierto nivel de confianza.

¿Qué tenemos?

- **Muestra aleatoria:** $X_1, \dots, X_n$ variables aleatorias i.i.d. con distribución F : $X_i \sim F$
- **Característica de interés:** la esperanza o media, la varianza, la función de distribución acumulada, los cuantiles, la función de densidad, entre otras.

Ejemplo: Cuantiles

Ejemplo 2.1

- **Variable de interés:** $X \sim F$, donde X = cantidad de anticuerpos IgG e IgM en un individuo 20 días después de la segunda dosis de vacuna contra COVID.
- **Características de interés:** $F^{-1}(p)$ cuantiles de la distribución.
- **Muestra aleatoria:** $X_1, \dots, X_n$ donde X_i = cantidad de anticuerpos del i -ésimo paciente.
- **Datos:**

5.9, 6.3, 19.6, 7.2, ...

Ejemplo: El modelo de posición

Ejemplo 2.2

Un investigador desea determinar cuanto vale cierta magnitud y para ello realiza n mediciones.

Supone que

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde ϵ_i son los errores de medición y θ es el mesurando (es decir, la magnitud que se desea medir).

Supone además que ϵ_i son i.i.d. con $E(\epsilon_i) = 0$

- **Distribución de X_i :** $F = F_{X_i}$
- **Característica:** $\theta = \mathbb{E}_F(X_i) = \theta(F)$
- **Muestra aleatoria:** $X_1, \dots, X_n$ donde X_i = el valor de la i -ésima medición.
- **Datos:** 1, 1.05, 0.98, 0.1.02, 0.96

Estimación puntual: ¿Qué es un estimador puntual?

Definition 2.3

Dadas variables aleatorias independientes e idénticamente distribuídas $X_1, \dots, X_n$ con distribución F y $\theta = \theta(F)$ una característica de interés, llamamos **estimador puntual** de θ a una función medible de $X_1, \dots, X_n$.

- Por convención, un estimador de θ se denota $\hat{\theta}$ o $\hat{\theta}_n$.
- Se tiene que para cierta g medible:

$$\hat{\theta} = \hat{\theta}_n = g(X_1, \dots, X_n)$$

- **Nota:** Un estimador es una variable aleatoria.

Estimación puntual: ¿Qué es una estimación de θ ?

Definition 2.4

Una **estimación** de θ es el valor observado de un estimador $\hat{\theta}$ cuando éste es evaluado en un conjunto de datos $x_1, \dots, x_n$.

- Una estimación de θ es una realización de $\hat{\theta}$: $\hat{\theta}_{obs}$.

$$\hat{\theta}_{obs} = \hat{\theta}_{n\,obs} = g(x_1, \dots, x_n)$$

donde $x_1, \dots, x_n$ es una realización de $X_1, \dots, X_n$

Resumiendo

- **Muestra:** $(X_i)_{i \geq 1}$ i.i.d. $X_i \sim F$, $F \in \mathcal{F}$ familia de distribuciones posibles para nuestro problema
- **Objetivo:** inferir *algo relacionado* con el mecanismo que genera los datos:
 - $\mathbb{P}_F(X_1 \leq 20)$
 - F
 - $\mathbb{E}_F(X_1)$
 - $\mathbb{V}_F(X_1)$
- ¿Cómo estimaríamos para cada uno de los *objetivos* planteados?

¿Qué sabemos de F ?

Modelos Paramétricos y No Paramétricos

- **Modelos no paramétricos:** Asumimos que F pertenece a una familia de distribuciones que no puede ser indexadas por una cantidad finita de parámetros.
 - $\mathcal{F} = \{\text{distribuciones continuas}\}$
 - $\mathcal{F} = \{\text{distribuciones con densidad simétrica alrededor de } 0\}$
 - $\mathcal{F} = \{\text{distribuciones con media y varianza finitas}\}$
- **Modelos paramétricos:** Asumimos que F pertenece a una familia de distribuciones que puede ser indexadas por una cantidad finita de parámetros.

Modelos Paramétricos

Casos Discretos

Asumimos que F pertenece a una familia de distribuciones que no pueden ser indexadas por una cantidad finita de parámetros.

- **Bernoulli:** $X \sim \mathcal{B}(\theta)$, $p(x, \theta) = \theta^x (1 - \theta)^{1-x}$, $x = 0, 1$,
 $\theta \in \Theta = (0, 1)$.
- **Poisson:** $X \sim \mathcal{P}(\theta)$, $p(x, \theta) = e^{-\theta} \theta^x / x!$, $x \in \mathbb{N} \cup \{0\}$
 $\theta \in R_{>0}$

$$\mathcal{M} = \{p(\cdot, \theta), \theta \in \Theta\} .$$

Modelos Paramétricos

Casos Continuos

- **Uniforme:** $X \sim \mathcal{U}(0, \theta)$, $f(x, \theta) = \frac{1}{\theta} \mathcal{I}_{[0, \theta]}(x)$, $\theta \in \Theta = \mathbb{R}_{>0}$.
- **Normal:** $X \sim \mathcal{N}(\mu, \sigma^2)$, $f(x, \theta) = (2\pi\sigma^2)^{-1/2} e^{-(x-\mu)^2/2\sigma^2}$,
 $\theta = (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_{>0}$
- **Exponencial:** $X \sim \mathcal{E}(\theta)$, $f(x, \theta) = \theta e^{-\theta x} \mathcal{I}_{[0, \infty)}(x)$,
 $\theta \in \Theta = \mathbb{R}_{>0}$.
- **Gamma:** $X \sim \Gamma(\alpha, \lambda)$,
 $f(x, \alpha, \lambda) = \frac{1}{\Gamma(\alpha)} \lambda^\alpha x^{\alpha-1} e^{-\lambda x} \mathcal{I}_{[0, \infty)}(x)$,
 $\theta = (\alpha, \lambda) \in \mathbb{R}_{>0} \times \mathbb{R}_{>0}$.

$$\mathcal{M} = \{f(\cdot, \theta), \theta \in \Theta\}.$$

Algunas aplicaciones

- **Bernoulli**: surge naturalmente en caso de variables binarias.
- **Poisson**: suele usarse para modelar procesos de conteo
- **Normal**: Modelo de Posición: $X_i = \theta + \epsilon_i$; suele asumirse que los errores tienen distribución normal con $\mathbb{E}(\epsilon_i) = 0$.
- **Gamma**: El tiempo de hospitalización de un paciente suele modelarse con una distribución Gamma $\Gamma(\alpha, \lambda)$
- **Weibull**: El ingreso anual familiar en algunos países se modela con una distribución Weibull
$$f(x, \alpha, \beta) = (\alpha/\beta)(x/\beta)^{\alpha-1} \exp(-(x/\beta)^\alpha).$$

Por ahora abordaremos el enfoque paramétrico....

$\mathcal{F}$ es una familia paramétrica $\mathcal{F} = \{f(\cdot, \theta), \theta \in \Theta\}$

- Una $F \sim \mathcal{F}$ es de la forma $F(\cdot, \theta)$, por lo tanto para identificarla solo necesitamos conocer θ .
- En este caso, θ está relacionada con características de interés de la distribución tales como esperanza o varianza:
 - Bernoulli: $X \sim \mathcal{B}(\theta)$, $\mathbb{E}_{F_\theta}(X) = \theta$
 - Gamma: $X \sim \Gamma(\alpha, \lambda)$, $\theta = (\alpha, \lambda)$, $E_{F_\theta}(X) = \alpha/\lambda$

Métodos de estimación en modelos paramétricos

Veremos en principio dos métodos:

- Método de los Momentos
- Método de Máxima Verosimilitud

Método de los Momentos: ¿Qué son los momentos?

Definition 2.5

Momentos Poblacionales: Sea X una v.a. Llamamos momento (poblacional) de orden k o k -ésimo momento de X , si la esperanza existe, a

$$\mu_k = \mathbb{E}(X^k)$$

Definition 2.6

Momentos Muestrales: Sea $X_1, \dots, X_n$ una muestra aleatoria. Llamamos momento muestral de orden k o k -ésimo momento muestral de $X_1, \dots, X_n$ a

$$\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

Motivación para los Momentos

- **k -ésimo momento** $\mu_k = \mathbb{E}_F[X^k]$, $X \sim F$

$$\mu_1 = \mathbb{E}_F[X]$$

$$\mu_2 = \mathbb{E}_F[X^2]$$

Motivación para los Momentos

- **k -ésimo momento** $\mu_k = \mathbb{E}_F[X^k]$, $X \sim F$

$$\mu_1 = \mathbb{E}_F[X]$$

$$\mu_2 = \mathbb{E}_F[X^2]$$

- **k -ésimo momento muestral** $\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$, $X_1, \dots, X_n$, i.i.d., $X_i \sim F$.

Por la LGN, sabemos que si las esperanzas existen

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu_1 = \mathbb{E}_F[X]$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} \mu_2 = \mathbb{E}_F[X^2]$$

.....

$$\frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k = \mathbb{E}_F[X^k]$$

Ejemplos: Normal

Supongamos que $X_1, X_2, \dots, X_n$ i.i.d. $X_i \sim \mathcal{N}(\mu, \sigma_o^2)$, σ_o^2 conocida. En este caso $\theta = \mu$, que coincide con μ_1 .

- Utilizando la LGN, tenemos que

$\bar{X}_n \xrightarrow{P} \mu = \mu_1$, cuando $X_i \sim \mathcal{N}(\mu, \sigma_o^2)$ cualquiera sea $\mu \in \mathbb{R}$.

- estimamos a μ por $\hat{\theta} = \bar{X}_n$

Ejemplos: Uniforme

Supongamos que $X_1, X_2, \dots, X_n$ i.i.d., $X_i \sim \mathcal{U}(0, \theta)$.

Sabemos que $\mu_1 = \mathbb{E}_\theta(X_1) = \frac{\theta}{2}$.

- Utilizando la LGN, tenemos que

$$\bar{X}_n \xrightarrow{P} \mu_1 = \frac{\theta}{2} \text{ cualquiera sea } \theta \in \Theta = \mathbb{R}$$

Ejemplos: Uniforme

Supongamos que $X_1, X_2, \dots, X_n$ i.i.d., $X_i \sim \mathcal{U}(0, \theta)$.

Sabemos que $\mu_1 = \mathbb{E}_\theta(X_1) = \frac{\theta}{2}$.

- Utilizando la LGN, tenemos que

$$\bar{X}_n \xrightarrow{P} \mu_1 = \frac{\theta}{2} \text{ cualquiera sea } \theta \in \Theta = \mathbb{R}$$

- estimamos a θ por $\hat{\theta} = 2 \bar{X}_n$

Para hallar el estimador de momentos de θ , proponemos

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{\hat{\theta}}{2}$$

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{\hat{\theta}}{2} \Rightarrow \hat{\theta} = \frac{2}{n} \sum_{i=1}^n X_i = 2\bar{X}_n$$

$$\hat{\theta} = 2\bar{X}_n$$

Método de los Momentos

Definition 2.7

Sea $X_1, X_2, \dots, X_n$ una m.a. de una distribución con función de distribución F_θ .

- Si $\mu_1 = E_\theta(X)$ es $\theta = h_1(\mu_1)$, el estimador de momentos de θ basado en el primer momento es el valor $\hat{\theta}$ tal que

$$\hat{\theta} = h_1(\hat{\mu}_1) \quad \text{donde } \hat{\mu}_1 = \frac{1}{n} \sum_{i=1}^n X_i$$

- Si $\mu_k = E_\theta(X^k)$ es $\theta = h_k(\mu_k)$, el estimador de momentos de θ basado en el k -ésimo momento es el valor $\hat{\theta}$ tal que

$$\hat{\theta} = h_k(\hat{\mu}_k) \quad \text{donde } \hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k.$$

Ejemplos: Exponencial

Supongamos que $X_1 \dots X_n$ siguen una distribución $\mathcal{E}(\theta)$. ¿Cómo estimamos a θ a partir de una muestra aleatoria $X_1 \dots X_n$?

$$X_1, X_2, \dots, X_n \sim \mathcal{E}(\theta), \text{i.i.d.}$$

En este caso $\mu_1 = \mathbb{E}_\theta(X_1) = \frac{1}{\theta}$.

Para hallar el estimador de momentos de θ , debemos despejar $\hat{\theta}$ de

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{\hat{\theta}}$$

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{\hat{\theta}} \Rightarrow \hat{\theta} = \frac{1}{\bar{X}}$$

Ejemplos: Exponencial

Supongamos que $X_1 \dots X_n$ siguen una distribución $\mathcal{E}(\theta)$. ¿Cómo estimamos a θ a partir de una muestra aleatoria $X_1 \dots X_n$?

$$X_1, X_2, \dots, X_n \sim \mathcal{E}(\theta), \text{i.i.d.}$$

En este caso $\mu_1 = \mathbb{E}_\theta(X_1) = \frac{1}{\theta}$.

Para hallar el estimador de momentos de θ , debemos despejar $\hat{\theta}$ de

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{\hat{\theta}}$$

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{\hat{\theta}} \Rightarrow \hat{\theta} = \frac{1}{\bar{X}}$$

En este caso $h_1(\mu_1) = \frac{1}{\mu_1}$

¿Qué momentos usamos?

Ejercicio 2.8

Explorar el caso $X_1, X_2, \dots, X_n$ i.i.d., $X_i \sim \mathcal{U}(-\theta, \theta)$.

- ¿Sirve el primer momento? ¿Da información sobre θ ?
- ¿Qué obtenemos si usamos el segundo momento?

Definition 2.9

Supongamos que tenemos dos parámetros θ_1, θ_2 y que pueden ser expresados en función de los dos primeros momentos, μ_1 y μ_2 , como

$$\theta_1 = h_1(\mu_1, \mu_2)$$

$$\theta_2 = h_2(\mu_1, \mu_2)$$

entonces los estimadores del método de los momentos (el primero y el segundo) son

$$\hat{\theta}_1 = h_1(\hat{\mu}_1, \hat{\mu}_2)$$

$$\hat{\theta}_2 = h_2(\hat{\mu}_1, \hat{\mu}_2)$$

Estimadores de Momentos para parámetros multidimensionales

Definition 2.10

Sea $X_1, X_2, \dots, X_n$ una m.a. de una distribución que depende de m parámetros $\theta_1, \theta_2, \dots, \theta_m$ y supongamos que están relacionados con los m primeros momentos poblacionales, de tal forma que

$$\mu_i = H_i(\theta_1, \theta_2, \dots, \theta_m), i = 1, \dots, m.$$

Los estimadores de momentos de $\theta_1, \theta_2, \dots, \theta_m$ son los valores $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ que se obtienen resolviendo el sistema de m ecuaciones

$$\hat{\mu}_i = H_i(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m), i = 1, \dots, m.$$

Por lo tanto, despejando obtenemos

$$\begin{aligned}\hat{\theta}_1 &= h_1(\hat{\mu}_1, \hat{\mu}_2, \dots, \hat{\mu}_m) \\ &\dots \\ \hat{\theta}_m &= h_m(\hat{\mu}_1, \hat{\mu}_2, \dots, \hat{\mu}_m)\end{aligned}$$

para funciones h_i adecuadamente definidas.

Ejemplos: Estimación de μ y σ^2 en la normal

Ejemplo 2.11

Supongamos que tenemos una m. a. $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$.

Sabemos que $\mathbb{E}_{\mu, \sigma^2}(X_i) = \mu$ y $\mathbb{E}_{\mu, \sigma^2}(X_i^2) = \mu^2 + \sigma^2$.

Para encontrar el estimador de momentos de μ y σ^2 resolvemos el sistema

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n X_i &= \hat{\mu} \\ \frac{1}{n} \sum_{i=1}^n X_i^2 &= \hat{\mu}^2 + \hat{\sigma}^2\end{aligned}$$

Despejemos de aquí a $\hat{\mu}$ y $\hat{\sigma}^2$

Ejemplos: Estimación de μ y σ^2 en la normal

Ejemplo 2.11 (Continuación)

$$\begin{cases} \frac{1}{n} \sum_{i=1}^n X_i = \hat{\mu} \\ \frac{1}{n} \sum_{i=1}^n X_i^2 = \hat{\mu}^2 + \hat{\sigma}^2 \end{cases}$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2$$

Puede verificarse fácilmente que: $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$

Ejercicio 2.12

si $X_1, \dots, X_n$, i.i.d., $X_i \sim \Gamma(\alpha, \lambda)$, ¿cómo resultan los estimadores de momentos de α y λ ?

Estimador de momentos en modelos no paramétricos

Ejemplo 2.13

$X_1, \dots, X_n$ v.a. i.i.d. $X_i \sim F$

- $\theta = (\mu, \sigma^2)$. Tenemos que

$$\begin{aligned}\mathbb{E}_F[X] &= \mu \\ \mathbb{E}_F[X^2] &= \sigma^2 + \mu^2\end{aligned}$$

- Nos queda el mismo sistema que en el caso normal.
- $(\hat{\mu}, \hat{\sigma}^2)$ es solución de

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i \quad \hat{\mu}^2 + \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2$$

- Despejando, obtenemos igual que en el caso normal

$$\hat{\mu} = \bar{X}_n \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$