

Capítulo 2. Estimación puntual

August 28, 2025

Métodos de Estimación

- **Métodos de Estimación:** métodos que nos permiten aproximar o inferir el valor de una característica desconocida de interés de una población a partir de una muestra aleatoria de dicha población.
- Existen dos abordajes: la **estimación puntual** y la **estimación por intervalos**.

Estimación puntual y por intervalos

- En **estimación puntual** buscamos dar un único valor para la característica desconocida.
- En **estimación por intervalos** buscamos dar un rango de valores donde esperamos que esté la característica desconocida con un cierto nivel de confianza.

¿Qué tenemos?

- **Muestra aleatoria:** $X_1, \dots, X_n$ variables aleatorias i.i.d. con distribución F : $X_i \sim F$
- **Característica de interés:** la esperanza o media, la varianza, la función de distribución acumulada, los cuantiles, la función de densidad, entre otras.

Ejemplo: Cuantiles

Ejemplo 2.1

- **Variable de interés:** $X \sim F$, donde X = cantidad de anticuerpos IgG e IgM en un individuo 20 días después de la segunda dosis de vacuna contra COVID.
- **Características de interés:** $F^{-1}(p)$ cuantiles de la distribución.
- **Muestra aleatoria:** $X_1, \dots, X_n$ donde X_i = cantidad de anticuerpos del i -ésimo paciente.
- **Datos:**

5.9, 6.3, 19.6, 7.2, ...

Ejemplo: El modelo de posición

Ejemplo 2.2

Un investigador desea determinar cuanto vale cierta magnitud y para ello realiza n mediciones.

Supone que

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde ϵ_i son los errores de medición y θ es el mesurando (es decir, la magnitud que se desea medir).

Supone además que ϵ_i son i.i.d. con $E(\epsilon_i) = 0$

- **Distribución de X_i :** $F = F_{X_i}$
- **Característica:** $\theta = \mathbb{E}_F(X_i) = \theta(F)$
- **Muestra aleatoria:** $X_1, \dots, X_n$ donde X_i = el valor de la i -ésima medición.
- **Datos:** 1, 1.05, 0.98, 0.1.02, 0.96

Estimación puntual: ¿Qué es un estimador puntual?

Definition 2.3

Dadas variables aleatorias independientes e idénticamente distribuídas $X_1, \dots, X_n$ con distribución F y $\theta = \theta(F)$ una característica de interés, llamamos **estimador puntual** de θ a una función medible de $X_1, \dots, X_n$.

- Por convención, un estimador de θ se denota $\hat{\theta}$ o $\hat{\theta}_n$.
- Se tiene que para cierta g medible:

$$\hat{\theta} = \hat{\theta}_n = g(X_1, \dots, X_n)$$

- **Nota:** Un estimador es una variable aleatoria.

Estimación puntual: ¿Qué es una estimación de θ ?

Definition 2.4

Una **estimación** de θ es el valor observado de un estimador $\hat{\theta}$ cuando éste es evaluado en un conjunto de datos $x_1, \dots, x_n$.

- Una estimación de θ es una realización de $\hat{\theta}$: $\hat{\theta}_{obs}$.

$$\hat{\theta}_{obs} = \hat{\theta}_{n\,obs} = g(x_1, \dots, x_n)$$

donde $x_1, \dots, x_n$ es una realización de $X_1, \dots, X_n$

Resumiendo

- **Muestra:** $(X_i)_{i \geq 1}$ i.i.d. $X_i \sim F$, $F \in \mathcal{F}$ familia de distribuciones posibles para nuestro problema
- **Objetivo:** inferir *algo relacionado* con el mecanismo que genera los datos:
 - $\mathbb{P}_F(X_1 \leq 20)$
 - F
 - $\mathbb{E}_F(X_1)$
 - $\mathbb{V}_F(X_1)$
- ¿Cómo estimaríamos para cada uno de los *objetivos* planteados?

¿Qué sabemos de F ?

Modelos Paramétricos y No Paramétricos

- **Modelos no paramétricos:** Asumimos que F pertenece a una familia de distribuciones que no puede ser indexadas por una cantidad finita de parámetros.
 - $\mathcal{F} = \{\text{distribuciones continuas}\}$
 - $\mathcal{F} = \{\text{distribuciones con densidad simétrica alrededor de } 0\}$
 - $\mathcal{F} = \{\text{distribuciones con media y varianza finitas}\}$
- **Modelos paramétricos:** Asumimos que F pertenece a una familia de distribuciones que puede ser indexadas por una cantidad finita de parámetros.

Modelos Paramétricos

Casos Discretos

Asumimos que F pertenece a una familia de distribuciones que no pueden ser indexadas por una cantidad finita de parámetros.

- **Bernoulli:** $X \sim \mathcal{B}(\theta)$, $p(x, \theta) = \theta^x (1 - \theta)^{1-x}$, $x = 0, 1$,
 $\theta \in \Theta = (0, 1)$.
- **Poisson:** $X \sim \mathcal{P}(\theta)$, $p(x, \theta) = e^{-\theta} \theta^x / x!$, $x \in \mathbb{N} \cup \{0\}$
 $\theta \in \mathbb{R}_{>0}$

$$\mathcal{M} = \{p(\cdot, \theta), \theta \in \Theta\}.$$

Modelos Paramétricos

Casos Continuos

- **Uniforme:** $X \sim \mathcal{U}(0, \theta)$, $f(x, \theta) = \frac{1}{\theta} \mathcal{I}_{[0, \theta]}(x)$, $\theta \in \Theta = \mathbb{R}_{>0}$.
- **Normal:** $X \sim \mathcal{N}(\mu, \sigma^2)$, $f(x, \theta) = (2\pi\sigma^2)^{-1/2} e^{-(x-\mu)^2/2\sigma^2}$,
 $\theta = (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_{>0}$
- **Exponencial:** $X \sim \mathcal{E}(\theta)$, $f(x, \theta) = \theta e^{-\theta x} \mathcal{I}_{[0, \infty)}(x)$,
 $\theta \in \Theta = \mathbb{R}_{>0}$.
- **Gamma:** $X \sim \Gamma(\alpha, \lambda)$,
 $f(x, \alpha, \lambda) = \frac{1}{\Gamma(\alpha)} \lambda^\alpha x^{\alpha-1} e^{-\lambda x} \mathcal{I}_{[0, \infty)}(x)$,
 $\theta = (\alpha, \lambda) \in \mathbb{R}_{>0} \times \mathbb{R}_{>0}$.

$$\mathcal{M} = \{f(\cdot, \theta), \theta \in \Theta\}.$$

Algunas aplicaciones

- **Bernoulli**: surge naturalmente en caso de variables binarias.
- **Poisson**: suele usarse para modelar procesos de conteo
- **Normal**: Modelo de Posición: $X_i = \theta + \epsilon_i$; suele asumirse que los errores tienen distribución normal con $\mathbb{E}(\epsilon_i) = 0$.
- **Gamma**: El tiempo de hospitalización de un paciente suele modelarse con una distribución Gamma $\Gamma(\alpha, \lambda)$
- **Weibull**: El ingreso anual familiar en algunos países se modela con una distribución Weibull
$$f(x, \alpha, \beta) = (\alpha/\beta)(x/\beta)^{\alpha-1} \exp(-(x/\beta)^\alpha).$$

Por ahora abordaremos el enfoque paramétrico....

$\mathcal{F}$ es una familia paramétrica $\mathcal{F} = \{f(\cdot, \theta), \theta \in \Theta\}$

- Una $F \sim \mathcal{F}$ es de la forma $F(\cdot, \theta)$, por lo tanto para identificarla solo necesitamos conocer θ .
- En este caso, θ está relacionada con características de interés de la distribución tales como esperanza o varianza:
 - Bernoulli: $X \sim \mathcal{B}(\theta)$, $\mathbb{E}_{F_\theta}(X) = \theta$
 - Gamma: $X \sim \Gamma(\alpha, \lambda)$, $\theta = (\alpha, \lambda)$, $E_{F_\theta}(X) = \alpha/\lambda$

Métodos de estimación en modelos paramétricos

Veremos en principio dos métodos:

- Método de los Momentos
- Método de Máxima Verosimilitud

Método de los Momentos: ¿Qué son los momentos?

Definition 2.5

Momentos Poblacionales: Sea X una v.a. Llamamos momento (poblacional) de orden k o k -ésimo momento de X , si la esperanza existe, a

$$\mu_k = \mathbb{E}(X^k)$$

Definition 2.6

Momentos Muestrales: Sea $X_1, \dots, X_n$ una muestra aleatoria. Llamamos momento muestral de orden k o k -ésimo momento muestral de $X_1, \dots, X_n$ a

$$\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

Motivación para los Momentos

- **k -ésimo momento** $\mu_k = \mathbb{E}_F[X^k]$, $X \sim F$

$$\mu_1 = \mathbb{E}_F[X]$$

$$\mu_2 = \mathbb{E}_F[X^2]$$

- **k -ésimo momento muestral** $\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$, $X_1, \dots, X_n$, i.i.d., $X_i \sim F$.

Por la LGN, sabemos que si las esperanzas existen

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu_1 = \mathbb{E}_F[X]$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} \mu_2 = \mathbb{E}_F[X^2]$$

.....

$$\frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k = \mathbb{E}_F[X^k]$$

Ejemplos: Normal

Supongamos que $X_1, X_2, \dots, X_n$ i.i.d. $X_i \sim \mathcal{N}(\mu, \sigma_o^2)$, σ_o^2 conocida. En este caso $\theta = \mu = \mu_1$.

- Utilizando la LGN, tenemos que

$\bar{X}_n \xrightarrow{P} \mu$, cuando $X_i \sim \mathcal{N}(\mu, \sigma_o^2)$ cualquiera sea $\mu \in \mathbb{R}$.

- estimamos a μ por $\hat{\mu} = \bar{X}_n$

Ejemplos: Uniforme

Supongamos que $X_1, X_2, \dots, X_n$ i.i.d., $X_i \sim \mathcal{U}(0, \theta)$.

Sabemos que $\mu_1 = \mathbb{E}_\theta(X_1) = \frac{\theta}{2}$.

- Utilizando la LGN, tenemos que

$$\bar{X}_n \xrightarrow{P} \mu_1 = \frac{\theta}{2} \text{ cualquiera sea } \theta \in \Theta = \mathbb{R}$$

- estimamos a θ por $\hat{\theta} = 2 \bar{X}_n$

Para hallar el estimador de momentos de θ , proponemos

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{\hat{\theta}}{2}$$

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{\hat{\theta}}{2} \Rightarrow \hat{\theta} = \frac{2}{n} \sum_{i=1}^n X_i = 2\bar{X}_n$$

$$\hat{\theta} = 2\bar{X}_n$$

Método de los Momentos

Definition 2.7

Sea $X_1, X_2, \dots, X_n$ una m.a. de una distribución con función de distribución F_θ .

- el estimador de momentos de θ basado en el primer momento es el valor $\hat{\theta}$ tal que

$$E_{\hat{\theta}}(X) = \hat{\mu}_1 = \bar{X}$$

- el estimador de momentos de θ basado en el k -ésimo momento es el valor $\hat{\theta}$ tal que

$$E_{\hat{\theta}}(X^k) = \hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k.$$

Ejemplos: Exponencial

Supongamos que $X_1 \dots X_n$ siguen una distribución $\mathcal{E}(\theta)$. ¿Cómo estimamos a θ a partir de una muestra aleatoria $X_1 \dots X_n$?

$$X_1, X_2, \dots, X_n \sim \mathcal{E}(\theta), \text{i.i.d.}$$

En este caso $\mu_1 = \mathbb{E}_\theta(X_1) = \frac{1}{\theta}$.

Para hallar el estimador de momentos de θ , debemos despejar $\hat{\theta}$ de

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{\hat{\theta}}$$

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{\hat{\theta}} \Rightarrow \hat{\theta} = \frac{1}{\bar{X}}$$

¿Qué momentos usamos?

Ejercicio 2.8

Explorar el caso $X_1, X_2, \dots, X_n$ i.i.d., $X_i \sim \mathcal{U}(-\theta, \theta)$.

- ¿Sirve el primer momento? ¿Da información sobre θ ?
- ¿Qué obtenemos si usamos el segundo momento?

Estimadores de Momentos para parámetros multidimensionales

Definition 2.9

Sea $X_1, X_2, \dots, X_n$ una m.a. de una distribución que depende de m parámetros $\theta_1, \theta_2, \dots, \theta_m$ y supongamos que están relacionados con los m primeros momentos poblacionales, de tal forma que

$$\mu_i = H_i(\theta_1, \theta_2, \dots, \theta_m), i = 1, \dots, m.$$

Los estimadores de momentos de $\theta_1, \theta_2, \dots, \theta_m$ son los valores $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ que se obtienen resolviendo el sistema de m ecuaciones

$$\hat{\mu}_i = H_i(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m), i = 1, \dots, m.$$

Por lo tanto, despejando obtenemos

$$\begin{aligned}\hat{\theta}_1 &= h_1(\hat{\mu}_1, \hat{\mu}_2, \dots, \hat{\mu}_m) \\ &\dots \\ \hat{\theta}_m &= h_m(\hat{\mu}_1, \hat{\mu}_2, \dots, \hat{\mu}_m)\end{aligned}$$

para funciones h_i adecuadamente definidas.

Ejemplos: Estimación de μ y σ^2 en la normal

Ejemplo 2.10

Supongamos que tenemos una m. a. $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$.

Sabemos que $\mathbb{E}_{\mu, \sigma^2}(X_i) = \mu$ y $\mathbb{E}_{\mu, \sigma^2}(X_i^2) = \mu^2 + \sigma^2$.

Para encontrar el estimador de momentos de μ y σ^2 resolvemos el sistema

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n X_i &= \hat{\mu} \\ \frac{1}{n} \sum_{i=1}^n X_i^2 &= \hat{\mu}^2 + \hat{\sigma}^2\end{aligned}$$

Despejemos de aquí a $\hat{\mu}$ y $\hat{\sigma}^2$

Ejemplos: Estimación de μ y σ^2 en la normal

Ejemplo 2.10 (Continuación)

$$\begin{cases} \frac{1}{n} \sum_{i=1}^n X_i = \hat{\mu} \\ \frac{1}{n} \sum_{i=1}^n X_i^2 = \hat{\mu}^2 + \hat{\sigma}^2 \end{cases}$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2$$

Puede verificarse fácilmente que: $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$

Ejercicio 2.11

si $X_1, \dots, X_n$, i.i.d., $X_i \sim \Gamma(\alpha, \lambda)$, ¿cómo resultan los estimadores de momentos de α y λ ?

Estimador de momentos en modelos no paramétricos

Ejemplo 2.12

$X_1, \dots, X_n$ v.a. i.i.d. $X_i \sim F$

- $\theta = (\mu, \sigma^2)$. Tenemos que

$$\begin{aligned}\mathbb{E}_F[X] &= \mu \\ \mathbb{E}_F[X^2] &= \sigma^2 + \mu^2\end{aligned}$$

- Nos queda el mismo sistema que en el caso normal.
- $(\hat{\mu}, \hat{\sigma}^2)$ es solución de

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i \quad \hat{\mu}^2 + \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2$$

- Despejando, obtenemos igual que en el caso normal

$$\hat{\mu} = \bar{X}_n \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Estimadores de Máxima Verosimilitud

¿Qué es la verosimilitud?

- Antes de realizar el *experimento* el **resultado** es **desconocido**.
- Las probabilidades nos permiten decir cuán probable es un resultado **desconocido** a partir de parámetros **conocidos**: por ejemplo

$$P(\text{resultado}|\theta) \text{ por ej. caso Bernoulli} \equiv P(x|\theta) = \theta^x(1 - \theta)^{(1-x)}$$

Ahora se invierte el paradigma:

- Al realizar el experimento el **resultado** se hace **conocido**: **dato**.
- Nos interesa cuán **verosímil** es que un determinado parámetro haya generado el dato.

Verosimilitud

Ejemplo

Ejemplo 2.13

Supongamos que tenemos dos monedas. Sabemos que una es normal y la otra tiene probabilidad de cara 0.8. A simple vista son indistinguibles. Elegimos una de las dos monedas y queremos saber cuál de las dos es.

Lanzamos la moneda 100 veces y obtenemos

$$\begin{array}{ccccccc} \mathbf{x} = & \underbrace{1, \dots, 1}_{12 \text{ veces}} & \underbrace{0, \dots, 0}_{5 \text{ veces}} & \underbrace{1, \dots, 1}_{23 \text{ veces}} & \underbrace{0, \dots, 0}_{8 \text{ veces}} & \underbrace{1, \dots, 1}_{15 \text{ veces}} & \underbrace{0, \dots, 0}_{3 \text{ veces}} \\ & 1, \dots, 1 & 0, \dots, 0 & 1, \dots, 1 & 0, \dots, 0 & 1, \dots, 1 & 0, \dots, 0 \\ & \underbrace{\hspace{1cm}}_{11 \text{ veces}} & \underbrace{\hspace{1cm}}_{4 \text{ veces}} & \underbrace{\hspace{1cm}}_{13 \text{ veces}} & \underbrace{\hspace{1cm}}_{6 \text{ veces}} & & \end{array}$$

¿Cuál de las dos monedas diría que es la que lanzamos?

Función de Verosimilitud

Definition 2.14

Supongamos que las variables aleatorias $X_1, \dots, X_n$ tienen una densidad conjunta o una función de probabilidad puntual $f(x_1, x_2, \dots, x_n, \theta)$. Dados los valores observados $x_1 \dots x_n$, la verosimilitud de θ se define como

$$L(\theta) = f(x_1, x_2, \dots, x_n, \theta).$$

Observación 2.15

1. *Notar que consideramos la densidad conjunta como una función de θ más que como una función de los x_i .*
2. *Si la distribución es discreta, la función de verosimilitud da la probabilidad de observar los datos obtenidos en función del parámetro θ .*

Función de Verosimilitud

Ejemplo 2.13 (Continuación)

Dado el vector observado $\mathbf{x}$

- $L(0.8)$ = *probabilidad de observar la muestra $\mathbf{x}$ con moneda de $p = 0.8$.*

$$\begin{aligned} L(0.8) &= \underbrace{0.8 \dots 0.8}_{12 \text{ veces}} \underbrace{0.2 \dots 0.2}_{5 \text{ veces}} \underbrace{0.8 \dots 0.8}_{23 \text{ veces}} \underbrace{0.2 \dots 0.2}_{8 \text{ veces}} \underbrace{0.8 \dots 0.8}_{15 \text{ veces}} \underbrace{0.2 \dots 0.2}_{3 \text{ veces}} \\ &= \underbrace{0.8 \dots 0.8}_{11 \text{ veces}} \underbrace{0.2 \dots 0.2}_{4 \text{ veces}} \underbrace{0.8 \dots 0.8}_{13 \text{ veces}} \underbrace{0.2 \dots 0.2}_{6 \text{ veces}} = \\ &= (0.8)^{74} (0.2)^{26} = 4.523128 \cdot 10^{-26} \end{aligned}$$

repeticiones.

- $L(0.5)$ = *probabilidad de observar la muestra $\mathbf{x}$ con moneda de $p = 0.5$ (equilibrada).*

$$L(0.5) =$$

¿cuál de las dos monedas diríamos que se está utilizando?

Propuesta de Máxima Verosimilitud

Ejemplo 2.13

La propuesta de máxima verosimilitud consiste en pensar que la moneda que estamos utilizando es aquella para la cual los valores observados resultan más probables. Es decir, elegimos la moneda que maximiza la probabilidad de los valores observados. Siendo que

$$L(0.8) > L(0.5)$$

concluimos que se está utilizando la moneda no equilibrada

Caso Binomial en general

Ejemplo 2.16

$(X_i)_{i \geq 1}$ i.i.d., $X_i \sim \mathcal{B}(1, \theta)$, $p(x, \theta) = \theta^x(1 - \theta)^{1-x}$.

Dado un conjunto de observaciones $x_1, \dots, x_n$,

1. hallar la función de verosimilitud asociada
2. hallar el valor de θ que maximiza la verosimilitud
3. hallar la función de logverosimilitud $\log L(\theta)$
4. hallar el valor de θ que maximiza la logverosimilitud.

Estimación por máxima de verosimilitud

Definition 2.17

Sea $X_1, \dots, X_n$ una muestra aleatoria de una densidad o f.p.p. $f(x, \theta)$ y $x_1 \dots x_n$ una realización de la muestra. El valor de θ que maximiza la verosimilitud, se llama una estimación de θ por máxima verosimilitud:

$$\hat{\theta}_{obs} = \operatorname{argmax}_{\theta} \prod_{i=1}^n f(x_i, \theta) = \operatorname{argmax}_{\theta} \sum_{i=1}^n \log f(x_i, \theta)$$

Estimador de máxima de verosimilitud

Como cada vez que se observan los datos $x_1, \dots, x_n$ tenemos una estimación. Así queda definido un estimador:

Definition 2.18

Sea $X_1, \dots, X_n$ una muestra aleatoria de una densidad o f.p.p. $f(x, \theta)$, entonces llamamos estimador de máxima verosimilitud (EMV) de θ a

$$\hat{\theta} = \operatorname{argmax}_{\theta} \prod_{i=1}^n f(X_i, \theta) = \operatorname{argmax}_{\theta} \sum_{i=1}^n \log f(X_i, \theta)$$

Más ejemplos

Ejemplo 2.19

Sean $X_1, \dots, X_n$ v.a. i.i.d. $X_i \sim \mathcal{E}(\theta), \theta > 0$. Hallar el EMV de θ

EMV para la distribución uniforme

Ejemplo 2.19

Sean $X_1, \dots, X_n$ v.a. i.i.d. $X_i \sim \mathcal{U}(0, \theta), \theta > 0$. Hallar el EMV de θ .

Resolución


$$\begin{aligned} f(x_1, \dots, x_n, \theta) &= \prod_{i=1}^n \frac{1}{\theta} \mathcal{I}_{[0, \theta]}(x_i) = \frac{1}{\theta^n} \prod_{i=1}^n \mathcal{I}_{[0, \theta]}(x_i) \\ &= \begin{cases} \frac{1}{\theta^n} & \text{si } 0 \leq x_i \leq \theta \text{ para todo } i \\ 0 & \text{otro caso} \end{cases} \\ &= \begin{cases} \frac{1}{\theta^n} & \text{si } \theta \geq \max(x_i) \\ 0 & \text{otro caso} \end{cases} \end{aligned}$$

Verificar que $1/\theta^n$ es decreciente en cualquier intervalo incluido en $\mathbb{R} > 0$ y por lo tanto, el EMV de θ es $\hat{\theta}_n = \max_{1 \leq i \leq n} (X_i)$

EMV para la distribución uniforme

Ejemplo 2.19 (Continuación)

Gráfico de la función de verosimilitud, $f(\mathbf{x}, \theta)$ correspondiente a $n = 8$ observaciones tales que $\max_{1 \leq i \leq n}(X_i) = 5$.



Ejemplo

Ejemplo 2.20

Sean $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ iid. Hallar el EMV de (μ, σ^2)

$$L(\mu, \sigma^2) = \prod_{i=1}^n f(x_i, \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

Tomando logaritmo, resolviendo las ecuaciones

$$\frac{\partial \ell(\mu, \sigma^2)}{\partial \mu} = 0 \quad y \quad \frac{\partial \ell(\mu, \sigma^2)}{\partial \sigma^2} = 0$$

y verificando las condiciones de segundo orden se obtiene que los EMV de μ y σ^2 son

$$\hat{\mu} = \bar{X}_n \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{n}$$

Ver Libro "Statistical Inference de Casella & Berger" Ej 7.2.11

Propiedad de invarianza

Teorema 2.21

Si $\hat{\theta}$ es el único EMV de θ y $h : \Theta \rightarrow \Theta$ es biyectiva, entonces $\hat{\lambda} = h(\hat{\theta})$ es el EMV de λ .

Proof.

Sea $f(\mathbf{x}, \theta)$ la densidad conjunta de $X_1, \dots, X_n$

$$\max_{\theta \in \Theta} f(\mathbf{x}, \theta) = \max_{\lambda \in \Lambda} f(\mathbf{x}, h^{-1}(\lambda))$$

$$f(\mathbf{x}, \hat{\theta}) = f(\mathbf{x}, h^{-1}(\hat{\lambda}))$$

como el máximo de f es único y h es biunívoca

$$\hat{\theta} = h^{-1}(\hat{\lambda})$$

$$\hat{\lambda} = h(\hat{\theta})$$



Ejemplo 2.22

Sean $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ iid. Hallar el EMV de (μ, σ^2) , entonces

1. $\bar{X}^3$ es el EMV de μ^3
2. $\sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{n}}$ es el EMV de σ
3. ¿Es $\bar{X}^2$ el EMV de μ^2 ?

Theorem 2.23 (Propiedad de invarianza de los EMV)

Si $\hat{\theta}$ es el EMV de θ , entonces para cualquier función $\tau(\theta)$, el EMV de $\tau(\theta)$ es $\tau(\hat{\theta})$.

Proof.

Ver Ej 6 de la práctica 2 y Teorema 7.2.10 del libro “Statistical Inference” de Casella y Bergher.



Comparación de estimadores de momentos y de máxima verosimilitud para la uniforme

Estimador de mínimos cuadrados

Ejemplo 2.24

Consideremos el modelo de posición

$X_1, \dots, X_n$ son v.a. que iid satisfacen

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde ϵ_i son i.i.d. con $E(\epsilon_i) = 0$ y θ es el parámetro desconocido que se desea estimar. Es decir, se supone que la densidad de X_i pertenece a la siguiente familia

$\mathcal{F} = \{ \text{distribuciones con esperanza } \theta \}$

Vimos que el estimador de momentos de θ es $\bar{X}$.

Otra forma de llegar a este estimador es calcular el estimador de mínimos cuadrados:

$$\hat{\theta} = \operatorname{argmin}_{\theta} \sum_{i=1}^n (X_i - \theta)^2$$

Estimador de mínimos cuadrados

Definition 2.25

Sea $X_1, \dots, X_n$ una muestra aleatoria que sigue el modelo de posición $X_i = \theta_0 + \epsilon_i$ con $\mathbb{E}(\epsilon_i) = 0$. El estimador de mínimos cuadrados de θ_0 se define como

$$\hat{\theta} = \operatorname{argmin}_{\theta} \sum_{i=1}^n (X_i - \theta)^2.$$

Proposición 2.26

Sea $X_1, \dots, X_n$ una muestra aleatoria con esperanza finita θ_0 . El estimador de mínimos cuadrados de θ_0 es $\bar{X}$.

Proof.



Estimador de mínimos desviaciones absolutas

Definition 2.27

Sea $X_1, \dots, X_n$ una muestra aleatoria que sigue el modelo de posición $X_i = \theta_0 + \epsilon_i$ donde ϵ_i tiene una distribución simétrica alrededor de 0. El estimador de mínimas desviaciones absolutas de θ_0 se define como

$$\hat{\theta} = \operatorname{argmin}_{\theta} \sum_{i=1}^n |X_i - \theta|.$$

Proposición 2.28

Sea $X_1, \dots, X_n$ una muestra aleatoria que sigue el modelo de posición $X_i = \theta_0 + \epsilon_i$ donde ϵ_i tiene una distribución simétrica alrededor de 0. El estimador de mínimas desviaciones absolutas de θ_0 es la mediana muestral de $X_1 \dots X_n$.

M-estimadores

Definition 2.29

Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución $F(., \theta_0)$. Un M-estimador de θ_0 es un estimador definido como

$$\hat{\theta} = \operatorname{argmin}_{\theta} \sum_{i=1}^n \rho(X_i, \theta)$$

Observación 2.30

Los estimadores de mínimos cuadrados, de mínimas desviaciones absolutas y de máxima verosimilitud son M-estimadores.

Capítulo 2. Estimación puntual

Segunda parte: Propiedades de estimadores

August 28, 2025

Criterios de bondad de estimadores

- $X_1, \dots, X_n$ v.a. i.i.d. $X_i \sim \mathcal{U}[0, \theta]$
Estimador de Momentos: $\hat{\theta}_n = 2\bar{X}_n$
Estimador de Máxima Verosimilitud: $\tilde{\theta}_n = \max_{1 \leq i \leq n} (X_i)$
¿Cuál es mejor?
- En el modelo de posición, ¿Qué estimador es mejor, la media o la mediana?

Ejemplo: Estimamos una proporción

Ejemplo 2.31

Queremos estimar a p , la proporción estudiantes de la UBA que está a favor del paro. Para ello, elegiremos n estudiantes de la UBA al azar y se les preguntará si están a favor del paro o no. ¿Cómo estimamos a p ?

$$X_i = \begin{cases} 1 & \text{si la } i \text{ésimo encuestado dice que sí} \\ 0 & \text{si no} \end{cases}$$

- $X_1, \dots, X_n$ son variables aleatorias i.i.d. con distribución $B(1, p)$, siendo p la verdadera proporción que queremos estimar.
- Un estimador puntual (EMM o EMV) de p es $\hat{p}_n = \frac{1}{n} \sum_{i=1}^n X_i$
- Una vez realizado el experimento con $n = 1000$, observamos que hay 853 estudiantes a favor. Obtenemos una **estimación** para p : $\hat{p}_{n \text{ obs}} = 0.853$.
- ¿Por qué tomamos $n = 1000$? ¿Sería más conveniente tomar $n = 2000$? ¿Cómo se aprecia si es mejor una elección que la otra?

Criterios de bondad de un estimador: Sesgo

Definition 2.32

Sea $\mathbf{X}_n = (X_1 \dots X_n)$ una muestra aleatoria de una distribución $F \in \mathcal{F}$, $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$ y supongamos que queremos estimar $q(\theta)$, una función real del parámetro de F .

Un estimador de $q(\theta)$, $T_n = T(\mathbf{X}_n)$, se dice **insesgado** para $q(\theta)$ si

$$\mathbb{E}_\theta(T_n) = q(\theta) \text{ para todo } \theta \in \Theta.$$

Caso contrario, decimos que es **sesgado**.

Un estimador de $q(\theta)$, T_n , se dice **asintóticamente insesgado** para $q(\theta)$ si

$$\lim_{n \rightarrow \infty} \mathbb{E}_\theta(T_n) = q(\theta) \text{ para todo } \theta \in \Theta.$$

Llamamos **sesgo** de un estimador T_n de $q(\theta)$ a

$$\mathbb{B}_\theta(T_n) = \mathbb{E}_\theta(T_n) - q(\theta).$$

Ejemplo

Ejemplo 2.33 (Continuación)

$X_1, \dots, X_n$ son variables aleatorias i.i.d. $X_i \sim B(1, p)$, siendo p la verdadera proporción que queremos estimar. Tenemos que $\mathbb{E}_p(X_1) = p$.

- $\hat{p}_n = \frac{1}{n} \sum_{i=1}^n X_i$
- $\mathbb{E}_p(\hat{p}_n) = \mathbb{E}_p(\bar{X}_n) = \frac{1}{n} \mathbb{E}_p\left(\sum_{i=1}^n X_i\right) = \frac{n}{n} \mathbb{E}_p(X_1) = p$
- En este caso, resulta $\mathbb{E}_p(\hat{p}_n) = p$

Ejemplo: Caso general - F con media y varianza

Ejemplo 2.34

Sea $\mathbf{X}_n = (X_1 \dots X_n)$ una muestra aleatoria de una distribución $F \in \mathcal{F}$, y supongamos que queremos estimar $q_1(F) = \mathbb{E}_F(X_1)$ y $q_2(F) = \mathbb{V}_F(X_1)$.

- ¿Cómo estimamos a $q_1(F)$ y $q_2(F)$?
- Vimos que los estimadores de momentos son:

$$\begin{aligned}\hat{q}_1(F) &= \bar{X}_n \\ \hat{q}_2(F) &= \frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{n} = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2\end{aligned}$$

- ¿Son insesgados?

Ejemplo: Calculemos el sesgo de cada uno

- $E_F(\bar{X}_n) = \frac{1}{n} \mathbb{E}_F\left(\sum_{i=1}^n X_i\right) = \frac{n}{n} \mathbb{E}_F(X_1) = \mathbb{E}_F(X_1) = q_1(F)$

$\Rightarrow \bar{X}_n$ es insesgado!

- $\mathbb{E}_F\left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2\right)$

$$= \frac{1}{n} \sum_{i=1}^n \mathbb{E}_F(X_i^2) - \mathbb{E}_F(\bar{X}^2) = \frac{n}{n} \mathbb{E}_F(X_1^2) - \mathbb{E}_F(\bar{X}^2)$$

$$= \mathbb{V}_F(X_1) + \mathbb{E}_F(X_1)^2 - \left\{ \mathbb{V}_F(\bar{X}) + \mathbb{E}_F(\bar{X})^2 \right\}$$

$$= \mathbb{V}_F(X_1) + \mathbb{E}_F(X_1)^2 - \frac{\mathbb{V}_F(X_1)}{n} - \mathbb{E}_F(X_1)^2 = \frac{n-1}{n} \mathbb{V}_F(X_1)$$

Ejemplo: Calculemos el sesgo de cada uno

- El sesgo es

$$\begin{aligned}\mathbb{B}_F \left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \right) &= \frac{n-1}{n} \mathbb{V}_F(X_1) - \mathbb{V}_F(X_1) \\ &= -\mathbb{V}_F(X_1)/n < 0\end{aligned}$$

⇒ el estimador de momentos es sesgado

sesgo: $-\frac{1}{n} \mathbb{V}_F(X_1)$ subestima!

- El sesgo puede corregirse

$$\frac{n}{n-1} \hat{q}_2(F) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = S^2$$

que hemos llamado **varianza muestral**.

Ejemplo: Caso Normal

En particular, si $\mathbf{X}_n = (X_1 \dots X_n)$ i.i.d. $X_i \sim N(\mu, \sigma^2)$, y queremos estimar a μ y σ^2 .

Como $q_1(F) = \mathbb{E}_F(X_1) = \mu$ y $q_2(F) = \mathbb{V}_F(X_1) = \sigma^2$.

Por lo que hemos visto, $\bar{X}_n$ y $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ son estimadores insesgados de μ y σ^2 , respectivamente.

Error cuadrático medio

$\mathbf{X}_n = (X_1 \dots X_n)$ una m. a. de una distribución $F \in \mathcal{F}$,

$\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$ y queremos estimar $q(\theta)$.

Sea $T_n = T(\mathbf{X}_n)$ un estimador de $q(\theta)$. El error de estimación es:

$$T_n - q(\theta) \quad \text{es una v.a.}$$

Una noción del error cometido está dada por el **Error Cuadrático Medio**

$$ECM_{\theta}(T_n) = \mathbb{E}_{\theta} \left((T_n - q(\theta))^2 \right)$$

El **Error Cuadrático Medio** da un criterio para determinar si un estimador T_n de $q(\theta)$ es mejor que otro W_n , pues basta verificar si

$$ECM_{\theta}(T_n) \leq ECM_{\theta}(W_n) \quad \forall \theta \in \Theta$$

Compromiso sesgo-varianza

Theorem 2.35

$$ECM_{\theta}(T_n) = \mathbb{V}_{\theta}(T_n) + (\mathbb{B}_{\theta}(T_n))^2$$

Proof.

$$\begin{aligned} ECM_{\theta}(T_n) &= \mathbb{E}_{\theta} [(T_n - q(\theta))^2] \\ &= \mathbb{E}_{\theta} [(T_n - \mathbb{E}_{\theta}(T_n) + \mathbb{E}_{\theta}(T_n) - q(\theta))^2] \\ &= \mathbb{V}_{\theta} [(T_n - q(\theta))] + [\mathbb{E}_{\theta}(T_n - q(\theta))]^2 \\ &\quad + 2\mathbb{E}_{\theta} [(T_n - \mathbb{E}_{\theta}(T_n))(\mathbb{E}_{\theta}(T_n) - q(\theta))] \\ &= \mathbb{V}_{\theta} [(T_n - q(\theta))] + [\mathbb{E}_{\theta}(T_n - q(\theta))]^2 \\ &\quad + 2(\mathbb{E}_{\theta}(T_n) - \mathbb{E}_{\theta}(T_n))(\mathbb{E}_{\theta}(T_n) - q(\theta)) \\ &= \mathbb{V}_{\theta} [(T_n - q(\theta))] + [\mathbb{E}_{\theta}(T_n - q(\theta))]^2 \\ &= \mathbb{V}_{\theta}(T_n) + [\mathbb{E}_{\theta}(T_n) - q(\theta)]^2 \\ &= \mathbb{V}_{\theta}(T_n) + (\mathbb{B}_{\theta}(T_n))^2, \text{ como queríamos demostrar.} \end{aligned}$$



ECM

Notemos que

- si el estimador T_n es insesgado, $ECM_\theta(T_n) = \mathbb{V}_\theta(T_n)$
- comparar el ECM de dos estimadores insesgados, se reduce a comparar sus varianzas.

Volvamos al ejemplo de estimar la proporción.

Recordemos que $\hat{p}_n = \frac{1}{n} \sum_{i=1}^n X_i$ es insesgado como estimador de p .

Usando la independencia, tenemos que

$$\mathbb{V}(\hat{p}_n) = \frac{1}{n^2} \sum_{i=1}^n \mathbb{V}(X_i) = \frac{\mathbb{V}(X_1)}{n} = \frac{p(1-p)}{n}.$$

Como $\hat{p}_n$ es insesgado $ECM_p(\hat{p}_n) = \frac{p(1-p)}{n} \rightarrow 0$ si $n \rightarrow \infty$

ECM del EMM y EMV de θ para $U[0, \theta]$

(1) EMM: $\hat{\theta} = 2\bar{X}_n$. Para todo θ tenemos

$$E_{\theta}(\hat{\theta}) = 2E_{\theta}(\bar{X}_n) = 2 \frac{\theta}{2} = \theta$$

$$V_{\theta}(\hat{\theta}) = 4\mathbb{V}_{\theta}(\bar{X}_n) = 4 \frac{\theta^2}{12n} = \frac{\theta^2}{3n}$$

Por lo tanto

$$ECM_{\theta}(\hat{\theta}) = \mathbb{V}_{\theta}(\hat{\theta}) = \frac{\theta^2}{3n}$$

(2) EMV: $\tilde{\theta} = \max \{X_1, \dots, X_n\}$

Probarán que

$$ECM_{\theta}(\tilde{\theta}) = \frac{n}{(n+2)(n+1)^2} \theta^2 + \left(\frac{n}{n+1} \theta - \theta \right)^2 = \frac{2\theta^2}{(n+1)(n+2)}$$

En este caso, tenemos que $\forall n$

$$\frac{2\theta^2}{(n+1)(n+2)} \leq \frac{\theta^2}{3n}$$