

Ejemplo 2.47

Sea $X_1, \dots, X_n$ i.i.d

1. Si $X_i \sim U(0, \theta)$ entonces el estimador de momentos de θ es consistente y hallar su distribución asintótica.
2. Si $X_i \sim \mathcal{E}(\theta)$ entonces el estimador de momentos de θ es consistente y hallar su distribución asintótica.

Método Delta

Theorem 2.48 (Método Delta)

Sea $\{Z_n\}_{n \geq 1}$, una sucesión de variables aleatorias tales que para una sucesión numérica $a_n \uparrow \infty$

$$a_n (Z_n - \theta) \xrightarrow{\mathcal{D}} Z .$$

Sea $q : \mathbb{R} \rightarrow \mathbb{R}$ una función de clase $\mathcal{C}^1$ tal que $q'(\theta) \neq 0$, entonces

$$a_n (q(Z_n) - q(\theta)) \xrightarrow{\mathcal{D}} q'(\theta)Z .$$

Método Delta

Proof.

Esto resulta de un desarrollo de Taylor. En efecto,

$$q(Z_n) = q(\theta) + q'(\theta_n^*) (Z_n - \theta) ,$$

donde θ_n^* es un punto intermedio entre Z_n y θ .

Veamos en primera instancia que entonces $\theta_n^* \xrightarrow{P} \theta$. En efecto,

$$|\theta_n^* - \theta| < |Z_n - \theta| = a_n |Z_n - \theta| \xrightarrow{P} 0$$

y por lo tanto, por la continuidad de q' , $|q'(\theta_n^*) - q'(\theta)| \xrightarrow{P} 0$. Luego, usando el Teorema de Slutsky tenemos

$$a_n (q(Z_n) - q(\theta)) = q'(\theta_n^*) a_n (Z_n - \theta) \xrightarrow{\mathcal{D}} q'(\theta) Z$$



Método Delta

Por ejemplo, si

$$\sqrt{n} (Z_n - \theta) \xrightarrow{\mathcal{D}} N(0, \sigma^2) .$$

y $q : \mathbb{R} \rightarrow \mathbb{R}$ una función de clase $\mathcal{C}^1$ tal que $q'(\theta) \neq 0$.

Entonces

$$\sqrt{n} (q(Z_n) - q(\theta)) \xrightarrow{\mathcal{D}} N\left(0, \sigma^2 [q'(\theta)]^2\right)$$

Ejemplo 2.49

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población con densidad de la forma

$$f(x, \theta) = (1 - \theta)\mathbb{I}_{(-\frac{1}{2}, 0)}(x) + (1 + \theta)\mathbb{I}_{(0, \frac{1}{2})}(x), \quad -1 < \theta < 1$$

¿Cuál es la distribución asintótica del estimador de momentos generalizado que hallamos para $\mathbb{P}_\theta(X > 0)$?

Consistencia de los Estimadores de Máxima Verosimilitud

Theorem 2.50

Sea $X_1, \dots, X_n$ i.i.d. $X_i \sim f(x, \theta_0)$ con $\theta_0 \in \Theta$, donde Θ es un intervalo abierto de $\mathbb{R}$. Supongamos que:

R0. $f(x, \theta)$ es derivable respecto de θ

R1. el conjunto $\mathcal{S} = \{x : f(x, \theta) \neq 0\}$ es independiente de θ .

R2. $\theta_1 \neq \theta_2$ implica que $f(x, \theta_1) \neq f(x, \theta_2)$.

Sea $\hat{\theta}_n$ el estimador de máxima verosimilitud de θ_0 dado por

$$\sum_{i=1}^n \frac{\partial \log f(x_i, \hat{\theta}_n)}{\partial \theta} = 0$$

y supongamos que es único. Entonces,

$$\hat{\theta}_n \xrightarrow{c.s.} \theta_0.$$

Veamos un esbozo de la demostración.

Resultado previo (Video 1)

Lemma 2.51

Sean p y q dos densidades o dos funciones de probabilidad distintas con soporte común. Entonces,

$$\mathbb{E}_p\left(\ln \frac{q(X)}{p(X)}\right) < 0$$

Resultado previo (Video 1)

Lemma 2.51

Sean p y q dos densidades o dos funciones de probabilidad distintas con soporte común. Entonces,

$$\mathbb{E}_p\left(\ln \frac{q(X)}{p(X)}\right) < 0$$

Proof.

Caso continuo. Es claro que no puede ocurrir que $q(X)/p(X) = k$ c.t.p., si fuera así, entonces $\mathbb{E}_p(q(X)/p(X)) = k$ y

$$\int_{-\infty}^{+\infty} \frac{q(x)}{p(x)} p(x) dx = k \Rightarrow \int_{-\infty}^{+\infty} q(x) dx = k$$

luego, $k = 1$ pues $q(x)$ es una densidad, contradice la hipótesis pues $p \neq q$.

Además, $h(x) = -\ln(x)$ es una función estrictamente convexa ya que

$\frac{d^2(-\ln x)}{dx^2} = \frac{1}{x^2} > 0$. Aplicando la desigualdad de Jensen,

$$\mathbb{E}_p\left[-\ln \frac{q(X)}{p(X)}\right] > -\ln\left[\mathbb{E}_p \frac{q(X)}{p(X)}\right] = -\ln \int_{-\infty}^{+\infty} \frac{q(x)}{p(x)} p(x) dx = -\ln 1 = 0.$$

Bosquejo de la demo de la consistencia del EMV (Video 1)

- Log-verosimilitud: $\ell_n(\mathbf{X}_n, \theta) = \ell_n(X_1, \dots, X_n, \theta) = \frac{1}{n} \sum_{i=1}^n \log f(X_i, \theta)$
- $\hat{\theta}_n$ satisface $\ell_n(\mathbf{X}_n, \hat{\theta}_n) = \max_{\theta \in \Theta} \ell_n(\mathbf{X}_n, \theta)$ y $\frac{\partial \ell_n(\mathbf{X}_n, \hat{\theta}_n)}{\partial \theta} = 0$.
- Además, se tiene

$$\ell_n(\mathbf{X}_n, \theta_0 + \delta) - \ell_n(\mathbf{X}_n, \theta_0) = \frac{1}{n} \sum_{i=1}^n \log \left(\frac{f(X_i, \theta_0 + \delta)}{f(X_i, \theta_0)} \right)$$

$$\ell_n(\mathbf{X}_n, \theta_0 - \delta) - \ell_n(\mathbf{X}_n, \theta_0) = \frac{1}{n} \sum_{i=1}^n \log \left(\frac{f(X_i, \theta_0 - \delta)}{f(X_i, \theta_0)} \right)$$

- Aplicando el Lema resulta que

$$\mathbb{E}_{\theta_0} \left(\log \left[\frac{f(X_1, \theta_0 + \delta)}{f(X_1, \theta_0)} \right] \right) < 0 \text{ y } \mathbb{E}_{\theta_0} \left(\log \left[\frac{f(X_1, \theta_0 - \delta)}{f(X_1, \theta_0)} \right] \right) < 0$$

Por la Ley Fuerte, con probabilidad 1 existe un n_0 tal que si $n > n_0$

$$\ell_n(\mathbf{X}_n, \theta_0 + \delta) < \ell_n(\mathbf{X}_n, \theta_0)$$

$$\ell_n(\mathbf{X}_n, \theta_0 - \delta) < \ell_n(\mathbf{X}_n, \theta_0)$$

Bosquejo de la demo de la consistencia del EMV (Video 1)

Luego, para $n > n_0$ en $(\theta_0 - \delta, \theta_0 + \delta)$ existe un máximo relativo, digamos θ_n^* , que satisface

$$\frac{\partial \ell_n(\mathbf{X}_n, \theta_n^*)}{\partial \theta} = 0 ,$$

Como hemos supuesto que $\hat{\theta}_n$ era el único que satisfacía esta igualdad, resulta $\hat{\theta}_n = \theta_n^*$ y por lo tanto

$$\hat{\theta}_n \in (\theta_0 - \delta, \theta_0 + \delta)$$

Cota de Rao–Cramer y Eficiencia

Detalles: ver Apunte de Boente y Yohai.

- Estableceremos la conocida desigualdad de Rao–Cramer que da una cota inferior para la varianza de todo estimador insesgado bajo condiciones de regularidad.
- Veremos luego que, bajo condiciones de regularidad, los EMV alcanzan esta cota asintóticamente.

Estimador de máxima verosimilitud

Recordemos que el estimador de máxima verosimilitud de θ es el valor que maximiza

$$\ell_n(\theta, \mathbf{X}) = \sum_{i=1}^n \log f(X_i, \theta)$$

Estimador de máxima verosimilitud

Recordemos que el estimador de máxima verosimilitud de θ es el valor que maximiza

$$\ell_n(\theta, \mathbf{X}) = \sum_{i=1}^n \log f(X_i, \theta)$$

Bajo **condiciones de regularidad** el EMV se puede hallar como el cero de

$$\frac{\partial}{\partial \theta} \ell_n(\theta, \mathbf{X}_n) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(X_i, \theta)$$

Estimador de máxima verosimilitud

Recordemos que el estimador de máxima verosimilitud de θ es el valor que maximiza

$$\ell_n(\theta, \mathbf{X}) = \sum_{i=1}^n \log f(X_i, \theta)$$

Bajo **condiciones de regularidad** el EMV se puede hallar como el cero de

$$\frac{\partial}{\partial \theta} \ell_n(\theta, \mathbf{X}_n) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(X_i, \theta)$$

Definition 2.52

Llamamos **función de score**:

$$\frac{\partial}{\partial \theta} \log f(X, \theta)$$

Número de información de Fisher

Definition 2.53

Sea una X variable aleatoria con densidad o función de probabilidad puntual f . Llamamos número de información de Fisher de X a

$$I(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(X, \theta) \right)^2 \right]$$

Condiciones de regularidad

- Sea $X_1, \dots, X_n$ i.i.d. $X_i \sim f(x, \theta)$ con $\theta \in \Theta$, $X \sim X_i$, donde Θ es un intervalo abierto de $\mathbb{R}$. Supongamos además de R1 y R2 que:

R3. $f(x, \theta)$ es dos veces diferenciable respecto de θ

R4. La integral $\int f(x, \theta) dx$ es dos veces diferenciable respecto de θ y estas derivadas son intercambiables con el signo integral.

Número de Información de Fisher

Proposición 2.54

Si se cumplen R1 - R4

$$\mathbb{E}_{\theta} \left[\frac{\partial}{\partial \theta} \log f(X, \theta) \right] = 0 \text{ y } \mathbb{V}_{\theta} \left[\frac{\partial}{\partial \theta} \log f(X, \theta) \right] = I(\theta)$$

Proof.



Número de Información de Fisher

Proposición 2.55

Si se cumplen *R1* a *R4* entonces

$$I(\theta) = -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log f(X, \theta) \right]$$

Proof.

Derivamos en ambos miembros de (A)

$$0 = \int_{-\infty}^{\infty} \frac{\partial^2}{\partial \theta^2} \log f(x, \theta) f(x, \theta) dx + \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} \log f(x, \theta) \frac{\partial}{\partial \theta} \log f(x, \theta) f(x, \theta) dx,$$

es decir,

$$0 = \mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log f(X, \theta) \right] + \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(X, \theta) \right)^2 \right]$$

Número de Información de Fisher

Proposición 2.55

Si se cumplen *R1* a *R4* entonces

$$I(\theta) = -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log f(X, \theta) \right]$$

Proof.

Derivamos en ambos miembros de (A)

$$0 = \int_{-\infty}^{\infty} \frac{\partial^2}{\partial \theta^2} \log f(x, \theta) f(x, \theta) dx + \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} \log f(x, \theta) \frac{\partial}{\partial \theta} \log f(x, \theta) f(x, \theta) dx,$$

es decir,

$$0 = \mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log f(X, \theta) \right] + \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(X, \theta) \right)^2 \right] \quad (1)$$

$$= \mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log f(X, \theta) \right] + I(\theta) \quad (2)$$

Ejemplo: $X \sim B(1, \theta)$

Ejemplo 2.56

$$\log f(x, \theta) = x \log \theta + (1 - x) \log(1 - \theta)$$

$$\frac{\partial}{\partial \theta} \log f(x, \theta) = \frac{x}{\theta} - \frac{1 - x}{1 - \theta}$$

$$\frac{\partial^2}{\partial \theta^2} \log f(x; \theta) = -\frac{x}{\theta^2} - \frac{1 - x}{(1 - \theta)^2}$$

Claramente,

$$\begin{aligned} I(\theta) &= -E \left[\frac{-X}{\theta^2} - \frac{1 - X}{(1 - \theta)^2} \right] \\ &= \frac{\theta}{\theta^2} + \frac{1 - \theta}{(1 - \theta)^2} = \frac{1}{\theta} + \frac{1}{(1 - \theta)} = \frac{1}{\theta(1 - \theta)} \end{aligned}$$

que aumenta para valores de θ cercanos a 0 y 1.

Algunas observaciones

- El número de información indica la curvatura de la función que maximizamos al calcular el EMV en θ .
- A mayor curvatura mayor precisión en la estimación.
- El número de información de una muestra de tamaño n , $I_n(\theta)$, es n veces el de una muestra de tamaño 1. (ver Apunte de Boente y Yohai)
- Interpretamos $I_n(\theta)$ como la cantidad de información que nos da la muestra para estimar θ .

Cota de Rao–Cramer

Theorem 2.57

Bajo las condiciones de regularidad R1 a R4 , si $\hat{\theta}_n = \hat{\theta}_n(\mathbf{X}_n)$ es un estimador insesgado de θ , entonces

$$\text{Var}(\hat{\theta}_n) \geq \frac{1}{nI(\theta)}$$

Cota de Rao–Cramer

Theorem 2.57

Bajo las condiciones de regularidad R1 a R4 , si $\hat{\theta}_n = \hat{\theta}_n(\mathbf{X}_n)$ es un estimador insesgado de θ , entonces

$$\mathbb{V}ar(\hat{\theta}_n) \geq \frac{1}{nI(\theta)}$$

Proof.



Cota de Rao–Cramer

Theorem 2.57

Bajo las condiciones de regularidad *R1* a *R4*, si $\hat{\theta}_n = \hat{\theta}_n(\mathbf{X}_n)$ es un estimador insesgado de θ , entonces

$$\text{Var}(\hat{\theta}_n) \geq \frac{1}{nI(\theta)}$$

Proof.



Definition 2.58

Decimos que un estimador insesgado de θ , $\hat{\theta}_n$, es *eficiente* sii su varianza alcanza la cota de Rao–Cramer.

Ejemplo 2.59

Sea $X_1, \dots, X_n \sim B(1, \theta)$. Decidir si $\overline{X}_n$ es eficiente.

Ejemplo

El número de información de Fisher de un vector aleatorio

Definition 2.60

Sea una $\mathbf{X}$ un vector aleatorio con densidad o función de probabilidad puntual f . Llamamos número de información de Fisher de $\mathbf{X}$ a

$$I(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}, \theta) \right)^2 \right]$$

Ejemplo

El número de información de Fisher de un vector aleatorio

Definition 2.60

Sea una $\mathbf{X}$ un vector aleatorio con densidad o función de probabilidad puntual f . Llamamos número de información de Fisher de $\mathbf{X}$ a

$$I(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}, \theta) \right)^2 \right]$$

Observación 2.61

Las proposiciones ?? y ?? también valen para vectores aleatorios y las demostraciones son idénticas al caso univariado.

El número de información de Fisher de un vector aleatorio

Theorem 2.62

Sea $\mathbf{X}_1, \dots, \mathbf{X}_n$ una muestra aleatoria de una distribución con densidad $p(\mathbf{x}, \theta)$ con $\theta \in \Theta \subset \mathbb{R}$. Luego, si se denomina $I_n(\theta)$ al número de información de $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ e $I_1(\theta)$ al número de información de $\mathbf{X}_1$, entonces se tiene $I_n(\theta) = nI_1(\theta)$.

El número de información de Fisher de un vector aleatorio

Demostración.

$$p(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n, \theta) = \prod_{i=1}^n p(\mathbf{x}_i, \theta) \Rightarrow$$

$$\ln p(\mathbf{x}_1, \dots, \mathbf{x}_n, \theta) = \sum_{i=1}^n \ln p(\mathbf{x}_i, \theta) \Rightarrow$$

$$\frac{\partial \ln p(\mathbf{x}_1, \dots, \mathbf{x}_n, \theta)}{\partial \theta} = \sum_{i=1}^n \frac{\partial \ln p(\mathbf{x}_i, \theta)}{\partial \theta}$$

Por ser $\mathbf{X}_1, \dots, \mathbf{X}_n$ independientes, se tiene

$$\begin{aligned} I_n(\theta) &= \text{Var}_{\theta} \left(\frac{\partial \ln p(\mathbf{X}_1, \dots, \mathbf{X}_n, \theta)}{\partial \theta} \right) = \sum_{i=1}^n \text{Var}_{\theta} \left(\frac{\partial \ln p(\mathbf{X}_i, \theta)}{\partial \theta} \right) \\ &= nI_1(\theta) \end{aligned}$$



Distribución Asintótica del EMV

Consideremos además la siguiente condición

- R5. $f(x, \theta)$ es tres veces diferenciable respecto de θ . Además, para todo $\theta \in \Theta$, existen una constante c y una función $M(x)$ tal que
- $$\left| \frac{\partial^3}{\partial \theta^3} \log f(x, \theta) \right| \leq M(x), \text{ para todo } \theta_0 - c < \theta < \theta_0 + c \text{ y todo } x$$
- en el soporte de la X y con $\mathbb{E}_{\theta_0}[M(X)] < \infty$.

Teorema (Video 2)

Theorem 2.63

Si

- *se cumplen R1 a R5*
- $\hat{\theta}_n$ *un estimador de máxima verosimilitud consistente de θ_0 , entonces, $\hat{\theta}_n$ es asintóticamente normal para estimar θ_0 , o sea,*

$$\sqrt{n} \left(\hat{\theta}_n - \theta_0 \right) \xrightarrow{\mathcal{D}} N \left(0, \frac{1}{I(\theta_0)} \right)$$

Bosquejo de la demo (Video 2)

Demostración.

Notamos: $\ell'(\theta) = \frac{\partial \ell_n(\theta, \mathbf{X}_n)}{\partial \theta}$ y $\ell''(\theta) = \frac{\partial^2 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^2}$ $\ell'''(\theta) = \frac{\partial^3 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^3}$

Desarrollo de Taylor:

$$0 = \ell'(\hat{\theta}_n) = \ell'(\theta_0) + (\hat{\theta}_n - \theta_0) \ell''(\theta_0) + \frac{1}{2} \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)^2$$

donde ξ_n es un punto intermedio entre $\hat{\theta}_n$ y θ_0

$$(\hat{\theta}_n - \theta_0) = \frac{-\ell'(\theta_0)}{\ell''(\theta_0) + 1/2 \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)}$$

$$n^{1/2} (\hat{\theta}_n - \theta_0) = \frac{-n^{-1/2} \ell'(\theta_0)}{n^{-1} \ell''(\theta_0) + 1/2 n^{-1} \ell'''(\xi_n) (\hat{\theta}_n - \theta_0)}$$



Bosquejo de la demo (Video 2)

Continuación de la dem.

Primero, consideremos el numerador:

$$\left[n^{-1/2} \ell'(\theta_0) \right] = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{\partial \log f(X_i, \theta_0)}{\partial \theta}$$

Los sumandos son i.i.d. con

$$\mathbb{E}_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = 0$$

y

$$\mathbb{V}ar_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = \mathbb{E}_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right]^2 = I(\theta_0)$$



Bosquejo de la demo (Video 2)

Continuación de la dem.

Los sumandos son i.i.d. con

$$\mathbb{E}_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = 0$$

y

$$\mathbb{V}ar_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = I(\theta_0)$$

Luego, por el TCL,

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \xrightarrow{\mathcal{D}} N(0, I(\theta_0))$$

Bosquejo de la demo (Video 2)

Continuación de la dem.

Los sumandos son i.i.d. con

$$\mathbb{E}_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = 0$$

y

$$\mathbb{V}ar_{\theta_0} \left[\frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = I(\theta_0)$$

Luego, por el TCL,

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \xrightarrow{\mathcal{D}} N(0, I(\theta_0))$$

Consideremos el denominador. Por la L.G.N y los supuestos R1 - R5,

$$-\frac{1}{n} \ell''(\theta_0) + \frac{1}{2n} \ell'''(\xi_n) (\hat{\theta}_n - \theta) \xrightarrow{P} I(\theta_0)$$

y por Slutsky $\sqrt{n} (\hat{\theta}_n - \theta_0) \xrightarrow{\mathcal{D}} N\left(0, \frac{1}{I(\theta_0)}\right)$



Distribución asintótica del EMV

Proposición 2.64

Supongamos que se cumplen R1 a R5 y que

- $\hat{\theta}_n$ un estimador de máxima verosimilitud consistente de θ_0
- $q(\theta)$ derivable con $q'(\theta) \neq 0$ para todo θ ,

entonces, $q(\hat{\theta}_n)$ es asintóticamente normal para estimar $q(\theta)$, o sea,

$$\sqrt{n} \left(q(\hat{\theta}_n) - q(\theta_0) \right) \xrightarrow{\mathcal{D}} N \left(0, \frac{[q'(\theta_0)]^2}{I(\theta_0)} \right)$$

Distribución asintótica del EMV

Proposición 2.64

Supongamos que se cumplen R1 a R5 y que

- $\hat{\theta}_n$ un estimador de máxima verosimilitud consistente de θ_0
- $q(\theta)$ derivable con $q'(\theta) \neq 0$ para todo θ ,

entonces, $q(\hat{\theta}_n)$ es asintóticamente normal para estimar $q(\theta)$, o sea,

$$\sqrt{n} \left(q(\hat{\theta}_n) - q(\theta_0) \right) \xrightarrow{\mathcal{D}} N \left(0, \frac{[q'(\theta_0)]^2}{I(\theta_0)} \right)$$

Definition 2.65

Decimos que una sucesión de estimadores T_n de $q(\theta)$ es **asintóticamente normal y eficiente (A.N.E.)** si

$$\sqrt{n} (T_n - q(\theta_0)) \xrightarrow{\mathcal{D}} N \left(0, \frac{[q'(\theta_0)]^2}{I(\theta_0)} \right)$$