

Dos Muestras

Mediante el método del pivote podemos obtener tests de hipótesis que involucren dos muestras usando los pivotes con los que trabajamos en el contexto de intervalos de confianza.

Dos Muestras

Mediante el método del pivote podemos obtener tests de hipótesis que involucren dos muestras usando los pivotes con los que trabajamos en el contexto de intervalos de confianza.

Ejemplo: Comparación de dos tratamientos

- **Objetivo:** comparar el rendimiento de dos fertilizantes.
- Se divide un terreno en 30 parcelas homogéneas (por ej. cant. sol, humedad, etc.).
- En las 30 parcelas se cultiva la misma variedad de maíz.
- En 15 de ellas se utiliza el fertilizante A y en las restantes el fertilizante B.

Ejemplo: Comparación de dos tratamientos

Datos:

- Parcelas con Tratamiento A



238	237	235	220	233	203	228	220
221	215	218	217	232	225	209	

- Parcelas con Tratamiento B


253	227	241	245	237	248	250	218
239	243	257	208	215	240	229	

Queremos comparar el rendimiento medio de esta variedad de maíz cuando el terreno se trata con estos dos fertilizantes.

Ejemplo: Comparación de dos tratamientos



Ejemplo: Comparación de dos tratamientos



Modelo 1: Muestras normales independientes con igual varianza

Supongamos que:

- $X_1, \dots, X_{n_1} \sim \mathcal{N}(\mu_1, \sigma^2)$ i.i.d.
- $Y_1, \dots, Y_{n_2} \sim \mathcal{N}(\mu_2, \sigma^2)$ i.i.d.

Además, suponemos que las dos muestras aleatorias son independientes entre sí.

Test para $H_0 : \mu_1 - \mu_2 = \Delta$ vs. $H_1 : \mu_1 - \mu_2 \neq \Delta$

Observación. En muchas situaciones $\Delta = 0$. Notemos que, en este caso (y en nuestro ejemplo), podemos reescribir las hipótesis como:

$$H_0 : \mu_1 = \mu_2 \text{ vs. } H_1 : \mu_1 \neq \mu_2$$

Test para $H_0 : \mu_1 - \mu_2 = \Delta$ vs. $H_1 : \mu_1 - \mu_2 \neq \Delta$

Observación. En muchas situaciones $\Delta = 0$. Notemos que, en este caso (y en nuestro ejemplo), podemos reescribir las hipótesis como:

$$H_0 : \mu_1 = \mu_2 \text{ vs. } H_1 : \mu_1 \neq \mu_2$$

Varianzas desconocidas pero iguales: $\sigma_1^2 = \sigma_2^2 = \sigma^2$

Ya vieron que, bajo H_0 , se tiene que

$$\frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta \overset{\text{"}\mu_1 - \mu_2\text{"}}{\sim} \mathcal{N}(0, 1)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0, 1), \quad \frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \sim \mathcal{N}(0, 1)$$

Test para $H_0 : \mu_1 - \mu_2 = \Delta$ vs. $H_1 : \mu_1 - \mu_2 \neq \Delta$

Observación. En muchas situaciones $\Delta = 0$. Notemos que, en este caso (y en nuestro ejemplo), podemos reescribir las hipótesis como:

$$H_0 : \mu_1 = \mu_2 \text{ vs. } H_1 : \mu_1 \neq \mu_2$$

Varianzas desconocidas pero iguales: $\sigma_1^2 = \sigma_2^2 = \sigma^2$

Ya vieron que, bajo H_0 , se tiene que

$$\frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0, 1) \quad , \quad \frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \sim \mathcal{N}(0, 1)$$

Necesitamos estimar σ^2 . Tenemos dos estimadores:

$$S_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (X_i - \bar{X}_{n_1})^2 \quad , \quad S_2^2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (Y_i - \bar{Y}_{n_2})^2$$

Test para $H_0 : \mu_1 - \mu_2 = \Delta$ vs. $H_1 : \mu_1 - \mu_2 \neq \Delta$

Observación. En muchas situaciones $\Delta = 0$. Notemos que, en este caso (y en nuestro ejemplo), podemos reescribir las hipótesis como:

$$H_0 : \mu_1 = \mu_2 \text{ vs. } H_1 : \mu_1 \neq \mu_2$$

Varianzas desconocidas pero iguales: $\sigma_1^2 = \sigma_2^2 = \sigma^2$

Ya vieron que, bajo H_0 , se tiene que

$$\frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0, 1) \quad , \quad \frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \sim \mathcal{N}(0, 1)$$

Necesitamos estimar σ^2 . Tenemos dos estimadores:

$$S_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (X_i - \bar{X}_{n_1})^2 \quad , \quad S_2^2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (Y_i - \bar{Y}_{n_2})^2$$

Los combinamos:

$$S_p^2 = \frac{S_1^2 (n_1 - 1) + S_2^2 (n_2 - 1)}{n_1 + n_2 - 2}$$

El pivote

Bajo H_0 ,

$$\frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \sim t_{n_1+n_2-2}, \quad S_p^2 = \frac{S_1^2 (n_1 - 1) + S_2^2 (n_2 - 1)}{n_1 + n_2 - 2}$$

¿De dónde salía esto?

$$\frac{\frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}}{\sqrt{\frac{S_1^2 (n_1 - 1) + S_2^2 (n_2 - 1)}{\sigma^2 (n_1 + n_2 - 2)}}} \sim \frac{Z}{\sqrt{\frac{V}{n_1 + n_2 - 2}}} \sim t_{n_1+n_2-2}$$

con $Z \sim \mathcal{N}(0, 1)$ y $V \sim \chi_{n_1+n_2-2}^2$ independientes.

$$H_0 : \mu_1 - \mu_2 = \Delta \text{ vs. } H_1 : \mu_1 - \mu_2 \neq \Delta$$

Luego, para construir un test de nivel α , rechazamos H_0 si

$$\frac{|\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta|}{\sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} > t_{n_1+n_2-2, \alpha/2}$$

$$H_0 : \mu_1 - \mu_2 = \Delta \text{ vs. } H_1 : \mu_1 - \mu_2 \neq \Delta$$

Luego, para construir un test de nivel α , rechazamos H_0 si

$$\frac{|\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta|}{\sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} > t_{n_1+n_2-2, \alpha/2}$$

¿Pero cómo sabemos que las varianzas son iguales?

El test más tradicional para chequear esto es el test de F que asume que las dos poblaciones son normales.

Comparación de varianzas

Supongamos que tenemos dos muestras independientes:

- $X_1, \dots, X_{n_1} \sim \mathcal{N}(\mu_1, \sigma_1^2)$ i.i.d.
- $Y_1, \dots, Y_{n_2} \sim \mathcal{N}(\mu_2, \sigma_2^2)$ i.i.d.

Queremos testear a nivel α las hipótesis: $H_0 : \sigma_1^2 = \sigma_2^2$ vs.
 $H_1 : \sigma_1^2 \neq \sigma_2^2$

Parece razonable considerar el cociente

$$\frac{S_1^2}{S_2^2}$$

Como bajo H_0 esperamos que sea cercano a 1, rechazaremos H_0 si es mucho más grande o mucho más pequeño que 1.

Comparación de varianzas


¿Pero conocemos su distribución?

Si $U \sim \chi_k^2$ y $W \sim \chi_m^2$ son independientes, entonces

$$V = \frac{U/k}{W/m} \sim F_{k,m}$$

La distribución $F_{k,m}$ se llama “F de Fisher” o “F de Snedecor” o también distribución “Fisher–Snedecor”.

Densidad de la distribución F



En R,

- ★ la densidad se obtiene con `df(x, df1, df2)`,
- ★ la acumulada se obtiene con `pf(x, df1, df2)`,
- ★ los cuantiles se obtienen con `qf(x, df1, df2)`, y
- ★ los valores aleatorios se obtienen con `rf(x, df1, df2)`.

El pivote

Llamemos $F_{k,m,\beta}$ al punto que cumple

$$\beta = \mathbb{P}(V \geq F_{k,m,\beta}) \quad \text{para} \quad V \sim F_{k,m}.$$

Notemos que, bajo H_0 ,

$$\frac{S_1^2}{S_2^2} \sim F_{n_1-1, n_2-1}$$

Como $X_1, \dots, X_{n_1} \sim N(\mu_1, \sigma_1^2)$ iid $\rightarrow$ indep

$Y_1, \dots, Y_{n_2} \sim N(\mu_2, \sigma_2^2)$ iid

$$\Rightarrow \cdot \frac{(n_1-1)S_1^2}{\sigma_1^2} \sim \chi_{n_1-1}^2$$

$$\cdot \frac{(n_2-1)S_2^2}{\sigma_2^2} \sim \chi_{n_2-1}^2$$

$$\frac{\sum_{i=1}^{n_1} (X_i - \bar{X})^2}{\sigma_1^2}$$

$\rightarrow$ indep.

Fisher-Snedecor

$$\frac{\frac{(n_1-1)S_1^2}{\sigma_1^2} / \cancel{n_1-1}}{\frac{(n_2-1)S_2^2}{\sigma_2^2} / \cancel{n_2-1}}$$

$$\sim F_{n_1-1, n_2-1}$$

$$\text{Bajo } H_0: \frac{S_1^2}{S_2^2} \sim F_{n_1-1, n_2-1} \quad \checkmark$$

$$\leftarrow \frac{\sigma_2^2}{\sigma_1^2} \cdot \frac{S_1^2}{S_2^2}$$

El pivote

Llamemos $F_{k,m,\beta}$ al punto que cumple

$$\beta = \mathbb{P}(V \geq F_{k,m,\beta}) \quad \text{para} \quad V \sim F_{k,m}.$$

Notemos que, bajo H_0 ,

$$\frac{S_1^2}{S_2^2} \sim F_{n_1-1, n_2-1}$$

Por lo tanto, rechazaremos H_0 si

$$\frac{S_1^2}{S_2^2} \leq F_{n_1-1, n_2-1, 1-\alpha/2} \quad \text{o} \quad \frac{S_1^2}{S_2^2} \geq F_{n_1-1, n_2-1, \alpha/2}$$

El pivote

Llamemos $F_{k,m,\beta}$ al punto que cumple

$$\beta = \mathbb{P}(V \geq F_{k,m,\beta}) \quad \text{para} \quad V \sim F_{k,m}.$$

Notemos que, bajo H_0 ,

$$\frac{S_1^2}{S_2^2} \sim F_{n_1-1, n_2-1}$$

Por lo tanto, rechazaremos H_0 si

$$\frac{S_1^2}{S_2^2} \leq F_{n_1-1, n_2-1, 1-\alpha/2} \quad \text{o} \quad \frac{S_1^2}{S_2^2} \geq F_{n_1-1, n_2-1, \alpha/2}$$

¿Cómo comparamos las medias si rechazamos con este test la igualdad de varianzas?

tenemos dos muestras: $X_1 \dots X_{n_1} \sim N(\mu_1, \sigma_1^2)$ iid
 $Y_1 \dots Y_{n_2} \sim N(\mu_2, \sigma_2^2)$ iid } indep.

objetivo: $H_0: \mu_1 = \mu_2$ vs $H_1: \mu_1 \neq \mu_2$. $\leftarrow$ lo sabemos resolver si $\sigma_1^2 = \sigma_2^2$.

cas! Testear $H_0: \sigma_1^2 = \sigma_2^2$ vs $H_1: \sigma_1^2 \neq \sigma_2^2$ no es exactamente lo que queremos. ¿Y entonces? Se usa nivel $\alpha = 0,20$

¿Y sobre la normalidad? quisiéramos testear $H_0: X \sim \text{No Normal}$
vs $H_1: X \sim \text{Normal}$, no lo podemos hacer. Si podemos testear

$H_0: X \sim \text{Normal}$ vs $H_1: X \sim \text{No Normal}$.

cas! $\mathcal{F}$: familia de todas las distribuciones
 $\mathcal{N}$: familia de distribuciones normales

$H_0: F_X \in \mathcal{N}$ vs $H_1: F_X \notin \mathcal{N}$

Existen diferentes estrategias: Shapiro-Wilk o Kolmogorov-Smirnov.
También se usa $\alpha = 0,20$. Estos tests se llaman, **tests de**

bondad de ajuste.
Respecto del nivel: test $\swarrow \searrow$ test $\swarrow \searrow$
test

terminamos con tests que no tienen el nivel que queremos. En estas situaciones deberíamos calcular el nivel múltiplo. En se sabe.

Modelo 2: Muestras normales independientes con distintas varianzas

- $X_1, \dots, X_{n_1} \sim \mathcal{N}(\mu_1, \sigma_1^2)$ i.i.d.
- $Y_1, \dots, Y_{n_2} \sim \mathcal{N}(\mu_2, \sigma_2^2)$ i.i.d.

Las dos muestras aleatorias se suponen independientes entre sí.

Seguimos queriendo testear

$$H_0 : \mu_1 - \mu_2 = \Delta \quad \text{vs.} \quad H_1 : \mu_1 - \mu_2 \neq \Delta$$

El problema de comparar las medias en estas condiciones se conoce como el *problema de Fisher-Behrens*.

Parece natural considerar el estadístico:

$$T^* = \frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

Modelo 2: Muestras normales independientes con distintas varianzas

$$T^* = \frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

Sin embargo, la distribución de T^* ya **no** es una t de Student bajo H_0 , su distribución es la de Fisher-Behrens y depende de n_1, n_2 y de $\sigma_1^2/\sigma_2^2 \implies$ ya no tenemos un pivote (depende de parámetros desconocidos).

Modelo 2: Muestras normales independientes con distintas varianzas

$$T^* = \frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

Sin embargo, la distribución de T^* ya **no** es una t de Student bajo H_0 , su distribución es la de Fisher-Behrens y depende de n_1, n_2 y de $\sigma_1^2/\sigma_2^2 \implies$ ya no tenemos un pivote (depende de parámetros desconocidos).

Hay distintas soluciones a este problema, una de las más usadas se basa la solución de Welch (1947) en la que la distribución de T^* se aproxima por una t_ν , en la que los grados de libertad ν están dados por

$$\nu = \frac{(S_1^2/n_1 + S_2^2/n_2)^2}{(S_1^2/n_1)^2/(n_1 - 1) + (S_2^2/n_2)^2/(n_2 - 1)}$$

tenemos dos caminos

$$1^{\circ}) H_0: \sigma_1^2 = \sigma_2^2$$

Si

$$H_0: \mu_1 = \mu_2$$

No

2^o) No testeo nada de las varianzas

$$H_0: \mu_1 = \mu_2$$

test de Welch



Volvamos al ejemplo de los tratamientos

Veamos cómo se calcula en R:

```
A <- c(238, 237, 235, 220, 233, 203, 228, 220, 221,  
215, 218, 217, 232, 225, 209)
```

```
B <- c(253, 227, 241, 245, 237, 248, 250, 218, 239,  
243, 257, 208, 215, 240, 229)
```

```
xraya1 <- mean(A)  
xraya2 <- mean(B)  
> c(xraya1, xraya2)  
[1] 223.4000 236.6667
```

```
s1 <- sd(A)  
s2 <- sd(B)  
n1<-length(A)  
n2 <- length(B)  
sp2 <- (s1^2* (n1-1) + s2^2 * (n2-1))/(n1+n2-2)  
> c(s1^2, s2^2, sp2)  
[1] 108.2571 208.8095 158.5333
```

Volvamos al ejemplo de los tratamientos

El cociente entre las varianzas es:

```
> s1^2/s2^2  
[1] 0.5184493
```

Test para $H_0 : \sigma_1^2 = \sigma_2^2$ vs. $H_1 : \sigma_1^2 \neq \sigma_2^2$

A mano, comparamos con los cuantiles de la distribución $F_{n_1-1, n_2-1} = F_{14,14}$ y tenemos:

```
alpha <- 0.05  
> c(qf(alpha/2, n1-1, n2-1), qf(1-alpha/2, n1-1, n2-1))  
[1] 0.3357296 2.9785875
```

Volvamos al ejemplo de los tratamientos

El cociente entre las varianzas es:

```
> s1^2/s2^2  
[1] 0.5184493
```


Test para $H_0 : \sigma_1^2 = \sigma_2^2$ vs. $H_1 : \sigma_1^2 \neq \sigma_2^2$

A mano, comparamos con los cuantiles de la distribución $F_{n_1-1, n_2-1} = F_{14,14}$ y tenemos:

```
alpha <- 0.05  
> c(qf(alpha/2, n1-1, n2-1), qf(1-alpha/2, n1-1, n2-1))  
[1] 0.3357296 2.9785875
```

Teniendo en cuenta que el valor del estadístico observado fue de 0.5184493, el p-valor se calcula como:

```
p.valor <- pf(s1^2/s2^2, n1-1, n2-1)*2  
> p.valor  
[1] 0.2313703
```



Volvamos al ejemplo de los tratamientos

También tenemos una instrucción que hace el test deseado:

```
> var.test(A, B, alternative = "two.sided")
```

F test to compare two variances

data: A and B

F = 0.51845, num df = 14, denom df = 14, p-value = 0.2314

alternative hypothesis: true ratio of variances is not equal
to 1

95 percent confidence interval:

0.1740588 1.5442465

sample estimates:

ratio of variances

0.5184493

Volvamos al ejemplo de los tratamientos

También tenemos una instrucción que hace el test deseado:

```
> var.test(A, B, alternative = "two.sided")
```

```
F test to compare two variances
```

```
data: A and B
```

```
F = 0.51845, num df = 14, denom df = 14, p-value = 0.2314
```

```
alternative hypothesis: true ratio of variances is not equal  
to 1
```

```
95 percent confidence interval:
```

```
0.1740588 1.5442465
```

```
sample estimates:
```

```
ratio of variances
```

```
0.5184493
```

Mirando el p-valor podemos ver que, a nivel $\alpha = 0.20$, no tengo ^{evidencia} ~~eficiencia~~ suficiente para rechazar H_0 . En definitiva, pareciera razonable suponer igualdad de varianzas.

Volvamos al ejemplo de los tratamientos

Si queremos testear

$$H_0 : \mu_1 - \mu_2 = 0 \quad \text{vs.} \quad H_1 : \mu_1 - \mu_2 \neq 0$$

suponiendo igualdad de varianzas. Lo hacemos en R:

```
Tobs <- (xraya1-xraya2)/sqrt(sp2*(1/n1+1/n2))  
> Tobs  
[1] -2.885574  
> c(qt(alpha/2, n1+n2-2),qt(1-alpha/2, n1+n2-2))  
[1] -2.048407  2.048407
```

Volvamos al ejemplo de los tratamientos

Si queremos testear

$$H_0 : \mu_1 - \mu_2 = 0 \quad \text{vs.} \quad H_1 : \mu_1 - \mu_2 \neq 0$$

suponiendo igualdad de varianzas. Lo hacemos en R:

```
Tobs <- (xraya1-xraya2)/sqrt(sp2*(1/n1+1/n2))
> Tobs
[1] -2.885574
> c(qt(alpha/2, n1+n2-2),qt(1-alpha/2, n1+n2-2))
[1] -2.048407  2.048407
```

Y el p-valor se calcula como:

```
p.valor <- (1-pt(abs(Tobs), n1+n2-2))*2
> p.valor
[1] 0.007440352
```

Volvamos al ejemplo de los tratamientos

Si queremos testear

$$H_0 : \mu_1 - \mu_2 = 0 \quad \text{vs.} \quad H_1 : \mu_1 - \mu_2 \neq 0$$

suponiendo igualdad de varianzas. Lo hacemos en R:

```
Tobs <- (xraya1-xraya2)/sqrt(sp2*(1/n1+1/n2))
> Tobs
[1] -2.885574
> c(qt(alpha/2, n1+n2-2),qt(1-alpha/2, n1+n2-2))
[1] -2.048407  2.048407
```

Y el p-valor se calcula como:

```
p.valor <- (1-pt(abs(Tobs), n1+n2-2))*2
> p.valor
[1] 0.007440352
```

Conclusión: Rechazamos H_0 y, por lo tanto, hay evidencia estadística suficiente para decir que las medias de los dos tratamientos es distinta.

Volvamos al ejemplo de los tratamientos

Usando el `t.test`:

```
> t.test(A, B, var.equal = TRUE)
```

Two Sample t-test

data: A and B

$t = -2.8856$, $df = 28$, $p\text{-value} = 0.00744$

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

-22.684390 -3.848943

sample estimates:

mean of x mean of y

223.4000 236.6667

El default es (sacado del help de R) incluye $\mu = 0$ (donde μ es el Δ cuando hay dos muestras involucradas).

¿Y si no queremos suponer igualdad de varianzas?

El estadístico del test observado es:

```
Tobs <- (xraya1-xraya2)/sqrt(s1^2/n1+s2^2/n2)
> Tobs
[1] -2.885574
```

(Coincide con el otro T_{obs} porque $n_1 = n_2$)

Y los grados de libertad son, en este caso,

```
grados.welch <- (s1^2/n1+s2^2/n2)^2 / ((s1^2/n1)^2/(n1-1)
+(s2^2/n2)^2/(n2-1))
> grados.welch
[1] 25.44128
```

Luego, el p-valor se obtiene como

```
p.valor <- (1-pt(abs(Tobs), grados.welch))*2
> p.valor
[1] 0.007853842
```

¿Y si no queremos suponer igualdad de varianzas?

O bien

```
> t.test(A, B, var.equal = FALSE)
```

Welch Two Sample t-test

data: A and B

t = -2.8856, df = 25.441, p-value = 0.007854

alternative hypothesis: true difference in means is not equal
to 0

95 percent confidence interval:

-22.727247 -3.806086

sample estimates:

mean of x mean of y

223.4000 236.6667

Regiones de confianza

Dado un vector $\mathbf{X}$ con distribución perteneciente a la familia $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$, *una región de confianza $\mathcal{S}(\mathbf{X})$ para $\boldsymbol{\theta}$ con nivel de confianza $1 - \alpha$* será una función que a cada $\mathbf{X}$ le hace corresponder un subconjunto $\mathcal{S}(\mathbf{X}) \subseteq \Theta$ de manera que

$$\mathbb{P}_{\boldsymbol{\theta}}(\boldsymbol{\theta} \in \mathcal{S}(\mathbf{X})) = 1 - \alpha, \quad \forall \boldsymbol{\theta} \in \Theta$$

Es decir, $\mathcal{S}(\mathbf{X})$ cubre el valor verdadero del parámetro con probabilidad $1 - \alpha$.

Regiones de confianza

Dado un vector $\mathbf{X}$ con distribución perteneciente a la familia $F(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} \in \Theta$, *una región de confianza $\mathcal{S}(\mathbf{X})$ para $\boldsymbol{\theta}$ con nivel de confianza $1 - \alpha$* será una función que a cada $\mathbf{X}$ le hace corresponder un subconjunto $\mathcal{S}(\mathbf{X}) \subseteq \Theta$ de manera que

$$\mathbb{P}_{\boldsymbol{\theta}}(\boldsymbol{\theta} \in \mathcal{S}(\mathbf{X})) = 1 - \alpha, \quad \forall \boldsymbol{\theta} \in \Theta$$

Es decir, $\mathcal{S}(\mathbf{X})$ cubre el valor verdadero del parámetro con probabilidad $1 - \alpha$.

Caso particular: Si $\boldsymbol{\theta} \in \mathbb{R}$ se dirá que $\mathcal{S}(\mathbf{X})$ es un *intervalo de confianza* ↺

$$\mathcal{S}(\mathbf{X}) = [a(\mathbf{X}), b(\mathbf{X})].$$

La longitud de $\mathcal{S}(\mathbf{X})$ es

$$L = b(\mathbf{X}) - a(\mathbf{X}).$$

Relación entre Tests e Intervalos de confianza

- $\mathbf{X} \sim F(\mathbf{x}, \boldsymbol{\theta}), \boldsymbol{\theta} \in \Theta$.

Para cada $\boldsymbol{\theta}_0$ fijo sea $\phi_{\boldsymbol{\theta}_0}$, un test no aleatorizado de nivel α , para

$$H_0 : \boldsymbol{\theta} = \boldsymbol{\theta}_0 \quad \text{vs.} \quad H_1 : \boldsymbol{\theta} \neq \boldsymbol{\theta}_0.$$

Relación entre Tests e Intervalos de confianza

- $\mathbf{X} \sim F(\mathbf{x}, \boldsymbol{\theta}), \boldsymbol{\theta} \in \Theta$.

Para cada $\boldsymbol{\theta}_0$ fijo sea $\phi_{\boldsymbol{\theta}_0}$, un test no aleatorizado de nivel α , para

$$H_0 : \boldsymbol{\theta} = \boldsymbol{\theta}_0 \quad \text{vs.} \quad H_1 : \boldsymbol{\theta} \neq \boldsymbol{\theta}_0.$$

- $\mathcal{A}(\boldsymbol{\theta}_0)$: Región de aceptación de $\phi_{\boldsymbol{\theta}_0}$.
- Notemos que

$$P_{\boldsymbol{\theta}_0}(\mathbf{X} \in \mathcal{A}(\boldsymbol{\theta}_0)) = 1 - \alpha.$$

$$\mathcal{R}(\boldsymbol{\theta}_0) = \{x \in \mathbb{R}^n : \phi_{\boldsymbol{\theta}_0}(x) = 1\} \Rightarrow \mathcal{A}(\boldsymbol{\theta}_0) = \{x \in \mathbb{R}^n : \phi_{\boldsymbol{\theta}_0}(x) = 0\}$$

$$P_{\boldsymbol{\theta}_0}(x \in \mathcal{A}(\boldsymbol{\theta}_0)) = 1 - P_{\boldsymbol{\theta}_0}(x \notin \mathcal{A}(\boldsymbol{\theta}_0)) = 1 - \underbrace{P_{\boldsymbol{\theta}_0}(x \in \mathcal{R}(\boldsymbol{\theta}_0))}_{\text{nivel} = \alpha} = 1 - \alpha \quad \checkmark$$

Relación entre Tests e Intervalos de confianza

- $\mathbf{X} \sim F(\mathbf{x}, \boldsymbol{\theta}), \boldsymbol{\theta} \in \Theta$.

Para cada $\boldsymbol{\theta}_0$ fijo sea $\phi_{\boldsymbol{\theta}_0}$, un test no aleatorizado de nivel α , para

$$H_0 : \boldsymbol{\theta} = \boldsymbol{\theta}_0 \quad \text{vs.} \quad H_1 : \boldsymbol{\theta} \neq \boldsymbol{\theta}_0.$$

- $\mathcal{A}(\boldsymbol{\theta}_0)$: Región de aceptación de $\phi_{\boldsymbol{\theta}_0}$.
- Notemos que

$$P_{\boldsymbol{\theta}_0}(\mathbf{X} \in \mathcal{A}(\boldsymbol{\theta}_0)) = 1 - \alpha.$$

- Familias de regiones de aceptación:

$$\mathcal{S}(\mathbf{X}) = \{\boldsymbol{\theta} : \phi_{\boldsymbol{\theta}}(\mathbf{X}) = 0\} = \{\boldsymbol{\theta} : \mathbf{X} \in \mathcal{A}(\boldsymbol{\theta})\}$$

$\implies \mathcal{S}(\mathbf{X})$ es una **región de confianza de nivel $1 - \alpha$** para $\boldsymbol{\theta}$.

Decimos que $S(X)$ es una región de confianza de nivel $1-\alpha$ para θ

$$n \quad P_{\theta}(\theta \in S(X)) = 1-\alpha \quad \forall \theta \in \Theta$$

Sea $\theta \in \Theta$ fijo. Luego

$$P_{\theta}(\theta \in S(X)) = P_{\theta}(\phi_{\theta}(X) = 0) = P_{\theta}(X \in A(\theta)) = 1-\alpha \quad \checkmark$$

Como vale para cualquier $\theta \in \Theta$, tenemos el resultado. $\square$

Relación entre Test e Intervalos de confianza

- Recíprocamente, si $\mathcal{S}(\mathbf{X})$ es una región de confianza de nivel $1 - \alpha$ para θ , el test

$$\phi_{\theta_0}(\mathbf{X}) = \begin{cases} 1 & \text{si } \theta_0 \notin \mathcal{S}(\mathbf{X}) \\ 0 & \text{si } \theta_0 \in \mathcal{S}(\mathbf{X}) \end{cases}.$$

es un test de nivel de α para testear

$$H_0 : \theta = \theta_0 \quad \text{vs.} \quad H_1 : \theta \neq \theta_0.$$

$$\begin{aligned} \text{Nivel} &= P_{\theta_0}(\phi_{\theta_0}(\mathbf{X}) = 1) = P_{\theta_0}(\theta_0 \notin \mathcal{S}(\mathbf{X})) = 1 - \underbrace{P_{\theta_0}(\theta_0 \in \mathcal{S}(\mathbf{X}))}_{1 - \alpha \text{ por def.}} \\ &= 1 - (1 - \alpha) = \alpha \quad \checkmark \end{aligned}$$

Relación entre Test e Intervalos de confianza

En general, bajo ciertas condiciones que van más allá del panorama de la materia, podemos decir que:

- Para obtener un intervalos de confianza $[L(\mathbf{X}), U(\mathbf{X})]$ se puede considerar la región de aceptación de un test de la forma $H_0 : \theta = \theta_0$ vs. $H_1 : \theta \neq \theta_0$ y despejar en términos de θ .
- Para obtener una cota inferior de confianza $[L(\mathbf{X}), +\infty)$ se puede considerar la región de aceptación de un test de la forma $H_0 : \theta = \theta_0$ vs. $H_1 : \theta > \theta_0$ y despejar en términos de θ .
- Para obtener una cota superior de confianza $(-\infty, U(\mathbf{X})]$ se puede considerar la región de aceptación de un test de la forma $H_0 : \theta = \theta_0$ vs. $H_1 : \theta < \theta_0$ y despejar en términos de θ .

Veamos un ejemplo.

Ejemplo

Sea $X_1, \dots, X_n$ una m. a. de una distribución $N(\mu, \sigma_0^2)$ con σ_0^2 conocido. Vimos que el test UMP para

$$H_0 : \mu = \mu_0 \quad \text{vs.} \quad H_1 : \mu > \mu_0$$

es de la forma

$$\varphi_{\mu_0}(\mathbf{X}) = \begin{cases} 1 & \text{si } \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma_0} > z_\alpha \\ 0 & \text{si } \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma_0} \leq z_\alpha \end{cases}$$

Considerando la región de aceptación del test y despejando, tenemos:

$$\begin{aligned} S(\mathbf{X}) &= \{\mu \in \mathbb{R} : \varphi_\mu(\mathbf{X}) = 0\} = \{\mu : \bar{X} \in A(\mu)\} \\ &= \{\mu \in \mathbb{R} : \sqrt{n} \frac{\bar{X} - \mu}{\sigma_0} \leq z_\alpha\} \quad \text{CA: } \bar{X} \leq \left(\frac{z_\alpha \cdot \sigma_0}{\sqrt{n}} \right) + \mu \\ &= \{\mu \in \mathbb{R} : \bar{X} - \frac{\sigma_0}{\sqrt{n}} z_\alpha \leq \mu\} \end{aligned}$$

Ejemplo

Sea $X_1, \dots, X_n$ una m. a. de una distribución $N(\mu, \sigma_0^2)$ con σ_0^2 conocido. Vimos que el test UMP para

$$H_0 : \mu = \mu_0 \quad \text{vs.} \quad H_1 : \mu > \mu_0$$

es de la forma

$$\varphi_{\mu_0}(\mathbf{X}) = \begin{cases} 1 & \text{si } \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma_0} > z_\alpha \\ 0 & \text{si } \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma_0} \leq z_\alpha \end{cases}$$

Considerando la región de aceptación del test y despejando, tenemos:

$$\begin{aligned} S(\mathbf{X}) &= \{\mu \in \mathbb{R} : \varphi_\mu(\mathbf{X}) = 0\} \\ &= \left\{ \mu \in \mathbb{R} : \mu \geq \bar{X} - z_\alpha \frac{\sigma_0}{\sqrt{n}} \right\} \end{aligned}$$

Ejemplo

Luego,

$$L(\mathbf{X}) = \bar{X} - z_{\alpha} \frac{\sigma_0}{\sqrt{n}}$$

es cota inferior para μ y

$$I = [L(\mathbf{X}), +\infty) = \left[\bar{X} - z_{\alpha} \frac{\sigma_0}{\sqrt{n}} ; +\infty \right)$$

es un **intervalo de confianza *unilateral*** de nivel $1 - \alpha$ para μ .

Caso asintótico

Supongamos que $X_1, \dots, X_n$ es una m. a. de una distribución perteneciente a la familia $F(x, \boldsymbol{\theta})$ y que para cada $\boldsymbol{\theta}_0$ se tiene una sucesión de tests $\varphi_{n, \boldsymbol{\theta}_0}(X_1, \dots, X_n)$ con nivel asintótico $1 - \alpha$ para

$$H_0 : \boldsymbol{\theta} = \boldsymbol{\theta}_0 \quad \text{vs.} \quad H_1 : \boldsymbol{\theta} \neq \boldsymbol{\theta}_0$$

Luego, puede construirse una **sucesión de regiones de confianza con nivel asintótico $1 - \alpha$** definiendo

$$S_n(X_1, \dots, X_n) = \{\boldsymbol{\theta} : \varphi_{n, \boldsymbol{\theta}}(\mathbf{X}) = 0\}.$$

Caso asintótico

Supongamos que $X_1, \dots, X_n$ es una m. a. de una distribución perteneciente a la familia $F(x, \boldsymbol{\theta})$ y que para cada $\boldsymbol{\theta}_0$ se tiene una sucesión de tests $\varphi_{n, \boldsymbol{\theta}_0}(X_1, \dots, X_n)$ con nivel asintótico $1 - \alpha$ para

$$H_0 : \boldsymbol{\theta} = \boldsymbol{\theta}_0 \quad \text{vs.} \quad H_1 : \boldsymbol{\theta} \neq \boldsymbol{\theta}_0$$

Luego, puede construirse una **sucesión de regiones de confianza con nivel asintótico $1 - \alpha$** definiendo

$$S_n(X_1, \dots, X_n) = \{\boldsymbol{\theta} : \varphi_{n, \boldsymbol{\theta}}(\mathbf{X}) = 0\}.$$

Recíprocamente, dada una sucesión de regiones de confianza $S_n(X_1, \dots, X_n)$ de nivel asintótico $1 - \alpha$, si definimos

$$\varphi_{n, \boldsymbol{\theta}_0}(\mathbf{X}) = \begin{cases} 1 & \text{si } \boldsymbol{\theta}_0 \notin S_n(X_1, \dots, X_n) \\ 0 & \text{si } \boldsymbol{\theta}_0 \in S_n(X_1, \dots, X_n) \end{cases}$$

se tiene que $\varphi_{n, \boldsymbol{\theta}_0}$ es una **sucesión de tests con nivel de significación asintótico α** para

$$H_0 : \boldsymbol{\theta} = \boldsymbol{\theta}_0 \quad \text{vs.} \quad H_1 : \boldsymbol{\theta} \neq \boldsymbol{\theta}_0.$$

Caso asintótico: ejemplo

Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución $Bi(\theta, 1)$. Ya hemos visto que, cuando $\theta = \theta_0$,

$$\sqrt{n} \frac{\bar{X} - \theta_0}{\sqrt{\theta_0(1 - \theta_0)}}$$

converge en distribución a la $N(0, 1)$.

Un intervalo de confianza para θ de nivel asintótico $1 - \alpha$ viene dado por

$$S_n(\mathbf{X}) = \left\{ \theta : \sqrt{n} \frac{|\bar{X} - \theta|}{\sqrt{\theta(1 - \theta)}} < z_{\frac{\alpha}{2}} \right\}.$$

Caso asintótico: ejemplo

Luego, un test de significación asintótico α para

$$H_0 : \theta = \theta_0 \quad \text{vs.} \quad H_1 : \theta \neq \theta_0$$

está dado por

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \text{si } \sqrt{n} \frac{|\bar{X} - \theta_0|}{\sqrt{\theta_0(1 - \theta_0)}} \geq z_{\frac{\alpha}{2}} \\ 0 & \text{si } \sqrt{n} \frac{|\bar{X} - \theta_0|}{\sqrt{\theta_0(1 - \theta_0)}} < z_{\frac{\alpha}{2}} . \end{cases}$$