

Modelo Lineal

IECD

Modelización y Predicción

Algunos de los métodos estadísticos más extendidos se ocupan de la modelización de datos y de la predicción.

Muchas de estas técnicas estadísticas se encuadran en lo que hoy se conoce como **aprendizaje estadístico** (AE).

El AE abarca una amplia cantidad de técnicas que ayudan a comprender los datos cuando se analizan varias variables al mismo tiempo, ya sea postulando modelos o encontrando relaciones entre las variables o estructuras que ayudan a su comprensión.

Modelización y Predicción

Algunas de los métodos estadísticos más extendidos se ocupan de la modelización de datos y de la predicción.

Muchas de estas técnicas estadísticas se encuadran en lo que hoy se conoce como **aprendizaje estadístico** (AE).

El AE abarca una amplia cantidad de técnicas que ayudan a comprender los datos cuando se analizan varias variables al mismo tiempo, ya sea postulando modelos o encontrando relaciones entre las variables o estructuras que ayudan a su comprensión.

Los métodos de AE pueden reunirse en dos grandes grupos:

- **Aprendizaje Supervisado**: una de las variables es identificada como una respuesta.
- **Aprendizaje No Supervisado**: todas las variables cumplen un rol análogo.

Aprendizaje Estadístico

Algunos ejemplos de aprendizaje estadístico:

- Predecir si un paciente hospitalizado tendrá un segundo infarto de miocardio o no teniendo en cuenta mediciones clínicas, dietas y variables demográficas.
- Identificar los factores de riesgo de cáncer de próstata, usando mediciones clínicas y variables demográficas.
- Predecir los precios que tendrán en 6 meses las acciones de ciertas compañías a partir de mediciones del rendimiento de las compañías y datos macroeconómicos.
- Estimar la cantidad de glucosa en sangre que tendrá un individuo diabético a partir del espectro de absorción infrarrojo de la sangre.

Los dos primeros problemas están en el campo de lo que conocemos como clasificación, los dos últimos son un problema de regresión.

Ejemplo: alturas de madres e hijas


Pearson organizó la recolección de datos de 1100 familias en Inglaterra en el período 1893 a 1898. El paquete `alr4` de R contiene el conjunto de datos `Heights` que corresponde a la altura en pulgadas de madres e hijas (con hasta dos hijas por madre).

Las hijas tienen por lo menos 18 años y todas las madres son menores de 65 años.


Originalmente los datos aparecen en una tabla redondeados a la pulgada más cercana. Sin embargo, la librería de R les agrega un error de redondeo para que el gráfico no sea discreto.

Ejemplo: alturas de madres e hijas



```
library(alr4)  
data(Heights)
```



Ejemplo: alturas de madres e hijas



Ejemplo: alturas de madres e hijas



¿Cuánto medirá de grande?



¿Qué información adicional tenemos?

Escenario 1: ninguna

Escenario 2: sexo: será niña

Sabemos algo de la familia....

Escenario 3: será niña y la madre mide 156 cm.

Escenario 4: será niña, la madre mide 156 cm y el padre 178 cm.

Escenario 1: Mejor predictor constante

Queremos predecir cuánto medirá la hija de grande.

¿Cuál es la mejor predicción que podemos hacer? Sin información adicional, seguramente nuestra predicción será mediante una constante c . Queremos que la diferencia entre Y y c , digamos $(Y - c)^2$ sea pequeña, pero recordemos que es una v.a.

Podemos resumirla en un número, por ej., mediante el valor esperado:

Error cuadrático medio de predicción de c :

$$ECM(Y, c) = \mathbb{E}[(Y - c)^2]$$

¿Cuál es el mejor predictor constante?

Si Y es una v.a. con $\mathbb{E}(Y^2) < \infty$, entonces $\mu = \mathbb{E}(Y)$ es el mejor predictor constante en términos del error cuadrático medio (de predicción), en tanto para toda $c \in \mathbb{R}$

$$ECM(Y, \mu) \leq ECM(Y, c)$$

Sea $c \in \mathbb{R}$

$$\begin{aligned} ECM(Y, c) &= E((Y-c)^2) = E((Y-\mu + \mu - c)^2) = \\ &= E((Y-\mu)^2 + (\mu - c)^2 + 2(Y-\mu)(\mu - c)) = \\ &= E((Y-\mu)^2) + (\mu - c)^2 + 2(\mu - c) \underbrace{E(Y-\mu)}_{=0} \\ &= ECM(Y, \mu) + \underbrace{(\mu - c)^2}_{\geq 0} \geq ECM(Y, \mu) \quad \checkmark \end{aligned}$$

¿Cuál es el mejor predictor constante?

Notemos además que

$$\mathbb{E}[(Y - c)^2] = \mathbb{E}[(Y - \mu)^2] + (\mu - c)^2 = \text{Var}(Y) + (\mathbb{E}[Y] - c)^2$$

Por lo tanto, como $ECM(Y, \mu) = \text{Var}(Y)$, podemos pensar que éste es el precio que pagamos por la predecir a la v.a. Y por una constante.

Otros escenarios

¿Cuál es el mejor predictor de Y basado en X ?

En los otros escenarios tenemos información adicional dada a través de X , es decir, de otra/s variable/s.

Conociendo X , ahora queremos predecir a Y . Por ejemplo, sabemos que será niña o sabemos la altura de la madre o ambas cosas.

En este caso nuestra predicción será una función de X , digamos $m(X)$ y buscamos ahora que

$$ECM(Y, m(X)) = \mathbb{E} [(Y - m(X))^2]$$

sea tan pequeño como sea posible.

Otros escenarios

¿Cuál es el mejor predictor de Y basado en X ?

En los otros escenarios tenemos información adicional dada a través de X , es decir, de otra/s variable/s.

Conociendo X , ahora queremos predecir a Y . Por ejemplo, sabemos que será niña o sabemos la altura de la madre o ambas cosas.

En este caso nuestra predicción será una función de X , digamos $m(X)$ y buscamos ahora que

$$ECM(Y, m(X)) = \mathbb{E} [(Y - m(X))^2]$$

sea tan pequeño como sea posible.

Debemos elegir, entonces a m como **la esperanza condicional**.

¿Cuál es el mejor predictor basado en X ?

En efecto, si Y es una v.a. con $\mathbb{E}(Y^2) < \infty$, entonces $\tilde{m}(X) = \mathbb{E}(Y \mid X)$ es el mejor predictor basado en X , es decir, es la mejor aproximación en términos del error cuadrático medio en tanto para toda $m(X)$ con esperanza al cuadrado finita tenemos que

$$ECM(Y, \tilde{m}(X)) \leq ECM(Y, m(X))$$

¿Cuál es el mejor predictor basado en X ?

En efecto, si Y es una v.a. con $\mathbb{E}(Y^2) < \infty$, entonces $\tilde{m}(X) = \mathbb{E}(Y \mid X)$ es el mejor predictor basado en X , es decir, es la mejor aproximación en términos del error cuadrático medio en tanto para toda $m(X)$ con esperanza al cuadrado finita tenemos que

$$ECM(Y, \tilde{m}(X)) \leq ECM(Y, m(X))$$

Demostración: Sea $m(X)$ tal que $\mathbb{E}(m(X)^2) < \infty$, luego

$$\mathbb{E}[(Y - m(X))^2] =$$

¿Cuál es el mejor predictor basado en X ?

En efecto, si Y es una v.a. con $\mathbb{E}(Y^2) < \infty$, entonces $\tilde{m}(X) = \mathbb{E}(Y \mid X)$ es el mejor predictor basado en X , es decir, es la mejor aproximación en términos del error cuadrático medio en tanto para toda $m(X)$ con esperanza al cuadrado finita tenemos que

$$ECM(Y, \tilde{m}(X)) \leq ECM(Y, m(X))$$

Demostración: Sea $m(X)$ tal que $\mathbb{E}(m(X)^2) < \infty$, luego

$$\mathbb{E}[(Y - m(X))^2] = \mathbb{E}[(Y - \tilde{m}(X) + \tilde{m}(X) - m(X))^2]$$

¿Cuál es el mejor predictor basado en X ?

En efecto, si Y es una v.a. con $\mathbb{E}(Y^2) < \infty$, entonces $\tilde{m}(X) = \mathbb{E}(Y \mid X)$ es el mejor predictor basado en X , es decir, es la mejor aproximación en términos del error cuadrático medio en tanto para toda $m(X)$ con esperanza al cuadrado finita tenemos que

$$ECM(Y, \tilde{m}(X)) \leq ECM(Y, m(X))$$

Demostración: Sea $m(X)$ tal que $\mathbb{E}(m(X)^2) < \infty$, luego

$$\begin{aligned}\mathbb{E}[(Y - m(X))^2] &= \mathbb{E}[(Y - \tilde{m}(X) + \tilde{m}(X) - m(X))^2] \\ &= \mathbb{E}[(Y - \tilde{m}(X))^2] + \mathbb{E}[(\tilde{m}(X) - m(X))^2] \\ &\quad + 2\mathbb{E}[(Y - \tilde{m}(X))(\tilde{m}(X) - m(X))]\end{aligned}$$

¿Cuál es el mejor predictor basado en X ?

En efecto, si Y es una v.a. con $\mathbb{E}(Y^2) < \infty$, entonces $\tilde{m}(X) = \mathbb{E}(Y \mid X)$ es el mejor predictor basado en X , es decir, es la mejor aproximación en términos del error cuadrático medio en tanto para toda $m(X)$ con esperanza al cuadrado finita tenemos que

$$ECM(Y, \tilde{m}(X)) \leq ECM(Y, m(X))$$

Demostración: Sea $m(X)$ tal que $\mathbb{E}(m(X)^2) < \infty$, luego

$$\begin{aligned}\mathbb{E}[(Y - m(X))^2] &= \mathbb{E}[(Y - \tilde{m}(X) + \tilde{m}(X) - m(X))^2] \\ &= \mathbb{E}[(Y - \tilde{m}(X))^2] + \mathbb{E}[(\tilde{m}(X) - m(X))^2] \\ &\quad + 2\mathbb{E}[(Y - \tilde{m}(X))(\tilde{m}(X) - m(X))]\end{aligned}$$

Veamos que el tercer sumando se anula.

¿Cuál es el mejor predictor basado en X ?

$$\mathbb{E}[\underbrace{(Y - \tilde{m}(X))}_{u(X,Y)} \underbrace{(\tilde{m}(X) - m(X))}_{v(X)}] = \mathbb{E}[\overbrace{u(X,Y)v(X)}^z]$$

obs! $E(z) = E(E(z|X))$

¿Cuál es el mejor predictor basado en X ?

$$\begin{aligned}\mathbb{E}[\underbrace{(Y - \tilde{m}(X))}_{u(X,Y)} \underbrace{(\tilde{m}(X) - m(X))}_{v(X)}] &= \mathbb{E}[u(X, Y)v(X)] \\ &= \mathbb{E}[\mathbb{E}[\underbrace{u(X, Y)v(X)}_Z \mid X]]\end{aligned}$$

¿Cuál es el mejor predictor basado en X ?

$$\begin{aligned}\mathbb{E}[\underbrace{(Y - \tilde{m}(X))}_{u(X,Y)} \underbrace{(\tilde{m}(X) - m(X))}_{v(X)}] &= \mathbb{E}[u(X, Y)v(X)] \\ &= \mathbb{E}[\mathbb{E}[u(X, Y)v(X) \mid X]] \\ &= \mathbb{E}[v(X)\mathbb{E}[u(X, Y) \mid X]]\end{aligned}$$

¿Cuál es el mejor predictor basado en X ?

$$\begin{aligned}\mathbb{E}[\underbrace{(Y - \tilde{m}(X))}_{u(X,Y)} \underbrace{(\tilde{m}(X) - m(X))}_{v(X)}] &= \mathbb{E}[u(X, Y)v(X)] \\ &= \mathbb{E}[\mathbb{E}[u(X, Y)v(X) \mid X]] \\ &= \mathbb{E}[v(X)\mathbb{E}[u(X, Y) \mid X]]\end{aligned}$$

Luego,

$$\mathbb{E}[u(X, Y) \mid X] = \mathbb{E}[Y - \tilde{m}(X) \mid X]$$

¿Cuál es el mejor predictor basado en X ?

$$\begin{aligned}\mathbb{E}[\underbrace{(Y - \tilde{m}(X))}_{u(X,Y)} \underbrace{(\tilde{m}(X) - m(X))}_{v(X)}] &= \mathbb{E}[u(X, Y)v(X)] \\ &= \mathbb{E}[\mathbb{E}[u(X, Y)v(X) \mid X]] \\ &= \mathbb{E}[v(X)\mathbb{E}[u(X, Y) \mid X]]\end{aligned}$$

Luego,

$$\begin{aligned}\mathbb{E}[u(X, Y) \mid X] &= \mathbb{E}[Y - \tilde{m}(X) \mid X] \\ &= \underbrace{\mathbb{E}[Y \mid X]}_{\tilde{m}(x)} - \underbrace{\mathbb{E}[\tilde{m}(X) \mid X]}_{\tilde{m}(x)}\end{aligned}$$

¿Cuál es el mejor predictor basado en X ?

$$\begin{aligned}\mathbb{E}[\underbrace{(Y - \tilde{m}(X))}_{u(X,Y)} \underbrace{(\tilde{m}(X) - m(X))}_{v(X)}] &= \mathbb{E}[u(X, Y)v(X)] \\ &= \mathbb{E}[\mathbb{E}[u(X, Y)v(X) \mid X]] \\ &= \mathbb{E}[v(X)\mathbb{E}[u(X, Y) \mid X]]\end{aligned}$$

Luego,

$$\begin{aligned}\mathbb{E}[u(X, Y) \mid X] &= \mathbb{E}[Y - \tilde{m}(X) \mid X] \\ &= \mathbb{E}[Y \mid X] - \mathbb{E}[\tilde{m}(X) \mid X] \\ &= \tilde{m}(X) - \tilde{m}(X) = 0\end{aligned}$$

¿Cuál es el mejor predictor basado en X ?

$$\begin{aligned}\mathbb{E}[\underbrace{(Y - \tilde{m}(X))}_{u(X,Y)} \underbrace{(\tilde{m}(X) - m(X))}_{v(X)}] &= \mathbb{E}[u(X, Y)v(X)] \\ &= \mathbb{E}[\mathbb{E}[u(X, Y)v(X) \mid X]] \\ &= \mathbb{E}[v(X)\mathbb{E}[u(X, Y) \mid X]]\end{aligned}$$

Luego,

$$\begin{aligned}\mathbb{E}[u(X, Y) \mid X] &= \mathbb{E}[Y - \tilde{m}(X) \mid X] \\ &= \mathbb{E}[Y \mid X] - \mathbb{E}[\tilde{m}(X) \mid X] \\ &= \tilde{m}(X) - \tilde{m}(X) = 0\end{aligned}$$

Luego, tenemos que

$$\mathbb{E}[(Y - m(X))^2] = \mathbb{E}[(Y - \tilde{m}(X))^2] + \mathbb{E}[(\tilde{m}(X) - m(X))^2]$$

¿Cuál es el mejor predictor basado en X ?

Como $E[(\tilde{m}(X) - m(X))^2] \geq 0$, entonces

$$ECM(Y, \tilde{m}(X)) \leq ECM(Y, m(X))$$

y, además, la igualdad se alcanza si $E[(\tilde{m}(X) - m(X))^2] = 0$ y eso ocurre si

$$m(X) = \tilde{m}(X) = \mathbb{E}(Y \mid X)$$

con probabilidad 1.

¿Cuál es el mejor predictor basado en X ?

Como $E[(\tilde{m}(X) - m(X))^2] \geq 0$, entonces

$$ECM(Y, \tilde{m}(X)) \leq ECM(Y, m(X))$$

y, además, la igualdad se alcanza si $E[(\tilde{m}(X) - m(X))^2] = 0$ y eso ocurre si

$$m(X) = \tilde{m}(X) = \mathbb{E}(Y | X)$$

con probabilidad 1.

Ahora bien, si quisiéramos calcular a $\tilde{m}(X) = \mathbb{E}(Y | X)$ necesitaríamos la distribución conjunta de (Y, X) y, en la práctica, esa información, en general, no está disponible.

¿Cuál es el mejor predictor basado en X ?

Como $E[(\tilde{m}(X) - m(X))^2] \geq 0$, entonces

$$ECM(Y, \tilde{m}(X)) \leq ECM(Y, m(X))$$

y, además, la igualdad se alcanza si $E[(\tilde{m}(X) - m(X))^2] = 0$ y eso ocurre si

$$m(X) = \tilde{m}(X) = \mathbb{E}(Y \mid X)$$

con probabilidad 1.

Ahora bien, si quisiéramos calcular a $\tilde{m}(X) = \mathbb{E}(Y \mid X)$ necesitaríamos la distribución conjunta de (Y, X) y, en la práctica, esa información, en general, no está disponible.

Usualmente, tomamos un atajo haciendo un modelado e intentamos responder, por ejemplo, cuál es la función lineal en X que mejor aproxima a Y .

¿Cuál es el mejor predictor lineal de Y basado en X ?

En este caso buscamos la mejor aproximación dentro de la familia de funciones de la forma:

$$m(X) = \theta_0 + \theta_1 X$$

Buscamos los valores $\tilde{\theta}_0$ y $\tilde{\theta}_1$ que minimizan

$$ECM(Y, \theta_0 + \theta_1 X) = \mathbb{E} \left[(Y - (\theta_0 + \theta_1 X))^2 \right]$$

¿Cuál es el mejor predictor lineal de Y basado en X ?

En este caso buscamos la mejor aproximación dentro de la familia de funciones de la forma:

$$m(X) = \theta_0 + \theta_1 X$$

Buscamos los valores $\tilde{\theta}_0$ y $\tilde{\theta}_1$ que minimizan

$$ECM(Y, \theta_0 + \theta_1 X) = \mathbb{E} \left[(Y - (\theta_0 + \theta_1 X))^2 \right]$$

Es un ejercicio de la práctica comprobar, derivando e igualando a 0, que los puntos críticos son:

- $\tilde{\theta}_0 = \mathbb{E}(Y) - \frac{\text{Cov}(X, Y)}{\text{Var}(X)} \tilde{\theta}_1 \mathbb{E}(X)$
- $\tilde{\theta}_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$

En otras palabras, el mejor predictor lineal es de la forma:

$$m_L(X) = \mathbb{E}(Y) - \frac{\text{Cov}(X, Y)}{\text{Var}(X)} \mathbb{E}(X) + \frac{\text{Cov}(X, Y)}{\text{Var}(X)} X$$

¿Cuál es el mejor predictor lineal de Y basado en X ?

Notemos que

- $m_L(\mathbb{E}(X)) = \mathbb{E}(Y).$

¿Cuál es el mejor predictor lineal de Y basado en X ?

Notemos que

- $m_L(\mathbb{E}(X)) = \mathbb{E}(Y)$.
- En términos absolutos, la pendiente aumenta con la $\mathbb{C}ov(X, Y)$, que mide la asociación lineal entre las variables: $|\tilde{\theta}_1|$ aumenta con $|\mathbb{C}ov(X, Y)|$.

¿Cuál es el mejor predictor lineal de Y basado en X ?

Notemos que

- $m_L(\mathbb{E}(X)) = \mathbb{E}(Y)$.
- En términos absolutos, la pendiente aumenta con la $\text{Cov}(X, Y)$, que mide la asociación lineal entre las variables: $|\tilde{\theta}_1|$ aumenta con $|\text{Cov}(X, Y)|$.
- En términos absolutos, la pendiente decrece a 0 con la $\text{Var}(X)$, que mide la variabilidad de X : cuanto más dispersión en X , más se acerca $|\tilde{\theta}_1|$ a 0.

¿Cuál es el mejor predictor lineal de Y basado en X ?

Notemos que

- $m_L(\mathbb{E}(X)) = \mathbb{E}(Y)$.
- En términos absolutos, la pendiente aumenta con la $\mathbb{Cov}(X, Y)$, que mide la asociación lineal entre las variables: $|\tilde{\theta}_1|$ aumenta con $|\mathbb{Cov}(X, Y)|$.
- En términos absolutos, la pendiente decrece a 0 con la $\mathbb{Var}(X)$, que mide la variabilidad de X : cuanto más dispersión en X , más se acerca $|\tilde{\theta}_1|$ a 0.
- La aproximación lineal óptima obtenida no asume ninguna relación particular entre X e Y . Es de esperar que sea buena cuando se vinculan aproximadamente en forma lineal, pero puede ser muy mala si la relación entre ellas está muy lejos de la linealidad.

Otro ejemplo

En 97 pacientes que van a ser tratados con una prostatectomía radical se miden las siguientes variables:

- $x_1 = \text{**lweight**}$: log del peso de la próstata
- $x_2 = \text{**age**}$: edad
- $x_3 = \text{**lbph**}$: log de la cantidad de hiperplasia prostática benigna
- $x_4 = \text{**svi**}$: invasión seminal (si o no)
- $x_5 = \text{**lcp**}$: logaritmo de la penetración capsular
- $x_6 = \text{**gleason**}$: score de Gleason
- $x_7 = \text{**pgg46**}$: porcentaje de scores de Gleason 4 or 5.
- $x_8 = \text{**lpsa**}$: log de PSA

El objetivo es poder predecir el logaritmo del volumen del tumor ($y = \text{**lcavol**}$).

Diagrama de Dispersión





Diagrama de Dispersión



Modelos de regresión

Buscamos un modelo que exprese a la variable de respuesta en términos de las otras variables presentes (covariables).

Cuando hablamos de un modelo nos referimos a una expresión matemática que:

- sea válida aproximadamente,
- que describa en algún sentido el comportamiento de la variable de interés en función de las demás variables predictoras.

Modelos de regresión

Buscamos un modelo que exprese a la variable de respuesta en términos de las otras variables presentes (covariables).

Cuando hablamos de un modelo nos referimos a una expresión matemática que:

- sea válida aproximadamente,
- que describa en algún sentido el comportamiento de la variable de interés en función de las demás variables predictoras.

En un modelo de regresión se postularía:

$$y = m(x_1, x_2, x_3, \dots, x_p) + \varepsilon$$

o, en general, si llamamos $\mathbf{x} = (x_1, x_2, x_3, \dots, x_p)^T$, entonces

$$y = m(\mathbf{x}) + \varepsilon$$

Modelo de regresión no paramétrica

Modelos de regresión paramétrica

Sin embargo, las posibles funciones de regresión m pertenecen a una clase $\mathcal{M}$ tan grande que es frecuente que se simplifique el problema suponiendo cierta forma o ciertas propiedades de la función de regresión m .

Modelos de regresión paramétrica

Sin embargo, las posibles funciones de regresión m pertenecen a una clase $\mathcal{M}$ tan grande que es frecuente que se simplifique el problema suponiendo cierta forma o ciertas propiedades de la función de regresión m .

Una forma de simplificar el problema es suponiendo que la familia $\mathcal{M}$ puede expresarse en función de un número finito de constantes desconocidas, a estimar, llamadas **parámetros**, que controlan el comportamiento del modelo. En este sentido diremos que el **modelo de regresión es paramétrico**.

Modelos de regresión paramétrica

Para simplificar, pensemos que tenemos dos covariables x_1 y x_2 que son **determinísticas**.

Modelos paramétricos

$$(i) \quad y = \theta_1 + \theta_2 x_1 + \theta_3 x_2 + \varepsilon$$

$$(ii) \quad y = \theta_1 \log(x_1) + \theta_2 \log(x_2) + \theta_3 x_1^3 + \theta_4 \sin(x_2) + \varepsilon$$

$$(iii) \quad y = \theta_1 x_1^{\theta_2} x_2^{\theta_3} + \varepsilon$$

$$(iv) \quad y = \theta_1 e^{\theta_2 x_1} + \theta_3 e^{\theta_4 x_2} + \varepsilon$$

En general, tenemos dos escenarios posibles:

1) x 's fijas ^{✓ determinísticas}: por ejemplo, si estudio la cantidad de óxido que se produce en una reacción química, entonces y = "cant. de óxido", x_1 = "temperatura", x_2 = "concentración de la sustancia". Entonces, $x_1 = \{200^\circ\text{C}, 300^\circ\text{C}, 400^\circ\text{C}\}$, $x_2 = \{10\%, 30\%, 70\% \}$ y solo nos fijamos los resultados de y .

2) x 's aleatorias. Por ejemplo, en un experimento con alturas. En este caso, no podemos fijar la altura de antemano. ¿qué se hace? Se piensa en un modelo condicional, es decir, se trabaja modelando $y | (x_1, x_2)$.

Modelo Lineal

Uno de los modelos más sencillos es el **modelo lineal**, en el que los parámetros intervienen como simples coeficientes de las variables independientes o de funciones de éstas.

Es el caso de:

(i) $y = \theta_1 + \theta_2 x_1 + \theta_3 x_2 + \varepsilon$

(ii) $y = \theta_1 \log(x_1) + \theta_2 \log(x_2) + \theta_3 x_1^3 + \theta_4 \sin(x_2) + \varepsilon$

En estos dos ejemplos $m(x)$ es **lineal** en los **parámetros**.

Modelo Lineal

Uno de los modelos más sencillos es el **modelo lineal**, en el que los parámetros intervienen como simples coeficientes de las variables independientes o de funciones de éstas.

Es el caso de:

(i) $y = \theta_1 + \theta_2 x_1 + \theta_3 x_2 + \varepsilon$

(ii) $y = \theta_1 \log(x_1) + \theta_2 \log(x_2) + \theta_3 x_1^3 + \theta_4 \sin(x_2) + \varepsilon$

En estos dos ejemplos $m(x)$ es **lineal** en los **parámetros**.

No es el caso, por ejemplo, de $m(x) = \theta_1 e^{-\theta_2 x}$, conocido como *crecimiento exponencial*, ya que no es lineal como función de los parámetros θ_1 o θ_2 .

Algunos ejemplos sencillos de modelos lineales dependientes de una sola variable son:

$$m(x) = \theta_1 + \theta_2 x$$

$$m(x) = \theta_1 + \theta_2 x + \theta_3 x^2$$

$$m(x) = \theta_1 + \theta_2 \log(x)$$

Modelo Lineal

En general, en un modelo lineal tendremos que la i -ésima respuesta y_i está asociada a un vector de covariables $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^T \in \mathbb{R}^p$ de la siguiente forma

$$y_i = \theta_1 x_{i1} + \dots + \theta_p x_{ip} + \varepsilon_i,$$

es decir,

$$m(\mathbf{x}_i) = \theta_1 x_{i1} + \dots + \theta_p x_{ip} = \boldsymbol{\theta}^T \mathbf{x}_i$$

siendo $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p)^T$.

Modelo Lineal

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

En general, en un modelo lineal tendremos que la i -ésima respuesta y_i está asociada a un vector de covariables $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^T \in \mathbb{R}^p$ de la siguiente forma

$$y_i = \theta_1 x_{i1} + \dots + \theta_p x_{ip} + \varepsilon_i,$$

es decir,

$$m(\mathbf{x}_i) = \theta_1 x_{i1} + \dots + \theta_p x_{ip} = \boldsymbol{\theta}^T \mathbf{x}_i$$

siendo $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p)^T$.

$$\theta_0 + \theta_1 x$$

Eventualmente

$$\underline{x} = (1; x)^T$$

- las covariables podrían ser funciones de otras variables, tal como ocurre en el caso ii) y en nuestro ejemplo.
- $x_{i1} = 1$ para todo i , en este caso decimos que el modelo tiene intercept u ordenada al origen.

Modelo Lineal

Supondremos $x_j, 1 \leq j \leq p$, determinísticas.

Supongamos que $(x_{i1}, \dots, x_{ip}, y_i), 1 \leq i \leq n$, es una m.a. que satisface el modelo Ω dado por:

$$y_i = \theta_1 x_{i1} + \dots + \theta_p x_{ip} + \varepsilon_i$$

$$\mathbb{E}(\varepsilon_i) = 0$$

$$\mathbb{V}(\varepsilon_i) = \sigma^2$$

$$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0 \quad i \neq j$$

donde $\theta_1, \dots, \theta_p$ son p parámetros desconocidos a estimar.

Enfoque matricial

$$y_i = \theta_1 x_{i1} + \cdots + \theta_p x_{ip} + \varepsilon_i, \quad i = 1, \dots, n$$

Notaremos como

$$\mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & & & \vdots \\ \vdots & & & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix} \quad \begin{matrix} \in \mathbb{R}^n \end{matrix}$$
$$\boldsymbol{\theta} = \begin{pmatrix} \theta_1 \\ \vdots \\ \theta_p \end{pmatrix} \quad \boldsymbol{\epsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

$\Downarrow$

$\mathbf{Y}$	$=$	$\mathbf{X}$	$\boldsymbol{\theta}$	$+$	$\boldsymbol{\epsilon}$
$n \times 1$		$n \times p$	$p \times 1$		$n \times 1$

Enfoque matricial

La matriz $\mathbf{X} \in \mathbb{R}^{n \times p}$ recibe el nombre de **matriz de regresión** o **matriz de diseño**.

En general, se elige de tal forma que tenga rango máximo, es decir, $\text{rg}(\mathbf{X}) = p$, sin embargo esto no siempre es posible, como en el caso de algunos diseños tratados en análisis de la varianza (ANOVA).

Trataremos el caso de rango completo.

La teoría que veremos no necesita que la primera columna sea de 1's, es decir, que el modelo tenga intercept, por lo tanto, estudiaremos el caso general.

Algunos ejemplos: Modelo de regresión lineal simple

En el caso más sencillo de regresión lineal simple tendríamos

$$y_i = \theta_1 + \theta_2 x_i + \varepsilon_i, \quad 1 \leq i \leq n.$$

Se tiene

$$p = 2 \quad \mathbf{X} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} \quad \boldsymbol{\theta} = \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}$$

Modelo de posición

En este caso,

$$y_i = \mu + \varepsilon_i, \quad 1 \leq i \leq n.$$

Se tiene

$$p = 1 \quad \mathbf{X} = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \quad \theta = \mu$$

Modelo de dos muestras

También podríamos tener

$$y_{i1} = \mu_1 + \varepsilon_{i1} \quad 1 \leq i \leq n_1$$

$$y_{i2} = \mu_2 + \varepsilon_{i2} \quad 1 \leq i \leq n_2$$

Que se consigue con $p = 2$,

$$\mathbf{Y} = \begin{pmatrix} y_{11} \\ y_{21} \\ \vdots \\ y_{n_1 1} \\ y_{12} \\ y_{22} \\ \vdots \\ y_{n_2 2} \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 0 & 1 \\ 0 & 1 \\ \vdots & \vdots \\ 0 & 1 \end{pmatrix} \quad \boldsymbol{\theta} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$$

Modelo de regresión cuadrática

$$y_i = \theta_1 + \theta_2 x_i + \theta_3 x_i^2 + \varepsilon_i, \quad 1 \leq i \leq n.$$

En este caso, se tiene

$$p = 3 \quad \mathbf{X} = \begin{pmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{pmatrix} \quad \boldsymbol{\theta} = \begin{pmatrix} \theta_1 \\ \theta_2 \\ \theta_3 \end{pmatrix}$$

¿Cómo estimamos los parámetros?

Mínimos Cuadrados


Si los puntos en un gráfico parecen seguir una recta, el problema es elegir la recta que mejor ajusta los puntos.

Tendremos en cuenta:


- a) tomar una distancia promedio de la recta a todos los puntos,
- b) elegir la recta con esta distancia promedio lo más pequeña posible.

Si tenemos $(\mathbf{x}_i^T, y_i)$, $1 \leq i \leq n$, y queremos predecir y a partir de $\mathbf{x}$ usando una recta, podríamos definir el error cometido en cada punto como la distancia vertical del punto a la recta.

Mínimos Cuadrados



Mínimos Cuadrados



Método de Mínimos Cuadrados

Supongamos que tenemos un modelo que depende de p parámetros. Sean $(\mathbf{x}_i^T, y_i)$, $1 \leq i \leq n$, vectores aleatorios tales que

$$y_i = m(\mathbf{x}_i, \theta_1 \dots \theta_p) + \varepsilon_i$$

y los errores son tales que $\mathbb{E}(\varepsilon_i) = 0$, $\mathbb{V}(\varepsilon_i) = \sigma^2$, $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$, es decir, son no correlacionados y la función m es *conocida* salvo por los parámetros $\theta_1 \dots \theta_p$. Es un modelo paramétrico genérico.

Método de Mínimos Cuadrados

Supongamos que tenemos un modelo que depende de p parámetros. Sean $(\mathbf{x}_i^T, y_i)$, $1 \leq i \leq n$, vectores aleatorios tales que

$$y_i = m(\mathbf{x}_i, \theta_1 \dots \theta_p) + \varepsilon_i$$

y los errores son tales que $\mathbb{E}(\varepsilon_i) = 0$, $\mathbb{V}(\varepsilon_i) = \sigma^2$, $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$, es decir, son no correlacionados y la función m es *conocida* salvo por los parámetros $\theta_1 \dots \theta_p$. Es un modelo paramétrico genérico.

Estimamos $\theta_1 \dots \theta_p$ minimizando la suma de cuadrados residual. El estimador de mínimos cuadrados $\hat{\boldsymbol{\theta}} = (\hat{\theta}_1, \dots, \hat{\theta}_p)^T$ cumple

$$\hat{\boldsymbol{\theta}} = \underset{\mathbf{b} \in \mathbb{R}^p}{\operatorname{argmin}} \sum_{i=1}^n \underbrace{(y_i - m(\mathbf{x}_i, b_1 \dots, b_p))^2}_{\text{residuos}}$$

Método de Mínimos Cuadrados

En el caso de **regresión lineal simple**

$$m(x, \theta_1, \theta_2) = \theta_1 + \theta_2 x ,$$

el **estimador de mínimos cuadrados** se obtiene como el argumento que minimiza

$$\sum_{i=1}^n (y_i - m(\mathbf{x}_i, b_1 \dots, b_p))^2 ,$$

es decir, minimizando

$$\frac{1}{n} \sum_{i=1}^n (y_i - (b_1 + b_2 x_i))^2 .$$

A esta suma se la llama **suma de cuadrados residual para la recta** y la recta resultante es la **recta de mínimos cuadrados**.

Caso Lineal

Dado el vector $\mathbf{b} \in \mathbb{R}^p$, el **vector de residuos** es

$$\mathbf{r}(\mathbf{b}) = \mathbf{Y} - \mathbf{X}\mathbf{b}.$$

Luego, el **estimador de mínimos cuadrados de $\theta_1 \dots \theta_p$** es aquel que minimiza

$$\sum_{i=1}^n (y_i - b_1 x_{i1} - \dots - b_p x_{ip})^2 = \|\mathbf{Y} - \mathbf{X}\mathbf{b}\|^2,$$

donde $\|\mathbf{u}\|^2 = \mathbf{u}^T \mathbf{u} = \sum_{i=1}^n u_i^2.$

Caso Lineal

Dado el vector $\mathbf{b} \in \mathbb{R}^p$, el **vector de residuos** es

$$\mathbf{r}(\mathbf{b}) = \mathbf{Y} - \mathbf{X}\mathbf{b}.$$

Luego, el **estimador de mínimos cuadrados de $\theta_1 \dots \theta_p$** es aquel que minimiza

$$\sum_{i=1}^n (y_i - b_1 x_{i1} - \dots - b_p x_{ip})^2 = \|\mathbf{Y} - \mathbf{X}\mathbf{b}\|^2,$$

donde $\|\mathbf{u}\|^2 = \mathbf{u}^T \mathbf{u} = \sum_{i=1}^n u_i^2$.

Llamemos $\mathcal{S}(\mathbf{b})$ a la función objetivo:

$$\mathcal{S}(\mathbf{b}) = \|\mathbf{Y} - \mathbf{X}\mathbf{b}\|^2 = (\mathbf{Y} - \mathbf{X}\mathbf{b})^T (\mathbf{Y} - \mathbf{X}\mathbf{b}).$$

Un conjunto de funciones de $\mathbf{Y}$, $\hat{\theta}_1 = \hat{\theta}_1(\mathbf{Y})$, $\hat{\theta}_2 = \hat{\theta}_2(\mathbf{Y})$, $\dots$, $\hat{\theta}_p = \hat{\theta}_p(\mathbf{Y})$ que minimiza $\mathcal{S}(\mathbf{b})$ es el *estimador de mínimos cuadrados de θ* (LS, por sus siglas en inglés).

Observación: El LS siempre existe, aunque no siempre es único.

Ecuaciones Normales

Derivando e igualando a 0

$$\mathcal{S}(\mathbf{b}) = \sum_{i=1}^n (y_i - b_1 x_{i1} - \cdots - b_p x_{ip})^2$$

obtenemos las **ecuaciones normales**.

Los estimadores de mínimos cuadrados $\hat{\theta}_1, \dots, \hat{\theta}_p$ cumplen que, para $1 \leq k \leq p$,

$$\left. \frac{\partial \mathcal{S}(\mathbf{b})}{\partial b_k} \right|_{\mathbf{b}=\hat{\boldsymbol{\theta}}} = -2 \sum_{i=1}^n \left(y_i - \sum_{j=1}^p x_{ij} b_j \right) x_{ik} \Big|_{\mathbf{b}=\hat{\boldsymbol{\theta}}} = 0$$

Ecuaciones Normales

Por lo tanto, para $1 \leq k \leq p$,

$$\sum_{i=1}^n y_i x_{ik} = \sum_{i=1}^n \sum_{j=1}^p x_{ij} x_{ik} \hat{\theta}_j .$$

Ecuaciones Normales

Por lo tanto, para $1 \leq k \leq p$,

$$\sum_{i=1}^n y_i x_{ik} = \sum_{i=1}^n \sum_{j=1}^p x_{ij} x_{ik} \hat{\theta}_j.$$

Reordenando la suma, tenemos que

$$\sum_{i=1}^n y_i x_{ik} = \sum_{j=1}^p \hat{\theta}_j \sum_{i=1}^n x_{ij} x_{ik}$$

Ecuaciones Normales

Por lo tanto, para $1 \leq k \leq p$,

$$\sum_{i=1}^n y_i x_{ik} = \sum_{i=1}^n \sum_{j=1}^p x_{ij} x_{ik} \hat{\theta}_j.$$

Reordenando la suma, tenemos que

$$\sum_{i=1}^n y_i x_{ik} = \sum_{j=1}^p \hat{\theta}_j \sum_{i=1}^n x_{ij} x_{ik}$$

Supongamos ahora que el modelo tiene intercept, es decir, que $x_{i1} = 1$ para todo $1 \leq i \leq n$. Luego,

$$n\hat{\theta}_1 + \hat{\theta}_2 \sum_{i=1}^n x_{i2} + \cdots + \hat{\theta}_p \sum_{i=1}^n x_{ip} = \sum_{i=1}^n y_i$$

$$\hat{\theta}_1 \sum_{i=1}^n x_{ik} + \hat{\theta}_2 \sum_{i=1}^n x_{i2} x_{ik} + \cdots + \hat{\theta}_p \sum_{i=1}^n x_{ip} x_{ik} = \sum_{i=1}^n y_i x_{ik}, \quad k = 2, \dots, p$$

Ecuaciones Normales

En general, tenemos

$$\sum_{j=1}^p \hat{\theta}_j \sum_{i=1}^n x_{ij} x_{ik} = \sum_{i=1}^n y_i x_{ik}, \quad 1 \leq k \leq p$$

y el estimador de mínimos cuadrados cumple estas p ecuaciones, entonces

$$\mathbf{X}^T \mathbf{X} \hat{\boldsymbol{\theta}} = \mathbf{X}^T \mathbf{Y},$$

que se conocen como **ecuaciones normales**.

Ecuaciones Normales

En general, tenemos

$$\sum_{j=1}^p \hat{\theta}_j \sum_{i=1}^n x_{ij} x_{ik} = \sum_{i=1}^n y_i x_{ik}, \quad 1 \leq k \leq p$$

y el estimador de mínimos cuadrados cumple estas p ecuaciones, entonces

$$\mathbf{X}^T \mathbf{X} \hat{\boldsymbol{\theta}} = \mathbf{X}^T \mathbf{Y},$$

que se conocen como **ecuaciones normales**.

Si $\mathbf{X}^T \mathbf{X}$ es no singular, la solución es única y resulta

$$\hat{\boldsymbol{\theta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}.$$

Ecuaciones Normales

En general, tenemos

$$\sum_{j=1}^p \hat{\theta}_j \sum_{i=1}^n x_{ij} x_{ik} = \sum_{i=1}^n y_i x_{ik}, \quad 1 \leq k \leq p$$

y el estimador de mínimos cuadrados cumple estas p ecuaciones, entonces

$$\mathbf{X}^T \mathbf{X} \hat{\boldsymbol{\theta}} = \mathbf{X}^T \mathbf{Y},$$

que se conocen como **ecuaciones normales**.

Si $\mathbf{X}^T \mathbf{X}$ es no singular, la solución es única y resulta

$$\hat{\boldsymbol{\theta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}.$$

Al vector de valores predichos lo notamos:

$$\hat{\mathbf{Y}} = \mathbf{X}^T \hat{\boldsymbol{\theta}}.$$