

Estimador de mínimos cuadrados para regresión lineal

Supongamos que $(\mathbf{x}_i^T, y_i)$, $1 \leq i \leq n$, satisfacen el modelo Ω con

$$y_i = \mathbf{x}_i^T \boldsymbol{\theta} + \varepsilon_i.$$

Observación: Recordemos que el modelo Ω incluía los supuestos $\mathbb{E}(\varepsilon_i) = 0$, $\text{Var}(\varepsilon_i) = \sigma^2$ y $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$.

Luego, el **estimador de mínimos cuadrados** de $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p)^T$ es tal que minimiza

$$\sum_{i=1}^n (y_i - b_1 x_{i1} - \dots - b_p x_{ip})^2 = \|\mathbf{Y} - \mathbf{X}\mathbf{b}\|^2,$$

$\mathbf{Y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} x_{11} & \dots & x_{1p} \\ \vdots & & \vdots \\ x_{n1} & \dots & x_{np} \end{pmatrix} \in \mathbb{R}^{n \times p}$

donde $\|\mathbf{u}\|^2 = \mathbf{u}^T \mathbf{u} = \sum_{i=1}^n u_i^2$.

Estimador de mínimos cuadrados para regresión lineal

Llamemos $\mathcal{S}(\mathbf{b})$ a la función objetivo:

$$\mathcal{S}(\mathbf{b}) = \|\mathbf{Y} - \mathbf{X}\mathbf{b}\|^2 = (\mathbf{Y} - \mathbf{X}\mathbf{b})^T(\mathbf{Y} - \mathbf{X}\mathbf{b}).$$

Al conjunto de funciones de $\mathbf{Y}$, $\hat{\theta}_1 = \hat{\theta}_1(\mathbf{Y})$, $\hat{\theta}_2 = \hat{\theta}_2(\mathbf{Y})$, $\dots$
 $\hat{\theta}_p = \hat{\theta}_p(\mathbf{Y})$ que minimiza $\mathcal{S}(\mathbf{b})$ se lo denomina *estimador de mínimos cuadrados de θ* (LS, por sus siglas en inglés).

Observación: El LS siempre existe aunque no siempre es único.

Estimador de mínimos cuadrados para regresión lineal

Llamemos $\mathcal{S}(\mathbf{b})$ a la función objetivo:

$$\mathcal{S}(\mathbf{b}) = \|\mathbf{Y} - \mathbf{X}\mathbf{b}\|^2 = (\mathbf{Y} - \mathbf{X}\mathbf{b})^T(\mathbf{Y} - \mathbf{X}\mathbf{b}).$$

Al conjunto de funciones de $\mathbf{Y}$, $\hat{\theta}_1 = \hat{\theta}_1(\mathbf{Y})$, $\hat{\theta}_2 = \hat{\theta}_2(\mathbf{Y})$, $\dots$, $\hat{\theta}_p = \hat{\theta}_p(\mathbf{Y})$ que minimiza $\mathcal{S}(\mathbf{b})$ se lo denomina *estimador de mínimos cuadrados de θ* (LS, por sus siglas en inglés).

Observación: El LS siempre existe aunque no siempre es único.

Derivando e igualando a 0

$$\mathcal{S}(\mathbf{b}) = \sum_{i=1}^n (y_i - b_1 x_{i1} - \dots - b_p x_{ip})^2$$

obtenemos las **ecuaciones normales**.

Ecuaciones Normales

Los estimadores de mínimos cuadrados $\hat{\theta}_1, \dots, \hat{\theta}_p$ cumplen que, para $1 \leq k \leq p$,

$$\left. \frac{\partial S(\mathbf{b})}{\partial b_k} \right|_{\mathbf{b}=\hat{\boldsymbol{\theta}}} = -2 \sum_{i=1}^n \left(y_i - \sum_{j=1}^p x_{ij} b_j \right) x_{ik} \Big|_{\mathbf{b}=\hat{\boldsymbol{\theta}}} = 0$$

$$S(b) = \sum_{i=1}^n (y_i - b_1 x_{i1} - \dots - b_p x_{ip})^2$$

$$\left. \frac{\partial S(b)}{\partial b_k} \right|_{\mathbf{b}=\hat{\boldsymbol{\theta}}} = 2 \sum_{i=1}^n (y_i - b_1 x_{i1} - \dots - b_p x_{ip}) (-x_{ik}) \Big|_{\mathbf{b}=\hat{\boldsymbol{\theta}}} = 0 \quad \forall k=1, \dots, p$$

Ecuaciones Normales

Los estimadores de mínimos cuadrados $\hat{\theta}_1, \dots, \hat{\theta}_p$ cumplen que, para $1 \leq k \leq p$,

$$\left. \frac{\partial \mathcal{S}(\mathbf{b})}{\partial b_k} \right|_{\mathbf{b}=\hat{\boldsymbol{\theta}}} = -2 \sum_{i=1}^n \left(y_i - \sum_{j=1}^p x_{ij} b_j \right) x_{ik} \Big|_{\mathbf{b}=\hat{\boldsymbol{\theta}}} = 0$$

Por lo tanto, para $1 \leq k \leq p$,

$$\sum_{i=1}^n y_i x_{ik} = \sum_{i=1}^n \sum_{j=1}^p x_{ij} x_{ik} \hat{\theta}_j.$$

teníamos $\frac{\partial \mathcal{S}}{\partial b_k}(\hat{\boldsymbol{\theta}}) = \sum_{i=1}^n (y_i - \sum_{j=1}^p \hat{\theta}_j x_{ij}) x_{ik} = 0$

$$\sum_{i=1}^n y_i x_{ik} - \sum_{i=1}^n \sum_{j=1}^p \hat{\theta}_j x_{ij} x_{ik} = 0$$

Ecuaciones Normales

Los estimadores de mínimos cuadrados $\hat{\theta}_1, \dots, \hat{\theta}_p$ cumplen que, para $1 \leq k \leq p$,

$$\left. \frac{\partial \mathcal{S}(\mathbf{b})}{\partial b_k} \right|_{\mathbf{b}=\hat{\boldsymbol{\theta}}} = -2 \sum_{i=1}^n \left(y_i - \sum_{j=1}^p x_{ij} b_j \right) x_{ik} \Big|_{\mathbf{b}=\hat{\boldsymbol{\theta}}} = 0$$

Por lo tanto, para $1 \leq k \leq p$,

$$\sum_{i=1}^n y_i x_{ik} = \sum_{i=1}^n \sum_{j=1}^p x_{ij} x_{ik} \hat{\theta}_j.$$

Reordenando la suma, tenemos que

$$\sum_{i=1}^n y_i x_{ik} = \sum_{j=1}^p \hat{\theta}_j \sum_{i=1}^n x_{ij} x_{ik} \quad k=1 \dots p$$

Ecuaciones Normales

Supongamos ahora que el modelo tiene intercept, es decir, que $x_{i1} = 1$ para todo $1 \leq i \leq n$. Luego,

$$n\hat{\theta}_1 + \hat{\theta}_2 \sum_{i=1}^n x_{i2} + \cdots + \hat{\theta}_p \sum_{i=1}^n x_{ip} = \sum_{i=1}^n y_i \quad \checkmark$$

$$\hat{\theta}_1 \sum_{i=1}^n x_{ik} + \hat{\theta}_2 \sum_{i=1}^n x_{i2}x_{ik} + \cdots + \hat{\theta}_p \sum_{i=1}^n x_{ip}x_{ik} = \sum_{i=1}^n y_i x_{ik}, \quad k = 2, \dots, p$$

$$\underbrace{\sum_{i=1}^n y_i}_{k=1} \cdot \underbrace{1}_{\hat{\theta}_1} = \underbrace{\sum_{j=1}^p \hat{\theta}_j \sum_{i=1}^n x_{ij}}_{\text{green bracket}} = \hat{\theta}_1 \underbrace{\sum_{i=1}^n x_{i1}}_{\text{orange circle, } n} + \hat{\theta}_2 \sum_{i=1}^n x_{i2} + \dots + \hat{\theta}_p \sum_{i=1}^n x_{ip}$$

Ecuaciones Normales

En general, tenemos

$$\sum_{j=1}^p \hat{\theta}_j \sum_{i=1}^n x_{ij} x_{ik} = \sum_{i=1}^n y_i x_{ik}, \quad 1 \leq k \leq p$$

y el estimador de mínimos cuadrados cumple estas p ecuaciones, entonces

$$\mathbf{X}^T \mathbf{X} \hat{\boldsymbol{\theta}} = \mathbf{X}^T \mathbf{Y},$$

que se conocen como **ecuaciones normales**.

Recordemos que $\nabla S(\hat{\boldsymbol{\theta}}) = \vec{0} \Leftrightarrow \left(\begin{array}{c} \frac{\partial S}{\partial b_1} \\ \vdots \\ \frac{\partial S}{\partial b_p} \end{array} \right) \bigg|_{b=\hat{\boldsymbol{\theta}}} = \vec{0}$

$$\begin{aligned} \Leftrightarrow \forall k: \sum_{i=1}^n y_i x_{ik} &= \text{"columna } k \text{ de } \mathbf{X}^T \text{ por } \text{"} y \text{"} \\ &= (\text{columna } k \text{ de } \mathbf{X}^T) \cdot \mathbf{y} \\ &= (\text{fila } k \text{ de } \mathbf{X}) \cdot \mathbf{y} = (\mathbf{X}^T \cdot \mathbf{y})_k \end{aligned}$$

$$\cdot \sum_{j=1}^p \hat{\theta}_j \left[\sum_{i=1}^n x_{ij} x_{ik} \right] = \sum_{j=1}^p \hat{\theta}_j \cdot \left[\underbrace{(\text{column } j \text{ de } X)^T \cdot (\text{column } k \text{ de } X)}_{(\text{fila } j \text{ de } X^T) \cdot (\text{column } k \text{ de } X)} \right]$$

$$(X^T X)_{kj} = (X^T \cdot X)_{jk}$$

$\uparrow$ x simétrica

$$\Leftrightarrow \nabla S(\hat{\theta}) = \vec{0} \Leftrightarrow$$

$$\left\{ \begin{array}{l} (\text{fila } 1 \text{ de } X^T X) \cdot \hat{\theta} \\ \vdots \\ (\text{fila } p \text{ de } X^T X) \cdot \hat{\theta} \end{array} \right.$$

$$= (\text{fila } 1 \text{ de } X^T) \cdot y$$

$$\vdots$$

$$= (\text{fila } p \text{ de } X^T) \cdot y$$

$$\Leftrightarrow (X^T X) \cdot \hat{\theta} = X^T y \quad \checkmark$$

Ecuaciones Normales

En general, tenemos

$$\sum_{j=1}^p \hat{\theta}_j \sum_{i=1}^n x_{ij} x_{ik} = \sum_{i=1}^n y_i x_{ik}, \quad 1 \leq k \leq p$$

y el estimador de mínimos cuadrados cumple estas p ecuaciones, entonces

$$\mathbf{X}^T \mathbf{X} \hat{\boldsymbol{\theta}} = \mathbf{X}^T \mathbf{Y},$$

que se conocen como **ecuaciones normales**.

Si $\mathbf{X}^T \mathbf{X}$ es no singular, la solución es única y resulta

$$\hat{\boldsymbol{\theta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}.$$

Ecuaciones Normales

En general, tenemos

$$\sum_{j=1}^p \hat{\theta}_j \sum_{i=1}^n x_{ij} x_{ik} = \sum_{i=1}^n y_i x_{ik}, \quad 1 \leq k \leq p$$

y el estimador de mínimos cuadrados cumple estas p ecuaciones, entonces

$$\mathbf{X}^T \mathbf{X} \hat{\boldsymbol{\theta}} = \mathbf{X}^T \mathbf{Y},$$

que se conocen como **ecuaciones normales**.

Si $\mathbf{X}^T \mathbf{X}$ es no singular, la solución es única y resulta

$$\hat{\boldsymbol{\theta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}.$$

Al vector de valores predichos lo notamos:

$$\hat{\mathbf{Y}} = \mathbf{X} \hat{\boldsymbol{\theta}}.$$

Ejercicio: Comprobar

Queda como **Ejercicio** comprobar cómo queda el **estimador de mínimos cuadrados** para el caso del modelo de regresión lineal simple

$$y_i = \theta_1 + \theta_2 x_i + \varepsilon_i .$$

En este caso,

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} 1 & 1 & 1 & \cdots & 1 \\ x_1 & x_2 & x_3 & \cdots & x_n \end{pmatrix} \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}$$

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix}$$

Ejercicio: Comprobar

El sistema de ecuaciones normales es

$$\begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix} \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_i y_i \end{pmatrix}$$

Ejercicio: Comprobar

El sistema de ecuaciones normales es

$$\begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix} \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_i y_i \end{pmatrix}$$

La matriz inversa resulta

$$(\mathbf{X}^T \mathbf{X})^{-1} = \frac{1}{n \sum_{i=1}^n x_i^2 - n^2 \bar{x}^2} \begin{pmatrix} \sum_{i=1}^n x_i^2 & -\sum_{i=1}^n x_i \\ -\sum_{i=1}^n x_i & n \end{pmatrix}$$

y además

$$\mathbf{X}^T \mathbf{Y} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_i y_i \end{pmatrix}$$

Ejercicio: Comprobar

Por lo tanto

$$\begin{aligned}\hat{\boldsymbol{\theta}} &= \begin{pmatrix} \hat{\theta}_1 \\ \hat{\theta}_2 \end{pmatrix} \\ &= \frac{1}{n \sum_{i=1}^n (x_i - \bar{x})^2} \begin{pmatrix} \left(\sum_{i=1}^n y_i \right) \left(\sum_{i=1}^n x_i^2 \right) - \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n x_i y_i \right) \\ n \sum_{i=1}^n x_i y_i - \left(\sum_{i=1}^n y_i \right) \left(\sum_{i=1}^n x_i \right) \end{pmatrix}\end{aligned}$$

Ejercicio: Comprobar

Por lo tanto

$$\begin{aligned}\hat{\boldsymbol{\theta}} &= \begin{pmatrix} \hat{\theta}_1 \\ \hat{\theta}_2 \end{pmatrix} \\ &= \frac{1}{n \sum_{i=1}^n (x_i - \bar{x})^2} \begin{pmatrix} \left(\sum_{i=1}^n y_i \right) \left(\sum_{i=1}^n x_i^2 \right) - \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n x_i y_i \right) \\ n \sum_{i=1}^n x_i y_i - \left(\sum_{i=1}^n y_i \right) \left(\sum_{i=1}^n x_i \right) \end{pmatrix}\end{aligned}$$

Entonces

$$\hat{\theta}_1 = \bar{y} - \bar{x} \hat{\theta}_2$$

y por otro lado

$$\hat{\theta}_2 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\text{Cov}(\mathbf{x}, \mathbf{y})}{\text{Var}(\mathbf{x})}$$

Propiedades de vectores y matrices aleatorias

Dada una matriz $\mathbf{V}$ (de $r \times s$) de variables aleatorias $\{V_{ij}\}$ conjuntamente distribuidas con esperanza finita, definimos la matriz o vector de esperanzas como:

$$\{\mathbb{E}(\mathbf{V})\}_{ij} = \mathbb{E}(V_{ij}).$$

En el caso del modelo Ω , esto nos permite decir que el vector de errores es tal que

$$\mathbb{E}(\boldsymbol{\epsilon}) = \mathbf{0}$$

$$\mathbb{E}\left(\begin{pmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{pmatrix}\right) = \begin{pmatrix} \mathbb{E}(\epsilon_1) \\ \vdots \\ \mathbb{E}(\epsilon_n) \end{pmatrix} = \vec{0}$$

y que

$$\mathbb{E}(\boldsymbol{\epsilon}\boldsymbol{\epsilon}^T) = \mathbb{E}\begin{pmatrix} \epsilon_1\epsilon_1 & \epsilon_1\epsilon_2 & \dots & \epsilon_1\epsilon_n \\ \epsilon_2\epsilon_1 & \epsilon_2\epsilon_2 & \dots & \epsilon_2\epsilon_n \\ \dots & & \dots & \\ \dots & & \dots & \\ \epsilon_n\epsilon_1 & \epsilon_n\epsilon_2 & \dots & \epsilon_n\epsilon_n \end{pmatrix} = \begin{pmatrix} \mathbb{E}(\epsilon_1^2) & \dots & \\ \mathbb{E}(\epsilon_1\epsilon_2) & \dots & \\ \vdots & \ddots & \ddots \\ \mathbb{E}(\epsilon_n^2) & \dots & \end{pmatrix}$$

Propiedades de vectores y matrices aleatorias

Dada una matriz $\mathbf{V}$ (de $r \times s$) de variables aleatorias $\{V_{ij}\}$ conjuntamente distribuidas con esperanza finita, definimos la matriz o vector de esperanzas como:

$$\{\mathbb{E}(\mathbf{V})\}_{ij} = \mathbb{E}(V_{ij}).$$

En el caso del modelo Ω , esto nos permite decir que el vector de errores es tal que

$$\mathbb{E}(\boldsymbol{\epsilon}) = \mathbf{0}$$

y que

$$\mathbb{E}(\boldsymbol{\epsilon}\boldsymbol{\epsilon}^T) = \mathbb{E} \begin{pmatrix} \varepsilon_1\varepsilon_1 & \varepsilon_1\varepsilon_2 & \dots & \varepsilon_1\varepsilon_n \\ \varepsilon_2\varepsilon_1 & \varepsilon_2\varepsilon_2 & \dots & \varepsilon_2\varepsilon_n \\ \dots & & \dots & \\ \dots & & \dots & \\ \varepsilon_n\varepsilon_1 & \varepsilon_n\varepsilon_2 & \dots & \varepsilon_n\varepsilon_n \end{pmatrix} = \sigma^2 \mathbf{I}$$

Propiedades de la esperanza

Lema 6.1: Sean $\mathbf{A} \in \mathbb{R}^{q \times r}$, $\mathbf{B} \in \mathbb{R}^{s \times t}$ y $\mathbf{C} \in \mathbb{R}^{q \times t}$ matrices constantes y $\mathbf{V}$ una matriz aleatoria de dimensión $r \times s$, entonces:

$$\mathbb{E}(\mathbf{A}\mathbf{V}\mathbf{B} + \mathbf{C}) = \mathbf{A}\mathbb{E}(\mathbf{V})\mathbf{B} + \mathbf{C}.$$

Demo: Se demuestra coordenada a coordenada.

$$\forall q \quad \underbrace{(\mathbb{E}(\mathbf{A}\mathbf{V}\mathbf{B} + \mathbf{C}))}_{i,j} = (\mathbf{A}\mathbb{E}(\mathbf{V})\mathbf{B} + \mathbf{C})_{ij} \quad \begin{matrix} 1 \leq i \leq q \\ 1 \leq j \leq t \end{matrix}$$

Sea $1 \leq i \leq q$, $1 \leq j \leq t$.

$$(\mathbf{A}\mathbf{V}\mathbf{B} + \mathbf{C})_{ij} = (\underbrace{\mathbf{A}\mathbf{V}}_{q \times s})_{ij} + C_{ij} = \sum_{k=1}^s (\mathbf{A}\mathbf{V})_{ik} B_{kj} + C_{ij}$$

$$= \sum_{k=1}^s \sum_{l=1}^r A_{il} V_{lk} B_{kj} + C_{ij}$$

⇒ por linealidad de la esperanza

$$(\mathbb{E}(\mathbf{A}\mathbf{V}\mathbf{B} + \mathbf{C}))_{ij} \stackrel{x \text{ def}}{=} \mathbb{E}((\mathbf{A}\mathbf{V}\mathbf{B} + \mathbf{C})_{ij}) = \underbrace{\sum_{k=1}^s \sum_{l=1}^r A_{il} \mathbb{E}(V_{lk}) B_{kj} + C_{ij}}_{(\mathbf{A}\mathbb{E}(\mathbf{V})\mathbf{B} + \mathbf{C})_{ij}} \quad \checkmark$$

Propiedades de la esperanza

Lema 6.1: Sean $\mathbf{A} \in \mathbb{R}^{q \times r}$, $\mathbf{B} \in \mathbb{R}^{s \times t}$ y $\mathbf{C} \in \mathbb{R}^{q \times t}$ matrices constantes y $\mathbf{V}$ una matriz aleatoria de dimensión $r \times s$, entonces:

$$\mathbb{E}(\mathbf{A}\mathbf{V}\mathbf{B} + \mathbf{C}) = \mathbf{A}\mathbb{E}(\mathbf{V})\mathbf{B} + \mathbf{C}.$$

Caso particular: Si $\mathbf{A} \in \mathbb{R}^{p \times q}$ y $\mathbf{d} \in \mathbb{R}^p$ son una matriz y un vector constantes y $\mathbf{v} \in \mathbb{R}^q$ es un vector aleatorio, entonces $\mathbf{w} = \mathbf{A}\mathbf{v} + \mathbf{d} \in \mathbb{R}^p$ es un vector aleatorio y

$$\mathbb{E}(\mathbf{w}) = \mathbf{A}\mathbb{E}(\mathbf{v}) + \mathbf{d}.$$

Matriz de Covarianza

Sea $\mathbf{v} = (v_1, \dots, v_n)^T$ un vector aleatorio de variables con $E(v_i) = \mu_i$ y varianzas finitas.

Definimos la **matriz de covarianza de $\mathbf{v}$** , y la notamos con $\Sigma_{\mathbf{v}}$, como la matriz de $n \times n$ tal que para $1 \leq i, j \leq n$:

$$\{\Sigma_{\mathbf{v}}\}_{ij} = \text{Cov}(v_i, v_j) = \mathbb{E}[(v_i - \mu_i)(v_j - \mu_j)]$$

Podemos escribirla como:

$$\Sigma_{\mathbf{v}} = \text{Var}(\mathbf{v}) = \mathbb{E}[(\mathbf{v} - \boldsymbol{\mu})(\mathbf{v} - \boldsymbol{\mu})^T] \in \mathbb{R}^{n \times n}$$

donde $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^T$.

$$\begin{pmatrix} v_1 - \mu_1 \\ \vdots \\ v_n - \mu_n \end{pmatrix} (v_1 - \mu_1, \dots, v_n - \mu_n)$$

Matriz de Covarianza

Sea $\mathbf{v} = (v_1, \dots, v_n)^T$ un vector aleatorio de variables con $E(v_i) = \mu_i$ y varianzas finitas.

Definimos la **matriz de covarianza de $\mathbf{v}$** , y la notamos con $\Sigma_{\mathbf{v}}$, como la matriz de $n \times n$ tal que para $1 \leq i, j \leq n$:

$$\{\Sigma_{\mathbf{v}}\}_{ij} = \text{Cov}(v_i, v_j) = \mathbb{E}[(v_i - \mu_i)(v_j - \mu_j)]$$

Podemos escribirla como:

$$\Sigma_{\mathbf{v}} = \text{Var}(\mathbf{v}) = \mathbb{E}[(\mathbf{v} - \boldsymbol{\mu})(\mathbf{v} - \boldsymbol{\mu})^T]$$

donde $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^T$.

En este sentido, para el modelo Ω , como $\mathbb{E}(\boldsymbol{\epsilon}) = \mathbf{0}$, resulta que

$$\Sigma_{\boldsymbol{\epsilon}} = \mathbb{E}(\boldsymbol{\epsilon}\boldsymbol{\epsilon}^T) = \sigma^2 \mathbf{I}$$

Propiedades de la matriz de covarianza

Lema 6.2: Sean $\mathbf{A} \in \mathbb{R}^{m \times n}$ una matriz constante, $\mathbf{d}$ un vector de constantes y $\mathbf{v}$ un vector aleatorio n -dimensional con esperanza $\boldsymbol{\mu}$ y matriz de covarianza $\boldsymbol{\Sigma}_{\mathbf{v}}$. Si $\mathbf{w} = \mathbf{A}\mathbf{v} + \mathbf{d}$, entonces:

$$\boldsymbol{\Sigma}_{\mathbf{w}} = \mathbf{A}\boldsymbol{\Sigma}_{\mathbf{v}}\mathbf{A}^T.$$

Demo: Usaremos la linealidad de la esperanza vista anteriormente

$$\begin{aligned}\boldsymbol{\Sigma}_{\mathbf{w}} &= E\left((\mathbf{w} - \underbrace{E(\mathbf{w})}) (\mathbf{w} - \underbrace{E(\mathbf{w})})^T\right) = \\ &\quad \underbrace{E(\mathbf{w}) = \mathbf{A}E(\mathbf{v}) + \mathbf{d}}_{\mathbf{w} = \mathbf{A}\mathbf{v} + \mathbf{d}} \uparrow \\ &= E\left(\left(\cancel{\mathbf{A}\mathbf{v} + \mathbf{d}} - (\cancel{\mathbf{A}E(\mathbf{v}) + \mathbf{d}})\right) \cdot \left(\cancel{\mathbf{A}\mathbf{v} + \mathbf{d}} - (\cancel{\mathbf{A}E(\mathbf{v}) + \mathbf{d}})\right)^T\right) \\ &= E\left(\left(\mathbf{A}(\mathbf{v} - E(\mathbf{v}))\right) \left(\mathbf{A}(\mathbf{v} - E(\mathbf{v}))\right)^T\right) \\ &= E\left(\mathbf{A}(\mathbf{v} - E(\mathbf{v})) \cdot (\mathbf{v} - E(\mathbf{v}))^T \cdot \mathbf{A}^T\right) \\ &= \mathbf{A} \boldsymbol{\Sigma}_{\mathbf{v}} \mathbf{A}^T \quad \checkmark\end{aligned}$$



El modelo

El modelo que presentamos más arriba puede escribirse como:

$$(1) \quad \Omega : \mathbf{Y} = \mathbf{X}\boldsymbol{\theta} + \boldsymbol{\epsilon}, \quad \mathbb{E}(\boldsymbol{\epsilon}) = \mathbf{0}, \quad \Sigma_{\boldsymbol{\epsilon}} = \sigma^2 \mathbf{I}$$

o, equivalentemente,

$$(2) \quad \Omega : \mathbb{E}(\mathbf{Y}) = \mathbf{X}\boldsymbol{\theta}, \quad \Sigma_{\mathbf{Y}} = \sigma^2 \mathbf{I}$$

$$(1) \Rightarrow (2) \quad \begin{aligned} E(\mathbf{Y}) &= E(\mathbf{X}\boldsymbol{\theta} + \boldsymbol{\epsilon}) = \mathbf{X}\boldsymbol{\theta} + \overbrace{E(\boldsymbol{\epsilon})}^{\mathbf{0}} = \mathbf{X}\boldsymbol{\theta} \quad \checkmark \\ \Sigma_{\mathbf{Y}} &= \text{var}(\mathbf{X}\boldsymbol{\theta} + \boldsymbol{\epsilon}) = \text{var}(\boldsymbol{\epsilon}) = \Sigma_{\boldsymbol{\epsilon}} = \sigma^2 \mathbf{I} \quad \checkmark \end{aligned}$$

$$(2) \Rightarrow (1) \quad \begin{aligned} \mathbf{y} &= \mathbf{y} - \mathbf{X}\boldsymbol{\theta} + \mathbf{X}\boldsymbol{\theta} \\ &= \mathbf{X}\boldsymbol{\theta} + \boldsymbol{\epsilon} \quad \checkmark \end{aligned} \quad \text{Defino } \boldsymbol{\epsilon} := \mathbf{y} - \mathbf{X}\boldsymbol{\theta}$$

$$\begin{aligned} E(\boldsymbol{\epsilon}) &= E(\mathbf{y} - \mathbf{X}\boldsymbol{\theta}) = E(\mathbf{y}) - \mathbf{X}\boldsymbol{\theta} = \mathbf{X}\boldsymbol{\theta} - \mathbf{X}\boldsymbol{\theta} = \mathbf{0} \quad \checkmark \\ \Sigma_{\boldsymbol{\epsilon}} &= \text{var}(\boldsymbol{\epsilon}) = \text{var}(\mathbf{y} - \mathbf{X}\boldsymbol{\theta}) = \text{var}(\mathbf{y}) = \Sigma_{\mathbf{Y}} = \sigma^2 \mathbf{I} \quad \checkmark \end{aligned}$$

El modelo lineal: Interpretación Geométrica

Supondremos que $n \geq p$. Podemos pensar a la matriz de diseño de dos maneras:

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_n^T \end{pmatrix} = \left(\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(p)} \right)$$

Sea $\mathcal{V}$ el subespacio de $\mathbb{R}^n$ generado por las columnas de $\mathbf{X}$.

$$\dim(\mathcal{V}) = \text{rango}(\mathbf{X})$$

El modelo lineal: Interpretación Geométrica

Supondremos que $n \geq p$. Podemos pensar a la matriz de diseño de dos maneras:

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_n^T \end{pmatrix} = \left(\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(p)} \right)$$

Sea $\mathcal{V}$ el subespacio de $\mathbb{R}^n$ generado por las columnas de $\mathbf{X}$.

$$\dim(\mathcal{V}) = \text{rango}(\mathbf{X})$$

El modelo supuesto

$$\mathbb{E}(\mathbf{Y}) = \mathbf{X}\boldsymbol{\theta} = \theta_1 \mathbf{x}^{(1)} + \dots + \theta_p \mathbf{x}^{(p)}$$

El modelo lineal: Interpretación Geométrica

Supondremos que $n \geq p$. Podemos pensar a la matriz de diseño de dos maneras:

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_n^T \end{pmatrix} = \left(\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(p)} \right)$$

Sea $\mathcal{V}$ el subespacio de $\mathbb{R}^n$ generado por las columnas de $\mathbf{X}$.

$$\dim(\mathcal{V}) = \text{rango}(\mathbf{X})$$

El modelo supuesto

$$\mathbb{E}(\mathbf{Y}) = \mathbf{X}\boldsymbol{\theta} = \theta_1 \mathbf{x}^{(1)} + \dots + \theta_p \mathbf{x}^{(p)}$$

es decir, que $\mathbb{E}(\mathbf{Y})$ es una combinación lineal de las columnas de $\mathbf{X}$, o sea,

$$\mathbb{E}(\mathbf{Y}) \in \mathcal{V}$$

El modelo lineal: Interpretación Geométrica

- Si $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(p)}$ son linealmente independientes, o sea, si $\dim(\mathcal{V}) = \text{rango}(\mathbf{X}) = p$, existe un **único** $\boldsymbol{\theta}$ tal que $\mathbb{E}(\mathbf{Y}) = \mathbf{X}\boldsymbol{\theta}$.

El modelo lineal: Interpretación Geométrica

- Si $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(p)}$ son linealmente independientes, o sea, si $\dim(\mathcal{V}) = \text{rango}(\mathbf{X}) = p$, existe un **único** $\boldsymbol{\theta}$ tal que $\mathbb{E}(\mathbf{Y}) = \mathbf{X}\boldsymbol{\theta}$.
- Si $\dim(\mathcal{V}) = q < p$, $\boldsymbol{\theta}$ no está determinado aunque $\mathbb{E}(\mathbf{Y})$ sí lo está. En este caso, tenemos dos opciones

El modelo lineal: Interpretación Geométrica

- Si $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(p)}$ son linealmente independientes, o sea, si $\dim(\mathcal{V}) = \text{rango}(\mathbf{X}) = p$, existe un **único** $\boldsymbol{\theta}$ tal que $\mathbb{E}(\mathbf{Y}) = \mathbf{X}\boldsymbol{\theta}$.
- Si $\dim(\mathcal{V}) = q < p$, $\boldsymbol{\theta}$ **no está determinado** aunque $\mathbb{E}(\mathbf{Y})$ sí lo está. En este caso, tenemos dos opciones
 - Si $\dim(\mathcal{V}) = q$ y $\mathbf{x}^{(j_1)}, \dots, \mathbf{x}^{(j_q)}$ generan $\mathcal{V}$, tenemos que

$$\mathbb{E}(\mathbf{Y}) = \sum_{s=1}^q \tilde{\theta}_s \mathbf{x}^{(j_s)}$$

y el vector $\tilde{\boldsymbol{\theta}} = (\tilde{\theta}_1, \dots, \tilde{\theta}_q)^T$ está bien determinado.

El modelo lineal: Interpretación Geométrica

- Si $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(p)}$ son linealmente independientes, o sea, si $\dim(\mathcal{V}) = \text{rango}(\mathbf{X}) = p$, existe un **único** $\boldsymbol{\theta}$ tal que $\mathbb{E}(\mathbf{Y}) = \mathbf{X}\boldsymbol{\theta}$.
- Si $\dim(\mathcal{V}) = q < p$, $\boldsymbol{\theta}$ **no está determinado** aunque $\mathbb{E}(\mathbf{Y})$ sí lo está. En este caso, tenemos dos opciones
 - Si $\dim(\mathcal{V}) = q$ y $\mathbf{x}^{(j_1)}, \dots, \mathbf{x}^{(j_q)}$ generan $\mathcal{V}$, tenemos que

$$\mathbb{E}(\mathbf{Y}) = \sum_{s=1}^q \tilde{\theta}_s \mathbf{x}^{(j_s)}$$

y el vector $\tilde{\boldsymbol{\theta}} = (\tilde{\theta}_1, \dots, \tilde{\theta}_q)^T$ está bien determinado.

- La otra opción es **imponer restricciones lineales a $\boldsymbol{\theta}$** mediante

$$\mathbf{A}\boldsymbol{\theta} = \mathbf{0}$$

con $\mathbf{A}$ una matriz elegida para que el vector quede unívocamente determinado.

Interpretación Geométrica

Entonces

$$\mathcal{S}(\hat{\boldsymbol{\theta}}) = \min_{\mathbf{b} \in \mathbb{R}^p} \mathcal{S}(\mathbf{b}) = \min_{\mathbf{b} \in \mathbb{R}^p} \|\mathbf{Y} - \mathbf{X}\mathbf{b}\|^2 = \min_{\mathbf{z} \in \mathcal{V}} \|\mathbf{Y} - \mathbf{z}\|^2$$

El mínimo se alcanza en la proyección ortogonal de $\mathbf{Y}$ sobre $\mathcal{V}$: $\hat{\mathbf{Y}}$, a quien podemos escribir como $b_1\mathbf{x}^{(1)} + b_2\mathbf{x}^{(2)} + \dots + b_p\mathbf{x}^{(p)}$, siempre existe y es única, aunque los b_i pueden no serlo. Lo serán si $\mathbf{X}$ tiene rango completo.

Interpretación Geométrica

Entonces

$$\mathcal{S}(\hat{\boldsymbol{\theta}}) = \min_{\mathbf{b} \in \mathbb{R}^p} \mathcal{S}(\mathbf{b}) = \min_{\mathbf{b} \in \mathbb{R}^p} \|\mathbf{Y} - \mathbf{X}\mathbf{b}\|^2 = \min_{\mathbf{z} \in \mathcal{V}} \|\mathbf{Y} - \mathbf{z}\|^2$$

El mínimo se alcanza en la proyección ortogonal de $\mathbf{Y}$ sobre $\mathcal{V}$: $\hat{\mathbf{Y}}$, a quien podemos escribir como $b_1\mathbf{x}^{(1)} + b_2\mathbf{x}^{(2)} + \dots + b_p\mathbf{x}^{(p)}$, siempre existe y es única, aunque los b_i pueden no serlo. Lo serán si $\mathbf{X}$ tiene rango completo.

En términos de las ecuaciones normales tenemos que:

$$\mathbf{X}^T \hat{\mathbf{X}}\hat{\boldsymbol{\theta}} = \mathbf{X}^T \mathbf{Y}$$

$$\mathbf{X}^T \hat{\mathbf{Y}} = \mathbf{X}^T \mathbf{Y}$$

Caso $\text{rg}(\mathbf{X}) = p$

En este caso, existe la inversa de $\mathbf{X}^T\mathbf{X}$ ya que $\text{rg}(\mathbf{X}^T\mathbf{X}) = \text{rg}(\mathbf{X}) = p$.

Como de las ecuaciones normales:

$$\begin{aligned}\mathbf{X}^T\mathbf{X}\hat{\boldsymbol{\theta}} &= \mathbf{X}^T\mathbf{Y} \\ \hat{\boldsymbol{\theta}} &= (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y}\end{aligned}$$

entonces

$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\theta}} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y} = \mathbf{P}\mathbf{Y}$$

con $\mathbf{P} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T \in \mathbb{R}^{n \times n}$ llamada **hat matrix**.

En consecuencia, el vector de residuos es:

$$\begin{aligned}\mathbf{r}(\hat{\boldsymbol{\theta}}) &= \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\theta}} \\ &= \mathbf{Y} - \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y} \\ &= \mathbf{Y} - \mathbf{P}\mathbf{Y} = (\mathbf{I} - \mathbf{P})\mathbf{Y}\end{aligned}$$

Propiedades del Estimador de Mínimos Cuadrados

Usando la notación matricial escribimos el modelo como

$$\Omega: \mathbf{Y} = \mathbf{X}\boldsymbol{\theta} + \boldsymbol{\epsilon}$$

$$E(\boldsymbol{\epsilon}) = \mathbf{0}$$

$$\Sigma_{\boldsymbol{\epsilon}} = \sigma^2 \mathbf{I}$$

Lema 6.3: Si se cumple el modelo Ω y $\text{rg}(\mathbf{X}) = p$, tenemos que

★ $\hat{\boldsymbol{\theta}}$ es un estimador insesgado de $\boldsymbol{\theta}$, es decir $\mathbb{E}(\hat{\boldsymbol{\theta}}) = \boldsymbol{\theta}$.

★ $\Sigma_{\hat{\boldsymbol{\theta}}} = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$

Demo: $\hat{\boldsymbol{\theta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \Rightarrow E(\hat{\boldsymbol{\theta}}) = E((\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}) = E(\mathbf{A} (\mathbf{X}\boldsymbol{\theta} + \boldsymbol{\epsilon}))$
 $= \mathbf{A} E(\mathbf{X}\boldsymbol{\theta} + \boldsymbol{\epsilon}) = \mathbf{A} (\mathbf{X}\boldsymbol{\theta} + E(\boldsymbol{\epsilon})) = \mathbf{A} \mathbf{X}\boldsymbol{\theta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} \boldsymbol{\theta} = \boldsymbol{\theta} \checkmark$

$\cdot \Sigma_{\hat{\boldsymbol{\theta}}} = V(\mathbf{A} \mathbf{y}) = \mathbf{A} V(\mathbf{y}) \mathbf{A}^T = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \sigma^2 \mathbf{I} \mathbf{X} ((\mathbf{X}^T \mathbf{X})^{-1})^T$
 $= \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1} \checkmark$

Propiedades del Estimador de Mínimos Cuadrados

Usando la notación matricial escribimos el modelo como

$$\Omega : \quad \mathbf{Y} = \mathbf{X}\boldsymbol{\theta} + \boldsymbol{\epsilon}$$

$$E(\boldsymbol{\epsilon}) = \mathbf{0}$$

$$\boldsymbol{\Sigma}_{\boldsymbol{\epsilon}} = \sigma^2 \mathbf{I}$$

Lema 6.3: Si se cumple el modelo Ω y $\text{rg}(\mathbf{X}) = p$, tenemos que

- ★ $\hat{\boldsymbol{\theta}}$ es un estimador insesgado de $\boldsymbol{\theta}$, es decir $\mathbb{E}(\hat{\boldsymbol{\theta}}) = \boldsymbol{\theta}$.
- ★ $\boldsymbol{\Sigma}_{\hat{\boldsymbol{\theta}}} = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$

El mínimo valor de $\mathcal{S}$ se denomina *suma de cuadrados de los residuos* (RSS, Residual Sum of Squares):

$$\text{RSS} = \|\mathbf{Y} - \hat{\mathbf{Y}}\|^2 = \|\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\theta}}\|^2.$$