

Suponiendo normalidad bajo el modelo...

$$\Omega \quad : \quad \mathbf{Y} \sim N_n(\mathbf{X}\boldsymbol{\theta}, \sigma^2\mathbf{I})$$
$$\mathbf{X} \in \mathbb{R}^{n \times p}, \text{ rg}(\mathbf{X}) = p$$

Suponiendo normalidad bajo el modelo...

$$\Omega : \quad \mathbf{Y} \sim N_n(\mathbf{X}\boldsymbol{\theta}, \sigma^2\mathbf{I})$$
$$\mathbf{X} \in \mathbb{R}^{n \times p}, \text{ rg}(\mathbf{X}) = p$$

Teorema: Supongamos que $\mathbf{Y} \sim N_n(\mathbf{X}\boldsymbol{\theta}, \sigma^2\mathbf{I})$, $\text{rg}(\mathbf{X}) = p$, $\boldsymbol{\theta} \in \mathbb{R}^p$. Entonces, si $\hat{\boldsymbol{\theta}}$ es el estimador de mínimos cuadrados de $\boldsymbol{\theta}$, tenemos que

- i) $\hat{\boldsymbol{\theta}} \sim N_p(\boldsymbol{\theta}, \sigma^2(\mathbf{X}^T\mathbf{X})^{-1})$
- ii) $\frac{(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})^T(\mathbf{X}^T\mathbf{X})(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})}{\sigma^2} \sim \chi_p^2$
- iii) $\hat{\boldsymbol{\theta}}$ y $\frac{(n-p)S^2}{\sigma^2}$ son independientes
- iv) $\frac{(n-p)S^2}{\sigma^2} \sim \chi_{n-p}^2$
- v) $\frac{(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})^T(\mathbf{X}^T\mathbf{X})(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})}{p S^2} \sim F_{p, n-p}$

Demo:

$$i) \hat{\theta} = \underbrace{(X^T X)^{-1}}_{A \in \mathbb{R}^{p \times n}} X^T y \Rightarrow \hat{\theta} = A y \underset{x \text{ prop}}{\sim} N_p \left(\underbrace{A X \theta}_{\mu_y}; \underbrace{A \Sigma_y A^T}_{\sigma^2 I} \right)$$

$$CA: A X \theta = (\cancel{X^T X})^{-1} \cancel{X^T} X \theta = \theta$$

$$A \cdot \sigma^2 I A^T = \sigma^2 (\cancel{X^T X})^{-1} \cancel{X^T} X (\cancel{X^T X})^{-1}$$

$$\Rightarrow \hat{\theta} \sim N(\theta; \sigma^2 (X^T X)^{-1}) \checkmark$$

$$ii) \text{ Rec: } z \sim N_p(\mu_z; \Sigma_z) \Rightarrow (z - \mu_z)^T \Sigma_z^{-1} (z - \mu_z) \sim \chi_p^2$$

$$\Sigma_{\hat{\theta}} = \sigma^2 (X^T X)^{-1} \Rightarrow \Sigma_{\hat{\theta}}^{-1} = \frac{1}{\sigma^2} (X^T X) \quad (\mu_{\hat{\theta}} = \theta)$$

$$\Rightarrow \frac{(\hat{\theta} - \theta)^T (X^T X) (\hat{\theta} - \theta)}{\sigma^2} \sim \chi_p^2$$

$$iii) S^2 = \frac{y^T (I_n - P) y}{n-p}$$

$$P = X (X^T X)^{-1} X^T$$

obs! Como P é uma matriz de projecção $\Rightarrow P = U \begin{pmatrix} I_p & 0 \\ 0 & 0 \end{pmatrix} U^T$ $U \in \mathbb{R}^{n \times n}$

Teorema Espectral o de Descomposición ortogonal

Si A es una matriz simétrica, entonces existe una matriz ortogonal U (es decir, $U^T U = I$) y una matriz diagonal D tales que

$$A = U D U^T$$

Además, los elementos diagonales de D son los autovalores de A y las columnas de U son los autovectores ortonormales correspondientes.

↑ obs! $P = U D U^T$ $] = \Rightarrow D = D^2 \Rightarrow$ los autovalores son 0 y 1.
 $P^2 = U D^2 U^T$

↑ Como $\text{rg}(P) = p \Rightarrow$ tengo exactamente p autovalores 1's.

Entonces $U = \begin{bmatrix} U_1 & U_2 \end{bmatrix}$
 $n \times p \quad n \times (n-p)$

U_1 : las columnas de U forman una base ortonormal del espacio generado por las columnas de X .

U_2 : las columnas de U que forman una base ortonormal de $\text{col}(X)^\perp$.

obs! $U_1^T U_1 = I_p$ $U_1^T U_2 = 0$
 $U_2^T U_2 = I_{n-p}$

⇒ Multiplicamos Y por U^T :

$$\begin{pmatrix} U_1^T Y \\ U_2^T Y \end{pmatrix} = U^T Y = \begin{pmatrix} U_1^T \\ U_2^T \end{pmatrix} Y \sim N \left(\begin{pmatrix} U_1^T X \theta \\ U_2^T X \theta \end{pmatrix}; \begin{pmatrix} \sigma^2 U_1^T U_1 & \\ & \sigma^2 I \end{pmatrix} \right)$$

obs: $\text{Var}(AY) = A \Sigma Y A^T$

porque U_2 es ortogonal a X

Por lo tanto, $U_1^T Y$ y $U_2^T Y$ son independientes

Como $\hat{\theta} = (X^T X)^{-1} X^T Y = (B^T \underbrace{U_1^T U_1}_I B)^{-1} B^T \underbrace{U_1^T Y}_{\text{es función de } U_1^T Y}$

$X = U_1 B$ con B de $p \times p$ invertible

$$\text{Por otro lado } (n-p)S^2 = Y^T (\underbrace{I - P}) Y = ((I - P)Y)^T (I - P)Y$$
$$(I - P)^T (I - P)$$

$$\underbrace{(I - P)Y} = U \underbrace{\begin{pmatrix} \mathbb{O} & \mathbb{O} \\ \mathbb{O} & I_{n-p} \end{pmatrix}} U^T Y = \underbrace{U_2}_{\text{ortogonal a } X} \underbrace{U_2^T Y}_{\text{independiente de } U_1^T Y}$$

Luego, como $\hat{\theta}$ depende de $U_1^T Y$ y S^2 depende de $U_2^T Y$ entonces $\hat{\theta}$ y S^2 son independientes (porque $U_1^T Y$ y $U_2^T Y$ lo son) ✓

$$N) \quad S^2 = \frac{r^T r}{n-p} \quad \left[r = \underbrace{(I-P)}_{U_2 U_2^T} y = \underbrace{(I-P)}_{I-P = (I-P)^2} r \right]$$

$$\therefore S^2 = \frac{1}{n-p} r^T r = \frac{1}{n-p} ((I-P)r)^T (I-P)r = \frac{1}{n-p} r^T \underbrace{(I-P)}_{U_2 U_2^T} r$$

$$= \frac{1}{n-p} (U_2^T r)^T (U_2^T r)$$

ya vemos $U_2^T r \sim N_{n-p}(0, \sigma^2 I_{n-p})$

$$\Rightarrow Z = \frac{U_2^T r}{\sigma} \sim N_{n-p}(0, I_{n-p})$$

$$\frac{(n-p)S^2}{\sigma^2} = \frac{r^T r}{\sigma^2} = \frac{(U_2^T r)^T (U_2^T r)}{\sigma^2} = Z^T Z = \sum_{i=1}^{n-p} z_i^2 \sim \chi_{n-p}^2 \quad \checkmark$$

$$v) \quad \frac{(\hat{\theta} - \theta)^T (X^T X) (\hat{\theta} - \theta)}{p} \quad \bigg/ \quad \frac{(n-p)S^2}{(n-p)} = \frac{(\hat{\theta} - \theta)^T (X^T X) (\hat{\theta} - \theta)}{p S^2} \sim \widetilde{F}_{p, n-p}$$

per indep □

Combinaciones Lineales

En el contexto del Modelo Lineal suele interesarnos estimar o hacer inferencia sobre combinaciones lineales del vector de parámetros.

Así es que podría interesarnos hacer un test o un intervalo sobre alguna componente o estimar el valor esperado de la respuesta en un nuevo punto independiente con $\mathbf{x}_0 = (x_{01}, x_{02}, \dots, x_{0p})^T$.

Sea y_0 la respuesta en un punto de diseño $\mathbf{x}_0$. Supongamos que el modelo establece

$$\mathbb{E}(y_0) = \theta_1 x_{01} + \theta_2 x_{02} + \dots + \theta_p x_{0p}$$

y que tenemos interés en estimar $\theta_1 x_{01} + \theta_2 x_{01} + \dots + \theta_p x_{0p}$ o testear hipótesis como las siguientes:

$$H_0 : \theta_j = 0 \quad \text{vs.} \quad H_1 : \theta_j \neq 0$$

$$H_0 : \theta_1 - \theta_2 = 0 \quad \text{vs.} \quad H_1 : \theta_1 - \theta_2 \neq 0$$

$$H_0 : \theta_2 = \dots = \theta_p = 0 \quad \text{vs.} \quad H_1 : \text{existe } j : \theta_j \neq 0$$

Combinaciones Lineales

Esto involucra funciones de la forma

$$\varphi = \mathbf{a}^T \boldsymbol{\theta}$$

que son combinaciones lineales del vector de parámetros. Pero, ¿cómo lo estimamos?

Combinaciones Lineales

Esto involucra funciones de la forma

$$\varphi = \mathbf{a}^T \boldsymbol{\theta}$$

que son combinaciones lineales del vector de parámetros. Pero, ¿cómo lo estimamos?

$$\varphi = \mathbf{a}^T \boldsymbol{\theta} \Rightarrow \hat{\varphi} = \mathbf{a}^T \hat{\boldsymbol{\theta}}$$

Podría haber muchos estimadores de una función lineal $\mathbf{a}^T \boldsymbol{\theta}$, si nos enfocamos en los **estimadores lineales** en $\mathbf{Y} = (y_1, \dots, y_n)^T$ se puede probar el **Teorema de Gauss–Markov**, que establece que cuando el modelo es tal que $\mathbb{E}(\mathbf{Y}) = \mathbf{X}\boldsymbol{\theta}$, $\Sigma_{\mathbf{Y}} = \sigma^2 \mathbf{I}$, $\text{rg}(\mathbf{X}) = p$, el estimador $\hat{\varphi}$ propuesto es el de menor varianza dentro de los estimadores insesgados lineales en $\mathbf{Y}$.

Propiedades

Teorema: Supongamos que $\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\theta}, \sigma^2\mathbf{I})$, $\boldsymbol{\theta} \in \mathbb{R}^p$, $\text{rg}(\mathbf{X}) = p$ y definamos

$$\varphi = \mathbf{a}^T \boldsymbol{\theta}, \quad \hat{\varphi} = \mathbf{a}^T \hat{\boldsymbol{\theta}}$$

Entonces

- i) $\hat{\varphi} = \mathbf{a}^T \hat{\boldsymbol{\theta}}$ es un estimador insesgado para $\varphi = \mathbf{a}^T \boldsymbol{\theta}$ (Ejercicio)
- ii) $\text{VAR}(\hat{\varphi}) = \sigma^2 \mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a} = \sigma_{\hat{\varphi}}^2$ (Ejercicio)

Propiedades

Teorema: Supongamos que $\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\theta}, \sigma^2\mathbf{I})$, $\boldsymbol{\theta} \in \mathbb{R}^p$, $\text{rg}(\mathbf{X}) = p$ y definamos

$$\varphi = \mathbf{a}^T \boldsymbol{\theta}, \quad \hat{\varphi} = \mathbf{a}^T \hat{\boldsymbol{\theta}}$$

Entonces

- i) $\hat{\varphi} = \mathbf{a}^T \hat{\boldsymbol{\theta}}$ es un estimador insesgado para $\varphi = \mathbf{a}^T \boldsymbol{\theta}$ (Ejercicio)
- ii) $\text{VAR}(\hat{\varphi}) = \sigma^2 \mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a} = \sigma_{\hat{\varphi}}^2$ (Ejercicio)
- iii) $\hat{\varphi} \sim N(\varphi, \sigma^2 \mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a}) = N(\varphi, \sigma_{\hat{\varphi}}^2) \leftarrow \hat{\boldsymbol{\theta}} \sim N(\boldsymbol{\theta}; \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1})$

Propiedades

Teorema: Supongamos que $\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I})$, $\boldsymbol{\theta} \in \mathbb{R}^p$, $\text{rg}(\mathbf{X}) = p$ y definamos

$$\varphi = \mathbf{a}^T \boldsymbol{\theta}, \quad \hat{\varphi} = \mathbf{a}^T \hat{\boldsymbol{\theta}}$$

Entonces

- i) $\hat{\varphi} = \mathbf{a}^T \hat{\boldsymbol{\theta}}$ es un estimador insesgado para $\varphi = \mathbf{a}^T \boldsymbol{\theta}$ (Ejercicio)
- ii) $\text{VAR}(\hat{\varphi}) = \sigma^2 \mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a} = \sigma_{\hat{\varphi}}^2$ (Ejercicio)
- iii) $\hat{\varphi} \sim N(\varphi, \underbrace{\sigma^2 \mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a}}_{\sigma_{\hat{\varphi}}^2}) = N_1(\varphi, \underbrace{\sigma_{\hat{\varphi}}^2}_{\sigma_{\hat{\varphi}}^2})$
- iv) Sea $\hat{\sigma}_{\hat{\varphi}}^2 = S^2 \mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a}$ entonces

$$\frac{\hat{\varphi} - \varphi}{\hat{\sigma}_{\hat{\varphi}}} \sim t_{n-p}$$

Propiedades

Teorema: Supongamos que $\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\theta}, \sigma^2\mathbf{I})$, $\boldsymbol{\theta} \in \mathbb{R}^p$, $\text{rg}(\mathbf{X}) = p$ y definamos

$$\varphi = \mathbf{a}^T \boldsymbol{\theta}, \quad \hat{\varphi} = \mathbf{a}^T \hat{\boldsymbol{\theta}}$$

Entonces

- i) $\hat{\varphi} = \mathbf{a}^T \hat{\boldsymbol{\theta}}$ es un estimador insesgado para $\varphi = \mathbf{a}^T \boldsymbol{\theta}$ (Ejercicio)
- ii) $\text{VAR}(\hat{\varphi}) = \sigma^2 \mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a} = \sigma_{\hat{\varphi}}^2$ (Ejercicio)
- iii) $\hat{\varphi} \sim N(\varphi, \sigma^2 \mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a}) = N(\varphi, \sigma_{\hat{\varphi}}^2)$
- iv) Sea $\hat{\sigma}_{\hat{\varphi}}^2 = S^2 \mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a}$ entonces

$$\frac{\hat{\varphi} - \varphi}{\hat{\sigma}_{\hat{\varphi}}} \sim t_{n-p}$$

Rec: $\frac{n-p}{\sigma^2} S^2 \sim \chi^2_{n-p}$

Además $\frac{\hat{\varphi} - \varphi}{\sqrt{\sigma^2 \mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a}}} \sim N(0, 1)$ y $\hat{\varphi}$ y S^2 son independientes

luego,
$$\frac{\frac{\hat{\varphi} - \varphi}{\sqrt{\cancel{\sigma^2} \mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a}}}}{\sqrt{\frac{(n-p) \cancel{S^2}}{\cancel{\sigma^2} \cancel{n-p}}}} = \frac{\hat{\varphi} - \varphi}{\sqrt{S^2 \mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a}}} \sim t_{n-p} \quad \checkmark$$



Estimando cada componente

Estos resultados nos permiten deducir intervalos de confianza o tests para cada uno de los coeficientes del modelo lineal.

Como $\hat{\boldsymbol{\theta}} \sim N_p(\boldsymbol{\theta}, \sigma^2(\mathbf{X}^T\mathbf{X})^{-1})$, si $\mathbf{e}_i$ es el i -ésimo vector canónico, entonces

$$\hat{\theta}_i = \mathbf{e}_i^T \hat{\boldsymbol{\theta}} \sim N(\theta_i, \sigma^2 \mathbf{e}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{e}_i)$$

Si llamamos $\Sigma_{\hat{\boldsymbol{\theta}}} = \sigma^2 \mathbf{D}$, entonces

$$\hat{\theta}_i \sim N(\theta_i, \sigma^2 d_{ii})$$

siendo d_{ii} el i -ésimo elemento diagonal de $\mathbf{D} = (\mathbf{X}^T \mathbf{X})^{-1}$.

Estimando cada componente

Si para un i fijo quisiéramos testear

$$H_0 : \theta_i = 0 \quad \text{vs.} \quad H_1 : \theta_i \neq 0$$

tenemos que, bajo H_0 ,


$$\frac{\hat{\theta}_i}{\sqrt{d_{ii}}} \sim t_{n-p}$$

Por lo tanto, rechazaremos H_0 con nivel α si

$$\left| \frac{\hat{\theta}_i}{\sqrt{d_{ii}}} \right| > t_{n-p, \frac{\alpha}{2}}$$

Vayamos al ejemplo...

Ejemplo



Ejemplo

$$\text{lcavol}_i = \theta_0 + \theta_1 \text{age}_i + \theta_2 \text{lpsa}_i + \varepsilon_i$$

```
> salida <- lm(lcavol ~ age + lpsa)  
> summary(salida)
```

Handwritten note: -1 ↗ saca el intercept

Call:

```
lm(formula = lcavol ~ age + lpsa)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.23487	-0.62467	0.02114	0.54422	1.71757

Ejemplo


Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-1.50978	0.70670	-2.136	0.0352	*
age	0.01637	0.01112	1.473	0.1442	
lpsa	0.73201	0.07170	10.210	<2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.7992 on 94 degrees of freedom
Multiple R-squared: 0.5498, Adjusted R-squared: 0.5402
F-statistic: 57.4 on 2 and 94 DF, p-value: < 2.2e-16

Valores Predichos



Estimación en un nuevo $\mathbf{x}_0$

En un futuro valor $\mathbf{x}_0 = (x_{01}, \dots, x_{0p})^T$ independiente de los demás datos, ¿qué esperamos observar? $\mathbb{E}(y_0) = ?$

Estimación en un nuevo $\mathbf{x}_0$

En un futuro valor $\mathbf{x}_0 = (x_{o1}, \dots, x_{op})^T$ independiente de los demás datos, ¿qué esperamos observar? $\mathbb{E}(y_0) = ?$

$$\psi = \mathbb{E}(y_0) = \mathbf{x}_0^T \boldsymbol{\theta} \Rightarrow \hat{\psi} = \widehat{\mathbb{E}(y_0)} = \mathbf{x}_0^T \hat{\boldsymbol{\theta}}$$

Notemos que $\hat{\boldsymbol{\theta}}$ es insesgado, entonces el estimador propuesto será insesgado de $\mathbb{E}(y_0)$.

Estimación en un nuevo $\mathbf{x}_0$

También podríamos interesarnos realizar un IC para la esperanza de una nueva observación $\mathbf{x}_0$ independiente de las demás que cumpla el modelo

$$y_i = \theta_1 x_{i1} + \theta_2 x_{i2} + \cdots + \theta_p x_{ip} + \varepsilon_i$$

en $\mathbf{x}_0 = (x_{01}, \dots, x_{0p})^T$ donde $\varepsilon_i \sim N(0, \sigma^2)$ independientes.

Como nuestro estimador es $\mathbf{x}_0^T \hat{\boldsymbol{\theta}}$, tenemos que

$$\mathbf{x}_0^T \hat{\boldsymbol{\theta}} \sim N(\mathbf{x}_0^T \boldsymbol{\theta}, \sigma^2 \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0)$$

y es independiente de

$$\frac{(n-p)S^2}{\sigma^2} \sim \chi_{n-p}^2$$

por lo tanto,

$$T = \frac{\mathbf{x}_0^T \hat{\boldsymbol{\theta}} - \mathbf{x}_0^T \boldsymbol{\theta}}{S \sqrt{\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}} \sim t_{n-p}$$

Estimación en un nuevo $\mathbf{x}_0$

En consecuencia, tenemos el siguiente intervalo de confianza para el valor esperado de la respuesta en $\mathbf{x}_0$, es decir, para $\mathbf{x}_0^T \boldsymbol{\theta}$:

$$\mathbf{x}_0^T \hat{\boldsymbol{\theta}} \pm t_{n-p, \frac{\alpha}{2}} S \sqrt{\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$

de nivel exacto $1 - \alpha$.

Predicción en un nuevo $\mathbf{x}_0$

Podríamos estar interesados en la predicción de y_0 en una nueva observación que cumpla el modelo, y en un intervalo para ella, que llamaremos **intervalo de predicción** o sea $\mathbb{P}(A \leq y_0 \leq B) = 1 - \alpha$.

Predicción en un nuevo $\mathbf{x}_0$

Podríamos estar interesados en la predicción de y_0 en una nueva observación que cumpla el modelo, y en un intervalo para ella, que llamaremos **intervalo de predicción** o sea $\mathbb{P}(A \leq y_0 \leq B) = 1 - \alpha$.

Observemos que el predictor de y_0 es $\hat{y}_0 = \mathbf{x}_0^T \hat{\boldsymbol{\theta}}$. Aquí nos interesa el error de predicción. Notemos que

$$\mathbb{E}(\hat{y}_0 - y_0) = 0$$

¿Qué distribución tiene $\hat{y}_0 - y_0$?

Predicción en un nuevo $\mathbf{x}_0$

Tenemos que

$$\begin{aligned}\hat{y}_0 &\sim N(\mathbf{x}_0^T \boldsymbol{\theta}, \sigma^2 \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0) \\ y_0 &\sim N(\mathbf{x}_0^T \boldsymbol{\theta}, \sigma^2)\end{aligned}$$

y dado que y_0 es independiente de las restantes y_i 's con las que estimamos, entonces por la independencia entre estas dos normales queda que

$$\hat{y}_0 - y_0 \sim N(0, \sigma^2(1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0))$$

Predicción en un nuevo $\mathbf{x}_0$

Tenemos que

$$\begin{aligned}\hat{y}_0 &\sim N(\mathbf{x}_0^T \boldsymbol{\theta}, \sigma^2 \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0) \\ y_0 &\sim N(\mathbf{x}_0^T \boldsymbol{\theta}, \sigma^2)\end{aligned}$$

y dado que y_0 es independiente de las restantes y_i 's con las que estimamos, entonces por la independendencia entre estas dos normales queda que

$$\hat{y}_0 - y_0 \sim N(0, \sigma^2(1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0))$$

Por lo tanto, el intervalo de predicción de nivel $1 - \alpha$ estará dado por

$$\hat{y}_0 \pm t_{n-p, \frac{\alpha}{2}} S \sqrt{1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$

¿Cómo es la longitud del intervalo de predicción respecto de la del intervalo para la media?