

Capítulo 1: Estadística descriptiva, función de distribución empírica y estimación no paramétrica de la densidad

Primera parte: Estadística *descriptiva* o análisis exploratorio de datos

¿Qué es la estadística?

- La ciencia de recolectar, describir y analizar datos.
(de libro de Lock, "Unlocking the power of data")

Estadística Descriptiva

En Estadística Descriptiva se exploran los datos mediante:

- gráficos
- medidas de resumen.

La idea es **visualizar** en forma rápida las principales características del conjunto de datos.

QQ-plot

El qq-plot es un gráfico que nos sirve para comparar la distribución que genero un conjunto de datos (desconocida) a una distribución determinada F .

Para realizarlo los quantiles del conjunto de datos se grafican versus los quantiles teóricos de una distribución conocida F .

Si los datos provienen de la distribución F esperamos que el gráfico sea parecido a la recta $y = x$.

Ejemplo

Ejemplo 1.1

Hacer un QQ-plot de los siguientes datos. ¿Le parece que pueden provenir de una distribución normal?

$-0.61, 0.77, 0.16, -0.03, 0.01, -0.72, -1.48, 0.83, -0.90, 1.88$

```
x <- c(-0.61, 0.77, 0.16, -0.03, 0.01, -0.72, -1.48, 0.83,  
  #quantiles según nuestra definición  
normquantiles <- qnorm((1:10)/11)  
rbind(sort(x), normquantiles)  
plot(normquantiles, sort(x), xlab="Normal quantiles",  
      ylab="Sample quantiles")  
#quantiles, otra posible definición  
normquantiles2 <- qnorm(((1:10)-0.5)/10)  
rbind(sort(x), normquantiles2)  
plot(normquantiles2, sort(x), xlab="Normal quantiles",  
      ylab="Sample quantiles")  
  
qqnorm(x)
```

Estimación no paramétrica de la densidad

Estimación de la densidad

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$.

$X \sim F$ v.a. continua con densidad $f(x)$

Sabemos estimar F mediante $\hat{F}_n =$ la función de distribución empírica.

¿Cómo estimamos f ?

Queremos estimar f sin asumir una determinada forma:
solo asumimos que f es suave.

Histograma

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

- Sea I un intervalo que contiene a todos los datos y $\mathcal{C} = \{C_1, \dots, C_k\}$ una partición de I en intervalos o clases acotados (bins) y disjuntos. Es decir,

$$I = \cup_{j=1}^k C_j$$

- Para cada $x \in \mathbb{R}$

$$\hat{f}(x) = \begin{cases} \frac{\#\{X_i: X_i \in C_j\}}{n|C_j|} & \text{si } x \in C_j \\ 0 & \text{si } x \notin I \end{cases}$$

con $|C_j|$ longitud del intervalo C_j

Desventajas del histograma

- el estimador de la densidad depende del punto inicial de los bins:
- la densidad estimada no es suave, es *escalonada* y esto no es propio de la densidad sino de la herramienta de estimación

Idea 1: Enfoque Frecuentista


$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

$$\mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$$

Idea 2: Enfoque analítico

Si h es pequeño y f es continua.

$$\mathbb{P}(X \in [x-h, x+h]) = \int_{x-h}^{x+h} f(t) dt \approx 2hf(x)$$



Juntemos las dos ideas...

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

- $\mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$
- $\mathbb{P}(X \in [x - h, x + h]) \approx 2h f(x)$
- Entonces, podemos aproximar

$$2h f(x) \approx \mathbb{P}(X \in [x - h, x + h]) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{n}$$

$$f(x) \approx \frac{\#\{X_i \in [x - h, x + h]\}}{2h n}$$

Propuesta

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

$$\hat{f}_h(x) = \frac{\#\{X_i \in [x-h, x+h]\}}{2h n}$$

Podemos reescribir esta expresión como:

$$\hat{f}_h(x) = \frac{1}{2h n} \sum_{i=1}^n I_{[x-h, x+h]}(X_i)$$

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n \frac{1}{2} I_{[-1,1]} \left(\frac{x - X_i}{h} \right)$$

$$\text{si } K(t) = \frac{1}{2} I_{[-1,1]}(t) \quad \Rightarrow$$

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K \left(\frac{x - X_i}{h} \right)$$

Estimador de Rosenblatt-Parzen KDE

(KERNEL DENSITY ESTIMATION)

Definition 1.1 (Estimador de Rosenblatt-Parzen)

Dadas $X_1, \dots, X_n$, i.i.d.,

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)$$

donde $K \geq 0$ y $\int K(x)dx = 1$.

Ejercicio 1.2

a) $\bullet \hat{f}_h(x) \geq 0$

b) $\bullet \int \hat{f}_h(x)dx = 1$

EJ 1.2

$$a) \hat{f}_h(x) = \underbrace{\frac{1}{nh}}_{>0} \sum_{i=1}^n \underbrace{K\left(\frac{x-x_i}{h}\right)}_{\geq 0} \geq 0$$

$$\begin{aligned} b) \int \hat{f}_h(x) dx &= \int \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right) dx = \frac{1}{nh} \int \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right) dx \\ &= \frac{1}{nh} \int \sum_{i=1}^n h K(u) du \\ &= \frac{1}{nh} \int nh K(u) du \\ &= \int K(u) du = 1 \quad \square \end{aligned}$$

$u = \frac{x-x_i}{h}$
 $du = \frac{1}{h} dx$



Núcleo y ventana

$X_1, \dots, X_n$, i.i.d., donde $X_i \sim X$

Estimador de Rosenblatt-Parzen:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right), \text{ con } K(t) = \frac{1}{2}I_{[-1,1]}(t)$$

• K : núcleo • h : ventana




Tipos de núcleos


- Núcleo Rectangular: $K(t) = \frac{1}{2}I_{[-1,1]}(t)$
- Núcleo Triangular: $K(t) = (1 - |t|)I_{[-1,1]}(t)$
- Núcleo Gaussiano: $K(t) = \frac{1}{\sqrt{2\pi}}e^{-\frac{1}{2}t^2}$
- Núcleo Epanechnikov: $K(t) = \frac{3}{4}(1 - t^2)I_{[-1,1]}(t)$

Núcleos


Uniforme




Epanechnikov



Triangular





Normal



Estimadores de núcleos (Rosenblatt-Parzen)

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-X_i}{h}\right)$$

- K núcleo: * $K \geq 0$ y * $\int K(x)dx = 1$.
- h : ventana o parámetro de suavizado
- Notemos que $\hat{f}(x)$ depende de n , del núcleo K y de h



¿Cómo elegimos h ? Lo veremos más adelante

Ejemplo: Ingreso total familiar en Argentina

`https://campus.exactas.uba.ar/pluginfile.php/150710/mod\_resource/content/1/estimaciondensidad.pdf`

y

`https://glmconr2.shinyapps.io/app\_ker2/`

Capítulo 2. Estimación puntual

Métodos de Estimación

- **Métodos de Estimación:** métodos que nos permiten aproximar o inferir el valor de una característica desconocida de interés de una población a partir de una muestra aleatoria de dicha población.
- Existen dos abordajes: la **estimación puntual** y la **estimación por intervalos**.

Estimación puntual y por intervalos

- En **estimación puntual** buscamos dar un único valor para la característica desconocida.
- En **estimación por intervalos** buscamos dar un rango de valores donde esperamos que esté la característica desconocida con un cierto nivel de confianza.

¿Qué tenemos?

- **Muestra aleatoria:** $X_1, \dots, X_n$ variables aleatorias i.i.d. con distribución F : $X_i \sim F$
- **Característica de interés:** la esperanza o media, la varianza, la función de distribución acumulada, los cuantiles, la función de densidad, entre otras.

Ejemplo: Cuantiles

Ejemplo 2.1

- **Variable de interés:** $X \sim F$, donde $X =$ cantidad de anticuerpos IgG e IgM en un individuo 20 días después de la segunda dosis de vacuna contra COVID.
- **Características de interés:** $F^{-1}(p)$ cuantiles de la distribución.
- **Muestra aleatoria:** $X_1, \dots, X_n$ donde $X_i =$ cantidad de anticuerpos del i -ésimo paciente.
- **Datos:**

5.9, 6.3, 19.6, 7.2, ...

Ejemplo: El modelo de posición

Ejemplo 2.2

Un investigador desea determinar cuanto vale cierta magnitud y para ello realiza n mediciones.

Supone que

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde ϵ_i son los errores de medición y θ es el mesurando (es decir, la magnitud que se desea medir).

Supone además que ϵ_i son i.i.d. con $E(\epsilon_i) = 0$

- **Distribución de X_i :** $F = F_{X_i}$
- **Característica:** $\theta = \mathbb{E}_F(X_i) = \theta(F)$
- **Muestra aleatoria:** $X_1, \dots, X_n$ donde X_i = el valor de la i -ésima medición.
- **Datos:** 1, 1.05, 0.98, 0.1.02, 0.96

Estimación puntual: ¿Qué es un estimador puntual?

Definition 2.3

Dadas variables aleatorias independientes e idénticamente distribuídas $X_1, \dots, X_n$ con distribución F y $\theta = \theta(F)$ una característica de interés, llamamos **estimador puntual** de θ a una función medible de $X_1, \dots, X_n$.

- Por convención, un estimador de θ se denota $\hat{\theta}$ o $\hat{\theta}_n$.
- Se tiene que para cierta g medible:

$$\hat{\theta} = \hat{\theta}_n = g(X_1, \dots, X_n)$$

- **Nota:** Un estimador es una variable aleatoria.

Estimación puntual: ¿Qué es una estimación de θ ?

Definition 2.4

Una **estimación** de θ es el valor observado de un estimador $\hat{\theta}$ cuando éste es evaluado en un conjunto de datos $x_1, \dots, x_n$.

- Una estimación de θ es una realización de $\hat{\theta}$: $\hat{\theta}_{obs}$.

$$\hat{\theta}_{obs} = \hat{\theta}_{n\ obs} = g(x_1, \dots, x_n)$$

donde $x_1, \dots, x_n$ es una realización de $X_1, \dots, X_n$

Resumiendo

- **Muestra:** $(X_i)_{i \geq 1}$ i.i.d. $X_i \sim F$, $F \in \mathcal{F}$ familia de distribuciones posibles para nuestro problema
- **Objetivo:** inferir *algo relacionado* con el mecanismo que genera los datos:
 - $\mathbb{P}_F(X_1 \leq 20)$
 - F
 - $\mathbb{E}_F(X_1)$
 - $\mathbb{V}_F(X_1)$

Modelos Paramétricos y No Paramétricos

↗ EJ: K-NN, KDE, ARBOLES DE DECISIÓN

- **Modelos no paramétricos:** Asumimos que F pertenece a una familia de distribuciones que no puede ser indexadas por una cantidad finita de parámetros. *Estimamos $\mathcal{F}$*
 - $\mathcal{F} = \{\text{distribuciones continuas}\}$
 - $\mathcal{F} = \{\text{distribuciones con densidad simétrica alrededor de 0}\}$
 - $\mathcal{F} = \{\text{distribuciones con media y varianza finitas}\}$
- **Modelos paramétricos:** Asumimos que F pertenece a una familia de distribuciones que puede ser indexadas por una cantidad finita de parámetros.

Estimamos parámetro

Modelos Paramétricos

Casos Discretos

Asumimos que F pertenece a una familia de distribuciones que pueden ser indexadas por una cantidad finita de parámetros.

- **Bernoulli:** $X \sim \mathcal{B}(\theta)$, $p(x, \theta) = \theta^x (1 - \theta)^{1-x}$, $x = 0, 1$,
 $\theta \in \Theta = (0, 1)$.
- **Poisson:** $X \sim \mathcal{P}(\theta)$, $p(x, \theta) = e^{-\theta} \theta^x / x!$, $x \in \mathbb{N} \cup \{0\}$
 $\theta \in R_{>0}$

$$\mathcal{M} = \{p(\cdot, \theta) , \theta \in \Theta\} .$$

Modelos Paramétricos

Casos Continuos

- **Uniforme:** $X \sim \mathcal{U}(0, \theta)$, $f(x, \theta) = \frac{1}{\theta} \mathcal{I}_{[0, \theta]}(x)$, $\theta \in \Theta = \mathbb{R}_{>0}$.
- **Normal:** $X \sim \mathcal{N}(\mu, \sigma^2)$, $f(x, \theta) = (2\pi\sigma^2)^{-1/2} e^{-(x-\mu)^2/2\sigma^2}$,
 $\theta = (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_{>0}$
- **Exponencial:** $X \sim \mathcal{E}(\theta)$, $f(x, \theta) = \theta e^{-\theta x} \mathcal{I}_{[0, \infty)}(x)$,
 $\theta \in \Theta = \mathbb{R}_{>0}$.
- **Gamma:** $X \sim \Gamma(\alpha, \lambda)$,
 $f(x, \alpha, \lambda) = \frac{1}{\Gamma(\alpha)} \lambda^\alpha x^{\alpha-1} e^{-\lambda x} \mathcal{I}_{[0, \infty)}(x)$,
 $\theta = (\alpha, \lambda) \in \mathbb{R}_{>0} \times \mathbb{R}_{>0}$.

$$\mathcal{M} = \{f(\cdot, \theta), \theta \in \Theta\}.$$

Algunas aplicaciones

- **Bernoulli**: surge naturalmente en caso de variables binarias.
- **Poisson**: suele usarse para modelar procesos de conteo
- **Normal**: Modelo de Posición: $X_i = \theta + \epsilon_i$; suele asumirse que los errores tienen distribución normal con $\mathbb{E}(\epsilon_i) = 0$.
- **Gamma**: El tiempo de hospitalización de un paciente suele modelarse con una distribución Gamma $\Gamma(\alpha, \lambda)$
- **Weibull**: El ingreso anual familiar en algunos países se modela con una distribución Weibull
$$f(x, \alpha, \beta) = (\alpha/\beta)(x/\beta)^{\alpha-1} \exp(-(x/\beta)^\alpha).$$

Por ahora abordaremos el enfoque paramétrico.

$\mathcal{F}$ es una familia paramétrica $\mathcal{F} = \{f(\cdot, \theta), \theta \in \Theta\}$

- Una $F \sim \mathcal{F}$ es de la forma $F(\cdot, \theta)$, por lo tanto para identificarla solo necesitamos conocer θ .
- En este caso, θ está relacionada con características de interés de la distribución tales como esperanza o varianza:
 - Bernoulli: $X \sim \mathcal{B}(\theta), \mathbb{E}_{F_\theta}(X) = \theta$
 - Gamma: $X \sim \Gamma(\alpha, \lambda), \theta = (\alpha, \lambda), E_{F_\theta}(X) = \alpha/\lambda$

Métodos de estimación en modelos paramétricos

Veremos en principio dos métodos:

- Método de los Momentos
- Método de Máxima Verosimilitud

Método de los Momentos: ¿Qué son los momentos?

Definition 2.5

Momentos Poblacionales: Sea X una v.a. Llamamos momento (poblacional) de orden k o k -ésimo momento de X , si la esperanza existe, a

$$\mu_k = \mathbb{E}(X^k)$$

Definition 2.6

Momentos Muestrales: Sea $X_1, \dots, X_n$ una muestra aleatoria. Llamamos momento muestral de orden k o k -ésimo momento muestral de $X_1, \dots, X_n$ a

$$\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

Motivación para los Momentos

- **k -ésimo momento** $\mu_k = \mathbb{E}_F[X^k]$, $X \sim F$

$$\mu_1 = \mathbb{E}_F[X]$$

$$\mu_2 = \mathbb{E}_F[X^2]$$

- **k -ésimo momento muestral** $\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$, $X_1, \dots, X_n$, i.i.d., $X_i \sim F$.

Por la LGN, sabemos que si las esperanzas existen

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu_1 = \mathbb{E}_F[X]$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} \mu_2 = \mathbb{E}_F[X^2]$$

.....

$$\frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k = \mathbb{E}_F[X^k]$$

Ejemplos: Normal

Supongamos que $X_1, X_2, \dots, X_n$ i.i.d. $X_i \sim \mathcal{N}(\mu, \sigma_o^2)$, σ_o^2 conocida. En este caso $\theta = \mu = \mu_1$.

- Utilizando la LGN, tenemos que

$\bar{X}_n \xrightarrow{P} \mu$, cuando $X_i \sim \mathcal{N}(\mu, \sigma_o^2)$ cualquiera sea $\mu \in \mathbb{R}$.

- estimamos a μ por $\hat{\mu} = \bar{X}_n$

Ejemplos: Uniforme

Supongamos que $X_1, X_2, \dots, X_n$ i.i.d., $X_i \sim \mathcal{U}(0, \theta)$.

Sabemos que $\mu_1 = \mathbb{E}_\theta(X_1) = \frac{\theta}{2}$.

- Utilizando la LGN, tenemos que

$$\bar{X}_n \xrightarrow{P} \mu_1 = \frac{\theta}{2} \text{ cualquiera sea } \theta \in \Theta = \mathbb{R}$$

Para hallar el estimador de momentos de θ , proponemos

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{\hat{\theta}}{2}$$

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{\hat{\theta}}{2} \Rightarrow \hat{\theta} = \frac{2}{n} \sum_{i=1}^n X_i = 2\bar{X}_n$$

$$\hat{\theta} = 2\bar{X}_n$$

Método de los Momentos

Definition 2.7

Sea $X_1, X_2, \dots, X_n$ una m.a. de una distribución con función de distribución F_θ .

- el estimador de momentos de θ basado en el primer momento es el valor $\hat{\theta}$ tal que

$$E_{\hat{\theta}}(X) = \hat{\mu}_1 = \overline{X}$$

- el estimador de momentos de θ basado en el k -ésimo momento es el valor $\hat{\theta}$ tal que

$$E_{\hat{\theta}}(X^k) = \hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k.$$

Ejemplos: Exponencial

Supongamos que $X_1 \dots X_n$ siguen una distribución $\mathcal{E}(\theta)$. ¿Cómo estimamos a θ a partir de una muestra aleatoria $X_1 \dots X_n$?

$$X_1, X_2, \dots, X_n \sim \mathcal{E}(\theta), \text{i.i.d.}$$

En este caso $\mu_1 = \mathbb{E}_\theta(X_1) = \frac{1}{\theta}$.

Para hallar el estimador de momentos de θ , debemos despejar $\hat{\theta}$ de

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{\hat{\theta}}$$

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{\hat{\theta}} \Rightarrow \hat{\theta} = \frac{1}{\bar{X}}$$

¿Qué momentos usamos?

Ejercicio 2.8

Explorar el caso $X_1, X_2, \dots, X_n$ i.i.d., $X_i \sim \mathcal{U}(-\theta, \theta)$.

- *¿Sirve el primer momento? ¿Da información sobre θ ?*
- *¿Qué obtenemos si usamos el segundo momento?*

Ejemplos: Estimación de μ y σ^2 en la normal

Ejemplo 2.9

Supongamos que tenemos una m. a. $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$.

Sabemos que $\mathbb{E}_{\mu, \sigma^2}(X_i) = \mu$ y $\mathbb{E}_{\mu, \sigma^2}(X_i^2) = \mu^2 + \sigma^2$.

Para encontrar el estimador de momentos de μ y σ^2 resolvemos el sistema

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n X_i &= \hat{\mu} \\ \frac{1}{n} \sum_{i=1}^n X_i^2 &= \hat{\mu}^2 + \hat{\sigma}^2\end{aligned}$$

Despejemos de aquí a $\hat{\mu}$ y $\hat{\sigma}^2$

Ejemplos: Estimación de μ y σ^2 en la normal

Ejemplo 2.9 (Continuación)

$$\begin{cases} \frac{1}{n} \sum_{i=1}^n X_i = \hat{\mu} \\ \frac{1}{n} \sum_{i=1}^n X_i^2 = \hat{\mu}^2 + \hat{\sigma}^2 \end{cases}$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2$$

Puede verificarse fácilmente que: $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$

Ejercicio 2.10

si $X_1, \dots, X_n$, i.i.d., $X_i \sim \Gamma(\alpha, \lambda)$, ¿cómo resultan los estimadores de momentos de α y λ ?

$$\text{EJ: } E_{\alpha, \lambda}(X_1) = \frac{\alpha}{\lambda} \quad V_{\alpha, \lambda}(X_1) = \frac{\alpha}{\lambda^2}$$

$$\begin{cases} \frac{1}{n} \sum_{i=1}^n X_i = \frac{\hat{\alpha}}{\hat{\lambda}} \\ \frac{1}{n} \sum_{i=1}^n X_i^2 = \left(\frac{\hat{\alpha}}{\hat{\lambda}} \right)^2 + \frac{\hat{\alpha}}{\hat{\lambda}^2} \end{cases}$$

$$\Rightarrow \hat{\alpha} = \hat{\lambda} \bar{X}_n \Rightarrow \frac{1}{n} \sum_{i=1}^n X_i^2 = \frac{(\hat{\lambda} \bar{X}_n)^2 + \hat{\lambda} \bar{X}_n}{\hat{\lambda}^2} = \bar{X}_n^2 + \frac{\bar{X}_n}{\hat{\lambda}} \Rightarrow \hat{\lambda} = \frac{\bar{X}_n}{\bar{X}_n^2 - \bar{X}_n^2}$$

$$\Rightarrow \hat{\alpha} = \frac{\bar{X}_n^2}{\bar{X}_n^2 - \bar{X}_n^2}$$

Estimador de momentos en modelos no paramétricos

Ejemplo 2.11

$X_1, \dots, X_n$ v.a. i.i.d. $X_i \sim F$

- $\theta = (\mu, \sigma^2)$. Tenemos que

$$\begin{aligned}\mathbb{E}_F[X] &= \mu \\ \mathbb{E}_F[X^2] &= \sigma^2 + \mu^2\end{aligned}$$

- Nos queda el mismo sistema que en el caso normal.
- $(\hat{\mu}, \hat{\sigma}^2)$ es solución de

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i \quad \hat{\mu}^2 + \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2$$

- Despejando, obtenemos igual que en el caso normal

$$\hat{\mu} = \bar{X}_n \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Estimación por máxima de verosimilitud

Definition 2.12

Sea $X_1, \dots, X_n$ una muestra aleatoria de una densidad o f.p.p. $f(x, \theta)$ y $x_1 \dots x_n$ una realización de la muestra. El valor de θ que maximiza la verosimilitud, se llama una estimación de θ por máxima verosimilitud:

$$\hat{\theta}_{obs} = \operatorname{argmax}_{\theta} \prod_{i=1}^n f(x_i, \theta) = \operatorname{argmax}_{\theta} \sum_{i=1}^n \log f(x_i, \theta)$$

Estimador de máxima de verosimilitud

Como cada vez que se observan los datos $x_1, \dots, x_n$ tenemos una estimación. Así queda definido un estimador:

Definition 2.13

Sea $X_1, \dots, X_n$ una muestra aleatoria de una densidad o f.p.p. $f(x, \theta)$, entonces llamamos estimador de máxima verosimilitud (EMV) de θ a

$$\hat{\theta} = \operatorname{argmax}_{\theta} \prod_{i=1}^n f(X_i, \theta) = \operatorname{argmax}_{\theta} \sum_{i=1}^n \log f(X_i, \theta)$$

Ejemplos

Ejemplo 2.14

Sean $X_1, \dots, X_n$ v.a. i.i.d. $X_i \sim \mathcal{P}(\theta), \theta > 0$. Hallar el EMV de θ

Ejemplo 2.15

Sean $X_1, \dots, X_n$ v.a. i.i.d. $X_i \sim \mathcal{E}(\theta), \theta > 0$. Hallar el EMV de θ

Ejemplo 2.16

Sean $X_1, \dots, X_n$ v.a. i.i.d. $X_i \sim \mathcal{U}(0, \theta), \theta > 0$. Hallar el EMV de θ

2.14: $X_i \sim \mathcal{P}(\theta), \theta > 0$

$$L(\theta) = \prod_{i=1}^n \frac{\theta^{x_i}}{x_i!} e^{-\theta} = \frac{\theta^{\sum x_i}}{\prod x_i!} e^{-n\theta}$$

$$l(\theta) = \sum X_i \log \theta - \sum \log X_i! - n\theta$$

$$\frac{\partial}{\partial \theta} l(\theta) = \frac{\sum X_i}{\theta} - n = 0 \iff \boxed{\hat{\theta} = \bar{X}_n}$$

$$\frac{\partial^2}{\partial \theta^2} l(\theta) = -\frac{\sum X_i}{\theta^2} < 0 \quad \forall \theta > 0 \implies l(\theta) \text{ concave} \implies \hat{\theta} \text{ es m\u00e1x global.}$$

2.15: $X_i \sim \mathcal{E}(\theta), \theta > 0$

$$L(\theta) = \prod_{i=1}^n \theta e^{-\theta X_i} \mathbb{I}_{(0,+\infty)}(X_i) = \theta^n e^{-\theta \sum X_i} \underbrace{\mathbb{I}_{\{X_{(n)} > 0\}}}_{=1 \text{ c.s. pues } P(X_i > 0) = 1 \text{ c.s. } \forall i}$$

$$l(\theta) = n \log \theta - \theta \sum X_i$$

$$\frac{\partial}{\partial \theta} l(\theta) = \frac{n}{\theta} - \sum X_i = 0 \iff \hat{\theta} = \frac{1}{\bar{X}_n}$$

$$\frac{\partial^2}{\partial \theta^2} l(\theta) = -\frac{n}{\theta^2} < 0 \quad \forall \theta > 0 \implies \hat{\theta} \text{ m\u00e1x global}$$

2.16: $X_i \sim \mathcal{U}(0, \theta), \theta > 0$

$$L(\theta) = \prod \frac{X_i}{\theta} \mathbb{I}_{(0, \theta)}(X_i) = \theta^{-n} \cdot \prod X_i \cdot \mathbb{I}_{(\max X_i, +\infty)}(\theta)$$

Para $n \in \mathbb{N}$ fijo, $L(\theta)$ es ^{estrictamente} decreciente en θ , por lo tanto alcanza el m\u00e1ximo en el \u00ednfimo del soporte.

$$\hat{\theta} = \inf_{0 \leq i \leq n} (\max X_i, +\infty) = X_{(n)}$$

Ejemplo

Ejemplo 2.17

Sean $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ iid. Hallar el EMV de (μ, σ^2)

Resolución: Pizarrón

Ver Libro *Statistical Inference* de Casella & Berger Ej 7.2.11



Example 7.2.11 (Normal MLEs, μ and σ unknown) Let $X_1, \dots, X_n$ be iid $n(\theta, \sigma^2)$, with both θ and σ^2 unknown. Then

$$L(\theta, \sigma^2 | \mathbf{x}) = \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-(1/2)\sum_{i=1}^n (x_i - \theta)^2 / \sigma^2}$$

and

$$\log L(\theta, \sigma^2 | \mathbf{x}) = -\frac{n}{2} \log 2\pi - \frac{n}{2} \log \sigma^2 - \frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 / \sigma^2.$$

The partial derivatives, with respect to θ and σ^2 , are

$$\frac{\partial}{\partial \theta} \log L(\theta, \sigma^2 | \mathbf{x}) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \theta)$$

and

$$\frac{\partial}{\partial \sigma^2} \log L(\theta, \sigma^2 | \mathbf{x}) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \theta)^2.$$

Setting these partial derivatives equal to 0 and solving yields the solution $\hat{\theta} = \bar{x}$, $\hat{\sigma}^2 = n^{-1} \sum_{i=1}^n (x_i - \bar{x})^2$. To verify that this solution is, in fact, a global maximum, recall first that if $\theta \neq \bar{x}$, then $\sum (x_i - \theta)^2 > \sum (x_i - \bar{x})^2$. Hence, for any value of σ^2 ,

$$(7.2.6) \quad \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-(1/2)\sum_{i=1}^n (x_i - \bar{x})^2 / \sigma^2} \geq \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-(1/2)\sum_{i=1}^n (x_i - \theta)^2 / \sigma^2}.$$

Therefore, verifying that we have found the maximum likelihood estimators is reduced to a one-dimensional problem, verifying that $(\sigma^2)^{-n/2} \exp(-\frac{1}{2} \sum (x_i - \bar{x})^2 / \sigma^2)$ achieves its global maximum at $\sigma^2 = n^{-1} \sum (x_i - \bar{x})^2$. This is straightforward to do using univariate calculus and, in fact, the estimators $(\bar{X}, n^{-1} \sum (X_i - \bar{X})^2)$ are the MLEs.

We note that the left side of the inequality in (7.2.6) is known as the *profile likelihood* for σ^2 . See Miscellanea 7.5.5. ||

Propiedad de invarianza

Teorema 2.18

Si $\hat{\theta}$ es el único EMV de θ y $h : \Theta \rightarrow \Theta$ es biyectiva, entonces $\hat{\lambda} = h(\hat{\theta})$ es el EMV de λ .

Demostración.

Pizarrón



D/ Sea $X_1, \dots, X_n$ una muestra aleatoria con función de verosimilitud $L(\theta)$.

Por hipótesis,

$$L(\hat{\theta}) \geq L(\theta) \quad \forall \theta \in \Theta$$

Queremos EMV de $\lambda = h(\theta)$. Como h es biyectiva, existe una función inversa $\theta = h^{-1}(\lambda)$.

Redefinimos la función de máxima verosimilitud:

$$M(\lambda) = L(h^{-1}(\lambda))$$

Buscamos $\hat{\lambda}$ que maximiza $M(\lambda)$.

Evaluamos la función en $\hat{\lambda} = h(\hat{\theta})$:

$$M(\hat{\lambda}) = L(h^{-1}(h(\hat{\theta}))) = L(\hat{\theta})$$

Para cualquier otro valor $\lambda \in \Lambda$, por biyectividad, $\exists \theta \in \Theta$ tal $\theta = h^{-1}(\lambda)$. Por hip,

$$L(\hat{\theta}) \geq L(h^{-1}(\lambda)) \quad \forall \lambda \in \Lambda$$

$$\Rightarrow M(\hat{\lambda}) \geq M(\lambda) \quad \forall \lambda \in \Lambda$$

$$\Rightarrow \hat{\lambda} = h(\hat{\theta}) \text{ es el EMV de } \lambda = h(\theta).$$



Ejemplo 2.19

Sean $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ iid. Hallar el EMV de (μ, σ^2) , entonces

1. $\bar{X}^3$ es el EMV de μ^3
2. $\sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{n}}$ es el EMV de σ

Estimador de mínimos cuadrados (MLS)

Ejemplo 2.20

Consideremos el modelo de posición

$X_1, \dots, X_n$ son v.a. que iid satisfacen

$$X_i = \theta + \epsilon_i, \quad i = 1, \dots, n$$

donde ϵ_i son i.i.d. con $E(\epsilon_i) = 0$ y θ es el parámetro desconocido que se desea estimar. Es decir, se supone que la densidad de X_i pertenece a la siguiente familia

$\mathcal{F} = \{ \text{distribuciones con esperanza } \theta \}$

Vimos que el estimador de momentos de θ es $\bar{X}$.

Otra forma de llegar a este estimador es calcular el estimador de mínimos cuadrados:

$$\hat{\theta} = \operatorname{argmin}_{\theta} \sum_{i=1}^n (X_i - \theta)^2$$

Estimador de mínimos cuadrados

Definition 2.21

Sea $X_1, \dots, X_n$ una muestra aleatoria que sigue el modelo de posición $X_i = \theta_0 + \epsilon_i$ con $\mathbb{E}(\epsilon_i) = 0$. El estimador de mínimos cuadrados de θ_0 se define como

$$\hat{\theta} = \operatorname{argmin}_{\theta} \sum_{i=1}^n (X_i - \theta)^2.$$

Proposición 2.22

Sea $X_1, \dots, X_n$ una muestra aleatoria con esperanza finita θ_0 . El estimador de mínimos cuadrados de θ_0 es $\bar{X}$.

Proof.



D/QVA $\hat{\theta} = \operatorname{argmin}_{\theta} \sum_{i=1}^n (x_i - \theta)^2 = \bar{X}$

Definimos

$$S(\theta) = \sum_{i=1}^n (x_i - \theta)^2$$

Para hallar mínimos, derivamos

$$\frac{dS}{d\theta}(\theta) = -2 \sum_{i=1}^n (x_i - \theta)$$

Igualamos a 0 para hallar valor crítico $\hat{\theta}$:

$$-2 \sum (x_i - \hat{\theta}) = 0$$

$$\sum x_i = n \hat{\theta}$$

$$\bar{X} = \hat{\theta}$$

Calculamos segunda derivada para verificar que es mínimo

$$\frac{d^2 S}{d\theta^2}(\theta) = -2 \sum_{i=1}^n (-1) = 2n > 0 \Rightarrow \bar{X} \text{ es mínimo global} *$$



***RECORDAR:** Una función polinómica de grado K puede tener hasta $K-1$ puntos críticos.

Estimador de mínimos desviaciones absolutas (LAD)

Definition 2.23

Sea $X_1, \dots, X_n$ una muestra aleatoria que sigue el modelo de posición $X_i = \theta_0 + \epsilon_i$ donde ϵ_i tiene una distribución simétrica alrededor de 0. El estimador de mínimas desviaciones absolutas de θ_0 se define como

$$\hat{\theta} = \operatorname{argmin}_{\theta} \sum_{i=1}^n |X_i - \theta|.$$

Proposición 2.24

Sea $X_1, \dots, X_n$ una muestra aleatoria que sigue el modelo de posición $X_i = \theta_0 + \epsilon_i$ donde ϵ_i tiene una distribución simétrica alrededor de 0. El estimador de mínimas desviaciones absolutas de θ_0 es la mediana muestral de $X_1 \dots X_n$.

DEMO: NO LA VEMOS

M-estimadores

Definition 2.25

Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución $F(., \theta_0)$.
Un M-estimador de θ_0 es un estimador definido como

$$\hat{\theta} = \operatorname{argmin}_{\theta} \sum_{i=1}^n \rho(X_i, \theta)$$

Observación 2.26

Los estimadores de mínimos cuadrados, de mínimas desviaciones absolutas y de máxima verosimilitud son M-estimadores.

- $p(x_i, \theta) = p(x_i - \theta) = (x_i - \theta)^2 \rightarrow \text{MLS}$

$$|| = |x_i - \theta| \rightarrow \text{LAD}$$

- De EMV, $\hat{\theta} = \operatorname{argmax}_{\theta} \prod_{i=1}^n f(x_i, \theta)$

que equivale à :

$$\hat{\theta} = \underset{\theta}{\operatorname{argmin}} \sum -\log(f(x_i, \theta))$$

Entonces

$$\rho(x_i, \theta) = -\log(f(x_i, \theta))$$