

Bootstrap

El Bootstrap, introducido por Bradley Efron en 1979, refiere a la idea de aproximar la precisión de un estimador vía simulación. Es una técnica que ha tenido mucho impacto y le ha dado a Efron gran reconocimiento académico.

Hay distintas maneras de hacerlo: hay variantes del bootstrap, por eso es más una colección de métodos que una única técnica.

Estas diapositivas están basados en el
Capítulo 8 del libro de Wasserman

Revisitemos “La empírica”

X es una variable aleatoria con distribución acumulada $F : \mathbb{R} \rightarrow \mathbb{R}$ definida por

$$F(x) = P(X \leq x)$$

La empírica

Dada una muestra aleatoria $X_1, \dots, X_n$ de la distribución F , su función de distribución empírica $\hat{F}_n$ se define como

$$\hat{F}_n(x) = \frac{\sum_{i=1}^n I(X_i \leq x)}{n}$$

- ▶ $\hat{F}_n(x)$ es una función aleatoria
- ▶ Para cada realización $x_1, \dots, x_n$ de la muestra $\hat{F}_{n\,obs}(x)$ es una fda que asigna probabilidad $1/n$ a cada x_i .

Para cada x fijo

- ▶ $\mathbb{E}(\hat{F}_n(x)) = ?$ ¿Es insesgado para $F(x)$?
- ▶ $\mathbb{V}(\hat{F}_n(x)) = ?$
- ▶ ¿Es $\hat{F}_n(x)$ un estimador consistente de $F(x)$?

Para cada x fijo

- ▶ $\mathbb{E}(\hat{F}_n(x)) = ?$ ¿Es insesgado para $F(x)$?
- ▶ $\mathbb{V}(\hat{F}_n(x)) = ?$
- ▶ ¿Es $\hat{F}_n(x)$ un estimador consistente de $F(x)$?

Teorema (Glivenko - Cantelli) Sea $X_1, \dots, X_n \sim F$. Entonces

$$\sup_x \left| \hat{F}_n(x) - F(x) \right| \xrightarrow{c.s.} 0$$

Funcionales estadísticos

Un funcional estadístico es una función de F , $T(F)$

Ejemplos

- ▶ La esperanza: $F \mapsto \mathbb{E}_F(X) = \int x dF(x)$
- ▶ La varianza: $F \mapsto \mathbb{V}_F(X) = \int (x - \int x dF(x))^2 dF(x)$
- ▶ La mediana: $F \mapsto F^{-1}(1/2)$

Si T es un funcional continuo, por Teorema de Glivenko-Cantelli,

$$|T(\hat{F}_n) - T(F)| \Rightarrow T \text{ es consistente}$$

El estimador plug-in

Consideremos $T = T(F)$.

El estimador plug-in de $T = T(F)$ se define como

$$\hat{T} = T(\hat{F}_n)$$

Ejemplo: estimador plug-in de la esperanza

Sea $X_1, \dots, X_n \sim F$ y $T = T(F) = \mathbb{E}_F(X)$ entonces el estimador plug in de T es

$$\hat{T} = \mathbb{E}_{\hat{F}_n}(X).$$

Veamos que

$$\mathbb{E}_{\hat{F}_n}(X) = \overline{X}$$

Estimador plug-in de los cuantiles

Supongamos que F es continua y estrictamente creciente, el p -ésimo cuantil se define como

$T(F) = F^{-1}(p)$. Su estimador plug-in es

$$\hat{T} = T(\hat{F}_n) = \hat{F}_n^{-1}(p)$$

¡¡Pero cuidado!!! $\hat{F}_n$ no es inversible

Definimos la función cuantil

$$F^{-1}(p) = \inf\{x : F(x) \geq p\}$$

$\hat{F}_n^{-1}(p)$ se llama p -ésimo cuantil muestral.

Ejemplo: Ingreso total familiar en Argentina en 2023

(Fuente: INDEC, [www.indec.gob.ar])

```
ingresos <- read.table("ingresos_argentina_2023.txt")
ingresos <- unlist(ingresos)
ingresos <- ingresos[ingresos>0]
length(ingresos)
```


```
## [1] 21334
```

Estimamos la fda a mano

```
f_acu <- function(x, datos){
  mean(datos <= x)
}
```

```
xx <- ingresos
yy <- 0
for(i in 1:length(xx)){
  yy[i] <- f_acu(xx[i], ingresos)
}
plot(xx,yy, cex = 0.2)
```

Función de distribución empírica del ITF en Argentina en 2023



Estimar el cuantil 0.5 del ingreso total familiar en Argentina en 2023

Mediana

```
quantile(ingresos, 0.5)
```

```
##      50%
```

```
## 240000
```

Media

```
mean(ingresos)
```

```
## [1] 308205.3
```

Ejemplo: Tiempo de Vida de Lámparas

Se quiere estudiar el tiempo de vida de ciertas lámparas. Para ello se observa en 30 de ellas el tiempo de vida en días:

```
tiempos
```


```
##
```

```
##  3.5  4.5  3.1  4.2  2.4  2.8  3.0  3.8  2.5  2.7
```

```
##  2.8  2.6  3.4  2.5  3.6  2.6  3.1  4.0  2.3  3.5
```

```
##  4.1  2.9  2.6  2.0  3.0  2.5  2.9  3.1  2.3  2.8
```

```
boxplot(tiempos)
```



Nos interesa la mediana poblacional: m

¿Cuál es el tiempo de vida mediano de las lámparas?

Podríamos estimarlo a) asumiendo una distribución b) mediante la mediana muestral.

Caso a): si la distribución fuera $\mathcal{E}(\lambda)$, entonces

$$F(m) = 0.5$$

$$1 - \exp(-\lambda m) = 0.5 \text{ entonces } m = -\log(0.5)/\lambda$$

Nos interesa la mediana poblacional

¿Cuál es el tiempo de vida mediano de las lámparas?

Podríamos estimarlo a) asumiendo una distribución b) mediante la mediana muestral.

En el caso b), ¿cuán preciso es el estimador? ¿Cómo estimamos su error estándar?

¿Cómo calculamos un intervalo de confianza para la mediana?

En general, para responder estas preguntas tenemos distintas posibilidades:

- 1 - Conocemos algo de F , pero $\hat{T}_n$ es una función complicada de $X_1, \dots, X_n$ y es difícil hallar su distribución o su desvío estándar.
- 2 - No conocemos nada de F

Pensemos en la mediana poblacional

- a) Estimar la mediana poblacional asumiendo un modelo paramétrico.
- b) Estimar la mediana poblacional sin asumir ningún modelo.
- ▶ ¿Cómo estimar el error standard de un estimador?
BOOTSTRAP!!



Podemos hacer bootstrap de distintas maneras.

BOOTSTRAP → ESTIMAR LA DISTRIBUCIÓN
DE UN ESTIMADOR

BOOTSTRAP

	PARAMETRICO	NO PARAMETRICO
SUPOESTOS	ASUME DIST	NO ASUME DIST
DATOS	MUESTRA RANDOM DEL MODELO (dist)	MUESTRA CON REPOSICIÓN DE LA MUESTRA ORIGINAL
PRECISIÓN	MAYOR (SI EL MODELO ES CORRECTO)	MENOR (PERO MÁS ROBUSTO) (MAYOR TAMAÑO DE MUESTRA, MAYOR PRECISIÓN)
CUANDO USARLO	ESTAS SEGURO DE QUE TUS DATOS SIGUEN UNA DIST. ESPECIFICA	DATOS SIGUEN UNA DIST RARA (DOS PICOS & MUCHA ASIMETRÍA)

Escenario simulación: generamos tantos datos con distribución F como queremos. . . .

- ▶ Nos interesa $T = T(F)$, estimamos con $\hat{T}_n$ a partir de una muestra de tamaño n .
- ▶ ¿Cómo hallamos la distribución de $\hat{T}_n$?

Escenario simulación: generamos tantos datos con distribución F como queremos. . . .

- ▶ Nos interesa $T = T(F)$, estimamos con $\hat{T}_n$ a partir de una muestra de tamaño n .
- ▶ ¿Cómo hallamos la distribución de $\hat{T}_n$?

1 - Generamos muchos (digamos $B = 1000$) conjuntos de datos de tamaño muestral n . Para cada conjunto de datos calculamos el valor de $\hat{T}_n^*$.

2 - La distribución empírica de los valores resultantes:

$$\hat{T}_{n,1}^*, \hat{T}_{n,2}^*, \dots, \hat{T}_{n,B}^*$$

es una aproximación a la distribución de $\hat{T}_n$.

Escenario real: sólo tenemos $X_1, \dots, X_n$ con distribución F desconocida

Alternativa 1: $F = F(\theta)$ *Bootstrap paramétrico*

- Tenemos una muestra: $X_1, \dots, X_n$, $X_i \sim F(\theta)$, podemos utilizar el **método bootstrap paramétrico**

**** Bootstrap paramétrico ****

- 1 - Estimar el parámetro $\hat{\theta}_n$ y $\hat{T}_n$ usando la muestra.
- 2 - Generar B remuestras de tamaño n de $F(\hat{\theta}_n)$. Para cada una de ellas calcular el estimador de interés: $\hat{T}_n^*$.
- 3 - La distribución empírica de los valores resultantes: $\hat{T}_{n,1}^*, \hat{T}_{n,2}^*, \dots, \hat{T}_{n,B}^*$ es una aproximación a la distribución de $\hat{T}_n$.

En nuestro ejemplo: lámparas

- ▶ Nos interesa la mediana poblacional
- ▶ Tenemos una muestra: $X_1, \dots, X_n$
- ▶ Asumimos un modelo paramétrico: $X_i \sim \Gamma(\alpha, \lambda)$.

Bootstrap paramétrico

1 - Estimar los parámetros usando la muestra: $\rightarrow \hat{\alpha}_n$ y $\hat{\lambda}_n$.

2 - Generar B remuestras de tamaño n de $F(\hat{\alpha}_n, \hat{\lambda}_n)$:

$\mathbf{X}^* = X_1^*, \dots, X_n^*$. Para cada una de ellas estimar la mediana con el método que estemos usando: $\hat{T}_n^*$.

3 - La distribución empírica de los valores resultantes:

$\hat{T}_{n,1}^*, \hat{T}_{n,2}^*, \dots, \hat{T}_{n,B}^*$ es una aproximación a la distribución de $\hat{T}_n$.

Ejemplo: bootstrap paramétrico.

Asumo $X_i \sim \Gamma(\alpha, \lambda)$.

```
library(MASS)
B <- 1000; estmed <- 0
est.param <- fitdistr(tiempos, densfun = "gamma")$estimate
est.param

##      shape      rate
## 25.661823  8.450657
#### mediana
qgamma(0.5, shape = est.param[1], rate = est.param[2])

## [1] 2.997314
n <- length(tiempos)
for(i in 1:B){
  xboot <- rgamma(n, shape = est.param[1], rate = est.param[2])
  estboot <- fitdistr(xboot, densfun = "gamma")
  estshape <- estboot$estimate[1]
  estrate <- estboot$estimate[2]
  estmed[i] <- qgamma(0.5, shape = estshape,
                     rate = estrate)
}
head(estmed)

## [1] 2.998185 2.990779 3.068146 3.096810 2.936587 2.941222
```

Podríamos aproximar el desvío estándar calculando:

$$\hat{\text{se}}_{\text{boot}} = \sqrt{\frac{1}{B} \sum_{b=1}^B \left(\hat{T}_{n,b}^* - \frac{1}{B} \sum_{r=1}^B \hat{T}_{n,r}^* \right)^2}$$

```
sd(estmed)
```

```
## [1] 0.1083144
```


F caso general

Alternativa 2: Bootstrap uniforme

- ▶ Supongamos que tenemos un conjunto de datos $x_1, \dots, x_n$. Asumimos que los datos son una realización de una muestra $\mathbf{X} = X_1, \dots, X_n$.
- ▶ Sabiendo que la empírica $\hat{F}_n$ es un estimador consistente de la distribución F , la solución bootstrap es generar muestras con distribución $\hat{F}_n$.
- ▶ Una muestra aleatoria de tamaño n de la distribución $\hat{F}_n$ es entonces una muestra de tamaño n tomada **con reposición** de $X_1, \dots, X_n$.

Ejemplo: lámparas

```
median(tiempos)
```

```
## [1] 2.9
```

```
B <- 1000
```

```
n <- length(tiempos)
```

```
estmed <- 0
```

```
for(i in 1:B){
```

```
  xboot <- sample(tiempos, n, replace = TRUE )
```

```
  estmed[i] <- median(xboot)
```

```
}
```


```
head(estmed)
```

```
## [1] 2.95 2.80 2.80 3.00 3.00 2.80
```

```
sd(estmed)
```

```
## [1] 0.1232827
```

```
plot(density(estmed, bw=0.5))
```



Muestra bootstrap no paramétrico

Sea $\hat{F}_n$ la función de distribución empírica, que asigna probabilidad $1/n$ a cada observación X_i .

Una **muestra bootstrap** es una muestra aleatoria de la distribución empírica $\hat{F}_n$.

¿Cómo obtenemos una muestra bootstrap

$$\mathbf{X}^* = X_1^*, \dots, X_n^*$$

con esta alternativa?

Extrayendo una muestra con reposición de la muestra original
 $X_1, \dots, X_n$: $X_1^*, \dots, X_n^*$

Para cada muestra bootstrap hay una replicación bootstrap de $\hat{T}_n$:
 $\hat{T}_n^*$ estadístico bootstrap

El algoritmo bootstrap

Este algoritmo permite estimar el error estándar de un estimador

$$\hat{T}_n = \delta(X_1, \dots, X_n)$$

1 - Generar $X_1^*, \dots, X_n^*$ a partir de $\hat{F}_n$.

2 - Calcular $\hat{T}_n^* = \delta(X_1^*, \dots, X_n^*)$.

3 - Repetir los pasos 1 y 2, B veces, para obtener $\hat{T}_{n,1}^*, \dots, \hat{T}_{n,B}^*$.

4 - Calculamos

$$\widehat{\text{se}}_{\text{boot}} = \sqrt{\frac{1}{B} \sum_{b=1}^B \left(\hat{T}_{n,b}^* - \frac{1}{B} \sum_{r=1}^B \hat{T}_{n,r}^* \right)^2}$$

Resumendo

En el **bootstrap paramétrico** la distribución de la que remuestreamos se obtiene ajustando un modelo paramétrico a partir de los datos x_i .

En el **bootstrap no paramétrico** la distribución verdadera es aproximada por la distribución empírica, que es discreta y da masa $1/n$ a cada observación x_i y remuestreamos de esta distribución empírica.

Diagrama (Wasserman, 2003)

Mundo real $F \implies X_1, \dots, X_n \implies \hat{T}$

Mundo bootstrap $\hat{F}_n \implies X_1^*, \dots, X_n^* \implies \hat{T}^*$

Resumiendo:

- ▶ El Bootstrap nos da un camino para estimar el desvío estándar de un estimador.
- ▶ Dado el estimador $\hat{T}_n = \delta(X_1, \dots, X_n)$, la idea del bootstrap es:

Paso 1: Estimar $\text{Var}_F(\hat{T}_n)$ con $\text{Var}_{\hat{F}_n}(\hat{T}_n)$.

Paso 2: Aproximar $\text{Var}_{\hat{F}_n}(\hat{T}_n)$ por simulación.

- ▶ Veremos que también permite calcular intervalos de confianza.

Método 1. Intervalo bootstrap normal

- ▶ $\hat{T}_n$ asintóticamente normal si

$$\frac{\hat{T}_n - T(F)}{\text{se}(\hat{T}_n)} \approx \mathcal{N}(0, 1)$$

- ▶ Sea $\hat{\text{se}}_{\text{boot}}$ el estimador bootstrap de $\text{se}(\hat{T}_n)$

intervalo bootstrap normal nivel aproximado $1 - \alpha$:

$$\hat{T}_n \pm z_{\alpha/2} \hat{\text{se}}_{\text{boot}}$$

Método 1. Intervalo bootstrap normal

- $\hat{T}_n$ asintóticamente normal si

$$\frac{\hat{T}_n - T(F)}{\text{se}(\hat{T}_n)} \approx \mathcal{N}(0, 1)$$

- Sea $\hat{\text{se}}_{\text{boot}}$ el estimador bootstrap de $\text{se}(\hat{T}_n)$

intervalo bootstrap normal nivel aproximado $1 - \alpha$:

$$\hat{T}_n \pm z_{\alpha/2} \hat{\text{se}}_{\text{boot}}$$

Por ejemplo, bajo condiciones de regularidad, los cuantiles tienen distribución aproximadamente normal, por ejemplo, $\hat{M}_n = \text{med}_{1 \leq i \leq n}(X_i)$:

$$\sqrt{n}(\hat{M}_n - m) \rightarrow N\left(0, \frac{1}{4f^2(m)}\right) \quad \text{en distribución}$$

Ejemplo

Objetivo : Estimar el ingreso familiar mediano en Argentina en 2023 mediante un intervalo de confianza.

```
median(ingresos)
```

```
## [1] 240000
```

Estimación bootstrap del error estándar de la mediana

```
estimar_se_mediana <-  
  function(x, B = 1000){  
    titahatboot <- rep(0, B)  
    for(i in 1:B){  
      Xboot <- sample(x, length(x), replace = TRUE)  
      titahatboot[i] <- median(Xboot)  
    }  
    sqrt(mean((titahatboot - mean(titahatboot))^2))  
  }
```

IC para la mediana por bootstrap uniforme

Intervalo bootstrap normal de nivel aproximado 0.95

```
x <- ingresos  
set.seed(123)  
se_boot <- estimar_se_mediana(x)  
se_boot
```

```
## [1] 930.2423
```

```
intervalo_boot <- c(median(x) - 1.96*se_boot,  
                    median(x) + 1.96*se_boot)  
intervalo_boot
```

```
## [1] 238176.7 241823.3
```

Método 2: Intervalo bootstrap percentil

- ▶ B : número de iteraciones bootstrap
- ▶ Sean $\hat{T}_{n,1}^*, \dots, \hat{T}_{n,B}^*$ estadísticos bootstrap del estimador.

intervalo boot percentil $1 - \alpha$: $\left(\hat{T}_{\alpha/2}^*, \hat{T}_{1-\alpha/2}^* \right)$

donde $\hat{T}_{\beta}^*$ es el β -cuantil muestral de los estadísticos bootstrap.

Ejemplo 1: DasGupta (2008).

Porque $\mathbb{E}[X]$ es indefinida,
i.e. no aplica LGN

- ▶ $X_1, \dots, X_n$ i.i.d. Cauchy con mediana μ .
- ▶ El promedio muestral $\bar{X}_n$ es un mal estimador de μ (¿por qué?), por eso usamos la mediana muestral $\tilde{X}_n$.
- ▶ Para n impar, digamos $n = 2k + 1$, existe una fórmula exacta :

$$\mathbb{V}(\tilde{X}_n) = \frac{2n!}{(k!)^2 \pi^n} \int_0^{\pi/2} x^k (\pi - x)^k (\cot x)^2 dx.$$

- ▶ Mediante una aproximación asintótica obtenemos que

$$\widehat{\mathbb{V}(\tilde{X}_n)} = \pi^2 / 4n$$

- ▶ ¿Qué nos daría una aproximación bootstrap?

Consideremos $n = 21$:

$$\mathbb{V}(\tilde{X}_n) = 0.1367 \text{ y } \widehat{\mathbb{V}(\tilde{X}_n)} = 0.1175$$

Un estimador bootstrap de $\mathbb{V}(\tilde{X}_n)$ usando $B = 5000$ es

$$\widehat{\mathbb{V}(\tilde{X}_n)}_{\text{boot}} = 0.1356251$$

podemos obtenerla con muy poco esfuerzo.


```
set.seed(345)
```

```
x21 <- rcauchy(21)  
median(x21)
```

```
## [1] 0.28433
```

```
estimar_se_mediana <- function(x, B = 1000){  
  titahatboot <- rep(NA,B)  
  for(i in 1:B){  
    Xboot <- sample(x, length(x), replace = TRUE)  
    titahatboot[i] <- median(Xboot)  
  }  
  sqrt(mean((titahatboot-mean(titahatboot))^2))  
}
```

```
se.est<-estimar_se_mediana(x21, B = 5000)  
se.est*se.est
```

```
## [1] 0.1356251
```

Ejemplo 2:

Sea T una v.a. con distribución $\mathcal{E}(\lambda)$. A partir de un ejercicio de simulación se busca estudiar a los estimadores de la media y la mediana, usando Bootstrap.

- ▶ a) Generar una muestra de tamaño $n = 500$ de una v.a. con distribución $\mathcal{E}(1)$, que llamaremos muestra original. Recordar setear la semilla. Esta será la muestra en la que se basará todo el ejercicio.
- ▶ b) Hallar una estimación de la media y la mediana de T basada en la muestra original.
- ▶ c) Para entender el comportamiento de los estimadores, a partir de la muestra generada en el primer ítem, generar 1000 muestras bootstrap de tamaño 500, tomando subconjuntos *con reposición* de la muestra original. Para cada una de las 1000 muestras bootstrap, calcular la mediana y promedio y guardar los resultados en dos vectores.



Ejemplo 2 (cont.):

- ▶ d) Para cada uno de los vectores generados en el ítem anterior, realizar un histograma y hallar una estimación por núcleos de la función de densidad.
- ▶ e) Hallar intervalos de confianza de nivel 0.95 para la media y la mediana de X , mediante los dos métodos vistos en clase.

Resolución

```
set.seed(1000)
lambda <- 2
muestraoriginal <- rexp(500, lambda)
estmedia <- mean(muestraoriginal)
estmediana <- median(muestraoriginal)
estmediaboot <- estmedianaboot <- 0
for(i in 1:1000){
  muestraboot <- sample(muestraoriginal, size=500,
                        replace = TRUE)
  estmediaboot[i] <- mean(muestraboot)
  estmedianaboot[i] <- median(muestraboot)
}
```

```
par(mfrow=c(1,2))  
hist(estmedianaboot, probability = TRUE, col=2, main="")  
lines(density(estmedianaboot), col =2, lwd=3)  
hist(estmediaboot, probability=TRUE, col = 3, main="")  
lines(density(estmediaboot), col = 3, lwd=3)
```



```
# estimacion de la media poblacional  
mean(muestraoriginal)
```

```
## [1] 0.4667386
```

```
# verdadera media poblacional  
1/lambda
```

```
## [1] 0.5
```

```
# estimacion bootstrap del desvio estandar de la media  
# muestral  
sd(estmediaboot)
```

```
## [1] 0.02129938
```

```
# verdadero desvio estandar de la media muestral  
(1/lambda)/sqrt(500)
```

```
## [1] 0.02236068
```

```
# estimacion de la mediana poblacional  
median(muestraoriginal)
```

```
## [1] 0.3168387
```

```
# verdadera mediana poblacional  
log(2)/lambda
```

```
## [1] 0.3465736
```

```
# estimacion bootstrap del desvio estandar de la mediana  
# muestral  
sd(estmedianaboot)
```

```
## [1] 0.02045497
```

```
# desvio estandar aproximado basado en la distrib asint.  
# de la mediana  
sqrt((1/(4* dexp(log(2)/lambda, lambda)^2))/500)
```

```
## [1] 0.02236068
```

Intervalos de confianza bootstrap para la media

```
# Intervalo bootstrap normal
```

```
z <- qnorm(0.975)  
c(estmedia - sd(estmediaboot) * z,  
  estmedia + sd(estmediaboot) * z)
```

```
## [1] 0.4249926 0.5084847
```

```
# Intervalo de confianza bootstrap percentil
```

```
c(quantile(estmediaboot, 0.025),  
  quantile(estmediaboot, 0.975))
```

```
##      2.5%      97.5%
```

```
## 0.4248498 0.5079311
```


Intervalos de confianza bootstrap para la mediana

```
# intervalo bootstrap normal
```

```
c(estmediana - sd(estmedianaboot) * z,  
   estmediana + sd(estmedianaboot) * z)
```

```
## [1] 0.2767477 0.3569297
```

```
# intervalo bootstrap percentil
```

```
c(quantile(estmedianaboot, 0.025),  
   quantile(estmedianaboot, 0.975))
```

```
##          2.5%          97.5%
```

```
## 0.2824802 0.3672930
```