

Tests de Hipótesis V

Distribución asintótica del test de CV

En muchos casos la distribución de $\lambda^*(\mathbf{X})$ puede ser muy compleja y, en consecuencia, es difícil determinar la constante k_α necesaria para que el test tenga el nivel deseado.

En estas circunstancias, se puede optar por un test de nivel aproximado que surge de estudiar la distribución asintótica y que será útil para muestras de tamaño suficientemente grande.

Distribución asintótica del test de CV

- $\mathbf{X} = (X_1, \dots, X_n) \sim f(\mathbf{x}, \boldsymbol{\theta})$ con $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p) \in \Theta \subset \mathbb{R}^p$ que contiene una esfera.
- Θ_0 es un conjunto de dimensión $p - j$, $1 \leq j \leq p$.
- $H_0 : \boldsymbol{\theta} \in \Theta_0$ vs. $H_1 : \boldsymbol{\theta} \in \Theta_1$, con $\Theta = \Theta_0 \cup \Theta_1$.

$$\lambda^*(\mathbf{X}) = \frac{\sup_{\boldsymbol{\theta} \in \Theta_0} f(\mathbf{X}, \boldsymbol{\theta})}{\sup_{\boldsymbol{\theta} \in \Theta} f(\mathbf{X}, \boldsymbol{\theta})}.$$

Bajo condiciones de regularidad generales en $f(\mathbf{x}, \boldsymbol{\theta})$,

$$-2 \ln \lambda^*(\mathbf{X}) \xrightarrow{D} \chi_j^2 \text{ cuando } \boldsymbol{\theta} \in \Theta_0$$

Distribución asintótica del test de CV

⇒ Un test de nivel de significación asintótico α está dado por

$$\phi(\mathbf{X}) = \begin{cases} 1 & \text{si } -2 \ln \lambda^*(\mathbf{X}) \geq \chi_{j,\alpha}^2 \\ 0 & \text{si } -2 \ln \lambda^*(\mathbf{X}) < \chi_{j,\alpha}^2 \end{cases}$$

En este curso deduciremos la distribución en el caso particular en que

$$H_0 : \theta = \theta_0 \text{ vs. } H_1 : \theta \neq \theta_0.$$

Distribución asintótica del test de CV

Theorem 4.3 (TEOREMA DE WILKS APLICADO A TEST DE CV)

$X_1, \dots, X_n$ i.i.d. $X_1 \sim f(x, \theta)$ con $\theta \in \Theta$ y Θ un abierto en $\mathbb{R}$. Sea $f(\mathbf{x}, \theta)$ la densidad conjunta de $\mathbf{X} = (X_1, \dots, X_n)$.

Supongamos que se cumplen las siguientes condiciones

(A) El conjunto $\mathcal{S} = \{x : f(x, \theta) > 0\}$ es independiente de θ .

(Por ej: a $U(0, \theta)$ no aplica)

(B) Para todo $x \in \mathcal{S}$, $f(x, \theta)$ tiene derivada tercera respecto de θ
(continua y tal que

$\downarrow$
 $L(\theta)$
SUAVE

$$\left| \frac{\partial^3 \ln f(x, \theta)}{\partial \theta^3} \right| = \left| \frac{\partial^2 \psi(x, \theta)}{\partial \theta^2} \right| \leq K \quad \forall x \in \mathcal{S} \quad \forall \theta \in \Theta$$

$$\psi(x, \theta) = \frac{\partial \ln f(x, \theta)}{\partial \theta}.$$

Distribución asintótica del test de CV

Theorem 4.3 (Continuación)

(C) Si $h(\mathbf{X})$ es un estadístico tal que $\mathbb{E}_\theta[|h(\mathbf{X})|] < \infty, \forall \theta \in \Theta$

$$\frac{\partial}{\partial \theta} \left[\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} h(\mathbf{x}) f(\mathbf{x}, \theta) d\mathbf{x} \right] = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} h(\mathbf{x}) \frac{\partial f(\mathbf{x}, \theta)}{\partial \theta} d\mathbf{x}$$

(D) $0 < I(\theta) = \mathbb{E}_\theta \left[\left(\frac{\partial \ln f(X_1, \theta)}{\partial \theta} \right)^2 \right] < \infty .$

Sea $\hat{\theta}_n$ un EMV de θ consistente,

$$\lambda^*(\mathbf{X}) = \frac{f(\mathbf{X}, \theta_0)}{\sup_{\theta \in \Theta} f(\mathbf{X}, \theta)} = \frac{f(\mathbf{X}, \theta_0)}{f(\mathbf{X}, \hat{\theta}_n)} .$$

$$\implies U = -2 \ln (\lambda^*(\mathbf{X})) \xrightarrow{D} \chi_1^2$$

Distribución asintótica del test de CV

Theorem 4.3 (Continuación)

El test

$$\phi(\mathbf{X}) = \begin{cases} 1 & \text{si } U \geq \chi_{1,\alpha}^2 \\ 0 & \text{si } U < \chi_{1,\alpha}^2 \end{cases}$$

donde $U = -2 \ln(\lambda^*(\mathbf{X}))$, tiene nivel de significación asintótico α .

$$\begin{matrix} \lambda^* \rightarrow 0 & \text{p} \rightarrow \infty \\ \lambda^* \rightarrow 1 & \text{p} \rightarrow 0 \end{matrix}$$

¡IDEA:

- Si U es muy grande $\Rightarrow \lambda^*$ era muy cercano a 0, (mucha discrepancia entre hipótesis y datos)
 $\Rightarrow \phi = 1$
- Si U es muy chico $\Rightarrow \lambda^*$ cercano a 1 (no hay evidencia suficiente para rechazar H_0)
 $\Rightarrow \phi = 0$

Ejemplo

Ejemplo 4.4

Sea $X_1, \dots, X_n$ i.i.d. $X_i \sim Bi(1, \theta)$, $0 < \theta < 1$

Queremos testear $H_0 : \theta = \theta_0$ vs. $\theta \neq \theta_0$.

Luego, el test del cociente de verosimilitud es

$$\lambda^* = \frac{f(\mathbf{x}, \theta_0)}{\sup_{\theta \in \Theta} f(x, \theta)} = \frac{\theta_0^T (1 - \theta_0)^{n-T}}{\bar{X}^T (1 - \bar{X})^{n-T}},$$

donde $T = \sum_{i=1}^n X_i$. Luego,

$$U = -2 \ln \lambda^* = 2T \ln \frac{\bar{X}}{\theta_0} + 2(n - T) \ln \frac{(1 - \bar{X})}{1 - \theta_0}$$

tiene una distribución asintótica χ_1^2 bajo H_0 y un test de nivel asintótico estará dado por

$$\varphi(\mathbf{X}) = \begin{cases} 1 & \text{si } U \geq \chi_{1,\alpha}^2 \\ 0 & \text{si } U < \chi_{1,\alpha}^2. \end{cases}$$

Ejemplo

Ejemplo 4.5

Una empresa afirma que el 90% de sus lámparas LED duran más de 10000 horas. Una empresa de la competencia quiere demostrar que esa afirmación es falsa. Para ello, toman aleatoriamente $n=200$ lámparas y las prueban. Como resultado, observan que 168 superan las 10 000 horas y 32 no. ¿Cuál es la conclusión? ¿Cuál es la región de confianza asociada a este test?

$$X_i = \begin{cases} 1 & \text{dura +10000 hs} \\ 0 & \text{si no} \end{cases} \sim \text{Be}(p)$$

$$H_0: p = 0.9 \text{ vs } H_1: p \neq 0.9$$

$$n=200, K=168, \hat{p} = \bar{X} = \frac{K}{n} = 0.84$$

$$\lambda^*(X) = \frac{L(p_0|X)}{\sup_{p \in (0,1)} L(p|X)} = \frac{p_0^K (1-p_0)^{n-K}}{\hat{p}^K (1-\hat{p})^{n-K}} = \left(\frac{0.9}{0.84}\right)^{168} \cdot \left(\frac{0.1}{0.16}\right)^{32}$$

$$U = -2 \log \lambda^*(X) = 6.90 \rightarrow U_{\text{OBS}}$$

$$\text{Por Teo de Wilks, } U \xrightarrow{D} \chi^2_1, \quad P(\chi^2_1 \geq \chi^2_{1,\alpha}) = \alpha$$

$$\text{Si } 6.90 \geq \chi^2_{1,\alpha} \Rightarrow \text{hay evidencia de que } p \neq 0.9.$$


```

> T <- 168; phat <- 168/200
> n <- 200
> # Función del estadístico
> U <- function(theta){
+   2*T*log(phat/theta) +
+   2*(n-T)*log((1-phat)/(1-theta))
+ }
> # Uobs
> Uobs <- U(0.9)
> Uobs
[1] 6.898627
> # Valor crítico
> corte <- qchisq(0.95, df = 1)
> corte
[1] 3.841459
> curve(Utheta(x), from = 0.7, to = 0.99,
xlab = expression(theta),
ylab = expression(U(theta)))
> abline(h=corte)

```

$1-\alpha \Rightarrow \alpha=0.05$

$\chi^2_{1,\alpha}$



```
# Intervalo de confianza
> uniroot(function(theta) Utheta(theta) - corte,
+         interval = c(0.001, phat))$root
[1] 0.7850253
>
> # Extremo superior
> uniroot(function(theta) Utheta(theta) - corte,
+         interval = c(phat, 0.999))$root
[1] 0.8863335
>
> LI <- uniroot(function(theta) Utheta(theta) - corte,
+         interval = c(0.001, phat))$root
>
> LS <- uniroot(function(theta) Utheta(theta) - corte,
+         interval = c(phat, 0.999))$root
>
> c(LI, LS)
[1] 0.7850253 0.8863335
```

Ejemplo

Ejemplo 4.5 (Respuesta)

Hay evidencia, a nivel 0.05 de que la proporción de lámparas que duran mas de 10000 horas es diferente de 0.9.

La región de confianza observada para la verdadera proporción de lámparas que duran mas de 10000 horas que resulta de invertir el test del CV es, redondeando a 2 decimales, $[0.79, 0.89]$.

Dem del teorema 4.3 (Video)

Sea $\ell(\theta) = \ln f(\mathbf{X}, \theta) = \sum_{i=1}^n \ln(f(X_i, \theta))$.

Denotamos ℓ' , ℓ'' y ℓ''' a las derivadas hasta el orden tres respecto de θ de la función ℓ y por

$$\psi'(x, \theta) = \frac{\partial \psi(x, \theta)}{\partial \theta} \quad \text{y} \quad \psi''(x, \theta) = \frac{\partial^2 \psi(x, \theta)}{\partial \theta^2}.$$

Luego, $\hat{\theta}_n$ verifica

$$\ell'(\hat{\theta}_n) = \sum_{i=1}^n \psi(X_i, \hat{\theta}_n) = 0 .$$

Desarrollando por Taylor alrededor de $\hat{\theta}_n$ resulta

$$\begin{aligned} \ell(\theta_0) - \ell(\hat{\theta}_n) &= \ell'(\hat{\theta}_n)(\theta_0 - \hat{\theta}_n) + \frac{1}{2} \ell''(\xi_n^1)(\theta_0 - \hat{\theta}_n)^2 \\ &= \frac{1}{2}(\theta_0 - \hat{\theta}_n)^2 \left(\sum_{i=1}^n \psi'(X_i, \xi_n^1) \right) \\ &= \frac{1}{2} \left(n(\theta_0 - \hat{\theta}_n)^2 \right) \frac{1}{n} \sum_{i=1}^n \psi'(X_i, \theta_0) + R_n , \end{aligned}$$

donde ξ_n^1 es un punto intermedio entre $\hat{\theta}_n$ y θ_0 y

$$R_n = \frac{1}{2} \left(n(\theta_0 - \hat{\theta}_n)^2 \right) \left(\frac{1}{n} \sum_{i=1}^n \psi'(X_i, \xi_n^1) - \frac{1}{n} \sum_{i=1}^n \psi'(X_i, \theta_0) \right) .$$

Dem del teorema 4.3 (Video)

Aplicando el Teorema del Valor Medio resulta

$$R_n = \frac{1}{2} \left(n(\theta_0 - \hat{\theta}_n)^2 \right) \left(\frac{1}{n} \sum_{i=1}^n \psi''(X_i, \xi_n^2) (\xi_n^1 - \theta_0) \right) \quad (3)$$

donde ξ_n^2 es un punto intermedio entre ξ_n^1 y θ_0 .

Si definimos $A_n = -\frac{1}{n} \sum_{i=1}^n \psi'(X_i, \theta_0)$, entonces

$$Z = 2 \left(\ell(\hat{\theta}_n) - \ell(\theta_0) \right) = \left(n(\hat{\theta}_n - \theta_0)^2 \right) A_n - R_n . \quad (4)$$

Por un lado, tenemos que cuando $\theta = \theta_0$

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{D} \mathbf{N}(0, \frac{1}{I(\theta_0)})$$

y así resulta que

$$I(\theta_0) n (\hat{\theta}_n - \theta_0)^2 \xrightarrow{D} \chi_1^2 \quad (5)$$

Dem del teorema 4.3 (Video)

Por otro lado, por la L.G.N.

$$\frac{1}{n} \sum_{i=1}^n \psi'(X_i, \theta_0) \xrightarrow{p} \mathbb{E}(\psi'(X_1, \theta_0)) = -I(\theta_0) \quad (6)$$

con lo cual

$$\left(n (\hat{\theta}_n - \theta_0)^2 \right) A_n \xrightarrow{D} \chi_1^2. \quad (7)$$

Por lo tanto, deducimos que para obtener el resultado deseado bastará probar que

$$R_n \xrightarrow{p} 0.$$

Dem del teorema 4.3 (Video)

Notemos que

$$R_n = \frac{1}{2} \left(n(\theta_0 - \hat{\theta}_n)^2 \right) \left(\frac{1}{n} \sum_{i=1}^n \psi'(X_i, \xi_n^1) - \frac{1}{n} \sum_{i=1}^n \psi'(X_i, \theta_0) \right),$$

entonces

$$R_n = \frac{1}{2} \left(n(\theta_0 - \hat{\theta}_n)^2 \right) \left(\frac{1}{n} \sum_{i=1}^n \psi''(X_i, \xi_n^2)(\xi_n^1 - \theta_0) \right)$$

donde ξ_n^2 es un punto intermedio entre ξ_n^1 y θ_0 . Como $\hat{\theta}_n$ es un estimador consistente, se obtiene que $\xi_n^j \xrightarrow{p} \theta_0$ para $j = 1, 2$. Además, observemos que como $|\psi''(X_i, \theta)| \leq K$ para todo θ , en consecuencia vale

$$\left| \frac{1}{2n} \sum_{i=1}^n \psi''(X_i, \xi_n^2)(\xi_n^1 - \theta_0) \right| \leq \frac{K}{2} |(\xi_n^1 - \theta_0)|$$

y luego como $\xi_n^1 \xrightarrow{p} \theta_0$ se deduce que:

$$\frac{1}{n} \sum_{i=1}^n \psi''(X_i, \xi_n^2)(\xi_n^1 - \theta_0) \xrightarrow{p} 0. \quad (8)$$

y obtenemos que $R_n \xrightarrow{p} 0$ ya que además $n(\hat{\theta}_n - \theta_0)^2$ está acotado en probabilidad.

Dos Muestras

Mediante el método del pivote podemos obtener tests de hipótesis que involucren dos muestras usando los pivotes con los que trabajamos en el contexto de intervalos de confianza.

Volvamos al ejemplo de las parcelas

Ejemplo: Comparamos dos tratamientos

- **Objetivo:** comparar el rendimiento de dos fertilizantes.
- Se divide un terreno en 30 parcelas homogéneas (por ej. cant. sol, humedad, etc.).
- En las 30 parcelas se cultiva la misma variedad de maíz.
- En 15 de ellas se utiliza el fertilizante A y en las restantes el B.

Ejemplo: Comparamos dos tratamientos

Datos

- Parcelas con Tratamiento A

238, 237, 235, 220, 233, 203, 228, 220, 221,
215, 218, 217, 232, 225, 209

- Parcelas con Tratamiento B

253, 227, 241, 245, 237, 248, 250, 218, 239,
243, 257, 208, 215, 240, 229

- Queremos comparar el rendimiento medio de esta variedad de maíz cuando el terreno se trata con estos dos fertilizantes.

Modelo 1: Muestras normales independientes con igual varianza

Supongamos que:

- $X_1, \dots, X_{n_1} \sim \mathcal{N}(\mu_1, \sigma^2)$,
- $Y_1, \dots, Y_{n_2} \sim \mathcal{N}(\mu_2, \sigma^2)$

Además, asumimos que:

Las dos muestras aleatorias, independientes entre sí.

Test para $H_0 : \mu_1 - \mu_2 = \Delta$ vs. $H_1 : \mu_1 - \mu_2 \neq \Delta$

En muchas situaciones $\Delta = 0$. Notemos que en nuestro ejemplo podemos reescribir las hipótesis como:

$$H_0 : \mu_1 = \mu_2 \text{ vs. } H_1 : \mu_1 \neq \mu_2$$

Varianzas desconocidas pero iguales $\sigma_1^2 = \sigma_2^2 = \sigma^2$

$$\frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0, 1) , \quad \frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \sim \mathcal{N}(0, 1)$$

Necesitamos estimar σ^2 . Tenemos dos estimadores:

$$S_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (X_i - \bar{X}_{n_1})^2 , \quad S_2^2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (Y_i - \bar{Y}_{n_2})^2$$

Los combinamos:

$$S_p^2 = \frac{S_1^2 (n_1 - 1) + S_2^2 (n_2 - 1)}{n_1 + n_2 - 2}$$

Recordemos el

Teorema (Teorema 2.21)

Sean $X_1, \dots, X_{n_1}$ y $Y_1, \dots, Y_{n_2}$ dos muestras aleatorias independientes de las distribuciones $N(\mu_1, \sigma^2)$ y $N(\mu_2, \sigma^2)$, respectivamente. Sean

$$U = \frac{\bar{X} - \bar{Y} - \Delta}{\sqrt{\frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2}}} \quad V = \frac{\sum_{i=1}^{n_1} (X_i - \bar{X})^2}{\sigma^2} \quad W = \frac{\sum_{i=1}^{n_2} (Y_i - \bar{Y})^2}{\sigma^2}$$

$$\text{POOLED VARIANCE ESTIMATOR} \leftarrow S_p^2 = \frac{S_1^2 (n_1 - 1) + S_2^2 (n_2 - 1)}{n_1 + n_2 - 2} = \frac{\sigma^2 (V + W)}{n_1 + n_2 - 2}$$

Luego

- (i) U , V y W son variables aleatorias independientes con distribuciones $N(0, 1)$, $\chi_{n_1-1}^2$ y $\chi_{n_2-1}^2$ respectivamente.
- (ii) $Z = V + W \sim \chi_{n_1+n_2-2}^2$.
- (iii) $\frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \sim t_{n_1+n_2-2}$

Demo (iii)
 $S_p^2 / \sigma^2 \sim \frac{\chi_{n_1+n_2-2}^2}{n_1+n_2-2}$

$$\frac{\bar{X} - \bar{Y} - \Delta}{\sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \cdot \frac{\sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}{\sqrt{S_p^2 / \sigma^2}} = \frac{\bar{X} - \bar{Y} - \Delta}{\sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

$$H_0 : \mu_1 - \mu_2 = \Delta \text{ vs. } H_1 : \mu_1 - \mu_2 \neq \Delta$$

Test de nivel α

Rechazamos H_0 si

$$\frac{|\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta|}{\sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} > t_{n_1+n_2-2, \alpha/2}$$

.....¿y cómo sabemos si las varianzas son iguales????

El test más tradicional para chequear esto es el test de F que asume que las dos poblaciones son normales.

Comparación de varianzas

Supongamos que tenemos dos muestras independientes:

- $X_1, \dots, X_{n_1} \sim \mathcal{N}(\mu_1, \sigma_1^2)$,
- $Y_1, \dots, Y_{n_2} \sim \mathcal{N}(\mu_2, \sigma_2^2)$

Queremos testear a nivel α : $H_0 : \sigma_1^2 = \sigma_2^2$ vs. $H_1 : \sigma_1^2 \neq \sigma_2^2$

Parece razonable considerar el cociente

$$\frac{S_1^2}{S_2^2}$$

¿Por qué?
Si usamos $S_1^2 - S_2^2$ no queda una distribución conocida y además su varianza depende de σ_1^4 y σ_2^4 los cuales no conocemos.


Como bajo H_0 esperamos que sea cercano a 1, rechazaremos H_0 si es mucho más grande o mucho más pequeño que 1.

¿Pero conocemos su distribución?

Tengamos en cuenta que si $U \sim \chi_k^2$ y $W \sim \chi_m^2$ independientes, entonces

$$V = \frac{U/k}{W/m} \sim F_{k,m} \quad \rightarrow \text{F de Snedecor}$$

Densidad F



El pivote

Llamemos $F_{k,m,\beta}$ al punto que cumple

$$\beta = \mathbb{P}(V \geq F_{k,m,\beta}) \text{ para } V \sim F_{k,m}$$

.

Notemos que bajo H_0

$$\frac{S_1^2}{S_2^2} \sim F_{n_1-1, n_2-1}$$

¿por qué?

$$\begin{aligned} S_1^2 &= \frac{\sigma^2}{n_1-1} U, \quad U \sim \chi_{n_1-1}^2 \\ S_2^2 &= \frac{\sigma^2}{n_2-1} W, \quad W \sim \chi_{n_2-1}^2 \\ \Rightarrow \frac{S_1^2}{S_2^2} &= \frac{U/n_1-1}{W/n_2-1} \end{aligned}$$

por lo tanto, rechazaremos H_0 si

$$\frac{S_1^2}{S_2^2} \leq F_{n_1-1, n_2-1, 1-\alpha/2} \text{ o bien } \frac{S_1^2}{S_2^2} \geq F_{n_1-1, n_2-1, \alpha/2}$$

¿Cómo comparamos las medias si rechazamos con este test la igualdad de varianzas?

Modelo 2: Muestras normales independientes con distintas varianzas

- $X_1, \dots, X_{n_1} \sim \mathcal{N}(\mu_1, \sigma_1^2),$
- $Y_1, \dots, Y_{n_2} \sim \mathcal{N}(\mu_2, \sigma_2^2)$

Las dos muestras aleatorias, independientes entre sí.

$$H_0 : \mu_1 - \mu_2 = \Delta \quad \text{vs.} \quad H_1 : \mu_1 - \mu_2 \neq \Delta$$

El problema de comparar las medias en estas condiciones se conoce como el problema de Fisher-Behrens.

Parece natural considerar el estadístico:

$$T^* = \frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

La distribución de T^* ya no es una t de Student bajo H_0 , su distribución es la de Fisher-Behrens y depende de n_1, n_2 y de σ_1^2/σ_2^2 .

Modelo 2: Muestras normales independientes con distintas varianzas

$$T^* = \frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - \Delta}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

Hay distintas soluciones a este problema, una de las más usadas se basa la solución de Welch (1947) en la que la distribución de T^* se aproxima por una t_ν , en la que los grados de libertad ν están dados por

$$\nu = \frac{(S_1^2/n_1 + S_2^2/n_2)^2}{(S_1^2/n_1)^2 / (n_1 - 1) + (S_2^2/n_2)^2 / (n_2 - 1)}$$

Vayamos a R para terminar el ejemplo de las parcelas tratadas con dos fertilizantes.

```
> x <- c(238,237,235,220,233,203,228,220,  
+        221,215,218,217,232,225,209)  
> y <- c(253,227,241,245,237,248,250,218,  
+        239,243,257,208,215,240,229)  
> t.test(x,y, var.equal=TRUE)
```

MODELO 1

Two Sample t-test

data: x and y

t = -2.8856, df = 28, p-value = 0.00744

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

of [-22.684390 -3.848943]

sample estimates:

mean of x mean of y

223.4000 236.6667

Conclusión: Si asumo varianzas iguales encuentro evidencia a nivel 0.05 de que los rendimientos medios son distintos entre los tratamientos

```
> t.test(x,y)
```

MODELO 2 (default de R)

Welch Two Sample t-test

data: x and y *grados de libertad*

t = -2.8856, df = 25.441, p-value = 0.007854

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

Q# [-22.727247 -3.806086]

sample estimates:

mean of x mean of y

223.4000 236.6667

✓ **Conclusión:** Si no asumo varianzas iguales encuentro evidencia a nivel 0.05 de que los rendimientos medios son distintos entre los tratamientos

```
> var.test(x,y)
```

F test to compare two variances

data: x and y

F = 0.51845, num df = 14, denom df = 14, p-value
= 0.2314

alternative hypothesis: true ratio of variances is not equal
to 1

95 percent confidence interval:

$1 \in [0.1740588 \ 1.5442465]$ $\longrightarrow$ Recordar que

sample estimates:

$$H_0: \frac{\sigma_1^2}{\sigma_2^2} = 1$$

ratio of variances

0.5184493

Conclusión: No encontramos evidencia a nivel 0.05 de que los varianzas de los rendimientos son distintos entre los tratamientos.

i.e. podemos usar MODELO 1