

# Regresión lineal múltiple

IECD

# Enfoque matricial

$$y_i = \theta_1 x_{i1} + \cdots + \theta_p x_{ip} + \epsilon_i \quad i = 1, \dots, n$$

$$\mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \cdots & & \cdots & \\ \cdots & & \cdots & \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

$$\boldsymbol{\theta} = \begin{pmatrix} \theta_1 \\ \vdots \\ \theta_p \end{pmatrix} \quad \boldsymbol{\epsilon} = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

$\Downarrow$

$$\begin{array}{ccccccc} \mathbf{Y} & = & \mathbf{X} & \boldsymbol{\theta} & + & \boldsymbol{\epsilon} \\ n \times 1 & & n \times p & p \times 1 & & n \times 1 \end{array}$$

# Esperanza de una matriz aleatoria

Dada una matriz  $\mathbf{V}$  ( $r \times s$ ) de variables aleatorias con coordenadas  $\{V_{ij}\}$  con esperanza finita, definimos la matriz de esperanzas de  $\mathbf{V}$  como la matriz con coordenadas:

$$\{\mathbb{E}(\mathbf{V})\}_{ij} = \mathbb{E}(V_{ij})$$

# Propiedad de la esperanza de un vector aleatorio

## Teorema 4.17

*Si  $\mathbf{Z} = \mathbf{c} + \mathbf{A}\mathbf{Y}$ , donde  $\mathbf{Y}$  es un vector aleatorio,  $\mathbf{A}$  es una matriz fija y  $\mathbf{c}$  es un vector fijo, entonces*

$$E(\mathbf{Z}) = \mathbf{c} + \mathbf{A}E(\mathbf{Y})$$

Proof.

La  $i$ -ésima componente de  $\mathbf{Z}$  es

$$Z_i = c_i + \sum_{j=1}^n a_{ij} Y_j$$

Por la linealidad de la esperanza,

$$E(Z_i) = c_i + \sum_{j=1}^n a_{ij} E(Y_j)$$

Escribir estas ecuaciones en forma matricial completa la demostración. 



# Matriz de Covarianza de un vector aleatorio

Sea  $\mathbf{v} = (v_1, \dots, v_n)^t$  un vector aleatorio con  $E(v_i) = \mu_i$  y varianza finita. Definimos la matriz de covarianza de  $\mathbf{v}$  como la matriz con coordenadas:

$$\{\Sigma_{\mathbf{v}}\}_{ij} = \text{Cov}(v_i, v_j) = \mathbb{E}[(v_i - \mu_i)(v_j - \mu_j)]$$

Podemos escribirla como:

$$\Sigma_{\mathbf{v}} = \mathbb{E}[(\mathbf{v} - \boldsymbol{\mu})(\mathbf{v} - \boldsymbol{\mu})^t]$$

donde  $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^t$ .

# Propiedad de la matriz de covarianza

## Lemma 4.18

*Sean  $\mathbf{A} \in \mathbb{R}^{m \times n}$ , una matriz constante,  $\mathbf{d}$  un vector de constantes y  $\mathbf{v}$  un vector aleatorio  $n$ -dimensional con esperanza  $\mu$  y matriz de covarianza  $\Sigma_{\mathbf{v}}$ . Si  $\mathbf{w} = \mathbf{A}\mathbf{v} + \mathbf{d}$ , entonces:*

$$\Sigma_{\mathbf{w}} = \mathbf{A}\Sigma_{\mathbf{v}}\mathbf{A}^t.$$

## Demostración.

La constante  $\mathbf{d}$  no afecta la covarianza.

$$\begin{aligned}\text{Cov}(w_i, w_j) &= \text{Cov} \left( \sum_{k=1}^n a_{ik} v_k, \sum_{l=1}^n a_{jl} v_l \right) \\ &= \sum_{k=1}^n \sum_{l=1}^n a_{ik} a_{jl} \text{Cov}(v_k, v_l) \\ &= \sum_{k=1}^n \sum_{l=1}^n a_{ik} \sigma_{kl} a_{jl}\end{aligned}$$

Esto es igual al coeficiente  $ij$  de  $\mathbf{A}\Sigma_{\mathbf{v}}\mathbf{A}^t$ .



# Formas cuadráticas

## Definition 4.19

Sea  $\mathbf{A} \in \mathbb{R}^{n \times n}$ , una matriz fija y  $\mathbf{v} \in \mathbb{R}^n$  un vector. La expresión

$$\mathbf{v}^T \mathbf{A} \mathbf{v} = \sum_{i=1}^n \sum_{j=1}^n v_i v_j a_{ij}$$

se llama forma cuadrática

# Esperanza de una forma cuadrática

## Teorema 4.20

*Sea  $\mathbf{v}$  un vector aleatorio con media  $\boldsymbol{\mu}$  y matriz de covarianza  $\boldsymbol{\Sigma}$  y sea  $\mathbf{A}$  una matriz fija. Entonces*

$$\mathbb{E}(\mathbf{v}^T \mathbf{A} \mathbf{v}) = \text{tr}(\mathbf{A} \boldsymbol{\Sigma}) + \boldsymbol{\mu}^T \mathbf{A} \boldsymbol{\mu}$$

Proof.

Observar primero que

$$\mathbb{E}(v_i v_j) = \sigma_{ij} + \mu_i \mu_j \quad y \quad \mathbf{v}^T \mathbf{A} \mathbf{v} = \sum_{i=1}^n \sum_{j=1}^n v_i v_j a_{ij}$$

Entonces

$$\begin{aligned} \mathbb{E} \left( \sum_{i=1}^n \sum_{j=1}^n v_i v_j a_{ij} \right) &= \sum_{i=1}^n \sum_{j=1}^n \sigma_{ij} a_{ij} + \sum_{i=1}^n \sum_{j=1}^n \mu_i \mu_j a_{ij} \\ &= \text{tr}(\mathbf{A} \mathbf{\Sigma}) + \boldsymbol{\mu}^T \mathbf{A} \boldsymbol{\mu} \quad \blacksquare \end{aligned}$$

ya que  $\mathbf{\Sigma}$  es simétrica.



# Matriz de covarianza cruzada

## Definition 4.21

Si  $\mathbf{Y}_{p \times 1}$  y  $\mathbf{Z}_{m \times 1}$  son vectores aleatorios, la **matriz de covarianza cruzada** de  $\mathbf{Y}$  y  $\mathbf{Z}$  se define como la matriz  $\Sigma_{YZ}$  de dimensiones  $p \times m$  cuyo elemento  $ij$  es  $\sigma_{ij} = \text{Cov}(Y_i, Z_j)$ .

# Matriz de covarianza cruzada

## Theorem 4.22

Sea  $\mathbf{X}$  un vector aleatorio con matriz de covarianza  $\Sigma_{XX}$ . Si

$$\mathbf{Y} = \underset{p \times n}{\mathbf{A}} \mathbf{X}$$

y

$$\mathbf{Z} = \underset{m \times n}{\mathbf{B}} \mathbf{X}$$

donde  $\mathbf{A}$  y  $\mathbf{B}$  son matrices fijas, la matriz de covarianza cruzada de  $\mathbf{Y}$  y  $\mathbf{Z}$  es

$$\Sigma_{YZ} = \mathbf{A} \Sigma_{XX} \mathbf{B}^T$$

Proof.

Ejercicio (optativo)



# Modelo de regresión lineal múltiple, escritura matricial

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\theta} + \boldsymbol{\varepsilon} \quad \mathbb{E}(\boldsymbol{\varepsilon}) = \mathbf{0} \quad \boldsymbol{\Sigma}_{\boldsymbol{\varepsilon}} = \sigma^2 \mathbf{I}, \quad \text{o, equivalentemente}$$

$$\mathbb{E}(\mathbf{Y}) = \mathbf{X}\boldsymbol{\theta} \quad \boldsymbol{\Sigma}_{\mathbf{Y}} = \sigma^2 \mathbf{I}, \text{ donde}$$

$$\mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \cdot \\ \cdot \\ y_n \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \dots & & \dots & \\ \dots & & \dots & \\ x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix}$$

$$\boldsymbol{\theta} = \begin{pmatrix} \theta_1 \\ \cdot \\ \cdot \\ \theta_p \end{pmatrix} \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \epsilon_1 \\ \cdot \\ \cdot \\ \epsilon_n \end{pmatrix}$$

# Matriz de diseño

La matriz  $\mathbf{X} \in \mathbb{R}^{n \times p}$  recibe el nombre de **matriz de regresión** o de **diseño**.  
y vamos a asumir (por ahora) que tiene rango máximo, es decir  
 $\text{rg}(\mathbf{X}) = p$ .

# Caso particular 1: Modelo de regresión lineal simple

En el caso más sencillo de regresión simple tendríamos

$$y_i = \theta_1 + \theta_2 x_i + \epsilon_i \quad 1 \leq i \leq n$$

$$p = 2 \quad \mathbf{X} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \cdot & \cdot \\ \cdot & \cdot \\ 1 & x_n \end{pmatrix} \quad \boldsymbol{\theta} = \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}$$

## Caso particular 2: Modelo de posición

$$y_i = \mu + \epsilon_i \quad 1 \leq i \leq n$$

$$p = 1 \quad \mathbf{X} = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ \vdots \\ 1 \end{pmatrix} \quad \theta = \mu$$

## Caso particular 3: Modelo de 2 muestras

$$y_{i1} = \mu_1 + \epsilon_{i1} \quad 1 \leq i \leq n_1$$

$$y_{i2} = \mu_2 + \epsilon_{i2} \quad 1 \leq i \leq n_2$$

$$p = 2 \quad \mathbf{X} = \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ \cdot & \cdot \\ \cdot & \cdot \\ 1 & 0 \\ 0 & 1 \\ 0 & 1 \\ \cdot & \cdot \\ \cdot & \cdot \\ 0 & 1 \end{pmatrix} \quad \boldsymbol{\theta} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$$

## Caso particular 4: Modelo de regresión cuadrática

$$y_i = \theta_1 + \theta_2 x_i + \theta_3 x_i^2 + \epsilon_i \quad 1 \leq i \leq n$$

$$p = 3 \quad \mathbf{X} = \begin{pmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \\ 1 & x_n & x_n^2 \end{pmatrix} \quad \boldsymbol{\theta} = \begin{pmatrix} \theta_1 \\ \theta_2 \\ \theta_3 \end{pmatrix}$$

## Caso particular 5: Modelo de k muestras

$$y_{i1} = \mu_1 + \epsilon_{i1} \quad 1 \leq i \leq n_1$$

$$y_{i2} = \mu_2 + \epsilon_{i2} \quad 1 \leq i \leq n_2$$

...

$$y_{ik} = \mu_k + \epsilon_{ik} \quad 1 \leq i \leq n_k$$

$$\mathbf{X} = \begin{pmatrix} 1 & 0 & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \dots & 1 \end{pmatrix} \quad \boldsymbol{\theta} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_k \end{pmatrix}$$

# Mínimos cuadrados

## Definition 4.23

Supongamos  $\mathbf{X}$ ,  $\mathbf{Y}$  y  $\boldsymbol{\theta}$  verifican el modelo de regresión lineal múltiple. El estimador de mínimos cuadrados de  $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p)$  se define como

$$\hat{\boldsymbol{\theta}} = \operatorname{argmin}_{\mathbf{b} \in \mathbb{R}^p} \|\mathbf{Y} - \mathbf{X}\mathbf{b}\|^2,$$

o, equivalentemente,

$$\hat{\boldsymbol{\theta}} = \operatorname{argmin}_{\mathbf{b} \in \mathbb{R}^p} \sum_{i=1}^n [y_i - \theta_1 x_{i1} - \dots - \theta_p x_{ip}]^2$$

# Mínimos cuadrados y ecuaciones normales

## Teorema 4.24

*Asumamos que se cumple el modelo lineal:*

$$\mathbf{Y} = \mathbf{X} \boldsymbol{\theta} + \boldsymbol{\varepsilon}$$

*con  $\mathbf{Y}$  un vector aleatorio de  $n \times 1$ ,  $\mathbf{X}$  una matriz de números reales de  $n \times p$ , cuya primera columna es  $(1, \dots, 1)$ ,  $\boldsymbol{\theta}$  una matriz de números reales de  $p \times 1$  y  $\boldsymbol{\varepsilon}$  un vector aleatorio de  $n \times 1$  tal que sus coordenadas son independientes y tienen esperanza 0.*

*El estimador de mínimos cuadrados cumple*

$$\mathbf{X}^t \mathbf{X} \hat{\boldsymbol{\theta}} = \mathbf{X}^t \mathbf{Y},$$

*que se conocen como **ecuaciones normales**.*

*Si  $\mathbf{X}^t \mathbf{X}$  es no singular, la solución es única y resulta*

$$\hat{\boldsymbol{\theta}} = (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{Y}.$$

# Mínimos cuadrados y ecuaciones normales

## Proof.

Derivando e igualando a 0 obtenemos las **ecuaciones normales**.  
Los estimadores de mínimos cuadrados  $\hat{\theta}_1, \dots, \hat{\theta}_p$  cumplen:

$$\left. \frac{\partial \mathcal{S}(\mathbf{b})}{\partial b_k} \right|_{\mathbf{b}=\hat{\boldsymbol{\theta}}} = -2 \sum_{i=1}^n \left( y_i - \sum_{j=1}^p x_{ij} b_j \right) x_{ik} \Big|_{\mathbf{b}=\hat{\boldsymbol{\theta}}} = 0$$

Por lo tanto, para  $1 \leq k \leq p$

$$\sum_{i=1}^n y_i x_{ik} = \sum_{i=1}^n \sum_{j=1}^p x_{ij} x_{ik} \hat{\theta}_j$$

O sea,

$$\sum_{i=1}^n y_i x_{ik} = \sum_{j=1}^p \hat{\theta}_j \sum_{i=1}^n x_{ij} x_{ik} \quad 1 \leq k \leq p$$

Estas  $p$  ecuaciones son equivalentes a  $\mathbf{X}^t \mathbf{X} \hat{\boldsymbol{\theta}} = \mathbf{X}^t \mathbf{Y}$ .

Si  $\mathbf{X}^t \mathbf{X}$  es no singular, la solución es única y resulta  $\hat{\boldsymbol{\theta}} = \left( \mathbf{X}^t \mathbf{X} \right)^{-1} \mathbf{X}^t \mathbf{Y}$ .  $\square$

# Predichos y residuos

Dado un estimador  $\hat{\boldsymbol{\theta}}$  definimos

Vector de valores predichos:

$$\hat{\mathbf{Y}} = \mathbf{X}^t \hat{\boldsymbol{\theta}}.$$

Vector de residuos:

$$\mathbf{r} = \mathbf{Y} - \mathbf{X}^t \hat{\boldsymbol{\theta}}$$

### Observación 4.25

*Cuando el modelo tiene intercept, i.e, cuando  $x_{i1} = 1$  para todo  $i$ , las ecuaciones normales toman la forma*

$$n\hat{\theta}_1 + \hat{\theta}_2 \sum_{i=1}^n x_{i2} + \cdots + \hat{\theta}_p \sum_{i=1}^n x_{ip} = \sum_{i=1}^n y_i$$

$$\hat{\theta}_1 \sum_{i=1}^n x_{ik} + \hat{\theta}_2 \sum_{i=1}^n x_{i2}x_{ik} + \cdots + \hat{\theta}_p \sum_{i=1}^n x_{ip}x_{ik} = \sum_{i=1}^n y_i x_{ik} \quad k = 2, \dots, p$$

### Observación 4.26

$\mathbf{X}^T \mathbf{X}$  es no singular si y solo si el rango de  $\mathbf{X}$  es igual a  $p$ .

Dem.

Ejercicio ( Ver libro de Rice)



# Ejemplo - Ejercicio: Comprobar de nuevo las fórmulas para regresión simple

En el caso de regresión simple tendríamos

$$\mathbf{X}^t \mathbf{X} = \begin{pmatrix} 1 & 1 & 1 & \dots & 1 \\ x_1 & x_2 & x_3 & \dots & x_n \end{pmatrix} \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \cdot & \cdot \\ \cdot & \cdot \\ 1 & x_n \end{pmatrix}$$

$$\mathbf{X}^t \mathbf{X} = \begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix}$$

El sistema sería

$$\begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix} \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_i y_i \end{pmatrix}$$

# Ejemplo - Ejercicio: Comprobar de nuevo las fórmulas para regresión simple

La inversa resulta

$$(\mathbf{X}^t \mathbf{X})^{-1} = \frac{1}{n \sum_{i=1}^n x_i^2 - n^2 \bar{x}^2} \begin{pmatrix} \sum_{i=1}^n x_i^2 & -\sum_{i=1}^n x_i \\ -\sum_{i=1}^n x_i & n \end{pmatrix}$$

y además

$$\mathbf{X}^t \mathbf{Y} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_i y_i \end{pmatrix}$$

y por lo tanto

$$\hat{\boldsymbol{\theta}} = \begin{pmatrix} \hat{\theta}_1 \\ \hat{\theta}_2 \end{pmatrix} = \frac{1}{n \sum_{i=1}^n (x_i - \bar{x})^2} \begin{pmatrix} (\sum_{i=1}^n y_i)(\sum_{i=1}^n x_i^2) - (\sum_{i=1}^n x_i)(\sum_{i=1}^n x_i y_i) \\ n \sum_{i=1}^n x_i y_i - (\sum_{i=1}^n y_i)(\sum_{i=1}^n x_i) \end{pmatrix}$$

# Interpretación geométrica


## Observación 4.27

*Supongamos que se cumple el modelo lineal y que  $\mathbf{X}$  tiene rango máximo. La proyección ortogonal de  $\mathbf{Y}$  sobre el espacio generado por las columnas de  $\mathbf{X}$  tiene la forma  $\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\theta}}$ , donde  $\hat{\boldsymbol{\theta}}$  es el estimador de mínimos cuadrados.*

Dem

- $\min_{\mathbf{b}} \|\mathbf{Y} - \mathbf{X}\mathbf{b}\|^2 = \min_{\mathbf{z} \in \mathcal{V}} \|\mathbf{Y} - \mathbf{z}\|^2$
- El mínimo de la derecha se alcanza en la proyección ortogonal de  $\mathbf{Y}$  sobre el subespacio generado por las columnas de  $\mathbf{X}$ .
- Podemos escribir a esta proyección como  $\hat{\mathbf{Y}} = \hat{\theta}_1 \mathbf{x}^{(1)} + \hat{\theta}_2 \mathbf{x}^{(2)} + \dots + \hat{\theta}_p \mathbf{x}^{(p)} = \mathbf{X}\hat{\boldsymbol{\theta}}$ , donde  $\mathbf{x}^{(i)}$  son las columnas de  $\mathbf{X}$ .
- Por lo tanto el mínimo de la izquierda se alcanza cuando  $\mathbf{b} = \hat{\boldsymbol{\theta}}$  y por lo tanto  $\hat{\boldsymbol{\theta}}$  es el estimador de mínimos cuadrados. Más aún

$$\begin{aligned} \mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\theta}}) = 0 &\Rightarrow \mathbf{X}^\top \mathbf{Y} = \mathbf{X}^\top \mathbf{X}\hat{\boldsymbol{\theta}} \Rightarrow \mathbf{X}^\top \mathbf{Y} = \mathbf{X}^\top \mathbf{X}\hat{\boldsymbol{\theta}} \Rightarrow \\ \hat{\boldsymbol{\theta}} &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \end{aligned}$$



# Proyecciones

- Una matriz  $P_{n \times n}$  se dice que es de **proyección** si  $P^2 = P$ .  $[P(Px) = Px]$   
El complemento  $P^c := I - P$  es también una proyección  
 $(I - P)(I - P) = I - 2P + P^2 = I - P$ .
- Todo  $x$  se puede expresar como su proyección  $Px$  mas su complemento  $P^c x$ :  $x = Px + P^c x$ .
- Una proyección es **ortogonal** si  $P^T P^c = P^T (I - P) = 0$ . En ese caso, los dos componentes (proyección, complemento) son ortogonales  
 $x^T P^T \cdot P^c x = x^T P^T (I - P) x = 0$ .  
Una proyección **no** ortogonal se denomina **oblicua**.
- **Simetría:** Una proyección es ortogonal sí y sólo si es una matriz simétrica:  
[Ort  $\Rightarrow$  Sim]  $0 = P^T (I - P) = P^T - P^T P = P - P^T P$ , con lo que  $P^T P = P = P^T$ .  
[Sim  $\Rightarrow$  Ort]  $P^T (I - P) = P(I - P) = P - P^2 = P - P = 0$ .



- La matriz **pseudoinversa** de  $A_{n \times m}$ ,  $m \leq n$ ,  $\text{rango}(A) = m$ , es  $A_{m \times n}^\dagger := (A^T A)^{-1} A^T$ .
- La matriz  $P_{n \times n} = A_{n \times m} A_{m \times n}^\dagger = A(A^T A)^{-1} A^T$  es de rango  $m$ , y es una **proyección**.

En efecto  $P^2 = A(A^T A)^{-1} A^T A(A^T A)^{-1} A^T = A(A^T A)^{-1} A^T = P$ .

Además, es una proyección **ortogonal**, porque es  $P$  es una matriz simétrica. Proyecta ortogonalmente sobre el espacio columna de  $A$ : si  $x = A\mu$ ,  $Px = A(A^T A)^{-1} A^T A\mu = A\mu = x$ .

- Proyección sii  $P^2 = P$ .
- Proyección ortogonal, si además  $P^T(I - P) = 0$ , implica simétrica.

# Matriz de proyección

Sea  $\hat{\boldsymbol{\theta}}$  el estimador de mínimos cuadrados. Si  $\mathbf{X}$  tiene rango máximo, la matriz

$$\mathbf{P} = \mathbf{X}(\mathbf{X}^t\mathbf{X})^{-1}\mathbf{X}^t$$

se llama matriz de proyección .

## Observación 4.28

1. Los valores ajustados o predichos se pueden escribir como  $\hat{\mathbf{Y}} = \mathbf{P}\mathbf{Y}$
2. Los residuos se pueden escribir como  $\mathbf{r} = (\mathbf{I} - \mathbf{P})\mathbf{Y}$

## Proof.

1.  $\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\theta}} = \mathbf{X}(\mathbf{X}^t\mathbf{X})^{-1}\mathbf{X}^t\mathbf{Y} = \mathbf{P}\mathbf{Y}$
- 2.

$$\begin{aligned}\mathbf{r} &= \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\theta}} \\ &= \mathbf{Y} - \mathbf{X}(\mathbf{X}^t\mathbf{X})^{-1}\mathbf{X}^t\mathbf{Y} \\ &= \mathbf{Y} - \mathbf{P}\mathbf{Y} = (\mathbf{I} - \mathbf{P})\mathbf{Y}.\end{aligned}$$



# Propiedades de $\mathbf{P}$ e $\mathbf{I} - \mathbf{P}$

## Lemma 4.29

- i)  $\mathbf{P}$  y  $\mathbf{I} - \mathbf{P}$  son simétricas e idempotentes
- ii)  $\text{tr}(\mathbf{P}) = p$  y  $\text{tr}(\mathbf{I} - \mathbf{P}) = n - p$

## Demostración.

Pizarrón



# Insesgadez de los estimadores de mínimos cuadrados

## Theorem 4.30

*Sea  $\mathbf{Y} = \mathbf{X}\boldsymbol{\theta} + \boldsymbol{\varepsilon}$ . Si  $\mathbb{E}(\boldsymbol{\varepsilon}) = \mathbf{0}$ , los estimadores de mínimos cuadrados son insesgados.*

Proof.

El estimador de mínimos cuadrados de  $\theta$  es

$$\begin{aligned}\hat{\theta} &= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} \\ &= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{X} \theta + \varepsilon) \\ &= \theta + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \varepsilon\end{aligned}$$

$$\begin{aligned}\mathbb{E}(\hat{\theta}) &= \theta + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T E(\varepsilon) \\ &= \theta\end{aligned}$$



Observar que no es necesaria la hipótesis de que los errores tengan varianzza constante ni que sean no correlacionados.

# Matriz de covarianza de los estimadores de mínimos cuadrados

## Theorem 4.31

*Sea  $\mathbf{Y} = \mathbf{X}\boldsymbol{\theta} + \boldsymbol{\varepsilon}$ . Si  $\mathbb{E}(\boldsymbol{\varepsilon}) = \mathbf{0}$  y  $\boldsymbol{\Sigma}_{\boldsymbol{\varepsilon}} = \sigma^2\mathbf{I}$ , la matriz de covarianza del estimador de mínimos cuadrados  $\hat{\boldsymbol{\theta}}$  es*

$$\boldsymbol{\Sigma}_{\hat{\boldsymbol{\theta}}} = \sigma^2(\mathbf{X}^T\mathbf{X})^{-1}$$

Proof.

La matriz de covarianza de  $\hat{\boldsymbol{\theta}}$  es

$$\begin{aligned}\boldsymbol{\Sigma}_{\hat{\boldsymbol{\theta}}} &= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \boldsymbol{\Sigma}_{\boldsymbol{\varepsilon}} \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \\ &= \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}\end{aligned}$$

puesto que la matriz de covarianza de  $\boldsymbol{\varepsilon}$  es  $\sigma^2 \mathbf{I}$ , y  $\mathbf{X}^T \mathbf{X}$  y por lo tanto también  $(\mathbf{X}^T \mathbf{X})^{-1}$  son simétricas. □