

Regresión lineal múltiple

IECD

Estimación de σ^2

En regresión simple: $S^2 =$

En $\parallel$ multiple: $S^2 = \frac{\sum (y_i - \bar{y})^2}{n - p}$ o bien:

Lemma 4.32

Bajo los supuestos del modelo lineal

$$s^2 = \frac{\|\mathbf{Y} - \hat{\mathbf{Y}}\|^2}{n - p} = \frac{\|\mathbf{Y} - \mathbf{P}\mathbf{Y}\|^2}{n - p} = \frac{\mathbf{Y}^t(\mathbf{I} - \mathbf{P})\mathbf{Y}}{n - p}$$

es un estimador insesgado de σ^2 .

p : número de coeficientes

OBS: $\|a\|^2 = a^t a = (a_1 \dots a_n) \begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix}$

$$\Rightarrow \|\mathbf{Y} - \hat{\mathbf{Y}}\|^2 = ((\mathbf{I} - \mathbf{P})\mathbf{Y})^t (\mathbf{I} - \mathbf{P})\mathbf{Y} = \mathbf{Y}^t (\mathbf{I} - \mathbf{P})^t (\mathbf{I} - \mathbf{P})\mathbf{Y} = \mathbf{Y}^t (\mathbf{I} - \mathbf{P})\mathbf{Y}$$

$\nearrow$ $\mathbf{I} - \mathbf{P}$ simétrica e idempot.

Proof.

$$\Sigma_Y = \text{Cov}(Y, Y) = \sigma^2 \mathbf{I}$$
$$\mu_Y = E(Y)$$

$$\begin{aligned} \mathbb{E}(\|\mathbf{Y} - \hat{\mathbf{Y}}\|^2) &= \mathbb{E}(\mathbf{Y}^t(\mathbf{I} - \mathbf{P})\mathbf{Y}) \\ &= \text{tr}((\mathbf{I} - \mathbf{P})\Sigma_Y) + \mu_Y^\top (\mathbf{I} - \mathbf{P}) \mu_Y \text{ por Teorema 4.20} \\ &= \text{tr}((\mathbf{I} - \mathbf{P})\sigma^2 \mathbf{I}) + (\mathbf{X}\boldsymbol{\theta})^\top (\mathbf{I} - \mathbf{P})\mathbf{X}\boldsymbol{\theta} \\ &= \sigma^2(n - p) + (\mathbf{X}\boldsymbol{\theta})^\top (\mathbf{I} - \mathbf{P})\mathbf{X}\boldsymbol{\theta} \end{aligned}$$

Para concluir basta observar que el segundo término es 0 ya que

$$(\mathbf{I} - \mathbf{P})\mathbf{X} = \mathbf{X} - \mathbf{P}\mathbf{X} = \mathbf{X} - \underbrace{\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}}_{\mathbf{P}} = \mathbf{X} - \mathbf{X} = \mathbf{0}$$



Teorema 4.20

Sea $\mathbf{v}$ un vector aleatorio con media $\boldsymbol{\mu}$ y matriz de covarianza Σ y sea $\mathbf{A}$ una matriz fija. Entonces

$$\mathbb{E}(\mathbf{v}^T \mathbf{A} \mathbf{v}) = \text{tr}(\mathbf{A}\Sigma) + \boldsymbol{\mu}^T \mathbf{A} \boldsymbol{\mu}$$

Optimalidad del estimador de mínimos cuadrados

Teorema 4.33 (Gauss–Markov)

Bajo los supuestos del modelo lineal con $\mathbf{X}$ de rango máximo, sea $\hat{\boldsymbol{\theta}}$ el estimador de mínimos cuadrados y $\mathbf{c} \in \mathbb{R}^p$. Entonces, entre todos los estimadores insesgados de $\mathbf{c}^\top \boldsymbol{\theta}$, $\mathbf{c}^\top \hat{\boldsymbol{\theta}}$ es el único con varianza mínima.

Proof.

Se puede ver una versión más general en el libro de Seber, pag. 42 (opcional), □

Observación 4.34

Un estimador insesgado de mínima varianza entre todos los estimadores insesgados se suele llamar IMVU, en inglés BLUE.

El modelo lineal con errores normales

Si los errores además de ser independientes con media 0 y varianza σ^2 , son normales, es decir

$$\epsilon_i \sim N(0, \sigma^2) \quad i = 1, \dots, n$$

el modelo lineal puede resumirse de la siguiente forma:

$$\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I})$$

↖ FITAS

En este caso puede demostrarse que el estimador de máxima verosimilitud de $\boldsymbol{\theta}$ coincide con el de mínimos cuadrados.

QBS: Si los errores no son normales, los resultados valen aproximadamente

Inferencia sobre θ_i

Asumiremos que se cumple el modelo lineal con errores normales

Usando que las componentes de $\hat{\boldsymbol{\theta}}$ son combinaciones lineales de variables aleatorias independientes y normalmente distribuidas se puede probar que

$$\hat{\theta}_i \sim N(\theta_i, \sigma^2 c_{ii}),$$

donde $\mathbf{C} = (\mathbf{X}^T \mathbf{X})^{-1}$.

El error estándar de $\hat{\theta}_i$ puede ser estimado por

$$s_{\hat{\theta}_i} = s \sqrt{c_{ii}}$$

Inferencia sobre θ_i

Bajo el supuesto de normalidad de los errores, se puede demostrar que

$$\frac{\hat{\theta}_i - \theta_i}{s_{\hat{\theta}_i}} \sim t_{n-p}$$

De esto se deduce que un intervalo de confianza del $1 - \alpha$ para θ_i es

$$\hat{\theta}_i \pm t_{n-p, \alpha/2} s_{\hat{\theta}_i}$$

Inferencia sobre θ_i

Para testear la hipótesis nula $H_0 : \theta_i = \theta_{i0}$, donde θ_{i0} es un número fijo, podemos utilizar el estadístico

$$t = \frac{\hat{\theta}_i - \theta_{i0}}{s_{\hat{\theta}_i}}$$

Bajo H_0 , este estadístico sigue una distribución t con $n - p$ grados de libertad.

La hipótesis nula que se testea con mayor frecuencia es $H_0 : \theta_i = 0$, la cual establece que x_i no tiene valor predictivo.

Analisis del conjunto de datos fev

Este conjunto de datos consta de 439 observaciones de niños jóvenes de entre 9 y 19 años. El volumen espiratorio forzado (FEV), una medida de la capacidad pulmonar, es la variable de interés y se tienen cuatro variables predictoras: edad, altura (continuas), sexo y tabaquismo (categóricas).

```
#library(mplot)
data(fev)
fev <- fev[fev$age>8,]
head(fev)
```

```
##      age height sex smoke   fev
## 1      9   57.0   0     0 1.708
## 4      9   53.0   1     0 1.558
## 5      9   57.0   1     0 1.895
## 10     9   60.0   0     0 1.942
## 19     9   59.0   1     0 2.352
## 20     9   61.5   1     0 2.604
```

El modelo lineal asume que

$$y_i = \theta_0 + \theta_1 x_{i1} + \theta_2 x_{i2} + \theta_3 x_{i3} + \varepsilon_i$$

Donde

- y_i es el FEV del i -ésimo individuo
- x_{i1} es la edad del i -ésimo individuo
- x_{i2} es la altura del i -ésimo individuo
- x_{i3} es 1 si el i -ésimo individuo es varón y 0 si es mujer
- x_{i4} es 1 si el i -ésimo individuo fuma y 0 si no

y que ε_i son no correlacionados y con varianza constante σ^2 .

¿Cómo se interpretan los parámetros del modelo?

Estimación de los parámetros

```
m1 <- lm(fev~age + height + sex + smoke, data=fev)
summary(m1)
```

```
##
## Call:
## lm(formula = fev ~ age + height + sex + smoke, data = fev)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.53848 -0.26582 -0.00439  0.27123  1.78490
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -6.142998   0.372917  -16.473  < 2e-16 ***
## age           0.075881   0.011969   6.340 5.78e-10 ***
## height       0.128974   0.006795  18.982 < 2e-16 ***
## sex          0.113691   0.046334   2.454  0.0145 *
## smoke       -0.158084   0.065263  -2.422  0.0158 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

- manteniendo fija la altura, el sexo y el hábito de fumar, un aumento de 1 año de edad se asocia con un aumento de FEV estimado de 0.076 litros.
- a igual edad, sexo y condición de fumador, aumentar 1 unidad de altura el incremento del FEV esperado se estima en 0.13 litros.
- manteniendo edad, altura y tabaquismo constantes, se estima que los hombres tienen un FEV promedio mayor que las mujeres por 0.11 litros
- comparando individuos con misma edad, altura y sexo, los fumadores tienen un FEV esperado estimado de 0.16

Evaluando la bondad del ajuste en el modelo lineal

Residuos

Recordemos el vector de residuos,

$$\mathbf{r} = \mathbf{Y} - \hat{\mathbf{Y}} = (\mathbf{I} - \mathbf{P})\mathbf{Y}$$

Utilizaremos los residuos para comprobar los supuestos del modelo lineal

La matriz de covarianza de los residuos es

$$\begin{aligned}\Sigma_{\mathbf{r}} &= (\mathbf{I} - \mathbf{P})(\sigma^2\mathbf{I})(\mathbf{I} - \mathbf{P})^T \\ &= \sigma^2(\mathbf{I} - \mathbf{P})\end{aligned}$$

Vemos que los residuos están correlacionados entre sí y que diferentes residuos tienen varianzas distintas. La varianza del i -ésimo residuo es $\sigma^2(1 - p_{ii})$, donde p_{ii} es el i -ésimo elemento de la diagonal de $\mathbf{P}$.

Residuos estandarizados

Para hacer que los residuos sean comparables entre sí, a menudo se estandarizan. Además, la estandarización coloca a los residuos en la escala familiar correspondiente a una distribución con media 0 y varianza 1, lo que facilita la interpretación de sus magnitudes.

El i -ésimo residuo estandarizado es

$$\frac{Y_i - \hat{Y}_i}{s\sqrt{1 - p_{ii}}}$$


donde p_{ii} es el i -ésimo elemento de la diagonal de $\mathbf{P}$.

Residuos y valores ajustados


Theorem 4.35

Bajo los supuestos del modelo lineal, los residuos correspondientes al estimador de mínimos cuadrados no están correlacionados con los valores ajustados. Lo mismo vale para los residuos estandarizados.

El modelo debería explicar las correlaciones de los residuos (y patrones)



$\hat{y} \rightarrow f(r)$



Proof.

Recordemos

Residuos: $\mathbf{r} = (\mathbf{I} - \mathbf{P})\mathbf{Y}$, valores ajustados: $\hat{\mathbf{Y}} = \mathbf{P}\mathbf{Y}$

Por el teorema 4.22, la matriz de covarianza cruzada de $\mathbf{r}$ y $\hat{\mathbf{Y}}$ es


 $\Sigma_{YZ} = \mathbf{A}\Sigma_{XX}\mathbf{B}^T$

$$\begin{aligned}\Sigma_{\mathbf{r}\hat{\mathbf{Y}}} &= (\mathbf{I} - \mathbf{P})(\sigma^2\mathbf{I})\mathbf{P}^T \\ &= \sigma^2(\mathbf{P}^T - \mathbf{P}\mathbf{P}^T) \\ &= \mathbf{0}\end{aligned}$$

ya que $\mathbf{P}$ es simétrica e idempotente.



Gráficos de residuos

Si el modelo ajusta bien un gráfico de los residuos versus los valores ajustados debería verse como una nube de puntos sin estructura.

Un gráfico de los residuos estandarizados vs los valores ajustados también, pero además deberían estar aproximadamente entre -2.5 y 2.5

Ver gráficos anteriores

Descomposición de la variabilidad de Y

Proposición 4.36

Dado el modelo lineal

$Y_i = \theta_0 + \theta_1 x_{i1} + \cdots + \theta_{p-1} x_{i,p-1} + \varepsilon_i, (i = 1, 2, \dots, n)$ e $\hat{Y}_i$ los valores ajustados utilizando el estimador de mínimos cuadrados, se tiene

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 \quad (2)$$

O de forma equivalente mediante sus siglas en inglés:


$$\text{SST} = \text{SSR} + \text{SSE}$$

Donde cada componente se define como:

- **SST (Suma de cuadrados totales):** $\sum (Y_i - \bar{Y})^2$
- **SSR (Suma de cuadrados de la regresión):** $\sum (\hat{Y}_i - \bar{Y})^2$
- **SSE o RSS (Suma de cuadrados residual o de los errores):** $\sum (Y_i - \hat{Y}_i)^2$

Red line: $y_i - \bar{y}$

Green line: $y_i - \hat{y}_i$



Demostración.

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n \left[(Y_i - \hat{Y}_i) + (\hat{Y}_i - \bar{Y}) \right]^2$$

Desarrollando el binomio al cuadrado obtenemos:

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + 2 \sum_{i=1}^n (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y})$$

Para ver que el 3er termino es 0 veremos que

1. $\sum Y_i - \hat{Y}_i = 0$.
2. $\sum (Y_i - \hat{Y}_i) \hat{Y}_i = 0$.

y esto implica que

$$\sum_{i=1}^n (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y}) = \sum_{i=1}^n (Y_i - \hat{Y}_i) \hat{Y}_i - \sum_{i=1}^n (Y_i - \hat{Y}_i) \bar{Y} \stackrel{=0 \text{ (pensar)}}{=} \sum_{i=1}^n (Y_i - \hat{Y}_i) \hat{Y}_i - \bar{Y} \sum_{i=1}^n (Y_i - \hat{Y}_i) = \sum_{i=1}^n (Y_i - \hat{Y}_i) \hat{Y}_i = 0$$



Demostración.

1. Esto se deduce de que la derivada respecto de θ_0 de $S(\theta) = \sum (Y_i - \theta_0 - \theta_1 x_{i1} - \dots - \theta_{p-1} x_{i,p-1})^2$ es $-\sum (Y_i - \theta_0 - \theta_1 x_{i1} - \dots - \theta_{p-1} x_{i,p-1})$. Como el estimador de mínimos cuadrados minimiza la suma de cuadrados se tiene $\sum (Y_i - \hat{\theta}_0 - \hat{\theta}_1 x_{i1} - \dots - \hat{\theta}_{p-1} x_{i,p-1}) = 0$, es decir $\sum Y_i - \hat{Y}_i = 0$.

El EMC minimiza $S(\theta) = \sum (Y_i - \theta_0 - \dots - \theta_{p-1} x_{i,p-1})^2$

$$\Rightarrow \frac{\partial}{\partial \theta_0} S(\theta) = -2 \sum (Y_i - \theta_0 - \dots - \theta_{p-1} x_{i,p-1})$$

$$\Rightarrow \sum (Y_i - \hat{Y}_i) = 0$$

Demostración.

1. Esto se deduce de que la derivada respecto de θ_0 de $S(\theta) = \sum (Y_i - \theta_0 - \theta_1 x_{i1} - \dots \theta_{p-1} x_{i,p-1})^2$ es $-\sum (Y_i - \theta_0 - \theta_1 x_{i1} - \dots \theta_{p-1} x_{i,p-1})$. Como el estimador de mínimos cuadrados minimiza la suma de cuadrados se tiene $\sum (Y_i - \hat{\theta}_0 - \hat{\theta}_1 x_{i1} - \dots \hat{\theta}_{p-1} x_{i,p-1}) = 0$, es decir $\sum Y_i - \hat{Y}_i = 0$.
2. Esto se debe a que

$$\hat{\mathbf{Y}}^\top \hat{\mathbf{Y}} = (\mathbf{PY})^\top \mathbf{PY} = \mathbf{Y}^\top \mathbf{P}^2 \mathbf{Y} = \mathbf{Y}^\top \mathbf{P} \mathbf{Y} = \mathbf{Y}^\top \hat{\mathbf{Y}}$$

Esto quiere decir que $\sum Y_i \hat{Y}_i = \sum \hat{Y}_i \hat{Y}_i = 0$.



Esta demostración puede encontrarse en la página 112 del libro de Seber.

Coefficiente de correlación múltiple R^2

$$R^2 = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = \frac{\sum_{i=1}^n (Y_i - \bar{Y})^2 - \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$
$$= 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

Bajo el modelo lineal con intercept, se tiene

- Este coeficiente mide qué proporción de la variabilidad de Y es explicado por la regresión. *Basicamente ^{ver} si sirven más las X_i para explicar las Y_i*
- $0 \leq R^2 \leq 1$ (probarlo)
- $R^2 \approx 1 \Rightarrow$ el modelo explica muy bien
- $R^2 \approx 0 \Rightarrow$ el modelo provee un ajuste pobre

Significatividad de la regresión

no me importa si es 0 o no ya que no se relaciona con las X_i $\Rightarrow$ no entro en el test.

Dado el modelo lineal $Y_i = \theta_0 + \theta_1 x_{i1} + \dots + \theta_{p-1} x_{i,p-1} + \varepsilon_i$ ($i = 1, 2, \dots, n$), queremos testear si la regresión sobre las variables regresoras es o no significativa; es decir,

$$H_0 : \theta_1 = \theta_2 = \dots = \theta_{p-1} = 0 \text{ vs } H_1 : \exists i / \theta_i \neq 0$$

Se puede probar que, si se cumple H_0

$$F = \frac{\sum(Y_i - \bar{Y})^2 - \sum(Y_i - \hat{Y}_i)^2}{\sum(Y_i - \hat{Y}_i)^2} \frac{n-p}{p-1} \sim F_{p-1, n-p}$$

De esto se deduce un test para nuestras hipótesis de interés:

Rechazar H_0 si $F > F_{p-1, n-p, \alpha}$.

Estimación del valor esperado de la respuesta para un nuevo $\mathbf{x}_0$

En un futuro valor $\mathbf{x}_0 = (x_{o1}, \dots, x_{op})^t$ independiente de los demás datos, ¿qué esperamos observar? $\mathbb{E}(Y_0) = ?$

Podemos interpretar $\hat{Y}_0$ como

- $\hat{Y}_0 = \widehat{\mathbb{E}(Y_0)} \rightarrow$ Estimación
- $\hat{Y}_0$ predicción de Y_0

Estimación del valor esperado de la respuesta para un nuevo $\mathbf{x}_0$

En un futuro valor $\mathbf{x}_0 = (x_{o1}, \dots, x_{op})^t$ independiente de los demás datos, ¿qué esperamos observar? $\mathbb{E}(Y_0) = ?$

$$\mathbb{E}(Y_0) = \mathbf{x}_0^t \boldsymbol{\theta} \Rightarrow \widehat{\mathbb{E}(Y_0)} = \mathbf{x}_0^t \hat{\boldsymbol{\theta}}$$

Notemos que $\hat{\boldsymbol{\theta}}$ es insesgado, entonces el estimador propuesto será insesgado de $\mathbb{E}(Y_0)$.

Estimación del valor esperado de la respuesta para un nuevo $\mathbf{x}_0$

También podríamos interesarnos realizar un IC para la esperanza de una nueva observación $\mathbf{x}_0$ **independiente de las demás** que cumpla el modelo

$$Y_i = \theta_1 x_{i1} + \theta_2 x_{i2} + \cdots + \theta_p x_{ip} + \epsilon_i$$

en $\mathbf{x}_0 = (x_{o1}, \dots, x_{op})^t$ donde $\epsilon_i \sim N(0, \sigma^2)$ independientes.

Como nuestro estimador es $\mathbf{x}_0^t \hat{\boldsymbol{\theta}}$, tenemos que

$$\mathbf{x}_0^t \hat{\boldsymbol{\theta}} \sim N(\mathbf{x}_0^t \boldsymbol{\theta}, \sigma^2 \mathbf{x}_0^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{x}_0)$$

por lo tanto,

$$T = \frac{\mathbf{x}_0^t \hat{\boldsymbol{\theta}} - \mathbf{x}_0^t \boldsymbol{\theta}}{\sigma \sqrt{\mathbf{x}_0^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{x}_0}} \sim N(0, 1)$$

Se puede ver que

$$T = \frac{\mathbf{x}_0^t \hat{\boldsymbol{\theta}} - \mathbf{x}_0^t \boldsymbol{\theta}}{S \sqrt{\mathbf{x}_0^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{x}_0}} \sim t_{n-p}$$

↳ PASO INTERMEDIO

$$\hat{y}_0 - y_0 = x_0^T \hat{\theta} - x_0^T \theta$$

$$\begin{aligned} \hat{y}_0 &\sim N(x_0^T \theta, \sigma^2 x_0^T (X^T X)^{-1} x_0) & \hat{y}_0 &= x_0^T \hat{\theta} \\ & & E(\hat{y}_0) &= x_0^T \theta \\ y_0 &\sim N(x_0^T \theta, \sigma^2) & V(\hat{y}_0) &= x_0^T V(\hat{\theta}) x_0 \\ & & &= x_0^T (X^T X)^{-1} \sigma^2 x_0 \end{aligned}$$

$$\hat{y}_0 - y_0 \sim N\left(0, \sigma^2 \left(1 + x_0^T (X^T X)^{-1} x_0\right)\right)$$

Estimación del valor esperado de la respuesta para un nuevo $\mathbf{x}_0$

En consecuencia, tenemos el siguiente intervalo de confianza para el valor esperado de la respuesta en $\mathbf{x}_0$

$$\mathbf{x}_0^t \hat{\boldsymbol{\theta}} \pm t_{n-p, \frac{\alpha}{2}} S \sqrt{\mathbf{x}_0^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{x}_0}$$

de nivel exacto $1 - \alpha$.

Predicción de la respuesta para un nuevo $\mathbf{x}_0$

Podríamos estar interesados en la predicción de Y_0 , una nueva observación que cumpla el modelo, y en un intervalo para ella, que llamaremos **intervalo de predicción** o sea un intervalo $[A, B]$ tal que $\mathbb{P}(A \leq Y_0 \leq B) = 1 - \alpha$.

Observemos que el predictor de Y_0 es $\hat{Y}_0 = \mathbf{x}_0^t \hat{\boldsymbol{\theta}}$.

Notemos que

$$E(\hat{Y}_0 - Y_0) = 0$$

¿Qué distribución tiene $\hat{Y}_0 - Y_0$?

Predicción en un nuevo $\mathbf{x}_0$

Tenemos que

$$\begin{aligned}\hat{Y}_0 &\sim N(\mathbf{x}_0^t \boldsymbol{\theta}, \sigma^2 \mathbf{x}_0^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{x}_0) \\ Y_0 &\sim N(\mathbf{x}_0^t \boldsymbol{\theta}, \sigma^2)\end{aligned}$$

y dado que Y_0 es independiente de las restantes Y_i 's con las que estimamos, entonces por la independencia entre estas dos normales queda que

$$\hat{Y}_0 - Y_0 \sim N(0, \sigma^2(1 + \mathbf{x}_0^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{x}_0))$$

→ suma de las varianzas

Por lo tanto, el intervalo de predicción de nivel $1 - \alpha$ estará dado por

$$\left| \hat{Y}_0 \pm t_{n-p, \frac{\alpha}{2}} S \sqrt{1 + \mathbf{x}_0^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{x}_0} \right| \xrightarrow{n \rightarrow \infty} 0$$

¿Cómo es la longitud del intervalo de predicción respecto de la del intervalo para la media?

$$\left| \mathbf{x}_0^t \hat{\boldsymbol{\theta}} \pm t_{n-p, \frac{\alpha}{2}} S \sqrt{\mathbf{x}_0^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{x}_0} \right| \xrightarrow{n \rightarrow \infty} 0$$

Ejemplo (SIGNIFICATIVIDAD DE LA REGRESIÓN)

Volvamos al ejemplo de los datos de FEV VER ANEXO B:5

TEST: $H_0: \theta_1 = \theta_2 = \dots = \theta_{p-1} = 0$ vs. $H_1: \exists i / \theta_i \neq 0$

$p\text{-valor} < 2.2 \cdot 10^{-16} \Rightarrow$ se rechaza H_0

La regresión es significativa

Int para θ_1 : $\hat{\theta}_1 \pm t_{n-5, \frac{\alpha}{2}} \hat{se}_{\hat{\theta}_1}$

FIN CLASE 13.