

Covariables Aleatorias

Covariables Aleatorias

Asumimos que tenemos:

$$(Y_1, \mathbf{X}_1), \dots, (Y_n, \mathbf{X}_n)$$

- **Independencia:**

$(Y_1, \mathbf{X}_1), \dots, (Y_n, \mathbf{X}_n)$ son vectores independientes.

- **Esperanza Condicional:** $(Y, \mathbf{X}) \sim (Y_i, \mathbf{X}_i)$

$$\mathbb{E}(Y \mid \mathbf{X} = \mathbf{x}) = \mathbf{x}^t \boldsymbol{\theta}$$

- **Homoscedasticidad:**

$$\mathbb{V}(Y \mid \mathbf{X} = \mathbf{x}) = \sigma^2$$

Covariables Aleatorias

Cuando asumimos normalidad, podemos escribir

- $Y_i \mid \mathbf{X}_i = \mathbf{x} \sim N(\mathbf{x}^t \boldsymbol{\theta}, \sigma^2), i = 1, \dots, n$

o si lo pensamos en términos de la notación matricial

- $\mathbf{Y} \mid \mathbf{X} \sim N(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I})$

- Dado que al tomar la condicional a las covariables es como tomar las covariables como fijas, podemos aprovechar lo que hemos desarrollado hasta ahora.

Evaluación y selección de modelos

Esta parte está basada en el Cap 5 del libro de James, Witten, Hastie y Tibshirani

Error cuadrático medio de entrenamiento

El estimador de mínimos cuadrados minimiza

$$ECM = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

El ECM se calcula utilizando los mismos datos que se usaron para ajustar el modelo, llamados datos de entrenamiento, por lo que, para ser más exactos, debería denominarse ECM de entrenamiento.

Sin embargo, en general, no nos importa realmente qué tan bien funciona el método en los datos de entrenamiento, sino cuán buenas serán las predicciones en nuevos datos.

$$\hat{\Theta} = \operatorname{argmin} \frac{1}{n} \sum (y_i - \theta_0 - \theta_1 x_{i,1} - \dots - \theta_{p-1} x_{i,p-1})$$

$$\widehat{ECM} = \frac{1}{n} \sum (y_i - \underbrace{(\hat{\theta}_0 + \hat{\theta}_1 x_{i,1} + \dots + \hat{\theta}_{p-1} x_{i,p-1})}_{\hat{y}_i})^2$$

• In R:

`lm.fit $ fitted values = predict(lm.fit)`

Ejemplo: Varios modelos para el conjunto de datos Auto y sus ECM de entrenamiento


```
>library(ISLR)
>attach(Auto)
♥> lm.fit = lm(mpg ~ horsepower, data = Auto)
> mean((mpg - predict(lm.fit, Auto))^2)
[1] 23.94366
●> lm.fit2 = lm(mpg ~ poly(horsepower, 2), data = Auto)
> mean((mpg - predict(lm.fit2, Auto))^2)
[1] 18.98477
●> lm.fit3 = lm(mpg ~ poly(horsepower, 3), data = Auto)
> mean((mpg - predict(lm.fit3, Auto))^2)
[1] 18.94499
●> lm.fit10 = lm(mpg ~ poly(horsepower, 10), data = Auto)
> mean((mpg - predict(lm.fit10, Auto))^2)
[1] 18.00953
```

• l_m, Fit2 → MODELO
CUADRÁTICO: $y_i = \theta_0 + \theta_1 x_{i,1} + \theta_2 x_{i,2}^2 + \varepsilon_i$

Ejemplo: Conjunto de datos Auto y valores predichos por distintos modelos

```
> plot(horsepower, mpg)
> horsepowerord <- sort(horsepower)
> predlm <- predict(lm.fit, newdata =
  data.frame(horsepower=horsepowerord))
> lines(horsepowerord, predlm, col="red", lwd=2)
> predlm2 <- predict(lm.fit2, newdata =
  data.frame(horsepower=horsepowerord))
> lines(horsepowerord, predlm2, col="blue", lwd=2)
> predlm3 <- predict(lm.fit3, newdata =
  data.frame(horsepower=horsepowerord))
> lines(horsepowerord, predlm3, col="green4", lwd=2)
> predlm10 <- predict(lm.fit10, newdata =
  data.frame(horsepower=horsepowerord))
> lines(horsepowerord, predlm10, col="purple", lwd=2)
```

Ejemplo: Conjunto de datos Auto y valores predichos por distintos modelos



Error cuadrático medio de testeo

Lo que en realidad nos interesa minimizar es el ECM de testeo:

$$\mathbb{E} \left(\left(Y_0 - \hat{Y}_0 \right)^2 \right),$$

donde Y_0 es la respuesta para una nueva observación $\mathbf{x}_0$, independiente de las que se usaron para entrenar (o ajustar) el modelo e $\hat{Y}_0$ una predicción usando el modelo ajustado.

Si tenemos m observaciones que no se usaron para calcular el estimador $\hat{\boldsymbol{\theta}}$, podemos calcular el ECM de testeo como

$$\frac{1}{m} \sum_{i=1}^m (Y_{0i} - \hat{Y}_{0i})^2 = \frac{1}{m} \sum_{i=1}^m (Y_{0i} - \mathbf{x}_{0i}^t \hat{\boldsymbol{\theta}})^2$$

Este es el error que nos interesa que sea pequeño.

El compromiso entre sesgo y varianza

Observación 4.37

Supongamos que se tienen n observaciones para las que se asume cierto modelo (por ejemplo un modelo lineal) y en base a él se calcula una predicción para la respuesta Y_0 correspondiente a una nueva observación $\mathbf{x}_0$ independiente de las anteriores. Para predecir, usamos el modelo asumido, pero en realidad, lo que vale es $Y_0 = f(\mathbf{x}_0) + \epsilon_0$, con $\mathbb{V}(\epsilon_0) = \sigma^2$. Entonces

$$\mathbb{E} \left(\left(Y_0 - \hat{Y}_0 \right)^2 \right) = \text{Var}(\hat{Y}_0) + (\text{Sesgo}(\hat{Y}_0))^2 + \sigma^2, \quad (3)$$

donde $\text{Sesgo}(\hat{Y}_0) = \mathbb{E}(\hat{Y}_0) - \mathbb{E}(Y_0)$

Típicamente, a mayor complejidad en el modelo, menor sesgo y mayor varianza.

El ECM de testeo esperado nunca puede estar por debajo de $\mathbb{V}(\epsilon_0)$.

Descomposición sesgo-varianza

NO ENTRA

Demostración. (Elements of statistical learning)

$$\begin{aligned} E \left[(Y_0 - \hat{Y}_0)^2 \right] &= E \left[\left((Y_0 - E(\hat{Y}_0)) + (E(\hat{Y}_0) - \hat{Y}_0) \right)^2 \right] \\ &= E \left[(Y_0 - E(\hat{Y}_0))^2 \right] \\ &\quad + E \left[(E(\hat{Y}_0) - \hat{Y}_0)^2 \right] \\ &\quad + 2E \left[(Y_0 - E(\hat{Y}_0)) (E(\hat{Y}_0) - \hat{Y}_0) \right] \end{aligned}$$

Analicemos cada uno de los tres términos por separado :

Demostración (continuación).

1. Primer Término:

$$\begin{aligned}\mathbb{E} \left[(\underbrace{Y_0}_{f(\mathbf{x}_0)} - E(\hat{Y}_0))^2 \right] &= \mathbb{E} \left[(\underbrace{(f(\mathbf{x}_0) + \epsilon_0)}_{f(\mathbf{x}_0)} - \mathbb{E}(\hat{Y}_0))^2 \right] \\&= \mathbb{E} \left[(f(\mathbf{x}_0) - \mathbb{E}(\hat{Y}_0) + \epsilon_0)^2 \right] \\&= \mathbb{E} \left((f(\mathbf{x}_0) - \mathbb{E}(\hat{Y}_0))^2 + \epsilon_0^2 + 2(f(\mathbf{x}_0) - \mathbb{E}(\hat{Y}_0))\epsilon_0 \right) \\&= (f(\mathbf{x}_0) - \mathbb{E}(\hat{Y}_0))^2 + \mathbb{E}(\epsilon_0^2) + 2(f(\mathbf{x}_0) - \mathbb{E}(\hat{Y}_0))\mathbb{E}(\epsilon_0) \\&= (f(\mathbf{x}_0) - \mathbb{E}(\hat{Y}_0))^2 + \mathbb{E}(\epsilon_0^2) \\&= (\mathbb{E}(\hat{Y}_0) - \mathbb{E}(Y_0))^2 + \mathbb{E}[\epsilon_0^2] \\&= (\text{Sesgo}(\hat{Y}_0))^2 + \sigma^2.\end{aligned}$$

Demostración (continuación).

2. Segundo Término:

$$\mathbb{E} \left[(\hat{Y}_0 - \mathbb{E}(\hat{Y}_0))^2 \right] = \mathbb{V}(\hat{Y}_0)$$

3. Tercer Término: La nueva observación Y_0 (y su error ϵ_0) es independiente de los datos históricos $\mathbf{Y}$ con los que se entrenó el modelo para obtener $\hat{\theta}$. Por lo tanto, la esperanza del producto es el producto de las esperanzas:

$$\begin{aligned} & 2\mathbb{E} \left[(Y_0 - \mathbb{E}(\hat{Y}_0)) \right] \cdot \mathbb{E} \left[(\mathbb{E}(\hat{Y}_0) - \hat{Y}_0) \right] \\ &= 2\mathbb{E} \left[(Y_0 - \mathbb{E}(\hat{Y}_0)) \right] \cdot \left(\mathbb{E}(\hat{Y}_0) - \mathbb{E}(\hat{Y}_0) \right) = 0 \end{aligned}$$

indep de Y






Figure: Error de entrenamiento y testeo, como función de la complejidad del modelo (del libro Elements of Statistical Learning, de Hastie y Tibshirani)

Métodos de validación cruzada (CV)

Para poder estimar el error de testeo, se excluye un subconjunto de las observaciones del proceso de estimación y ajuste, luego se aplica el método de predicción a aquellas observaciones que fueron excluidas y se mide la bondad de esas predicciones

Método 1: una muestra de entrenamiento - una muestra de validación

Se divide aleatoriamente el conjunto de datos disponible en dos partes: un conjunto de entrenamiento y un conjunto de validación. El modelo se ajusta en el conjunto de entrenamiento, y el modelo ajustado se utiliza para predecir las respuestas de las observaciones en el conjunto de validación. El ECM resultante en el conjunto de validación proporciona una estimación de la tasa de error de testeo

Dos problemas:

- los resultados dependen de la partición
- el modelo se ajusta usando un conjunto de datos más pequeño que el disponible, por lo tanto los estimadores funcionarán un poco peor que si uso todos los datos.

Ejemplo del método 1: Conjunto de datos auto

```
> set.seed(1)
```

```
> train = sample(392, 196)
```

```
> lm.fit = lm(mpg ~ horsepower, data = Auto,  
subset = train)
```

```
> mean((mpg - predict(lm.fit, Auto))TEST[-train]^2)
```

```
[1] 23.26601
```

```
> lm.fit2 = lm(mpg ~ poly(horsepower, 2), data = Auto,  
subset = train)
```

```
> mean((mpg - predict(lm.fit2, Auto))[-train]^2)
```

```
[1] 18.71646
```

```
> lm.fit3 = lm(mpg ~ poly(horsepower, 3), data = Auto,  
subset = train)
```

```
> mean((mpg - predict(lm.fit3, Auto))[-train]^2)
```

```
[1] 18.79401
```

```
> lm.fit10 = lm(mpg ~ poly(horsepower, 10), data = Auto,  
subset = train)
```

```
> mean((mpg - predict(lm.fit10, Auto))[-train]^2)
```

```
[1] 22.867
```

ECM
DE
TESTE

MEJOR

Ejemplo del método 1: Conjunto de datos auto

```
> set.seed(2)
> train = sample(392, 196)
> lm.fit = lm(mpg ~ horsepower, data = Auto,
  subset = train)
> mean((mpg - predict(lm.fit, Auto))[-train]^2)
[1] 25.72651
> lm.fit2 = lm(mpg ~ poly(horsepower, 2), data = Auto,
  subset = train)
> mean((mpg - predict(lm.fit2, Auto))[-train]^2)
[1] 20.43036
> lm.fit3 = lm(mpg ~ poly(horsepower, 3), data = Auto,
  subset = train)
> mean((mpg - predict(lm.fit3, Auto))[-train]^2)
[1] 20.38533
> lm.fit10 = lm(mpg ~ poly(horsepower, 10), data = Auto,
  subset = train)
> mean((mpg - predict(lm.fit10, Auto))[-train]^2)
[1] 22.07439
```

MEJOR

Ejemplo del método 1: Conjunto de datos auto

En el ejemplo el menor ECM de testeo estimado se alcanza con el modelo cuadrático, con una de las semillas y con el modelo cúbico con la otra semilla

Método 2: Validación cruzada dejando uno afuera (LOOCV)

Al igual que el método 1, en LOOCV se divide el conjunto de observaciones en dos partes. Sin embargo, en lugar de crear dos subconjuntos de tamaño comparable, se utiliza una sola observación (x_1, y_1) para el conjunto de validación, y las observaciones restantes $\{(x_2, y_2), \dots, (x_n, y_n)\}$ componen el conjunto de entrenamiento.

El modelo se ajusta con las $n - 1$ observaciones de entrenamiento, y se realiza una predicción $\hat{y}_1$ para la observación excluida utilizando su valor x_1 . Dado que (x_1, y_1) no se empleó en el proceso de ajuste, $ECM_1 = (y_1 - \hat{y}_1)^2$ proporciona una estimación aproximadamente insesgada del error de testeo. Pero, aunque ECM_1 es insesgado para el error de testeo, es una estimación deficiente porque resulta altamente variable al basarse en una única observación (x_1, y_1) .

Método 2: Validación cruzada dejando uno afuera (LOOCV) (continuación)

Para disminuir la varianza, podemos repetir el procedimiento seleccionando (x_2, y_2) para los datos de validación, entrenando el procedimiento de aprendizaje estadístico con las $n - 1$ observaciones $\{(x_1, y_1), (x_3, y_3), \dots, (x_n, y_n)\}$, y calculando $ECM_2 = (y_2 - \hat{y}_2)^2$. Repetir este enfoque n veces produce n errores cuadráticos, $ECM_1, \dots, ECM_n$. La estimación de LOOCV para el ECM de testeo es el promedio de estas n estimaciones del error de testeo:

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n ECM_i$$

Desventajas: LOOCV requiere ajustar el modelo n veces. Esto puede ser computacionalmente costoso.

Ejemplo del método 2: Conjunto de datos auto

GENERALIZED LM, sin distribución declarada es = lm pero tiene cv.

```
> glm.fit <- glm(mpg~horsepower, data = Auto)
> cv.err <- cv.glm(Auto, glm.fit, K=N default)
> cv.err$delta
[1] 24.23151 24.23114
> cv.error = rep(0, 4)
> grados <- c(1, 2, 3, 10)
> for (i in 1:4) {
+   glm.fit <- glm(mpg~poly(horsepower, grados[i]), data = Auto)
+   cv.error[i] <- cv.glm(Auto, glm.fit)$delta[1]
+ }
> cv.error
[1] 24.23151 19.24821 19.33498 19.49093
```

El menor ECM de testeo estimado se alcanza con el modelo cuadrático

Método 3: Validación cruzada de k -partes (k-fold CV)

Se divide aleatoriamente el conjunto de observaciones en k partes o grupos, de tamaño aproximadamente igual. El primer grupo se usa como un conjunto de validación, y el método se ajusta con los $k - 1$ grupos restantes. Luego, se calcula el error cuadrático medio, MSE_1 , en las observaciones del grupo que se dejó fuera.

Este procedimiento se repite k veces; cada vez, se toma a un grupo diferente de observaciones como conjunto de validación.

Resultado: k estimaciones del error de testeo:

$MSE_1, MSE_2, \dots, MSE_k$.

Estimación del error de testeo:


$$CV_{(k)} = \frac{1}{k} \sum_{i=1}^k ECM_i$$

Método 3: Validación cruzada de k -partes (k-fold CV)(Continuación)

Observar que LOOCV es validación cruzada de n partes.

En la práctica, típicamente se utiliza $k = 5$ o $k = 10$.

Método 3: Validación cruzada de k -partes (k-fold CV)



Ejemplo del método 3: Conjunto de datos auto

```
> glm.fit <- glm(mpg ~ poly(horsepower ,2),data=Auto)
> cv.glm(Auto, glm.fit, K=10)$delta
[1] 19.2994 19.2826
> ies <- c(1,2,3,10)
> set.seed(17)
> cv.error.ies <- rep (0, 4)
> for (i in 1:4){
+   glm.fit <- glm(mpg ~ poly(horsepower ,i),data=Auto)
+   cv.error.ies[i] <- cv.glm(Auto, glm.fit, K=10)$delta
+ }
> cv.error.ies
[1] 24.20520 19.18924 19.30662 19.33799
```

A ECM corregido (no lo vamos a ver)

grados

El menor ECM de testeo estimado se alcanza con el modelo cuadrático

Comparación de métodos de CV

El método 3 (k-fold CV) con k entre 5 y 10 es el más recomendable, teniendo en cuenta el tiempo de cómputo y su precisión y exactitud como estimador del error de testeo.