

# Métodos robustos

(NO ENTRA)

June 7, 2026

# Contenidos

El modelo de regresión lineal con covariables aleatorias

Outliers en el análisis de regresión.

M-estimadores de regresión

# Ejemplo: Datos de salinidad

Este conjunto de datos fue introducido en Rupert y Carrol (1980) y contiene mediciones de la salinidad y el caudal de agua en la desembocadura del seno del Pamlico en Carolina del Norte. Se quiere predecir la salinidad (`sal`) usando como covariables:

- `lag`: la salinidad dos semanas antes,
- `trend`: cantidad de periodos de dos semanas desde el comienzo de la primavera,
- `dis`: caudal en la desembocadura.

El conjunto de datos original fue ligeramente modificado con fines didácticos.

## Ejemplo: Datos de salinidad

|    | lag   | trend | dis   | sal   |
|----|-------|-------|-------|-------|
| 1  | 8.20  | 4     | 23.00 | 7.60  |
| 2  | 7.60  | 5     | 23.87 | 7.70  |
| 3  | 4.60  | 0     | 26.42 | 4.30  |
| 4  | 4.30  | 1     | 24.87 | 5.90  |
| 5  | 5.90  | 2     | 32.00 | 12.00 |
| 6  | 5.00  | 3     | 24.20 | 6.50  |
| 7  | 6.50  | 4     | 23.21 | 8.30  |
| 8  | 8.30  | 5     | 21.86 | 8.20  |
| 9  | 10.10 | 0     | 22.27 | 13.20 |
| 10 | 13.20 | 1     | 23.83 | 12.60 |
| 11 | 12.60 | 2     | 25.14 | 10.40 |
| 12 | 10.40 | 3     | 22.43 | 10.80 |
| 13 | 10.80 | 4     | 21.79 | 13.10 |
| 14 | 13.10 | 5     | 22.38 | 12.30 |
| 15 | 13.30 | 0     | 23.93 | 10.40 |
| 16 | 10.40 | 1     | 33.44 | 10.50 |
| 17 | 10.50 | 2     | 24.86 | 7.70  |
| 18 | 7.70  | 3     | 22.69 | 9.50  |
| 19 | 10.00 | 0     | 21.79 | 12.00 |
| 20 | 12.00 | 1     | 22.04 | 12.60 |
| 21 | 12.10 | 4     | 21.03 | 13.60 |
| 22 | 13.60 | 5     | 21.00 | 14.10 |
| 23 | 15.00 | 0     | 25.86 | 13.50 |
| 24 | 13.50 | 1     | 26.29 | 11.50 |
| 25 | 11.50 | 2     | 22.93 | 12.00 |
| 26 | 12.00 | 3     | 21.31 | 13.00 |
| 27 | 13.00 | 4     | 20.77 | 14.10 |
| 28 | 14.10 | 5     | 21.39 | 15.10 |

# El modelo de regresión lineal

Supongamos que nuestras observaciones son de la forma

$$(x_{11}, x_{12}, \dots, x_{1p}, y_1) = (\mathbf{x}_1, y_1)$$

$$(x_{21}, x_{22}, \dots, x_{2p}, y_2) = (\mathbf{x}_2, y_2)$$

$\dots$

$$(x_{n1}, x_{n2}, \dots, x_{np}, y_n) = (\mathbf{x}_n, y_n)$$

# El modelo de regresión lineal

Supongamos que nuestras observaciones son de la forma

$$(x_{11}, x_{12}, \dots, x_{1p}, y_1) = (\mathbf{x}_1, y_1)$$

$$(x_{21}, x_{22}, \dots, x_{2p}, y_2) = (\mathbf{x}_2, y_2)$$

...

$$(x_{n1}, x_{n2}, \dots, x_{np}, y_n) = (\mathbf{x}_n, y_n)$$

Asumimos que las observaciones son  $n$  realizaciones independientes de un vector aleatorio  $(X_1, \dots, X_p, Y) = (\mathbf{X}, Y)$  que cumple

$$\begin{cases} Y = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots \theta_p x_p + \epsilon \\ E(\epsilon|\mathbf{x}) = 0 \\ V(\epsilon|\mathbf{x}) = \sigma^2 \end{cases}$$

## Ejemplo: Datos de salinidad

Para cada una de las 28 observaciones, es decir para  $i = 1, \dots, 28$ , se tiene

- $x_{i1} = \text{lag}_i = \text{salinidad dos semanas antes,}$
- $x_{i2} = \text{trend}_i = \text{cantidad de periodos de dos semanas desde el comienzo de la primavera,}$
- $x_{i3} = \text{dis}_i = \text{caudal en la desemocadura}$
- $y_i = \text{sal}_i = \text{salinidad}$

Se asume que existen constantes  $\theta_0$ ,  $\theta_1$ ,  $\theta_2$  y  $\theta_3$  y un error aleatorio  $\epsilon_i$  tales que

$$\begin{cases} y = \theta_0 + \theta_1 \text{lag}_i + \theta_2 \text{trend}_i + \theta_3 \text{dis}_i + \epsilon_i \\ E(\epsilon_i) = 0 \\ V(\epsilon_i) = \sigma^2 \end{cases}$$

# Outliers

Los conjuntos de datos rara vez verifican completamente las hipótesis del modelo lineal.







# Outliers

Los conjuntos de datos rara vez verifican completamente las hipótesis del modelo lineal.

Cuando algunos datos se alejan del modelo los efectos en el estimador de mínimos cuadrados pueden ser dramáticos.

# Ejemplos de regresión simple.



# Métodos clásicos de detección de outliers

Las estadísticas clásicamente usados medir la influencia de un punto  $(\mathbf{x}_i, y_i)$  se basan en comparar el estimador de mínimos cuadrados basado en el conjunto completo de datos con el estimador de mínimos cuadrados basado en el conjunto de datos omitiendo la observación  $(\mathbf{x}_i, y_i)$ .

# Distancia de Cook

Sea  $\hat{\boldsymbol{\theta}}$  el estimador de mínimos cuadrados calculado usando todas las observaciones y  $\hat{\boldsymbol{\theta}}^{(i)}$  el estimador de mínimos cuadrados calculado sin la observación  $i$ . Además notemos

$$\hat{y} = \hat{\theta}_0 - \hat{\theta}_1 x_{i1} - \dots \hat{\theta}_p x_{ip},$$

$$\hat{y}^{(i)} = \hat{\theta}_0^{(i)} - \hat{\theta}^{(i)} x_{i1} - \dots \hat{\theta}_p^{(i)} x_{ip}$$

La distancia de Cook  $D_i$  se define como

$$\frac{1}{ps^2} \left\| \hat{y}^{(i)} - \hat{y} \right\|^2$$

# Desventajas de la distancia de Cook

La distancia de Cook puede detectar puntos influyentes en casos sencillos pero puede fallar debido a que

- $s^2$  resulta influenciado por outliers.
- Puede haber más de un outlier de alto leverage que influyen a  $\hat{y}^{(i)}$ . Si estos outliers son similares puede producirse enmascaramiento, es decir, algunos outliers influyen los estadísticos usados para detectar a otros, "enmascarándolos".

# Residuos estudentizados

Recordar la definición de los residuos:  $r_i = y_i - \hat{y}_i$  donde  $\hat{y}_i = \hat{\theta}_0 - \sum_{j=1}^p \hat{\theta}_j x_{ij}$  y la de los residuos estandarizados:

$$\frac{r_i}{s\sqrt{1 - p_{ii}}},$$

donde  $p_{ii}$  son los elementos de la diagonal de la matriz de proyección  $\mathbf{P}$ .

Los residuos estudentizados son:

$$t_i = \frac{r_i}{s_{(i)}\sqrt{1 - p_{ii}}},$$

donde  $s_{(i)}$  se calcula como  $s$ , pero omitiendo la observación  $i$ .

Bajo normalidad, se puede probar que  $t_i \sim t_{n-1}$  y por lo tanto, un test para detectar outliers es decidir que la observación  $i$  es un outlier si  $|t_i| > t_{n-1\alpha/2}$ .

# Desventajas del test para residuos estudentizados

El test para residuos estudentizados puede detectar outliers en casos sencillos pero puede fallar cuando hay varios outliers y se produce enmascaramiento.

# Desventajas de los métodos clásicos de detección de outliers

Hay una amplia literatura acerca de los métodos de detección de outliers.

Sin embargo

- pueden fallar cuando hay enmascaramiento
- La distribución de los estimadores resultantes es desconocida.
- La variabilidad de los estimadores puede ser subestimada.
- Una vez que retiramos un outlier, otros pueden aparecer y no está claro cuándo parar



# Ejemplo: Datos de salinidad

Mediciones de la salinidad y el caudal de agua en la desembocadura del seno de Pamlico en Carolina del Norte. Se quiere predecir la salinidad (`sal`) usando como covariables:

- `lag`: la salinidad dos semanas antes,
- `trend`: cantidad de periodos de dos semanas desde el comienzo de la primavera,
- `dis`: caudal en la desembocadura.

```
> salinitymod <- read.table("salinitymod.txt")
> sallm <- lm(Y~x1+x2+x3, data = salinitymod)
> summary(sallm)
```

Call:

```
lm(formula = Y ~ X1 + X2 + X3, data = salinitymod)
```

Residuals:

| Min     | 1Q      | Median  | 3Q     | Max    |
|---------|---------|---------|--------|--------|
| -3.1418 | -1.3792 | -0.0378 | 0.9468 | 4.5886 |

Coefficients:

|             | Estimate | Std. Error | t value | Pr(> t )     |
|-------------|----------|------------|---------|--------------|
| (Intercept) | 3.38708  | 3.95860    | 0.856   | 0.401        |
| X1          | 0.72153  | 0.11554    | 6.245   | 1.87e-06 *** |
| X2          | 0.13309  | 0.21200    | 0.628   | 0.536        |
| X3          | -0.01559 | 0.13231    | -0.118  | 0.907        |

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Coefficients:

Estimate Std. Error t value Pr(>|t|)

(Intercept) 3.38708 3.95860 0.856 0.401

X1 0.72153 0.11554 6.245 1.87e-06 \*\*\*

X2 0.13309 0.21200 0.628 0.536

X3 -0.01559 0.13231 -0.118 0.907

---


Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.771 on 24 degrees of freedom


Multiple R-squared: 0.6483, Adjusted R-squared: 0.6044

F-statistic: 14.75 on 3 and 24 DF, p-value: 1.184e-05

## Residuos vs predichos en los datos salinity



# Distancias de Cook en los datos salinity



# Distancias de Cook en los datos salinity

La mayoría de los autores sugieren que observaciones con distancias de Cook mayores a 1 deben considerarse peligrosamente influyentes.

En nuestro ejemplo la única que cumple esa condición es la observación número 5

# El estimador L1

Recordemos la definición del estimador de mínimos cuadrados

$$\hat{\theta} = \arg \min_{\theta} \sum_{i=1}^n \left( y_i - \theta_0 - \sum_{j=1}^p \theta_j X_{ij} \right)^2$$


El estimador L1 se define como:

$$\hat{\theta} = \arg \min_{\theta} \sum_{i=1}^n \left| y_i - \theta_0 - \sum_{j=1}^p \theta_j x_{ij} \right|$$

El estimador L1 puede usarse en el caso de que no haya puntos de alto leverage.

Cuando las covariables son aleatorias, puede haber puntos de alto leverage y en estos casos el estimador L1 no es robusto.

# Cuadrado y módulo





# El estimador LMS (*Least Median of Squares*)

Propuesto por Rousseeuw (1984), el estimador LMS se define como

$$\hat{\boldsymbol{\theta}} = \arg \min_{\boldsymbol{\theta}} \left\{ \text{med} \left( y_i - \theta_0 - \sum_{j=1}^p \theta_j x_{ij} \right)^2 \right\}$$

Este estimador es altamente robusto pero tiene la desventaja de que, **cuando no hay outliers**, su desempeño, comparado con el estimador de mínimos cuadrados **es muy malo**.

# M-estimadores de regresión

Los M-estimadores de regresión se definen como

$$\hat{\boldsymbol{\theta}} = \arg \min_{\boldsymbol{\theta}} \sum_{i=1}^n \rho \left( \frac{y_i - \theta_0 - \sum_{j=1}^p \theta_j x_{ij}}{\hat{\sigma}} \right)$$

donde  $\hat{\sigma}$  es un estimador de la escala de los errores (también debe ser robusto, por ejemplo, la MAD).


En el estimador de mínimos cuadrados  $\rho(x) = x^2$

En el estimador L1  $\rho(x) = |x|$

**Observación:** El estimador de mínimos cuadrados, el estimador L1 y el estimador LMS no dependen de  $\hat{\sigma}$ , por lo tanto se pueden calcular sin un estimador de escala previo.

```
library(robustbase)
plot(x, Mchi(x, 3, "Huber"),col=3,type="l")
lines(x,abs(x),col=2)
lines(x,x^2)
lines(x, Mchi(x, 3, "bisquare"),col=4)
legend("top",c("cuadratica","modulo","huber","bicuadrada"),
```

# Funciones $\rho$ más usadas



# Funciones $\rho$ más usadas

$\rho$  de Huber:

$$\rho(x) = \begin{cases} x^2 & \text{si } x \leq k \\ 2k|x| - k^2 & \text{si } x > k \end{cases}$$

•  $\rho$  bicuadrada:

$$\rho(x) = \begin{cases} 1 - \left(1 - \left(\frac{x}{k}\right)^2\right)^3 & \text{si } x \leq k \\ 1 & \text{si } x > k \end{cases}$$

Ambas dependen de una constante de calibración  $k$ .

# Ecuaciones de estimación

Derivando se obtienen las ecuaciones de estimación para el estimador de mínimos cuadrados (ecuaciones normales):


$$\sum_{i=1}^n \left( y_i - \theta_0 - \sum_{j=1}^p \theta_j x_{ij} \right) \mathbf{x}_i = 0$$

para M-estimadores :

$$\sum_{i=1}^n \psi \left( \frac{y_i - \theta_0 - \sum_{j=1}^p \theta_j x_{ij}}{\hat{\sigma}} \right) \mathbf{x}_i = 0$$

donde  $\psi = \rho'$

# Funciones $\psi$ más usadas



Los M-estimadores correspondientes a funciones  $\psi$  monótonas se llaman M-estimadores monótonos.

Los M-estimadores correspondientes a funciones  $\psi$  que tienden a cero en  $-\infty$  y  $+\infty$  se llaman M-estimadores redescendientes.



Los M-estimadores correspondientes a funciones  $\psi$  monótonas se llaman M-estimadores monótonos.

Los M-estimadores correspondientes a funciones  $\psi$  que tienden a cero en  $-\infty$  y  $+\infty$  se llaman M-estimadores redescendientes.

Para protegerse de los outliers de alto leverage y del efecto de enmascaramiento resulta imprescindible usar M-estimadores redescendientes.

## ¿Cómo se calculan los M-estimadores?

1. Calcular un estimador inicial robusto que no necesite un estimador de escala previo. Llamémoslo  $\hat{\boldsymbol{\theta}}_0$ .
2. Calcular los residuos correspondientes al ajuste hecho en el paso anterior :

$$r_i = y_i - \theta_0 - \sum_{j=1}^p \theta_j x_{ij}$$

y luego calcular un estimador robusto de la escala de los residuos,  $\hat{\sigma}$ .

3. Encontrar una solución de

$$\sum_{i=1}^n \psi \left( \frac{y_i - \theta_0 - \sum_{j=1}^p \theta_j x_{ij}}{\hat{\sigma}} \right) \mathbf{x}_i = 0$$

usando un método iterativo comenzando en  $\hat{\boldsymbol{\theta}}_0$ . El método iterativo se llama mínimos cuadrados pesados iterados (IRWLS).

En el paso 1 podría usarse el LMS ( o el estimador L1 en el caso en que las covariables sean fijas y sin puntos influyentes)y en el paso 2 la MAD.

Yohai (1987) propone un método para llevar a cabo la estimación para obtener una robustez y eficiencia óptimas.

Los estimadores calculados con este método se llaman MM-estimadores.

Ver detalles en Maronna, Martin y Yohai (2019).

LIBRERIAS R:

-RobstatTM

# Ajuste robusto en el ejemplo salinity

Call:

```
lmrobdetMM(formula = Y ~ X1 + X2 + X3, data = salinitymod)
```

Residuals:

| Min     | 1Q      | Median | 3Q     | Max     |
|---------|---------|--------|--------|---------|
| -2.3933 | -0.3161 | 0.1239 | 0.7924 | 11.7040 |

Coefficients:

Estimate Std. Error t value Pr(>|t|)

|                                      |          |         |        |          |     |
|--------------------------------------|----------|---------|--------|----------|-----|
| $\hat{\theta}_{0,rob}$ = (Intercept) | 23.34585 | 4.10617 | 5.686  | 7.42e-06 | *** |
| $\hat{\theta}_{1,rob}$ X1            | 0.70681  | 0.07072 | 9.994  | 4.97e-10 | *** |
| X2                                   | -0.26738 | 0.13905 | -1.923 | 0.0664   | .   |
| X3                                   | -0.83392 | 0.15597 | -5.347 | 1.73e-05 | *** |

---


Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Robust residual standard error: 1.12

Multiple R-squared: 0.7706, Adjusted R-squared: 0.7419

Convergence in 9 IRWLS iterations

# Residuos vs. predichos en el ajuste robusto



OUTLIERS

```
> sallmrob$rweights
```

|           |           |           |           |           |           |
|-----------|-----------|-----------|-----------|-----------|-----------|
| 1         | 2         | 3         | 4         | 5         | 6         |
| 0.9936808 | 1.0000000 | 1.0000000 | 1.0000000 | 0.0000000 | 1.0000000 |
| 7         | 8         | 9         | 10        | 11        | 12        |
| 1.0000000 | 0.9858126 | 0.9935983 | 1.0000000 | 1.0000000 | 1.0000000 |
| 13        | 14        | 15        | 16        | 17        | 18        |
| 0.9906487 | 1.0000000 | 0.7482736 | 0.0000000 | 0.9498908 | 1.0000000 |
| 19        | 20        | 21        | 22        | 23        | 24        |
| 1.0000000 | 1.0000000 | 1.0000000 | 1.0000000 | 0.9984865 | 1.0000000 |
| 25        | 26        | 27        | 28        |           |           |
| 1.0000000 | 1.0000000 | 1.0000000 | 0.9999995 |           |           |

# Ventajas y desventajas del método robusto

## Ventajas

- obtenemos un estimador que es consistente y asintóticamente normal si todas las observaciones siguen el modelo lineal con errores con distribución simétrica alrededor del 0.
- si hay una pequeña proporción de outliers los estimadores no resultan muy alterados.
- no es necesario retirar outliers, ya que los resultados con o sin ellos serán similares.
- como los outliers no afectan los estimadores, es posible identificarlos.

# Ventajas y desventajas del método robusto

## Desventajas

- los cálculos y demostraciones son mucho más complicados que en el estimador de mínimos cuadrados,
- no existe una fórmula explícita para calcularlos,
- la distribución de los parámetros es asintóticamente normal, no exactamente normal, por más que los errores sean exactamente normales
- típicamente hacen falta más observaciones para obtener un buen ajuste que en el caso de mínimos cuadrados.