

1054/24



1. Introducción

Este trabajo tiene como objetivo principal el análisis y la selección del modelo de regresión más adecuado para estimar el tiempo de operación en función del peso de la carga. Se trabajó con el conjunto de datos `glakes.csv`, el cual contiene la información del tiempo requerido (Tiempo) en función del *Tonnage*(Peso).

Para este conjunto, se proponen los siguientes cuatro modelos predictivos:

- a) $\text{Tiempo} = \beta \cdot \text{Peso} + \varepsilon_i$
- b) $\text{Tiempo} = \alpha + \beta \cdot \text{Peso} + \varepsilon_i$
- c) $\log(\text{Tiempo}) = \alpha + \beta \cdot \text{Peso}^{0,25} + \varepsilon_i$
- d) $\log(\text{Tiempo}) = \alpha + \beta \cdot \text{Peso}^{0,25} + \gamma \cdot \text{Peso}^{0,5} + \varepsilon_i$

Para evaluar la precisión predictiva de cada modelo, se utilizó un enfoque de validación cruzada dejando uno afuera. El procedimiento iterativo consiste en los siguientes pasos:

- Fijar un $i \in \{1, \dots, n\}$ y obtener los coeficientes estimados que corresponden al modelo utilizando todas las observaciones salvo la i -ésima.
- Con los coeficientes obtenidos, predecir el valor de la i -ésima observación (denotada como $\hat{Y}_i$) y calcular su residuo de predicción: $r_i = Y_i - \hat{Y}_i$.
- Variar el índice i desde 1 hasta n (donde n es la cantidad total de observaciones), repitiendo los pasos anteriores para obtener el conjunto completo de residuos $r_1, \dots, r_n$.
- Obtener el estadístico de error W , calculado como: $W = \sum_{i=1}^n r_i^2$.

Importante: Para los modelos (c) y (d), las predicciones en la escala original se obtienen aplicando la función exponencial: $\hat{Y}_i = \exp\{\hat{\alpha} + \hat{\beta} \times \text{Peso}_i^{0,25}\}$ y $\hat{Y}_i = \exp\{\hat{\alpha} + \hat{\beta} \times \text{Peso}_i^{0,25} + \hat{\gamma} \times \text{Peso}_i^{0,5}\}$, respectivamente.

Finalmente, aplicando este procedimiento a cada uno de los cuatro modelos, se elegirá aquel que presente el menor estadístico W , garantizando así el modelo más adecuado para este escenario.



2. Resolución

2.1. Modelo A

$$\text{Tiempo}_i = \beta \cdot \text{Peso}_i + \varepsilon_i \quad (1)$$

El estadístico obtenido para este modelo fue de $W = 6583,148$.

Como se verá más adelante, este fue el peor resultado de los 4 calculados (con una gran diferencia).

En este modelo se toma un valor de α nulo (ordenada al origen nula). Se presume una relación proporcional entre el tiempo y el peso. Esto significa que no hay tiempos fijos. Es decir, si el peso es nulo entonces el tiempo también.

2.2. Modelo B

$$\text{Tiempo}_i = \alpha + \beta \cdot \text{Peso}_i + \varepsilon_i \quad (2)$$

El estadístico obtenido para este modelo fue de $W = 4375,183$.

En este modelo hubo una mejora muy grande respecto al anterior. Incluso llegó a asemejarse mucho más a los modelos (c) y (d) que al (a). Esto muestra la importancia del parámetro α ya que sin esta el estadístico resultó ser un 50.47 % mayor.

2.3. Modelo C

$$\log(\text{Tiempo}_i) = \alpha + \beta \cdot \text{Peso}_i^{0,25} + \varepsilon_i \quad (3)$$

El estadístico obtenido para este modelo fue de $W = 4105,534$.

Al aplicar el logaritmo a la variable dependiente, establecemos que la relación entre las variables no es constante, a diferencia de los modelos (a) y (b). Es decir, si bien el modelo estadístico sigue siendo lineal en sus parámetros, la relación entre el tiempo y el peso en su escala original deja de ser lineal. En consecuencia, el incremento del tiempo no es una cantidad fija por cada tonelada adicional, sino que es relativo a la magnitud de la operación. Si despejamos el tiempo aplicando la función exponencial, notamos que el tiempo total se calcula como el producto de tres factores exponenciales:

$$\text{Tiempo}_i = e^\alpha \cdot e^{\beta \cdot \text{Peso}_i^{0,25}} \cdot e^{\varepsilon_i}$$

Por otro lado, al elevar el peso a 0,25, implicamos que la tasa de cambio de la curva disminuye a medida que el peso aumenta.


2.4. Modelo D

$$\log(\text{Tiempo}_i) = \alpha + \beta \cdot \text{Peso}_i^{0,25} + \gamma \cdot \text{Peso}_i^{0,5} + \varepsilon_i \quad (4)$$


El estadístico obtenido para este modelo fue de $W = 4559,155$.

Este modelo extiende al modelo (c) agregando un termino adicional con su propio coeficiente, por lo que es el más flexible de los cuatro. Con tres parámetros ajusta los datos de entrenamiento al menos tan bien como el (c). Sin embargo, su W resultó un 11.05 % mayor que el modelo anterior. Esto es un indicio de sobreajuste puesto que el parámetro adicional permite acomodarse mejor a las observaciones, pero a la vez captura más ruido muestral en lugar de estructura real.

3. Gráficos



A partir de este gráfico podemos visualizar los errores absolutos mediante diagramas de caja (boxplot). Notamos claramente que el modelo (a) presente el mayor error mediano y la mayor dispersión en sus predicciones (posee la caja intercuartil más amplia), lo que lo vuelve altamente inconsistente. Por otro lado, los modelos (b), (c) y (d) muestran un comportamiento visualmente similar en términos de error absoluto mediano.



Al observar el ajuste de las predicciones sobre los datos reales, se evidencia que los modelos (a) y (b) asumen un crecimiento constante, lo que provoca que pasen muy por encima de los puntos reales en los pesos más altos. Se puede observar también que, para pesos bajos, la recta del modelo (a) pasa por debajo de casi todos los puntos. Esto se debe a que se forzó una ordenada en cero. En cambio, el modelo (c) logra curvarse y aplanarse, mostrando su eficiencia en operaciones de mayor escala. Al comparar los modelos (c) y (d), es sencillo notar que las curvas son casi indistinguibles cuando el peso está entre (aproximadamente) 2500 y 7500; sin embargo se separan en el extremo derecho porque el término adicional del (d) lo hace crecer mas rápido.



4. Conclusiones

A partir de la evaluación de los cuatro modelos propuestos mediante el cálculo del estadístico W , se concluye que el Modelo (c) es el más adecuado para estimar el tiempo de operación en función del peso.

Los modelos que aplican el logaritmo a la variable dependiente logran un mejor ajuste al comprender que los cambios en el tiempo son relativos. En particular, el Modelo (c) logra el menor error predictivo ($W = 4105,534$) gracias a la incorporación de la variable transformada $\text{Peso}^{0,25}$. Además refleja que los tiempos iniciales de operación son altos, pero a medida que el peso aumenta, el proceso se vuelve más eficiente y el tiempo requerido por cada nueva tonelada es cada vez menor (la curva de crecimiento se aplanan).

En definitiva, el Modelo (c) definido por la ecuación $\log(\text{Tiempo}_i) = \alpha + \beta \cdot \text{Peso}_i^{0,25} + \varepsilon_i$ es la mejor elección.