

Trabajo Práctico

Selección de modelos de regresión mediante LOOCV

Introducción a la Estadística y Ciencia de Datos

Dino Bronfman Joy Yamila Shih Rodrigo Quirno Costa

Facultad de Ciencias Exactas y Naturales – UBA

Introducción

Objetivo: seleccionar, entre cuatro modelos de regresión, el que mejor predice el tiempo de operación (Time) a partir del peso (Tonnage), usando los datos de `glakes.csv`.

Modelos propuestos:

- a) $\text{Tiempo} = \beta \cdot \text{Peso} + \varepsilon_i$
- b) $\text{Tiempo} = \alpha + \beta \cdot \text{Peso} + \varepsilon_i$
- c) $\log(\text{Tiempo}) = \alpha + \beta \cdot \text{Peso}^{0.25} + \varepsilon_i$
- d) $\log(\text{Tiempo}) = \alpha + \beta \cdot \text{Peso}^{0.25} + \gamma \cdot \text{Peso}^{0.5} + \varepsilon_i$

Criterio de selección: validación cruzada dejando uno afuera (LOOCV), resumida en el estadístico

$$W = \sum_{i=1}^n r_i^2, \quad r_i = Y_i - \hat{Y}_i,$$



donde $\hat{Y}_i$ se obtiene ajustando el modelo *sin* la observación i . Se elige el modelo con menor W : es el que mejor predice datos que no participaron del ajuste.

Implementación: la función `calcular_W`

```
calcular_W <- function(formula, predecir_obs, data) {  
  n <- nrow(data)  
  Y_hat <- rep(0, n) # vector de valores predichos  
  r <- rep(0, n) # vector de residuos  
  
  for (i in seq_len(n)) { # LOOCV  
    model <- lm(formula, data = data[-i, ]) # sin la i-esima obs  
    Y_hat[i] <- predecir_obs(coef(model), data, i)  
    r[i] <- data$Time[i] - Y_hat[i]  
  }  
  
  list(W = sum(r^2), residuos = r)  
}
```

La función es **genérica**: recibe la fórmula de cada modelo y una función `predecir_obs` que devuelve la predicción en la escala original. Esto permite comparar los cuatro modelos con el mismo código, incluso los que ajustan sobre $\log(\text{Tiempo})$.

Análisis gráfico



- **Curvas ajustadas:** (a) y (b) imponen un crecimiento lineal y sobreestiman el tiempo para los pesos altos; el modelo (c) se curva y se aplanan, acompañando la forma de los datos.
- **Boxplot del error absoluto:** (a) presenta el mayor error mediano y la mayor dispersión, mientras que (b), (c) y (d) resultan comparables a simple vista. Para distinguirlos hace falta el criterio cuantitativo.

Resultados

Modelo	Ecuación	W
(a)	$T = \beta \cdot P$	6583,148
(b)	$T = \alpha + \beta \cdot P$	4375,183
(c)	$\log(T) = \alpha + \beta \cdot P^{0,25}$	4105,534
(d)	$\log(T) = \alpha + \beta \cdot P^{0,25} + \gamma \cdot P^{0,5}$	4559,155

- (a) es claramente el peor: al forzar la recta por el origen, su W resulta un 50,47 % mayor que el de (b).
- (c) alcanza el menor error: el logaritmo modela cambios *relativos* en el tiempo, y el exponente 0,25 suaviza el crecimiento en la escala de los pesos grandes.
- (d) es más flexible, pero su W supera en un 11,05 % al de (c). Es un caso de **sobreajuste**: el parámetro extra captura ruido muestral en lugar de estructura real.

Conclusiones

- Según el criterio de LOOCV y el estadístico W , el **Modelo (c)** es el más adecuado para estimar el tiempo de operación en función del peso ($W = 4105,534$).
- Los modelos con logaritmo en la variable respuesta ajustan mejor: reflejan que los tiempos iniciales son altos, pero que el proceso gana eficiencia a medida que el peso aumenta.
- Mayor complejidad no garantiza mejor predicción: el modelo (d) predice peor que (c). Es el compromiso sesgo-varianza: un modelo más flexible se pega al ruido de la muestra y generaliza peor.

Modelo elegido

$$\log(\text{Tiempo}_i) = \alpha + \beta \cdot \text{Peso}_i^{0,25} + \varepsilon_i$$